



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

이학석사 학위논문

인공지능 거버넌스와
정책형성과정 연구

- 윤리 규범 형성에서부터 법제화까지 -

2024년 8월

서울대학교 대학원
과학학과 과학정책전공
김 지 원

인공지능 거버넌스와 정책형성과정 연구

- 윤리 규범 형성에서부터 법제화까지 -

지도교수 김 정 은

이 논문을 이학석사 학위논문으로 제출함
2024년 8월

서울대학교 대학원
과학학과 과학정책전공
김 지 원

김지원의 석사 학위논문을 인준함
2024년 8월

위 원 장 _____ 천 현 득 (인)

부위원장 _____ 김 정 은 (인)

위 원 _____ 박 상 욱 (인)

국문초록

본 연구는 정책과 정책 행위자가 상호작용하며 인공지능 윤리 거버넌스를 구축해 나가는 과정을 설명하고 그 특성을 파악하고자 한다. 인공지능 기술이 빠르게 발전함에 따라 인공지능 기술과 관련한 사회적 · 윤리적 문제도 급격히 증가한다. 이에 따라 기술의 개발 단계에서부터 인공지능의 윤리성을 확보할 수 있는 인공지능 거버넌스의 필요성이 대두된다. 인공지능의 개발부터 사용까지 영향을 미치는 국가 차원의 인공지능 정책은 인공지능 거버넌스 구축에 큰 영향을 미친다. 국가 차원의 인공지능 정책형성이 어떻게 이루어져 왔는지를 분석하여 그 특성과 함의를 찾아내는 것은 앞으로 구축해야 할 인공지능 거버넌스 형성에 필수적이다.

이를 위해 본 연구는 정책과 정책 행위자의 상호작용 및 정책네트워크의 행위자 관계성에 주목하여 인공지능의 사회적 · 윤리적 부작용을 최소화하기 위한 규범적 접근이 정책에 반영되는 현상을 분석한다. 특히 한국에서 인공지능 윤리 정책을 담당하는 과학기술정보통신부를 중심으로, 2016년~2023년 사이 정부의 주요 정책을 파악한다. 또한 해당 정책형성과정에 참여한 주요 행위자를 정부, 전문가, 기업 및 협회, 시민단체로 파악하여 분석 대상으로 삼는다. 방법론으로는 집합적 사례연구, 문헌 연구, 반구조화 면접을 사용하여 분석을 진행한다. 또한 사회기술시스템과 정책네트워크를 이론적 배경으로 삼고 주요 정책의 배경, 목적, 내용 등을 분석하고 주요 정책 행위자의 권력 분포, 행위자 선호, 상호작용 유형을 유기적으로 분석한다.

결과적으로 정책 흐름에 따라 정책네트워크가 변화하고 집단 간의 관계성이 정책 변화를 일으키는 중요한 요인이라는 것을 확인한다. 한국의 정책 흐름은 2016년 이후의 윤리강령, 2020년 이후의

법제도 정비 2023년 이후의 인공지능 기본법안 마련에 초점을 두어 진행되었다. 정책 흐름에 따라 형성된 정부, 전문가, 기업 및 협회, 시민단체 집단으로 이루어진 정책네트워크는 다시 정책에 영향을 미치며 정책 변화를 이끌어 냈다. 본 연구의 결과는 한국의 인공지능 거버넌스와 정책형성과정을 이해하고 더욱 효과적인 인공지능 정책 수립을 위한 정책적 함의를 제공한다.

주요어 : 인공지능 거버넌스, 인공지능 정책형성과정, 한국 인공지능 정책, 인공지능 윤리, 정책네트워크, 사회기술시스템
학 번 : 2022-26945

목 차

제 1 장 서론	1
제 2 장 이론적 배경 및 선행문헌 분석	6
1. 이론적 배경	6
1-1. 사회기술시스템(Socio-technical Systems) 관점에서 본 기술과 사회의 공진화	6
1-2. 정책네트워크(Policy Networks) 관점의 행위자 관계성과 정책형성과정	9
2. 선행문헌 분석	15
2-1. 인공지능 윤리(AI Ethics)	15
2-2. 인공지능 거버넌스(AI Governance)	27
제 3 장 방법론 및 분석틀 설계	42
1. 방법론	42
2. 분석틀 설계	47
제 4 장 인공지능 거버넌스와 정책형성과정 분석	51
1. 주요 인공지능 정책 분석	51
1-1. 지능정보 정책	53
1-2. 인공지능 정책	58
1-3. 디지털 정책	68
1-4. 한국 인공지능 정책 분석 정리	78
2. 주요 인공지능 정책 행위자 분석	80
2-1. 권력 분포	81
2-2. 행위자 선호	88
2-3. 상호작용 유형	100
2-4. 한국 인공지능 정책네트워크 특성	107
3. 한국 인공지능 거버넌스 및 정책형성과정 특성	111

제 5 장 결론 및 정책적 함의	114
참고문헌	118

표 목 차

<표 1> 정책네트워크 주요 분석요소	12
<표 2> 탈중앙화와 재생에너지원에 대한 정책 입장 파악 지표 ·	14
<표 3> 인공지능 윤리 물결	26
<표 4> 인공지능 거버넌스 발전의 세계적 흐름	31
<표 5> 과학기술정보통신부 주요 인공지능 정책	45
<표 6> 주요 인공지능 정책 행위자	46
<표 7> 반구조화 면접 내역	46
<표 8> 정책형성과정 분석을 위한 주요 정책과 주요 행위자 분석 ·	48
<표 9> 행위자 선호 분석틀	49
<표 10> 정책네트워크 분석 보조 자료	50
<표 11> 한국 인공지능 정책 변화에 영향을 준 주요 사건 ····	72
<표 12> 과학기술정보통신부의 주요 인공지능 정책 분석	72
<표 13> 한국 인공지능 정책네트워크의 행위자 선호	98

그 립 목 차

[그림 1] 인공지능의 성능 향상 속도	2
[그림 2] 사회기술시스템의 상호연관된 분석의 차원: 사회기술시스 템, 제도, 행위자	8
[그림 3] 정책네트워크 분석 요소	12
[그림 4] 인공지능 윤리 문서에서 가장 많이 언급된 인공지능 윤 리적 가치	19
[그림 5] 인공지능 원칙 문서 연대표	34
[그림 6] 주요 인공지능 정책 구조	77
[그림 7] 한국 인공지능 정책네트워크의 행위자 선호 그래프	99


[그림 8] 한국 인공지능 정책네트워크	110
[그림 9] 한국 인공지능 윤리 거버넌스 및 정책형성과정 특성	113

제 1 장 서론

인공지능(Artificial Intelligence, AI)¹⁾ 기술이 빠르게 발전함에 따라 인공지능 기술과 관련한 윤리적 · 사회적 문제 발생도 급격히 증가하고 있으므로 이에 대응하기 위한 노력이 시급하다(BBC, 2023 May). 인공지능 기술은 2010년대 이후 비약적인 발전 속도를 보인다. 인공지능의 발전을 이끄는 주요 요소는 알고리즘 혁신, 데이터, 컴퓨팅 성능이다. 그중 컴퓨팅 성능의 발전 속도를 보이는 [그림 1]을 보면 2012년 이후로 인공지능 기술이 급속도로 발전함을 알 수 있다.²⁾ 인공지능 기술이 빠르게 발전하고 서비스가 확대됨에 따라 사회적 · 윤리적 문제도 빠르게 증가한다. 차별 및 공정성 문제, 투명성 문제, 해악 금지 문제, 프라이버시 문제 등과 이에서 파생되는 더욱 구체적인 문제인 자율주행 시스템 문제, 자율 살상 무기 시스템 문제, 민감 특성을 기반으로 한 생체 인식 분류 시스템 문제, 일자리 문제 등이 있다(Russell et al., 2015; Jobin et al., 2019; High-Level Expert Group on Artificial Intelligence, 2019; UNESCO, 2021). 대표적으로 2015년에 구글 포토(Google Photos)가 미국의 흑인 남성이 친구와 함께 찍은 사진을 ‘고릴라(Gorillas)’로 자동 분류하여 인종차별 논란을 일으킨 사건, 2018년 아마존(Amazon)의 인공지능 채용 프로그램이 ‘여성’과 관련된 단어가 포함된 이력서에 감점을 주는 것이 확인되어

1) 인공지능은 기계를 지능적으로 만들고자 하는 시도에서 출발하여 인간의 사고 작용을 연구하고 인간의 지능을 연구하는 것을 통해 인간처럼 기계가 문제를 풀 수 있도록 연구하는 분야이다. 이때 지능은 개체가 주변 환경에서 적절하고 예지력을 가지고 기능할 수 있도록 하는 품질, 인간이 그렇게 행동한다면 지능적이라고 할 수 있는 방식으로 기계가 행동하는 것을 말한다. (McCarthy et al., 1955; Nilsson, 2009; Russell and Norvig, 2016).

2) 알고리즘 혁신과 데이터 혁신은 추적하기 어렵지만 컴퓨팅 성능은 정량화할 수 있으므로 인공지능 발전 속도를 측정하는 데 사용될 수 있다. (OpenAI, <https://openai.com/research/ai-and-compute>, 최종 접속일: 2024.4.2.).



[그림 1] 인공지능의 성능 향상 속도 (※출처: OpenAI, ‘AI and compute’, <https://openai.com/research/ai-and-compute>, 최종 접속일: 2024.4.3.) (페타플롭(Petaflop)은 1초당 1,000조 번의 수학 연산처리를 뜻한다. Petaflop/s-days는 하루 동안 초당 1페타플롭의 속도로 수행되는 부동 소수점 연산 횟수를 뜻한다.)

성차별 논란으로 폐기된 사건, 이미지 생성 인공지능인 스테빌리티 AI(Stability AI)의 스테이블 디퓨전(Stable Diffusion)과 오픈AI(OpenAI)의 달리(DALL-E)가 유색인종과 여성에 대한 고정관념을 증폭하는 이미지를 생성하여 인종차별과 성차별 문제를 모두 일으킨 사건(Nature, 2024 March) 등이 있다. 한국의 경우, 2021년에 실제 카카오톡 대화 내용 약 100억 건을 토대로 개발된 스캐터랩의 인공지능 챗봇 ‘이루다’가 개발 과

정에서 개인정보 처리를 명확히 하지 않아 개인정보보호위원회가 과징금과 과태료 등 제재 처분을 한 사건이 대표적이다. 또한 재취업 컨설팅 기업인 챌린저, 그레이앤드크리스마스(Challenger, Gray & Christmas)에 따르면 2023년 5월부터 2024년 1월까지 인공지능으로 직장을 잃은 사람이 4,628명이고 IBM CEO 아르빈드 크리슈나는 향후 5년간 인공지능으로 대체 가능성이 있는 분야는 채용을 중단하려 한다고 밝혔다(조선일보, 2024. 2.).

인공지능 기술이 야기하는 다양한 문제를 미리 파악하고 그에 대응하기 위해서는 기술의 개발 단계에서부터 윤리성을 확보할 수 있는 인공지능 거버넌스가 필요하다. 기술은 대개 비가역적인 특성이 있고 윤리적 사항을 고려하지 않은 기술 개발의 경우 사회적 수용성을 확보하지 못하는 특성이 있으므로 기술의 개발 단계에서부터 윤리적 고려가 함께 이루어질 필요가 있다.

인공지능 기술의 사회적·윤리적 문제가 심화됨에 따라 이에 대처하기 위한 노력이 다양한 층위에서 이루어진다(Fjeld et al., 2020). 세계적으로 시민단체 차원, 기업 차원, 국가 차원, 국제기구 차원 등의 대응이 펼쳐진다. 시민단체 차원으로는 인권과 프라이버시 문제를 다루던 곳들을 중심으로 활동이 펼쳐진다. 기업 차원에서는 인공지능 기술을 선도하던 빅테크 기업 위주로 인공지능의 윤리적, 사회적 문제에 대응하기 위한 움직임이 포착된다. 국가 차원에서는 정책적으로 기술 육성 및 산업 진흥과 함께 규제를 어떻게 할 것인지에 대한 움직임이 파악된다. 국제기구 차원에서는 인공지능 관련 문제에 대응한 가이드라인과 지침 및 표준 등을 제시하고 회원 국가들이 연합하여 인공지능에 대한 대응을 어떻게 할 것인지에 대한 대응을 마련한다.

특히 그중에서도 인공지능 생태계에 가장 큰 영향을 미치는 것은 국가 차원의 정책이다. 개발부터 사용까지의 각 단계에서 인공지능을 윤리적 방향성에 맞춰 개발하고 사용하도록 돕는 정책이 뒷받침되어야 인공지능의 부작용을 최소화하는 강건한 인공지능 거버넌스를 만들 수 있다.

따라서 국가 차원의 인공지능 정책을 분석하여 그 특성과 함의를 찾아내는 것은 앞으로 구축해야 할 인공지능 거버넌스 형성에 필수적이다.

한국은 인공지능 기술과 연구 상위 10개국 안에 포함되는 국가이자 인공지능 기술을 국가혁신 기술로 삼고 꾸준히 투자해 온 국가이다.³⁾ 인공지능 기술의 주요국 중 하나인 한국은 인공지능 기술과 산업의 혁신 그리고 인공지능의 사회적 · 윤리적 부작용을 최소화하기 위한 윤리를 모두 주요한 정책 기조로 택하고 있는 국가이다. 한국의 인공지능 정책은 산업의 진흥과 기술의 부작용 억제를 위한 노력이 어떻게 상호작용하며 이루어지는지를 볼 수 있는 좋은 사례이다. 따라서 본 연구에서는 한국의 인공지능 정책 사례를 분석한다.

기존 인공지능 거버넌스 선행 연구는 주로 윤리 문서에 집중하거나 규제에 집중하여 전반적인 국가 정책을 보지 못한다는 한계가 있다. 기존 인공지능 거버넌스 문헌에서는 인공지능 정책형성과정에 초점을 두어 정책과 행위자가 상호작용하며 거버넌스를 구축해 가는 과정을 보인 연구를 찾아보기 어려웠다. 인공지능 거버넌스는 정책뿐만 아니라 행위자와 상호작용하여 형성된다는 점에서 다양한 차원의 정책과 행위자에 초점을 두어 분석할 필요성이 있다. 따라서 본 논문에서는 인공지능 기술의 발전과 함께 대두되는 사회적 · 윤리적 문제를 최소화하기 위한 규범적 접근이 한국의 인공지능 거버넌스와 정책형성과정에 반영되어 온 양상을 분석한다. 특히 한국의 종합적인 인공지능 윤리 정책의 논의를 이끌어 온 과학기술정보통신부를 중심으로 정부 정책을 파악하고 해당 정책의 정책형성과정에 참여한 정책 행위자를 분석 대상으로 삼아 한국 인공지능 정책형성과정을 분석한다.

본 논문은 1장 서론, 2장 이론적 배경 및 선행문헌 분석, 3장 방법론 및 분석틀 설계, 4장 인공지능 거버넌스와 정책형성과정 분석, 5장 결론

3) 임대준. (2023. 11.). AI타임스. 한국, 인공지능 국가 순위서 7위...중국·싱가포르 이어 아시아 3번째. <https://www.aitimes.com/news/articleView.html?idxno=155408> (최종 접속 일: 2024. 5. 30.)

및 정책적 함의로 구성되었다. 2장 이론적 배경 및 선행문헌 분석에서는 본 연구의 이론적 배경을 살펴보고 선행문헌을 분석한다. 본 연구에서는 인공지능 기술이 사회적 측면과 상호작용하여 형성된다는 사회기술시스템의 이론에 바탕을 두고 사회적 측면인 제도와 행위자를 분석한다. 또한 제도와 상호작용 하는 행위자를 파악하기 위해 정책네트워크 이론을 바탕으로 분석을 진행한다. 선행문헌 분석 부분에서는 인공지능의 윤리와 거버넌스를 연구한 문헌들을 살펴본다. 정책에서 다루어지는 인공지능 윤리가 무엇이고 그 논의가 어떻게 발전되어 왔는지를 검토한다. 또한 인공지능 연구 · 개발이 역사적으로 이루어져 온 맥락, 인공지능의 부작용을 막기 위한 윤리적 논의와 거버넌스가 이루어져 온 흐름을 선행문헌 분석을 통해 제시한다. 3장 방법론 및 분석틀 설계에서는 본 연구에서 사용한 방법론과 분석의 바탕이 될 분석틀을 설계한 내용을 제시한다. 본 연구에서는 한국의 인공지능 정책형성과정 분석을 위해 질적연구를 연구 방법론으로 삼고 그중에서도 집합적 사례연구, 문헌연구, 반구조화 면접을 주요 방법론으로 사용한다. 또한 정책형성과정 분석을 위해 이론적 배경에서 살펴본 사회기술시스템 이론과 정책네트워크 이론을 사용하여 분석틀을 설계한다. 4장 인공지능 거버넌스와 정책형성과정 분석에서는 3장의 방법론과 분석틀을 바탕으로 인공지능 정책형성과정을 분석한다. 우선 과학기술정보통신부를 중심으로 파악한 정부의 주요 인공지능 정책을 분석한다. 이후 해당 정책형성과정에 참여한 주요 인공지능 정책 행위자를 식별하고 그들의 정책네트워크를 분석한다. 정책과 행위자 분석을 바탕으로 한국 인공지능 정책형성과정에서 정책과 행위자가 어떻게 상호작용하며 한국의 인공지능 거버넌스를 형성하고 있는지를 제시한다. 5장 결론 및 정책적 함의에서는 본 연구의 결론과 정책적 함의를 제시한다. 본 연구의 결과를 요약하고 연구를 통한 인공지능 거버넌스에 대한 정책적 함의를 제시한다. 이후 연구의 한계 그리고 향후 연구 방향을 제시한다.

제 2 장 이론적 배경 및 선행문헌 분석

1. 이론적 배경

1-1. 사회기술시스템(Socio-technical Systems) 관점에서 본 기술과 사회의 공진화


사회기술시스템(Socio-technical Systems)이란 기존의 혁신 시스템(Innovation Systems)에서 발전한 논의로 기술의 생산과 확산뿐만 아니라 사용을 포괄하고 사용자 측면을 분석에 명시적으로 포함하여 기술의 사회적 측면과 규범성을 고려하는 시스템을 말한다(Geels, 2004). 사회기술시스템은 혁신연구 및 혁신시스템 접근(Innovation Studies and Innovation System Approaches), 진화경제학(Evolutionary Economics), 과학기술학(Science and Technology Studies), 조직이론(Organization Theory) 등을 통합한 연구이다. 사회기술시스템에서는 과학 기술과 사회의 상호작용 그리고 기술의 공급과 수요 측면의 상호작용을 시스템 관점에서 통합하며 시스템 분석에서 지속가능한 목표와 같은 바람직한 방향으로의 변화를 목적으로 한다(Elzen et al., 2004; 송위진, 2013; 박상욱, 2013).

사회기술시스템은 본 연구의 이론적 배경으로 중요한데 그 이유는 다음과 같다. 첫째, 사회기술시스템은 분석에 사용자 측면을 명시적으로 통합한다. Elzen et al.(2004)은 “기술은 독자적으로 존재하는 것이 아니라 기술의 사용과 사회적 측면에 맞게 조정”되고 “사회기술시스템은 ‘공진화’ 방식으로 발전한다”라고 주장하였다. 기존의 혁신시스템 연구는 혁신이 일어나는 공급 측면에 초점을 두어 연구를 진행하였다. 대표적으로 특정 산업 분야에서 혁신이 발생하는 방식과 프로세스를 분석하는 산업

혁신시스템(Sectoral Systems of Innovation), 특정 기술 분야의 혁신이 발생하는 방식과 프로세스를 분석하는 기술시스템(Technological System), 대규모 인프라 및 기술 시스템의 발전과 운영을 연구하는 대규모기술시스템(Large Technical System)이 있다. 사회기술시스템 관점에 따르면 기술과 사회는 함께 공동구성되고 기술, 지식, 산업구조를 포함하는 공급 측면과 사용자 선호, 문화, 제도, 인프라 등을 포함하는 사용 측면이 상호작용하며 변화한다.

둘째, 사회기술시스템은 시스템, 행위자(Human actors, Organisations, Social groups), 제도(Rules, Institutions)를 구분하고 시스템, 행위자, 제도의 상호작용에 주목한다. 사회기술시스템은 “특정 사회적 기능(예: 물과 에너지 공급)의 수행을 가능하게 하는 고도로 제도화된 구성으로 제도적 요소와 기술적 요소가 공진화하는 과정을 연구”한다(Fuenfschilling & Truffer, 2016). Geels(2004)는 “사회기술시스템은 자율적으로 기능하는 것이 아니라 인간 행위자, 제도와 상호작용을 통해 서로 영향을 미치며 기능”한다고 주장한다. 이때 사회기술시스템은 사회 기능을 수행하는 데 필요한 자원, 물질적 측면을 말한다. 이때 기술은 이 기능을 수행하기 위한 중요한 요소이기 때문에 하위 기능은 기술의 생산, 확산, 사용으로 구분되고 사회기술시스템은 인공물, 지식, 자본, 노동, 문화적 의미 등으로 구성된다. 사회기술시스템의 상호 연관된 분석의 차원은 [그림 2]와 같다. 제도는 행위자의 인식과 상호작용을 인도하고 행위자들은 제도를 만들고 전달한다. 이 과정을 통해 제도와 행위자가 상호작용한다. Geels(2004)는 기존 연구가 제도를 관성과 안정성의 특성을 가진 것으로만 설명하는 것을 비판하며 제도의 역동성에 주목한다. 제도는 행위자와 시스템과 상호작용하며 변화한다. Geels(2004)에 따르면 제도는 규제적(Regulative), 규범적(Normative), 인식적(Cognitive) 제도로 나뉜다. 규제적 제도는 행동이나 상호작용을 제약하는 명시적이고 공식적인 규칙으로 강제와 처벌을 통해 작동한다. 규범적 제도는 가치, 규범, 역할 기대치, 의무, 권리, 책임을 부여하는 것으로 규범적 압력과 같은 사회적 제재를

통해 작동한다. 인식적 제도는 우선순위, 지식체계, 신념체계를 말하며 모방과 학습을 통해 작동한다. Geels(2004)는 사회기술시스템을 구성하는 행위자에 기업과 산업의 행위자뿐만 아니라 사용자, 사회단체, 공공기관, 연구기관과 같은 사회 측면의 행위자도 포함한다. 또한 각 사회집단은 특정 인식, 문제 의제, 규범, 선호도 등을 공유하며 각 집단은 다른 그룹과 상호작용하며 네트워크를 형성한다.



[그림 2] 사회기술시스템의 상호연관된 분석의 차원: 사회기술시스템, 제도, 행위자 (※ 출처: Geels, 2004)

셋째, 사회기술시스템은 바람직한 방향으로의 발전을 내포하며 규범적인 방향을 설정한다. 사회기술시스템이 내포하고 있는 규범성과 가치지향적 특성은 바람직한 사회를 만들고자 하는 목표를 가진 정책 부문과도 활발히 상호작용한다(송위진, 2013). 예를 들어 Elzen et al.(2004)은 시스템 혁신을 통한 지속가능성 전이를 다룬다. 이때 사회기술시스템은 기존 시스템의 문제를 분석하고 파악하여 지속가능한 사회기술시스템으로의 전이를 만들기 위해 분석된다. Lindberg et al.(2019)은 유럽연합의 에너지 정책과 행위자 분석을 통해 지속가능한 전이 경로를 연구하였다.

본 연구는 사회기술시스템론에 다음과 같은 이론적 배경을 둔다. 우선 기술은 단독으로 존재하는 것이 아니라 사회와 영향을 주고받으며 상호작용하는 사회기술시스템 안에서 존재하므로 기술과 사회의 공진화를 설명하는 사회기술시스템적 접근 방식이 필요하다. 따라서 본 연구는 인공

지능 사회기술시스템의 사회 측면인 제도와 행위자에 집중하여 분석을 진행한다. 다음으로 사회기술시스템은 제도와 행위자를 독립된 분석으로 보는 관점을 넘어 제도와 행위자의 상호작용에 주목한다. 사회기술시스템은 제도는 안정성을 갖는 것이 아니라 행위자와 상호작용하며 역동성을 갖는 것으로 본다. 인공지능 정책도 안정성을 가지고 형성되는 것이 아니라 그 과정에서 다양한 행위자와 상호작용하며 역동적으로 형성된다는 점에서 정책과 행위자의 상호작용을 파악하는 것은 중요하다. 마지막으로 정책은 바람직한 사회를 이룩하려는 목표를 가진다(정정길 외, 2010). 사회기술시스템은 지속가능성과 같은 규범적 방향을 설정하는데 이러한 방향성은 바람직한 사회를 만들기 위한 인공지능 정책을 분석하기 위한 이론적 배경으로 중요하다.

1-2. 정책네트워크(Policy Networks) 관점의 행위자 관계성과 정책 형성과정

정책네트워크(Policy Networks)는 “서로 다른 행위자 간의 관계, 특히 서로 다른 이익집단과 정부 간의 관계를 반영하는 모델”이다(Marsh & Rhodes, 1992). 정책네트워크 이론은 본 연구에 행위자의 관계성과 정책의 형성 과정을 설명하는 이론적 배경이 된다. 우선 해당 모델은 정책 문제 또는 정책 프로그램을 중심으로 형성되어 정책 행위자 간의 다소 안정적인 상호의존적 관계를 보이는 것을 전제한다(Adam & Kriesi, 2019). 이러한 정책네트워크의 특성은 인공지능 윤리 정책네트워크에서 행위자 간의 관계성을 파악하기 위한 좋은 이론적 배경을 제공한다. 다음으로 정책네트워크는 정책형성과정의 숨겨진 관계를 드러낼 수 있는 도구로 정책네트워크가 정책형성과정에 영향을 미치는 것을 전제한다(Marsh & Smith, 2000). 이러한 특성은 인공지능 윤리 정책형성과정에 참여하는 행위자를 중심으로 정책의 형성 과정을 설명하기 위한 이론적

배경을 제공한다. 마지막으로 정책네트워크 분석은 개인 차원의 미시적 수준과 국가 차원의 거시적 수준 사이에 있는 중급이론이다(Marsh & Rhodes, 1992; Dowding, 1995). 정책네트워크의 유형은 Jordan(1981)에 따르면 철의삼각, 이슈네트워크, 조합주의로 나뉘고 Rhodes(1988)에 따르면 폐쇄적인 정책공동체부터 전문가네트워크, 정부간네트워크, 생산자네트워크, 이슈네트워크까지 여섯 가지로 나뉜다. Dowding(1995)은 정책네트워크를 일반 범주로 그리고 정책공동체와 이슈네트워크와 같은 분류를 하위 범주로 본다. 따라서 해당 모델은 개별 행위자가 모여 집단을 이루어 형성되는 한국 인공지능 윤리 정책네트워크를 분석하기에 적절하다.

정책네트워크 이론을 정책형성과정 설명에 적용한 연구는 다음과 같다. Marsh & Smitch(2000)은 정책 결과를 설명하기 위해 정책네트워크 모델을 가져오는데 네트워크와 정책 결과 사이에는 네트워크의 구조와 그 안의 정책 행위자, 네트워크와 네트워크의 작동 맥락, 네트워크와 정책 결과라는 세 가지 상호작용이 존재한다고 주장한다. Kriesi et al.(2006)는 서유럽 7개 국가의 정책네트워크 비교를 위해 정책네트워크의 분석 요소를 권력 분포와 상호작용 유형을 제시한다. Normann(2017)은 에너지 전이에서 정책네트워크의 작용을 소개하는데 네트워크 구조, 네트워크 상호작용, 행위자 이익과 자원, 정책 결과가 상호작용하여 정책이 결정됨을 보인다. Creutzburg & Lieberherr(2021)는 스위스 산림 정책에서 드러나는 행위자 사이의 정책 입장에 대한 갈등을 정책네트워크로 분석하는데 행위자들의 정책 선호도와 인식된 중요성 및 정보 공유가 상호작용하여 정책결과로 이어짐을 주장한다. König & Bräuninger(1998)은 독일 노동 정책 영역에서 정책네트워크 형성에 대한 실증 분석을 통해 선호, 제도, 정보와 교환 관계의 행위자 선택이 상호작용하며 정책네트워크를 형성하는 것을 보인다. 또한 해당 연구는 선호의 유사성에 의해 정책네트워크 접촉 선택이 이루어지고, 이는 제도적 환경


에 의해 제한된다고 주장한다.

Marsh & Smitch (2000), Kriesi et al.(2006), Normann(2017), Adam & Kriesi(2019), Creutzburg & Lieberherr(2021), König & Bräuninger(1998)의 문헌을 통해 정책네트워크의 주요 분석 요소를 권력 분포, 상호작용 유형, 행위자 선호로 파악하였다(<표 1> 참고). “행위자의 선호를 조사하는 것, 네트워크 내 상호작용, 권력 차원을 통합하는 것”이 정책네트워크 분석에 중요하다(Creutzburg & Lieberherr, 2021). 권력 분포, 상호작용 유형, 행위자 선호는 상호작용하며 정책 네트워크를 구성한다([그림 3] 참고). 권력 분포란 “권력이 한 명의 지배적 행위자 또는 행위자 연합의 손에 집중되어 있는지, 행위자 또는 행위자 연합 간에 공유되는지와 관련”이 있다(Kriesi et al., 2006). 권력 분포는 집중과 분산으로 나타난다. 상호작용 유형이란 “행위자 및 행위자 연합 간의 협력 정도”로 “정책 결정에 있어 공공 및 민간 행위자 간의 매우 다양한 패턴”을 말한다(Kriesi et al., 2006; Creutzburg & Lieberherr, 2021). Kriesi et al.(2006)은 상호작용 유형을 협력 정도에 따라 갈등, 협상, 협력으로 구분한다. 상호작용 유형은 협력 (우위), 협상 (우위), 갈등 (우위)으로 나타난다. 협상은 갈등과 협력을 모두 특징으로 하는 중간 유형 또는 양가 유형을 말한다. 행위자 선호는 행위자의 이해(interest) 그리고 행위자의 정책 입장이라는 두 가지 요소로 설명된다(König & Bräuninger, 1998). 이해가 증가할 때 다른 정책 입장을 가진 행위자들은 입장의 차이가 증가하지만, 정책 입장을 공유하는 행위자들은 입장의 유사성이 높아진다. 행위자의 정책 입장은 지지, 반대, 무관심으로 나타나는데 무관심인 경우 이해가 증가해도 두 행위자 사이의 거리에 영향을 미치지 않는다. 정책네트워크 접촉의 선택은 주로 행위자들의 선호도 유사성에 의해 결정되는데, 선호도가 유사할수록 접촉을 많이 한다(König & Bräuninger, 1998). 정책네트워크 분석을 통해 행위자 선호가 네트워크 내에서 행위자들의 권력 및 상호작용과 어떻게 관련되는지 설명할 수

있다(Knoke, 2011). 정책네트워크의 각 집단은 공유되는 특정 인식, 의제, 선호 등을 공유하고 그룹 내에서 조율이 이루어지기도 한다. 행위자 선호 파악은 네트워크 안의 각 집단을 식별하고 이를 바탕으로 권력 분포와 상호작용 유형을 파악하는 데 중요한 역할을 한다. 또한 파악된 정책네트워크가 정책 형성에 어떤 방식으로 영향을 미치는지를 파악하는 데 중요한 역할을 한다.

<표 1> 정책네트워크 주요 분석요소 (※ 출처: Kriesi et al.(2006); Adam & Kriesi(2019); König & Bräuninger, 1998)

주요 분석 요소	구분
권력 분포	집중
	분산
상호작용 유형	협력
	협상
	갈등
행위자 선호	이해
	정책 입장



[그림 3] 정책네트워크 분석 요소 (※ 출처: Normann(2017), <Fig1>; Creutzburg & Lieberherr(2021), <Fig1> 재구성)

Kriesi et al.(2006)은 권력 분포와 상호작용 유형을 파악하기 위해 평판 지표(Reputational indicators)와 네트워크 지표(Network indicators)를 제시하였다. 평판 지표란 정책네트워크의 권력 분포 및 연합의 구성을 식별하기 위한 지표를 말한다. 평판 지표를 통해 정책 행위자의 영향력과 중요성을 파악할 수 있다. 인터뷰 대상자는 정책형성과정에서 영향력이 컸던 기관을 묻는 질문을 받는다. 이를 통해 정책네트워크에서 영향력 있는 행위자를 식별할 수 있고 언급 빈도에 따라 권력 분포를 파악할 수 있다. 네트워크 지표란 정책네트워크의 상호작용 유형을 식별하기 위한 지표를 말한다. 네트워크 지표를 통해 정책 행위자들이 상호작용하면서 어떤 관계를 맺고 있는지 식별할 수 있다. 인터뷰 대상자는 자신이 영향력 있다고 파악한 각 행위자에 대해 협력, 갈등, 협상이라는 세 가지 유형의 상호작용에 대한 구체적인 질문을 받는다. Lindberg et al.(2019)은 행위자 선호를 행위자가 정책 기조에 보이는 입장을 분석하여 파악하였다. 해당 연구는 유럽연합 차원의 ‘지속가능성’을 위한 에너지 시스템 전이 경로를 파악하기 위해 지속가능성의 정도(the degree of sustainability)와 파괴성의 정도(the degree of disruption)에 대한 정책 조합(policy mix)과 행위자 선호를 분석한다. 이때 Lindberg et al.(2019)은 각 정책과 행위자가 지속가능성의 정도와 파괴성의 정도에 어떤 입장을 취하고 있는지를 파악하여 선호를 분석한다. 지속가능성의 정도와 파괴성의 정도를 분석하는 이유는 지속가능성과 파괴성이 에너지 시스템 전이의 주요 갈등 지점이고 시스템 전이 경로 분석에 행위자들의 갈등 지점에 대한 입장 파악이 중요하기 때문이다. 또한 Lindberg et al.(2019)은 각 갈등 지점에 대한 행위자 선호를 파악하는데 지속가능성의 정도는 재생에너지와 탈탄소화에 대한 입장을 통해 파악하고 파괴성의 정도는 전기 시스템의 탈중앙화에 대한 입장을 통해 파악한다 (<표 2> 참고).

선행 연구 중 인공지능 정책과 정책 행위자를 정책 네트워크의 관점에서 분석한 연구로는 홍중영과 이찬구(2022)의 중국 인공지능 산업 육성 정책네트워크를 분석이 있었고 그 이외의 연구를 찾기 어려웠다. 하

지만 신기술의 정책형성 과정을 정책네트워크의 관점으로 연구한 논문은 찾을 수 있었다. 주로 생명공학 기술의 정책형성 과정에 대한 연구를 참고할 수 있었는데 김훈기(2003)는 정책네트워크 개념을 활용해 한국의 생명윤리 법제화를 이끌어 낸 주요 요인을 분석한다. 또한 송미원과 권기창(2003)은 생명윤리의 입법화과정을 정책과정 참여 행위자들 간의 관계를 통해 분석한다. 이들 연구에서는 정책네트워크의 분석 요소로 행위자 유형, 상호작용 유형, 권력 분포, 통합성, 자원 배분 등을 파악하였다. 또한 해당 연구들은 행위자 선호를 행위자 이해 분석 혹은 상호작용 유형 분석에서 녹여내어 작성하였다. 하지만, 이 경우 행위자들이 어떤 지점에서 선호의 차이를 보이는지에 대한 명확한 파악이 어렵다는 문제가 있기 때문에 행위자의 이해와 정책 입장을 분석에 포함하여 정책네트워크를 분석하는 것이 바람직하다.

<표 2> 탈중앙화와 재생에너지원에 대한 정책 입장 파악 지표 (※ 출처: Lindberg et al.(2019), <Table4>)

탈중앙화 정도	내용
1	탈중앙화는 그 자체로 목표가 아니며 장려해서는 안 된다.
2	탈중앙화를 지원할 필요가 거의 없다.
3	어느 정도 탈중앙화를 지원해야 한다.
4	탈중앙화는 주요 목표 중 하나이며 시장 법률을 변경할 때 고려해야 한다.
재생에너지원 정도	내용
1	현재 재생에너지 전기가 충분히 보급되어 있다.
2	일부 지역에서는 조금 더 배포할 수 있지만 추가 재생에너지원 개발을 지원할 필요는 없다.
3	재생에너지원 점유율을 높이고, 재생에너지원에 대한 목표가 있는지 확인해야 한다.
4	완전히 재생에너지 전력 시스템으로의 전환이 필요하다.

2. 선행문헌 분석

2-1. 인공지능 윤리(AI Ethics)

1) 인공지능 기술의 발전과 윤리 문제

인공지능이라는 용어는 1956년 다트머스 대학에서 열린 컨퍼런스에서 인공지능이라는 용어가 공식적으로 만들어진 이래로 오래 존재해 왔음에도 불구하고 일반적으로 통용되는 정의를 찾기가 어렵다(Collins et al., 2021). 그 이유는 인공지능 기술의 복잡성과 광범위성 때문이다. 인공지능 기술은 다양한 분야에 뿌리를 두고 있고 그 사용 또한 광범위하게 이루어진다. 인공지능 기술은 철학, 수학, 경제학, 신경과학, 심리학, 컴퓨터 공학, 제어이론과 사이버네틱스, 언어학 등 다양한 학문 분야에 기반을 두고 있고 금융, 헬스케어, 법, 인지, 예술, 교육, 번역, 모빌리티 등 다양한 분야에서 사용된다. 그럼에도 각 전문가와 조직은 인공지능의 합의된 정의를 도출하기 위해 노력해 왔다. 이러한 점에서 인공지능의 정의는 협상의 결과물이다. 인공지능에 대해 합의된 정의를 찾기 어려웠기 때문에 국제사회에 파급 효과가 크고 각국 인공지능 정책에 방향과 지침을 제공하는 OECD에서는 연구와 토론을 통해 인공지능의 정의를 도출하고자 하였다. 2019 OECD 권고안(OECD, 2019)에서 각국 정부 관계자, 학계 전문가, 인공지능 관련 빅테크 기업이 참여한 OECD 인공지능 전문가 그룹(OECD Expert Group on AI, AIGO)은 회의를 통해 인공지능 정의를 다음과 같이 합의하였다. “인공지능 시스템은 인간이 정의한 명시적 또는 암묵적 목표에 따라 주어진 입력으로부터 물리적 실제 또는 가상 환경에 영향을 미칠 수 있는 예측, 콘텐츠, 추천 또는 결정과 같은 출력을 생성하는 방법을 추론할 수 있는 기계 기반 시스템이다. 다양한 AI 시스템은 배포 후 자율성과 적응성의 수준에 따라 다양하게 작동하도록

설계되었다(OECD, 2019).” 인공지능 기술 발전에 따라 합의된 정의가 수정되기도 하였다. 2024 OECD 권고안(OECD, 2024)에서는 “AI 시스템은 명시적 또는 암묵적 목표를 위해 수신된 입력으로부터 물리적 또는 가상 환경에 영향을 줄 수 있는 예측, 콘텐츠, 추천 또는 결정과 같은 출력을 생성하는 방법을 추론하는 기계 기반 시스템이다. AI 시스템마다 배포 후 자율성 및 적응성 수준이 다르다(OECD, 2024).”로 갱신되었다. 각 OECD 권고안은 국제사회에 영향을 미쳤고 대표적인 인공지능 규제 법안인 EU의 ‘인공지능 법안’에도 반영되었다. 또한 인공지능 연구 선구자인 존 매카시(John McCarthy), 존 nil슨(Nils J. Nilsson), 스텐턴 러셀(Stuart Russell)이 제시한 인공지능의 정의를 종합하면 다음과 같이 정리할 수 있다. 인공지능은 기계를 지능적으로 만들고자 하는 시도에서 출발하여 인간의 사고 작용을 연구하고 인간의 지능을 연구하는 것을 통해 인간처럼 기계가 문제를 풀 수 있도록 연구하는 분야이다. 이때 지능은 개체가 주변 환경에서 적절하고 예지력을 가지고 기능할 수 있도록 하는 품질, 인간이 그렇게 행동한다면 지능적이라고 할 수 있는 방식으로 기계가 행동하는 것을 말한다(McCarthy et al., 1955; Nilsson, 2009; Russell & Norvig, 2016). 해당 전문가들의 논의는 현재 합의되는 인공지능 정의의 기반이 되었다.

인공지능의 폭발적인 발전을 일으킨 작동 방식은 머신러닝(Machine Learning)이고 그중에서도 특히 딥러닝(Deep Learning) 방식이다. 머신러닝이란 컴퓨터가 스스로 학습할 수 있도록 알고리즘과 기술을 개발하는 분야를 말한다. 머신러닝은 이전의 일반적인 알고리즘 작동 방식이라고 할 수 있는 전문가 시스템(Expert System)⁴⁾과 구분되는 방식으로 컴퓨터에게 직접 학습을 진행시키는 방식이다. 이때 컴퓨터는 주어진 규칙을 바탕으로 문제를 푸는 것이 아니라 데이터와 정답 간의 관계에 대한

4) 전문가 시스템은 1980년대 인공지능의 첫 번째 황금기를 이끈 알고리즘 작동 방식으로 특정 영역의 전문 지식을 가진 인간 전문가의 판단 능력을 모방하는 시스템이다. 지식을 투입하여 생성된 “if-then” 형태의 규칙 집합으로 이루어진다.

학습을 진행한다. 딥러닝이란 머신러닝 방법론 중 하나로 인간 뉴런의 작동 방식을 그대로 알고리즘화하여 학습을 진행하는 방식을 말한다. 딥러닝 방식은 인간 지능을 가장 유사하게 모방하고 높은 정확성을 보인다.

인공지능 윤리 논의가 본격적으로 시작된 것은 인공지능 학습 방법 중 하나인 딥러닝의 전성기가 시작된 2012년 이미지넷 대회(ImageNet Large Scale Visual Recognition Challenge, ILSVRC: 대규모 시각 인식 챌린지) 이후이다. 이 대회에서 제프리 힌튼(Jeffrey Hinton) 교수팀의 알렉스넷(AlexNet)은 기존의 방식에서 벗어나 딥러닝 기술을 활용하여 전년도 기록과 10% 이상의 차이를 벌리며 압도적 성적으로 우승을 차지하였다. 해당 기록은 이전 기록들에 비해 비약적인 성능의 향상을 보인 기록이었다. 이후 딥러닝 알고리즘이 주류를 이루게 되고 딥러닝의 전성기가 찾아오게 되었다. 딥러닝 방식을 통한 인공지능의 폭발적인 성능 향상은 이미지 인식, 음성 인식, 자연어 처리 분야에서 비약적인 발전을 촉발하였다.

현재 촉발되는 인공지능 윤리 이슈들은 주로 머신러닝과 딥러닝 기반 시스템에서 촉발된 문제이다. 급격한 발전을 이룬 최근 인공지능의 경우 천억 개가 넘는 파라미터가 상호작용하며 모델을 구성한다는 점⁵⁾, 엄청난 데이터에 기반하여 만들어진다는 점, 인간 지능을 가장 유사하게 모방하여 높은 정확성을 가지고 인간의 결정을 대체할 수 있다는 점의 특성을 가진다. 이러한 인공지능 기술의 특성은 그에 따른 리스크 특성과 취약성을 가진다. 인공지능 모델의 복잡성으로 그 작동 방식을 설명하기 어렵다는 점에서 인공지능의 투명성과 설명가능성의 윤리 문제를 촉발한다. 또한 인공지능이 엄청난 데이터를 기반으로 학습한다는 점에서 데이터 자체 그리고 데이터로 학습한 결과에 대한 공정성과 편향성의 윤리 문제를 촉발한다. 게다가 인간 지능을 가장 유사하게 모방하여 높은 정확성을 갖는다는 점에서 인간의 결정을 대체하는 곳에 쓰이게 되고, 이


5) ChatGPT-3 기준으로 작성하였다.

는 책임성이라는 윤리 문제를 촉발한다.

Liao(2020)는 인공지능의 취약성을 머신러닝과 딥러닝 기술 자체의 취약성(Vulnerabilities in Machine Learning)과 인간 취약성(Human Vulnerabilities)으로 구분한다. 인공지능 기술 자체의 속성에 따라 기술 자체가 가지는 취약성으로는 데이터 편향의 문제, 신뢰성의 문제 등이 있다. 인공지능을 인간이 사용함에 따라 발생하는 오남용으로 인한 취약성으로는 인간 취약성을 딥페이크의 악용, 얼굴 인식을 이용한 시민 감시 문제, 자율살상무기 문제, 인간 노동 대체 문제 등이 있다. 김재선(2021)은 인공지능 리스크의 특성을 구분하고 이를 연결성, 자동성, 데이터 의존성, 모호성, 복잡성으로 나눈다. 연결성(Connectivity) 리스크는 인공지능 시스템이 악의적으로 해킹되거나 연결성이 결여된 경우와 관련된다. 자동성(Autonomy) 리스크의 경우 사전에 리스크를 인지하지 못한 경우 대응이 어렵다는 점과 인공지능의 행동을 통제하기 어렵다는 점과 관련된다. 데이터 의존성(Data-dependency) 리스크의 경우 데이터가 잘못 입력된 경우 잘못된 결과를 초래하는 경우와 관련된다. 모호성(Opacity) 리스크의 경우 책임성과도 관련되는데 손해가 발생할 경우 원인이 결합하여 나타날 수 있어서 원인을 규명하기 어렵다는 점과 관련된다. 복잡성(Complexity) 리스크의 경우 인공지능 시스템이 예측가능한 사용범위를 넘어 사용되는 경우 인간이 이를 통제하기 어렵다는 점과 관련된다.

2019년 4월까지 기관에서 발행된 84개의 AI 가이드라인 문서를 분석한 Jobin(2019)은 인공지능 윤리 문서에서 가장 많이 언급된 윤리적 가치를 투명성, 정의 및 공정, 해악 금지, 책임성, 프라이버시로 제시하였다. 이는 [그림 4]와 같다. 인공지능의 투명성 문제는 인공지능 시스템의 결정에 대한 이해가능한 설명을 제시하는 설명가능성의 문제를 포함하여 데이터 처리나 편향 그리고 모델의 한계 등에 대한 정보를 제공하는 것을 말한다. 이는 인공지능의 신뢰성 확보에 직결되는 문제로 편향을 식별하고 안전을 확보하기 위해 중요하다. 공정성과 편향성은 차별의 문제

와도 관련이 있는데 인공지능 학습데이터나 알고리즘 설계에서 편향성이 나타나지 않게 설계하고 인공지능의 모든 사용자가 불리한 편견이나 차별을 받지 않도록 하는 것을 말한다. 책임성은 자동화된 의사결정 시스템이 인간의 결정을 대체하는 경우 그 결과에 대한 책임 주체가 불분명해지는 문제가 발생하므로 이에 대한 책임 소재를 명확히 해야 함을 말한다.



[그림 4] 인공지능 윤리 문서에서 가장 많이 언급된 인공지능 윤리적 가치 (※ 출처: Jobin et al.(2019), <Table3> 재구성)

2) 인공지능 윤리 개념과 논의의 흐름

인공지능 윤리란 인공지능 기술의 신뢰성과 수용성을 확보하기 위한 사회적 합의를 말한다. 이때 인공지능 윤리의 개념은 개인적인 선악 판단과 구분되며 윤리적 인공지능을 구축하기 위한 개념으로 다루어진다. 우선 인공지능 윤리는 개인적인 선악 판단과 구분된 개념이다. EURON(2006)에 따르면 인공지능 ‘윤리(Ethics)’는 일반적으로 다른 사람과의 관계, 우리의 공적 영역과 연관되며 어떤 것을 판단하기 위해 우리가 사용하거나 제기하는 기준에 대한 연구를 말한다. 반면, ‘도덕(Morality)’은 우리 양심의 목소리, 우리 스스로와의 관계와 연관된 것으로 행동, 삶의 방식, 결정의 옳고 그름에 관한 것이다. 이상욱(2021)은 인공지능 윤리 분야를 우리 사회에서 AI에 대한 다양한 쟁점과 관련하여 제도적, 문화적으로 풀어가야 할 복합적인 문제에 대한 핵심적 가치를 탐구하는 분야로 소개한다. 여기서 말하는 윤리란 개인적인 선악 판단의 의미를 가지는 ‘윤리(倫理)’ 개념이 아니라 우리 사회에서 제도적, 문화적으로 풀어가야 할 복합적인 문제에 대한 핵심적 가치의 의미를 가지는 ‘윤리(Ethics)’ 개념을 말한다(이상욱 & 이호영, 2021). 인공지능 윤리 논의는 “AI의 산출물, 특히 인간의 지속적인 통제를 받지 않는 ‘자동화된 결정’이 기본 인권 등 우리가 소중하게 여기는 다양한 사회적 가치를 최대한 존중하는 방식으로 활용되기 위해서 어떤 점에 주목하고 어떤 방식의 제도적 대응을 수행해야 하는지에 대한 논의”이다(이상욱, 2023). 구체적으로 인공지능 윤리 분야는 차별 및 공정성 문제, 투명성 문제, 해악 금지 문제, 프라이버시 문제 등과 이에서 파생되는 더욱 구체적인 문제인 자율주행 시스템 문제, 자율 살상 무기 시스템 문제, 민감 특성을 기반으로 한 생체 인식 분류 시스템 문제, 일자리 문제 등 다양한 쟁점을 통합적으로 다루어 인공지능 기술의 신뢰성과 수용성을 확보하기 위한 사회적 합의를 바탕으로 한다.

다음으로 인공지능 윤리는 윤리적 인공지능을 구축하기 위한 논의이

다. Siau & Wang(2020)은 ‘인공지능 윤리(AI Ethics)’를 ‘인공지능의 윤리(Ethics of AI)’와 ‘윤리적 인공지능(Ethical AI)’을 구축하는 방법에 대해 고민하는 분야로 제시한다. 인공지능의 윤리란 인공지능에 필요한 윤리적 원칙이나 정책을 수립하기 위해 인공지능으로 인해 발생할 수 있는 잠재적인 윤리적 문제를 인식하고 이해하는 분야이다. 윤리적 인공지능이란 적절한 인공지능의 윤리를 바탕으로 윤리적 행동을 보이는 인공지능을 구축하는 분야를 말한다. 인공지능의 윤리가 바탕이 되어 윤리적 인공지능을 구축하게 된다. 결국 인공지능 윤리는 인공지능의 잠재적 부작용을 식별하고 기술의 개발 과정부터 적용할 수 있는 원칙을 수립하여 기술의 신뢰성과 수용성을 확보하기 위한 사회적 합의이다.

인공지능 윤리 논의는 시기에 따라 흐름을 형성한다. 흐름에 따라 주된 논의의 내용과 행위자가 변화하였다. 2016년 이후로, 본격적으로 논의되기 시작한 인공지능 윤리는 인공지능 기술의 신뢰성과 수용성을 높이기 위한 같은 목적 아래에서 그 양상이 조금씩 바뀌어 나타났다. 이러한 변화의 흐름을 인공지능 윤리 물결(Waves of AI Ethics) 또는 윤리적 인공지능 물결(Waves of Ethical AI)라고 한다(Kind, 2020; Van Wynsberghe, 2021; Georgieva et al., 2022). 기존 연구를 바탕으로 인공지능 윤리 물결의 흐름을 정리하면 다음과 같다 (<표 3> 참고).

첫 번째 인공지능 윤리 물결은 2016년에 시작되었다. 2016년은 알파고(AlphaGo)와 이세돌 9단의 대국이 열린 해이다. 알파고는 구글(Google) 딥마인드(DeepMind)가 개발한 인공지능 컴퓨터 바둑 프로그램이다. 당시 바둑은 기계가 정복하지 못한 게임으로 전문가들 사이에서도 기계가 인간을 이기는 것은 힘들 것이라는 예상이 많았다.⁶⁾ 하지만, 이 예상을 깨고 알파고는 이세돌 9단에 4대 1로 승리하였다.⁷⁾ 바둑은 인간 고유의

6) 조환규. (2016. 2.). 경향신문. *이세돌과 인공지능 알파고의 ‘반상 결투’*. <https://www.khan.co.kr/opinion/column/article/201602282045415> (최종접속일: 2024. 4. 4.).

김용영. (2016. 2.). 매일경제. *바둑 프로 6단 출신 AI 전문가, 알파고의 약점을 밝히다*. <https://www.mk.co.kr/news/sports/7241624> (최종접속일: 2024. 4. 4.).

7) 해당 대국에서 알파고는 정책망(Policy Network)과 가치망(Value Network)의 결합으

능력이라 믿어지던 직관과 추론이 작용하는 영역이라고 여겨져 왔기 때문에 알파고와 이세돌 9단의 대국 결과는 사람들에게 큰 충격을 안겨주었다. 해당 사건은 인공지능 기술에 대한 폭발적 관심과 함께 인공지능 기술이 가져올 윤리적, 사회적 부작용에 대한 우려를 촉발하였다. 또한 인공지능과 관련한 윤리 규범과 가이드라인에 대한 필요성 논의를 촉발하였다. 2019년 기준 인공지능 윤리 문건의 88%가 2016년 이후에 발행되었다(Jobin et. al., 2019). 2016년에 인공지능이 본격적으로 여론의 관심을 받게 되면서 국제적으로 인공지능 윤리에 대한 관심도 커지게 되었다. 첫 번째 인공지능 윤리 물결은 인공지능이 무엇을 할 수 있는지에 초점을 둔 논의이다. 이세돌을 이긴 알파고와 같이 인간을 이긴 로봇에 대한 위협에서 출발하여 로봇의 반란이라는 공상적 시나리오에 대한 윤리에 해당한다(Van Wynsberghe, 2021). 이때 정책 입안자들과 기술 개발자들은 앞으로 대두될 인공지능 기술의 사회적 · 윤리적 부작용을 최소화 하기 위한 방안들을 고민하게 되고 철학자와 윤리학자들에게 강령과 기준을 개발해 달라고 요청한다(Kind, 2020). 첫 번째 윤리 물결에서는 법보다 윤리에 초점을 두었으며 다양한 기관에서 인공지능의 윤리적 원칙과 가이드라인이 대거 쏟아졌다. 인공지능 윤리 기준과 가이드라인은 전반적인 인공지능의 개발 · 활용 · 사용의 방향을 제시한다는 점에서 의미가 있지만 개별 사용 사례나 애플리케이션에 필요한 구체적인 내용을 담고 있는 경우가 거의 없다는 한계를 가진다. 이로 인해 실제로 인공지능을 개발 · 활용 · 사용하는 현장에서 해당 윤리 원칙을 적용하기가 어려웠다. 또한 인공지능 기술을 선도하는 빅테크(Big Tech)가 추상적인 인공지능 윤리 원칙과 가이드라인만 내어놓고 윤리적 인공지능을 구축하기 위한 실질적인 행동을 하지 않는다는 비판이 등장하게 되었다. 즉 빅테크가 인공지능 기술의 윤리적 문제에 대응하고 있다는 것을 공개적으로 보이기 위해 추상적인 윤리 원칙만 제시하고 실질적인 행동을 하

로 만들어진 심층신경망(Deep Neural Network, DNN)이 몬테카를로 트리 탐색(Monte Carlo Tree Search, MCTS)을 통해 수를 두는 방식을 사용하였다.

지 않는다는 ‘윤리 세탁(Ethics Washing)’에 대한 비판이 거세졌다 (Jobin, 2019; Greene et al., 2019; Bietti, 2020).⁸⁾

윤리 강령의 생산과 논의가 주를 이룬 인공지능 윤리 물결의 한계점이 드러나자 2018년쯤 두 번째 인공지능 윤리 물결이 등장하였다. 인공지능 윤리 강령에 기반을 둔 논의가 인공지능의 실질적인 개발과 사용에 도움이 되는 구체적인 내용을 담고 있는 경우가 거의 없다는 비판을 바탕으로 기술적 해결에 중점을 둔 윤리 논의가 등장하였다. 당시 인공지능의 사회적 영향과 해악을 조명하는 조직인 Gender Shades는 Microsoft와 IBM이 배포한 얼굴 인식 소프트웨어가 여성과 유색인종의 얼굴에 대해 더 높은 위양성률(rate of false positives)과 위음성률(rate of false negative)을 보인다는 연구를 발표하였다. 또한 미국의 ProPublica는 탐사보도를 통해 미국 법원 재범 위험성을 예측하는 알고리즘인 COMPAS가 실제 재범하지 않을 사람을 고위험으로 잘못 분류한 비율(위양성률)은 흑인이 훨씬 높으나 실제 재범할 사람을 저위험으로 잘못 분류한 비율(위음성률)은 백인이 훨씬 높게 나타났다는 사실을 밝혔다. 이러한 배경을 바탕으로 인공지능 윤리 문제를 기술적 개입을 통해 해결해야 할 필요성이 대두되었다. 기술적 개입의 필요성으로 두 번째 인공지능 윤리 물결은 첫 번째 윤리 물결의 주요 행위자였던 철학자에 더하여 컴퓨터 과학자가 주도 하게 되었다. 당시 윤리 물결의 주요 내용은 윤리적 해악, 특히 공정성과 편견, 비차별과 관련된 문제에 초점을 두고 이를 해결하기 위한 기술적 개입을 모색하는 것이었다. 이때 공정 머신러닝(fair-ML)이라는 영역이 탄생하게 되었다. 하지만 기술적 해결에 초점을 맞춘 두 번째 윤리 물결도 한계를 드러냈다. 두 번째 윤리 물결은 인공지능의 윤리적 문제를 공정성과 정확

8) Jobin(2019)은 “다양한 이해관계자들이 AI 원칙을 발간하려는 열정적인 노력은 단순히 윤리적 가이드라인이 필요해서인 것만이 아니라 자신들의 상대적 우선순위에 맞추기 위한 방법으로 AI 윤리를 형성하는 강력한 이해관계 때문”이라고 설명하였다. Bietti(2020)는 기술 정책에서 윤리는 “규제 완화, 자율 규제 또는 무간섭 거버넌스(hands-off governance)를 지지하기 위해 무기화”되고 있고 “점점 더 기술 기업의 자율 규제 노력과 알팍한 윤리적 행동으로 인식”되고 있다고 주장하였다.

성의 좁은 기술적 해결의 문제로 한정하게 되면서 기업들이 데이터 수집 확대를 윤리적 인공지능에 대한 투자와 동일시 할 수 있게 됐다. 이로 인해 기술은 사회적 맥락을 떠나 이해할 수 없고 기술적인 해결책만으로는 사회적으로 유익한 결과를 만들 수 없다는 인식이 커졌고 기술은 사회적 맥락을 떠나서는 이해할 수 없다는 사회기술시스템적 접근 방법이 대두되었다.

세 번째 인공지능 윤리 물결은 2020년쯤에 시작되었다. 세 번째 물결은 윤리적 인공지능 연구의 시선이 기술적인 것에서 사회기술적인 것으로 바뀌었다는 점, 인공지능 윤리와 정부 정책을 연결하기 어렵다는 점이 배경이 되었다. 여전히 인공지능 기술의 윤리적 문제가 계속해서 대두되고 있었고 기업의 윤리 세척 문제가 해결되지 않고 있었다. 따라서 윤리적 문제를 해결할 수 있는 실질적인 해결에 초점을 둔 윤리 논의가 등장하였다. 우선 인공지능 윤리 원칙 혹은 기술적 해결책을 넘어 사회와 기술이 상호작용하며 발전할 수 있는 실질적인 매커니즘을 찾기 위한 노력이 이루어졌다. 세 번째 윤리 물결에서는 연구자와 활동가가 기존의 철학자, 기술자 집단에 더하여 두각을 나타냈다. 연구자와 활동가가 주도하는 세 번째 윤리 물결은 사회 정의, 인종 정의, 경제 정의 환경 정의 등의 정의 개념을 바탕으로 한 윤리적 인공지능에 대한 새로운 논의 방식과 ‘지속가능성’과 같은 규범성을 포함한 기술 발전과 사용의 가능성을 중심으로 논의가 이루어졌다(Nishant, 2020; Crawford, 2021; Van Wynsberghe, 2021; Wu et al., 2022). 하지만 세 번째 윤리 물결에도 한계가 존재한다. 사회기술적인 시선과 정의를 바탕으로 인공지능을 개발해야 한다는 인식이 아직 기술 업계 전반에서 받아들여지지 않고 있다는 점이 한계점으로 제시된다.

인공지능 윤리 물결 흐름을 통해 인공지능의 부작용을 최소화하기 위한 노력의 양상이 조금씩 변화해 왔고 주된 행위자의 구성이 중첩되며 변화하는 것을 확인할 수 있다. 이 모든 노력은 결국 인공지능 기술의 신뢰성과 수용성을 확보하기 위한 공동체적인 노력이다. 인공지능 윤리 논의

는 바람직한 인공지능 기술과 함께 살아갈 바람직한 사회를 형성하기 위한 노력이다.

하지만 위에서 살펴본 인공지능 윤리 물결 논의는 인공지능 거버넌스가 규제 거버넌스로 넘어오며 인공지능 거버넌스의 주요 행위자로 등장한 법학계와 법조계의 행위자를 담지 못하고 있다는 한계가 있다. 2021년 이후 인공지능 서비스가 본격화되면서 인공지능 일반 그리고 각 산업 분야와 관련된 인공지능 제품과 서비스에 대한 법적인 쟁점이 촉발되었다. 따라서 법, 제도, 규제 정비의 필요성이 높아졌고 인공지능의 부작용을 막기 위한 규제적 차원의 논의가 활발하게 진행되어 왔다. 이 흐름에서 법학계와 법조계 전문가가 주요한 행위자로 활동하고 있다. 또한 인공지능 윤리 물결 논의의 경우 주로 유럽과 북미의 인공지능 윤리 논의 흐름을 담고 있기 때문에 한국의 맥락에는 적용되기 힘들다. 한국도 2016년 이후에 철학자가 주도하여 인공지능의 윤리 강령과 가이드라인 등을 만들기는 하였지만 그 이후의 기술자 중심으로 이루어진 기술적 해결에 대한 움직임을 찾아보기 어렵고 활동가의 역할 또한 좀 더 늦게 등장하였다. 본 연구는 한국 인공지능 윤리 정책형성과정을 분석한다. 2016년 이후 인공지능 윤리 정책 논의가 어떻게 진행되었는지를 정책 분석과 주요 행위자 분석을 바탕으로 진행한다. 따라서 본 연구는 인공지능 윤리 흐름 논의에서 한국의 맥락을 분석하고 제시할 수 있다는 것에서 그 의미를 찾을 수 있고 유럽이나 북미 이외의 국가에서 진행되고 있는 윤리 논의의 흐름을 제시할 수 있다는 점에서 의미가 있다.

<표 3> 인공지능 윤리 물결 (※ 출처: Kind(2020); Van Wynsberghe(2021); Georgieva et al.(2022) 재구성)

윤리물결 구분	첫 번째 인공지능 윤리 물결	두 번째 인공지능 윤리 물결	세 번째 인공지능 윤리 물결
시기	2016~	2018~	2020~
주요 행위자	철학자 주도	컴퓨터 과학자 주도	연구자, 활동가 주도
축발 배경	2016년 알파고와 이세돌 대국 사건 - 정책 입안자들과 기술 개발자들은 앞으로 닥칠 피해를 어떻게 이해하고 예방할 수 있을지 고민하면서 철학자와 윤리학자들에게 강령과 표준을 개발해 달라고 요청	- Microsoft와 IBM이 배포한 얼굴 인식 소프트웨어가 여성과 유색인종의 얼굴에 대해 더 높은 위양성률과 위음성률을 보인다는 연구 등장(Gender Shades, 2018) - COMPAS 선고 알고리즘 도구에 대한 조사로 흑인 피고인이 백인 피고인보다 재범 위험이 높은 것으로 잘못 판단될 가능성이 훨씬 높게 나타난다는 사실 발견(ProPublica, 2016 May) - 기술적 개입을 통한 해결의 필요성 대두	- 윤리적 AI 연구의 시선이 기술적인 것(technical)에서 사회기술적인 것(socio-technical)으로 변화 - 인공지능 윤리와 정부 정책을 연결하기 어려움
주요 특성	법보다 윤리에 초점	기술적 해결에 초점을 맞춤	실질적인 해결에 초점을 둠
주요 내용	- AI 윤리적 원칙 또는 가이드라인이 발표 - 빠르게 발전하는 머신러닝과 AI 기능의 잠재적 위험과 위협을 막 이해하기 시작한 시기	- 윤리적 해악, 특히 공정성, 편견, 차별과 관련된 문제에 초점을 맞추고 이를 해결하기 위한 기술적 개입을 모색 ‘공정 ML(fair-ML)’이라는 영역 탄생	- 원칙과 기술을 넘어 권력 불균형을 바로잡고 개인과 사회의 정의를 실현하기 위한 실질적인 매커니즘 - 사회 정의, 인종 정의, 경제 정의, 환경 정의 등으로 정의되는 윤리적 AI에 대한 새로운 논의 방식을 중심으로 함 - 인공지능 정책을 위한 실행가능한 프레임워크와 매커니즘 제시: 알고리즘 감사, 알고리즘 영향 평가 등의 도구를 제시
한계	- 개별 사용 사례와 애플리케이션에 필요한 구체적인 내용을 담고 있는 경우는 거의 없음 - 윤리 세탁	- 윤리적 문제를 공정성과 정확성의 좁은 문제로 한정함으로써, 기업들은 데이터 수집 확대를 “윤리적 AI”에 대한 투자와 동일시할 수 있음 - 기술 시스템은 사실 사회기술시스템(socio-technical systems)이며, 그 시스템이 배치된 사회적 맥락을 떠나서는 이해할 수 없고, 기술적인 조정만으로는 사회적으로 유익하고 수용 가능한 결과를 위해 최적화할 수 없다는 인식 커짐	사회기술적인 시선과 정의를 바탕으로 한 새로운 방식이 아직 기술 업계 전반에서 받아들여지지 않고 있음

2-2. 인공지능 거버넌스(AI Governance)

1) 인공지능 기술 발전에 따른 공공과 민간의 거버넌스 변화

거버넌스(Governance)는 “네트워크와 함께 그리고 네트워크를 통치하는 것을 의미”하는 것으로 “명령 및 통제 기반의 정책 패러다임에서 이해당사자들이 참여하고 협력하는 패러다임으로의 이행 지점을 강조”한다(Rhodes, 1997; 2007). Elzen et al.(2004)은 정책 패러다임이 일반적으로 전통적인 하향식 모델, 상향식 또는 시장 모델, 거버넌스 또는 정책네트워크 모델로 나뉜다고 제시한다. 명령 및 통제 패러다임은 정부가 규칙과 규제를 사용하여 중심 역할을 하며 위계적 관계를 맺는 모델이다. 상향식 또는 시장 모델은 보조금, 세금, 재정적 인센티브를 통해 지역 행위자에게 자율성을 부여하는 모델이다. 거버넌스 또는 네트워크 모델은 네트워크 관리, 학습 과정, 실험 및 대화형 정책 결정을 통해 “가치와 신념이 다른 상호 의존적 행위자 간의 규칙 결정과 합의를 공유”하는 모델이다(Elzen et al., 2004). 특히 과학기술 분야의 경우 고도의 전문성이 요구되기 때문에 민간의 네트워크가 중시되고 정부는 조정적인 역할을 하는 거버넌스적 과정이 두드러진다(STEPI, 2005). 인공지능 분야도 민간의 전문성이 두드러지는 거버넌스 양상을 보인다.

인공지능 거버넌스를 파악하기 위해서는 인공지능 부문이 발전해 온 역사를 공공 부문과 민간 부문 관계에 초점을 두어 간략히 알아볼 필요가 있다. 현재 활발히 형성되고 있는 인공지능 거버넌스의 경우 공공과 민간 부문의 역할이 함께 두드러진다. 이러한 인공지능 거버넌스의 형태는 인공지능 부문 발전의 역사와 맞닿아 있다. 우선, 인공지능은 초기에 국책 연구로 시작하여 오랜 시간 동안 대중의 관심에 멀어져서 발전하였다. 둘째, 공공 자금이 회수된 후에 인공지능은 민간 부문에 의존하여 발전하게 되었고 민간 부문이 인공지능 연구와 상업적 적용 성공의 결정적인 역할을 담당하였다. 셋째, 기술 발전 역사에서 민간 부문의 주도적 역

할로 인해 초기 거버넌스 형성 과정에서의 관리 권한이 민간 부문 행위자들에게 있었고 민간 행위자들은 초기 인공지능 거버넌스 맥락 형성에 큰 영향을 미쳤다. 넷째, 인공지능의 윤리적 이슈가 본격화됨에 따라 정부가 인공지능 거버넌스의 중심 행위자로 부상하게 되었다. 다섯째, 이후 인공지능 거버넌스는 정부와 민간이 함께 구축하는 양상을 띤다.

인공지능이 본격적인 연구 분야로 등장한 것은 1950년대 중반 이후이다.⁹⁾ ‘인공지능(Artificial Intelligence)’이라는 용어는 1956년에 다트머스 대학(Dartmouth College)에서 존 매카시(John McCarthy)의 주도로 개최된 “인공지능에 관한 여름 연구 프로젝트(Summer Research Project on Artificial Intelligence)”에서 처음 사용되었다.¹⁰⁾ 인공지능 분야의 경우 초기에 공공 부문이 주도하여 발전하다가 민간 부문에 의존하여 발전하였다. 초기 인공지능 분야는 기계지능(machine intelligence), 신경 기능(neuronic functions) 및 로봇 공학(robotics)에 대한 연구가 미국, 영국, 일본 정부로부터 상당한 자금을 지원받으면서 발전하였다(Bietti, 2020; Radu, 2021; Koniakou, 2023). 하지만 ‘첫 번째 인공지능의 겨울(First AI Winter)’이라고 불리는 1970년대에 인공지능 연구가 기대만큼의 성과를 보여주지 못하였고 구체적인 결과와 응용 분야가 부족하여 공공 자금이 회수되었다. 정부의 자금이 철회된 후에는 인공지능 분야는 민간 부문의 주도적 역할로 성장하였다. 민간 기업들은 1980년대에 전문가 시스템 개발에 뛰어들어 인공지능 분야를 다시 새롭게 부상시켰지만 결국 전문가

9) “인공 지능이 본격적인 연구 분야로 등장한 것은 1955년, 1956년, 1958년 세 차례에 걸친 중요한 회의”에서였다. “1955년 로스앤젤레스에서 열린 1955년 서부 합동 컴퓨터 회의와 함께 ‘학습 기계에 관한 세션’이 열렸다. 1956년에는 다트머스 대학에서 ‘인공 지능에 관한 여름 연구 프로젝트’가 개최되었다. 그리고 1958년에는 영국 국립물리 연구소의 후원으로 ‘사고 과정의 기계화’에 관한 심포지엄이 열렸다.” (Nilsson, 2009)

10) 당시 록펠러 재단에 제출한 제안서에 있던 내용은 다음과 같다. “기계가 언어를 사용하고, 추상화와 개념을 형성하고, 현재 인간에게 맡겨진 종류의 문제를 해결하고, 스스로를 향상시킬 수 있는 방법을 찾으려는 시도가 이루어질 것이다.”, “현재 인공지능 문제는 인간이 그렇게 행동한다면 지능적이라고 할 수 있는 방식으로 기계가 행동하도록 만드는 것으로 간주된다.” (Nilsson, 2009)

시스템 역시 기대만큼의 성과를 보여주지 못하고 ‘두 번째 인공지능의 겨울(Second AI Winter)’이 오게 되었다. 하지만 2000년 이후 빅데이터(Big Data)와 머신러닝이 부상하였고 2012년 딥러닝의 등장으로 인공지능의 황금기가 열렸다. 이 과정에서 민간 부문은 인공지능 연구와 상업적 적용 성공의 결정적인 역할을 담당하였다(Koniakou, 2023).

인공지능 기술이 비약적으로 발전하는 동안 국가 자금 지원의 결여와 감독의 결여는 초기 인공지능 윤리적 논의와 거버넌스 형성이 민간 주도로 이루어지는 결과를 낳았다. 2016년 이후 본격적으로 인공지능 윤리 논의가 시작되면서 인공지능 거버넌스가 형성되기 시작하였는데 그 첫걸음이 바로 인공지능 윤리 강령과 가이드라인이었다. 이때 초반 인공지능 강령과 가이드라인은 민간 부문에서 쏟아져 나오게 되고 초기의 윤리적 논의가 민간 주도로 이루어졌다. Jobin et al.(2019)의 연구는 2019년 4월까지 발행된 84개의 인공지능 윤리 가이드라인 문서 중 22.6%가 민간 기업에서 발행되었음을 보였다. 해당 연구에서 민간 기업은 정부 기관, 학계와 연구 기관, 정부 간 또는 초국가적 조직 등의 발행 주체 중 가장 많은 윤리 가이드라인 문서를 발간한 것으로 집계되었다.¹¹⁾

2018년 이후 인공지능 서비스가 본격화되면서 인공지능 기술이 내포하고 있는 위험성에 대한 인식이 커지고 그에 대한 대중의 우려가 커지자, 정부 부문이 인공지능 거버넌스의 중심 행위자로 부상하였다. 정부 부문은 인공지능의 윤리적 이슈에 대응하고 인공지능 기술의 신뢰성과 수용성을 확보하기 위해 인공지능 거버넌스를 구축하려고 노력해 왔다.

인공지능의 윤리적 이슈가 본격화됨에 따라 인공지능 거버넌스를 구축하려는 초기 시도는 주로 민간에서 이루어졌지만, 정부가 인공지능 거버넌스의 중심 행위자로 부상한 이후 인공지능 거버넌스는 정부와 민간이 함께 구축하는 양상을 띠었다. 거버넌스의 구축 맥락은 국가마다 다르게 나타나지만, 각국의 정부는 중앙 집중식 비전을 가지고 접근 방식

11) 이어서 정부 기관은 21.4%, 학계와 연구 기관은 10.7%, 정부 간 또는 초국가적 조직은 9.5%를 차지했다(Jobin et al., 2019).

을 채택하고 민간 부문은 정부의 비전 구축 과정에서 주된 역할을 해 왔다. 2017년부터 2019년 사이에 발표된 12개 국가의 인공지능 국가 전략을 분석하여 인공지능 거버넌스의 특성을 밝힌 Radu(2021)는 인공지능 거버넌스의 혼종성(hybridity)을 강조한다. 인공지능 거버넌스의 혼종성은 초기 인공지능 거버넌스 형성을 민간 부문이 지배하다가 국가가 인공지능 거버넌스의 중심 행위자로 부상하였기 때문에 거버넌스에서 국가와 민간의 역할이 모호해지는 현상을 말한다. 한국의 경우에도 기업 대표들이 주도하여 2018년 인공지능 국가 전략을 작성한 바 있다.¹²⁾ 이후에도 한국 인공지능 거버넌스에서 민간 부문은 주요 역할을 담당해 왔다.

2) 인공지능 거버넌스의 세계적 흐름

인공지능 거버넌스는 현재까지 크게 네 단계를 거쳐 발전해 왔다. 인공지능 거버넌스 발전의 세계적 흐름은 로봇 윤리, 인공지능의 윤리적 방향성, 인공지능 윤리 강령, 인공지능 규제에 네 단계로 나뉜다(<표 4>참고). 우선 로봇 윤리를 통한 거버넌스 단계는 초기 인공지능의 윤리가 로봇 윤리의 부분으로 다루어질 때의 시기를 말한다. 로봇 윤리 거버넌스는 인공지능 거버넌스의 출발점이 된다.¹³⁾ 로봇 윤리 거버넌스의 시작

12) 스타트업 기업가이자 투자자인 장병규가 민간 산업 대표 35명과 정부 관계자 5명으로 구성된 한국 4차 산업혁명위원회를 이끌었다(Radu, 2021).

13) 인공지능 윤리는 로봇 윤리뿐만 아니라 다양한 분야의 윤리적 논의가 복합적으로 적용되어 발전한 분야이다. 인공지능 기술은 데이터, 네트워크, 로봇 기술을 복합하여 만들어지는 기술이고 인권에 영향을 미치는 기술이다. 따라서 인공지능의 윤리적 논의가 형성될 때, 기존의 로봇 윤리, 인터넷 윤리, 데이터 윤리와 함께 인권과 관련한 생명 윤리의 논의도 함께 고려되어 형성되었다. 이는 인공지능 윤리에서 다루는 기술과 인권의 측면이 기존 인터넷 윤리 그리고 생명윤리와 맞닿는 지점들이 있기 때문이다. 인공지능 윤리의 시초는 흔히 1942년 아이작 아시모프(Issac Asimov)의 ‘런어라운드(Runaround)’라는 소설에 나오는 로봇 3원칙으로 알려져 있다. 아시모프 로봇 3원칙은 이후 로봇과 인공지능 윤리의 정립에 근간이 되는 역할을 하게 된다. 또한 이후 2006년 유럽로봇연구 네트워크의 ‘로봇윤리로드맵’과 2007년 한국 산업자원부가 발표한 ‘로봇윤리현장초안’ 등 로봇 윤리 거버넌스 형성에 영향을 미치게 된다. 따라서 본 연구에서는 아시모프 로봇 3

<표 4> 인공지능 거버넌스 발전의 세계적 흐름

거버넌스 단계	대표적 문건과 정책
로봇 윤리	• (2004) 국제 로봇 박람회, ‘세계로봇 선언’ • (2006) EURON, ‘로봇윤리로드맵’ • (2007) 한국 산업자원부, ‘로봇윤리 헌장 초안’ • (2011) EPSRC, ‘다섯 가지 로봇 원칙’
AI의 윤리적 방향성	• (2015) Russell et al., ‘강건하고 유익한 인공지능을 위한 연구 우선순위’ • (2016) 스탠포드 대학교, ‘2030년의 인공지능과 삶: 인공지능에 대한 100년 연구’
AI 윤리 강령	• (2016) Partnership on AI, ‘Tenets’ • (2017) Future of Life Institute, ‘Asilomar AI Principles’ • 위의 두 강령에 뿌리를 둔 “AI Ethics” 규범 및 가이드라인 쏟아져 나옴
AI 규제	• (2021) EU, ‘AI ACT 제안’ • (2022) 미국, 2022 알고리즘 책임 법안 • (2023) 미국, ‘바이든 행정명령’

딥러닝
전성기 시작

알파고와
이세돌 대국

인공지능
서비스
본격화,
오남용 사례
빠르게 증가

은 2004년으로 거슬러 올라가는데, 일본 후쿠오카에서 개최된 국제 로봇 박람회(International Robot Fair)에서 ‘세계로봇선언(World—Robot Declaration)’이 발표되었다.¹⁴⁾ 해당 선언은 인공지능 로봇에 관한 세계

원칙에 근간을 둔 로봇 거버넌스를 인공지능 거버넌스의 시작점으로 두었다(김명주, 2019; 고학수 외, 2020; Park, D. H. et al., 2024)

14) 2004년, 일본 후쿠오카 세계 로봇 선언의 주요 내용은 ‘차세대 로봇은 인간과 공존하는 파트너가 될 것이다, 차세대 로봇은 인간을 육체적으로 그리고 정신적으로 보조할

최초의 윤리 규범으로 평가받는다(고학수 외, 2020). 이후 2006년에 EURON(유럽로봇연구네트워크)은 ‘로봇윤리로드맵(The EURON Roboethics Roadmap)’을 발표하였다.¹⁵⁾ 2000년에 유럽 연합의 산하 기구로 만들어진 유럽로봇연구네트워크는 상당수의 전문가가 참여해 로드맵을 작성하였다. 해당 로드맵에는 이전과는 달리 로봇이 준수해야 할 윤리 이외에 인간이 준수해야 할 윤리를 주된 목표로 삼았다(고학수 외, 2020). 2007년에는 한국 산업자원부에서도 ‘로봇윤리현장 초안’을 발표하였다.¹⁶⁾ ‘로봇윤리현장 초안’은 2006년 ‘로봇윤리로드맵’과 같이 로봇의 윤리가 아닌 사람의 윤리에 초점을 두고 있다. 해당 현장은 세계 최초의 로봇 윤리 현장으로 발표될 것으로 기대되었으나, 초안 발표 이후 국가 차원에서 해당 현장을 공식화하지는 않았다(변순용 외, 2017). 2011년 영국의 EPSRC(공학과학물리과학연구위원회)는 현실 세계에서의 로봇 관리를 위한 ‘다섯 가지 로봇 원칙’을 발표하였다.¹⁷⁾ 해당 원칙은 이전의 규범들이 주로 현실세계와 동떨어진 로봇을 다루고 있다는 것에 대한 비판에서 출발하였다, 또한 법적 책임을 인간에게 명시적으로 귀속시켰다는 점 그리고 프라이버시 문제가 대두되었다는 점에서 이전의 규범들과는 구분된다.

다음은 인공지능의 윤리적 방향성을 제시한 거버넌스 단계이다. 이 단계는 인공지능 기술의 윤리적, 사회적 영향을 더욱 현실적으로 인식하고 인공지능 기술 연구의 방향성과 기술의 사용에 대한 방향성을 제시하기

것이다, 차세대 로봇은 안전하고 평화로운 사회 구현에 기여할 것이다’이다.

15) 해당 로드맵에서는 인간 존엄성과 인권, 평등, 정의의 공평, 이익과 해악, 문화적 다양성과 다원주의에 대한 존중, 비차별과 비낙인, 자율성과 개인의 책임, 고지된 동의, 프라이버시, 기밀성, 연대와 협동, 사회적 책임, 이익의 공유, 생물권 대한 책임의 윤리 원칙의 내용이 다루어진다(Roboethics Roadmap, 2006).

16) 로봇윤리현장 초안은 로봇 원칙의 목표, 인간과 로봇의 공동원칙, 인간 윤리 로봇 윤리, 제조자 윤리, 사용자 윤리, 실행의 약속을 포함한다(로봇신문. (2013). <https://www.irobotnews.com/news/articleView.html?idxno=1606> (최종접속일: 2024. 4. 4.))

17) 다섯 가지 로봇 원칙은 살생의 원칙, 규정 준수의 원칙, 상품화의 원칙, 투명성의 원칙, 법적 책임의 원칙을 포함한다(Bryson, 2017).


시작한 단계이다. 2012년 딥러닝의 전성기가 찾아온 이후 인공지능 윤리는 로봇의 하위 분야로 다루어지던 것에서 벗어났고 인공지능의 방향성에 대한 본격적인 고민이 나타나게 되었다. 2015년 AAAI(전미인공지능학회)의 학회지인 'AI Magazine'에 스튜어트 러셀(Stuart Jonathan Russell) 등이 '강건하고 유익한 인공지능을 위한 연구 우선순위(Research Priorities for Robust and Beneficial Artificial Intelligence)'라는 글을 실었다.¹⁸⁾ 해당 글은 인공지능 연구의 방향성을 제시하는 영향력 있는 글로 인공지능의 사회적 이익을 극대화하는 방향으로 연구가 이루어져야 한다는 주장을 담고 있다. 2016년 9월 스탠포드 대학교에서 인공지능의 응용 영역 중 여덟 가지 영역에 집중하여 각 영역이 당면한 사회적 문제를 정리하고 이에 대한 정책적 제언을 제시하는 보고서인 '2030년의 인공지능과 삶: 인공지능에 대한 100년 연구(Artificial intelligence and life in 2030: the one hundred year study on artificial intelligence)'를 발표하였다.¹⁹⁾ 이는 2014년 시작된 '인공지능에 대한 100년 연구(The One Hundred Year Study on Artificial Intelligence)'의 첫 번째 성과였다(Stone et al., 2022).

세 번째 인공지능 거버넌스의 양상은 인공지능 윤리 강령이 주를 이룬 거버넌스 형태이다. 인공지능 윤리 강령으로는 인공지능 윤리 기준, 원칙, 가이드라인 등이 있다. 2016년은 알파고와李世돌의 대국에서 알파고의 승리는 인공지능의 인간 초월성 문제, 인공지능이 인간을 대체할 가능성에 대한 우려, 인공지능과 인간의 관계, 인공지능의 위험성 문제 등에 대한 논의를 촉발하였고 인공지능 기술에 대한 대중의 관심이 처음

18) 단기적 연구 우선순위로는 인공지능의 경제적 영향 최적화 연구, 법과 윤리 연구, 강건한 인공지능을 위한 컴퓨터과학 연구가 포함되고 장기적 우선순위로는 검증가능한 인공지능 시스템 연구, 인공지능 보안 연구, 인공지능 통제 연구가 포함된다(Russell and Tegmark, 2015).

19) 해당 보고서는 인공지능이 사회적 영역에서 제기하는 대표적 문제를 운송, 가정/서비스 로봇, 헬스케어, 교육, 자원 부족 공동체, 공공 안전 및 보안, 고용 및 직장, 엔터테인먼트의 8가지로 정리하고 이에 대한 정책적 제언을 제시하였다(Stone et al., 2022).

으로 폭발적으로 집중되었다. 인공지능에 대한 우려가 커지자, 인공지능 윤리 강령이 대거 쏟아져 나오게 되었다. 이때 인공지능 산업에 속해 있는 글로벌 빅테크가 가장 발 빠른 대응을 했다. 2019년까지 발행된 36개의 주요 인공지능 원칙 문서를 분석한 Fjeld et al.(2020)의 연구에 따르면, 알파고 사건 이후 인공지능 거버넌스의 필요성이 본격적으로 대두된 시기인 2016년에서 2017년 사이에 인공지능 윤리 원칙 문서를 발행한 집단이 주로 정부가 아닌 민간 집단임을 알 수 있다([그림 5] 참고).



[그림 5] 인공지능 윤리 원칙 문서 연대표 (※ 출처: Fjeld et al.(2020))

알파고 사건 이후 가장 먼저 인공지능 윤리 신조를 발표한 집단은 아마존(Amazon), 페이스북(Facebook), 구글(Google), IBM, 마이크로소프트(Microsoft)가 만든 비영리 조직인 ‘파트너십온에이아이(Partnership on AI)’이다²⁰⁾. 2017년 1월에는 최초의 인공지능 규범으로 여겨지는 ‘아실로마 인공지능 원칙(Asilomar AI Principles)’이 발표되었다.²¹⁾ 해당 원칙은

20) Partnership on AI. *Our Tenets*. <https://partnershiponai.org/about/#tenets> (최종 접속일: 2024. 4. 4.)

인공지능 원칙 중 가장 빨리 만들어졌고 가장 영향력 있는 원칙 중 하나였다. 이 원칙은 비영리 조직인 삶의 미래 연구소(Future of Life Institute)가 미국 캘리포니아주 아실로마에서 개최한 ‘유익한 인공지능을 위한 아실로마 컨퍼런스(Asilomar Conference on Beneficial AI)’에 학계 전문가, 엔지니어, 기업인 등 세계 유수의 인공지능 관련 분야의 전문가가 참여하여 만들어졌다. 아실로마 인공지능 원칙은 세계 유수의 전문가들이 인공지능의 윤리적, 사회적 부작용의 위험성을 일찍이 깨닫고 유익한 인공지능을 만들기 위한 목표를 공유하며 만들었다는 점에서 인공지능 거버넌스의 초기 형성 과정의 특성을 잘 나타낸다.²²⁾ 이후 위의 두 인공지능 윤리 강령에 뿌리를 둔 인공지능 윤리 규범 및 가이드라인이 쏟아져 나왔다. 지역, 국가, 전문기관, 시민단체 및 다양한 싱크탱크, 주요 기술 기업 등 다양한 수준에서 인공지능 윤리 강령이 발표되었다. 인공지능 윤리 강령에서 발행 주체 별로 강조하는 원칙이 다르기는 하지만 결국 잠재적인 규범적 합의와 프레임워크의 수렴이 일어났다(Zeng, 2018, Georgieva et al., 2022; Fjeld et al., 2020; Jobin, 2019).

인공지능 윤리 강령은 법이라는 강제적 방식 대신에 규범적 압력을 통해 윤리적 방향으로 사람들의 행동에 영향을 미칠 수 있다는 점에서 유용하게 작동한다(Koniakou, 2023). 윤리 강령은 책임감 있는 방식으로의 인공지능 기술 연구 개발과 사용을 촉발한다. Stahl(2022)은 자신의 연구에서 인공지능 규범이 인공지능 기술을 사용하는 조직의 실천으로 바뀌어 영향을 미친다고 주장한다. 해당 연구는 인공지능 기술을 사용하는 조직에 대한 사례 연구를 통해 인공지능 윤리 규범이 조직의 인식과

21) 아실로마 인공지능 원칙은 다섯 가지 연구 이슈(연구 목표, 연구비 지원, 과학정책 연계, 연구 문화, 경쟁 회피), 열세 가지 윤리와 가치(안전, 실패의 투명성, 사법적 투명성, 책임성, 가치 일치, 인간의 가치, 개인정보 보호, 자유와 프라이버시, 이익의 공유, 번영의 공유, 인간 통제, 사회 전복 방지, 인공지능 무기경쟁), 다섯 가지 장기 이슈(역량 경고, 중요성, 위험성, 자기 개선 순환, 공동의 선)로 구성된다 (Future of Life Institute. (2017). Asilomar AI Principles.. <https://futureoflife.org/open-letter/ai-principles/>. (최종 접속일: 2024. 4. 4.))

22) 민간 행위자들은 초기 인공지능 거버넌스 맥락 형성에 큰 영향을 미쳤다.

반성, 기술적 접근, 인간의 감독, 윤리 훈련 등에 영향을 미친다고 주장한다. 하지만 인공지능 윤리 강령은 한계 또한 존재한다. 윤리 강령은 구속력이 없다는 점, 윤리 강령이 윤리 세탁(ethics washing)의 수단으로 사용될 수 있다는 점, 윤리 강령의 경우 개념적 명확성과 구체적인 방향성이 부족하다는 점이 한계이다. Hagendorff(2020)는 자신의 연구에서 인공지능 윤리 규범이 인공지능 분야에 있는 인간의 의사 결정에 실제적 영향을 주지 못한다는 분석을 제시한다. 해당 연구는 인공지능 가이드라인이나 강령, 규범만으로는 기술 개발에 전혀 영향을 미치지 못한다고 주장하며 개발자들은 기술 개발 단계에서 윤리적 이슈를 교육받지도 않고, 윤리적 우려를 제기하도록 권한을 부여받지도 않는다고 설명한다. 이러한 인공지능 윤리 강령에 대한 한계점은 이후 인공지능 거버넌스가 인공지능 규제 거버넌스의 흐름으로 넘어가는 계기가 되었다.

네 번째 거버넌스의 흐름은 인공지능 규제 거버넌스이다. 인공지능 서비스가 본격화되고 기술 오남용 사례들이 빠르게 증가하면서 인공지능 윤리 강령 거버넌스의 한계가 점차 드러나고 인공지능 서비스에 대한 규제 마련의 시급성이 고조되었다. 인공지능 규제 거버넌스는 민간 자율 규제 방식과 정부 규제 방식이 함께 이루어지고 있다. 정부가 강제성이 있는 규제 방식을 함께 진행하게 되면서 인공지능 거버넌스에서 정부가 중심 행위자로 부상하였고 인공지능 거버넌스는 정부와 민간이 함께 구축하는 양상을 띠게 되었다. 각국의 정부는 신뢰성을 확보하기 위해 민간과 함께 인공지능 표준화와 법제화를 추진하고 있다.

2021년 4월에 유럽연합 집행위원회(European Commission)가 ‘유럽연합 인공지능 법안(EU AI Act)’²³⁾을 발표하면서 인공지능 거버넌스는 본격적인 인공지능 규제 거버넌스 국면으로 전환되었다. 유럽연합 인공지

23) 2023년에 유럽의회(European Parliament)에서 세계 최초 ‘인공지능 기술 규제 법안’으로 채택되었다 (정미하. (2024. 3). 조선비즈. *EU, 세계 최초 AI 규제 법안 마련... 여기면 연매출 7% 과징금*.

https://biz.chosun.com/international/international_general/2024/03/14/D57D5VMKLNBJEDSRBNQD5DJN4/ (최종 접속일: 2024. 4. 4.))

능 법안은 이후 세계적인 인공지능 규제 경쟁을 촉발하게 되었다. 당시 미·중 기술 패권 경쟁과 주요국의 기술 주권 확보 전략에 대한 논의가 커지며 인공지능을 통한 글로벌 인공지능 주도권을 확보하려는 노력이 더해져 인공지능 기술의 표준과 규제를 선점하려는 경쟁이 시작되었다. 2021년에 발표된 유럽연합의 인공지능 법안은 세계 최초의 인공지능 기술 규제 법안으로 리스크에 따라 차등 규제가 적용된다는 점과 수평적 규제 체계라는 점이 특징이다.²⁴⁾ 유럽연합의 법안은 인공지능 일반에 대한 리스크를 나열하고 규제하는데 높은 리스크로 분류되면 규제를 일률적으로 가하는 수평적 규제 체계이다(Park, 2023).²⁵⁾ 이때 인공지능의 리스크는 수인불가능한 리스크(Unacceptable risk), 높은 리스크(High risk), 제한적 리스크(Limited risk), 최소의 리스크 또는 리스크 없음(Minimal or No risk)으로 나뉜다. 각 리스크에 따라 규제의 정도가 금지, 적합성 평가, 고지 의무 등으로 나뉜다. 미국도 2022년 2월에 「2022 알고리즘 책임법안(Algorithmic Accountability Act of 2022)」을 발표하며 국제 규범 이끌기 위한 입법 움직임을 보였다. 2022 알고리즘 책임법안은 「2019 알고리즘 책임 법(Algorithmic Accountability Act of 2019)」의 한계를 수정하여 발표된 것으로 감독을 통한 인공지능의 투명성과 책임성을 확보하려는 목적을 바탕으로 두었다. 해당 법안을 통해 이전까지 자율성을 강조하던 미국에서도 규제 거버넌스의 흐름에 따라 정책의 방향성을 형성하고 있다는 점을 알 수 있다. 해당 법안에서는 인공지능 시스템에 대한 사전영향평가를 실시하고 이에 대한 요약보고서를 규제기관에 제출하도록 하는 내용을 포함하였다(홍석한, 2023). 이후 2023

24) 인공지능 규제 프레임워크는 크게 두 가지로 나뉜다. 유럽연합으로 대표되는 수평적 규제 프레임워크(Horizontal approach)와 미국과 영국으로 대표되는 상황 구체적 규제 프레임워크(Context-specific approach)이다. 수평적 규제 접근법을 취하는 국가는 대표적으로 유럽연합, 캐나다, 브라질, 한국이고 상황 구체적 접근법을 취하는 국가는 대표적으로 미국, 영국, 이스라엘, 스위스, 중국이다(Park, 2023).

25) 반면 미국과 영국은 사용 사례별로 접근하는 상황별 규제 체계이다. 사례별로 지켜야 할 규제는 다르나 리스크별로 나누어 규제의 정도를 정하는 방식이다.

년 생성형 인공지능(Generative AI) 문제가 심화되면서 인공지능 위험에 대한 경각심과 규제에 대한 필요성이 더욱 커졌다. 이에 따라 2023년 10월 미국 바이든 행정부는 실질적 법적 효력을 갖는 첫 인공지능 행정 명령인 ‘안전하고 보안이 보장되며 신뢰할 수 있는 인공지능의 개발과 사용에 관한 행정명령(Executive Order on the Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence)’을 발표하였다. 해당 행정 명령은 인공지능 안전성 평가 의무화, 인공지능 도구의 안전성 표준 마련, 콘텐츠 인증 표준 수립, 개인정보 보호 강화 등의 내용을 포함하였다(INSS, 2023).

3) 인공지능 거버넌스 선행연구

인공지능 거버넌스에 대한 선행연구는 크게 네 가지로 나뉜다. 첫 번째 유형은 기업, 정부, NGO에서 발행한 인공지능 윤리 문서를 분석한 연구이다. Schiff et al.(2020)은 기업, 정부, NGO에서 발표한 인공지능 윤리 강령, 원칙, 프레임워크, 정책 전략을 포함한 80가지 이상의 인공지능 윤리 문서를 분석하는데 문서의 발간자, 문서의 목표, 문서의 영향을 분석하여 해당 문서들이 인공지능 거버넌스에 미칠 수 있는 영향을 분석한다. Fjeld, J. et al.(2021)은 36가지의 주요 인공지능 윤리 문서를 비교하여 문서의 발간 시기별 주체를 식별하고 핵심 규범을 구성하는 원칙을 분석하여 공유되는 원칙과 그 내용을 보인다. Jobin et al.(2019)은 2015년부터 민간 기업, 연구 기관, 공공 부문에서 발표한 인공지능 원칙과 지침을 분석하여 수립되는 인공지능 원칙, 이 원칙이 해석되는 방식, 중요하다고 간주되는 이유 등을 제시한다. Zeng et al.(2018)은 연구기관, 정부기관, 업계에서 나온 인공지능 원칙을 분석하여 주체별로 강조하는 인공지능 원칙이 다르다는 것을 주장한다. 이를 바탕으로 장기적인 관점에서 특정 인공지능 원칙을 채택하기보다는 다양한 인공지능 원칙을 포괄하여 통합해야 할 필요성을 설명한다. 해당 연구들 모두 세계적인 인공

지능 윤리 문서의 배경, 발간자, 내용, 발간 시기, 지역 등을 비교하여 특징과 유형을 도출한다. 이 유형의 연구는 주로 인공지능 거버넌스가 규제 거버넌스의 흐름으로 넘어가기 전인 인공지능 윤리 강령 거버넌스를 분석한다.

두 번째 유형은 인공지능 규제 거버넌스 연구이다. 윤혜선(2019)은 인공지능 규제 논의를 선도하고 있는 미국과 중국, 영국, 유럽연합, 일본의 규제 정책을 분석하여 그 특징과 동향을 제시한다. 인공지능 기술 발전 수준이 높은 미국과 중국의 경우 인공지능 규제 정책이 발전과 촉진에 기울어져 있다고 주장한다. 인공지능 발전 수준이 미국이나 중국보다는 낮지만, 인공지능 기술 혁신 의지가 높은 영국은 미국과 중국보다는 규범력이 높지만 기술 발전 촉진을 위한 정책을 펼치고 있다고 제시한다. 반면 유럽 연합의 경우 인공지능 규제 정책에서 규범력을 확보하려는 노력이 가장 강한 것으로 파악되었다고 주장한다. 일본의 경우 주로 연성적 접근의 규제 형태를 보인다고 제시한다. 고학수 외(2020)는 국내에서 2007년에 시작된 인공지능 논의의 발전 과정과 해외의 인공지능 윤리 규범 및 규제 거버넌스를 비교 분석한다. 인공지능 윤리는 인간을 중시하는 윤리관을 시작으로 윤리의 주체가 인간에서 로봇으로 확장되어 오고 있다는 점, 책임성 개념이 맥락에 따라 확장되고 있다는 점, 해외 인공지능 윤리 논의가 수렴하고 있으나 개별적으로 차이를 보인다는 점을 강조한다. 여기에 더하여 우리나라 초기의 인공지능 규범 논의를 제시한다. 김송옥(2022)은 유럽 연합이 인공지능 법안을 제기하기까지의 과정과 법안의 내용을 살피고 이를 우리나라의 인공지능 정책 현황 및 법제 논의와 비교하여 앞으로의 방향을 제시한다. 김정민(2020)은 해외의 인공지능 알고리즘 규제 현황과 동향 및 시사점을 살펴보고 한국의 현황을 검토하여 향후 개선 방향과 법적 시사점을 도출한다. Schmitt(2022)는 전 세계적으로 생겨나고 있는 인공지능의 규제 체계를 설명하고 평가하려는 목적을 바탕으로 국제기구가 인공지능 정책에 중요한 역할을 하고 있음을 강조한다. Tallberg et al.(2023)은 전 세계적으로 중요한 규제 대상이

되는 인공지능 기술의 규제 접근 방식에 대한 분석을 제시한다. 특히 인공지능 규제 연구에서 정의와 민주주의 가치에 초점을 맞춰 인공지능 거버넌스의 함의를 이해하는 것과 인공지능 거버넌스의 방식을 설명할 수 있는 이론적 도구의 필요성을 강조한다.

세 번째 유형은 인공지능 거버넌스의 특성을 분석한 연구이다. Radu(2021)는 세계 각국의 인공지능 국가 전략을 분석하여 인공지능 거버넌스의 특성을 도출한다. Radu(2021)는 신흥 기술 전문 지식이 민간에 집중되어 있어서 인공지능 거버넌스가 전문가에 대한 높은 의존도를 요구하고 있고 공공 부문과 영리 부문의 입장과 이해관계가 명확하게 정의되어 있지 않아 기능적 불확정성이 높다고 주장한다. Koniakou(2023)는 인공지능 거버넌스 발전에 대한 조감도를 제공한다. 윤리 강령을 바탕으로 한 거버넌스 모델에서 법과 구속력 있는 의무를 바탕으로 한 거버넌스 모델로의 변화 과정을 설명하고 이 과정에서 인권의 역할을 강조한다. 인공지능 거버넌스의 특성을 분석한 연구는 인공지능 거버넌스에서 민간의 역할이 두드러진다는 점, 거버넌스가 구속력 있는 거버넌스로 이행하고 있다는 점을 제시한다. Park et al.(2024)는 한국 인공지능 거버넌스의 궤적에 큰 영향을 미친 몇 가지 사건을 제시하고 인공지능 거버넌스가 어떻게 발전해 왔는지를 설명한다. 해당 연구에서는 이 주요 사건을 2007년 로봇 윤리헌장, 2016년 알파고 대국, 2020년 이루다 사건으로 파악한다. 또한 한국 인공지능 거버넌스 발전 과정에서 정부, 학계, 시민사회, 산업계 모두 거버넌스 담론 형성에 중요한 역할을 해 왔음을 강조한다.

네 번째 유형은 바람직한 인공지능 거버넌스의 형태를 제시한 연구이다. Gasser & Almeida(2017)는 바람직한 인공지능 거버넌스를 위한 층위 모델을 제시했다. 해당 연구에서는 데이터 거버넌스, 알고리즘 책임성, 표준으로 구성된 기술 층위, 기준, 원칙으로 구성된 윤리 층위, 규범, 규제, 법제화로 구성된 사회 및 법 층위로 구성되며 각 층위는 상호작용한다고 제시한다. Walz & Firth-Butterfield(2019)는 인공지능 시스템에

서 윤리적 문제를 구현하기 위한 등급별 거버넌스 모델을 제공한다. 해당 연구는 양도할 수 없는 윤리적 핵심 가치, 헌법적 윤리적 가치, 집단별 윤리적 가치, 개인의 윤리적 가치를 제시하고 이러한 가치들은 각각 국가적 법제와 국제 조약, 가적 법제와 국제 조약, 협회와 인증 시스템, 계약 규정 인증 시스템을 통해 달성되어야 함을 설명한다.

기존 인공지능 거버넌스 연구의 경우 세계적으로 다양한 기관을 통해 발표되는 윤리 문서를 분석한 연구 혹은 세계 각국의 인공지능 규제 동향을 파악한 연구가 대다수이다. 인공지능 정책을 분석한 연구(Radu, 2021)가 있기는 하지만 그 또한 세계 각국의 주요 인공지능 전략을 비교하여 공통 특성을 뽑아내는 데 집중하였다. 특히 한국의 거버넌스를 다룬 문헌의 경우 인공지능 거버넌스 분석이 법적 규제에 치중되어 다루어지고 있거나 정책과 행위자의 유기적인 상호작용에 초점을 두지 않는다. 인공지능 거버넌스는 규제를 통해서만 이루어지는 것이 아니다. 정부는 인공지능의 부작용을 최소화하기 위한 다양한 차원의 정책을 발표하고 있다. 또한 이 정책형성과정에는 다양한 정책 행위자가 참여하여 정책을 형성하고 있다. 따라서 본 연구에서는 한국의 인공지능 정책과 정책 행위자에 초점을 두어 한국의 인공지능 정책형성과정을 분석하고자 한다. 본 연구는 사회적 · 윤리적 부작용을 최소화하기 위한 정책에 집중하여 한국의 인공지능 정책형성과정을 탐구한다는 점, 한국의 인공지능 거버넌스 분석에서 법규제에만 치중하지 않고 다른 정책을 모두 포함하여 분석한다는 점, 제도와 행위자가 상호작용하며 거버넌스가 구성되는 측면을 보여준다는 점에서 인공지능 거버넌스 문헌에 기여할 수 있다.

제 3 장 방법론 및 분석틀 설계

1. 방법론

본 연구에서는 한국에서 인공지능의 사회적 · 윤리적 부작용을 최소화하기 위한 규범적 접근이 정책에 반영되는 현상을 분석하기 위해 한국의 인공지능 정책과 정책 행위자에 초점을 맞추어 한국의 인공지능 거버넌스와 정책형성과정을 분석한다. 이를 위해 본 연구에서는 질적 연구 방법을 사용한다. 그중에서도 집합적 사례 연구(collective case study), 문헌 연구, 반구조화 면접(semi-structured interview)의 방법을 사용한다.

본 연구에서는 한국의 인공지능 거버넌스와 정책형성과정에 관한 현상을 이해하기 위해 집합적 사례 연구(collective case study)를 사용한다. Stake(2003)는 사례 연구를 세 가지 유형인 본질적 사례 연구(intrinsic case study), 도구적 사례 연구(instrumental case study), 집합적 사례 연구의 유형으로 나누어 설명한다. 집합적 사례 연구는 도구적 사례 연구의 연장이며 도구적 사례 연구와는 달리 다수의 사례를 연구한다. 도구적 사례 연구는 특정 사례를 이슈에 대한 통찰을 얻거나 일반화를 변경하기 위해 조사하는 연구 방법이다. 도구적 사례연구는 본질적 사례 연구와 구분되는데 본질적 사례 연구는 특정 케이스 자체를 더 잘 이해하고 싶어서 택하는 방식이고 도구적 사례 연구는 특정 사례에 대한 연구가 다른 것에 대한 이해를 돕기 위해 택하는 방식이다. 집합적 사례 연구에서 선정된 사례들은 현상이나 일반적 상태에 대한 이해로 이어질 것이라고 믿어지기 때문에 선택된다(Stake, 2003). 본 연구에서 한국의 인공지능 거버넌스와 정책형성과정에 관한 현상을 이해하기 위해 택한 다수의 사례는 과학기술정보통신부를 중심으로 파악한 정부의 주요 인공

지능 정책이다. 본 연구에서 분석하는 주요 인공지능 정책은 <표 5>와 같다. <표 5>의 사례는 2016년에서 2023년까지 과학기술정보통신부가 주무 부처가 되어 발표한 인공지능 정책 중 인공지능에 대한 사회적·윤리적 고려를 포함한 주요 정책으로 선정하였다. 해당 정책은 인공지능 기술의 부작용을 최소화하고 신뢰성을 확보하기 위한 목표를 포함한다.

과학기술정보통신부의 주요 인공지능 정책 사례들을 분석하기 위해 문헌 분석의 방법을 사용한다. 문헌 분석에서는 정부에서 발행한 정책 문서와 보도자료, 국내 포럼 자료, 선행 연구, 국제기구 및 해외 국가의 인공지능 관련 논의 자료, 기업 및 협회 자료, 기사 등을 분석한다. 문헌 분석 대상의 1차 문헌으로 정부에서 발표한 『2015년도 기술영향평가』(2016), 『제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』(2016), 『인공지능(AI) R&D 전략』(2018), 『지능정보사회 윤리 가이드라인 및 윤리현장』(2018.), 『인공지능(AI) 국가전략』(2019), 『사람이 중심이 되는 인공지능(AI) 윤리기준』(2020), 『인공지능 법·제도·규제 정비 로드맵』(2020), 『신뢰할 수 있는 인공지능 실현 전략(안)』(2021), 『대한민국 디지털 전략』(2020), 『윤리기준 실천을 위한 자율점검표(안)』(2023), 『신뢰할 수 있는 인공지능 개발안내서』(2023), 『인공지능 윤리교재』(2023)를 분석한다. 또한 과학기술정보통신부가 추진한 「지능정보화 기본법」(2020), 「인공지능산업 육성 및 신뢰 기반 조성에 관한 법률(안)」(2021; 2022; 2023)을 분석한다. 여기에 더하여 인공지능 정책 관련 포럼 자료, 인공지능 정책 관련 보도자료 등을 분석한다. 2차 문헌으로 인공지능 윤리와 거버넌스 맥락 이해에 도움을 줄 수 있는 선행연구, UNESCO, EU 등의 국제기구 및 해외 국가의 인공지능 관련 논의 자료, 기업 및 협회 자료, 관련 기사, 공동 논평 입장문 등을 분석한다.

과학기술정보통신부의 정책을 분석의 대상으로 삼은 이유는 다음과 같다. 우선 과학기술정보통신부는 인공지능에 대한 본격적인 정책적 접

근이 시작되었던 2016년부터 인공지능 일반과 인공지능의 산업별 용례에 대한 정책을 모두 아우르는 정책을 담당해 왔기 때문이다. 다음으로 2019년에 발표된 『인공지능(AI) 국가전략』에서 ‘역기능 방지 및 AI 윤리 체계 마련’ 아젠다를 맡고 있는 부처가 과학기술정보통신부이기 때문이다.²⁶⁾ 인공지능의 사회적·윤리적 부작용을 막기 위한 정책은 과학기술정보통신부에서만 발표되는 것이 아니다. 대표적으로 개인정보보호위원회, 방송통신위원회가 인공지능의 부작용을 최소화하기 위한 정책을 발표하였다. 생성형 인공지능 서비스가 본격화됨에 따라 문화체육관광부도 저작권과 관련한 인공지능 정책 논의에 참여하였다. 하지만 개인정보보호위원회, 방송통신위원회, 문화체육관광부의 정책의 경우 담당하는 분야가 한정적이다.

문헌 분석만으로는 파악하기 힘든 인공지능 정책형성과정과 정책네트워크 그리고 행위자의 의도 및 지향을 파악하기 위해 과학기술정보통신부의 주요 인공지능 정책 행위자를 대상으로 반구조화 면접을 진행하였다. 인터뷰는 인터뷰 대상을 주요 정책행위자와 관련 집단 중에서 선정하고 대면으로 진행되었다. 과학기술정보통신부의 주요 인공지능 정책 행위자 집단은 크게 네 그룹으로 나뉜다. 주요 집단은 정부, 전문가, 기업 및 협회, 시민단체이다. 과학기술정보통신부 정책을 중심으로 한 인공지능 거버넌스의 주요 정책 행위자는 <표 6>과 같다. 주요 정책행위자는 주요 정책 문헌, 정부 보도 자료, 주요 포럼의 구성원 명단, 기사를 통해 파악하고 인터뷰를 통하여 상호검증하였다. 인터뷰 대상은 <표 7>과 같다. 인터뷰의 정보는 요청에 따라 익명처리하였다. 인터뷰는 대면으로 진행하였고 50분에서 120분 사이로 진행되었다.

26) 해당 아젠다의 세부 과제를 맡고 있는 교육부와 방통위도 있기는 하지만, 해당 기관들은 ‘AI 윤리 규범 마련 및 교육 커리큘럼 개발·보급’, ‘이용자 보호 정책 수립 지원 체계 마련’과 같이 해당 특수 분야에 대한 과제를 담당하고 있다.

<표 5> 과학기술정보통신부 주요 인공지능 정책

시기	정책	주관 기관
2016. 1.	2015년도 기술영향평가	미래창조과학부, KISTEP
2016. 9.	지능정보사회 추진단 출범	미래창조과학부
2016. 12.	제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책	관계부처 합동, 미래창조과학부
2018. 5.	인공지능(AI) R&D 전략	과학기술정보통신부
2018. 10.	지능정보화사회 윤리 가이드라인 및 윤리현장	과학기술정보통신부, NIA
2019. 12.	인공지능(AI) 국가 전략	관계부처 합동, 과학기술정보통신부
2020. 4.	인공지능 법제정비단 1기 발족	과학기술정보통신부
2020. 6.	지능정보화 기본법	과학기술정보통신부
2020. 12.	사람이 중심이 되는 인공지능(AI) 윤리기준	관계부처 합동, 과학기술정보통신부, KISDI
2020. 12.	인공지능 법·제도·규제 정비 로드맵	관계부처 합동, 과학기술정보통신부
2021. 3.	인공지능 법제정비단 2기	과학기술정보통신부, NIA
2021. 5.	사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)	관계부처 합동, 과학기술정보통신부
2021. 7.	인공지능 육성 및 신뢰 기반 조성 등에 관한 법률안	정필모 의원 대표 발의
2022. 2.	인공지능 윤리 정책 포럼 1기 출범	과학기술정보통신부
2022. 6.	인공지능 법제정비단 3기	과학기술정보통신부
2022. 9.	대한민국 디지털 전략	관계부처 합동, 과학기술정보통신부
2022. 12.	인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안	윤두현 의원 대표 발의
2023. 2.	인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안 의결	국회과학기술정보방송 통신위원회 정보통신방송법안심사 소위
2023. 3.	디지털 신질서정립 협의체 출범	과학기술정보통신부

2023. 4.	인공지능 윤리 정책 포럼 2기 출범	과학기술정보통신부, TTA
2023. 2~7.	윤리기준 실천을 위한 자율점검표(안), 신뢰할 수 있는 인공지능 개발안내서, 인공지능 윤리교재	과학기술정보통신부, KISDI, TTA
2023. 8.	인공지능 법제정비단 4기	과학기술정보통신부
2023. 9.	디지털 권리장전	과학기술정보통신부
2023. 12.	인공지능 시스템 신뢰성 제고를 위한 요구사항(정보통신단체표준)	과학기술정보통신부, TTA

<표 6> 주요 인공지능 정책 행위자

집단	정부	전문가	기업 및 협회	시민단체
주요 정책 행위자	과학기술정보 통신부 KISDI NIA TTA	인문 · 사회 법학 · 법조 공학	대기업 중소기업 스타트업 인공지능 기업 관련 각종 협회	소비자연맹 소비자시민모임 진보네트워크센터 참여연대 등 각종 시민단체

<표 7> 반구조화 면접 내역

집단	소속	인터뷰 대상자	일자	인터뷰 방식
정부	정부출연연구기관	A	24. 6. 4.	대면
	정부출연연구기관	B	24. 6. 15	대면
	과기부 2차관 산하기관	C	24. 5. 12.	대면
	감사원 소속기관	D	24. 2. 26.	대면
전문가	인문 · 사회	E	23. 12. 5.	대면
	법학	F	23. 12. 27	대면
	공학	G	24. 3. 19.	대면
기업 및 협회	한국 대기업	H	24. 6. 5.	대면
	한국 스타트업	I	23. 12. 22.	대면
	인공지능 기업 관련 협회	J	24. 3. 8.	대면
시민 단체	정보인권 시민단체	K	24. 5. 31.	대면

2. 분석틀 설계

본 연구에서는 기술의 사회적 측면을 분석에 포괄하는 사회기술시스템론을 기반으로 제도(Rules)와 행위자(Actors and Social groups)에 초점을 두고 정책네트워크의 권력 분포, 상호작용 유형, 행위자 선호를 주요 분석 요소로 삼는다. 본 연구의 주요 분석 대상은 한국의 인공지능 정책과 주요 정책 행위자이다. 인공지능 윤리 정책을 주관하는 주무 부처가 과학기술정보통신부이기 때문에 과학기술정보통신부의 인공지능 정책에 초점을 두어 정책을 분석한다. 과학기술정보통신부의 인공지능 윤리와 관련된 각 주요 정책을 <표 8>과 같이 배경, 목표, 수단으로 나누어 분석한다. 각 정책의 배경 분석을 통해 정책이 수립되게 된 맥락을 파악한다. 또한 정책의 목표 분석을 통해 정책의 방향을 파악한다. 정책의 수단 분석을 통해서 인공지능 거버넌스가 어떤 정책 수단을 통해 구성되고 있는지를 파악한다. 각 정책의 수단은 Geels(2004)가 제시한 제도의 구분인 규제적 수단, 규범적 수단, 인식적 수단으로 구분하여 파악한다. 행위자의 경우 인공지능 정책의 주요 행위자를 분석한다. 주요 행위자 집단을 정부, 전문가, 기업 및 협회, 시민단체로 나누어 파악한다. 이 과정에서 한국 인공지능 정책의 주요 행위자를 식별하여 네트워크를 파악하는 정책네트워크 분석을 진행한다. 정책네트워크는 <표 8>과 같이 권력 분포, 상호작용 유형, 행위자 선호 분석을 통해 파악한다. 정책네트워크는 권력 분포, 상호작용 유형, 행위자 선호가 상호 의존하며 구성된다. 권력 분포는 분산과 집중으로 나뉘고 상호작용 유형은 갈등, 협상, 협력으로 구분된다. 행위자 선호는 행위자 이해와 정책 입장으로 구성된다.

본 논문에서는 한국의 인공지능 정책네트워크에서 행위자 선호를 파악하기 위해 정책 기조에 대한 주요 갈등 지점을 ‘윤리적 AI’와 ‘규제’에 대한 입장으로 파악한다 (<표 9> 참고). 그 이유는 인공지능의 역기능을 최소화하고 신뢰성을 확보하기 위한 인공지능 정책이 내포하고 있는 규

<표 8> 정책형성과정 분석을 위한 주요 정책과 주요 행위자 분석

연구의 분석 대상	분석 요소	
주요 정책	배경	
	목표	
	수단	규제적
		규범적
		인식적
주요 행위자	권력 분포	집중
		분산
	상호작용 유형	협력
		협상
		갈등
	행위자 선호	윤리적 AI
		규제

범적 방향성이 윤리적 인공지능이고 인공지능 규제가 현 인공지능 거버넌스 맥락에서 가장 화두가 되는 갈등 지점이기 때문이다. 따라서 ‘윤리적 AI’와 ‘규제’에 대한 정책 입장을 파악하는 것이 인공지능 정책네트워크의 행위자 선호 파악에서 중심이 된다. 우선 ‘윤리적 AI’에 대한 입장은 해당 행위자가 사회적 · 윤리적 문제 방지와 성능 향상 · 혁신 중 어느 쪽을 더 강조하는지를 파악하는 것이다. 선호를 이 두 가지로 파악하는 이유는 실질적으로 인공지능 개발 과정에서 윤리적 사항들을 고려하다 보면 비용이 들고 성능이 떨어지는 결과가 초래되기 때문이다. 다음으로 한국 인공지능 규제에 대한 주요 갈등 지점은 형식, 주체, 시점이다(김건우 외, 2023). 행위자의 선호는 행위자가 정책에 보이는 입장을 통해 파악할 수 있다. 규제 형식에서는 경성과 연성에 대한 선호의 정도를 파악한다. 이를 위해 각 정책행위자가 경성 규범과 연성 규범에 보이는

정책 입장을 파악한다. 규제 주체에서는 정부 규제와 민간 규제에 대한 선호의 정도를 파악한다. 이를 위해 각 정책행위자가 민간 주체와 정부 주체 정책 기조에 보이는 정책 입장을 파악한다. 규제 시점에서는 사전 규제와 사후 규제에 대한 선호를 파악한다. 이를 위해 각 정책행위자가 ‘사전허용-사후규제’ 문제로 화두가 된 인공지능 기본법안에 보이는 정책 입장을 파악한다.

<표 9> 행위자 선호 분석틀

행위자 선호	윤리적 AI		사회적 · 윤리적 문제 방지	성능 향상 · 혁신
	규제	형식	경성	연성
		주체	정부	민간
		시점	사전	사후

정책네트워크의 권력분포, 상호작용 유형, 행위자 선호를 파악하기 위해서는 문헌 연구와 함께 인터뷰를 진행한다. 문헌 연구와 인터뷰에서는 정책네트워크 분석을 위해 보조 자료로 <표 10>을 참고하였다. 이는 Kriesi et al.(2006)의 평판 지표와 네트워크 지표 그리고 Lindberg et al.(2019)의 정책 입장 파악 지표를 본 연구에 맞게 재구성하였다. 권력 분포 파악을 위해 각 집단의 행위자가 주로 관계를 맺었다고 생각한 집단과 각 집단의 행위자가 정책형성과정에서 영향력이 컸다고 생각한 집단을 식별한다. 상호작용 유형 파악을 위해 각 집단이 다른 집단과 관계 맺는 유형을 식별한다. 행위자 선호를 파악하기 위해 정책 행위자가 ‘윤리적 AI’와 ‘규제’에 대해 보이는 세 가지 측면의 입장을 식별한다.

<표 10> 정책네트워크 분석 보조 자료

1. 네트워크의 권력 분포 식별		
구분	내용	
1	행위자 중 영향력이 가장 크다	
2	행위자 중 영향력이 크다	
3	행위자 중 영향력이 작다	
4	행위자 중 영향력이 가장 작다	
2. 네트워크의 상호작용 유형 식별		
구분	내용	
협력	이 행위자와 긴밀히 협력	
갈등	이 행위자와 주요한 의견 불일치	
협상	이 행위자와 협력과 갈등의 양상을 모두 보임	
3. 행위자 선호 식별		
3-1 윤리적 AI		
입장	내용	
사회적· 윤리적 문제 강조	AI의 사회적 · 윤리적 문제를 방지하는 것이 최우선 목표이다	
	AI의 사회적 · 윤리적 문제를 방지하는 것과 성능 향상 · 혁신을 강조하는 것 모두 중요하다	
성능 향상· 혁신 강조	AI의 성능 향상 · 혁신이 최우선 목표이다	
3-2 규제		
항목	입장	내용
형식	연성	AI 규제는 연성 규범(soft law)의 형태로만 이루어져야 한다
		AI 규제는 연성 규범과 경성 규범(hard law)의 형태 둘 다로 이루어져야 한다
	경성	AI 규제는 경성 규범의 형태로만 이루어져야 한다
주체	민간	AI 규제의 주체는 민간으로만 이루어져야 한다
	정부	AI 규제의 주체는 정부와 민간 둘 다로 이루어져야 한다
		AI 규제의 규제 주체는 정부로만 이루어져야 한다
시점	사후	AI 규제는 사후 규제여야 한다
		AI 규제는 사전과 사후 규제 모두 포함하여야 한다
	사전	AI 규제는 사전 규제여야 한다

제 4 장 인공지능 거버넌스와 정책형식과정 분석

1. 주요 인공지능 정책 분석

본 연구에서는 인공지능의 윤리적 · 사회적 이슈를 해결하고 인공지능의 신뢰성을 확보하기 위한 인공지능 정책을 분석한다. 이는 인공지능의 윤리적 개발과 활용을 촉진하기 위한 정책이다. 특히 인공지능에 대한 종합적인 정책을 담당해 오고 인공지능의 사회적 · 윤리적 부작용을 줄이기 위한 규범적 논의와 정책을 주도해 온 과학기술정보통신부의 인공지능 정책에 초점을 두어 분석한다. 해당 정책에서는 구체적으로 인공지능의 편향성, 차별, 프라이버시 침해, 개인정보 오남용 및 악의적 이용, 일자리 문제 등 역기능 대응 방안과 책임성, 공정성, 투명성 확보 방안 등을 다룬다. 아래에서는 과학기술정보통신부의 정책을 주요 키워드를 중심으로 구분하여 분석한다. 주요 인공지능 정책은 시기에 따라 지능정보 정책, 인공지능 정책, 디지털 정책으로 구분된다. 과학기술정보통신부의 주요 인공지능 정책을 분석한 내용은 <표 12>와 같다. 또한 주요 인공지능 윤리 정책의 구조는 [그림 6]과 같다. 본격적인 인공지능 정책을 분석하기에 앞서 아래에서는 인공지능 정책의 시작이 된 지능정보 정책 이전에 인공지능 기술에 대한 정부 차원의 윤리적 고려를 담은 정책인 『로봇윤리헌장초안』과 『2015 기술영향평가』를 간략하게 살펴본다.

『로봇윤리헌장초안』(2007. 3.)

정부 차원에서 인공지능 윤리와 관련한 정책을 처음 발표한 것은 2007년 산업통상자원부의 로봇윤리헌장초안이다. 로봇 윤리 헌장 초안은 로봇

산업과 로봇 기술이 성장함에 따라 높아진 로봇 윤리 정립에 대한 필요성에 대응하기 위해 발표되었다. 당시 세계적 거버넌스 흐름은 로봇 윤리와 관련한 논의를 활발히 진행하던 시기였다. 2004년 국제 로봇 박람회에서 ‘세계로봇선언’이 발표되고 2006년 유럽로봇연구네트워크는 ‘로봇 윤리로드맵’을 발표하며 논의가 진행되었다.

산업자원부의 로봇 윤리 헌장 초안은 2006년 11월에 발족한 로봇산업 정책포럼의 로봇윤리 작업반에서 국내외 자료와 전문가 의견을 바탕으로 만들어졌다(산업자원부, 2007). 로봇 윤리 작업반은 과학자, 의사, 심리학자, 변호사 등의 전문가로 구성되었다(로봇신문, 2013). 해당 헌장은 목표, 인간, 로봇의 공동 원칙, 인간 윤리, 로봇 윤리, 제조자 윤리, 사용자 윤리, 실행의 약속을 포함하여 총 7장으로 구성되어 있다. 하지만 이후 헌장이 국가적 차원에서 진행되지는 못하였다.

『2015 기술영향평가』 (2016. 1.)

2007년 『로봇윤리헌장초안』 이후 한국 정부 차원에서 정책적으로 인공지능 기술이 끼칠 사회적 영향에 주목하기 시작한 것은 2015년 『2015 기술영향평가』이다. 기술영향평가란 정부가 “새로운 과학기술의 발전이 경제·사회·문화·윤리·환경 등에 미치는 영향을 사전에 평가”하는 것을 말한다(과학기술기본법 제 14조 1항). 2015년은 딥러닝의 전성기가 시작된 2012년 이후로, 세계적으로 인공지능 기술에 대한 관심이 높아지던 시기였다. 2015년은 미국의 OpenAI가 설립된 해이기도 하다. 세계적 거버넌스 흐름으로 보면 인공지능의 윤리적 방향성을 설정하려는 노력이 대두되던 시기였다. 한국 정부도 부상하고 있는 인공지능 기술에 관심을 가지기 시작하였고 과학기술정보통신부의 전신인 미래창조과학부는 2015년의 기술영향평가 대상으로 인공지능 기술을 선정하였다. 기술영향평가 대상 기술로 선정되려면 현재 등장하고 있는 신기술, 국민 생활에 파급

효과가 큰 기술, 사회적 관심도가 높아 시의적설성이 높은 기술, 다수 부처와 연관된 범국가 차원의 기술 등에 해당하여야 한다(2015 기술영향평가, 2016). 당시 인공지능 기술은 지능형 비서, 의료 진단, 법률 서비스 지원, 지능형 금융 서비스, 지능형 감시시스템, 기사 작성, 추천 시스템, 지능형 로봇 등의 응용 분야에서 빠르게 확산되고 있었고 사회 전반에 큰 영향을 줄 것으로 예측되어 기술영향평가의 대상이 되었다.

당시 기술영향평가에서 집중한 인공지능 기술의 경제적 · 사회적 · 윤리적 문제는 산업 및 일자리 변화, 사회적 · 문화적 변화, 새로운 윤리적 문제였다. 산업 및 일자리 변화와 관련하여서는 산업 발전 및 산업 구조 개편, 일자리 변화, 주요 자원의 집중 가능성이 주요 주제로 평가되었다. 사회적 · 문화적 변화와 관련하여서는 삶의 질 향상과 새로운 기회, 사회적 위험과 새로운 문제 발생, 창작활동 및 문화소비 변화, 감정 및 인간관계 문화의 변화가 주요 주제로 평가되었다. 새로운 윤리적 문제와 관련하여서는 인공지능의 판단, 책임, 권한의 문제와 인간의 권리 침해 가능성이 주요 주제로 평가되었다.

1-1. 지능정보 정책

지능정보기술이란 “인공지능 기술과 데이터 활용기술(ICBM)²⁷⁾을 융합하여 기계에 인간의 고차원적 정보처리 능력(인지, 학습, 추론)을 구현하는 기술”을 말한다 (4차 산업혁명에 대응한 지능정보사회 중장기 종합대책, 2016). 이때 인공지능 기술이란 인간 인지 능력의 일부를 모사하는 약한 인공지능을 말한다.

27) 사물인터넷(IoT), 클라우드 컴퓨팅(Cloud Computing), 빅 데이터(Big Data), 모바일(Mobile) 기술을 말한다.

『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』 (2016. 12)

한국에서 정책적으로 인공지능 기술에 대한 본격적인 관심이 시작된 것은 2016년이였다. 2016년은 구글 딥마인드가 개발한 알파고와 이세돌 9단의 대국이 열린 해로 알파고가 이세돌을 상대로 대국에서 승리하며 인공지능 기술에 대한 여론의 관심이 폭발적으로 증가한 해였다. 이와 더불어 정부 차원에서도 지능정보기술이 경제 사회 구조의 대변혁을 일으킬 것으로 전망하고 그 원인, 파급효과 및 국가적 대책 마련의 필요성이 시급함을 인식하였다.

이에 따라 미래창조과학부에서는 2016년 9월에 ‘지능정보사회 추진단’을 출범하여 2016년 이내에 지능정보사회에 대비한 중장기적인 대책을 세우고 구체적인 실행 계획을 마련할 계획임을 발표하였다. 지능정보사회 추진단은 관계부처 및 민간 전문가로 구성되었다.

지능정보사회 추진단 출범 이후 정부는 관계부처 합동으로 같은 해 12월에 『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』을 발표하였다. 해당 종합 대책은 글로벌 수준의 지능정보기술의 기반을 확보하고, 전 산업의 지능정보화를 촉진하고, 사회정책 개선을 통한 선제적 대응을 목적으로 하였다. 『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』에서는 인공지능 기술이 기반이 된 지능정보기술의 확대로 노동의 본질 변화, 양극화, 해킹 등의 사회구조 변화와 역기능에 대응하기 위한 ‘사회정책 개선을 통한 선제적 대응’의 정책 방향을 제시하였다. 구체적인 추진 과제로는 ‘교육 혁신’, ‘고용 형태 변화에 대한 대응’, ‘사회안전망 강화’, ‘법제도 정립 및 윤리 정립’, ‘사이버위협과 인공 지능 역기능 대응’을 제시하였다.

해당 종합대책에서는 인공지능의 사회적 · 윤리적 부작용을 막기 위한 정책 수단으로 규제적, 규범적, 인식적 제도를 모두 포함하였다. 정책 수단으로 국가정보화 기본법을 지능정보화 기본법으로 개정하는 방안과 법제 정비, 지능정보 소프트웨어 안전성 인증 체계 마련 등을 통한 규제

적 수단, 지능정보기술 윤리헌장 제정 추진을 통한 규범적 수단, 창의력과 지능정보 이해력 등의 필수 역량을 높이기 위한 지능정보사회 미래교육 혁신을 통한 인식적 수단이 제시되었다. 종합대책에 제시된 지능정보 이해력 등의 필수 역량을 높이기 위한 교육 혁신 정책의 경우 인공지능의 사회적 · 윤리적 부작용을 막기 위해 기술에 대한 비판 능력을 키우는 윤리 리터러시 증진과는 다른 차원의 정책이다. 해당 교육 정책의 경우 지능정보 기술을 활용하는 능력에 초점을 두어 정책이 제시되었다.

『지능정보사회 윤리 가이드라인 및 윤리헌장』 (2018. 5.)

2016년 이후로 인공지능 거버넌스의 세계적 흐름이 인공지능 윤리 강령으로 넘어가면서 세계적으로 기업, 협회, 시민단체, 정부 간 조직, 정부 등 다양한 조직에서 윤리 강령이 쏟아져 나오게 되었다. 인공지능 분야는 이전까지 민간에 의존하여 성장하였기 때문에 2016년 인공지능의 영향력에 대한 여론의 관심이 집중되었을 때 이에 가장 먼저 대응한 조직은 정부가 아닌 민간 부문이었다. 세계적으로 윤리 강령을 가장 빠르게 발표한 조직은 2016년에 윤리 강령을 발표한 인공지능 분야의 글로벌 빅테크가 모여 만든 비영리 조직인 Partnership on AI였다. 이후로 2017년 인공지능 관련 분야의 전문가들이 모여 ‘아실로마 인공지능 원칙’을 만들었다. 이후로도 민간 부문이 주축이 되어 각종 윤리 강령을 발표하였다.

한국에서도 빠르게 발전하는 인공지능의 영향력에 대응하여 윤리 강령이 발표되었다. 한국도 세계적인 인공지능 거버넌스의 흐름과 마찬가지로 민간 부문의 대응이 빨랐다. 한국에서 가장 발 빠르게 윤리 강령을 발표한 곳은 인공지능이 적용된 서비스를 상용화하려는 움직임을 보이고 있던 한국의 IT기업인 카카오였다. 카카오는 2018년 1월에 ‘카카오 알고리즘 윤리 헌장’을 발표하였다. 뒤이어 2018년 4월에 카이스트(KAIST)도 ‘인공지능을 위한 윤리 헌장’을 발표하였다. 이는 카이스트가 한국의 방산 기업과 함께 인공지능 관련 연구 협력을 하는 것에 대해 세계 각국

의 인공지능 전문가들이 반대 서한을 발표한 것에 대한 대응이었다. 윤리 강령을 필두로 하는 인공지능 거버넌스의 흐름이 2020년까지는 이어졌기 때문에 한국의 민간 부문의 대응이 늦은 편은 아니었음을 알 수 있다.

이후 각국 정부 차원에서도 인공지능 윤리 강령을 발표하는 대응을 시작하였다. 한국 과학기술정보통신부는 2018년 『지능정보화사회 윤리 가이드라인 및 윤리헌장』을 발표하였다. 과학기술정보통신부는 지능정보기술이라는 분류 안에서 인공지능 기술을 다루고 지능정보기술을 모두 포괄하는 윤리 강령을 발표하였다. 해당 윤리 가이드라인 및 윤리헌장의 경우 2016년에 만들어지기 시작하여 3년 동안 작업하고 2018년에 발표되었다. 해당 윤리 강령은 과학기술정보통신부, NIA(한국정보화진흥원), 정보문화포럼이 주축이 되어 만들어졌다. 당시 외부 전문가로 철학, 윤리학, 법학, 사회학 분야의 전문가들이 참여하였고 공학 계열의 전문가는 한 명 뿐이었다(인터뷰이 G).

해당 정책은 지능정보기술의 산업적, 사회적 활용에 대한 부작용에 대한 우려가 커짐에 따라 주체별 권리와 책임의 범위와 관련한 규범적 논의의 필요성이 대두되어 발표되었다. 해당 윤리 가이드라인 및 윤리 헌장은 개발자, 공급자, 이용자의 윤리적 사고를 통해 지능정보기술의 오작동과 남용을 최소화하기 위한 지침을 제공하는 것을 목적으로 하였다. 또한 윤리 가이드라인 및 윤리 헌장의 기본적인 방향성은 인공지능 분야의 자율 규제 환경을 조성하는 것이었다. 윤리 가이드라인 및 윤리 헌장은 인공지능 산업을 포함하는 지능정보기술의 산업 환경을 저해하지 않고 기술로 인한 사회적 윤리적 부작용을 최소화하기 위한 노력의 일환이었다.

해당 윤리 가이드라인 및 윤리 헌장에서는 개발자, 공급자, 이용자가 모두 함께 지켜야 하는 '공통원칙(PACT)'을 제시하였다. 이 원칙(PACT)은 공공성(Publicness), 책무성(Accountability), 통제성(Controllability), 투명성(Transparency)이다.²⁸⁾ 당시 다른 국가의 인공지

능 윤리 가이드라인 및 윤리 현장이 주로 개발자와 사용자의 윤리에 초점을 두어 작성되었다는 것을 볼 때, 한국의 『지능정보화사회 윤리 가이드라인 및 윤리현장』은 이용자와 사회의 윤리까지 다뤘다는 점에서 의미가 있었다.

『지능정보사회 윤리 가이드라인 및 윤리현장』은 『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』에서 나온 대표적인 규범적 정책 수단이었다. 가치, 규범, 역할 기대치, 의무, 권리, 책임을 부여하여 규범적 압력과 같은 사회적 제재를 통해 작동하는 규범적 정책 수단이었다.

『지능정보화 기본법』(2020. 6. 9. 공포, 2020. 12. 10. 시행)

정보화에서 지능정보화 시대로의 이행에 발맞춰 인공지능 시대의 기본법 마련이 필요해졌다. 이에 과학기술정보통신부에서는 법제도적 뒷받침 하에 세계를 선도할 인공지능 생태계를 구축하고 국가적 추진체계와 기반을 정비하기 위한 목적으로 「국가정보화 기본법」을 「지능정보화 기본법」으로 전면 개편하는 방안을 추진하였다(과학기술정보통신부, 2020).

「지능정보화 기본법」에서는 기존 「국가정보화 기본법」에서는 정의되지 않았던 '데이터'와 '알고리즘' 등 과 같은 개념을 명시하여 새로운 시대에 발맞춘 법을 마련하려고 하였다. 정부에서는 이미 2016년 『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』에서 지능정보사회에 대비한 법제 정비 및 윤리 정립 과제의 구체적 추진 과제로 지능정보사회 방향 제시를 위한 기본법 마련을 제시했다.

지능정보화 기본법은 인공지능 기본법이 통과되지 않은 지금까지 인

28) 공공성은 지능정보 기술을 통한 공공의 번영과 혜택을 의미하고, 책무성은 지능정보 기술 및 서비스에 의한 책임과 의미를 의미하고, 통제성은 지능정보 기술 및 서비스에 대한 인간의 제어 가능성 및 오작동에 대한 관리 그리고 이용자의 선택권을 의미하고, 투명성은 지능정보 기술의 설명가능성, 이용 단계에서의 위험성에 대한 정보 공유, 이용자/시민 참여를 의미한다(지능정보사회 윤리 가이드라인 및 윤리현장, 2018).

공지능 정책에서 주축이 되는 법으로 작용해 오고 있다. 「지능정보화 기본법」에는 지능정보화 사회 중합계획 수립, 전문 인력 양성, 표준화 추진 등의 지능정보 기술 고도화 시책과 국가차원의 인공지능 윤리 준칙 마련, 기술안전성 확보를 위한 보호조치, 일자리·교육·복지 등 대책 마련을 규정한 역기능 방지와 사회 변화에 대응하기 위한 시책이 포함되었다.

1-2. 인공지능 정책

인공지능이란 “인간의 지적능력을 컴퓨터로 구현하는 과학기술로서, 상황을 인지하고, 이성적 논리적으로 판단·행동하며, 감성적·창의적인 기능을 수행하는 능력까지 포함”한다(인공지능(AI) 국가 전략, 2018)

‘인공지능’이란 학습, 추론, 지각, 판단, 자연언어의 이해 등 인간이 가진 지적 능력을 전자적 방법으로 구현하기 위한 것을 말한다(인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안(의안번호: 2111261; 2118726 제2조).

‘인공지능기술’이란 인공지능을 구현하기 위하여 필요한 하드웨어 기술 또는 그것을 시스템적으로 지원하는 일련의 소프트웨어 기술이나 그 기술들로 만들어진 기반기술 등을 말한다(인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안(의안번호: 2118726 제2조).

『인공지능(AI) R&D 전략』 (2018. 5.)

미국, 영국, 독일, 싱가포르, 캐나다 등 주요국은 2017년을 기점으로 인공지능 R&D 전략과 국가 전략을 추진하기 시작하였다. 2017년 3월에 캐나다 정부가 세계 최초로 국가 AI 전략을 발표한 이후로 세계 각국은 경쟁적으로 국가 AI 전략을 마련하기 시작하였다(NIA, 2022). 한국의 과학기술정보통신부는 세계 각국의 흐름에 맞춰 인공지능이 경제 성장과 사

회 난제 해결의 돌파구가 될 것으로 기대하고 『인공지능(AI) R&D 전략』을 발표하였다.

해당 정책의 경우 인공지능 기술력, 인재 확보, 생태계 구축을 주요 목표로 하는 R&D 전략이기는 하지만 중점추진 과제인 ‘개방 협력형 연구 기반 조성’ 목표의 ‘제도 개선’ 부분에서 ‘성능평가 기준 마련’, ‘윤리적 AI 기술 기반’, ‘모니터링 기술 확보’를 추진하는 과제를 포함했다. 성능평가 기준 마련 과제는 인공지능 시스템의 안정성, 정확도, 투명성 등에 대한 성능을 객관적으로 비교하기 위한 것이었다. 또한 윤리적 AI 기술 기반 과제는 데이터 및 알고리즘에 인간의 윤리 규범이 내재된 ‘윤리적 AI를 위한 아키텍처의 설계’에 관한 연구를 추진하는 것을 목표로 했다. 또한 인공지능 설계 단계에서부터 『지능정보사회 윤리 가이드라인 및 윤리헌장』의 규범을 바탕으로 기술을 설계하도록 하는 연구를 추진하려는 과제를 포함하였다. 또한 지능정보사회 윤리 가이드라인 보급을 바탕으로 이용자 권리에 대한 인식 확산과 인공지능 분야별 도덕적 기준에 대한 사회적 합의를 도출하는 과제를 포함하였다. 모니터링 기술 확보 과제는 인공지능이 통제 불능 상태에 빠지지 않도록 하는 중장기적 프로젝트를 추진하는 내용을 포함하였다.

『인공지능(AI) R&D 전략』은 인공지능의 사회적 · 윤리적 부작용을 최소화하기 위한 정책 수단으로 규범적, 인식적 정책 수단을 포함했다. 해당 전략에서는 인공지능 시스템의 윤리적 성능을 파악하기 위한 기준 마련을 통한 규범적 수단과 윤리 가이드라인 보급을 바탕으로 한 이용자 인식을 제고하는 인식적 수단을 제시하였다.

『인공지능(AI) 국가 전략』 (2019. 12.)

인공지능 기술이 빠르게 발전하고 인공지능 기술의 중요성이 커지면서 인공지능 정책이 과학기술정보통신부의 주요 정책으로 자리잡기 시작하였다(인터뷰이 C). 이에 따라 인공지능 정책을 총괄하는 전담 부서의 필요

요성이 커지며 2019년 11월에 과학기술정보통신부 제2차관 산하에 ‘인공지능기반정책관’이 신설되었다. 또한 급변하는 인공지능 기술 발전에 적극 대응하고 경제와 사회에 인공지능 기술을 활용해야 하는 필요성이 커지면서 범정부 차원의 첫 인공지능 국가전략이 발표되었다.

『인공지능(AI) 국가 전략』은 2019년 10월 문재인 대통령이 발표한 대통령 인공지능 기본 구상을 바탕으로 만들어졌다. 과학기술정보통신부 주도로 전 부처가 참여하여 만든 관계부처 합동 인공지능 정책이었다.

『인공지능(AI) 국가 전략』은 아래에서 다룰 많은 한국의 인공지능 정책을 파생시킨 중심 정책이다. 당시 인공지능 국가 전략은 진흥과 윤리를 모두 다루었는데 이는 상대적으로 인공지능에 대한 국가 차원의 전략적 접근이 늦었던 한국이 진흥과 윤리 두 마리 토끼를 모두 잡으려고 했던 시도였다. 이에 따라 진흥 정책과 윤리 정책이 같이 이루어지게 되었다.

해당 전략의 경우 인공지능 경쟁력을 위한 인공지능 생태계 구축, 인공지능 활용 전면화, 인공지능 기술과 사회의 조화 · 공존의 3대 분야를 목적으로 한다. 해당 3대 분야를 달성하기 위해 9대 세부 전략을 세우고 100대 실행 과제를 설정하였다. 『인공지능(AI) 국가 전략』에서 인공지능의 사회적 · 윤리적 부작용을 최소화하기 위한 세부 전략은 생태계 구축 분야의 ‘과감한 규제 혁신 및 법 제도 정비’와 인공지능 기술과 사회의 조화 · 공존 분야의 ‘역기능 방지 및 AI 윤리 체계 마련’ 전략이다. 두 전략의 소관부처는 모두 과학기술정보통신부였다.

우선 ‘과감한 규제 혁신 및 법 제도 정비’ 전략에는 ‘인공지능 법제정비단’ 출범의 내용, ‘인공지능 기본법제’ 마련의 내용, ‘우선허용-사후규제’ 방향성이 포함되었다. ‘인공지능 법제정비단’은 2020년 4월 발족한 1기에서 시작하여 2023년 4월에 4기까지 발족하며 꾸준히 인공지능 법제정비의 역할을 담당해 왔다. 인공지능 법제정비단은 이후 2020년 『인공지능 법 · 제도 · 규제 정비 로드맵』을 발표하였다. 또한 범정부 차원의 규제 혁신 및 법 제도 정비의 기본 기조는 ‘우선허용-사후규제’ 방향이

다. 기본적으로 정부는 인공지능 기술 발전 저해를 최소화하면서 역기능을 방지하고자 하는 입장을 보였다. 인공지능 기술과 서비스에 대한 ‘우선허용-사후규제’의 방향성은 2021년과 2023년에 발의된 인공지능 기본법안인 『인공지능 육성 및 신뢰 기반 조성 등에 관한 법률안』의 내용과도 이어졌다. 다음으로 ‘역기능 방지 및 AI 윤리 체계 마련’ 전략에는 ‘AI 기반 사이버 침해 사고 탐지·대응’, ‘새로운 유형 역기능 대비’, ‘AI 윤리 기준 및 실천방안 마련’의 내용이 포함되었다. 해당 과제는 이후 2020년 『사람이 중심이 되는 인공지능(AI) 윤리 기준』, 2023년 『사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)』 발표로 이어졌다.

『인공지능(AI) 국가 전략』은 인공지능의 사회적·윤리적 부작용을 최소화하기 위한 정책 수단으로 규제적, 규범적, 인식적 정책 수단을 모두 포함하였다. 해당 전략은 인공지능 법제도 정비와 같은 규제적 수단, 인공지능 윤리 기준 정립과 같은 규범적 수단, 대상별 인공지능 윤리교육 커리큘럼 개발·보급과 같은 인식적 수단을 포함하였다.

『사람이 중심이 되는 인공지능(AI) 윤리기준』(2020. 12. 23.)

『사람이 중심이 되는 인공지능(AI) 윤리기준』은 관계부처 합동으로 국가 차원에서 이루어진 한국 최초의 인공지능 윤리 규범이다. 2018년도에 『지능정보사회 윤리 가이드라인 및 윤리헌장』이 만들어졌지만, 당시 지능정보라는 용어가 세계적으로 사용되지 않았고 세계 각국에서는 인공지능에 특화된 윤리 기준과 가이드라인을 제시하고 있었다. 따라서 국가 차원에서 인공지능에 특화된 윤리 기준이 발표되었다. 인공지능 윤리 기준은 과학기술정보통신부와 KISDI(정보통신정책연구원)가 주도하여 관계부처 합동으로 발표하였다. 유럽연합은 2019년 4월에 ‘신뢰할 수 있는 AI 가이드라인(ETHICS GUIDELINES FOR TRUSTWORTHY AI)’을 발표하였고 일본은 2018년 ‘AI 활용 원칙 초안(Draft AI Utilization

Principles)’를 발표하였다. 한국도 이러한 흐름에 맞춰 국가 차원의 인공지능 윤리 기준을 따로 만들었다. 해당 윤리 기준 작성에는 주로 윤리학자와 교육학자들의 주도로 법학, 공학 계열의 전문가들이 함께 참여하여 만들어졌다(인터뷰이 G). 해당 윤리 기준은 문헌 분석 연구, 주요 기구와 단체의 윤리 기준을 검토하여 만들어졌다(인터뷰이 F).

『사람이 중심이 되는 인공지능(AI) 윤리 기준』의 목표 및 지향점은 ‘모든 사회구성원이 모든 분야에서 자율적으로 준수하며 지속 발전하는 윤리기준’이다. 해당 윤리 기준은 인공지능 국가 전략의 규범적 정책 수단으로 발표된 정책으로 인공지능 산업 피해를 최소화하고 혁신을 위한 제도 정비에 중점을 둔 정책이었다. 또한 인공지능 관련 규제를 최대한 민간 자율로 맡기려는 의도가 담겨있었다.

『사람이 중심이 되는 인공지능(AI) 윤리기준』은 ‘사람 중심의 인공지능’을 위한 최고 가치인 ‘인간성(Humanity)’을 위한 3대 기본원칙과 10대 핵심요건을 제시하였다. 여기서 말하는 ‘인간성’은 인공지능이 인간의 수단임을 의미한다. 해당 윤리기준은 본 기준에서 상정하는 인공지능이 하나의 인격으로 존재하거나 스스로를 인식하는 강인공지능이 아님을 명시하였다. 본 윤리기준은 3대 기본원칙으로 ‘인간 존엄성 원칙’, ‘사회의 공공선 원칙’, ‘기술의 합목적성 원칙’을 제시하였다. 또한 10대 핵심요건으로는 ‘인권보장’, ‘프라이버시 보호’, ‘다양성 존중’, ‘침해금지’, ‘공공성’, ‘연대성’, ‘데이터 관리’, ‘책임성’, ‘안전성’, ‘투명성’을 제시하였다. 이 윤리 기준은 이후 정부 모든 인공지능 윤리 정책의 기반이 되어 작용하였다.

『인공지능 법 · 제도 · 규제 정비 로드맵』(2020. 12. 24.)

인공지능 국가전략이 발표된 이후 국가전략에서 발표한 대로 2020년 4월에 과학기술정보통신부와 NIA의 주관으로 ‘인공지능 법제정비단’이 출범하였다. 인공지능 법제정비단은 인공지능과 관련된 산업계, 법조계, 학계의 전문가로 이루어졌고 인공지능 관련 법제도 정비 추진 분야와 과제를

도출하는 목적을 가지고 있었다. 2020년 12월에 이들의 첫 성과로 과학 기술정보통신부가 주도하여 관계부처합동으로 발표한 『인공지능 법 · 제도 · 규제 정비 로드맵』이 발표되었다.

해당 로드맵은 인공지능 기술력 향상과 도입이 본격화되면서 산업 경쟁력을 높이고 활용 걸림돌을 제거하면서도 부작용을 최소화한 선제적인 법 · 제도 · 규제 정비의 필요성이 커지면서 발표되었다. 이 정책은 인공지능 법 · 제도 · 규제 로드맵을 제시하고 인공지능 공통 기반과 분야별 활용 확산에 초점을 둔 과제를 도출하는 것을 목표로 하였다.

당시 미국의 경우 2019년 4월에 ‘2019 알고리즘 책임 법안 (Algorithmic Accountability Act of 2019)’을 발표하였고 EU의 경우 2018년 5월에 유럽연합 일반데이터보호규칙(GDPR, General Data Protection Regulation)이 발효되었다. 인공지능 법제정비단은 주요국의 입법동향과 현황을 분석하여 주요 정비 과제를 도출하였다.

정부가 인공지능의 진흥과 윤리를 모두 다루겠다는 의지는 해당 로드맵에서도 드러났다. 로드맵에서는 18개의 ‘산업 진흥과 활용 기반 강화’ 과제와 12개의 역기능 방지 과제가 제시되었다. 역기능 방지 과제는 법령 9건, 지침과 가이드라인 4건, 제도운영개선 4건을 포함하였다. 구체적으로는 ‘디지털 포용법 제정’, ‘알고리즘 공정성 · 투명성 확보’, ‘인공지능 윤리기준 마련’ 등이 포함되었다. 이때 인공지능 윤리기준 마련은 2020년 12월 23일 발표된 윤리기준의 후속 정책인 ‘윤리교육 커리큘럼 연구 · 개발’과 ‘각급학교 윤리 교육 추진’을 말한다.

해당 로드맵은 규제적, 규범적, 인식적 정책 수단을 모두 포함했다. 디지털 포용법 제정과 같은 규제적 수단, 인공지능 윤리 기준 정립과 같은 규범적 수단, 인공지능 윤리 교육 커리큘럼 개발과 같은 인식적 수단을 포함했다. 또한 로드맵이 나온 이후 또 다른 법 · 제도 · 규제 정비 과제를 발굴하고 실현하기 위해 2021년 3월에 인공지능 법제정비단 2기, 2022년 6월에 인공지능 법제정비단 3기, 2023년 4월에 인공지능 법제정

비단 4기가 출범하였다.

『사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)』 (2021. 7.)

인공지능 서비스가 본격화되면서 인공지능 기술의 오남용 사례들이 빠르게 증가하였다. 한국의 가장 대표적인 사례로는 2021년 1월의 인공지능 챗봇 ‘이루다’ 사건이 있었다.²⁹⁾ 이에 따라 인공지능의 윤리성을 확보하고 역기능을 최소화하기 위한 노력인 신뢰할 수 있는 인공지능(Trustworthy AI)에 대한 관심이 점차 높아졌다. 신뢰할 수 있는 인공지능이란 인공지능의 리스크를 줄이고 사용자와 사회가 인공지능을 활용할 때 시스템 수용성을 높인 인공지능을 말한다.³⁰⁾ 『사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)』에서는 인공지능의 신뢰성을 구축하는 주요 요소를 공정성(Fairness), 안전성(Safety), 투명성(Transparency), 개인정보 보호(Privacy), 견고성(Robustness), 설명가능성(Explanability)으로 파악하였다.

세계 각국에서도 신뢰할 수 있는 인공지능을 구축하기 위한 가이드라인을 발표하였다. 유럽연합의 경우 2019년 4월에 ‘신뢰할 수 있는 AI 가이드라인’을 발표하였고 미국의 경우 NIST(National Institute of Standards and Technology)에서 2021년 5월에 ‘인공 지능 시스템의 사용자 신뢰 평가 방법(Method for Evaluating User Trust in Artificial Intelligence Systems)’을 발표하였다.

『사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)』은 인공지능의 혜택은 극대화하고 위험 · 부작용은 최소화

29) 이후 스캐터랩은 정부와 함께 인공지능 윤리 준칙과 윤리 점검표를 개발하여 2022년 3월에 서비스를 개시하였다.

30) 신뢰할 수 있는 인공지능은 시스템이 명시된 요구 사항과 관련된 증거를 기반으로 신뢰할 수 있는 시스템임을 보장하는 프레임워크이다. 사용자와 이해관계자의 기대가 검증 가능한 방식으로 충족되는지 확인한다(Kaur et al., 2022).

하기 위해 인공지능 신뢰 확보를 목적으로 발표되었다. 해당 전략은 인공지능 국가전략과 인공지능 윤리기준을 바탕으로 둔 정책으로 2020년에 발표한 『사람이 중심이 되는 인공지능(AI) 윤리기준』의 실천 방안을 구체화하였다. 구체적으로 ‘신뢰가능한 인공지능 구현 환경 조성’, ‘안전한 인공지능 활용을 위한 기반 마련’, ‘사회 전반 건전한 인공지능 의식 확산’을 목적으로 하여 추진 전략을 도출하였다. 신뢰가능한 인공지능 구현 환경 조성 전략에는 개발 가이드북, 검증체계, 인증, 신뢰성 표준 등의 방법이 제시되었다. 안전한 인공지능 활용을 위한 기반 마련 전략에는 인공지능 영향평가 추진, 인공지능 법제도 정비의 내용이 포함되었다. 사회 전반 건전한 인공지능 의식 확산 전략에는 윤리 교육 강화, 주체별 체크리스트 마련, 윤리 정책 플랫폼 운영의 내용이 포함되었다.

해당 정책은 민간 자율 규제에 초점을 두고 민간이 자율적으로 신뢰성을 확보할 수 있도록 하는 지원책을 담았다. 인공지능의 신뢰성 확보를 위한 제도 개선 전략의 경우도 제도 개선은 민간의 자율성을 저해하지 않는 선에서 정책을 시행하려는 계획을 담았다. 또한 인공지능의 신뢰성 확보를 위한 윤리 전략에서도 민간 중심으로 윤리를 정립하고 의식을 확산시키려는 계획을 담았다.

‘인공지능 윤리 정책 플랫폼 운영’의 구체적 과제였던 ‘인공지능 윤리 포럼 운영’은 2022년 2월의 ‘인공지능 윤리 정책 포럼 1기’ 출범으로 이어졌다. 해당 포럼은 윤리, 기술, 교육 분과로 이루어졌는데 각 분과에서는 2023년에 건전한 인공지능 의식 확산을 위한 구체적인 정책 결과물을 만들었다. 우선 2023년 2월에 교육 분과에서 인공지능 윤리 확산을 위한 교육 커리큘럼인 『인공지능 윤리교재』를 발표했다. 4월에는 윤리 분과에서 윤리 기준을 준수하고 있는지 평가할 수 있는 『인공지능 윤리기준 실천을 위한 자율점검표(안)』를 발표하였다. 7월에는 기술 분과에서 인공지능의 개발에서 사용할 수 있는 일반 및 분야별 체크리스트인 『신뢰할 수 있는 인공지능 개발안내서』를 발표하였다.

이후 2023년 12월에는 과학기술정보통신부와 TTA가 추진한 인공지

능 신뢰성 단체표준인 『인공지능 시스템 신뢰성 제고를 위한 요구사항』이 발표되었다. 해당 단체표준은 관계부처 합동으로 발표한 『사람이 중심이 되는 인공지능(AI) 윤리기준』, 과학기술정보통신부가 발표한 『신뢰할 수 있는 인공지능 개발안내서』를 기반으로 신뢰성 적용범위, 특성, 시스템 생명주기 및 이해관계자 등 인공지능 시스템 신뢰성 구성 요소와 요구사항을 제시하였다(과학기술정보통신부, 2023b).

해당 실현 전략은 규제적, 규범적, 인식적 정책 수단을 모두 포함한 정책이었다. 인공지능 법제도 정비와 같은 규제적 수단, 개발 가이드북과 같은 규범적 수단, 윤리 교육 강화와 같은 인식적 수단을 모두 포함하였다.

『인공지능 육성 및 신뢰 기반 조성 등에 관한 법률안』(2021. 7.; 2022. 12.; 2023. 2.)

인공지능 기본법 논의는 인공지능 정책 전반에서 가장 중요하게 다루어지고 가장 화두가 되는 논의이다. 인공지능 서비스가 본격화되고 기술 오남용 사례들이 빠르게 증가함에 따라 인공지능 규제 마련의 시급성이 고조되었다. 유럽연합의 경우 2021년 4월에 인공지능 기술을 규제하는 방안을 담은 유럽연합 인공지능 법안을 발표하였다. 유럽연합의 법안은 이후 세계적인 인공지능 규제 경쟁을 촉발하였다. 미국의 경우 2022년 2월에 알고리즘 책임 법안을 발표하였다.

한국은 2019년 발표한 인공지능 국가 전략에서 인공지능 기본법제 마련의 전략을 제시하였고 2020년부터 인공지능 법제정비단이 출범하여 법제를 정비해 왔다. 세계적인 규제 거버넌스 흐름과 더불어 기존 법제 정비와 법제 마련의 필요성에 따라 한국도 산업 육성과 인공지능 신뢰성을 확보할 수 있는 법률 제정을 추진하게 되었다.

국회 과학기술정보방송통신위원회 법안심사 소위원회는 2023년 2월에 ‘인공지능산업 육성 및 신뢰 기반 조성 등에 관한 법률’ 제정안을 의결하였다. 해당 제정안의 경우 2020년 이후 여야의원이 발의한 기존 7개 법

안을 통합한 위원회안이다. 통합된 제정안은 2021년 7월 정필모 의원이 발의한 법안과 2022년 12월 윤두현 의원이 발의한 법안의 내용이 주로 반영되었다.³¹⁾ 해당 법안은 인공지능 기본계획 수립·시행, 인공지능위원회 등 관련 조직 신설, 국가 인공지능 센터 설립, 인공지능 기술개발 등의 근거를 마련한 내용과 인공지능 윤리 원칙에 따른 정책 수립, 고위험영역 인공지능에 대한 내용을 포함하였다.

하지만 2023년 2월 과학기술정보통신위원회 법안심사 소위원회를 통과한 인공지능법안은 1년 4개월간 국회에 표류하다가 결국 폐기 수순을 밟았다.³²⁾ 주요한 이유는 시민단체와 국가인권위원회의 반대에 부딪혔다는 점과 국회의 현안에서 밀려나 있다는 점이다(인터뷰이 C). 우선 해당 인공지능법안은 시민단체와 국가인권위원회의 반대에 직면했다. 국회에 표류하고 있던 인공지능 기본법의 경우 정책네트워크를 구성하는 각 집단의 입장이 뚜렷이 나타난 정책이다. 특히 과학기술정보통신부와 시민단체의 갈등이 뚜렷이 나타났다. 과학기술정보통신부는 인공지능 정책 추진을 위한 근거법을 마련하기 위해 인공지능 기본법의 조속한 통과를 촉구해 왔다. 반면 시민단체는 해당 법안의 ‘우선허용-사후규제’ 원칙, 고위험 인공지능에 대한 금지나 처벌 조항이 없다는 점, 인공지능 산업 육성을 하는 역할을 하는 과학기술정보통신부가 규제 감독의 기구가 되는 것은 문제가 있다는 점 등을 지적하였다(참여연대, 2023. 2.). 또한 국가인권위원회는 2023년 8월에 국회의장에게 국회에서 논의 중인 해당 법률안에 대해 의견을 표명하였다. 국가인권위원회는 해당 법률안이 “인공지능 개발·활용 과정에서 발생할 수 있는 인권침해, 차별 등의 문제를 예방 및 규제하기 위한 규정이 미흡”하므로 “‘우선허용-사후규제’ 원칙

31) 이종현. (2024. 4. 1.). *AI기본법 통과 필요성 재차 강조한 정부…과방위에 쏠리는 눈길*. 디지털데일리. <https://m.ddaily.co.kr/page/view/2024021414150253599> (최종접속일: 2024. 4. 1.); 정재훈. (2024. 1. 26.). *1년간 국회 계류중인 AI법안…경쟁에서 뒤처지면 어쩌나*. 전자신문. <https://www.etnews.com/20240126000220> (최종접속일: 2024. 5. 21)

32) 정상원. (2024. 5. 21.). *AI기본법, 1년4개월 국회표류 끝에 폐기 수순*. 한국경제. <https://www.hankyung.com/article/2024052135641> (최종접속일: 2024. 5. 21)

삭제하고, 인권영향평가 도입”해야 한다고 의견을 표명하였다(국가인권위원회, 2023). 다음으로 해당 인공지능법안은 21대 국회의 주요 현안에서 밀려나 통과되지 못했다. 하지만 결국 과학기술정보방송통신위원회 전체회의가 여야 의원들의 입장차이로 열리지 않으면서 인공지능 기본법안은 통과되지 못했다(한국경제, 2024. 5.).

1-3. 디지털 정책

디지털(Digital)은 “기술 · 산업 중심의 기존 ICT를 넘어 디지털로 전 분야가 근본적으로 재편되는 디지털 전환(Digital Transformation)을 의미”한다(대한민국 디지털 전략, 2022).

주요 디지털 기술은 AI, AI 반도체, 5G와 6G 통신, 양자, 메타버스, 사이버 보안 기술을 말한다(대한민국 디지털 전략, 2022).

『대한민국 디지털 전략』(2022. 9)

윤석열 대통령은 후보 시절 2022년 1월 대선 공약으로 ‘디지털 플랫폼 정부’, ‘디지털 경제 패권’, ‘과학기술 선도’ 공약을 발표하였다 (NIA, 2023). 이에 바탕을 두어 윤석열 대통령은 2022년 9월 미국 뉴욕 대학교가 주최한 디지털 포럼에 참석하여 디지털 혁신의 방향과 디지털 질서를 제시하는 ‘뉴욕 구상’을 발표하였다.³³⁾ 『대한민국 디지털 전략』은 뉴욕 구상을 실현하기 위한 정책 이행 방안으로 등장하였다. 디지털 전략은

33) 뉴욕 구상에서 윤석열 대통령은 디지털 기술은 자유를 확대하는데 기여해야 한다는 점, 누구든 디지털데이터에 공정하게 접근하고 정의롭게 활용할 수 있어야 하고 이를 바탕으로 경제적, 사회적 가치를 창출할 수 있어야 한다는 점, 디지털 생태계는 누구에게나 개방되고 누구든 들어와 활동할 수 있어야 하며 디지털 접근성을 높이기 위한 과감한 지원이 이루어져야 한다는 점, 디지털 시대의 노동과 일자리 개념을 새롭게 정립하고 디지털 위해에 대한 대처 방안을 고민해야 한다는 점을 강조하였다 (대한민국 디지털 전략, 2022)

디지털이 지닌 전략적 가치를 통해 디지털 선도 국가로 자리매김하기 위한 방향을 설정한 정책이었다. 해당 전략은 주요 디지털 혁신 기술에 집중하여 기술 패권을 확보하고 정부와 경제·사회 전반을 디지털에 적합한 구조로 5년 내 전환하고 기술을 활용하여 사회 문제를 해결하려는 것이 주요 목적이었다.

디지털 전략은 5대 전략과 19대 세부 과제로 이루어졌다. 5대 전략은 ‘세계 최고 디지털 역량’, ‘확장되는 디지털 경제’, ‘포용하는 디지털 사회’, ‘함께하는 디지털 플랫폼 정부’, ‘혁신하는 디지털 문화’로 이루어졌다. 해당 전략은 인공지능의 사회적·윤리적 부작용을 최소화하기 위해 다음과 같은 추진 과제를 포함하였다. 세계 최고 디지털 역량 전략에서 ‘사람과 공존하는 AI 윤리·제도 정립’ 과제를 제시하고 구체적으로 ‘AI 윤리·신뢰성 사회 정착 지원’, ‘국제적 AI 표준·규범 선도’, ‘AI 법·제도·규제 혁신 로드맵 2.0 마련’의 내용을 포함하고 있다. 포용하는 디지털 사회 전략에서는 국민 누구나 디지털 혜택을 보장하기 위해 디지털 활용을 보편적 권리로 보장하고 디지털 접근권과 리터러시 확보를 통해 모두가 디지털 혜택을 누리는 사회를 구현하겠다는 내용이 담겼다. 구체적으로 ‘디지털 권리장전 수립’의 추진 과제가 제시되었다. 함께하는 디지털 플랫폼 정부 전략에서는 안전하고 신뢰할 수 있는 이용환경 보장을 위해 ‘활용과 보안을 동시에 제고하는 신 보안체계 구축 및 이용 기반 마련’, ‘신뢰 확보를 위한 개인정보의 안전한 활용 기반 강화’, ‘보안 사고 신속 대응, 피해복구 등 종합지원’의 과제가 제시되었다. 혁신하는 디지털 문화 전략에서는 ‘디지털 경제·사회를 위한 기본법제 마련’의 내용이 포함되었다. 구체적으로 ‘인공지능기본법’, ‘디지털사회기본법’, ‘메타버스특별법’, ‘사이버안보기본법’, ‘디지털포용법’과 같은 디지털 경제의 5대 기반법을 제시하였다.

해당 전략은 인공지능뿐만 아니라 정부에서 집중하는 주요 디지털 혁신 기술 모두를 포괄하는 정책을 제시하였다. 이 중 인공지능의 사회적·윤리적 부작용을 최소화하기 위한 정책으로는 국민의 디지털 리터러시

향상과 같은 인식적 수단, 인공지능 국제 표준과 규범 선도와 같은 규범적 수단, 인공지능기본법 제정과 같은 규제적 정책 수단이 모두 포함되었다.

『디지털 권리장전』(2023. 9.)

2023년은 생성형 인공지능 서비스의 엄청난 과급력으로 다시 한번 인공지능 윤리와 정책에 대한 필요성이 커졌던 시기이다. 2022년 11월 OpenAI사에는 ChatGPT를 출시하였는데 해당 서비스는 출시 2개월 만에 사용자 1억 명을 돌파하며 엄청난 과급력을 보여주었다(The Guardian, 2023 Feb). 대규모 언어모델 서비스 이외에도 이미지 생성과 비디오 서비스 생성 등의 인공지능 서비스가 출시되었다. 하지만 생성형 인공지능 서비스의 경우 윤리적 이슈들이 충분히 논의되지 못한 상태로 출시되었다. 생성형 인공지능의 경우 학습 측면의 데이터와 연관된 저작권 문제, 출력 측면의 생성물과 연관된 허위 정보 문제가 대표적이다. 특히 생성형 인공지능을 통한 딥페이크, 가짜 뉴스 등 악용 사례들에 대한 위협이 커지며 인공지능 윤리 문제와 문제에 대한 대응의 필요성이 고조되었다. 이에 따라 인공지능 전문가들의 우려 목소리도 높아졌다. 대표적으로 2023년 3월에 테슬라 최고 경영자 일론 머스크(Elon Musk) 등 인공지능 전문가 1,000여 명은 인공지능의 개발을 잠정적으로 중단해야 한다는 공개서한에 서명했고 2023년 5월에 인공지능의 대부라 불리는 제프리 힌튼은 구글에서 퇴사하며 인공지능의 위험성을 경고했다. 또한 세계 각국은 정책적으로 생성형 인공지능 서비스에 대한 대응을 마련하려고 노력하였다.

한국 정부는 이 시기를 디지털 기술이 이끄는 변혁의 시기로 파악하고 디지털 선도 국가로 자리매김하겠다는 포부로 디지털 정책을 추진하였다. 인공지능 정책은 디지털 혁신 기술 중 하나로서 디지털 정책 안에서 다루어졌다. 2023년 1월에는 과학기술정보통신부 정보통신정책관에

‘디지털전략팀’이 신설되었고 2023년 3월에 해당 팀을 담당 부서로 ‘디지털 신질서 정립 협의체’가 출범하였다. 이 협의체는 뉴욕구상을 구체화한 『대한민국 디지털 전략』에서 파생된 『디지털 권리장전』을 만들기 위해 만들어졌다. 해당 협의체는 전문가와 이해관계자 등으로 구성되었다. 정치·사회, 철학·윤리, 법학, ICT의 학계 전문가와 산업계, 고령자, 장애인, 이용자 협단체 이해관계자 총 20명으로 구성되었다.

『디지털 권리장전』은 디지털 기술이 이끄는 사회에서는 자유와 평등, 인간 존엄과 같은 보편적 가치를 지키기 위한 새로운 차원의 규범이 요구된다는 배경하에 등장하였다. 또한 세계 각국에서 인공지능과 디지털 규범에 경쟁이 치열한 상황에서 글로벌 규범을 선도하고자 하는 목적을 바탕으로 한 정책이었다(대한민국 정책브리핑, 2023. 9.). 디지털 권리장전은 총 6장, 28개 조로 구성되어 있고 5가지 기본 원칙과 그 세부 원칙으로 이루어져 있으며 디지털 심화 시대³⁴⁾에 보장되어야 할 개인의 권리, 안전에 대한 내용과 함께 디지털 혁신과 성장에 대한 담론을 포함하고 있다(디지털 권리장전 해설서, 2023). 구체적으로 ‘자유와 권리 보장’, ‘공정한 접근과 기회의 균등’, ‘안전과 신뢰의 확보’, ‘디지털 혁신의 촉진’, ‘인류 후생 증진’ 내용을 포함한다. 특히 안전과 신뢰의 확보에서는 구체적으로 ‘디지털 기술의 윤리적 개발과 사용’, ‘디지털 위험 대응’, ‘디지털 프라이버시의 보호’, ‘건전한 디지털 환경 조성’, ‘아동·청소년의 보호’와 같은 내용을 포함하였다.

해당 정책은 디지털 정책의 대표적인 규범적 정책 수단이다. 『디지털 권리장전』은 발표된 이후 디지털 정책의 대표적인 정책으로 활용되었다. 해당 권리 장전의 5대 원칙은 이후 2024년 5월에 발표된 20대 정책과제를 담은 『새로운 디지털 질서 정립 추진계획』의 토대가 되었다.

34) 디지털 심화 시대는 플랫폼의 전방위적 확산, 생산의 자동화와 직무의 자동화로 일의 양상 변화, 개인별 맞춤형 서비스 제공의 확장, 가상세계와 현실 세계의 융합을 특징으로 한다 (디지털 권리장전 해설서, 2023).

<표 11> 한국 인공지능 정책 변화에 영향을 준 주요 사건

년도	사건
2012	이미지넷 대회, 딥러닝 전성기 시작
2016	알파고와 이세돌 대국
2017	아실로마 원칙, 주요국 인공지능 국가 전략 추진
2018	EU GDPR 발효, 인공지능 서비스 본격화와 오남용 사례 빠르게 증가
2019	EU 신뢰할 수 있는 인공지능 가이드라인 발표, 미국 2019 알고리즘 책임 법안 발표, OECD 권고안 발표
2021	이루다 사건, EU 인공지능 법안 발표
2022	미국 2022 알고리즘 책임 법안 발표, CahtGPT 출시
2023	생성형 인공지능 서비스 본격화

<표 12> 과학기술정보통신부의 주요 인공지능 정책 분석


번호	시기	주요정책	주관기관	배경	목적	수단
1	2016. 12.	제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책	관계부처 합동, 미래창조과학부	4차 산업혁명으로 경제 사회구조 대변혁이 발생할 것으로 전망되는 상황에서 그 원인, 과급효과 및 국가적 대책 마련 등이 매우 시급	- 글로벌 수준의 지능정보기술 기반 확보 - 전 산업의 지능정보화 촉진 - 사회정책 개선을 통한 선제적 대응	규제, 규범, 인식 모두 포함
2	2018. 5.	인공지능(AI) R&D	과학기술정보통신	인공지능이 경제 성장과 사회 난제 해결의 돌파구가 될 것으로	세계적 수준의 인공지능 기술력 및 R&D 생태계 확보	규범, 인식

		전략	부	기대되나 한국은 인공지능 전문 인력 확보와 역동적 기술혁신 생태계 구축이 미비	세계적 수준의 AI 기술력 확보, 최고급 인재 양성, 개방 협력형 연구기반 조성	
3	2018. 10.	지능정보화 사회 윤리 가이드라인 및 윤리헌장	과학기술정보통신부, NIA	4차 산업혁명에 경제 사회 구조와 개인의 삶의 방식까지 근본적으로 변화시킬 것으로 예측되면서 지능정보기술의 산업적, 사회적 활용에 대한 부작용에 대한 우려가 커짐에 따라 주체별 권리·책임의 범위와 관련한 규범적 논의의 필요성 대두	인간 중심의 지능정보사회를 구현하기 위해, 지능정보기술 및 서비스 개발자·공급자의 책임윤리 강화 및 이용자의 오남용 방지를 위한 지침 제공	규범
4	2019. 12.	인공지능(AI) 국가 전략	관계부처 합동, 과학기술정보통신부	세계는 4차 산업혁명으로 인한 변화와 인공지능 기술의 발전에 직면하고 있기 때문에 이에 대한 적극 대응과 인공지능 기술 활용이 경제와 사회에 필요	인공지능 생태계 구축, 인공지능 활용 전면화, 인공지능과 조화·공존	규제, 규범, 인식 모두 포함
5	2020. 6.	지능정보화 기본법	과학기술정보통신부	정보화에서 지능정보화 시대로의 이행에 발맞춰 인공지능 시대의 기본법 마련의 필요	법제도적 뒷받침 하에 세계를 선도할 인공지능 생태계를 구축, 국가적 추진체계와 기반을 정비할 필요	규제
6	2020. 12.	사람이 중심이 되는	관계부처 합동,	인공지능 기술의 발전·확산과 함께 인공지능 기술의 윤리적 개	인공지능 시대 바람직한 인공지능 개발·활용 방향 제시	규범

	(23)	인공지능(AI) 윤리기준	과학기술 정보통신 부, KISDI	발· 활용 역시 세계 각국과 주요 국제기구의 관심 대상이 되어 옴		
7	2020. 12. (24)	인공지능 법·제도·규 제 정비 로드맵	관계부처 합동, 과학기술 정보통신 부	인공지능 기술력 향상과 도입이 본격화되면서, 산업 경쟁력을 높 이고 활용 걸림돌을 제거하면서 도 부작용을 최소화한 선제적 법·제도·규제 정비 필요	• 사람 중심의 인공지능 시대 실 현을 위한 인공지능 법 · 제도 · 규제 로드맵 제시 • 인공지능 공통 기반, 분야별 활용 확산에 초점을 둔 과제 도출	규제, 규범, 인식 모두 포함
8	2021. 5.	사람이 중심이 되는 인공지능을 위한 신뢰할 수 있는 인공지능 실현전략(안)	관계부처 합동, 과학기술 정보통신 부	인공지능이 전 분야에 빠르게 도 입 · 활용되며 혁신을 창출하고 있으나, 예상치 못한 사회적 이 슈 · 우려도 대두되고 있는 상황 에서 인공지능의 혜택은 극대화 하면서 위험 · 부작용을 최소화 하기 위한 인공지능 신뢰 확보 방안 필요	• 신뢰 가능한 인공지능 구현 환 경 조성 • 안전한 인공지능 활용을 위한 기반 마련 • 사회 전반 건전한 인공지능 의 식 확산	규제, 규범, 인식 모두 포함
9	2021. 7.	인공지능 육성 및 신뢰 기반 조성 등에	정필모 의원 대표 발의	새로운 기술로 인한 새로운 문제 대두(e.g. 이루다, 배달 앱 요기 요, 포털 뉴스 서비스), 인공지능 진흥과 인공지능의 신뢰는 같이	산업 육성하면서도 인공지능 윤리 원칙을 바탕으로 인공지능 신뢰성 을 확보	규제

		관한 법률안		확보되어야 함		
10	2022. 9.	대한민국 디지털 전략	관계부처 합동, 과학기술 정보통신 부	디지털이 지닌 전략적 가치를 통해 새로운 선도 국가로 자리매김할 수 있는 새로운 문명사적 전환기를 맞이하여 디지털 시대의 패권 국가로 도약을 준비	세계 최고 수준의 디지털 역량을 갖추고 정부와 경제 · 사회 전반을 디지털에 적합한 구조로 5년 내 전환	규제, 규범, 인식 모두 포함
11	2022. 12.	인공지능 육성 및 신뢰 기반 조성 등에 관한 법률안	윤두현 의원 대표 발의	미국, 유럽연합 등에서는 인공지능 산업 진흥을 위한 지원 체계와 신뢰성과 윤리 확보를 위한 법률을 추진 중, 한국은 인공지능 분야에 특화된 기본법이 부재하고 정책 내용과 주체가 분절되어 있음	인공지능산업 발전과 신뢰성 확보의 균형을 달성하는 법 · 제도적 질서 마련	규제
12	2023. 2.	인공지능산업 육성 및 신뢰 기반 조성에 관한 법률	국회과학기술정보 방송통신 위원회	인공지능은 디지털 경제의 핵심 역량, 산업 육성을 위해 지원 체계 마련 필요, 기술과 산업의 혁신뿐만 아니라 신뢰성 또는 윤리가 중요한 문제로 대두, 미국과 유럽연합도 인공지능 신뢰성과	산업 육성과 인공지능 신뢰성 방안 모색하여 균형을 달성하는 법 · 제도적 질서 마련	규제

				윤리를 확보할 수 있는 인공지능 법률 제정 추진		
13	2023. 9.	디지털 권리장전	과학기술 정보통신 부	디지털 기술이 이끄는 변혁은 인 간의 삶과 사회 모습에 변화를 유발하며 자유와 평등, 인간 존 엄과 같은 보편적 가치를 지키기 위한 새로운 차원의 규범이 요구 됨	• 글로벌 디지털 규범을 선도 • 인간의 존엄과 가치에 대한 존 중을 기본으로 디지털 향유권 이 인간의 보편적 권리로 보장 되는 새로운 디지털 질서 정립	규범



[그림 6] 주요 인공지능 정책 구조

1-4. 한국 인공지능 정책 분석 정리

우선 한국의 인공지능 윤리 정책은 지능정보, 인공지능, 디지털의 주요 키워드를 중심으로 변화를 보였다. 이렇게 변화가 일어난 이유는 정권 변화에 따른 주요 정책 변화와 인공지능 기술의 중요성이 변화하였기 때문이다. 지능정보 정책의 경우 박근혜 정부에서 다뤄졌는데 인공지능과 밀접한 관련을 맺고 있는 기술에 대한 집합적 정책을 제시하였다. 하지만 이후 세계 각국에서 인공지능을 키워드로 한 정책이 발표되고 인공지능의 중요성이 커지게 되면서 문재인 정부로 넘어와서 인공지능을 키워드로 한 정책이 발표되었다. 이후 윤석열 정부에 들어서게 되면서 디지털이라는 주요 정책 키워드 아래에서 6대 디지털 혁신 기술³⁵⁾ 중 하나로 인공지능 정책이 추진되었다.

둘째, 과학기술정보통신부의 인공지능 윤리 정책은 윤리 강령, 법률안, 지침과 가이드라인, 인증 및 표준 순서로 발표되었다. 2016년도 지능정보사회 윤리 강령이 나온 이후 2020년에 국가정보화 기본법이 지능정보화 기본법으로 개편되고, 인공지능 법제정비단이 출범하는 등 본격적으로 인공지능 법제도 정비가 시작되었다. 또한 인공지능 윤리 정책 포럼이 출범하며 인공지능 윤리 기준에서 제시된 규범적 접근을 반영하는 지침과 가이드라인 작업이 시작되었다. 이후 2023년에 인공지능 분야에 특화된 기본법 논의가 본격화되고 한국 최초 인공지능 단체표준이 발표되었다. 이를 통해 정책 수단이 인식과 규범의 정책 수단에서 규제적 수단으로 넘어가는 것을 알 수 있다. 이는 세계적인 인공지능 거버넌스 흐름을 따라가는 양상을 보인다. 과학기술정보통신부는 민간 자율 규제를 활성화하는 방향으로 정부 차원에서 분야별 개발 안내서, 자율점검표, 표준 등을 제공해 왔다. 하지만 [그림 6]에서 확인할 수 있듯이 해당 정책이 진행되는 과정이 분절적으로 형성되지 않았다. 이는 한국 인공지능 윤리

35) 6대 디지털 혁신 기술은 양자, 사이버보안, 인공지능, 인공지능반도체, 메타버스, 5G, 6G이다.

정책의 세 번째 특성과의 연결된다.

셋째, 한국은 미국, 유럽연합과 비교했을 때 인공지능 윤리 거버넌스를 선도하고 있지는 않지만, 거버넌스를 선도하는 국가들을 따라 인공지능 윤리 강령, 전략, 법제 등의 정책을 추진하는 속도가 빠르다. 국가 차원의 윤리 기준, 규제 정비 로드맵, 법률안, 체크리스트, 표준 등이 선도국들에 뒤처지지 않고 모두 나온 것을 확인할 수 있었다.

넷째, 과학기술정보통신부의 인공지능 정책은 전반적으로 산업 육성 및 진흥과 민간 자율 규제의 양상을 보인다. 우선 과학기술정보통신부는 산업 육성 및 진흥과 인공지능 윤리 및 신뢰성을 모두 포괄하여 정책을 내고 있지만 초점이 육성 및 진흥 쪽에 더 가깝다. 이는 『인공지능(AI) 국가 전략』에서 ‘우선허용-사후규제’ 방향을 명시한 점과 이를 바탕으로 법제도를 정비해 온 점에서도 확인할 수 있었다. 다음으로 과학기술정보통신부의 정책은 민간 자율 규제 기조 아래에서 민간 자율을 바탕으로 한 점검표와 표준 등을 강조해 왔다.

마지막으로 대부분의 인공지능 윤리 정책이 민관 협력 조직을 통해 구성되었다. 지능정보사회 추진단, 정보문화 포럼, 인공지능 법제정비단, 인공지능 윤리 정책 포럼, 디지털 신질서 정립 협의체 등의 조직은 정부, 기업 및 협회, 전문가, 시민단체 행위자를 포함하여 구성되었으며 이를 통해 인공지능 윤리 정책형성과정에서 정책네트워크가 형성되어 왔음을 알 수 있다.

2. 주요 인공지능 정책 행위자 분석

한국 인공지능 거버넌스와 정책형성과정을 분석하기 위해서는 한국 인공지능 윤리 정책형성과정의 주요 행위자를 식별하고 그들의 정책네트워크를 분석하는 것이 필요하다. 정책과 정책행위자는 상호작용하며 형성되고 정책네트워크의 분석 요소인 행위자 권력 분포, 선호, 상호작용 유형은 서로 영향을 미치며 정책형성과정에 영향을 미치기 때문이다.

한국 인공지능 정책의 주요 행위자 집단은 공공 부문인 정부와 민간 부문인 전문가, 기업 및 협회, 시민단체로 나뉜다. 주요 행위자는 정부 문서, 보도자료, 인터뷰, 기사를 통해 파악하였다. 정부에서는 과학기술정보통신부를 중심으로 국무총리 산하 경제인문사회연구회 소속 정부출연 연구기관인 KISDI(정보통신정책연구원), 과학기술정보통신부 산하의 위탁집행형 준정부기관인 NIA(한국지능정보사회진흥원), 정보통신 단체표준 제정기관인 TTA(한국정보통신기술협회)가 주요 행위자로 파악되었다. 과학기술정보통신부와 협력관계를 맺고 있는 KISDI, NIA, TTA는 과학기술정보통신부와 같은 입장으로 파악하였다. 인공지능 윤리 정책과 관련한 또 다른 정부 행위자로는 개인정보보호위원회, 방송통신위원회, 산업통상자원부, 문화체육관광부, 공정거래위원회 등이 있지만 본 연구는 과학기술정보통신부의 정책에 초점을 두고 있기 때문에 해당 기관들은 주요 분석의 범위에서 제외하였다. 전문가 집단에서는 인문·사회학, 법학·법조, 공학계가 주요 행위자로 파악되었다. 이 외에도 인공지능 윤리 정책의 행위자 집단으로 교육학, 교육계의 전문가 집단이 있지만 해당 집단의 경우 윤리 교육이라는 특정 주제에 집중하여 활동하는 것으로 보이고 그룹의 폐쇄성이 짙은 것으로 나타났기 때문에 분석에서 제외하였다. 기업 및 협회에서는 인공지능 분야의 한국 대기업, 중소기업, 스타트업, 인공지능 관련 협회가 주요 행위자로 파악되었다. 인공지능 산업에서 인공지능 분야의 글로벌 빅테크를 빼고 논할 수는 없지만 글로벌 빅테크의 경우 인공지능의 역기능을 최소화하고 신뢰성을 확보하기 위한

한국 인공지능 정책형성과정에 개입하는 주요 정책 행위자로 파악되지는 않았다. 시민단체에서는 소비자연맹, 소비자시민모임, 진보네트워크센터, 참여연대 등의 시민단체가 주요 행위자로 파악되었다.

2-1. 권력 분포

1) 정부

과학기술정보통신부는 인공지능 정책의 핵심 행위자로 파악되었다. 과학기술정보통신부는 인공지능 정책네트워크에서 집중된 권력을 가진 집단이다. 또한 과학기술정보통신부는 KISDI, NIA, TTA와 협력하여 인공지능 윤리 정책을 형성해 왔다. KISDI는 연구를 통해 정책의 방향성을 제시하고 NIA는 과학기술정보통신부의 정책 방향성을 바탕으로 정책을 구성해 왔다(인터뷰이 A, C). TTA는 과학기술정보통신부와 인공지능 표준 제정과 보급 분야에서 협력해 왔다.

모든 인터뷰이는 공통적으로 정책형성과정에서 과학기술정보통신부가 집중된 권력을 가지고 있다고 말했다. 모든 집단은 과학기술정보통신부는 주요한 관계를 맺었다. 또한 각 집단의 인터뷰이는 과학기술정보통신부가 정책형성과정에서 영향력이 가장 컸다고 답변했다. 한국 인공지능 윤리 정책에 인문·사회 전문가로 활발하게 참여하는 인터뷰이 E는 “전문가도 인공지능 윤리 정책의 방향성을 제시하고 있으나 결국 과학기술정보통신부의 입장이 정책형성과정에서 가장 중요한 역할을 한다”고 말했다.

2) 전문가

전문가는 인공지능 정책형성과정에서 각 집단에 자문 역할을 하고 있는 핵심 행위자로 파악되었다. 전문가 집단은 인공지능 윤리 기준, 인공지능

윤리 가이드라인, 인공지능 법제도 로드맵, 인공지능 기본법안, 인공지능 표준 등을 만드는 데 활발히 참여해 왔다. 전문가 집단은 단일한 집단이 아니라 인문 · 사회계, 법학계, 법조계, 공학계로 이루어져 있는 복합적인 집단이다. 또한 각 분야 안에서도 상이한 의견이 존재한다. 각 분야마다 주로 참여하는 정책도 다르고 윤리 정책에 끼치는 영향도 다르게 나타났다.

인문 · 사회계 전문가의 경우 인공지능 정책 형성 초기부터 꾸준히 정책형성과정에 참여하면서 영향력을 끼치고 있는 것으로 파악되었다. 하지만 인공지능 거버넌스의 흐름이 윤리 강령에서 규제 중심으로 넘어가게 되면서 전문가 집단의 중심 권력이 인문 · 사회계 집단에서 법학계와 법조계 집단으로 이동하였다. 우선 인문 · 사회계 전문가의 경우 주로 인공지능 윤리 기준, 가이드라인 정책 형성에 참여해 왔다. 법학 · 법조계 전문가의 경우 인공지능 윤리 기준, 가이드라인, 인공지능 표준, 인공지능 법제도 로드맵, 인공지능 기본법안 등 대부분의 정책 형성에 참여해 왔다. 공학계 전문가의 경우 지능정보사회 윤리 가이드라인 및 윤리 현장과 같은 윤리 강령이 처음 형성되던 논의에는 거의 참여하지 않다가 점차 참여가 증가하였다.³⁶⁾ 하지만 인터뷰이들은 여전히 공학계의 전문가들이 다른 분야의 전문가에 비해 정책형성과정에 참여를 덜 한다고 전했다(인터뷰이 G, I).

포럼과 협의체 명단³⁷⁾ 그리고 인터뷰를 통해 전문가 집단 중 법학계와 법조계의 영향력이 가장 크게 나타남을 알 수 있었다. 인공지능 스타트업의 인터뷰이 I는 실제로 정책형성 과정에서 “법학계와 법조계의 행위자가 과대대표”되는 양상을 띠었다고 말했다. 하지만 “법학계와 법조계

36) 지능정보사회 윤리 가이드라인 및 윤리현장 작업에 참여한 인터뷰이 G에 따르면 당시 외부 전문가는 철학, 윤리, 법학, 사회 전문가로 구성되어 있었고 공학계 전문가는 한 명뿐이었다.

37) 인공지능 윤리 정책 포럼 1기, 2기와 해당 포럼의 연장선인 인공지능 윤리 · 신뢰성 포럼 3기의 명단을 통해 확인하였다 (인공지능 윤리 소통채널; 과학기술정보통신부, 2023a).

전문가는 실상 기술에 대한 이해도가 낮다”고 비판하였다. 전문가 집단에서 법학계와 법조계의 전문가에게 권력이 집중된 이유는 우선 한국의 인공지능 정책이 비교적 짧은 시기에 한 번에 형성되었고 정책화의 속도도 굉장히 빠르게 나타났기 때문이다. 인터뷰이 E는 “정부가 여론과 시민의 반응에 굉장히 민감하여 정책화 속도가 굉장히 빠르게 나타났다”고 주장했다. 실제로 한국 정책에서 인공지능 윤리 기준, 표준, 법제화의 작업이 거의 동시에 이루어졌다. 이 과정에서 필수적으로 법학계와 법조계 전문가 집단의 자문이 필요하였고 이들 집단이 자연스럽게 주류의 논의이루게 된 것으로 보인다. 다음으로 주요 인공지능 정책 논의가 2020년도 이후 법제도 정비 논의로 변화하며 영향력을 키워 온 법학 법조계 전문가들이 그 이후로도 꾸준히 인공지능 윤리 정책 영향을 끼치고 있기 때문이다. 법학 · 법조계가 주된 행위자로 영향력을 키워나가게 되면서 인공지능 윤리 정책의 논의 또한 꾸준히 법제도 중심으로 이루어지게 되고 다시 법제도 중심의 정책 논의는 법학 · 법조계의 영향력을 키우는 방향으로 작용하였다. 감사원 소속기관의 인공지능 규제 전문가 D는 “인공지능 정책형성과정에서 법학 · 법조계가 중심이 되고 있기 때문에 더욱 규제 이야기가 많이 등장하게 되는 것”이라고 지적하였다. 이 경향은 선행문헌 연구에서도 찾아볼 수 있는데 한국의 인공지능 거버넌스 연구는 주로 법학계 전문가들에 의해 이루어지고 있었다.

반면 공학계 전문가는 정책형성과정에서 전문가 집단 중 가장 영향력이 작다고 파악되었다. 인공지능 윤리 정책에 인문 · 사회적 지식만 필요한 게 아니라 공학적 지식도 필요함에도 불구하고 공학계 전문가는 다른 전문가 집단보다 정책형성과정에서의 영향력이 작게 파악되었다. 공학계 전문가의 영향력이 작게 파악된 이유는 다음과 같다. 우선 공학계 전문가들이 정책 관련 공론장에 잘 나오지 않기 때문이다. 인터뷰이들은 공학계 전문가들이 인공지능 정책과 관련한 공론장에 잘 나오지 않는다고 입을 모았다. 또한 인터뷰이 I는 “기술자 자체가 공론장에 잘 나오지 않는다”고 이야기하며 “기술자가 규제 감수성을 높일 필요가 있다”고 지

적하였다. 다음으로 다른 분야 전문가와 공학계 전문가가 사용하는 용어의 의미가 달라 소통이 쉽지 않았기 때문이다. 법학계 전문가 F는 “초기 인공지능 법안에 대해 의견 수렴 작업을 할 때 학계별로 정의하는 용어가 많이 달라서 회의 과정에 어려움이 많았다”고 전했다. 예를 들면 설명가능성이나 공정성에 대한 용어의 의미에 대해 법학계와 공학계가 정의하는 방식이 달라 소통에 어려움을 겪었다고 했다. 마지막으로 공학계 전문가들이 기술의 윤리나 사회적 영향에 대한 고려가 다른 집단의 전문가보다 낮기 때문이다. 공학계 전문가 G는 “공학계 전문가는 주로 기술의 역기능보다는 기술적 해결가능성을 생각한다”고 주장했다. G는 “공학계가 보통 기술에 역기능이 있어도 이를 기술적으로 해결할 수 있고 통제 가능하다고 생각하는 경향이 있다”고 전했다. 이는 전문가 F와의 인터뷰에서도 확인할 수 있었는데 전문가 F는 “공학계열은 윤리나 사회적 영향에 대한 인식이 다소 낮다”고 말했다.

3) 기업 및 협회

기업과 협회는 과학기술정보통신부의 인공지능 윤리 정책형성과정에 활발히 참여해 온 행위자이다. 한국 인공지능 윤리 정책형성과정에서 기업은 인공지능 분야의 대기업, 중소기업, 스타트업으로 그 층위가 나뉘지만, 정책형성과정에 모든 층위의 기업 모두 활발히 참여하고 있는 것으로 나타났다. 하지만 기업 내의 권력 분포는 대기업에 집중된 것으로 파악됐다. 인공지능 기업 관련 협회 관계자 J는 “협회 차원의 입장이 수렴되는 과정에서 회장사인 대기업의 입장이 많이 반영된다”고 전했다. 협회는 기업들의 의견을 수렴하여 정부에 전달하는 역할을 맡아 왔다.

기업들은 학계, KISDI나 NIA와 같은 정책연구원에서 주최하는 각종 포럼과 추진단, 협의체 활동을 통해 정책을 같이 형성하거나 정책의 의견 수렴 과정에서 꾸준히 기업 및 협회의 입장을 전달하며 정책에 영향을 미쳐 왔다. 한국 인공지능 분야 대기업 관계자 H는 “과학기술정보통신

신부에서 정책을 만들 때 기업은 기업의 사내 개발 프로세스 내용을 전하며 서로 영향을 주고받기도 한다”고 말했다. 또한 인터뷰이 H는 “기업이 인공지능 개발 가이드라인과 같은 정책의 최종본이 나오기 전에 기업 의견을 수렴하는 과정에서 그리고 과학기술정보통신부가 작업한 인공지능 기본법에 대한 의견 수렴 과정에서 주로 협회를 통해 입장을 전달했다”고 전했다. 인공지능 기업 관련 협회 관계자인 인터뷰이 J는 “협회가 간담회를 통해 업계 차원의 의견을 전달하며 과학기술정보통신부 정책형성 과정에 참여해 왔다”고 말했다.

4) 시민단체

시민단체는 초기 인공지능 윤리 정책형성과정에서는 영향력이 두드러지지 않다가 2023년 2월 과학기술정보통신부가 추진한 인공지능 기본법안이 국회 과학기술정보방송통신위원회 정보통신방송법안심사소위를 통과한 이후 주요 행위자로 나타났다. 한국의 인공지능 윤리 정책이 만들어지기 시작하던 초기에는 정책에 대한 시민 차원의 관심이 낮았고 시민단체의 인공지능 기술에 대한 이해도도 많이 낮았다(인터뷰이 E, F, I). 그러다 점차 시민단체는 기존에 초점을 맞춰오던 개인정보, 데이터, 인권과 관련한 관점에서 인공지능의 사회적 · 윤리적 문제에 접근해 왔다. 정보인권 관련 시민단체 대표 K에 따르면 2023년 이전에 시민단체는 인공지능을 도입한 채용 문제³⁸⁾, 인공지능 챗봇의 혐오 · 차별 발언과 개인정보 침해 문제, 인공지능 학습용 생체정보 민간 업체 이관 문제³⁹⁾ 등을 비판하는 활동을 해 왔다. 2023년 2월 이후, 인공지능 기본법안 논의가 본격적으로 촉발된 후 시민단체의 영향력은 급격히 커졌다. 2023년 2월

38) 김남영. (2020. 10. 27). 공공기관 AI 면접 기준 뭐냐”...정보공개 소송 낸 시민단체. 한국경제. <https://www.hankyung.com/article/2020102755421> (최종 접속일: 2024. 6. 9.)

39) 천호성. (2021. 10. 21). 정부, 출입국 얼굴사진 1억7천만건 AI업체에 넘겼다. 한겨레. <https://www.hani.co.kr/arti/economy/it/1016022.html> (최종 접속일: 2024. 6. 9.)

에 기존 7개 법안을 통합한 위원회안이 법안심사 소위원회를 통과한 것에 대해 진보네트워킹센터 등 15개 인권시민단체는 과학기술정보방송통신위원회에 반대 의견서를 제출하였다(참여연대, 2023. 3.). 또한 2023년 8월에 국가인권위원회가 해당 법안에 대해 반대 의견을 표명한 이후 참여연대, 진보네트워킹센터 등 31개 시민단체는 “국회는 인공지능 법률안에 대한 국가인권위원회의 의견을 수용하라”는 반대 의견을 표명하였다(31개 단체, 2023). 시민단체는 과학기술정보통신부가 추진하고 있는 해당 법안의 취지가 ‘우선허용-사후규제’이고 위험한 인공지능을 금지하고 규제하는 조항이 미비하다고 지적하며 이는 소비자권, 프라이버시 보호, 인권 측면에서 통과되어서는 안 되는 법안임을 주장하였다. 이러한 시민단체의 주장은 이후 인공지능 기본법 논의에 영향을 주게 되었다. 인공지능 기업 관련 협회 관계자 J는 “기업들이 사전 규제를 부담스러워하나 시민단체의 반발과 비판에 대한 우려도 동시에 하고 있다”고 전했다. 또한 2024년에 국회 과학기술정보방송통신위원회는 ‘우선허용-사후규제’ 원칙을 삭제한 ‘인공지능 법안 수정안’을 21대 국회가 끝나기 전까지 추진했다(한겨레, 2024).

시민단체는 과학기술정보통신부의 정책형성과정에 참여해 왔음에도 과학기술정보통신부의 실질적인 정책 기조에 끼치는 영향력은 작았다. 2022년 과학기술정보통신부의 인공지능 윤리 정책 포럼, 2023년 디지털신질서 정립 협의체 등 민관협력 조직에 꾸준히 참여하며 정책형성과정에서 소비자권, 프라이버시 보호, 인권 측면을 강조해 왔고 인공지능의 위험을 실질적으로 규제할 방안을 마련해 달라고 정부에 촉구하며 시민단체는 인공지능 규제에 대한 강력한 입장을 드러내 왔다. 정보인권 시민단체 대표 K는 “인공지능 기본법안에 인공지능의 위험을 실질적으로 규제할 수 있게끔 고위험 인공지능에 대한 세밀한 정의, 처벌 규정, 세부 규정, 피해 구제 방안 등이 포함되어야 한다”고 주장하였다. 하지만 과학기술정보통신부가 추진해 온 정책과 법안은 여전히 혁신을 저해하는 규

제를 반대하는 정책 방향을 보여 왔다. 인공지능 정책 포럼과 디지털 신질서 정립 협의체 모두에 참여했던 전문가 E는 “시민단체가 정책형성과정에 참여하는 조직에 포함되는 등 시민단체의 의견이 정책적으로 들어갈 통로는 마련되어 있지만, 시민단체는 자신들의 의견이 강제력을 발휘할 수 없는 조직에만 속해있다”고 지적하였다. 이에 더하여 과학기술정보통신부와 협력하여 정책을 구성하는 산하기관에서는 의견 수렴 과정에서도 시민단체와의 소통은 거의 이루어지지 않았다. 인공지능 정책과 관련한 의견 수렴 과정에서 주로 전문가와 기업의 의견을 수렴해 왔다. 과학기술정보통신부 2차관 산하기관 소속 인터뷰이 C는 그 이유로 내부에서 정부 정책 입장에 반대하는 의견이 나오면 안 되기 때문이라고 설명했다. 또한 전반적으로 인공지능 정책 자체가 전문가와 기업 위주로 돌아가고 시민단체의 목소리가 거의 반영되지 않는다는 지적도 있었다(인터뷰이 C).

5) 한국 인공지능 정책네트워크의 권력 분포

우선 한국의 인공지능 윤리 정책네트워크의 권력 분포는 정부에게 집중된 양상을 보였다. 기업과 전문가가 그다음의 영향력을 발휘하고 있었고 시민단체가 가장 작은 영향력을 보였다. 둘째, 전문가 집단 내에서 정책 흐름 변화에 따라 영향력 있는 행위자가 변화하는 것을 파악하였다. 한국 인공지능 윤리 정책이 윤리 기준에서 표준이나 인증 그리고 법과 같은 규제 방향으로 넘어오게 되면서 중심 행위자가 인문·사회계 전문가에서 법학계와 법조계 전문가로 변화하였다. 셋째, 현재 전문가 집단 내에서의 권력 분포는 법학계와 법조계 전문가의 영향력이 가장 크고 공학계 전문가의 영향력이 가장 작았다. 넷째, 기업 집단 내에서의 권력 분포를 살펴보면 대기업의 영향력이 다른 기업들의 영향력보다 컸다. 마지막으로 시민단체는 2023년 인공지능 기본법안 논의 이후에 주된 행위자로 등장하

였고 인공지능 기본법 논의에 강력한 영향을 끼치고 있었다. 하지만 여전히 과학기술정보통신부의 인공지능 정책 기조에 끼치는 영향력은 낮았다.

2-2. 행위자 선호

1) 정부

과학기술정보통신부는 인공지능 정책네트워크에서 집중된 권력 분포를 가진 집단으로 과학기술정보통신부가 발표한 인공지능 윤리 정책을 통해 과학기술정보통신부의 선호를 알 수 있다. 우선 사회적 · 윤리적 문제를 강조하는 것과 성능 향상 · 혁신을 강조하는 것 중 어떤 것에 더 우선의 목표를 두는지에 관한 입장인 ‘윤리적 AI’ 선호에서 과학기술정보통신부는 ‘AI의 사회적 · 윤리적 문제를 방지하는 것과 성능 향상 · 혁신을 강조하는 것 모두 중요하다’는 정책 입장을 가진다. 과학기술정보통신부의 ‘윤리적 AI’ 선호는 정권 변화와 관계없이 유지돼 왔다. 과학기술정보통신부는 인공지능 윤리 정책을 인공지능 정책의 초기부터 꾸준히 추진해 왔고 인공지능 기술을 주요 국가 혁신 기술로 선정하고 인공지능 기술과 산업을 키우려는 정책 방향을 꾸준히 보여 왔다. 다만 과학기술정보통신부는 규제와 관련하여서 인공지능의 위험을 방지하기 위한 실질적 규제보다는 산업 장려를 더 강조해 왔다. 감사원 소속기관의 인공지능 규제 전문가 D는 “정부가 규제보다는 산업 장려를 더 강조한다”고 전했다.

과학기술정보통신부의 규제 형식, 주체, 시점에 대한 입장인 ‘규제’ 선호는 다음과 같다. 우선 인공지능 규제 형식에 관하여 과학기술정보통신부는 인공지능 산업 육성과 신뢰 기반 조성을 위한 근거법 마련을 위한 인공지능 기본법안을 추진하며 경성 규범에 대한 작업을 하면서도 인공지능 윤리 기준, 개발안내서, 자율점검표, 표준과 같은 그 이외의 규범 형식도 발표해 왔다. 하지만 과학기술정보통신부가 21대 국회에서 추진한 법안에는 인공지능 위험을 실질적으로 규제하기 위한 내용이 들어가

있지 않다는 비판을 받기도 했다. 다음으로 인공지능 규제 주체에 관하여 과학기술정보통신부는 민간이 이끄는 거버넌스와 민간 자율 규제를 강조해 왔다. 과학기술정보통신부에서 발표하는 자율점검표, 개발 안내서 등은 민간이 자율적으로 참고하여 신뢰성을 확보할 수 있도록 하는 지원책이다. 정부가 이런 정책을 시작한 계기 중 하나가 인력이 부족한 기업들이 참고하여 자율적으로 규제할 수 있는 환경을 조성하고자 함이었다. 인공지능의 신뢰성 확보를 위한 제도 개선 전략의 경우도 제도 개선은 민간의 자율성을 저해하지 않는 선에서 정책을 시행하려는 계획을 담았다. 또한 인공지능의 신뢰성 확보를 위한 윤리 전략에서도 민간 중심으로 윤리를 정립하고 의식을 확산시키려는 계획을 담았다. 마지막으로 인공지능 규제 시점에 관하여 과학기술정보통신부의 정책 입장은 과학기술정보통신부가 추진한 인공지능 기본법안의 내용을 통해 확인된다. 법안 소위를 통과한 인공지능 기본법안에는 금지 인공지능과 고위험 인공지능의 경우 인간을 위한 개발을 해야 한다는 의무를 명시하고 있다는 점에서 사전적 규제의 가능성이 담겨 있었다. 하지만 해당 법안은 이러한 의무를 어겼을 때 처벌 규정이 명시되어 있지 않아 결국 사후 규제의 정책 입장을 담았다고 볼 수 있다. 이러한 ‘우선허용-사후규제’의 정책 입장은 과학기술정보통신부가 2019년 발표한 『인공지능(AI) 국가 전략』에서부터 확인할 수 있다. 당시 이미 법제 정비의 기본 기조를 ‘우선허용-사후규제’로 명시하였다.

2) 전문가

전문가 집단은 기업 및 협회 혹은 시민단체와 달리 명확한 이해관계를 가지고 있는 집단이 아니어서 수렴된 정책 입장을 식별하기 어려우나 집단 안에서 다양한 정책 입장이 나타나는 것은 확인할 수 있었다. 전문가 집단은 인공지능 윤리 정책형성과정에서 정부, 기업, 시민사회 각 집단에 자문의 역할을 하며 각 집단을 중개하는 역할을 해 왔다. 인터뷰를 통해

인공지능 윤리 정책형성과정에 활발히 참여하고 있는 각 분야 전문가의 정책 입장을 파악해 보고자 하였는데 인터뷰를 통해 파악한 전문가 집단의 선호는 인문·사회계, 법학계와 법조계, 공학계의 선호가 모두 다르게 파악되었다. 또한 이 세부 분류 안에서도 전문가들 사이의 의견이 달리 나타났다.

우선 ‘윤리적 AI’ 선호에 대해서 인문·사회계의 전문가 E는 규제가 기술 혁신과 산업 진흥을 억압한다는 이분법적 프레임 자체를 비판했다. 인터뷰이 E는 과학기술정보통신부가 이런 이분법적 시각을 견지하고 있음을 비판하며 이 둘 사이의 적절한 지점을 찾아야 한다고 주장했다. 즉, 인공지능 기업들이 경쟁하고 있는 상황에서 기술의 발전 속도를 늦출 수는 없지만 기술의 방향성을 생각하는 윤리적 고려와 제도적 장치를 마련해야 할 필요성을 강조하였다. 또한 개발 단계에서부터 인공지능을 윤리적으로 만들기 위해 노력을 해야 하는 건 맞지만 각국의 산업 현실에 맞는 정책을 할 필요성을 주장하였다. 공학계 전문가 G는 공학자가 주로 ‘인공지능의 성능 향상·혁신이 최우선 목표이다’라는 정책 입장을 가진다고 전했다. 공학계는 연구 과정에서 역기능은 주로 보지 않고 역기능이 있어도 이에 대한 기술적 해결 방법을 생각하며 역기능이 통제 가능하다고 생각한다고 말했다.

다음으로 규제에 대해서도 전문가 집단의 행위자들은 각기 다른 정책 입장을 보였다. 인문·사회계 전문가 E는 “산업의 현실을 고려하고 규제 비용을 줄이면서 인공지능 윤리를 고려하는 방안으로 자율점검표와 표준의 중요성을 강조”하였다. “경성 규범의 형태로 모든 것을 통제할 수 없기 때문에 인증이나 표준 형태로 관리하는 것이 적절하다”고 전했다(인터뷰이 E). 또한 “정부는 생태계를 조성하는 역할을 맡아야 한다”고 전했다. 한편 법학계 전문가 F는 “기업 입장에서는 불확실성을 가장 꺼릴 것이어서 연성이든 경성이든 확실하게 정부가 입장을 표명해야 한다”고 전했다. 또한 “한국의 경우 연성 형태의 지침이 자율적이라는 보장이 없기 때문에 기업 입장에서는 차라리 경성 규범의 형태로 법이 만

들어지는 것이 더 편할 것”이라고 전했다. 인터뷰이 F는 “연성 규범은 사회적 비용과 시간이 많이 드는 규제 형태인데 한국의 경우 문화 자체가 연성 규범이 작동할 수 있는 문화가 아니”라는 지적을 하였다. 다만 법안심사소위원회를 통과한 인공지능 법안에 대해서는 아주 비판적인 입장을 보였다. 그 이유로 ‘사전허용-사후규제’의 내용을 담았다는 점과 “진흥과 규제를 모두 담으려고 했다”는 점을 꼽았다. 공학계 전문가 G는 “주로 공학계 전문가들은 윤리나 규제를 꺼리는 입장”이라고 전했다.

3) 기업 및 협회

기업 및 협회의 행위자들은 인공지능 윤리 정책의 방향에 따라 규제 준수 비용, 시장 개척, 사업화와 관련한 이해관계를 가지기 때문에 비슷한 정책 입장을 공유하며 정부의 정책형성과정에 적극적으로 참여해 왔다. 인공지능 대기업, 중소기업, 스타트업은 인공지능 산업에서 처한 위치가 다르기 때문에 정책 입장도 다르게 나타날 수 있지만 동일한 이해를 공유하고 의견을 수렴하여 함께 협력해 왔다. 대기업의 경우 인공지능 윤리팀을 꾸릴 수 있고 규제가 강화될 경우 대비할 수 있는 능력이 되지만 중소기업이나 스타트업 입장에서는 윤리 팀을 꾸리거나 규제에 대처할 수 있는 여력이 없었다. 스타트업 관계자 인터뷰이 I는 “윤리적 규제가 강해지면 오히려 대기업이 스타트업에 비해 유리할 수 있기 때문에 기업 별로 규제를 차등 적용해야 한다”고 전했다. 하지만 대기업, 중소기업, 스타트업은 ‘윤리적 AI’와 ‘규제’에 대한 선호에 대해서는 수렴된 정책 입장을 나타내 왔다. 기업들의 의견은 협회를 통해 수렴되었다. 인공지능 기업 관련 협회 관계자 J는 “아직 한국 정책형성과정에서 기업 간에 크게 의견이 갈리는 부분은 찾기 어렵다”고 말했다. 관계자 J는 “기업들이 오히려 같이 협력하여 인공지능 시장을 개척하는 것에 관심이 있다”고 언급하였다.

‘윤리적 AI’에 대한 기업 및 협회의 선호는 ‘성능 향상 · 혁신이 최우

선 목표이다’라는 선호를 보였다. 그 이유는 다음과 같다. 우선 기업 입장에서 비용 문제가 중요하게 작용하는데 인공지능 서비스를 윤리적 가치에 맞게 개발하고 재조정하는 과정에서 비용이 증가한다. 즉 인공지능에 대한 사회적 윤리적 부작용을 줄이려고 하면 규제와 윤리를 준수하는 비용이 증가하게 된다. 대기업의 경우 인공지능 윤리와 정책을 담당하는 팀을 꾸려 운영해 왔다. 하지만 스타트업의 경우 인공지능 개발 과정의 윤리적 고려 사항을 고려하기 힘들고 회사 내에서 관련 규제를 점검하는 인력을 확충하는 것도 어려운 것으로 파악됐다. 협회 차원에서도 인공지능 윤리를 고려하는 조직은 따로 없었다. 다음으로 개발 과정에서의 윤리적 고려는 성능의 하락 문제도 유발한다. 스타트업 관계자 인터뷰이 I는 “단기적 그리고 장기적 차원을 나누어 봐야 하기는 하겠지만 실질적으로 단기적 차원의 윤리적 고려는 규제 준수 비용을 증가시키고 제품과 서비스 성능의 하락을 가져온다”고 전했다. 대기업 관계자 인터뷰이 H도 “서비스 개발 과정에서 윤리적 문제는 성능, 사용자 수, 매출이 연관되어 있다”고 전했다. “윤리적 문제가 있는 경우 이걸 해결하려고 하면 기능이 저감되고 사용자 수가 줄게 되어 매출이 주는 상황이 발생할 수 있다”고 말했다(인터뷰이 H).

그렇다고 기업 차원에서 윤리에 대한 중요성을 강조하지 않는 것은 아니나 그 중점이 성능 향상 · 혁신에 있다는 것이다. 기업은 글로벌 차원에서 인공지능 윤리에 대한 강조점이 높아짐에 따라 그리고 시민 사회의 인공지능 역기능 문제에 대한 관심이 커짐에 따라 인공지능 윤리의 중요성 또한 강조해 왔다. 인문 · 사회계의 전문가 E에 따르면 “기업들은 변화하는 국제 환경에 대응하여 인공지능 윤리를 고려하는 방향의 시류를 따라가고 있다”고 전했다. 또한 인공지능 대기업 관계자 H는 “애초에 사용자 기반이 큰 기업은 인공지능뿐만이 아니라 다양한 사용자가 제기하는 문제에 대응하고 점검하려 하며 사용자의 반응과 기사 등을 통해 외부의 요구를 충족할 수밖에 없다”고 말했다. 인공지능 관련 협회 관계자 J 또한 “기업들이 의견 수렴 과정에서 시민단체의 반발과 비판을 고

려한다”고 전했다.

기업 및 협회의 규제 형식, 주체, 시점에 대한 입장인 ‘규제’ 선호는 다음과 같다. 우선 현 상황에서 기업들은 경성 규범 형태보다는 연성 규범 형태를, 정부 규제보다는 민간의 자율 규제를, 사전 규제보다는 사후 규제를 더 선호하는 정책 입장을 보였다. 그 이유는 다음과 같다. 첫째, 정부에서 제시하는 인공지능 윤리 기준과 가이드라인이 주로 인공지능 일반을 다루고 있어 각 기업 차원의 실질적 사례에 적용하기 어렵다는 문제가 있기 때문이다. 인공지능 대기업 관계자 H는 “인공지능 윤리기준에 등장하는 가치들이 실천적 수준의 사례에 왔을 때 어떤 것을 의미하는 것인지 해석이 달라지고 심지어 가치들끼리 상충하기도 하므로 기업에 실질적으로 적용하기 어렵다”고 말했다. 또한 “이러한 원칙에 바탕을 두고 정부에서 만들어진 자율점검표나 개발가이드라인의 경우도 주로 인공지능 일반을 다루며 산업별로 다루고 있다고 해도 개별 기업별로 목적과 사용 대상 등이 다르기 때문에 기업마다 자체적인 준비가 필요하다”고 전했다(인터뷰이 H). 둘째, 정부에서 자율이라고 내어놓는 정책들이 실상 기업 입장에서 자율이 아니고 어느 정도 강제성을 가지기 때문이다. 이는 정책네트워크에서 정부가 집중된 권력을 가진다는 사실과도 연결된다. 인공지능 대기업 관계자 H는 “자율이라고 내어놓는 가이드라인과 같은 정책들은 실은 자율이 아니고 정책을 내면 실질적으로 따라야 하는 상황”이라고 전했다. 이는 기업들이 정부가 주최하는 행사에 참여하고 교류하는 과정에서 해당 정책들을 실천하는 모습을 보여야 하기 때문이라고 설명했다. 또한 이후에 문제가 되었을 때 비판이 들어올 수 있기 때문에 따라야 한다고 설명했다. 인공지능 스타트업 관계자 I도 “정부 주관의 포럼에 참여하여 나오는 가이드라인이나 점검표가 부담스럽다”는 입장을 표명하였다. “가이드라인이나 점검표가 차라리 법을 통한 규제보다는 낮고 공개적으로 윤리적 차원의 아무런 행동도 하지 말자고 입장을 표명하기는 힘들기 때문에 가이드라인이나 점검표를 만들어야 한다고 말하기는 하지만 이런 정책이 나오면 따라야 하는 상황이기 때문에

부담이 된다”는 입장이었다(인터뷰이 I). 법학계 전문가 F 또한 인터뷰를 통해 한국에서 “정부의 지침이 자율적이라는 보장이 없다”고 전하였다. 이러한 맥락에서 기업들은 연성 규범의 형태를 그리고 민간 자율 규제 형식을 선호하는 정책 입장을 보였다. 셋째, 현 상황에서 인공지능 기술은 빠르게 발전하고 있어 유예가 필요한 상황이고 이전엔 위험이라고 생각되던 것들이 나중에는 문제가 되지 않는 경우도 많기 때문에, 선불리 규제 강화하는 것은 무리가 있다는 입장이다. 또한 수익이 나지 않는 상황에서 사전적인 규제까지 적용하는 것은 기업이 중요시하는 규제 준수 비용, 시장 개척, 사업화에 치명적인 영향을 미칠 수 있다는 입장이다. 인공지능 대기업 관계자 H는 “인공지능의 부작용이 자명해 보이면 규제하는 게 맞고 이것을 기업 입장에서 반대하기도 어렵다”고 전했다. 하지만 “기업 입장에서 가장 꺼리는 상황은 인공지능의 사회적 · 윤리적 부작용이 자명한데 서비스를 낼 수 없는 상황이 아니라, 인공지능의 사회적 · 윤리적 부작용이 없는 게 자명해 보이는데도 사업을 못 하게 된다가 나 너무 과중한 서류 작업이 적용되는 경우”라고 말했다(인터뷰이 H).

4) 시민단체

시민단체 행위자들은 인공지능 윤리 정책의 방향이 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제와 밀접하게 연관되어 있기 때문에 비슷한 정책 입장을 공유하며 정부의 정책형성과정에 적극적으로 참여해 왔다. 시민단체 집단 안에도 다양한 단체가 존재하지만, 이들은 비슷한 이해를 바탕으로 정책 입장을 수립하여 발표해 왔다.

‘윤리적 AI’ 선호에 대해 시민단체는 ‘AI 사회적 · 윤리적 문제를 방지하는 것이 최우선 목표이다’는 입장을 보였다. 정보인권 시민단체 대표 K는 인공지능 정책네트워크에서 “시민사회만의 역할이 있다고 생각한다”고 말했다. 시민단체는 정책네트워크 안에서 인공지능 위험에 대한 규제를 강화해야 한다고 주장하는 유일한 집단이었다. 모든 인터뷰이들

이 공통으로 인공지능 위험에 대응하기 위한 규제를 강화해야 한다는 정책 입장을 강력히 표명하는 단체는 시민단체뿐이라고 전했다. 시민단체는 토론회와 간담회 등을 통해 인공지능을 소비자 보호, 소비자 권리, 프라이버시 보호, 인권 등의 측면에서 생각해야 할 필요성을 강조하였다. 소비자 권리의 측면에서 인공지능 정책형성과정에 활발히 참여하고 있는 특정 시민단체는 ‘생성형AI와 소비자보호 이슈 및 과제 토론회’에서 인공지능과 관련해 많은 논의가 국회와 정부에서 진행되고 있는데 산업, 사업, 개발자의 관점으로 이루어지고 있기 때문에 인공지능 논의를 소비자 관점에서 바라볼 필요성이 있다는 입장을 드러내기도 하였다.

시민단체의 ‘규제’ 선호는 다음과 같다. 우선 규제 형식, 규제 주체, 규제 시점과 관련하여 시민단체는 연성과 경성, 민간과 정부, 사전과 사후의 방식의 규제가 모두 필요하다는 입장이었다. 정보인권 시민단체 대표 K는 “법제로 모든 것을 다 규율하기 어렵기 때문에 연성 규범도 필요하다”고 전하였고 “법제가 있다고 민간의 자율규제가 의미 없는 것이 아니기 때문에 민간 자율 규제도 필요하다”는 입장을 전했다. 하지만 시민단체는 현 규제 상황이 위험을 실질적으로 규제할 방법을 명시하지 않고 있다는 점, 법안에 세밀한 안전성 기준을 포함하지 않는다면 기업은 계속해서 이를 회피할 것이라는 점, 피해를 사전적으로 예방하는 것이 무엇보다 중요하다는 점을 강조하였다. 정보인권 시민단체 대표 M은 “인공지능 기본법안은 사전 규제와 사후 규제를 모두 포함해야 하지만 사후적으로 규제하는 내용만 포함되어서는 안 된다”고 주장했다. 또한 “심사소위를 통과한 법안에는 인공지능의 위험을 실질적으로 규제할 수 있는 사항 자체가 포함되어 있지 않다”고 비판했다(인터뷰이 K). 따라서 현 규제 상황에서는 경성 규범, 정부 규제, 사전 규제의 방식이 더 강화될 필요가 있음을 주장했다. 시민단체 집단은 인공지능 기본법안을 비판하는 공동 성명을 내며 수렴된 입장을 표명하였다. 시민단체는 인공지능 기본법안과 관련하여 시민의 권리 보호 측면에 집중하는데 EU의 「AI ACT」를 좋은 본보기로 삼고 있었다. EU의 「AI ACT」가 사람 중심의

가치에 집중하고 있다고 주장하며 이를 반영하여 인공지능 법이 만들어져야 한다고 입장을 표명하였다. EU는 대표적인 사전규제의 입장을 담고 있는 법안으로 리스크에 따라 인공지능을 분류하여 애초에 개발할 수 없는 제품과 서비스의 유형을 명시한 바 있다.


5) 한국 인공지능 정책네트워크의 행위자 선호

각 집단의 선호를 요약하여 주요 특징을 도출하면 다음과 같다(선호에 대한 표 및 그림은 <표 13>과 [그림 7] 참고). 우선 과학기술정보통신부는 인공지능의 사회적·윤리적 문제 방지와 성능 향상·혁신을 모두 강조하는 정책을 발표해 왔다. 이를 통해 인공지능 기술의 부작용 최소화화 산업 진흥을 위한 노력을 모두 강조했다. 다만 실질적 규제를 만드는 문제에 있어서 과학기술정보통신부는 인공지능의 위험 방지보다는 산업 진흥에 초점을 둔 규제를 강조해 왔다. 둘째 전문가 집단은 명확한 이해관계를 가지고 있는 집단이 아니기 때문에 수렴된 정책 입장을 식별하기 어려우나 전문가 집단 안에서 다양한 정책 입장이 나타나는 것은 확인할 수 있었다. 셋째, 기업 및 협회와 시민단체의 ‘윤리적 AI’ 선호는 양극단으로 나타났다. 기업 및 협회는 인공지능의 성능 향상·혁신을 최우선 목표로 두는 입장을 보였다. 반면 시민단체는 인공지능의 사회적·윤리적 문제를 방지하는 것을 최우선 목표 두는 입장을 보였다. 넷째, 기업은 민간 자율 규제 활성화를 위한 정부 차원의 정책 결과에도 부담을 느끼지만, 시민단체는 인공지능 위험을 실질적으로 규제할 체계가 부족함을 강조하는 입장을 보였다. 정부 차원에서 민간의 자율 규제를 활성화하는 목표로 인공지능 윤리 기준과 자율점검표 등을 발표하는데 기업은 이를 자율적 정책 수단이 아닌 어느 정도 강제적인 수단으로 받아들이고 있었다. 다섯째, 수렴된 선호를 보이는 집단 중 인공지능의 위험에 대응하기 위한 규제 강화를 주장하는 집단은 시민단체뿐이었다. 마지막으로 ‘규제’ 선호에서 선호가 수렴된 모든 집단은 리스크 기반 접근이

라는 공통된 입장을 가지고 있었다. 각 집단은 규제 형식, 주체, 시점과 관련하여 조금씩 다른 정책 입장을 가지고 있지만 인공지능 규제를 리스크와 파급력을 기반으로 구축해야 한다는 입장을 공유하고 있었다.

<표 13> 한국 인공지능 정책네트워크의 행위자 선호

행위자 집단	선호 구분	행위자 선호
정부 (과기부)	윤리적 AI	• AI의 사회적 · 윤리적 문제를 방지하는 것과 성능 향상 · 혁신을 강조하는 것 모두 중요함 • 다만 실질적 규제를 만드는 문제에 대해서는 규제보다는 산업 장려를 더 강조해 옴
	규제	♦ 연성/경성, 민간/정부, 사후/사전 모두 고려함 ♦ 다만 정책적으로 연성 규범 형태의 지침을 주로 발표하였고 추진한 인공지능 기본법안도 진흥에 중점을 두고 있음 ♦ 꾸준히 민간 자율 규제를 강조해 옴 ♦ 과기부가 추진한 기본법안에서는 사전적 규제 가능성이 담겨 있으나 의무를 어겼을 때 처벌 규정이 명시되어 있지 않음 ♦ 기본적으로 리스크와 파급력에 따른 규제 입장을 가짐
기업 및 협회	윤리적 AI	• AI의 성능 향상 · 혁신이 최우선 목표임 • 규제 준수 비용 저감, 시장 개척, 사업화라는 이해가 기반이 됨 • 윤리 중요성 또한 강조하기는 하지만 비용과 성능 문제가 가장 중요함
	규제	• 연성, 민간, 사후 규제의 형태 선호함 • 규제가 심해질 경우 규제 준수 비용이 증가하고, 시장 개척과 사업화가 어려워진다는 점을 강조함 • 현 상황에서는 인공지능 기술이 빠르게 발전 중이고, 인공지능의 위험을 명확히 파악할 수 없고, 사용 사례별로 맥락이 너무 다르기 때문에 규제를 강화하는 것을 선호하지 않음 • 기본적으로 리스크와 파급력에 따른 규제 입장을 가짐
시민단체	윤리적 AI	• AI의 사회적 · 윤리적 문제를 방지하는 것이 최우선 목표임 • 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제와 관련한 이해가 기반이 됨
	규제	• 연성/경성, 민간/정부, 사후/사전 규제가 모두 필요하다는 입장을 가짐 • 다만 현 규제 상황은 위험을 실질적으로 규제할 방법을 명시하지 않고 있다는 점, 법안에 세밀한 안전성 기준을 포함하지 않는다면 기업은 계속해서 이를 회피할 것이라는 점, 피해를 사전적으로 예방하는 것이 무엇보다 중요하다는 점을 강조함 • 기본적으로 리스크와 파급력에 따른 규제 입장을 가짐



[그림 7] 한국 인공지능 정책네트워크의 행위자 선호 그래프

2-3. 상호작용 유형

1) 정부 - 전문가: 협력

정부는 인공지능 정책네트워크의 전문가, 기업 및 협회, 시민단체 집단과 각기 다른 상호작용 유형을 맺어 왔다. 전문가 집단은 정부와 협력의 유형으로 상호작용을 해왔다. 전문가 집단은 정책적으로 인공지능 기술에 대한 본격적인 관심이 시작되던 과학기술정보통신부의 초기 인공지능 정책부터 자문의 역할을 주로 맡아 오며 정책형성과정의 주요 행위자로 활동해 왔다. 전문가 집단은 초기 과학기술정보통신부의 주요 인공지능 정책인 2016년의 『제 4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』부터 2023년 『인공지능 시스템 신뢰성 제고를 위한 요구사항』 표준 작업까지 전반적인 정책에서 자문의 역할을 하며 정부와 협력해 왔다.

정책형성과정에 참여한 전문가 집단은 하나의 단일한 집단이 아니라 인문 · 사회계, 법학계, 법조계, 공학계로 이루어져 있는 복합적인 집단이지만, 모두 정부와 협력관계를 맺어 왔다. 인공지능 윤리 정책에 참여하는 전문가 집단과 정부 사이의 뚜렷한 갈등 지점은 드러나지 않았다. 그 이유는 우선 전문가 집단은 기업 및 협회 혹은 시민단체와 달리 명확한 이해관계를 가지고 있는 집단이 아니고 수렴된 정책 입장을 드러내는 집단이 아니기 때문이다. 다음 이유는 정책에 참여해 온 전문가의 구성이 초기 정책부터 큰 변동 없이 이어져 왔고 정부 정책 자문에 포함된 전문가의 경우 정부에 협력적인 전문가로 구성되어 왔기 때문이다. 인공지능 정책 논의를 위한 조직으로 다양한 포럼, 추진단, 협의체 등이 있지만 해당 조직에서 주된 역할을 하는 전문가들이 정책 초기 참여자와 크게 달라지지 않았고 같은 시기에 활동하는 조직 안에서도 주요 전문가의 구성이 많이 겹치는 것으로 파악됐다. 과기부 2차관 산하기관 관계자 C는 “같은 전문가가 계속해서 여러 위원회와 포럼 등에 참여하고 있고 이 때문에 새로운 의견이 반영될 수 있는 기회가 제한되어 있다”고 전했다.

또한 “과학기술정보통신부 산하 기관에서 정책 연구를 할 때도 이미 네트워크가 형성된 전문가의 자문을 지속적으로 받고 있다”고 전했다(인터뷰이 C). 인터뷰이 J는 “정부 여러 부처에서 앞다투어 인공지능 정책을 펴고 있지만 각 정책에 자문하는 전문가가 거의 겹치고 있는 상황”이라고 말했다.

2) 정부 - 기업 및 협회: 협상

기업 및 협회 집단은 과학기술정보통신부와 협상 유형으로 상호작용해 왔다. 인공지능 윤리 정책네트워크의 권력 분포는 과학기술정보통신부에 집중된 양상을 보이기 때문에 정책형성과정에서 기업 및 협회는 정부와 협상하며 비슷한 이해를 바탕으로 수렴된 기업의 정책 입장을 전달해 왔다. 각 기업은 인공지능 윤리 정책과 관련한 각종 추진단, 포럼, 정비단, 협의체 등에 참여하며 정부 행위자에게 기업의 입장을 전달해 왔고 협회는 정부 관계자와의 회의를 통해 기업들의 수렴된 정책 입장을 전달해 왔다.

정부와 기업 및 협회는 공유하는 정책 입장을 바탕으로 지속적인 협력을 해 왔다. ‘윤리적 AI’ 선호에서 정부는 인공지능의 사회적 · 윤리적 문제를 방지하는 것과 성능 향상 · 혁신을 강조하는 것 모두 중요하다는 입장을 가지고 있기 때문에 인공지능의 성능 향상과 · 혁신을 강조하는 기업의 입장과 공유하는 지점이 있다. 또한 정부는 인공지능 기술을 국가 혁신 기술로 선정하고 꾸준히 인공지능 기술과 산업을 키우려는 정책 방향을 보여 오며 위험을 방지하기 위한 실질적 규제보다는 산업 진흥을 더 강조해 왔기 때문에 이 지점에서도 기업과 공유하는 정책 입장을 가진다. 스타트업 관계자 인터뷰이 I도 전반적인 인공지능에 대한 정책 기조를 규제보다는 진흥으로 파악하고 있었다. 정부의 산업 진흥 입장은 인공지능 정책이 본격적으로 시작된 이후 계속 유지해 오던 입장이었다. 반면, 정부와 기업 및 협회는 서로 다른 정책 입장을 보이는 ‘규제’ 선호

측면에서 갈등을 보였다. 우선 기업은 이미 정부에서 인공지능 기술의 부작용을 최소화하기 위해 발표하는 민간 자율 가이드라인이나 개발안내서 등에 부담을 느끼고 있었다. 다음으로 기업은 정부가 인공지능 윤리 기준과 가이드라인에서 발표한 추상적인 가치를 실질적으로 규제에 적용하는 것의 문제를 지적하며 갈등을 드러냈다. 마지막으로 기업은 인공지능 일반이 아닌 사용 사례별로 규제가 형성되어야 한다는 견해를 피력하며 기업마다 서비스의 맥락이 다르기 때문에 기업 차원에서 자율적으로 대응할 수 있는 민간 자율 규제의 필요성을 강조했다.

3) 정부 - 시민단체: 협상

시민단체는 정부와 협상 유형으로 상호작용해 왔다. 시민단체는 각종 추진단, 포럼, 정비단, 협의체 등의 회의 혹은 시민단체 공동 성명 발표와 같은 공식적 경로를 통하거나 비공식적 경로를 통해서 수렴된 정책 입장을 전달했다. 인공지능 윤리 정책을 담당해 온 정부출연연구기관 관계자 인터뷰이 A는 “포럼을 구성할 때 시민사회를 포함하여 각 집단의 의견이 고루 반영될 수 있도록 위원을 구성한다”고 전했다. 또한 정보인권 시민단체 대표 인터뷰이 K는 “정부는 공식 협의체 이외의 방법으로도 정책형성과정에서 시민단체의 의견을 청취하였다”고 말했다.

‘윤리적 AI’ 선호에서 정부와 시민단체는 AI 사회적 · 윤리적 문제를 방지해야 한다는 공통된 입장을 공유하고 있기 때문에 두 집단은 사회적 · 윤리적 문제의 중요성을 공유하며 협력해 왔다. 반면, 과학기술정보통신부와 시민단체는 ‘규제’에 대한 정책 입장에서 갈등을 보였다. 시민단체는 정부에 인공지능 위험을 실질적으로 규제할 방안을 마련할 것을 촉구했다. 특히 갈등은 2023년 인공지능 기본법안 논의가 촉발된 이후로 두드러지게 나타났다. 시민단체는 의견을 수렴하여 국회에 반대 의견서를 제출하고 과학기술정보통신부의 답변에 반박 의견서를 발표하는 등 갈등의 양상을 보였다. 시민단체는 과학기술정보방송통신위원회 심사소

위를 통과한 법안의 취지가 ‘우선허용-사후규제’이고 위험한 인공지능을 금지하고 규제하는 조항이 미비하다고 지적하며 이는 소비자권, 프라이버시 보호, 인권 측면에서 통과되어서는 안 되는 법안임을 주장하였다. 구체적으로 정보인권 시민단체 대표 K는 “인공지능의 위험을 실질적으로 규제하는 방향이 정책에 포함되어야 하며 위험 인공지능에 대한 세밀한 정의, 처벌 규정, 세부 규정, 피해 구제 방안 등이 포함되어야 한다”고 주장했다.

4) 전문가 - 기업 및 협회: 협력

전문가 집단은 명확한 이해관계를 가지고 있는 집단이 아니어서 모든 집단에 자문을 제공하며 협력 관계를 맺어왔다. 전문가 집단은 기업 및 협회와도 정책네트워크에서 협력 관계를 맺어 왔다. 우선 기업은 전문가를 기업의 입장을 정부에 간접적으로 전달할 수 있는 창구로 인식하였다. 인공지능 스타트업 관계자 인터뷰이 I는 학계 전문가를 기업과 정부를 연결하는 중개자 역할로 인식하고 있었고 전문가 집단이 기업에 우호적 입장을 가지고 있다고 전했다. 다음으로 전문가 집단은 기업의 인공지능 윤리 준칙 생성 과정에 협력하며 네트워크를 형성해 오기도 하였다. 전문가 집단은 기업의 인공지능 윤리 준칙 생성 과정의 처음부터 참여하며 협력하거나 기업의 윤리 준칙 생성 과정에서 자문의 역할을 하며 협력하는 형태를 보였다. 가장 대표적으로 2021년 네이버의 ‘네이버 AI 윤리 준칙’과 스캐터랩의 ‘스캐터랩 AI 윤리 준칙’이 있다. 네이버의 인공지능 윤리 준칙은 법학 기반의 전문가들로 구성된 서울대학교 인공지능 정책 이니셔티브(SAPI)와 협업하여 만들어졌다. SAPI는 그 이후로도 꾸준히 네이버와 협업하며 후속 활동을 해 왔다. 스캐터랩은 이루다 2.0을 만들 때 공학, 법학, 윤리학, 여성학 등 다양한 기반의 전문가 논의를 거쳐 만들었다.

전문가 집단이 모든 지점에서 기업과 동일한 입장을 보이는 것은 아

하지만 인공지능 산업이 성장할 수 있도록 기반을 마련해야 한다는 입장을 공통적으로 견지하며 기업과 협력의 상호작용을 하고 있었다. 전문가들은 기업이 감당해야 하는 규제 비용과 시장 확보의 어려움 등 기업들이 고충을 느끼는 지점에 대한 이해하고 있었고 인공지능 산업을 진흥하기 위해서는 산업 생태계가 기반이 되어야 한다는 입장을 드러내었다. 전문가들은 기업과 공유하는 입장을 정비단, 포럼, 협의체 등을 통해 정부에 전달하고 직접 법제 논의 등에 참여하여 반영해 왔다.

다만 인공지능 산업 진흥을 위한 기반 마련의 방식에 대한 정책 입장에서 차이는 존재하였다. 인공지능 법제 논의에서 주요한 역할을 담당해 온 법학계 전문가 F는 “기업 입장에서는 불확실한 규제가 오히려 독이 된다”고 주장하며 “연성 규범이든 경성 규범이든 확실히 해서 규제 비용을 줄이는 쪽으로 정책 방향이 가야 한다”고 주장하였다. 다만 “한국의 경우 연성 규범이 작동할 수 있는 문화가 확립되어 있지 않기 때문에 법으로 확실히 하는 경성 규범의 방향이 기업 입장에서 더 편할 것”이라고 설명했다(인터뷰이 F). 규제의 불확실성에 대한 문제 지적은 모든 분야의 전문가가 지적한 부분이었다. 인공지능 윤리 정책의 초기 논의부터 중요한 역할을 해 온 공학계 전문가 G는 “규제의 불확실성이 오히려 기업의 부담을 높이기 때문에 인공지능 규제를 할 거면 빨리 마련하는 것이 중요하다”고 하였다. 반면 인공지능 스타트업 관계자 I는 “불확실성보다도 법적 규제에 대한 부담이 더 크다”고 전하며 전문가들과는 다른 입장을 전했다.

5) 전문가 - 시민단체: 협력

전문가 집단은 기업 및 협회와도 정책네트워크에서 협력 관계를 맺어 왔다. 각 전문가의 정책 입장은 전문가 집단 안에서도 굉장히 다양하게 나타나나 명확한 이해를 가지고 있지 않기 때문에 시민단체에 자문을 제공하며 협력의 관계를 맺어 왔다. 전문가들은 정부에서 주최하는 포럼이나

토론회 등을 통해 시민단체와 소통하거나 시민단체에서 연구 프로젝트를 진행할 때 전문가를 불러 의견을 청취하는 방식으로 상호작용해 왔다. 전문가 집단은 시민단체에 인공지능 기술, 윤리, 정책과 관련한 자문을 제공하며 협력하는 것으로 나타났다. 한편, 정보인권 시민단체 대표 K는 “주로 시민단체와 함께 활동한 전문가들 중심으로 상호작용해 왔다”고 말했다.

6) 기업 및 협회 - 시민단체: 갈등

기업 및 협회와 시민단체는 상호작용 유형 중 갈등의 관계를 맺어왔다. 기업과 시민단체 모두 인공지능 윤리 정책형성과정에서 명확한 이해를 가진 집단이다. 기업과 시민단체는 각기 규제 준수 비용, 시장 개척, 사업화 그리고 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제라는 명확한 이해를 바탕으로 각 집단이 수렴된 정책 입장을 보이며 기업과 시민단체는 뚜렷한 갈등 관계를 맺어 왔다. 우선 ‘윤리적 AI’ 선호에서 기업 및 협회와 시민단체는 양극단의 선호를 보였다. 기업은 인공지능의 성능 향상 · 혁신을 최우선 목표로 두고 있고 시민단체는 인공지능의 사회적 · 윤리적 문제를 방지하는 것을 최우선 목표로 두고 있다.

이러한 선호 차이를 바탕으로 기업과 시민단체는 ‘규제’ 선호에서도 뚜렷한 갈등을 보였다. 기업은 현재 주로 이루어지는 가이드라인이나 표준 형태의 규제 또한 부담으로 느끼고 있지만 시민단체는 법적 규제로 인공지능 위험을 실질적으로 규제할 방안을 마련해야 함을 촉구하고 있었다. 특히 기업과 시민단체는 인공지능 기본법안 논의를 중심으로 극명한 대립을 보였다. 시민단체가 인공지능 규제에 관해 꾸준히 주장해 왔던 바는 인공지능의 위험을 실질적으로 규제할 수 있는 조항을 마련해야 한다는 것이었다. 규제 형식에서 연성, 경성 규제 주체에서 민간, 정부 규제 시점에서 사전, 사후 모두 포함되어야 하지만 규제를 연성, 민간, 사전적으로만 하면 안 된다는 입장을 보여 왔다. 정보인권 시민단체 대

표 K는 “인공지능 안전성에 대한 기준, 고위험 인공지능에 대한 세밀한 정의, 처벌 규정, 피해구제 규정 등이 법안 안에 포함되어야 하고 이 기준이 없다면 기업은 계속해서 회피하고자 할 것”이라고 입장을 전하며 이것이 법제가 필요한 이유라고 주장했다. 반면 기업이 인공지능 기본법안에 대해 꾸준히 주장해 왔던 바는 인공지능 일반에 대해 규제하는 접근 방식이 아니라 각 사용 사례에 따라 리스크와 과급력을 고려하여 규제하는 접근이 필요하다는 것이다. 또한 현 상황에서 이를 고려하여 법적인 규제로 만들기는 어렵다는 것이다. 인공지능 대기업 관계자 H는 “인공지능 리스크를 일반화해서 경성 규범으로 만들기에는 무리가 있다”고 말했다.

기업 및 협회와 시민단체는 뚜렷한 갈등 관계를 보이면서 직접적인 교류 자체도 부족한 것으로 나타났다. 정보인권 시민단체 K는 “주로 협의체나 토론회를 통해 기업 관계자를 만나게 되는데 이런 토론회는 단순히 서로의 입장을 확인하기 위한 자리일 뿐 의견을 교류하고 합의하는 자리가 아니”라고 밝혔다. 인공지능 대기업 관계자 H도 “특정 행사나 발표를 통해 기업 담당자 혹은 대표가 시민단체 관계자를 만나기는 하나 다른 차원의 직접적인 커뮤니케이션은 없다”고 전하며 “만약 시민단체가 공문을 보내어 요청하면 사안에 맞게 대응하는 정도”라고 말했다. 협회 관계자 J는 “협회 차원에서는 직접적으로 시민단체와 관계를 맺지 않고 시민단체의 입장을 주로 매체를 통해 확인한다”고 전했다.

7) 한국 인공지능 정책네트워크의 상호작용 유형

우선 전문가 집단은 정책네트워크의 모든 집단과 협력 관계를 맺으며 상호작용했다. 전문가는 명확한 이해관계를 가지고 있는 집단이 아니어서 수렴된 정책 입장을 식별하기 어려우나 집단 안의 다양한 정책 입장을 바탕으로 정책네트워크 안의 모든 집단에 자문을 제공하며 협력 관계를 맺었다. 전문가 집단은 과학기술정보통신부와 KISDI와 NIA에서 진행하

는 각종 추진단, 포럼, 정비단, 협의체 활동을 통해 정부의 정책형성 과정에 협력했다.. 또한 전문가 집단은 기업의 윤리 준칙 형성에도 참여하며 협력했으면 시민단체의 연구 프로젝트 등에서 의견을 교류했다. 둘째, 기업 및 협회는 과학기술정보통신부와 협상의 관계를 맺으며 상호작용했다. 기업 및 협회는 정부와 인공지능 성능 향상 · 혁신, 산업 진흥의 중요성을 공유하며 정부가 추진하는 각종 인공지능 관련 조직활동에 참여하고 협력했다. 반면 기업은 인공지능 일반이 아닌 사용 사례에 대한 정책 입장, 강제성을 띠는 가이드라인이 아닌 민간이 자율적으로 운용할 수 있는 형식의 정책 입장을 꾸준히 정부에 피력하며 정책 입장이 일치하지 않는 부분을 조정하려고 노력했다. 셋째, 시민단체는 과학기술정보통신부와 협상의 관계를 맺으며 상호작용했다. 시민단체는 정부와 사회적 · 윤리적 문제의 중요성을 공유하며 정부가 추진하는 각종 인공지능 관련 조직활동에 참여하고 협력했다. 반면 시민단체는 인공지능 위험을 예방하고 위험에 대응할 수 있는 실질적 규제 마련의 필요성, 규제 강화의 필요성을 강조하며 정부의 정책 방향에 비판을 제기했다. 마지막으로 기업 및 협회와 시민단체는 각기 규제 준수 비용, 시장 개척, 사업화 그리고 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제라는 명확한 이해를 바탕으로 뚜렷한 갈등 관계를 맺었다. 특히 과학기술정보통신부의 규제 정책을 인식하는 점에서 차이를 보였고 특히 인공지능 기본법안에 대한 입장 차이가 두드러졌다. 더불어 갈등의 상호작용 유형을 보이는 기업 및 협회와 시민단체는 직접적인 교류 자체가 부족한 것으로 나타났다.

2-4. 한국 인공지능 정책네트워크 특성

본 연구에서는 한국 인공지능 정책네트워크를 권력 분포, 선호, 상호작용 유형을 통해 파악하였다. 권력 분포, 행위자 선호, 상호작용 유형은 서로 영향을 미치며 정책네트워크를 구성한다([그림 8] 참고). 한국 인공지능

정책네트워크는 권력 분포가 정부에 집중된 양상을 보인다. 각 집단은 정부와 주로 관계를 맺고 정부는 정책형성과정에서 중심 역할을 한다. 한국 인공지능 정책네트워크에서 가장 큰 영향력을 가진 정부는 인공지능의 사회적 · 윤리적 문제를 방지하는 것과 성능 향상 · 혁신을 강조하는 것 모두를 중요한 목표로 두어 왔다. 이 지점이 정부가 기업 및 협회와 시민단체 두 집단 모두와 협력할 수 있는 지점이다. 그런데 정부는 규제를 적용함에 있어서는 위험을 방지하기 위한 실질적 규제보다는 산업 진흥을 더 강조해 왔다. 이러한 정책 입장은 이는 기업 및 협회의 선호와 일치한다. 이러한 측면에서 기업의 영향력이 시민단체의 영향력보다 더 크게 작용한다는 것을 알 수 있다. 시민단체는 2023년 이후에 정책네트워크의 주요 행위자로 등장하여 인공지능 기본법안에 영향을 미치고 있으나 실질적인 규제보다는 산업 진흥을 장려하는 정부에 정책 기조에는 큰 영향을 미치지 못했다. 정책형성과정에서 시민단체의 의견이 반영될 수 있는 통로는 마련되어 있지만 시민단체는 그 의견이 강제력을 발휘할 수 없는 조직에만 속해있었다.


기업 및 협회는 정부와 성능 향상 · 혁신, 산업 진흥의 중요성 공유하며 협력한다. 반면 기업 및 협회는 정부와 다른 정책 입장을 피력하며 갈등을 보이는 부분도 있다. 기업은 정부 차원에서 민간 자율 규제 활성화를 위해 발표하는 가이드라인이나 점검표 같은 정책 결과에서도 부담을 느낀다는 입장이었다. 이에 따라 정부의 정책 기조가 민간 자율 규제를 표방하고 있음에도 기업 차원에서 민간 자율 규제를 꾸준히 강조해 왔다. 또한 정부에서 인공지능 윤리 기준이나 가이드라인에서 제시된 추상적 가치를 일관적으로 실질적 규제에 적용하려 하는 것에 문제를 제기하며 사용 사례별 규제 형성의 필요성을 강조했다.

정부와 시민단체는 인공지능의 사회적 · 윤리적 문제를 방지의 중요성을 공유하며 협력한다. 하지만 실질적 규제보다는 산업 진흥을 더 강조해 온 정부의 정책 입장은 정부와 시민단체 사이의 갈등 기반이 된다. 특히 이 갈등은 2023년 인공지능 기본법안 논의가 촉발된 이후로 더욱

심화되었다. 시민단체는 인공지능 기본법에 위험 인공지능에 대한 세밀한 정의, 문제를 사전적으로 예방할 수 있는 규제 방안, 처벌 방안, 피해를 구제할 방안이 미흡하다고 주장하였다.

기업 및 협회와 시민단체는 뚜렷한 이해를 바탕으로 갈등을 보인다. 기업 및 협회는 규제 준수 비용 저감, 시장 개척, 사업화라는 이해를 가지고 시민단체는 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제와 관련한 이해를 가진다. 이러한 이해의 차이를 바탕으로 기업 및 협회와 시민단체는 ‘윤리적 AI’ 선호와 ‘규제’ 선호에서 극명한 차이를 보이며 갈등의 유형으로 상호작용 한다. 기업 및 협회는 인공지능의 성능 향상 · 혁신을 최우선 목표로 두고 있고 시민단체는 인공지능의 사회적 · 윤리적 문제를 방지하는 것을 최우선 목표로 두고 있다. 또한 정부에서 발표하는 같은 정책 결과에 대해 기업 및 협회는 규제가 부담된다는 입장을 시민단체는 규제를 강화해야 한다는 입장을 보였다.

전문가는 모든 집단에 자문을 제공하고 각 집단의 의견을 정부에 전달하는 역할을 하며 협력한다. 전문가 집단은 인공지능 윤리 정책에 명확한 이해를 가지고 있는 집단이 아니기 때문에 정책네트워크의 모든 집단과 협력 관계를 맺으며 상호작용한다. 또한 시기에 따라 전문가 집단 안에서 영향력 있는 행위자가 인문, 사회계 전문가에서 법학, 법조계 전문가로 변화하였다.



[그림 8] 한국 인공지능 정책네트워크

3. 한국의 인공지능 거버넌스 및 정책형성과정 특성

3절에서는 정책과 행위자가 상호작용하며 만들어내는 한국 인공지능 거버넌스 및 정책형성과정 특성을 종합적으로 제시한다([그림 9] 참고). 한국에서 정책적으로 인공지능 기술에 대한 본격적인 관심을 두기 시작한 것은 2016년 이후이다. 딥러닝의 전성기가 시작된 이후 점차 인공지능 기술의 중요성이 더욱 커지기 시작했고 2016년 알파고와 이세돌 대국은 인공지능 기술이 가져올 윤리적, 사회적 부작용에 대한 우려를 촉발하였다. 이에 2017년에는 아실로마 인공지능 원칙이 발표되고 세계적으로 인공지능 윤리 강령이 쏟아져 나오게 되었다. 한국도 이러한 흐름에 맞춰 인공지능 기술에 대응하고자 하였다. 처음 한국에서 인공지능에 대한 정책적 논의가 시작되었을 때는 인공지능 기술로 인한 사회 구조 변화와 역기능에 대응하기 위한 목표를 바탕으로 인공지능 윤리를 정립하고자 하였다. 당시 미래창조과학부는 지능정보사회에 대비한 중장기적 대책을 세우기 위해 ‘지능정보사회 추진단’을 출범하였다. 이 추진단은 관계부처 및 민간 전문가로 구성되었다. 한국 인공지능 정책형성과정의 초기부터 과학기술정보통신부, 전문가, 기업 및 협회는 지속적으로 정책 논의를 주도하는 주요 행위자였다. 전문가 집단 중에서도 인문·사회계의 전문가는 인공지능 윤리와 가이드라인 정립에 주요한 행위자로 참여하며 정책형성과정에 영향력을 발휘하였다.

기술의 중요성이 더욱 증가하고 인공지능 서비스가 본격화되어 인공지능 오남용 사례 증가하면서 당시 주요 국가들은 본격적으로 국가 차원에서 인공지능 전략을 추진하기 시작하였다. 이때 인공지능 법, 제도, 규제 정비의 필요성이 중요하게 대두되었다. EU에서는 GDPR을 발효하고 신뢰할 수 있는 인공지능 가이드라인 발표하는 등의 접근을 보였고 미국은 알고리즘 책임 법안 발표하고 OECD는 인공지능 권고안을 발표하였다. 한국도 2020년부터 법제도를 정비하는 방향으로 정책의 흐름이 변화하였다. 당시 법제도 정비 정책의 기본 기조는 산업 경쟁력을 높이고 활

용 걸림돌을 제거하면서도 부작용을 최소화하는 것이었다. 이때 정부의 규제 정책 방향은 민간 자율 규제 활성화, 우선허용-사후규제 원칙에 기반하였다. 이러한 정책 기조는 이후 출범한 인공지능 윤리 정책 포럼에서 개발된 가이드라인, 개발안내서 등을 통해 더욱 구체화 되었다. 이 시기에도 기업과 전문가는 정부의 정책형성과정의 주요 행위자로 참여하며 정책에 영향을 미쳤다. 기업은 꾸준히 규제 준수 비용 저감, 시장 개척, 사업화에 기반을 둔 자신들의 정책 입장이 정책에 반영될 수 있도록 목소리를 냈다. 주요 정책의 흐름이 법제도 정비로 변화함에 따라 전문가 집단 안에서의 영향력도 변화를 보였는데, 전문가 집단 안에서 가장 큰 영향력을 가진 전문가가 인문·사회계에서 법학·법조계로 변화하였다. 이로 인해 이후 인공지능의 역기능을 최소화하기 위한 인공지능 정책의 논의 또한 꾸준히 법제도 중심으로 이루어지게 되었다. 전문가 중 공학계 전문가는 전문가 집단에서 영향력이 가장 작았다.

이후 한국에서는 이루다 사건이 일어났고 글로벌 차원에서는 인공지능 규제 논의가 더욱 활발해졌다. EU에서는 인공지능법안을 발표하고 미국은 수정된 알고리즘 책임 법안을 발표하였다. 또한 ChatGPT가 출시되며 생성형 인공지능 서비스가 본격화 되었다. 2023년 이후 한국에서는 인공지능 기본법안에 대한 논의가 본격화되면서 시민단체가 영향력을 드러내기 시작하였다. 2023년 2월에 ‘사전허용-사후규제’의 내용을 담은 인공지능 기본법안이 국회 과학기술정보방송통신위원회의 법안 심사 소위를 통과하자 시민단체는 법안에 대한 문제를 제기했다. 시민단체는 소비자권, 프라이버시 보호, 시민의 안전, 인권, 차별 문제를 기반으로 한 자신들의 정책 입장이 정책에 반영될 수 있도록 본격적으로 반대 의사를 표명했다. 이는 이후 법안에서 ‘사전허용-사후규제’의 내용이 삭제되는데 영향을 미쳤다. 또한 기업 및 협회는 시민단체의 입장을 수용하려는 노력을 보였으나 실질적 규제보다는 산업 진흥을 더 강조해 온 정부의 정책 기조 속에서 시민단체의 주장이 근본적인 정책 기조의 변화를 이끌어내지는 못했다.

시기	2016~	2020~	2023~
주요 정책 흐름	윤리 강령	법제도 정비	인공지능 기본법안
정책 흐름에 영향을 준 주요 사건	이미지넷 대회, 딥러닝 전성기 시작, 알파고와 이세돌 대국, 아실로마 인공지능 원칙	주요 국가들의 인공지능 전략 추진, EU GDPR 발효, 인공지능 서비스 본격화와 오남용 사례 증가, EU 신뢰할 수 있는 인공지능 가이드라인 발표, 2019 미국 알고리즘 책임 법안 발표, OECD 권고안 발표	이루다 사건, EU 인공지능법안 발표, 2022 미국 알고리즘 책임 법안 발표, ChatGPT 출시, 생성형 인공지능 서비스 본격화
정책네트워크			

영향력 순위(권력분포)
 1 = 과기부
 2 = 전문가, 기업 및 협회
 3 = 시민단체

상호작용 유형
 ————— 협력
 - - - - - 협상
 <-----> 갈등

[그림 9] 한국 인공지능 거버넌스 및 정책형성과정 특성

제 5 장 결론 및 정책적 함의

본 논문에서는 인공지능의 부작용을 최소화하고 신뢰성을 확보하기 위한 정책을 중심으로 한국의 인공지능 거버넌스와 정책형성과정을 분석하였다. 특히, 한국의 종합적인 인공지능 윤리 정책의 논의를 이끌어 온 과학기술정보통신부를 중심으로 한 정부의 인공지능 정책과 해당 정책의 정책형성과정에 참여한 정책 행위자에 초점을 두어, 정책과 행위자가 상호작용하며 한국의 인공지능 거버넌스를 구축해 가는 과정을 분석하였다. 이를 통해 정책 흐름에 따라 정책네트워크가 변하고 네트워크의 변화가 정책 변화를 일으키는 중요한 요인이라는 것을 확인하였다. 또한 정부, 전문가, 기업 및 협회, 시민단체로 구성된 정책네트워크의 공공과 민간 영역이 함께 정책을 형성하며 한국의 인공지능 거버넌스 구축해 왔음을 보였다. 각 집단이 상호작용하며 정책을 형성하고 이 과정에서 기술의 부작용을 최소화하기 위한 노력이 지속적으로 이루어지고 있었다. 본 연구의 결과는 한국의 인공지능 거버넌스와 정책형성과정을 이해하고 더욱 효과적인 인공지능 정책 수립을 위한 정책적 함의를 제공한다.

한국 인공지능 정책은 주요 정책 맥락에 따라 정책네트워크의 양상이 달라졌고 변화된 정책네트워크는 다시 정책에 영향을 미쳤다. 한국 인공지능 정책은 2016년 이후의 윤리 강령, 2020년 이후의 법제도 정비, 2023년 이후의 인공지능 기본법안 마련에 초점을 두어 진행되어 왔다. 이에 따라 정책 논의를 주도하는 행위자가 정부, 인문·사회계 전문가, 기업에서 정부, 법학·법조계 전문가, 기업으로 그리고 정부, 법학·법조계 전문가, 기업, 시민단체로 변화함을 파악하였다. 이 과정에서 인공지능 정책의 주된 논의가 정책네트워크 특성에 따라 달라졌음을 파악하였다. 초기의 인공지능 정책형성과정에서부터 큰 영향력을 보인 과학기술정보통신부와 기업의 정책 입장은 꾸준히 정책의 방향성을 형성하였다. 과학기술정보통신부의 정책은 꾸준히 실질적인 규제보다는 산업 진흥을 추진

하는 쪽으로 진행되어 왔다. 또한 법제도 논의 이후 영향력이 커진 법학·법조계 전문가들은 이후 법제도 중심의 인공지능 윤리 정책 논의를 이끌어 갔다. 시민단체는 인공지능 기본법 논의 이후 주된 행위자로 등장하며 인공지능 기본법안의 문제가 된 조항을 삭제하는 데 영향을 미치는 등 정책의 주요 논의에 영향을 끼쳤다.

한국 인공지능 정책형성과정을 파악함으로써 앞으로의 한국 인공지능 거버넌스 형성을 위한 정책적 함의를 도출할 수 있다. 우선 한국의 인공지능 정책 초기부터 주된 담론을 이끌어 온 과학기술정보통신부는 기술 발전과 인공지능에 대한 윤리적 고려라는 두 마리 토끼를 모두 잡으려고 했지만 법제화 과정에서 인공지능 위험에 대응하는 실질적 규제 체계를 마련하는 데에는 소극적 입장을 보였다. 과학기술정보통신부의 인공지능 정책은 전반적으로 산업 육성 및 진흥과 민간 자율 규제 양상을 띤다. 과학기술정보통신부를 중심으로 한 인공지능 윤리 정책은 윤리 강령, 법률안, 지침과 가이드라인, 인증 및 표준의 순서로 발표되며 인공지능의 윤리와 신뢰성을 확보하기 위한 노력을 보여 왔다. 하지만 지능정보, 인공지능, 디지털의 주요 키워드를 중심으로 정권에 따라 정책의 큰 흐름은 변화하는데 위험을 실질적으로 규제할 수 있는 수단보다는 규범적인 정책을 반복해서 발표해 왔다. 대표적으로 지능정보 정책의 지능정보사회 윤리 가이드라인 및 윤리헌장, 인공지능 정책의 사람이 중심이 되는 인공지능 윤리기준, 디지털 정책의 디지털 권리장전이 그 예이다. 이는 규제가 기술 혁신과 산업 진흥을 억압한다는 이분법적 프레임을 견지한 입장이다. 하지만 결국 인공지능 시대에 기술과 규범을 선도하는 국가가 되기 위해서는 기술과 산업의 혁신뿐만 아니라 신뢰성과 윤리를 통합하는 정책이 필요하다. 즉, 혁신과 윤리를 통합할 수 있는 정책이 필요하다. 기술의 육성과 산업 진흥 과정에서 사회적·윤리적 위험에 대한 실질적 대응 방안이 결여된다면 결국 문제가 발생하게 된다. 한국 정부도 규범적 정책을 반복하기보다는 인공지능의 사용 사례별로 리스크와 파급력을 고려하여 위험에 대응할 수 있는 실질적 방안을 구축해야 한다.

다음으로 한국의 인공지능 정책네트워크의 권력 분포는 정부에 집중된 양상을 띠고 정책의 방향성 설정에 기업과 전문가의 영향력이 크게 작용했다. 반면 시민단체는 정책형성과정에서 영향력이 크지 않았다. 또한 시민단체는 상호작용 유형에서 기업 및 협회와 갈등 관계를 맺고 있고 소통도 단절되어 있었다. 또한 정책형성과정에서 인공지능의 사회적·윤리적 문제 방지를 최우선 목표로 두고 있는 시민단체의 입장이 반영될 수 있는 실질적인 창구를 찾기 어려웠다. 또한 한국 인공지능 정책네트워크는 정책형성 초기부터 참여해 온 참여자의 구성에 큰 변동이 없어서 정책형성과정에서 새로운 의견이 반영될 수 있는 기회가 적었다. 하지만 인공지능 기술과 규범을 선도하는 국가로 자리매김하기 위해서는 정책네트워크 권력 분포의 중심에 있는 정부 차원에서 단절되어 있는 소통의 통로를 마련하고 다양한 구성의 조직을 운영하는 방안을 고려할 필요성이 있다.

마지막으로 과학기술정보통신부의 정책은 꾸준히 민간 자율 거버넌스 형성을 강조해 왔다. 하지만 정책 기조와는 달리 거버넌스가 정부 중심으로 구축되는 양상을 보여 왔다. 한국 인공지능 윤리 거버넌스에서 가장 큰 영향력을 행사하고 있는 것은 정부이다. 그런데 정부 차원에서 민간 자율 거버넌스를 형성하고 싶다면 민간이 윤리 거버넌스를 형성할 수 있게 돕는 것이 중요하다. 예를 들어 민간의 윤리 거버넌스 역량 향상을 위해 인공지능 리터러시를 함양하는 방법이 있다. 이는 기술의 활용에 초점을 둔 교육이 아닌 인공지능의 역기능을 인식하고 대응할 수 있는 비판 능력을 키우는 데 초점을 둔 교육을 말한다. 또는 기업 차원에서 적용할 수 있는 자체 평가 제도를 만들어 이를 운영할 수 있는 시스템을 구축하는 것이 필요하다.

본 연구는 다음의 이유로 후속 연구가 더 필요하다. 우선 인공지능 윤리 정책에 관여하는 부처는 과학기술정보통신부만이 아니다. 개인정보보호위원회, 방송통신위원회, 산업자원부, 공정거래위원회, 문화체육관광부 등도 인공지능 윤리 정책을 발표하고 있다. 따라서 연구의 범위를 정부

전체로 넓혔을 때 추가적인 한국의 인공지능 거버넌스와 정책형성과정의 특성을 찾을 수 있을 것으로 기대한다. 다음으로 인공지능 윤리 정책은 2024년 이후로도 꾸준히 발표되어 왔다. 특히 2024년 상반기에 과학기술 정보통신부는 민·관 인공지능 최고위거버넌스인 ‘인공지능전략최고위 협의회’를 출범하고 이제까지 분산된 거버넌스를 이루고 있던 주요 관계 부처와 분절적으로 운영되던 포럼, 자문위원회, 협의체 등을 연계하겠다는 포부를 밝혔다. 또한 2024년 하반기에는 ‘인공지능전략최고위 협의회’를 대통령 직속으로 격상한 ‘국가 인공지능 위원회’가 출범할 예정이다. 따라서 2024년 이후 한국 인공지능 거버넌스의 통합이라는 새로운 변화를 고려하여 연구한다면, 이전까지는 각 부처에서 분산되어 시행되던 정책 체계가 통합되어 실행되었을 때 한국의 인공지능 거버넌스와 정책형성과정의 특성이 어떻게 변화하는지를 규명할 수 있을 것으로 기대한다.

참 고 문 헌

1차 문헌

<정부 보고서>

- 과학기술정보통신부, KISDI. (2023). 『2023 윤리기준 자율점검표(안)』 .
_____. (2023). 『인공지능 윤리 교재』 .
- 과학기술정보통신부, NIA. (2018). 『지능정보화사회 윤리 가이드라인 및 윤리헌장』 .
- 과학기술정보통신부, TTA. (2023). 『2023 신뢰할 수 있는 인공지능 개발안내서』 .
- 과학기술정보통신부. (2018). 『인공지능(AI) R&D 전략』 .
- 관계부처 합동. (2016). 『제4차 산업혁명에 대응한 지능정보사회 중장기 종합대책』 .
- 관계부처 합동. (2019). 『인공지능(AI) 국가전략』 .
_____. (2020). 『인공지능(AI) 윤리기준』 .
_____. (2020). 『인공지능법·제도·규제정비로드맵』 .
_____. (2021). 『신뢰할 수 있는 인공지능 실현 전략(안)』 .
_____. (2022). 『대한민국 디지털 전략』 .
- 대한민국 정부. (2023). 『디지털 권리장전 해설서』 .
- 미래창조과학부, KISTEP. (2016). 『2015년도 기술영향평가』 .

<정부 보도자료>

과학기술정보통신부. (2020). 인공지능 시대를 대비한 기본법제 마련.

과학기술정보통신부. (2023a). 디지털 심화 시대, 디지털 신(新)질서 정립 착수.

과학기술정보통신부. (2023b). 안전하고 신뢰할 수 있는 인공지능 확산을 위한 국내 최초 인공지능 신뢰성 단체표준 제정.

국가인권위원회. (2023). 「인공지능 법률안」, ‘우선허용 · 사후규제’ 원칙 삭제하고, 인권영향평가 도입해야.

산업자원부. (2007), 로봇윤리헌장 제정으로, 1가구 1로봇시대 앞당겨질 듯.

<법안과 법>

정필모 의원 발의, “인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안”, 2111261, (2021. 7. 1.).

윤두현 의원 발의, “인공지능산업 육성 및 신뢰 기반 조성에 관한 법률안”, 2118726, (2022. 12. 7.)

지능정보화 기본법, [https://www.law.go.kr/법령/지능정보화 기본법](https://www.law.go.kr/법령/지능정보화_기본법).

<웹사이트>

인공지능 윤리 소통채널. <https://ai.kisdi.re.kr/aieth/main/main.do> (최종 접속일 2024. 4. 3.)

디지털공론장. <http://beingdigital.kr/front/main.do> (최종접속일: 2024. 4. 3.)

2차 문헌

<국문 문헌>

- 고학수, 박도현, & 이나래. (2020). 인공지능 윤리규범과 규제 거버넌스의 현황과 과제. *경제규제와 법*, 13(1), 7-36.
- 권기창 & 배귀희. (2006). 과학기술정책의 거버넌스 변화. *한국정책과학학회보*, 10(3), 27-53.
- 김건우, 김송옥, 심우민, 윤혜선, & 이상용. (2023). *인공지능 규제 거버넌스의 현재와 미래*. 파이돈.
- 김명주. (2019). 인공지능 윤리 원칙 Seoul PACT 를 적용한 지능형 전자정부 서비스 윤리 가이드라인. *한국 IT 서비스학회지*, 18(3), 117-128.
- 김송옥. (2021). AI 법제의 최신 동향과 과제-유럽연합 (EU) 법제와의 비교를 중심으로. *공법학연구*, 22(4), 115-148.
- 김재선. (2021). 인공지능 안전과 책임 확보를 위한 법제 논의에 관한 검토-유럽연합 인공지능 관리 법제 논의에 기초하여-. *행정법연구*, (64), 157-181.
- 김정민. (2020). 인공지능 알고리즘 규제 현황과 최근동향 및 법적합의-인공지능 편향성 문제를 중심으로. *디지털 윤리*, 4(2), 27-42.
- 김훈기. (2003). 한국 생명윤리 의제 형성에 대한 정책네트워크 분석. *생명윤리*, 4(1), 89-116.
- 박상욱. (2013). 도로교통분야에서의 사회·기술시스템 전환: 연료전지 자동차 사례: 연료전지 자동차 사례. *과학기술정책*, (193), 17-26.
- 변순용, 정진규, 김형주, & 신현우. (2017). 로봇윤리현장의 필요성과 내용에 대한 연구. *윤리연구*, 1(112), 295-319.
- 송미원, & 권기창. (2003). 생명윤리 입법화 과정에서의 정책네트워크 분

- 석에 관한 연구. *한국행정연구*, 12(3), 32-62.
- 송위진. (2013). 사회·기술시스템론과 과학기술혁신정책. *기술혁신학회지*, 16(1), 156-175.
- 윤혜선. (2019). 인공지능 규제 정책에 관한 연구: 주요국의 규제 정책 사례를 중심으로. *정보통신정책연구*, 26(4), 135-176.
- 이상욱 & 이호영. (2021). *인공지능(AI) 윤리와 법 (1) - AI 윤리의 쟁점과 거버넌스 연구*. 유네스코한국위원회
- 이상욱. (2021). *유네스코 인공지능(AI) 윤리 권고 해설서 인공지능 윤리 이해하기*, 유네스코한국위원회.
- 이중원, 홍성욱, 손화철, 송위진, 이두갑, 이상욱, 임소연, 천현득, 현재환, & 과학과 가치 연구회. (2023). *과학과 가치*. 이음.
- 정정길, 최종원, 이시원, 정준금, & 정광호. (2010). *정책학원론*, 대명출판사.
- 홍석한. (2023). 미국 “2022 알고리즘 책임법안”에 대한 고찰. *미국헌법연구*, 34(1), 73-107.
- 홍중영, & 이찬구. (2022). 중국 인공지능 산업 육성의 정책네트워크 분석: 차세대 AI 산업 발전 3 개년 행동계획 사례. *Journal of China Studies*, 25(1), 1-34.
- INSS(국가안보전략연구원). (2023). 바이든 행정부의 첫 인공지능(AI) 행정명령과 시사점, *이슈브리프*.
- NIA(한국정보화진흥원). (2022). 주요 국가 AI 전략 분석 - 미국, 영국, 독일, 싱가포르, 캐나다를 중심으로 -, *IT & Future Strategy*.
- _____. (2023). 윤석열 정부 1년, 디지털 정책 추진 현황과 성과, *GDX*.
- STEPI(과학기술정책연구원). (2005). 혁신주체의 참여를 통한 과학기술 거버넌스 구축방안. *조사연구*.

<영문 문헌>

- Adam, S., & Kriesi, H. (2019). The network approach. In *Theories of the Policy Process*, Second Edition (pp. 129-154). Routledge.
- Bietti, E. (2020). From ethics washing to ethics bashing: a view on tech ethics from within moral philosophy. In *Proceedings of the 2020 conference on fairness, accountability, and transparency*, 210-219.
- Bryson, J. J. (2017). The meaning of the EPSRC principles of robotics. *Connection Science*, 29(2), 130-136.
- Collins, C., Dennehy, D., Conboy, K., & Mikalef, P. (2021). Artificial intelligence in information systems research: A systematic literature review and research agenda. *International Journal of Information Management*, 60, 102383.
- Crawford, K. (2021). *The atlas of AI: Power, politics, and the planetary costs of artificial intelligence*. Yale University Press.
- Creutzburg, L., & Lieberherr, E. (2021). To log or not to log? Actor preferences and networks in Swiss forest policy. *Forest policy and economics*, 125, 102395.
- Dowding, K. (1995). Model or metaphor? A critical review of the policy network approach. *Political studies*, 43(1), 136-158.
- Elzen, B., Geels, F. W., & Green, K. (Eds.). (2004). *System innovation and the transition to sustainability: theory, evidence and policy*. Edward Elgar Publishing.
- EURON. (2006). *The EURON Roboethics Roadmap*.
- Fjeld, J., Achten, N., Hilligoss, H., Nagy, A., & Srikumar, M. (2020). *Principled artificial intelligence: Mapping consensus in ethical and rights-based approaches to principles for AI*. Berkman

- Klein Center Research Publication, (2020-1).
- Fuenfschilling, L., & Truffer, B. (2016). The interplay of institutions, actors and technologies in socio-technical systems – An analysis of transformations in the Australian urban water sector. *Technological Forecasting and Social Change*, 103, 298–312.
- Gasser, U., & Almeida, V. A. (2017). A layered model for AI governance. *IEEE Internet Computing*, 21(6), 58 – 62.
- Geels, F. W. (2004). From sectoral systems of innovation to socio-technical systems: Insights about dynamics and change from sociology and institutional theory. *Research policy*, 33(6–7), 897–920.
- Georgieva, I., Lazo, C., Timan, T., & van Veenstra, A. F. (2022). From AI ethics principles to data science practice: a reflection and a gap analysis based on recent frameworks and practical experience. *AI and Ethics*, 2(4), 697–711.
- Hagendorff, T. (2020). The ethics of AI ethics: An evaluation of guidelines. *Minds and machines*, 30(1), 99–120.
- High-Level Expert Group on Artificial Intelligence. (2019). *ETHICS GUIDELINES FOR TRUSTWORTHY AI*. European Commission.
- Jobin, A., Ienca, M., & Vayena, E. (2019). The global landscape of AI ethics guidelines. *Nature Machine Intelligence*, 1(9), 389–399.
- Jordan, A. G. (1981). Iron triangles, woolly corporatism and elastic nets: Images of the policy process. *Journal of public policy*, 1(1), 95–123.
- Kaur, D., Uslu, S., Rittichier, K. J., & Durresi, A. (2022). Trustworthy artificial intelligence: a review. *ACM computing surveys*

- (*CSUR*), 55(2), 1–38.
- Knoke, D. (2011). *Policy networks*. The SAGE handbook of social network analysis, 210–222.
- König, T., & Bräuninger, T. (1998). The formation of policy networks: Preferences, institutions and actors' choice of information and exchange relations. *Journal of theoretical politics*, 10(4), 445–471
- Koniakou, V. (2023). From the “rush to ethics” to the “race for governance” in Artificial Intelligence. *Information Systems Frontiers*, 25(1), 71–102.
- Kriesi, H., Adam, S., & Jochum, M. (2006). Comparative analysis of policy networks in Western Europe. *Journal of European public policy*, 13(3), 341–361.
- Liao, S. M. (Ed.). (2020). *Ethics of artificial intelligence*. Oxford University Press.
- Lindberg, M. B., Markard, J., & Andersen, A. D. (2019). Policies, actors and sustainability transition pathways: A study of the EU's energy policy mix. *Research policy*, 48(10), 103668.
- Marsh, D., & Rhodes, R. A. W. (1992). *Policy networks in British government*. Clarendon Press.
- Marsh, D., & Smith, M. (2000). Understanding policy networks: towards a dialectical approach. *Political studies*, 48(1), 4–21.
- McCarthy, J., Minsky, M. L., Rochester, N., & Shannon, C. E. (2006). A proposal for the dartmouth summer research project on artificial intelligence, august 31, 1955. *AI magazine*, 27(4), 12–12.
- Nilsson, N. J. (2009). *The quest for artificial intelligence*. Cambridge University Press.

- Nishant, R., Kennedy, M., & Corbett, J. (2020). Artificial intelligence for sustainability: Challenges, opportunities, and a research agenda. *International Journal of Information Management*, 53, 102104.
- Normann, H. E. (2017). Policy networks in energy transitions: The cases of carbon capture and storage and offshore wind in Norway. *Technological Forecasting and Social Change*, 118, 80–93.
- OECD. (2019). *Recommendation of the Council on Artificial Intelligence*. OECD Legal Instruments.
- _____. (2024). *Explanatory memorandum on the updated OECD definition of an AI system*. OECD Artificial Intelligence Papers, No. 8, OECD Publishing, Paris.
- Park, S. (2023). Bridging the Global Divide in Ai Regulation: A Proposal for Contextual, Coherent, and Commensurable Framework.
- Park, D. H., Cho, E., & Lim, Y. (2024). A Tough Balancing Act - The Evolving AI Governance in Korea. *East Asian Science, Technology and Society: An International Journal*, 18(2), 135 - 154.
- Radu, R. (2021). Steering the governance of artificial intelligence: national strategies in perspective. *Policy and society*, 40(2), 178–193.
- Rhodes, R. A. (1997). *Understanding governance: Policy networks, governance, reflexivity and accountability*. Open University.
- _____. (1988). *Beyond Westminster and Whitehall: The sub-central governments of Britain*. Routledge.
- _____. (2007). Understanding governance: Ten years on.

- Organization studies*, 28(8), 1243–1264.
- Russell, S. J., & Norvig, P. (2016). *Artificial intelligence: a modern approach*. Pearson.
- Russell, S., Dewey, D., & Tegmark, M. (2015). Research priorities for robust and beneficial artificial intelligence. *AI magazine*, 36(4), 105–114.
- Sabatier, P. A. (Eds.) (2007). *Theories of the policy process*. Westview Press.
- Schiff, D., Biddle, J., Borenstein, J., and Laas, K.(2020). What's next for ai ethics, policy, and governance? a global overview. In *Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society*, 153–158.
- Schmitt, L. (2022). Mapping global AI governance: a nascent regime in a fragmented landscape. *AI and Ethics*, 2(2), 303–314.
- Siau, K., & Wang, W. (2020). Artificial intelligence (AI) ethics: ethics of AI and ethical AI. *Journal of Database Management (JDM)*, 31(2), 74–87.
- Stahl, B. C., Antoniou, J., Ryan, M., Macnish, K., & Jiya, T. (2022). Organisational responses to the ethical issues of artificial intelligence. *AI & SOCIETY*, 37(1), 23–37
- Stake, R. (2003). Case studies. In N. K. Denzin & Y. S. Lincoln (Eds.), *Strategies of qualitative inquiry* (2nd Ed.) (pp. 134 – 164). Thousand Oaks, CA: Sage.
- Stone, P., Brooks, R., Brynjolfsson, E., Calo, R., Etzioni, O., Hager, G., ... & Teller, A. (2022). Artificial intelligence and life in 2030: the one hundred year study on artificial intelligence. *arXiv preprint arXiv:2211.06318*.
- Tallberg, J., Erman, E., Furendal, M., Geith, J., Klamberg, M., &

- Lundgren, M. (2023). The global governance of artificial intelligence: Next steps for empirical and normative research. *International Studies Review*, 25(3), viad040.
- UNESCO. (2021) *Recommendation on the Ethics of Artificial Intelligence*.
- Van Wynsberghe, A. (2021). Sustainable AI: AI for sustainability and the sustainability of AI. *AI and Ethics*, 1(3), 213-218.
- Walz, A., & Firth-Butterfield, K. (2019). *AI Governance: A Holistic Approach to Implement Ethics into AI*. World Economic Forum.
- Wu, C. J., Raghavendra, R., Gupta, U., Acun, B., Ardalani, N., Maeng, K., ... & Hazelwood, K. (2022). Sustainable ai: Environmental implications, challenges and opportunities. *Proceedings of Machine Learning and Systems*, 4, 795-813.
- Zeng, Y., Lu, E., & Huangfu, C. (2018). Linking artificial intelligence principles. *arXiv preprint arXiv:1812.04814*.

<웹사이트>

- Kind, C. (2020. August). *The term ‘ethical AI’ is finally starting to mean something*. VentureBeat.
<https://venturebeat.com/2020/08/23/the-term-ethical-ai-is-finally-starting-to-mean-something/> (최종 접속일: 2024. 4. 3.)
- OpenAI (2018. May). *AI and compute*.
<https://openai.com/research/ai-and-compute> (최종 접속일: 2024. 4. 3.)
- Stanford University. <https://ai100.stanford.edu/about/history> (최종 접속일: 2024. 4. 3)
- 과학기술정보통신부. (2023. 9.). *디지털 환경에서 자유와 권리 보장...‘디지털*

권리장전' 발표. 대한민국 정책브리핑.
<https://www.korea.kr/news/policyNewsView.do?newsId=148920752>
(최종 접속일: 2024. 5. 24.)

<기사>

- 김은성. (2023. 3. 22.). '선택용 후규제' AI법 논란...시민단체 "사회·경제 손실 초래. 경향신문.
<https://m.khan.co.kr/economy/economy-general/article/202303221729001#c2b> (최종 접속일: 2024. 4. 3.)
- 로봇신문사. (2013. 12. 16). 로봇 윤리 현장. 로봇신문.
<http://m.irobotnews.com/news/articleView.html?idxno=1606>
(최종 접속일: 2024. 5. 21.)
- 박지영. (2024. 5. 14). '인공지능 앞잡이' 법안 우려...윤 정부, AI 기본법 밀어붙이기. 한겨레.
https://www.hani.co.kr/arti/economy/economy_general/1140507.html (최종 접속일: 2024. 5. 29.)
- 정상원. (2024. 5. 22.). AI기본법, 1년4개월 국회표류 끝에 폐기 수순. 한국경제. <https://www.hankyung.com/article/2024052135641>
(최종접속일: 2024. 5. 26.)
- 홍준기. (2024. 2. 23). 당신의 직장을 위협하는 AI... 실제 미국 해고 사례 분석하니. 조선일보.
<https://www.chosun.com/economy/weeklybiz/2024/02/22/XXA3KNQQFRDIDH3GMEIATCRFIY/> (최종접속일: 2024. 7. 30)
- 참여연대. (2024. 3. 2). 15개 인권시민단체, 국회 과방위 법안심사소위 통과한 인공지능육성법안 반대 의견서 제출.
<https://www.peoplepower21.org/publiclaw/1927781> (최종 접속일:

2024. 5. 26.)

Dan Milmo and agency. (2023. Feb 2). *ChatGPT reaches 100 million users two months after launch*. The Guardian.
<https://www.theguardian.com/technology/2023/feb/02/chatgpt-100-million-users-open-ai-fastest-growing-app> (최종 접속일: 2024. 5. 24.)

Julia Angwin, Jeff Larson, Surya Mattu and Lauren Kirchner. (2016. May 23). *Machine Bias*. ProPublica.
<https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing> (최종 접속일: 2024. 5. 30.)

Ananya. *AI image generators often give racist and sexist results: can they be fixed?*. Nature.
<https://www.nature.com/articles/d41586-024-00674-9> (최종 접속일: 2024. 4. 3.)

Zoe Kleinman & Chris Vallance. (2023. May 2). *AI 'godfather' Geoffrey Hinton warns of dangers as he quits Google*. BBC.
<https://www.bbc.com/news/world-us-canada-65452940> (최종 접속일: 2024. 4. 3.)

<기타 자료>

31개 단체. (2023. 8. 30.). [공동논평]“국회는 인공지능 법률안에 대한 국가인권위원회 의견을 수용하라”.
<https://docs.google.com/document/d/1WXk-0NaRUGR2T83vM39wWbJW3zQRcajue5dbXMj1vII/edit>

Gender Shade. (2018. Feb 10). <http://gendershades.org/> (최종 접속일: 2024. 5. 30.)

Greene, D., Hoffmann, A. L., & Stark, L. (2019). Better, nicer, clearer, fairer: A critical assessment of the movement for ethical artificial intelligence and machine learning., *Proceedings of the 52nd Hawaii International Conference on System Sciences*.

인터뷰

정부 인터뷰이(A). 대면 인터뷰. 2024. 6. 4.
정부 인터뷰이(B). 대면 인터뷰. 2024. 6. 15.
정부 인터뷰이(C). 대면 인터뷰. 2024. 5. 12.
정부 인터뷰이(D). 대면 인터뷰. 2024. 2. 26.
전문가 인터뷰이(E). 대면 인터뷰. 2023. 12. 5.
전문가 인터뷰이(F). 대면 인터뷰. 2023. 12. 27.
전문가 인터뷰이(G). 대면 인터뷰. 2024. 3. 19.
기업 및 협회 인터뷰이(H). 대면 인터뷰. 2023. 12. 22.
기업 및 협회 인터뷰이(I). 대면 인터뷰. 2024. 3. 8.
시민단체 인터뷰이(J). 대면 인터뷰. 2024. 5. 31.

Abstract

A Study on AI Governance and Policy Formation Process : From Ethical Norms to Legislation

Jiwon Kim

Department of Science Studies, Science Policy

The Graduate School

Seoul National University

This study aims to describe and characterize the process of building ethical governance of Artificial Intelligence(“AI”) through the interaction of policies and policy actors. As AI technology has been rapidly developing, social and ethical issues related to AI technology have also increased dramatically. Therefore, the need for AI governance that can secure the ethics of AI from the development stage of the technology has emerged. National AI policies have a major impact on the establishment of AI governance, affecting AI from its development to use. Analyzing how national AI policies have been formed and identifying their characteristics and implications are essential for shaping the AI governance that needs to be built in the future.

To this end, this study analyzes the phenomenon that normative approaches to minimize the social and ethical side effects of AI are reflected in policies by focusing on the interaction between policies and policy actors, and the actor relationships in policy networks. Focusing on the Ministry of Science and ICT, which is in charge of AI ethics policy in South Korea, this study identifies major government policies between 2016 and 2023, and the main actors involved in the policy formation process, including the government, experts, companies and associations, and civil society organizations. As a methodology, this study uses collective case study, literature research, and semi-structured interviews. Furthermore, using socio-technical systems and policy networks as the theoretical framework, this study analyzes the background, objectives, and content of key policies, as well as the distribution of power among key policy actors, their preferences, and their types of interactions.

As a result, this study finds that policy networks change in response to policy streams, and that the relationships between groups are an important factor in causing policy change. In South Korea, the policy streams have shifted from the Code of Ethics for AI since 2016 to the reorganization of Legal Systems for AI since 2020, and the preparation of the Basic Act on AI since 2023. The policy networks formed by the government, experts, companies and associations, and civil society groups in response to the policy streams in turn influenced policies and led to policy changes. The results of this study provide policy implications for understanding AI governance and policy formation in South Korea and for establishing more effective AI policies.

Keywords : AI Governance, AI Policy Formation Process, AI Policy in South Korea, AI Ethics, Policy Networks, Socio-technical Systems

Student Number : 2022-26945