

인공지능의 윤리와 법의 접점

The Intersection of Artificial Intelligence Ethics and Law

원 상 철*

Won, Sang-Chul

《 목 차 》

I. AI의 윤리를 위한 관련성

II. 주요 쟁점의 토론

III. AI 윤리지침

IV. 맺음말

[국 문 초 록]

AI 기술이 우리의 개인정보에 미치는 잠재적 피해와 영향 외에도 도덕적 및 법적 지위(권리를 포함한다.), 도덕적 선택의지 및 인내심, 가능한 인격 및 존엄성과 관련된 문제가 포함된다. 그러나 인공지능과 인공지능이 인간사회와의 관계와 관련하여 가장 중요한 사안은 시기적으로 구분한다. 즉, (1) 단기(2021년 초부터): 자율

■ 투고일자: 2024년 05월 02일

■ 심사일자: 2024년 05월 18일

■ 게재확정: 2024년 05월 22일

* 용인예술과학대학교 경찰행정과교수, 법학박사(Ph.D)

시스템(운송, 무기), 법의 기계 편향, 개인정보보호 및 감시, 블랙박스 문제 및 AI 의사결정; (2) 중기(2040년대부터 세기말까지): AI 거버넌스, 지능형 기계(인공도덕 행위자)의 도덕적 및 법적 지위 확인, 인간-기계의 상호작용, 대량 자동화; (3) 장기(2100년대부터): 기술적 특이점, 대량 실업, 우주 식민지화와 같은 문제들을 세 가지 다른 시기에 따라 구분하는 것이 일반적이다.

이 글은 인공지능(AI)이 인간사회에 미치는 영향과 관련된 주요 윤리적 문제에 대한 포괄적인 개요를 제공한다. AI는 일반적으로 인간의 지능이 필요한 작업을 수행하기 위해 기계를 사용하는 것이다. 인간생활의 많은 영역에서 AI는 인간사회와 우리가 서로 상호작용하는 방식에 빠르고 중대한 영향을 미쳤다. 앞으로도 계속 그렇게 할 것이다. 그 과정에서 AI는 철저한 철학적, 윤리적 분석을 요구하는 동시에 상당한 윤리적, 사회정치적 과제를 제시했다. AI의 부정적인 영향을 회피하기 위해 그것이 미치는 사회적 영향을 연구해야 한다. AI 시스템은 점점 더 자율적이고, 합리적으로 보이며, 지능적으로 변하고 있다. 이것의 포괄적인 개발은 수많은 문제를 야기한다.

주제어

인공지능윤리, 개인정보보호, 기술특이점, 인간존엄성, 기계편견.

I. AI의 윤리를 위한 관련성

이하에서는 인간과 기계의 상호작용이 증가함에 따라 AI가 윤리 및 도덕 시스템에 가장 중요한 이유에 대해 설명하고자 한다.

1. AI의 개념

AI는 여러 가지 다른 것을 의미할 수 있으며 다양한 방식으로 정의된다. 앨런 튜링(Alan Turing)이 기계가 생각할 수 있는지에 대한 그의 유명한 1950년 에세이에서 소위 튜링 테스트(그는 ‘모방 게임’이라고 불렀다.)를 소개했을 때, ‘인공지능’

능’이라는 용어는 아직 소개되지 않았다. 튜링은 기계가 생각할 수 있는지 여부를 고려했고, 그 질문을 인간을 매우 설득력 있게 모방할 수 있는 기계를 만드는 것이 가능할 수 있는지에 대한 질문으로 대체하는 것이 더 명확할 것이라고 제안했다.

‘인공지능(AI)’이라는 용어는 1955년 존 매카시(John McCarthy), 마빈 L. 민스키(Marvin L. Minsky), 나다니엘 로체스터(Nathaniel Rochester), 클로드 E. 섀넌(Claude E. Shannon)과 같은 연구자 그룹에 의해 만들어졌는데, 이들은 1956년 다트머스 대학에서 ‘인공지능 연구’에 관한 유명한 여름 워크숍을 조직했다. 이 사건은 AI 연구의 시작으로 널리 알려져 있다. 주최 측은 워크숍을 다음과 같이 설명했다.

우리는 1956년 여름에 뉴햄프셔 주 하노버에 있는 다트머스 대학에서 2개월간 10명을 대상으로 인공지능에 대한 연구를 수행할 것을 제안한다. 이 연구는 학습의 모든 측면이나 지능의 다른 특징이 원칙적으로 매우 정확하게 기술되어 기계가 그것을 시뮬레이션할 수 있다는 추측에 기초하여 진행되어야 한다. 기계가 언어를 사용하게 하고, 추상과 개념을 형성하고, 현재 인간에게 유보된 종류의 문제를 해결하고, 스스로를 개선하는 방법을 찾으려는 시도가 이루어질 것이다. 우리는 신중하게 선택된 과학자 그룹이 여름 동안 함께 연구한다면 이러한 문제 중 하나 이상에서 상당한 진전을 이룰 수 있다고 생각한다.

나중에 학계에서 내린 또 다른 정의는 AI를 다음과 같이 설명한다. 즉, “디지털 컴퓨터 또는 컴퓨터 제어 로봇이 일반적으로 지능적인 존재와 관련된 작업을 수행하는 능력이다.” 이 용어는 추론 능력, 의미의 발견, 일반화 또는 과거의 경험에서 배우는 능력과 같은 인간의 지적 과정을 부여받은 시스템을 개발하는 프로젝트에 자주 적용된다.²⁾

21세기 초, 많은 컴퓨터 전문가와 엔지니어의 궁극적인 목표는 기계의 기원을 제외하고는 인간의 지능과 다르지 않은 강력한 AI 시스템을 구축하는 것이었다.

2) 김명호, “인공지능, 창작을 하다: 데이터 수집과 윤리,” 한국과학기술기획평가원 KISTEP InI, (2023.4), 84-87면.

이것이 과연 가능한지는 수십 년 동안 활발한 논쟁의 대상이었다. 미국의 저명한 철학자 존 설(John Searle, 1980)은 이른바 ‘중국식 방 논증’을 도입하여 강력한 인공일반지능(AGI) 즉, 인간과 같은 지능을 필요로 하는 다양하고 복잡한 작업을 처리할 수 있는 인공지능 시스템을 구축하는 것은 원칙적으로 불가능하다고 주장했다. 그렇게 함으로써 그는 AGI의 가능성에 대한 오랜 일반적인 논쟁을 촉발시켰다. 현재의 AI 시스템은 협소한 초점(즉, 약한 AI)이며, 서양의 체스나 한중일의 바둑 게임과 같은 특정 작업만 해결할 수 있다. 설(Searle)의 일반적인 논제는 기계가 아무리 복잡하고 정교하더라도 계산능력과 달리 이해하는 능력의 전제조건인 ‘의식’이나 ‘마음’을 갖지 않는다는 것이었다.

설(Searle)의 주장은 기능주의와 계산주의의 반론에 대해 비판적으로 평가되었다. 일반적으로 지능은 탄소 기반 존재와 같은 특정 하위계층을 필요로 하지 않지만, 시스템이 충분히 복잡하다면 실리콘 기반 환경에서도 진화할 것이라고 주장된다.

21세기 초반에 AI 개발에 종사하는 많은 연구자들은 AI를 주로 다양한 형태의 소위 머신 러닝 즉, 데이터의 패턴을 식별하는 기술과 연관시켰다. 이러한 시스템의 더 단순한 형태는 ‘지도학습’에 관여한다고 알려져 있지만(그럼에도 불구하고 여전히 상당한 인간의 입력과 감독이 필요하다.) 많은 연구자들, 아마도 가장 두드러진 Yann LeCun의 목표는 소위 자기지도학습 시스템을 개발하는 것이었다. 요즘 일부 연구자들은 AI의 개념을 기계학습과 동일시하는 방식으로 AI에 대해 논의하기 시작했다. 그러나 이 글에서는 기계학습 기술을 포함하되 이에 국한되지 않는 더 넓은 의미로 ‘AI’라는 용어를 사용한다.

2. 윤리적 타당성

AI가 인간사회에 제기하는 주요 윤리적 과제는 Vincent Müller, Mark Coeckelbergh, Janina Loh, Catrin Misselhorn 및 David Gunkel의 훌륭한 저서 서문에 잘 나와 있다. AGI를 해석할 가능성과 상관없이, 자율 AI 시스템은 이미 상당한 윤리적 문제를 제기하고 있다. 예를 들어, 법의 기계 편향성, 스마트 알고리즘을 통한 채용 결정, 인종차별적이고 성차별적인 챗봇, 성(Gender) 중립적이지

않은 언어번역 등이 그것이다. AI의 일반적인 정의 중 하나인 인간의 지능을 ‘모방’하는 기계라는 아이디어 자체만으로도 속임수에 대한 우려가 제기되며, 특히 AI가 인간처럼 보이거나 행동하도록 설계된 로봇에 내장된 경우 더욱 그렇다. 더욱이 로잘린드 피카르(Rosalind Picard)는 “기계의 자유가 클수록 도덕적 기준이 더 많이 필요하다”고 주장한다. 이는 AI 시스템과 인간 간의 모든 상호작용이 예를 들어, 자율주행의 맥락에서 필연적으로 윤리적 차원을 수반한다는 주장을 입증한다.

기계 내에서 윤리를 구현한다는 아이디어는 기계윤리 분야의 주요 연구목표 중 하나이다. 많은 시스템의 우수한 성능(디버깅 단계를 성공적으로 통과한 후)에서 알 수 있듯이 휴식 없이, 지속적인 감독이 필요 없이 인간보다 훨씬 빠르게 작업할 수 있는 자율 AI 시스템으로 점점 더 많은 책임이 인간에게서 이전되었다.³⁾

인류의 미래 존재는 인공지능 시스템의 확고한 도덕적 기준의 구현에 달려 있으며, 이러한 시스템이 어느 시점에서 인간의 능력과 일치하거나 대체할 수 있다는 가능성이 있다. 이 시점은 1983년 Vernon Vinge에 의해 ‘기술적 특이점’이라고 불렸다.⁴⁾ 유명한 극작가 칼 차페크(Karl Čapek), 저명한 천체물리학자 스티븐 호킹(Stephen Hawking), 영향력 있는 철학자 닉 보스트롬(Nick Bostrom)은 모두 지능형 기계가 창조자의 저주 즉, 인간에게 등을 돌릴 경우 초래할 수 있는 기술적 특이점의 위험에 대해 경고했다. 따라서 Nick Bostrom에 따르면 인간에게 친숙한 AI를 구축하는 것이 가장 중요하다.

결론적으로, AI 윤리의 구현은 인류의 실존적 위험을 미리 예방할 수 있는 안전지침을 제공하고, AI에 대한 편견과 관련된 모든 문제를 해결하고, 우리의 윤리기준을 채택할 인간 친화적인 AI 시스템을 구축하고, 인류의 번영을 돕는 여러 가지 이유로 AI 시스템에 윤리적 제한을 장착하는 것이 매우 중요하다.

3) 하진봉, “도덕과 인공지능 윤리교육에 대한 도덕심리학적 이해,” 한국윤리학회(윤리학) 윤리연구 1(141), (2023.6), 229-249면.

4) Walsh, T., “The singularity may never be near,” Proc. IJCAI-2016 Ethics for Artificial Intelligence Workshop (2016).

II. 주요 쟁점의 토론

다음 논쟁은 AI와 윤리의 맥락에서 가장 중요하다. 이 분야에서 유일하게 중요한 논쟁은 아니지만, 수십 년 동안 매우 중요하게 남을 가능성이 높은 주제에 대한 좋은 이해와 논쟁의 개요를 소개하고자 한다.

1. 기계윤리

기계윤리의 선구자인 수잔 앤더슨(Susan Anderson)은 기계윤리의 목표를 다음과 같이 정의한다. 즉, 행동을 안내하는 데 있어 이상적인 윤리적 원칙 또는 일련의 원칙을 따르는 기계를 만드는 것, 다른 말로 하자면, 그것은 그것이 취할 수 있는 가능한 행동방침에 대해 내리는 결정에서 이 원칙 또는 이 원칙들에 의해 인도되어야 한다. 더 간단히 말하자면, 이것은 기계에 “윤리적 차원을 더하는 것”을 포함한다.

또한 기계윤리 연구는 지능형 기계의 도덕적 지위에 관한 문제를 검토하고 도덕적 및 법적 권리를 부여받아야 하는지 여부를 묻는 것이다. 일반적으로 기계윤리는 기술윤리의 학제 간 하위분야이며, 이는 응용윤리 내의 학문이다. 기술윤리는 로봇윤리의 하위분야도 포함한다. 인간이 로봇을 설계, 구성 및 사용하는 방법에 대한 질문과 관련이 있다. 이외에도 컴퓨터 윤리, 컴퓨터 및 정보와 관련된 예를 들어, 데이터 보안, 개인정보보호 문제 등 상업적 행동과 관련이 있다.⁵⁾

AI 시스템에 대한 최초의 윤리강령은 유명한 공상과학소설 작가 아이작 아시모프(Isaac Asimov)에 의해 소개되었으며, 그는 런어라운드(Runaround)에서 로봇공학의 세 가지 법칙을 발표했다. 이 세 가지는 나중에 ‘로봇과 제국’에서 ‘로봇공학의 제로 법칙’(Zeroth Law of Robotics)이라고 불리는 네 번째 법칙으로 보완되었다. 네 가지 법칙은 다음과 같다.

- 로봇은 인간을 다치게 하거나 부작위를 통해 인간이 해를 입도록 허

5) 배재권, “비즈니스 영역에서 인공지능 기술의 활용과 인공지능 윤리,” 한국지식정보기술학회 한국지식정보기술학회 논문지 17(6), (2022.12), 1,341-1,352면.

용해서는 안 된다.

- 로봇은 인간이 내린 명령에 복종해야 하며, 그러한 명령이 제1법칙과 충돌하는 경우를 제외하고는 복종해야 한다.

- 로봇은 그러한 보호가 첫 번째 또는 두 번째 법칙과 충돌하지 않는 한 자신의 존재를 보호해야 한다.

- 로봇은 인류에게 해를 끼치지 않을 수 있으며, 무대응으로 인류가 해를 입도록 내버려 둘 수도 없다

아시모프의 4가지 법칙은 수십 년 동안 기계윤리에서 중요한 역할을 해왔으며 전문가들에 의해 널리 논의되어 왔다. 네 가지 법칙에 대한 표준적인 견해는 그것들이 중요하지만 도덕적 기계와 관련된 모든 복잡성을 다루기에는 불충분하다는 것이다.⁶⁾ 아시모프는 자신의 법이 모든 문제를 다룰 수 있다고 주장한 적이 없기 때문에 이것은 공정한 평가로 보인다. 만약, 정말로 그랬다면, 아시모프는 아마도 부분적으로 네 가지 법칙에 의해 야기된 문제들에 대한 그의 매혹적인 이야기를 쓰지 않았을 것이다.

21세기 초반에는 기계가 도덕적 결정을 내리는 데 사용할 수 있는 윤리적 원칙을 AI 시스템에 제공하기 위해 기계 내에서 윤리를 구현하는 다양한 접근방식이 제안되었다. 우리는 적어도 상향식, 하향식, 혼합형 등의 세 가지 유형의 접근 방식을 구별할 수 있다.⁷⁾ 각 유형의 예가 아래에 나와 있다.

(1) 상향식 접근방식: Casuistry

괴리니(Guarini)의 시스템은 상향식 접근방식의 한 예이다. 그것은 신경망이 윤리적 딜레마에 대한 알려진 정답을 제시하는 학습과정을 기반으로 윤리적 결정을 내리는 신경망을 사용한다. 초기 학습과정 이후, 시스템은 새로운 윤리적 딜레마를 스스로 해결할 수 있어야 한다. 그러나 괴리니(Guarini)의 시스템은 상황에 대한 적절한 반영과 정확한 표현의 부족으로 인해 사례의 재분류와 관련된 문

6) Amodei, D., et al., "Concrete Problems in AI Safety," arXiv: 1606.06565 (2016).

7) 野村総合研究所, "日本の労働人口の 49%が人工知能やロボット等で代替可能に," プレスリリース (2015年 12月 2日).

제를 야기한다. 피리니(Guarini) 자신도 계산법만으로는 기계윤리에 불충분하다는 것을 인정한다.

(2) 하향식 접근방식: Moral DM 접근방식

Dehghani et al.이 고안한 시스템은 유추 추론과 함께 공리주의와 의무론이라는 두 가지 주요 윤리이론을 결합한다. 공리주의적 추론은 ‘신성한 가치’에 관한 적용되며, 그 시점에서 시스템은 의무론적 방식으로 작동하고 행동과 결과의 효용에 덜 민감해진다. 시스템을 인간의 도덕적 결정에 맞추기 위해 Dehghani et al.은 대다수의 인간이 특정 사례를 결정하는 방법에 대한 심리학 연구와 비교하여 시스템을 평가한다.

Moral DM 접근법은 두 가지 주요 윤리이론(의무론과 공리주의)을 적절하게 존중하고 유익하고 유망한 방식으로 결합한다는 점에서 특히 성공적이다. 그러나 다수 견해와 일치하는 결정만을 옳은 것으로 간주함으로써 인간의 도덕적 결정을 반영하기 위해 경험적 연구를 사용하는 그들의 추가 전략은 오해의 소지가 있으며 심각한 결함이 있다. 오히려, 그들의 체계는 윤리적 행동에 대한 서술적 연구의 모델로 보아야 하지만, 규범적 윤리의 모델로 보아서는 안 된다.⁸⁾

(3) 혼합식 접근방식: 하이브리드 접근방식

왈라(Wallach et al.)의 인간 인지의 하이브리드 모델은 도덕적 추론과 의사결정의 기초로 간주되는 이론중심의 추론인 하향식 구성요소와 진화 및 학습에 의해 형성된 상향식 구성요소를 결합한다. 지금까지의 결과는 인간 인지의 상당 부분을 모델링하는 포괄적인 개념 및 계산 모델을 제공하는 AGI 소프트웨어인 LIDA이다. 도덕적 추론의 하이브리드 모델은 하향식과 상향식 접근방식의 복잡한 조합에 호소하여 인간의 의사결정을 재현하려고 시도하며, 결국 규범적이지 않은 윤리 모델로 이어진다. 또한 도덕철학의 두 가지 접근방식에 대한 다소 특이한 이해는 실제로 도덕철학자들이 규범윤리에서 그것들을 이해하고 사용하는

8) 전 준, “생성형 인공지능 기반 사회과학연구에 대한 윤리인식 연구,” 한국사회학회 한국사회학회 사회학대회 논문집, (2023.8), 64-64면.

방식과 일치하지 않는다.⁹⁾ Wallach et al.이 제시한 이 모델은 도덕적 의사결정이 경험적 의미에서 어떻게 작동하는지와 관련하여 반드시 부정확하지는 않지만 그들의 접근방식은 본질적으로 규범적이라기보다는 설명적이다. 그러므로, 그들의 경험적 모델은 도덕적 기계가 어떻게 행동해야 하는가에 대한 규범적 문제를 해결하지 못한다. 서술적 윤리와 규범적 윤리는 서로 다른 것이다. 전자는 인간이 어떻게 도덕적 결정을 내리는지를 알려준다. 후자는 우리가 어떻게 행동해야 하는가에 관한 것이다.

2. 자율 시스템

위에서 논의한 기계윤리 시스템에 대한 제안은 인간의 생명에 해를 끼칠 위험이 있는 자율 시스템과 관련하여 점점 더 많이 논의되고 있다. 가장 자주 논의되는 두 가지 예는 자율주행 차량(자율주행 자동차)과 자율무기 시스템(때로는 ‘킬러 로봇’이라고도 함)이다.

일부 저자(Müller and Simpson)들은 자율무기가 인간 군인을 대체할 수 있을 것이라고 생각한다. 예를 들어, Arkin은 인간 군인 대신 기계가 우리를 위해 전쟁을 치르게 하는 것이 전쟁과 교전의 규칙을 일관되게 따르는 ‘윤리적 통치자’ 시스템을 기계에 장착한다면 전쟁범죄를 줄일 수 있다고 주장한다. 그러나 다른 사람들은 AI 기반 자율무기 시스템의 광범위한 가용성에 대해 우려하는데, 이는 그러한 시스템의 가용성이 사람들이 더 자주 전쟁에 나가도록 유혹할 수 있다고 생각하거나 전쟁의 윤리적, 법적 원칙을 해석하고 적용할 수 있는 AI 시스템의 가능성에 대해 회의적이기 때문이다. ‘킬러 로봇’이 해킹당할 수 있다는 우려도 있다.

마찬가지로, 많은 저자들은 교통안전 향상, 연료사용 효율향상, 교통환경의 조정 개선과 같은 자율주행 자동차의 이점을 인정하면서도 발생할 수 있는 사고에 대해서도 언급했다. 기본 아이디어는 자율주행 차량에 사람의 생명과 안전이 위태로운 사고 시나리오에 어떻게 대응해야 하는지 결정하는 데 도움이 되는 ‘윤리 설정’을 갖추어야 한다는 것이다. 이것은 우리 사회가 시급히 씨름해서 결정해야

9) 知的財産戦略本部, “次世代知財システム検討委員会報告書,” (2016년 4월).

할 기계윤리의 또 다른 실제 적용으로 간주된다.¹⁰⁾

AI 시스템이 적절하게 준비되지 않았을 수 있는 치명적인 사고에 자율주행 자동차가 연루될 수 있다는 우려는 비극적이게도 일부 사람들이 그러한 사고로 사망함에 따라 이미 실현되었다. 2016년 5월, ‘오토파일럿’ 모드의 테슬라 모델 S 차량인 자율주행차에 탑승한 차량운전자가 사망했다. 첫 번째 보행자는 2018년 3월 차량호출 회사인 우버(Uber)가 운영하는 실험용 자율주행차에 치여 사망했다. 후자의 경우 문제의 일부는 자동차의 AI 시스템이 경로에 갑자기 나타난 물체를 분류하는 데 어려움을 겪었다는 것이다. 처음에는 피해자를 ‘알 수 없음’으로, 그 다음에는 ‘차량’으로, 마지막으로 ‘자전거’로 분류했다. 충돌 직전에 시스템은 브레이크를 밟기로 결정했지만 그때는 너무 늦었다. 따라서 자동차의 AI 시스템이 제대로 작동하는지 여부는 삶과 죽음의 문제가 될 수 있다.

이러한 경우를 논의하는 철학자들은 제때 브레이크를 밟지 못하더라도 자동차가 한쪽으로 방향을 틀 수 있다고 제안할 수 있다. 하지만 차가 방향을 틀 수 있는 유일한 길에 다섯 사람이 있다면 어떨까? 또는 도로에 다섯 사람이 나타나고 한 사람이 차가 방향을 틀 수 있는 연석에 있다면 어떻게 될까? 이러한 시나리오에 이미 이 글의 앞에서 논의한 ‘트롤리 문제’와 유사하다. 선택은 다섯 명을 구하기 위해 한 사람을 죽이는 것을 포함하며, 문제는 어떤 종류의 상황에서 그 결정이 허용될 것인지 아닌지가 될 것이다. 학자들의 여러 연구논문에서 자율주행차와 관련된 충돌사고의 윤리와 트롤리 문제의 철학 사이의 유사점과 차이점에 대해 논의했다.¹¹⁾

자율 시스템에 대해 논의하는 윤리학자들이 직면한 한 가지 질문은 인간에게 해를 끼칠 수 있는 상황에서 어떤 윤리적 원칙이 의사결정 과정을 지배해야 하는가 하는 것이다. 이와 관련된 문제는 자율기계가 인간을 죽이거나 해치는 것이 과연 용인될 수 있는지, 특히 다른 방식으로 기계에 프로그래밍되거나 기계의 일부가 된 특정 원칙에 의해 통제되는 방식으로 그렇게 하는 경우 더욱 그렇다. 여기서 자율주행차로 인한 사망(일반적으로 매우 유감스럽지만 예측 가능한 부작용

10) 김자미, 김용, “인공지능 기술 딜레마를 기반으로 한 인공지능 윤리 교육에 대한 소고,” 한국 창의정보문화학회 창 의정보문화연구 8(2), (2022.5), 87-95면.

11) Chui, M., Manyika, J. and Miremadi, M., “Where Machines Could Replace Humans — and Where They Can’t (yet),” McKinsey Quarterly (2016).

으로 간주된다.)과 일부 사람들이 도덕적으로 용납할 수 없는 것으로 간주하는 자율주행 무기체계에 의한 사망을 구분한다. 심지어 노엘 샤키(Noel Sharkey)와 피터 아사로(Peter Asaro)와 같은 많은 AI 윤리학자들의 지지를 받는 ‘킬러 로봇을 막자’는 캠페인도 시작되었다.¹²⁾

캠페인이 제시하는 자율무기 시스템을 금지해야 한다고 주장하는 한 가지 이유는 그들이 ‘의미 있는 인간 통제’라고 부르는 것이 유지되어야 한다는 것이다. 이 개념은 자율주행 자동차와 관련해서도 논의된다. 많은 연구자들은 ‘책임 격차’를 만들 위험 또는 자율 AI 시스템에 의해 내려진 결정으로 인해 발생한 피해에 대해 누가 책임을 져야 하는지 불분명한 경우에 대해 우려해 왔다. 여기서 핵심 과제는 자율 시스템의 맥락에서 도덕적 책임을 이해하는 방법을 제시하는 것인데, 이를 통해 우리는 그러한 시스템의 이익을 확보하는 동시에 바람직하지 않은 결과에 대한 책임을 적절하게 귀속시킬 수 있다.

기계가 해를 끼치면 기계의 행동에 관련된 인간은 책임을 회피하려고 할 수 있다. 사실, 어떤 경우에는 기계가 한 일에 대해 사람들을 비난하는 것이 불공평해 보일 수 있다. 물론, 자율 시스템이 좋은 결과를 낳는다면, 일부 인간이 칭찬 받아 마땅하다고 주장하는 경우, 그 결과는 똑같이 불분명할 수 있다. 일반적으로 사람들은 자율 시스템이 낳은 나쁜 결과보다 좋은 결과에 대해 더 기꺼이 책임을 질 수 있다. 그러나 두 경우 모두 책임 공백이 발생할 수 있다. 따라서 철학자들은 좋은 나쁜든 기능적으로 자율적인 AI 기술이 생산한 결과에 대한 책임을 배분하는 방법에 대한 이론을 공식화할 필요가 있다.

3. 기계편견(bias)

많은 사람들은 스마트 기술을 사용하면 기계의 ‘중립성’ 때문에 인간의 편견이 사라질 것이라고 믿는다. 그러나 우리는 기계가 여성, 다른 민족, 노인, 의학적 장애가 있는 사람 또는 기타 그룹에 대한 인간의 편견을 유지하고 심지어 입증할 수 있다는 것을 깨닫게 되었다. 결과적으로 기계학습의 맥락에서 가장 시급한 질

12) 西田豊明, “人間力・社會力を強化する情報通信技術 人工知能を中心に,” 情報管理, Vol.57, No.8, pp.517-530 (2014).

문 중 하나는 기계편향을 피하는 방법이다.¹³⁾ 인간의 의사결정을 지원하기 위해 AI 시스템을 사용한다는 아이디어는 일반적으로 AI의 ‘의사결정 및 최상의 답변 찾기의 효율성, 정확성, 규모 및 속도 향상’을 고려할 때 훌륭한 목표이다. 그러나 기계편향은 긍정적으로 보이는 이 상황을 다양한 방식으로 훼손할 수 있다. 기계편향의 몇 가지 두드러진 사례는 (a) 고용의 성별 편견, (b) 특정 인종집단이 특정 유형의 직업만 제공한다는 점에서 인종적 편견, (c) 대출 신청자의 신용도에 대한 결정에서의 인종적 편견, (d) 가석방 수감자를 석방할지 여부를 결정할 때 인종적 편견, (e) 도시지역의 범죄활동을 예측하는 데 있어 인종적 편견, (f) 개인의 성적 지향을 식별할 때 성적 편견, (g) 밝은 피부색을 선호하는 안면인식 시스템의 인종적 편견, (h) 거주지의 지리적 위치를 민족 또는 사회경제적 지위의 대리물로 사용하는 인종 및 사회적 편견 등과 같은 사항이 제시되고 있다.¹⁴⁾

기계편향의 세 가지 이유는 (1) 데이터 편향, (2) 계산/알고리즘 편향, (3) 결과 편향이다. 첫째, 암시적 또는 명시적 불균형이 포함된 데이터를 사용하여 학습된 기계학습 시스템은 향후 의사결정과 관련하여 데이터의 왜곡을 강화하여 편향을 체계적으로 만든다. 둘째, 프로그램은 개발자의 암묵적 또는 명시적 편향으로 인해 알고리즘 편향으로 어려움을 겪을 수 있다. 프로그램의 설계는 프로그램의 영향을 받는 사용자 및 이해관계자를 포함하여 다른 사람들의 규범적 및 비규범적 가치에 대한 개발자의 이해에 의존한다. 셋째, 결과 편향은 예를 들어, 특정 도시지역의 범죄활동을 예측하기 위해 역사적 기록을 사용하는 것을 기반으로 할 수 있다. 이 시스템은 특정 지역에 더 많은 경찰을 배치하여 이전에는 눈에 띄지 않았던 신고 사례를 증가시킬 수 있다. 이 논리는 다른 도시지역에도 비슷하거나 더 많은 범죄가 있을 수 있지만 치안 부족으로 인해 보고되지 않는 범죄가 더 많음에도 불구하고 이 지역에 경찰을 배치하기로 한 AI 시스템의 결정을 입증할 것이다.

대부분의 AI 연구자, 프로그래머 및 개발자와 기술분야에서 일하는 학자들은 우리가 완전히 편향되지 않은 시스템을 설계할 수 없을 것이라고 믿는다. 따라서

13) 김중호, “인공지능 시대의 윤리와 법적 과제,” 한남대학교 과학기술법연구원 과학기술법연구 24(3), (2018.1), 155-205면.

14) 디비ッド·에드몬즈, “太った男を殺しますか? 「トリロ問題」が教えてくれること,” 太田出版 (2016).

기계의 편향을 줄이고 인간에 대한 해로운 영향을 최소화하는 데 중점을 둔다. 그럼에도 불구하고 여전히 여러 가지 의문이 남는다. 걸러낼 수 없는 편향 유형은 무엇이며, 남은 편향은 언제쯤 만족해야 할까? 법정에 선 사람이 인간적 편견 뿐만 아니라 기계적인 편견의 대상이 된다는 것, 그리고 두 가지 형태의 부당함이 그 사람의 형량을 결정하는 데 잠재적으로 도움이 된다는 것은 무엇을 의미하는가? 한 가지 유형의 편향만으로는 충분하지 않은가? 우리는 새로운 편견을 도입하는 대신 인간의 편견을 없애는 것을 목표로 삼아야 하지 않을까?

4. 불투명도의 문제

AI 시스템은 사람들의 삶에 큰 영향을 미치는 다양한 종류의 결정을 내리는 데 사용된다. AI는 누가 대출을 받는지, 누가 대학에 입학하는지, 누가 광고에 나오는 일자리를 얻는지, 누가 재범 가능성이 있는지 등을 결정하는 데 사용할 수 있다. 이러한 결정은 사람들에게 큰 영향을 미치기 때문에 우리는 그 근본적인 이유를 이해할 수 있어야 한다. 즉, AI와 AI의 의사결정은 설명 가능해야 한다. 실제로 AI의 윤리에 대해 논의하는 많은 연구자는 AI 의사결정의 수용 가능성에 대한 기본 윤리 기준으로 설명 가능성을 제안한다. 그러나 자율 AI 시스템이 내리는 많은 결정은 사람들이 쉽게 설명할 수 없다. 이것은 불투명도의 문제라고 불리게 되었다.

AI 의사결정의 불투명성은 관련 요인에 따라 다양한 종류가 될 수 있다. 일부 AI 결정은 그 결정의 이면에 있는 알고리즘이 이해하기 쉽지만 이를 사용하는 회사가 회사 외부의 누구와도 공유하고 싶지 않은 보호되는 영업비밀이기 때문에 영향을 받는 사람들에게 불투명하다. AI 불투명성의 또 다른 이유는 해당 기술에 대해 본질적으로 불투명한 것이 없더라도 대부분의 사람들이 AI 기반 시스템의 작동방식을 이해할 수 있는 기술의 전문지식이 부족하기 때문이다.¹⁵⁾ 일부 형태의 AI를 사용하면 전문가조차도 사용되는 의사결정 프로세스를 이해할 수 없다. Wachter, Mittelstadt and Russell 등은 이를 ‘블랙박스’ 문제라고 한다.

15) 김지연, “인공지능(AI)의 윤리적 지위: 인간과 비인간 사이에서 어울리기,” 한국이론사회학회 사회와 이론 46, (2023.11), 89-131면.

개인적 차원에서 기계가 왜 그런 결정을 내렸는지 불분명하거나 심지어 알 수 없는 경우, 삶의 중요한 측면에 대한 결정을 기계가 내리는 것은 개인의 존엄성과 자율성에 대한 모욕으로 보일 수 있다. 사회적 차원에서 알고리즘 의사결정의 중요성이 커지면서 민주적 절차에 위협이 될 수 있다. 헨리 키신저(Henry Kissinger) 전 미국 국무장관은 “우리는 지도 철학을 찾기 위해 지배적인 기술을 만들었음지도 모른다”고 말한 적이 있다. 존 다나허(John Danaher)는 이 생각에 대해 논평하면서, 사람들이 비의 춤이나 그와 유사한 행동을 통해 자연현상에 영향을 미칠 수 있다고 믿었던 이전 시대의 사람들처럼 미신적이고 비이성적인 방식으로 행동하도록 이끌릴지도 모른다고 우려한다. 다나허(Danaher)는 이러한 상황을 ‘알고크라시(algocracy)의 위협’ 즉, “우리가 이해하지 못하지만 복종해야 하는 알고리즘에 의한 지배의 위협”이라고 불렀다.¹⁶⁾

하지만 AI의 불투명성은 항상, 그리고 필연적으로 문제가 되는 것일까? 모든 상황에서 똑같이 문제가 있을까? AI가 모든 경우에 설명 가능해야 한다는 절대적인 요구사항이 있어야 할까? 스콧 로빈스(Scott Robbins)는 이 아이디어에 반대하는 흥미롭고 주목할 만한 주장을 제시했다. 로빈스는 무엇보다도 설명 가능성에 대한 엄격한 요구사항이 AI의 가능한 모든 이점을 누리는 데 방해가 될 수 있다고 주장한다. 예를 들어, 그는 AI 시스템이 우리가 설명하거나 이해할 수 없는 방식으로 어떤 형태의 암을 안정적으로 감지하거나 예측할 수 있다면, 정보를 아는 것의 가치가 AI 시스템이 어떻게 이러한 결론에 도달했는지 모르는 것에 대한 우려보다 더 클 것이라고 지적한다. 일반적으로 의사결정의 이면에 있는 절차가 그 자체로 중요한 상황과 결과의 질만 중요한 맥락을 구별할 수도 있다.¹⁷⁾

불투명성 문제에 대한 또 다른 유망한 대응책은 AI의 결정을 설명하는 대안적 모드를 구축하여 불투명성을 고려하면서도 사람들이 행동할 수 있는 어떤 형태의 설명을 제공하는 것이다. Sandra Wachter, Brent Mittelstadt, Chris Russell은 이러한 결정에 대한 ‘반사실적 설명’이라는 아이디어를 개발했으며, 이는 AI가 이해하지 못하는 결정에 합리적으로 대응하고자 하는 사람들에게 실용적인 지침

16) 江間有沙, 長倉克枝, “公開討論-人工知能學會倫理委員會,” 特集: 2016年度人工知能學會全國大會 (第30回), 人工知能, Vol.31, No.6 (2016).

17) Frey, C. B. and Osborne, M. A., “The Future of Employment: How Susceptible are Jobs to Computerization,” http://www.oxfordmartin.ox.ac.uk/downloads/academic/The_Future_of_Employment.pdf (2013).

을 제공하기 위해 고안되었다. 그들은 “사실에 반하는 설명은 AI에 의한 의사결정이 내부적으로 어떻게 이루어지는지 명확히 하려고 시도하지 않는다. 대신, 원하는 결과에 도달하기 위해 어떤 외부 사실이 다를 수 있는지에 대한 통찰력을 제공한다.” AI 의사결정을 설명하는 이러한 외부적이고 반사실적인 방법은 AI 의사결정이 매우 중요하지만 대부분 또는 모든 사람에게 불투명한 내부 논리에 따라 작동하는 경우에 유망한 대안이 될 수 있다.

5. 기계 의식

일부 연구자들은 기계가 점점 더 정교해지고 지능화되면 어느 시점에서 자발적으로 의식을 갖게 될 것이라고 생각한다(Russell). 과연 그럴까? 이것은 일종의 수수께끼가 될 수 있지만 윤리적 관점에서 볼 때 잠재적으로 매우 중요한 고급 AI 개발의 부작용이 될 수는 있다. 어떤 사람들은 의도적으로 인공의식을 가진 기계를 만들려고 한다. 성공한 엔지니어인 아사다 쿠니히로(Kunihiro Asada)는 쾌락과 고통을 경험할 수 있는 로봇을 만드는 것을 목표로 삼았는데, 이러한 로봇은 인간 아기가 언어를 습득하기 전에 할 수 있는 것과 같은 종류의 사전 언어 학습에 참여할 수 있다는 것을 기반으로 했다(Marchese). 또 다른 예로는 로봇 소피아가 있는데, 헨슨 로보틱스(Hanson Robotics)의 개발자들은 결국 ‘의식이 있고 살아있는 기계’가 될 ‘초지능의 자비로운 존재’를 만들고 싶다고 말한다.

조안나 브라이슨(Joanna Bryson)과 같은 다른 사람들은 우리가 의식을 어떻게 정의하느냐에 따라 일부 기계는 이미 어떤 형태의 의식을 가지고 있을 수 있다고 지적한다. Bryson은 의식을 내부 상태의 존재와 이러한 상태를 다른 에이전트에게 보고할 수 있는 능력을 의미한다면 일부 기계는 지금도 이러한 기준을 충족할 수 있다고 주장한다. 또한 Aida Elamrani-Raoult와 Roman Yampolskiy는 기계의식에 대한 21가지 가능한 테스트를 확인했다.

더욱이, 기계가 마음을 가질 수 있는지에 대한 문제에 대해서도 비슷한 주장이 제기될 수 있다.¹⁸⁾ 만약, 마음이 적어도 부분적으로는 기능적인 방식으로 외

18) 이희진, 이수빈, 김지연, “가상 인간의 프라이버시 침해 예방을 위한 인공지능 윤리 및 개인 정보보호법 동향 연구,” 한국통신학회 한국통신학회지(정보와 통신) 39(12), (2022.11), 8-12면.

부 환경으로부터 들어오는 입력의 내부 처리로서 그 환경에 대해 겉보기에 지능적인 반응을 일으킨다면, 기계는 마음을 소유할 수 있다(Nyholm). 물론, 기계가 어떤 의미에서 마음이나 의식을 가지고 있다고 말할 수 있다 하더라도, 그것들은 여전히 인간의 마음과 전혀 같지 않을 것이다. 결국, 어떤 존재의 특정한 의식과 주관성은 그 존재가 어떤 종류의 ‘하드웨어’(뇌, 감각기관, 신경계 등)를 가지고 있느냐에 달려 있다(Nagel).

일부 AI 기계가 이미 의식을 가지고 있다고 생각하든 그렇지 않든, (우연히 또는 설계로) 의식을 갖게 될 수 있다고 생각하든 그렇지 않든, 이 문제는 윤리적 논란의 핵심 원천이다. 예를 들어, 토마스 메칭거(Thomas Metzinger)는 사회가 인공지능 윤리의 기본원칙으로 고통을 줄 수 있는 기계를 만들지 말라는 규칙을 채택해야 한다고 주장한다. 그의 주장은 간단하다. 고통은 나쁘고, 고통을 야기하는 것은 부도덕하며, 따라서 고통받는 기계를 만드는 것은 부도덕하다. 조안나 브라이슨(Joanna Bryson)도 비슷한 주장을 하는데, 중요한 도덕적 지위를 가진 기계를 만드는 것은 가능하지만, 그렇게 하지 않는 것이 최선이다.¹⁹⁾ 그녀의 견해에 따르면, 우리는 우리가 의무를 저야 할 기계를 만들지 말아야 할 도덕적 의무가 있다. 다시 말하지만, 이것은 모두 우리가 의식으로 이해하는 것에 달려 있을 수 있다. 이에 에릭 슈비츠게벨(Eric Schwitzgebel)과 마라 가르자(Mara Garza)는 “사회가 더 정교한 인공지능을 발전시키는 방향으로 계속 나아가고 있다면, 좋은 의식이론을 개발하는 것은 도덕적 의무”라고 말한다.²⁰⁾

또 다른 흥미로운 관점은 니콜라스 아가(Nicholas Agar)에 의해 제공되는데, 그는 특정 첨단기계가 마음과 의식을 가지고 있을 가능성에 찬성하는 주장과 반대하는 주장이 모두 있다면, 우리는 조심하는 쪽에서 실수를 저지르고 기계가 마음을 가지고 있다는 가정을 전제로 진행해야 한다고 제안한다. 이를 바탕으로 우리는 그들에게 고통을 줄 수 있는 모든 행동을 피해야 한다. 대조적으로, 다나허(John Danaher)는 기계가 의식적인 경험을 가지고 있는지 여부에 대해 결코 확신할 수 없지만 이러한 불확실성은 중요하지 않다고 말한다. 만약, 기계가 도덕적

19) 松尾 豊, “人工知能 自動運転: ものづくりが変わる 日本の製造業に勝機あり,” エコノミスト (2015年 10月 6日号).

20) Gatys, L. A., Ecker, A. S. and Bethge, M., “A Neural Algorithm of Artistic Style,” arXiv preprint arXiv: 1508.06576 (2015).

지위를 가진 의식적 존재가 행동하는 방식과 비슷하게 행동한다면, 이것은 다나히의 ‘윤리적 행동주의’에 따르면, 우리가 의식이 있는 존재를 대하는 것과 동일한 도덕적 고려로 기계를 대하기에 충분한 도덕적 이유이다. 표준 접근법은 기계가 실제로 의식을 가지고 있는지 여부를 고려한 다음 이 답변이 기계에 도덕적 지위를 부여할지 여부에 대한 질문에 어떤 영향을 미쳐야 하는지 고려해야 한다.²¹⁾

6. 인공지능 기계의 도덕적 지위

전통적으로 도덕적 지위의 개념은 도덕적 지위를 가진 존재가 도덕적 공동체의 일부로 간주되고 도덕적 보호를 받을 자격이 있기 때문에 윤리와 도덕철학에서 가장 중요했다. 도덕적 공동체의 모든 구성원이 동일한 도덕적 지위를 갖는 것은 아니며, 따라서 도덕적 보호에 대한 주장과 관련하여 다르다. 예를 들어, 개와 고양이는 우리의 도덕적 공동체의 일부이지만, 일반적인 성인 인간과 같은 도덕적 지위를 누리지는 못한다. 어떤 존재가 도덕적 지위를 가진다면, 그 존재는 특정한 도덕적 (그리고 법적) 권리도 갖는다. 20세기에는 소수민족, 여성, LGBTQ+ 커뮤니티의 권리, 심지어 동물과 환경의 권리에 대한 인식이 높아졌다. 이 확장되는 도덕적 순환은 결국 인공지능 기계가 존재하게 되면 (로봇의 권리운동이 옹호하는 것처럼) 인공지능 기계를 포함하도록 더 성장할 수 있다.

인격의 개념은 (그것이 무엇을 의미하든 간에) 실체가 완전한 도덕적 지위를 가지고 있는지 여부와 도덕적 지위에 따라 완전한 도덕적 권리를 향유해야 하는지 여부를 결정하는 데 관련이 되었다. 도덕적 지위에 대한 한 가지 두드러진 정의는 캄(Frances Kamm)에 의해 제공되었다. 그래서 우리는 그 자체로 중요한 실체들의 부류에, 그들 자신의 권리와 그들 자신을 위해 우리에게 행동할 이유를 줄 수 있는 실체들이 있다는 것을 알 수 있다.

나는 사람들이 일반적으로 도덕적 지위를 실체에 귀속시킬 때 염두에 두는 것이 바로 이것이라고 생각한다. 그래서 이제부터 나는 어떤 실체가 그 자체로 도덕적으로 계산되는 것과 그것이 도덕적 지위를 갖는 것을 구별할 것이다. 나는

21) 이창규, “인공지능(AI) 기술의 윤리적·법적 관점에서의 談論,” 전남대학교 공익인권법센터 인권법평론 28, (2022.3), 233-270면.

어떤 실체가 그 자체의 권리와 그 자체를 위해, 그것을 파괴하거나 돕지 않는 것과 같은 일을 할 이유를 우리에게 줄 수 있을 때 도덕적 지위를 갖는다고 말할 것이다.²²⁾

캠(Frances Kamm)에 따르면, X가 의식이 있거나 고통을 느낄 수 있다면 X를 위해서도 할 수 있는 일들이 가능하다고 한다. 이 정의는 일반적으로 인간과 대부분의 동물을 포함하는 반면, 자연의 무생물 부분은 주로 의식이 부족하고 고통을 느낄 수 없다는 이유로 제외된다. 그러나 도덕적 추론과 의사결정의 범위를 환경까지 확대해야 하는 데에는 타당한 이유가 있다. 예를 들어, 그랜드 캐니언(Grand Canyon)은 인간의 의사결정에 도덕적 고려가 될 수 있는데, 그 독특한 형태와 뛰어난 미적 가치를 감안할 때, 비록 그것이 인격과 도덕적 지위가 결여되어 있음에도 불구하고 고려할 수 있다. 더욱이, 일부 전문가들은 유인원이나 코끼리와 같은 지각 있는 동물들이 인간이 아님에도 불구하고 인격체로 취급해 왔다.²³⁾

또한 우리는 (a) 사회적 상황에서 사용되는 현재의 로봇이나 (b) 인공지능 기체가 만들어졌을 때 인간의 도덕적 지위와 권리에 필적하는 도덕적 지위와 도덕적 권리를 가질 수 있는지에 대한 중요한 질문을 제기할 수 있다. 다음 세 가지 주요 접근방식은 토론에 대한 간략한 개요와 이해의 단초를 제공한다.

(1) 자율성 접근법

칸트와 그의 추종자들은 도덕적 지위와 권리의 맥락에서 자율성의 개념을 매우 강조한다. 도덕적인 사람은 이성적이고 자율적인 존재로 정의된다. 이러한 배경에서 인공지능 기체가 도덕적 결정을 내리는 데 있어 일정 수준의 자율성에 도달하면 인격을 부여할 수 있을 것이라는 제안이 있다. 현재의 기계는 점점 더 자율화되고 있으므로 이 도덕적 임계값을 충족하는 것은 시간 문제인 것 같다. 자율성에 기초한 기계에 도덕적 지위를 부여하는 것을 지지하는 칸트적 논증은 다음과 같이 구성될 수 있다.²⁴⁾

22) 松尾 豊ほか, “公開討論-人工知能學會倫理委員會,” 特集: 2015 年度人工知能學會全國大會 (第29回)), 人工知能, Vol.30, No.6, (2015), pp.754-755.

23) Bostrom, N., “Superintelligence,” Oxford University Press (2014).

이성적 행위자는 도덕적 요구에 따라 행동할 것인지(또는 행동하지 않을 것인지)를 결정할 수 있는 능력을 가지고 있다. 결정을 내리고 무엇이 좋은지 결정하는 능력은 절대적인 가치를 지닌다. 그러한 결정을 내릴 수 있는 능력은 이성적인 인간에게 절대적인 가치를 부여한다.

이성적 행위자는 도덕적 원칙에 따라 행동하는 것을 포함하여 자율적으로 행동할 수 있다. 이성적 행위자는 자율적으로 행동하는 한 존엄성을 갖는다. 자율적으로 행동하는 것은 사람을 도덕적으로 책임지게 만든다. 그러한 존재 즉, 이성적 행위자는 도덕적 인격을 갖는다.²⁵⁾

기계는 아무리 자율적이고 이성적이라 할지라도 인간이 아니므로 칸트적 추론 노선에 따라 도덕적 지위와 그에 수반되는 권리를 부여받아서는 안 된다는 반론이 제기될 수 있다. 그러나 칸트 자신이 그의 Groundwork에서 인간은 인간이기 때문이 아니라 자율적 행위자이기 때문에 도덕적 행위자로 간주되어야 한다고 분명히 말하고 있기 때문에 이러한 반론은 오해의 소지가 있다. 칸트는 그의 로고스 중심주의(logocentrism)에 대해 그의 반대자들에 의해 비판을 받아왔는데, 바로 이 주장이 그가 종차별주의(speciesism)의 더 심각한 반대 즉, 단순히 종 자체의 경험적 특징(인간의 경우, 특정 DNA) 때문에 특정 종이 도덕적으로 우월하다고 주장하는 것을 피하는 데 도움이 되었다. 그럼에도 불구하고 이것은 종 수준에서의 인종차별과 동등한 것으로 널리 여겨져 왔다.

(2) 간접의무 접근법

간접의무 접근법은 동물에 대한 우리의 행동에 대한 칸트의 분석에 기초한다. 일반적으로 칸트는 그의 윤리학 강의에서 인간이 동물에 대한 직접적인 의무를 가지고 있지 않다 하더라도 (인간이 아니기 때문에) 동물에 대한 간접적인 의무는 여전히 가지고 있다고 주장한다. 근본적인 이유는 인간이 동물을 학대하고 학대함으로써 나쁜 습관을 기르면 동료 인간을 나쁘게 대하기 시작할 수 있기 때문

24) Kurzweil, R., "The Singularity is Near," Duckworth Overlook (2005).

25) 우승하, 김재완, "인공지능 활용에 따른 법적 책임과 윤리에 관한 동향-인공지능 활용과 윤리인공지능의 비동조화인공지능의 민사책임," 충북대학교 법학연구소 과학기술과 법 12(1), (2021.1), 119-156면.

이다. 다시 말해, 동물을 학대하는 것은 인간의 성격에 해롭고 잔인한 영향을 미칠 수 있다.²⁶⁾

케이트 달링(Kate Darling)은 칸트적 논리를 적용하여 현재의 소셜 로봇도 도덕적, 법적 보호를 받을 자격이 있음을 보여주었다. 그녀는 로봇과 같이 인간과 상호작용하는 생명체와 같은 존재는 생명권이 없더라도 사회가 충분히 관심을 가질 때 보호해야 한다고 주장한다. 달링은 소셜 로봇을 이런 식으로 다루어야 하는 두 가지 주장을 제시한다. 그녀의 첫 번째 주장은 로봇에 대한 학대와 학대 사례를 목격한 사람들에게 관한 것으로, 그들이 ‘트라우마’에 빠지고 ‘둔감’해 질 수 있다고 지적한다. 둘째, 그녀는 로봇을 학대하는 것이 학대자의 성격에 해로운 영향을 미쳐 동료 인간을 나쁘게 대하기 시작할 수 있다고 주장한다.²⁷⁾

실제로, 현재의 소셜 로봇은 간접의무 접근법에 의해 가장 잘 보호될 수 있지만, 인간의 능력과 일치하거나 대체하는 더 정교한 미래의 로봇에도 정확히 동일한 주장이 적용되어야 한다는 생각은 다소 골치 아픈 일이다. 보통, 이러한 미래의 로봇은 오늘날의 달링의 사회적 로봇과는 달리 도덕적 환자일 뿐만 아니라 적절한 도덕적 행위자가 될 것이라고 기대할 수 있다. 또한 생명체와 같은 존재에 대해 ‘사회가 충분히 깊은 관심을 가질 때’ 보호해야 한다는 관점은 순전히 사람들이 그들을 도덕적 공동체의 구성원으로 받아들이지 않으려 한다는 이유로 사회적 배제의 문을 열어준다. 도덕적으로 말하자면, 이것은 용납될 수 없는 일이다. 다음 접근방식은 이 상황을 처리하려고 시도한다.

(3) 관계적 접근

도덕적 지위에 대한 관계적 접근의 선구자인 쿼켈버그(Mark Coeckelbergh)와 군켈(David Gunkel)은 로봇이 인간과의 사회적 관계에 따라 도덕적 지위를 갖는다고 믿는다. 즉, 도덕적 지위 또는 인격은 지각과 의식과 같은 존재에 내재된 기준에 의존하는 것이 아니라 인간과 로봇과 같은 서로 다른 개체 간의 사회적 관계를 통해 나타난다.²⁸⁾ 이 접근법의 이면에 있는 일반적인 아이디어는 다음 핵심

26) Orseau, L. and Armstrong, S., “Safely Interruptible Agents,” <https://intelligence.org/files/Interruptibility.pdf> (2016).

27) 松尾 豊ほか, “人工知能學會倫理委員會の取組み (アーティクル),” 人工知能, Vol.30, No.3, (2015), pp.358-364.

구절에서 전면에 등장한다.

우리는 로봇이 “기계”로 남을 것인지, 아니면 인간의 동반자가 될 수 있을지 궁금할 수 있다. 사람들이 “개를 만났다”고 말하는 경향이 있듯이 누군가가 “로봇을 만났다”고 말할 수 있다. 그런 사람이 로봇과 그런 관계를 맺고 있는데도 로봇 앞에서 부끄러움을 느끼겠는가? 그리고 개인적 참여의 관점에서 로봇의 “도덕적 지위”에 대해 여전히 이야기할 필요가 있는가? 도덕적 자질은 여기에서 나타난 바로 그 관계 속에 이미 함축되어 있지 않은가? 예를 들어, 노인이 이미 파로 로봇(Paro Robot)에 매우 애착을 가지고 있고 그것을 애완동물이나 아기로 간주한다면, 논의해야 할 것은 로봇의 “도덕적 지위”가 아니라 그 관계이다. 타자 즉, 로봇에 대한 개인적 경험은 이러한 관계적, 현상학적 접근의 핵심요소이다. 인격의 관계적 개념은 다음과 같은 방식으로 구체화될 수 있다.

자율성의 사회적 모델은 자율성은 개별적으로 정의되지 않고 사회적 관계의 맥락에 서 있다고 설명한다. 인격은 절대적이고 사회적 존재로서의 모든 실존적 개체에 선천적이다.²⁹⁾ 그것은 등급이나 정도로 오지 않는다. 인격의 상호작용주의적 모델로 존재하는 것이며, 인격은 본질적으로 관계적이며 (반드시 상호적이지는 않다.) 비인지주의적 용어로 정의된다.

위의 주장은 결정적인 논쟁의 단계가 아니다. 오히려, 그들은 사회적 관계의 도덕적 중요성에 관한 일반적인 추론 노선을 묘사한다. 관계형 접근방식은 로봇이 개별 개체로서 합리적이거나 지능적이거나 자율적일 것을 요구하지 않는다. 대신 로봇과의 사회적 만남이 도덕적으로 결정적이라고 이해한다. 로봇의 도덕적 지위는 바로 이러한 사회적 만남에 기초한다.

관계적 접근의 문제점은 로봇의 도덕적 지위가 로봇과 사회적 관계를 맺으려는 인간의 의지에 전적으로 의존한다는 점이다. 다른 말로 하자면, 인간이 (어떤 이유로든) 그러한 관계를 맺고 싶지 않다면, 그들은 합리성과 지각력과 같은 보다 객관적인 기준에 따라 로봇이 부여받을 수 있는 도덕적 지위를 로봇에게 부여하지 않을 수 있다. 따라서 관계형 접근방식은 실제로 로봇 권리에 대한 강력한

28) Barrat, J., “Our Final Invention, “Artificial Intelligence and the End of the Human Era.,” Thomas Dunne Books (2013).

29) 박도현, “인공지능 윤리의 두 가지 가치,” 중앙대학교 법학연구원 法學論文集 45(1), (2021.1), 89-118면.

기반을 제공하지 않는다. 오히려, 그것은 도덕적 공동체에서 (이미 도덕적 지위를 가진) 로봇을 더 쉽게 환영할 수 있는 실용적인 관점을 지지한다.

(4) 결과

위에서 논의된 세 가지 접근방식은 모두 로봇에게 도덕적 지위와 권리를 부여하는 개념을 어떻게 이해할 수 있는지 보여주려고 한다. 그러나 가장 중요한 관찰은 로봇이 관련 기준을 충족하면 우리의 의견과 무관하게 도덕적 지위와 권리를 가질 자격이 있다는 것이다. 인간이 실제로 자신의 지위와 권리를 인정할 것 인지는 다른 문제이다.

7. 특이점(Singularity)과 가치의 정렬(Value Alignment)

위에서 논의된 인공지능 에이전트(대리인)의 잠재적, 도덕적 지위에 대한 이론 중 일부는 일부 논자가 공상과학 소설에 속한다는 인상을 받았다. 다음으로 고려할 주제인 특이점에 대해서도 마찬가지이다. 기술적 특이점에 관한 근본적인 주장은 통계학자 어빈 굿(Irvin. J. Good)이 ‘최초의 초지능 기계에 관한 추측(Speculations Concerning the First Ultra-intelligent Machine)’에서 소개했다.³⁰⁾

초지능 기계란 아무리 영리한 사람의 모든 지적 활동을 훨씬 능가할 수 있는 기계로 정의되어야 한다. 기계의 설계는 이러한 지적 활동 중 하나이기 때문에 초지능 기계는 더 나은 기계를 설계할 수 있다. 그러면 의심할 여지 없이 “지능 폭발”이 일어날 것이며, 인간의 지능은 훨씬 뒤쳐질 것이다. 따라서 최초의 초지능 기계는 인간이 만들어야 할 마지막 발명품이다.

자가복제, 초지능 AI 기계와 관련된 지능의 폭발에 대한 아이디어는 많은 사람들에게 상상할 수 없는 것처럼 보인다. 일부 평론가들은 이러한 주장을 AI의 미래 발전에 대한 신화라고 일축한다(예: Floridi). 그러나 학계 안팎의 저명한 목소리는 이 생각을 매우 심각하게 받아들이고 있으며, 사실 그들은 인류 멸종의 위험과 같은 소위 ‘실존적 위험’의 가능한 결과를 두려워할 정도로 심각하게 받아

30) 伊庭齊志, “人工知能と人工生命の基礎,” オーム社 (2016).

들이고 있다. 그러한 두려움을 표명하는 사람들 중에는 닉 보스트롬(Nick Bostrom)과 토비 오드(Toby Ord)와 같은 철학자뿐만 아니라 일론 머스크(Elon Musk)와 고 스티븐 호킹(Stephen Hawking)과 같은 저명한 인물들도 있다.

기술적 특이점이라는 개념에 대해 논의하는 저자들은 무엇이 그것을 초래할 수 있는지에 대해 서로 다른 견해를 가지고 있다.³¹⁾ 유명한 미래학자 레이 커즈와일(Ray Kurzweil)은 ‘무어의 법칙(Moore’s law)’과 관련하여 기하급수적으로 증가하는 컴퓨팅 파워를 가진 특이점(singularity)의 아이디어를 옹호한 것으로 잘 알려져 있는데, 이 법칙은 이 글을 쓰는 시점에서 트랜지스터의 컴퓨팅 파워가 1970년대 이후 2년마다 두 배로 증가해 왔으며 앞으로도 계속 증가할 것으로 합리적으로 예상할 수 있다고 지적한다(Kurzweil). 이 접근법은 하드웨어의 지속적인 개선을 통해 초지능으로 가는 길이 진행될 가능성이 높다고 본다. 저명한 AI 연구자인 스튜어트 러셀(Stuart Russell)이 선호하는 초지능으로 이어질 수 있는 또 다른 방법은 알고리즘에 초점을 맞춘다. Russell의 관점에서 볼 때, 특이점이 발생하기 위해 필요한 것은 언어 및 상식적 처리의 연구, 학습과정과 같은 영역에서의 개념적 돌파구이다.

특이점에 관심이 있는 연구자들은 이러한 실존적 위협으로부터 인류를 보호하기 위해 무엇을 해야 하는지에 대한 문제에 여러 가지 다른 방식으로 접근하는데, 부분적으로는 이러한 실존적 위협이 무엇에 의존한다고 생각하는지에 따라 다르다. 예를 들어, 보스트롬은 초지능을 인공지능 시스템과 관련된 모든 목표를 달성할 수 있는 극도로 강력한 능력으로 구성된 것으로 이해한다.³²⁾ 많이 논의된 그의 예(Bostrom)에서 초지능 기계는 전 세계의 종이 클립(clip) 수를 최대화하는데 최적으로 효율적이 됨으로써 인간 삶의 미래를 위협하고 있으며, 이 목표는 종이 클립을 위한 더 많은 공간을 만들기 위해 인간을 제거함으로써 달성을 촉진할 수 있다. 이러한 관점에서 볼 때, 초지능 AI 기계에 올바른 목표를 부여하여 최대한 효율적인 방식으로 이러한 목표를 추구할 때 그 과정에서 인류를 멸종시킬 위험이 없도록 하는 것이 중요하다. 이것은 유익한 초지능을 만드는 방법에

31) Pistono, F. and Yampolskiy, R. V., “Unethical Research: How to Create a Malevolent Artificial Intelligence,” Proc. IJCAI 2016 Ethics for Artificial Intelligence Workshop (2016).

32) 김지영, 김지은, 김지은 외 1명, “디지털 전환 시대의 윤리경영: 빅데이터와 인공지능 기술을 중심으로,” 아태인문사회융합기술교류학회 아시아태평양융합연구교류논문지 9(3), (2023.3), 117-127면.

대해 생각하는 한 가지 방법이다.

러셀(Russell)은 AI 설계에 대한 세 가지 규칙을 공식화하여 대안적인 그림을 제시하는데, 이는 아시모프의 가상의 로봇공학 법칙의 업데이트된 버전이거나 제안된 대체물로 볼 수 있다.³³⁾

기계의 유일한 목표는 인간의 선호도를 극대화하는 것이다. 기계는 처음에 이러한 선호도가 무엇인지 확신하지 못한다. 인간의 선호도에 대한 정보의 궁극적인 출처는 인간의 행동이다. 이 글에서 논의되는 이론은 때때로 ‘가치정렬’ 즉, AI 시스템, 특히 초지능 미래 AI 시스템의 목표와 기능이 인간의 가치와 적절하게 정렬되어야 한다는 개념에 대한 다양한 아이디어를 나타낸다. AI는 인간의 이익과 가치를 추적해야 하며, 가치정렬의 이상에 따라 AI의 기능은 우리에게 이익이 되어야 하며 실존적 위협으로 이어지지 않아야 한다. 이 글의 시작 부분에서 언급했듯이 일부 평론가에게 AI가 초지능이 되어 실존적 위협을 가할 수 있다는 생각은 깨뜨려야 할 신화일 뿐이다. 그러나 토비 오드(Toby Ord)와 같은 사상가들에 따르면, AI는 인류의 미래가 위태로운 중요한 시기에 있는 주된 이유 중 하나라고 한다. 이러한 평가에 따르면, AI는 적절한 가치 조정이 이루어지지 않는 한 우리 모두를 큰 위험에 빠뜨릴 수 있는 핵무기 및 기타 잠재적으로 매우 파괴적인 기술과 동등하게 취급되어야 한다.³⁴⁾

가치정렬과 관련된 핵심문제는 특히 러셀(Russell)의 세 가지 원칙에 따라 이해된다면, AI가 누구의 가치나 선호도에 부합해야 하는가 하는 것이다. 가브리엘(Iason Gabriel)이 지적했듯이 합리적인 사람들은 AI의 기능(초지능 여부)을 조정하는 데 적합한 가치와 이익이 무엇인지에 대해 동의하지 않을 수 있다. 이 문제를 해결하기 위한 가브리엘의 제안은 존 롤스(John Rawls)의 ‘합리적 다원주의’에 대한 연구에서 영감을 받았다. 롤스는 사회구성원들 사이에 가치에 대한 보다 구체적이고 합리적인 의견 차이가 존재함에도 불구하고 중첩되는 합의 또는 광범위한 합의를 도출할 수 있는 ‘공정한 원칙’을 찾기 위해 노력해야 한다고 제안한다. 그러나 일반원칙에 대한 이러한 종류의 수렴이 광범위한 지지를 받을 가능성은 얼마나 될까?

33) Russell, S., Dewey, D. and Tegmark, M., “Research Priorities for Robust and Beneficial Artificial Intelligence,” AI Magazine, Winter (2015).

34) 젤러리·카플란, “人間さまお斷り—人工知能時代の經濟と勞働の手引,” 三省堂 (2016).

8. 다른 논쟁들

위에서 강조한 주제 외에도 AI 윤리 내에서 그다지 주목받지 못한 다른 문제가 논의되기 시작했다. 이러한 다섯 가지 문제를 아래에서 간략하게 논의하기로 한다.

(1) 도덕적 향상 또는 도덕적 조언자의 한 형태로서의 AI

AI 시스템은 온라인 쇼핑, 온라인 엔터테인먼트(예: 음악 및 영화 스트리밍) 및 기타 영역에서 ‘추천 시스템’으로 사용되는 경향이 있다. 일부 윤리학자들은 AI 시스템의 장점과 단점에 대해 논의했으며, AI 시스템의 권장사항은 우리가 더 나은 선택을 하고 우리의 기본가치와 더 일치하는 선택을 하는 데 도움이 될 수 있다. 어쩌면 AI 시스템은 언젠가 우리의 가치를 개선하는 데 도움이 될 수도 있다. 이러한 질문 및 관련 질문에 대한 연구에 참여한 학자는 Borenstein 및 Arkin, Giubilini et al., Klincewicz 및 O'Neill et al.이 포함된다.

(2) AI 및 일(Work)의 미래

AI와 일의 미래에 대한 많은 논의는 AI와 다른 형태의 자동화가 구축된 기계가 대체할 많은 수의 인간 일자리를 제거함으로써 광범위한 ‘기술실업’을 야기할 것인지에 대한 중요한 문제와 관련이 있다(Danaher). 이것은 종종 부정적인 전망으로 제시되는데, 여기서 문제는 노동이 없는 세상이 사람들에게 성취감과 의미 있는 활동에 대한 전망을 어떻게 제공하는지, 그리고 어떻게 할 것인가 하는 것인데 왜냐하면, 노동을 통해 취득한 특정 재화(소득 제외)는 다른 맥락에서 달성하기 어렵기 때문이다(Gheaus and Herzog). 그러나 일부 학자들은 현대사회의 노동이 많은 사람들을 다양한 종류의 피해에 노출시킨다고 주장했다(Anderson). 다나허(Danaher)는 일자리가 적은 세상이 실제로 더 나은지에 대한 중요한 질문을 조사한다. 어떤 사람들은 기계가 인간을 대체했기 때문에 인간이 더 이상 일(또는 삶)에서 의미 있는 목적을 찾을 수 없다면 실존적 지루함이 확산될 것이라

고 주장한다(Bloch). 이와는 대조적으로, 요나스(Jonas)는 블로흐(Bloch)를 비판하면서, 지루함은 전혀 실질적인 문제가 되지 않을 것이라고 주장하기도 한다. 또 다른 관련 문제는 아마도 단기 및 중기적으로 더 관련성이 높을 수 있는 점점 더 기술화된 작업을 의미 있게 유지하는 방법이다(Smids et al.).

(3) AI 그리고 대인관계의 미래

다양한 AI 기반 기술은 우정, 로맨스 및 기타 대인 관계의 본질에 영향을 미치며 미래에는 더 큰 영향을 미칠 수 있다. 소셜미디어를 통해 형성된 온라인 ‘우정’은 인공지능 알고리즘에 의해 부분적으로 큐레이팅된 관계가 진정한 우정이 될 수 있는지에 대해 의견이 분분한 철학자들이 조사하고 연구하였다. 일부 철학자들은 AI 기반 데이트 앱이 부정적인 고정관념과 부정적인 성별 기대를 강화할 수 있다고 신랄하게 비판했다(Frank and Klinecicz). 공상과학 소설과 같은 기술철학은 현실 생활에 점점 더 많이 존재할 수 있지만, 인간이 첨단 AI를 갖춘 로봇 및 기타 인공 대리인과 진정한 우정이나 낭만적인 관계를 가질 수 있는지에 대한 논의도 있었다.

(4) AI 그리고 인간의 ‘연약함’에 대한 우려

우리 삶의 점점 더 많은 측면이 AI 시스템의 권장사항에 의해 주도된다면 (우리는 AI 시스템의 기능을 이해하지 못하고 기능의 적절성에 의문을 제기할 수 있기 때문에) 그 결과는 ‘도덕적 선택의지의 위기’(Danaher), 인간의 ‘약화’(Russell) 또는 인간 삶의 다양한 영역에서의 ‘탈숙련’(Vallor)으로 이어 질 수 있다. 이 시나리오는 기술적 특이점이 달성될 경우 더욱 가능성이 높아지는데, 그 시점에서 모든 연구와 엔지니어링을 포함한 모든 작업이 지능형 기계에 의해 수행될 수 있기 때문이다. 몇 세대가 지나면 인간은 삶의 모든 영역에서 기계에 완전히 의존하고 시계를 되돌릴 수 없게 될 것이다. 이 상황은 매우 위험하다. 따라서 인간이 AI 능력을 개발하는 동안 숙련되고 지식을 유지하는 것이 가장 중요하다.

(5) 의인화

인간의 사고와 행동을 모방하는 인공지능 기계라는 개념 자체가 일부에 따르면 피해야 할 의인화의 한 형태를 포함할 수 있다. 다시 말해, 인간이 아닌 기계에 인간과 같은 특성을 부여하는 것은 문제가 될 수 있다. 다양한 형태의 AI 기술(또는 일반 대중에게 제공되는 방식)에 대한 일반적인 걱정은 기만적이라는 것이다.³⁵⁾ 많은 사람들은 기업들이 자사제품이 AI 기술을 기반으로 하는 정도를 과장하는 경향이 있다고 반대했다. 예를 들어, Sharkey와 Bryson 같은 몇몇 저명한 인공지능 연구자들과 윤리학자들은 소피아 로봇의 제작자들이 소피아를 실제로 다 훨씬 더 인간처럼 묘사하고 있다고 비판했다. 그리고 어쩐지 문제가 있거나 부적합한 인간의 의인화 반응을 촉구하도록 설계되었다. 인공지능 기술에 대한 의인화된 반응이 항상 문제가 되는지에 대한 관련 질문은 더 많은 고려가 필요하며, 이는 점점 더 많이 받아들여지고 있다.³⁶⁾

AI 윤리분야에서 새롭게 떠오르는 이 주제 목록은 이 분야가 매우 비옥하고 새로운 문제가 지속적으로 발생하기 때문에 완전하지 않다. 이것은 아마도 윤리 및 도덕철학 연구에서 가장 빠르게 성장하는 분야일 것이다.

III. AI 윤리지침

AI와 관련된 윤리적 문제에 대한 인식과 관심이 확산됨에 따라 여러 영향력 있는 기관(정부, 유럽 연합, 대기업 및 기타 협회를 포함한다.)은 이미 전문가 패널에게 AI에 대한 정책문서 및 윤리지침의 초안을 작성하는 임무를 맡겼다. 이러한 문서는 발표되는 모든 최신 AI 윤리지침을 추적하기가 매우 어려울 정도로 확산되었다. 또한 AI 윤리는 다양한 공공 및 민간 출처로부터 상당한 자금을 지원받고 있으며 AI 윤리를 위한 여러 연구센터가 설립되었다. 이러한 발전은 대부분 긍정적인 반응을 얻었지만, 소위 ‘윤리세탁’ 즉, 더 비판적인 관점에서 윤리적

35) Song, J., “Addressing Sustainability via AI — Report from the 23rd Int’l Joint Conf. on Artificial Intelligence,” Bulletin of the Chinese Academy of Sciences, Vol. 27 (2013).

36) 井上智洋, “人工知能と経済の未来 2030 年雇用大崩壊,” 文藝春秋 (2016).

으로 문제가 될 수 있는 것에 윤리적 승인 도장을 찍는 것에 대한 우려와 일부 노력이 상대적으로 이빨이 없거나 서구에 너무 집중될 수 있다는 우려도 있었다. AI 윤리에 대한 비서구적 관점을 무시한 결과이다. 이 글에서는 이러한 비판을 논의하기 전에 이미 발표된 윤리지침의 예를 검토하고 이러한 서로 다른 지침 간에 합의가 이루어질 수 있는지 여부를 고려한다.

이러한 맥락에서 훌륭한 자료는 조빈(Jobin et al.) 등이 제시한 개요로 그는 여러 국가의 정부 또는 국제기관에서 발행한 84개의 윤리지침에 대한 실질적인 비교검토를 수행했다. Jobin et al.은 투명성, 정의 및 공정성, 악의 없음, 책임, 개인정보보호라는 다섯 가지 핵심원칙을 중심으로 강력한 수렴을 발견했다. 그들의 발견은 원래 논문에서 논의된 원칙의 일부(전부는 아님)에 대한 이러한 수렴의 정도를 설명하기 위해 이 글에 인용한 내용을 보고하였다. 아래 표에서 왼쪽의 두 번째 열의 숫자는 조사 대상 84개 문서 중 특정 원칙이 두드러지게 등장하는 윤리지침 문서의 수를 나타낸다. Jobin et al.이 사용한 코드는 독자가 분류의 기초를 볼 수 있도록 포함되어 있다.

윤리 원칙	문서 수 (N = 84)	포함된 코드
투명성	73	투명성, 설명 가능성, 이해 가능성, 해석 가능성, 커뮤니케이션, 공개
정의와 공평	68	정의, 공정성, 일관성, 포용성, 평등, 형평성, (비)편견, (비)차별, 다양성, 다수성, 접근성, 가역성, 구제, 도전, 접근, 분배
비악의적	60	비악의, 보안, 안전, 위해, 보호, 예방, 무결성(신체적 또는 정신적), 전복 방지
책임	60	책임, 의무, 성실한 행동
사생활	47	개인정보
선행	41	혜택, 선행, 복지, 평화, 사회적 선, 공동선
자유와 자율성	34	자유, 자율성, 동의, 선택, 자기 결정권, 권한 부여
신뢰	28	신뢰
지속 가능성	14	지속가능경영, 환경(자연), 에너지, 자원(에너지)
존엄	13	존엄
연대	6	연대, 사회보장, 결속

Jobin et al.이 수행한 검토는 적어도 목록의 처음 5가지 원칙과 관련하여 AI에 대한 윤리적 지침을 만들려는 이러한 시도에서 상당한 수준의 중복을 보여준다. 반면에, 목록의 마지막 6개 항목(선행으로 시작)은 연구된 문서의 절반 미만에서 핵심원칙으로 나타났다. 이와 관련하여, 다양한 충돌 딜레마 시나리오에서 자율주행차가 무엇을 하도록 프로그래밍해야 하는지에 대한 사람들의 태도를 조사한 ‘도덕적 기계’ 연구 프로젝트에 참여한 연구자들도 문화 간 다양성을 포함하여 큰 차이를 발견했다.³⁷⁾

이러한 윤리지침은 내용과 제작방법 측면에서 상당한 비판을 받았다(Metzinger). 메칭거에게 ‘신뢰할 수 있는 AI’라는 개념 자체가 ‘넌센스’인데, 기계가 아닌 인간만이 신뢰할 수 있거나 그렇지 않기 때문이다. 더욱이 유럽연합의 AI 고위급 전문가 그룹에는 윤리분야의 전문가는 거의 없었지만 AI 산업에 대한 윤리적 우려를 해소하는 데 관심이 있는 업계 대표가 다수 포함됐다. 또한 EU 문서 ‘신뢰할 수 있는 AI를 위한 윤리지침’은 모호하고 비대립적인 언어를 사용한다. Resseguier와 Rodrigues가 선호하는 용어를 사용하자면, 대부분 ‘이빨이 없는’ 문서이다. 업계 대표들이 이빨을 드러내지 않은 것으로 추정되는 EU 윤리지침은 ‘윤리적 세탁’ 가능성에 대해 제기된 우려를 잘 보여준다.

이러한 종류의 윤리지침에 대한 또 다른 비판은 지침의 초안을 작성하는 많은 전문가 패널이 포괄적이지 않으며 AI와 윤리에 대한 비서구(예: 아프리카 및 아시아)의 관점을 고려하지 않는다는 것이다. 그러므로, 그러한 지침의 향후 버전이나 새로운 윤리지침에는 비서구의 기여를 포함하는 것이 중요할 것이다. 특히, 기술윤리에 초점을 맞춘 학술저널에서는 다오(DAO), 유교적 덕-윤리 관점, 인격 및 대인관계에 대한 ‘우분투’ 철학을 포함한 남부 아프리카의 관계 및 공동체 윤리 관점을 적용하는 등 AI 윤리에 대한 비서구적 관점을 공표하는 데 약간의 진전이 있었다.

37) 若田部昌澄, “經濟學者は人工知能の夢を見るか: 第2次機械時代の經濟社會構想,” 總務省 ICT インテリジェント化影響評価検討會議 (2016年 2月 2日).

IV. 맺음말

AI의 윤리는 이제 기술철학에서 가장 활발한 논의주제 중 하나가 되었다. AI는 우리의 전통적인 도덕개념, 윤리적 접근방식 및 도덕이론을 재정의할 수 있는 잠재력을 가지고 있다. 인간의 능력과 동등하거나 대체할 수 있는 인공지능 기계의 출현은 세계에서 가장 높은 도덕적 지위를 가진 유일한 존재로서의 인류의 전통적인 자기이해에 큰 도전을 제기한다. 따라서 AI 윤리의 미래는 예측할 수 없지만 상당한 흥분과 놀라움을 선사할 것이다.

자율주행차와 알고리즘 거래, 임상판단 지원 시스템, 데이터 마이닝 등 다양한 장면에서 사용되는 인공지능(AI)의 열쇠를 잡는 것은 빅데이터와 기계학습. AI의 발전에는 대용량 데이터의 이용이 필수적인 조건이다. 따라서 디지털 플랫폼과 도구가 전례 없는 규모로 활용되는 인도, 중국, 미국, 브라질 등의 거대한 인구와 비즈니스 부문은 인공지능의 혜택을 누릴 것이다. 또한 디지털 세계에 사용자가 남기는 행동 흔적에서 수집한 정보에 이용 제한이 없는 것도 큰 이점이 된다. 또한 인도에서는 생체인증 토큰시스템의 도입과 고액지폐의 폐지, 물품·서비스제도의 통합 등 국내 경제의 디지털화가 진행되고 있다.

한편, 페이스북이나 케임브리지 애널리티카의 개인정보 부정 이용으로 윤리적 배려라는 문제가 부각되었다. 그러나 이것은 단지 문제의 일부일 뿐이다. 인공지능의 이용은 머신러닝 지원과 우리의 업무를 대행하기 위해 과거에 대용량의 데이터 처리를 수반하며, 기업은 정보의 취급에 점점 신중해질 것이 요구되고 있다. 사고가 폭넓게 보도된 테슬라와 우버는 자율주행차 개발사업을 축소했다. AI의 이용에는 어떤 윤리와 책임이 수반되어야 할까? 국제적인 기준이 존재하지 않는 가운데 어떻게 그러한 책임의식을 높여 나갈 수 있을까?

현재 시점에서 AI와 그 기술의 적용에는 명확한 윤리규정이 없기 때문에, 기업은 어떻게 그 위험을 회피하는지를 내외의 이해관계자와 검토할 수밖에 없다. 여기서 <의무론>과 <목적론>에서 윤리기준을 비교해 보기로 하자. 전자는 의도와 수단, 후자는 목적과 결과가 중요시된다. 자율주행차의 경우, 환경에 배려한 무사고 수송 시스템이 목적이라면, 다양한 운전상황을 상정한 대규모의 데이터 수집이나, AI의 실용시험은 충분한 정당성을 가지고 있다. 대조적으로, 임상적 개

입이나 임상시험은 목적론으로 정당화될 수 없다. 바쁜 인체실험의 역사를 감안하면 기업이나 AI 연구자는 오히려 의도와 수단을 근거로 한 의무론의 관점에서 자신들의 활동의 윤리성을 판단하는 것이 타당하다.

타인으로부터 자신에게 받고 싶은 행위를 사람에게 행하는 것을 설교하는, 이른바 황금률도 윤리의 기준의 하나이다. 다만, 개인정보가 수집·분석되는 측의 사람들과 잠재적으로 혜택을 받는 사람들 사이에는 의견이 큰 간격이 있으므로 급성장하는 AI 분야에는 쉽게 적용할 수 없다. 즉, 데이터 수집의 행위 자체에는 황금률을 직접 적용할 수 없다.

다음으로 <문화상대주의>와 <보편주의>의 차이로부터 윤리기준을 검토해 보자. 전자는 특정 문화의 가치관과 규범, 후자는 상호합의한 기준이 윤리적인 행위의 근거가 된다. 정보기밀의 사고방식이 유럽과 미국에서 대립하고, 구글이나 페이스북과 같은 기업의 시장세력도에 영향을 주고 있는 것은, 이 비교로부터 설명할 수 있을 것이다. 중국이나 인도 등 신흥시장이 내세우는 기본이념은 문화상대주의. 기술입국으로서의 발전을 방해하는 규제를 회피하는 것으로 유리한 상황을 확보하려고 하는 것이다.

1980년대 이후의 기술기준과 같이 윤리기준도 세계 시장세력도 형성에 중요한 역할을 할 것이다. AI 데이터의 이해와 필요가 있는 이상, 기업은 활동과 목적의 세부사항까지 윤리적 책임이 묻는다. AI의 이용이 글로벌화되는 가운데 우리는 윤리가 가진 역할에 주목하고 있다. 경제계나 사회의 대응이 디지털 사회에서의 AI 이용을 결정한다고 해도 과언이 아니다.

한편, AI가 윤리적인 역할을 하기 위해서는 예측 가능성과 신뢰성이라는 두 가지 관련 측면이 중요하다. AI가 대응할 수 없는 설명책임이나 데이터의 사용허가 등의 복잡한 문제에 미리 대처해 두는 것은 AI 분야에 대한 투자촉진으로 이어질 것이다. AI의 발전에는 그 기술과 영향, 데이터 이용에 대한 소비자의 신뢰도 필요하며, 이 신뢰를 높이는 것은 예측 가능하고 투명한 대응이다.

인지기능을 갖춘 기계는 사고, 이해, 학습, 문제해결, 의사결정 등이 고급 프로세스를 실행할 수 있다. AI를 활용함으로써 인간의 지능을 보완하고 경제와 정부의 활동을 발전시킬 것으로 기대된다. 그러나 인지기능이 있고 AI를 갖춘 기계의 개발에는 윤리적인 문제가 수반된다. 인지기능을 가진 기계가 독립적으로 의사결정을 내리는 의미는 무엇인가? 라는 문제이다. 이러한 문제는 복잡하고 날마다

변화하기 때문에, 확고한 법적 틀에서의 대응이 필요하지만, 정치나 법률만으로는 불충분하다. 신뢰성을 높이기 위해서는 윤리규정도 마찬가지로 중요하다.³⁸⁾

정부는 AI의 윤리에 대해 모든 당사자를 끌어들여 논의를 진행시켜 나가야 한다. 민간부문, 소비자 단체, 학술계를 끌어들여 기술적, 사회적, 정치적 발전에 호응한 윤리규정을 수립할 수 있을 것이다. 또 정부는 기존의 대처와 연계하여 AI의 윤리를 연구하고 논의해 나가야 한다. 이러한 이니셔티브는 많이 존재한다. 예를 들어, 앨런 튜링 연구소, 미래의 인텔리전스를 위한 레버폼 센터, 세계경제포럼 제4차 산업혁명센터, 왕립협회, “사람들과 사회에 공헌하는 인공지능을 위한 파트너십”이 진행하는 이니셔티브이다. 그러나 이러한 이니셔티브에도 윤리적 문제가 수반된다.

● 의사결정 및 책임: AI의 이용이 늘어나면 의사결정의 책임분배가 보다 어려워진다. 잘못된 결정이 손해를 입을 경우, 누가 그 위험을 요구해야 하는가?

● 투명성: 복잡한 기계학습 시스템을 사용하여 중요한 의사결정을 내리는 경우 특정 행동에 숨어있는 문제의 원인을 해결하는 것은 어렵다. 책임을 완수하기 위해서는 기계가 내는 추론에 대해 명확한 설명이 필요하다.

● 편견: 기계학습 시스템은 의사결정 시스템의 기존 경향을 우선 할 수 있으며 AI가 중립적으로 발전할 수 있도록 고려해야 한다.

● 인간의 가치관: AI 시스템은 프로그래밍에 의해 가치관과 상식이 설정된다. 로봇과 로봇 시스템의 윤리적인 디자인과 응용에 관한 영국표준협회의 표준 BS 8611은 “로봇은 인간을 죽이거나 상처를 입히는 것을 단일 또는 주요 목적으로 설계해서는 안 된다. 하지만 인간이 그 책임 주체이다. 모든 로봇과 그 행동에 대해 책임자를 찾을 수 있도록 해야 한다.”고 제시하고 있다.

● 데이터 보호 및 지적재산: AI의 잠재성은 대용량 데이터 세트에 대한 액세스가 결정적인 방법이다. 단일 데이터 세트로 AI 시스템을 구축한 후, 해당

38) 김경동, “새로운 노멀, 인공지능(AI)과 윤리규범에 관한 소고,” 한국법학회 법학연구 23(2), (2023.6), 25-50면; 김중호, “인공지능 로봇의 출현으로 인한 법적 논란에 관한 영역별 쟁점의 고찰,” (사)한국법이론실무학회 법이론실무연구 6(2), (2018.5), 225-263면; 김중호, “가상화폐와 핀테크 산업의 발전에 따른 금융기관의 대응방향-일본의 경험을 중심으로” 한국법학회 법학연구 18(1), (2018.3), 211-245면.

시스템에서 새로운 데이터 세트를 학습하면 어떻게 될까?

책임있는 AI는 도덕적 원칙과 윤리적 가치를 고려하여 인간의 기본 윤리관과 모순되지 않는지 확인해야 한다. AI를 비윤리적으로 사용한 기업에 대한 신고가 진행되는 가운데 아마존, 구글, 페이스북, IBM, 마이크로소프트는 인공지능기술의 모범사례 창출, 시민의 이해추진, 인공지능에 관한 플랫폼 기능을 목적 비영리 파트너십을 형성한다. 이러한 활동들이 인공지능 윤리의 기준을 설정하는데 도움이 될 것으로 생각한다. 널리 교류하고 공통의 접점을 늘려가면서 보편타당한 윤리 기준을 설정하기를 기대한다.

《참 고 문 헌》

1. 국내문헌

- 김경동, “새로운 노멀, 인공지능(AI)과 윤리규범에 관한 소고,” 한국법학회 법학연구 23(2), 2023.6, 25-50면.
- 김명호, “인공지능, 창작을 하다: 데이터 수집과 윤리,” 한국과학기술기획평가원 KISTEP InI, 2023.4, 84-87면.
- 김자미, 김 용, “인공지능 기술 딜레마를 기반으로 한 인공지능 윤리 교육에 대한 소고,” 한국창의정보문화학회 창의정보문화연구 8(2), 2022.5, 87-95면.
- 김종호, “인공지능 시대의 윤리와 법적 과제,” 한남대학교 과학기술법연구원 과학기술법연구 24(3), 2018.), 155-205면.
- , “인공지능 로봇의 출현으로 인한 법적 논란에 관한 영역별 쟁점의 고찰”, (사)한국법이론실무학회 법이론실무연구 6(2), 2018.5, 225-263면.
- , “가상화폐와 핀테크 산업의 발전에 따른 금융기관의 대응방향 -일본의 경험을 중심으로”, 한국법학회 법학연구 18(1), 2018.3, 211-245면.
- 김지연, “인공지능(AI)의 윤리적 지위: 인간과 비인간 사이에서 어울리기,” 한국이론사회학회 사회와 이론 46, 2023.11, 89-131면.
- 김지영, 김지은, 김지은 외 1명, “디지털 전환 시대의 윤리경영: 빅데이터와 인공지능 기술을 중심으로,” 아태인문사회융합기술교류학회 아시아태평양융합연구교류논문지 9(3), 2023.3, 117-127면.
- 박도현, “인공지능 윤리의 두 가지 가치,” 중앙대학교 법학연구원 法學論文集 45(1), 2021.1, 89-118면.
- 배재권, “비즈니스 영역에서 인공지능 기술의 활용과 인공지능 윤리,” 한국지식정보기술학회 한국지식정보기술학회 논문지 17(6), 2022.12, 1,341-1,352면.
- 우승하, 김제완, “인공지능 활용에 따른 법적 책임과 윤리에 관한 동향-인공지능 활용과 윤리인공지능의 비동조화인공지능의 민사책임,” 충북대학교 법학연구소 과학기술과 법 12(1), 2021.1, 119-156면.
- 이창규, “인공지능(AI) 기술의 윤리적·법적 관점에서의 談論,” 전남대학교 공익

인권법센터 인권법평론 28, 2022.3, 233-270면.

이희진, 이수빈, 김지연, “가상 인간의 프라이버시 침해 예방을 위한 인공지능 윤리 및 개인정보보호법 동향 연구,” 한국통신학회 한국통신학회지(정보와 통신) 39(12), 2022.11, 8-12면.

전 준, “생성형 인공지능 기반 사회과학연구에 대한 윤리인식 연구,” 한국사회학회 한국사회학회 사회학대회 논문집, 2023.8, 64-64면.

하진봉, “도덕과 인공지능 윤리교육에 대한 도덕심리학적 이해,” 한국윤리학회(윤리학) 윤리연구 1(141), 2023.6, 229-249면.

2. 외국문헌

Amodei, D., et al., “Concrete Problems in AI Safety,” arXiv: 1606.06565 (2016).

Barrat, J., “Our Final Invention, Artificial Intelligence and the End of the Human Era.,” Thomas Dunne Books (2013).

Bostrom, N., “Superintelligence,” Oxford University Press (2014).

Chui, M., Manyika, J. and Miremadi, M., “Where machines could replace humans — and where they can’t (yet),” McKinsey Quarterly (2016).

Frey, C. B. and Osborne, M. A., “The Future of Employment: How Susceptible are Jobs to Computerization,” http://www.oxfordmartin.ox.ac.uk/downloads/academic/The_Future_of_Employment.pdf (2013).

Gatys, L. A., Ecker, A. S. and Bethge, M., “A Neural Algorithm of Artistic Style,” arXiv preprint arXiv:1508.06576 (2015).

Kurzweil, R., “The Singularity is Near,” Duckworth Overlook (2005).

Orseau, L. and Armstrong, S., “Safely Interruptible Agents,” <https://intelligence.org/files/Interruptibility.pdf> (2016).

Pistono, F. and Yampolskiy, R. V., “Unethical research: How to create a malevolent artificial intelligence,” Proc. IJCAI 2016 Ethics for Artificial Intelligence Workshop (2016).

Russell, S., Dewey, D. and Tegmark, M., “Research priorities for robust and beneficial artificial intelligence,” AI Magazine, winter (2015).

- Song, J., “Addressing sustainability via AI — Report from the 23rd International Joint Conf. on Artificial Intelligence,” Bulletin of the Chinese Academy of Sciences, Vol. 27 (2013).
- Walsh, T., “The singularity may never be near,” Proc. IJCAI-2016 Ethics for Artificial Intelligence Workshop (2016).
- 知的財産戦略本部, “次世代知財システム検討委員会報告書,” (2016年 4月).
- ディビッド・エドモンズ, “太った男を殺しますか? 「トロリ問題」が教えてくれること,” 太田出版 (2016).
- 江間有沙, 長倉克枝, “公開討論「人工知能學會倫理委員會,” (特集 2016 年度人工知能學會全國大會 (第30回), 人工知能, Vol.31, No.6 (2016).
- 伊庭齊志, “人工知能と人工生命の基礎,” オーム社 (2016).
- 井上智洋, “人工知能と經濟の未來 2030 年雇用大崩壊,” 文藝春秋 (2016).
- ジェリー・カプラン, “人間さまお断り—人工知能時代の經濟と労働の手引,” 三省堂 (2016).
- 松尾 豊 ほか, “人工知能學會倫理委員會の取組み (アーティクル),” 人工知能, Vol.30, No.3, (2015), pp.358-364.
- 松尾 豊 ほか, “公開討論-人工知能學會倫理委員會,” (特集 2015 年度人工知能學會全國大會 (第29回)), 人工知能, Vol. 30, No.6, pp.754-755 (2015).
- 松尾 豊, “人工知能 自動運轉: ものづくりが変わる 日本の製造業に勝機あり,” エコノミスト (2015年 10月 6日号).
- 西田豊明, “人間力・社會力を強化する情報通信技術 人工知能を中心に,” 情報管理, Vol.57, No.8, (2014), pp.517-530.
- 野村総合研究所, “日本の労働人口の 49%が人工知能やロボット等で代替可能に,” プレスリリース (2015年 12月 2日).
- 若田部昌澄, “經濟學者は人工知能の夢を見るか: 第 2次機械時代の經濟社會構想,” 總務省 ICT インテリジェント化影響評価検討會議 (2016年 2月 2日).

[ABSTRACT]

The Intersection of Artificial Intelligence Ethics and Law

Won, Sang-Chul*

In addition to the potential harm and impact of AI technologies on our personal data, these include issues related to moral and legal status (including rights), moral agency and patience, and possible personhood and dignity. However, the most important issues related to artificial intelligence and its relationship with human society are separated by time period. That is, (1) near-term (starting in early 2021): autonomous systems (transportation, weapons), machine bias in law, privacy and surveillance, black box issues, and AI decision-making; (2) Mid-term (2040s to the end of the century): AI governance, affirmation of moral and legal status of intelligent machines (artificial moral agents), human-machine interaction, mass automation; (3) Long-term (from the 2100s): It is common to divide problems such as technological singularity, mass unemployment, and space colonization into three different periods.

This article provides a comprehensive overview of key ethical issues related to the impact of artificial intelligence (AI) on human society. AI is the use of machines to perform tasks that typically require human intelligence. In many areas of human life,

AI has had a rapid and significant impact on human society and the way we interact with each other. We will continue to do so in the future. In the process, AI requires thorough philosophical and ethical analysis while also presenting significant ethical and socio-political challenges. To avoid the negative effects of AI, we need to study its social impact. AI systems are

* Professor at Yongin Arts & Science University, Ph.D.

becoming increasingly autonomous, rational, and intelligent. Its comprehensive development raises numerous problems.

Key Words

artificial intelligence ethics, personal information protection, technological singularity, human dignity, machine bias