



## 저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

博士學位 請求論文  
指導教授 安 星 珍

# 인공지능 윤리원칙 분류 모형 및 윤리 측정지표 개발과 신뢰성에 관한 연구

成均館大學校 一般大學院

敎科敎育學科

컴퓨터 敎育專攻

蘇 順 柱

博  
士  
學  
位  
請  
求  
論  
文

인공지능  
측정지표  
윤리원칙  
개발과  
신뢰성에  
분류  
모형  
관한  
및  
연구  
윤리

2  
0  
2  
3

蘇  
順  
柱

博士學位 請求論文  
指導教授 安 星 珍

# 인공지능 윤리원칙 분류 모형 및 윤리 측정지표 개발과 신뢰성에 관한 연구

A Study on the Development and Trustworthiness of  
Artificial Intelligence Ethical Principles Classification  
Model and Ethics Measurement Indicators

成均館大學校 一般大學院

敎科敎育學科

컴퓨터 敎育專攻

蘇 順 柱

博士學位 請求論文

指導教授 安 星 珍

# 인공지능 윤리원칙 분류 모형 및 윤리 측정지표 개발과 신뢰성에 관한 연구

A Study on the Development and Trustworthiness of  
Artificial Intelligence Ethical Principles Classification  
Model and Ethics Measurement Indicators

이 論文을 教育學 博士學位請求論文으로 提出합니다.

2022 年 10 月 日

成均館大學校 一般大學院

教科教育學科

컴퓨터 教育專攻

蘇 順 柱

이 論文을 蘇順柱의 教育學  
博士學位 論文으로 認定함.

2022 年 12 月 日

審査委員長

---

審査委員

---

審査委員

---

審査委員

---

審査委員

---

# 목 차

|                                       |    |
|---------------------------------------|----|
| 제 1 장 서 론 .....                       | 1  |
| 제 1 절 연구 배경 및 목적 .....                | 1  |
| 제 2 절 연구 범위 및 방법 .....                | 3  |
| 제 2 장 이론적 배경 .....                    | 5  |
| 제 1 절 인공지능 기술과 윤리적 이슈 .....           | 5  |
| 1. 인공지능 기술 현황 .....                   | 5  |
| 2. 인공지능의 윤리적 이슈 .....                 | 8  |
| 제 2 절 인공지능 윤리 기준 및 정책 추진 동향 .....     | 11 |
| 1. 해외 인공지능 윤리 기준 및 정책 추진 동향 .....     | 11 |
| 2. 국내 인공지능 윤리 기준 및 정책 추진 동향 .....     | 15 |
| 3. 국내외 인공지능 윤리 기준 및 정책 관련 주요 쟁점 ..... | 18 |
| 제 3 절 인공지능 윤리 관련 선행 연구 .....          | 21 |
| 1. 인공지능의 윤리적 특성 .....                 | 21 |
| 2. 인공지능 인증 시험 및 표준화 .....             | 30 |
| 3. 인공지능 기술이 적용된 분야별 인공지능 윤리 .....     | 38 |
| 4. 측정지표 및 윤리 평가 .....                 | 46 |
| 제 3 장 인공지능 윤리원칙 및 윤리 측정지표 .....       | 53 |
| 제 1 절 인공지능 윤리원칙 분류 모형 및 구성요소 .....    | 53 |
| 1. 인공지능 윤리원칙 분류 및 구성요소 .....          | 53 |

|                                       |    |
|---------------------------------------|----|
| 2. 인공지능 윤리원칙 분류 모형 및 구성요소 검증 .....    | 58 |
| 3. 인공지능 윤리원칙 분류 모형 및 구성요소 연구 결과 ..... | 62 |
| 제 2 절 인공지능 윤리 측정지표 .....              | 64 |
| 1. 인공지능 윤리 측정지표 .....                 | 64 |
| 2. 인공지능 윤리 측정지표 검증 .....              | 72 |
| 3. 인공지능 윤리 측정지표 연구 결과 .....           | 77 |
| 제 3 절 인공지능 윤리 측정지표 확장 개발 .....        | 79 |
| 1. 인공지능 윤리 측정지표 항목 확장 개발 연구 방법 .....  | 79 |
| 2. 전문가 심층 면접과 델파이 설문조사 .....          | 80 |
| 3. 델파이 설문조사 결과 분석 .....               | 88 |
| 4. 인공지능 신뢰성 확보를 위한 윤리 측정지표 .....      | 92 |

## 제 4 장 인공지능 윤리 측정지표와 신뢰성 탐색 ..... 95

|                                            |     |
|--------------------------------------------|-----|
| 제 1 절 인공지능 윤리 측정지표 신뢰성 연구 방법 및 절차 .....    | 95  |
| 1. 인공지능 윤리 측정지표 신뢰성 연구 방법 .....            | 95  |
| 2. 인공지능 윤리 측정지표 신뢰성 연구 절차 .....            | 96  |
| 제 2 절 인공지능 윤리원칙과 신뢰할 수 있는 평가목록 .....       | 98  |
| 1. 신뢰할 수 있는 인공지능 평가목록 탐색 .....             | 98  |
| 2. 신뢰할 수 있는 인공지능 평가목록의 윤리적 신뢰성 관계 정의 ..... | 102 |
| 3. 신뢰할 수 있는 인공지능 평가목록에 대한 시사점 .....        | 104 |
| 제 3 절 인공지능 윤리원칙에 기반한 윤리 측정지표 .....         | 105 |
| 1. 인공지능 윤리원칙 및 구성요소별 윤리 측정지표 현황 .....      | 105 |
| 2. 인공지능 윤리 측정지표 최종 항목 .....                | 107 |
| 제 4 절 인공지능 윤리 측정지표와 신뢰성 간의 관계 설정 .....     | 111 |
| 1. 인공지능 윤리 측정지표와 신뢰성 간의 관계 정의 .....        | 111 |

|                                                             |         |
|-------------------------------------------------------------|---------|
| 2. ALTAI의 요구사항별 평가목록 변수 정의 .....                            | 114     |
| 제 5 절 인공지능 윤리 측정지표와 신뢰성에 관한 설문조사 결과 분석 .....                | 120     |
| 1. 설문 대상 표본의 특성 .....                                       | 120     |
| 2. 기술통계량분석 .....                                            | 123     |
| 3. 타당성 검증 .....                                             | 126     |
| 4. 신뢰도 분석 .....                                             | 130     |
| 5. 상관관계분석 .....                                             | 134     |
| 제 6 절 인공지능 윤리 측정지표에 대한 신뢰성 연구 결과 .....                      | 140     |
| 1. 신뢰성 검증이 완료된 인공지능 윤리 측정지표 .....                           | 140     |
| 2. EMI-AI와 ALTAI 간의 관계 검증 .....                             | 144     |
| <br>제 5 장 결 론 .....                                         | <br>151 |
| <br>참고문헌 .....                                              | <br>156 |
| <br>부록 .....                                                | <br>167 |
| <부록 1> 인공지능 윤리 측정지표 개발을 위한 전문가 델파이 설문지 .....                | 167     |
| <부록 2> 인공지능 윤리원칙에 기반한 인공지능 윤리 측정지표 개발과<br>신뢰성에 관한 설문지 ..... | 178     |
| <br>ABSTRACT .....                                          | <br>188 |

## 표 목차

|                                                 |    |
|-------------------------------------------------|----|
| [표 2-1] 인공지능 기술별 분류 현황 .....                    | 6  |
| [표 2-2] 인공지능 적용 사례 .....                        | 7  |
| [표 2-3] 해외 인공지능 윤리 가이드라인 및 정책 추진 현황 .....       | 11 |
| [표 2-4] 국내 인공지능 윤리 가이드라인 및 정책 추진 현황 .....       | 16 |
| [표 2-5] 국내외 인공지능 윤리 관련 주요 쟁점 현황 .....           | 19 |
| [표 2-6] 국내외 인공지능 윤리원칙 및 특징 .....                | 22 |
| [표 2-7] 아실로마 AI 원칙 23항목 .....                   | 24 |
| [표 2-8] 지능정보사회 구현을 위한 공통원칙과 세부지침 현황 .....       | 25 |
| [표 2-9] 소프트웨어 인증기준의 품질 특성별 정의 .....             | 32 |
| [표 2-10] 인공지능 표준화 그룹별 대표 표준화 항목 .....           | 35 |
| [표 2-11] IEEE SA에서 진행하는 인공지능 윤리 관련 표준화 현황 ..... | 36 |
| [표 2-12] 로봇 분류 .....                            | 39 |
| [표 2-13] 자율주행자동차 저장의무 데이터 종류 .....              | 42 |
| [표 2-14] 자율주행자동차 윤리 가이드라인 .....                 | 44 |
| [표 2-15] 인공지능 서비스 품질 측정항목 .....                 | 47 |
| [표 2-16] 인공지능 신뢰성 확보를 위한 기술적 요구사항과 윤리 요건 .....  | 48 |
| [표 2-17] 인공지능 생명주기 단계별 요구사항 확인 및 검증 주체 .....    | 49 |
| [표 2-18] ALTAI의 요구사항 및 평가목록 항목 수 현황 .....       | 51 |
| [표 3-1] 인공지능 윤리원칙 정의 .....                      | 54 |
| [표 3-2] 투명성 윤리원칙에 포함된 구성요소 정의 .....             | 55 |
| [표 3-3] 책무성 윤리원칙에 포함된 구성요소 정의 .....             | 55 |
| [표 3-4] 공정성 윤리원칙에 포함된 구성요소 정의 .....             | 56 |

|                                                |    |
|------------------------------------------------|----|
| [표 3-5] 통제성 윤리원칙에 포함된 구성요소 정의 .....            | 56 |
| [표 3-6] 안전성 윤리원칙에 포함된 구성요소 정의 .....            | 57 |
| [표 3-7] 인공지능 윤리원칙 분류의 신뢰도 분석 결과 .....          | 58 |
| [표 3-8] 인공지능 윤리원칙 분류의 상관관계분석 결과 .....          | 59 |
| [표 3-9] 인공지능 윤리원칙의 구성요소 신뢰도 분석 결과 .....        | 59 |
| [표 3-10] 투명성 원칙의 구성요소 상관관계분석 결과 .....          | 60 |
| [표 3-11] 책무성 원칙의 구성요소 상관관계분석 결과 .....          | 60 |
| [표 3-12] 공정성 원칙의 구성요소 상관관계분석 결과 .....          | 61 |
| [표 3-13] 통제성 원칙의 구성요소 상관관계분석 결과 .....          | 61 |
| [표 3-14] 안전성 원칙의 구성요소 상관관계분석 결과 .....          | 61 |
| [표 3-15] 인공지능 윤리원칙 구성요소별 측정지표 검증대상 항목 현황 ..... | 65 |
| [표 3-16] 투명성 원칙에 포함된 윤리 측정지표 항목 정의 .....       | 65 |
| [표 3-17] 책무성 원칙에 포함된 윤리 측정지표 항목 정의 .....       | 67 |
| [표 3-18] 공정성 원칙에 포함된 윤리 측정지표 항목 정의 .....       | 68 |
| [표 3-19] 통제성 원칙에 포함된 윤리 측정지표 항목 정의 .....       | 70 |
| [표 3-20] 안전성 원칙에 포함된 윤리 측정지표 항목 정의 .....       | 70 |
| [표 3-21] 인공지능 윤리 측정지표 신뢰도 분석 결과 .....          | 72 |
| [표 3-22] 설명가능성의 측정지표 상관관계분석 결과 .....           | 74 |
| [표 3-23] 추적가능성의 측정지표 상관관계분석 결과 .....           | 74 |
| [표 3-24] 준법성의 측정지표 상관관계분석 결과 .....             | 74 |
| [표 3-25] 책임식별성의 측정지표 상관관계분석 결과 .....           | 75 |
| [표 3-26] 알고리즘 차별성의 측정지표 상관관계분석 결과 .....        | 75 |
| [표 3-27] 데이터 편향성의 측정지표 상관관계분석 결과 .....         | 75 |
| [표 3-28] 제어가능성의 측정지표 상관관계분석 결과 .....           | 76 |
| [표 3-29] 견고성의 측정지표 상관관계분석 결과 .....             | 76 |

|                                                 |     |
|-------------------------------------------------|-----|
| [표 3-30] 보안성의 측정지표 상관관계분석 결과 .....              | 76  |
| [표 3-31] 프라이버시 보호 측정지표 상관관계분석 결과 .....          | 76  |
| [표 3-32] 인공지능 윤리 측정지표 현황 .....                  | 77  |
| [표 3-33] 전문가 그룹 참여자 현황 .....                    | 80  |
| [표 3-34] 투명성 원칙에 속하는 윤리 측정지표 정의 .....           | 82  |
| [표 3-35] 책무성 원칙에 속하는 윤리 측정지표 정의 .....           | 83  |
| [표 3-36] 공정성 원칙에 속하는 윤리 측정지표 정의 .....           | 84  |
| [표 3-37] 통제성 원칙에 속하는 윤리 측정지표 정의 .....           | 86  |
| [표 3-38] 안전성 원칙에 속하는 윤리 측정지표 정의 .....           | 87  |
| [표 3-39] 인공지능 윤리 측정지표 내용타당도 분석 결과 및 선정 현황 ..... | 88  |
| [표 3-40] 윤리원칙 구성요소별 측정지표 타당성 항목 수 현황 .....      | 91  |
| [표 3-41] 신뢰성 확보를 위한 인공지능 윤리 측정지표 항목 현황 .....    | 93  |
| [표 4-1] 인간의 기본권, 자율성, 존엄성 존중 요구사항 .....         | 98  |
| [표 4-2] 기술적 견고성과 안전성 요구사항 .....                 | 99  |
| [표 4-3] 개인정보 보호 및 데이터 거버넌스 요구사항 .....           | 100 |
| [표 4-4] 투명성 요구사항 .....                          | 100 |
| [표 4-5] 다양성, 차별금지 및 공정성 요구사항 .....              | 101 |
| [표 4-6] 사회 및 환경에 미치는 영향 요구사항 .....              | 101 |
| [표 4-7] 책무성 요구사항 .....                          | 102 |
| [표 4-8] 인공지능 윤리원칙 및 구성요소별 윤리 측정지표 항목 현황 .....   | 105 |
| [표 4-9] 인공지능 윤리 측정지표 최종 항목 .....                | 107 |
| [표 4-10] 인공지능 윤리 측정지표와 신뢰성 간의 관계 정의 .....       | 111 |
| [표 4-11] ALTAI의 요구사항 1번의 변수 정의 및 평가목록 .....     | 114 |
| [표 4-12] ALTAI의 요구사항 2번의 변수 정의 및 평가목록 .....     | 115 |
| [표 4-13] ALTAI의 요구사항 3번의 변수 정의 및 평가목록 .....     | 116 |

|                                                       |     |
|-------------------------------------------------------|-----|
| [표 4-14] ALTAI의 요구사항 4번의 변수 정의 및 평가목록 .....           | 116 |
| [표 4-15] ALTAI의 요구사항 5번의 변수 정의 및 평가목록 .....           | 117 |
| [표 4-16] ALTAI의 요구사항 6번의 변수 정의 및 평가목록 .....           | 118 |
| [표 4-17] ALTAI의 요구사항 7번의 변수 정의 및 평가목록 .....           | 119 |
| [표 4-18] 표본의 인구 통계적 특성 .....                          | 120 |
| [표 4-19] 직업(직무)별 경력 및 평균연령 분석 결과 .....                | 122 |
| [표 4-20] 기술통계량분석 결과 .....                             | 123 |
| [표 4-21] KMO와 Bartlett의 검증 결과 .....                   | 126 |
| [표 4-22] 탐색적 요인분석 결과 .....                            | 127 |
| [표 4-23] 신뢰도 분석 결과 .....                              | 131 |
| [표 4-24] 통제성 상관관계분석 결과 .....                          | 135 |
| [표 4-25] 안전성 상관관계분석 결과 .....                          | 135 |
| [표 4-26] 투명성 상관관계분석 결과 .....                          | 136 |
| [표 4-27] 공정성 상관관계분석 결과 .....                          | 137 |
| [표 4-28] 보안성 상관관계분석 결과 .....                          | 138 |
| [표 4-29] 사회적영향 상관관계분석 결과 .....                        | 138 |
| [표 4-30] 책무성 상관관계분석 결과 .....                          | 139 |
| [표 4-31] EMI-AI 항목 .....                              | 141 |
| [표 4-32] EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 참여자 현황 ..... | 144 |
| [표 4-33] EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 분석 결과 .....  | 145 |
| [표 4-34] EMI-AI에만 존재하는 인공지능 윤리 측정지표 18개 항목 .....      | 149 |

## 그림 목차

|                                                 |     |
|-------------------------------------------------|-----|
| <그림 2-1> 연구 범위 프레임워크 구성도 .....                  | 3   |
| <그림 2-2> 연구 방법 요약 .....                         | 4   |
| <그림 2-3> 인공지능 윤리 3대 기본 원칙과 10대 핵심 요건 .....      | 27  |
| <그림 2-4> 신뢰할 수 있는 인공지능 실현 전략 비전·목표·추진 전략 .....  | 29  |
| <그림 2-5> 인공지능 시험기준 구성도 .....                    | 30  |
| <그림 2-6> 소프트웨어 인증기준 구성도 .....                   | 32  |
| <그림 2-7> 아시모프의 로봇 3원칙 .....                     | 39  |
| <그림 2-8> 자기 점검 윤리 문항의 구성 .....                  | 41  |
| <그림 3-1> 인공지능 윤리원칙 분류 모형 및 구성요소 .....           | 62  |
| <그림 4-1> 인공지능 윤리 측정지표 신뢰성 연구 절차와 실행 내용 .....    | 96  |
| <그림 4-2> 신뢰할 수 있는 인공지능 평가목록의 윤리 신뢰성 관계 정의 ..... | 103 |
| <그림 4-3> 인공지능 윤리원칙별 윤리 측정지표 항목 분포도 .....        | 106 |
| <그림 4-4> 인공지능 윤리원칙 구성요소별 윤리 측정지표 항목 분포도 .....   | 106 |
| <그림 4-5> 인공지능 윤리 측정지표 항목 수 현황 .....             | 110 |
| <그림 4-6> 직업(직무)별 참여 인원 분포도 .....                | 121 |
| <그림 4-7> EMI-AI 항목 현황 .....                     | 140 |
| <그림 4-8> EMI-AI와 ALTAI 평가목록 간의 관계성 .....        | 148 |
| <그림 4-9> EMI-AI와 ALTAI 평가목록 간의 포함 관계 .....      | 150 |

## 논문 요약

# 인공지능 윤리원칙 분류 모형 및 윤리 측정지표 개발과 신뢰성에 관한 연구

인공지능은 4차 산업혁명에서 빅데이터, 클라우드, 메타버스, IOT 등의 핵심적인 기술 중에서도 가장 중심이 되는 기술로 자리매김하고 있다. 인공지능은 인간과 상호 관계, 인공지능 간의 상호 관계를 형성하면서 인간에게 많은 편의성과 효율적 가치를 제공하고 있다. 5G와 메타버스, 자율주행자동차, 로봇이 발전하면서 인공지능이 더욱 인간과 가까워지고 유익하게 활용되고 있다. 하지만 인공지능이 인간에게 항상 순기능만 제공하는 것은 아니다. 인공지능이 인간의 생명을 위협할 수 있으며, 인격권을 훼손하고, 재산과 정보 보안에 심각한 타격을 가할 수도 있다. 이러한 인공지능의 역기능을 사전에 방지하고, 문제 발생 시 선제적으로 대응할 수 있도록 하는 인공지능 윤리 적용기준과 방법이 절실하게 요구되고 있다.

이 논문에서는 인공지능 윤리원칙 분류 모형과 구성요소를 기반으로 신뢰성이 확보된 범용적인 인공지능 윤리 측정지표 개발과 검증을 실시하여 인공지능 산업분야에 즉시 사용할 수 있도록 연구하였다. 신뢰성이 확보된 윤리 측정지표를 개발하기 위하여 연구자가 선행 연구한 인공지능 윤리원칙과 구성요소 연구 결과와 인공지능 윤리 측정지표 40개 항목 연구 결과를 바탕으로 인공지능 윤리 측정지표 50개를 확장 개발하였다. 국내외 인공지능 윤리 관련 가이드라인, 헌장, 지침, 규정, 정책, 법·제도 등 다양한 문헌을 분석하여 윤리 측정지표를 정의하고 인공지능 윤리 관련 전문가 30명을 대상으로 FGI를 3회 진행하여 55개의 윤리 측정지표를 도출하고 정의하였다. FGI에서 도출된 측정지표 55개에 대한 전문가 델파이 설문조사와 설문 데

이더 타당도 분석을 통하여 50개의 윤리 측정지표를 확장 개발하였다. 확장 개발된 50개의 윤리 측정지표와 연구자가 선행 개발한 40개의 윤리 측정지표를 통합하였으며, 신뢰성 확보를 위한 윤리 측정지표 개발을 위해 유럽연합에서 공표한 신뢰할 수 있는 인공지능 평가목록(ATAI)을 참고하여 7개의 신뢰성 변수를 정의하고 설문지를 설계하였다. 통합된 90개 항목의 윤리 측정지표 신뢰성 검증을 위하여 설문조사를 실시하였으며, 설문조사에 참여한 표본은 164명이었다. 설문 통계분석은 SPSS 도구를 사용하였다. 윤리 측정지표 분석 결과 90개 항목에 대한 타당성 검정 결과는 매우 높은 수준으로 나타났다. 요인분석 결과로 적합성이 검증되었으며, 탐색적 요인분석에서는 86개의 변수를 적재하여 타당도를 확보하였다. 신뢰도 분석 결과에서는 모든 변수들이 높은 신뢰계수로 검증되었다. 상관관계분석 결과에 의하여 90개의 윤리 측정지표 중 86개가 신뢰성이 확보된 인공지능 윤리 측정지표(EMI-AI)로 완성되었다. 이어서 EMI-AI의 86개 항목과 ATAI의 69개 평가목록을 대상으로 관계성 검증을 위해 전문가 델파이 설문조사 결과 ATAI의 평가목록 중 61개 항목이 EMI-AI의 측정지표 항목과 공통적인 유사성을 갖는 것으로 분석되었다. 그리고 EMI-AI에만 존재하는 항목은 18개로 분석되었으며, ATAI에만 존재하는 평가목록은 8개로 분석되었다.

이 논문에서 최종적으로 확정된 윤리 측정지표 86개 항목은 신뢰성이 확보된 인공지능 윤리 측정지표이며, 인공지능과 관련된 모든 산업 분야에 적용할 수 있도록 범용적으로 개발되었기 때문에 국내는 물론 해외에서도 활용이 가능할 것이다. 또한 인공지능 윤리원칙 분류 모형과 구성요소를 기반으로 개발된 윤리 측정지표이기 때문에 지속적인 측정지표 개발과 확장이 이루어질 수 있을 것이다. 인공지능 윤리 측정지표를 이용하여 윤리 평가목록, 인증·검사 목록, 윤리 관련 세부 지침 등을 신속하게 개발할 수 있는 기틀이 마련되었다는데 이 논문의 큰 의의가 있다고 본다.

주제어 : 인공지능 윤리원칙, 인공지능 윤리 측정지표, 윤리 측정지표와 신뢰성, AI 윤리 측정지표, EMI-AI

# 제 1 장 서 론

## 제 1 절 연구의 배경 및 목적

디지털 트랜스포메이션(Digital Transformation)은 각 산업 분야에서 급속하게 진행되고 있으며, 디지털 기반의 초연결, 초지능 및 융합화, 5G+ 이동통신 기술에 의하여 인공지능(Artificial Intelligence) 기술이 모든 산업분야에 적용되어 산업의 가치사슬을 변화시키고 있다. 인공지능은 4차 산업혁명에서 가장 핵심적인 기술 요소로서 각 산업분야의 생산성과 효율성, 편리성을 향상시키고 있다. 인공지능 기술은 기존 비즈니스 프로세스가 사물인터넷(IOT), 위치기반 서비스(LBS), SNS (Social Network Service), 빅데이터(Big Data), 클라우드(Cloud) 기술 등에 의하여 대변혁이 이루어지고 있다. 로봇 기술과 결합된 인공지능, 휴머노이드, 자율주행자동차와 결합된 인공지능, 헬스케어와 결합된 인공지능, 빅데이터 증가에 의한 인공지능 비즈니스 모델 증가, 인공지능 무인 무기체계, 인공지능 콘텐츠 서비스 지능화 등이 인공지능 기술을 적용하는 대표적인 응용 사례들이다. 현재의 인공지능 기술은 인간과 공존하며 상호작용으로 인간에게 삶의 질을 향상시키고 친화적 사용으로 인간의 감성까지 인지할 수 있는 수준에 이르렀다. 인공지능 기술이 발전하면서 인간에게 많은 순기능을 제공하지만, 한편으로 다양한 역기능을 가지고 있다. 인공지능이 급속하게 발전하면서 인간에게 유용하지 못한 윤리적인 문제점과 이슈들을 미리 정확하게 파악하여 안전하고 신뢰할 수 있는 인공지능의 안전장치 마련이 절실하게 필요하다. 인공지능의 윤리적 이슈로는 알고리즘의 편향성 문제, 의사결정 오류와 안전성 문제, 악용 문제, 인간의 인격권 문제, 개인정보보호 문제, 인간 생명 문제, 신뢰성 상실, 투명성 문제, 책임 문제, 가치정렬 불일치 등을 들 수 있다. 이러한 다양한 윤리적 문제들을 예방하고 해결할 수 있도록 철저히 준비하여야 안전하고

신뢰할 수 있는 인공지능 사회를 만들 수 있을 것이다(Leslie. D, 2019).

본 논문에서는 인공지능이 가지는 순기능과 역기능을 살펴보고 인공지능에 대한 윤리원칙, 구성요소, 측정지표를 개발하여 신뢰할 수 있고 안전한 인공지능 제품이나 서비스 개발과 운용 등에 적용될 수 있도록 하는 연구를 진행하고자 하였다.

인공지능 윤리(Artificial Intelligence Ethics)는 인공지능과 관련된 다양한 문제점을 윤리적, 사회적 가치 관점에서 인간의 도덕적 관계와 신뢰, 안전, 책임, 임무 등을 포괄하여 인간 삶에 미치는 영향을 윤리학적으로 규정하는 것을 말한다(IEEE, 2011). 인공지능 윤리 대응을 위해서 각국에서는 인공지능 윤리 가이드라인 제정, 윤리 현장 제정, 윤리 관련 법·제도 제정, 윤리원칙 발표, 신뢰성 평가목록 개발, 윤리 기준 제정, 다양한 윤리 관련 가이드라인을 개발하여 배포하고 있다. 따라서 본 논문에서는 인공지능 윤리원칙 분류 모형과 구성요소를 바탕으로 신뢰성이 확보된 인공지능 윤리 측정지표(EMI-AI)<sup>1)</sup> 개발과 유럽연합에서 공개한 신뢰할 수 있는 인공지능 자체 평가목록(ALTAI)<sup>2)</sup>을 분석하여 EMI-AI와 ALTAI 간 포함 관계를 탐색하여 그 결과를 제시하는 데 목적을 두었다.

인공지능 윤리원칙 분류 모형 및 구성요소<sup>3)</sup>는 2021년에 개발된 연구 결과를 적용하였으며, 인공지능 윤리 측정지표<sup>4)</sup>는 2022년에 개발된 40개 항목의 윤리 측정지표를 적용하였다. 본 연구에서 인공지능 윤리원칙 분류 모형과 구성요소를 바탕으로 신뢰성 확보를 위한 인공지능 윤리 측정지표 항목을 확장 개발과 EMI-AI를 개발하고 ALTAI와 EMI-AI 간 관계성을 분석하여 EMI-AI에 대한 차별성 및 특징, 향후 활용성을 제시하고자 하였다.

---

1) EMI-AI (Ethical Measurement Indicators of Artificial Intelligence), 본 연구 결과에서 신뢰성이 확보된 인공지능 윤리 측정지표

2) EU 집행위원회, 신뢰할 수 있는 인공지능 평가목록(The Assessment List for Trustworthy Artificial Intelligence(ALTAI) for Self Assessment, 2020


3) 인공지능 윤리원칙 분류 모형 및 구성요소에 관한 연구, 소순주·안성진, 2021

4) 인공지능 윤리원칙 기반의 인격권 및 재산보호를 위한 인공지능 윤리 측정지표, 소순주·안성진, 2022

## 제 2 절 연구의 범위 및 방법

인공지능 윤리가 이슈화되면서 각국에서는 인공지능 윤리 가이드라인, 윤리원칙, 인공지능 개발 지침, 인공지능 인증 등이 정부, 연구기관, 기업을 중심으로 연구·개발 및 적용되고 있다. 하지만 대부분 인공지능 윤리원칙이라는 개념적 범주 내에서 인간의 존엄성, 투명성, 설명가능성, 책무성, 공정성, 신뢰성 등으로 구분하여 정책 수립 및 윤리 현장 제정, 지침 개발, 기본적인 추진전략 등을 마련하고 있다.


본 연구에서는 인공지능 윤리원칙 분류 모형과 구성요소를 바탕으로 인공지능 제품이나 서비스에 적용할 수 있도록 하는 인공지능 윤리 측정지표 50개 항목을 확장 연구 개발하였다. 또한 유럽연합에서 공표한 신뢰할 수 있는 인공지능 평가목록의 7개 요구사항을 적용하여 신뢰성에 대한 관계를 탐색하는 것을 연구 범위로 하였다. 연구 범위에 대한 전체적인 프레임워크는 <그림 2-1>과 같이 구성하였다.



<그림 2-1> 연구 범위 프레임워크 구성도

신뢰성 탐색은 선행 개발된 윤리 측정지표 40개 항목과 본 연구에서 개발한 50개 항목을 포함하여 총 90개의 인공지능 윤리 측정지표 항목을 대상으로 진행하였다.

본 연구 방법은 첫째, 선행 연구된 인공지능 윤리원칙 분류 모형과 구성요소를 바탕으로 인공지능 관련 학술지, 기관 연구보고서, 학위 논문, 뉴스, 웹 사이트, 기업의 제품 및 서비스, 윤리 관련 사례, 정부 정책, 법·제도, 지침, 선행연구, 동향 등을 분석하였다. 전문가 그룹을 통해 FGI 및 델파이 설문조사에 의하여 신뢰할 수 있는 인공지능 윤리 측정지표 50개 항목을 확장 개발하였다. 둘째, 선행 개발된 윤리 측정지표 40개 항목과 확장 개발한 50개 항목을 통합하여 윤리 측정지표 90개 항목에 대한 신뢰성 검증을 위하여 설문조사와 통계분석으로 EMI-AI 86개 항목을 개발하였다. 셋째, 전문가 델파이 조사를 통하여 ALTAI의 평가목록과 EMI-AI 간의 윤리 측정지표 항목에 대한 관계성을 탐색하여 분석 결과를 제시하였다. <그림 2-2>는 본 연구 방법의 요약 내용을 도식화한 것이다.



<그림 2-2> 연구 방법 요약

본 연구에 참여한 전문가 그룹은 총 30명이었으며, FGI를 진행한 도구로는 마인드맵(Mind Map)을 사용하였다. 전문가를 대상으로 한 설문조사는 델파이 설문조사를 실시하였다. 또한 인공지능 윤리 측정지표 90개 항목에 대하여 신뢰성 확보를 위한 설문조사는 164명이 참여하였으며, 설문조사 결과를 분석한 도구는 SPSS를 이용하여 통계분석을 진행하였다.

## 제 2 장 이론적 배경

### 제 1 절 인공지능 기술과 윤리적 이슈

#### 1. 인공지능 기술 현황

인공지능 기술은 인간의 뇌신경과 학습능력, 인지능력, 이해능력, 추론능력 등을 실현하는 기술로 1950년 영국의 수학자 앨런 튜링에 의하여 인공지능 개념이 제시되었다. 1951년 마빈 민스키, 딘 에드몬즈는 SNARC를 개발하여 최초로 학습하는 기계를 개발하였다. 오늘날 4차 산업혁명에 핵심 기술로 인공지능은 인간의 학습능력과 추론능력, 지각능력, 자연언어의 이해능력 등을 컴퓨터 프로그램으로 실현하는 기술로 정의하고 있다(과학기술정책연구원, 2019). 디지털 콘텐츠의 증가, 빅데이터, 클라우드, 엣지 컴퓨팅 기술의 발전으로 인하여 인공지능 기술이 발전할 수 있는 좋은 환경이 만들어졌다. 인공지능 발전단계는 크게 약 인공지능(Narrow, AI), 강 인공지능(General AI), 초 인공지능(Super AI)으로 나누어지는데 현재는 약 인공지능 단계라 할 수 있을 것이다. 인공지능 서비스가 활성화되면서 머신러닝을 위한 학습용 데이터에 관심이 높아지고 있으며 양질의 데이터셋 확보를 위해 경쟁이 치열해지고 있다. 향후 10년간은 인공지능 기술이 기업의 성패를 가르는 중요한 요소가 되기 때문에 기술경쟁력 확보를 위해서 데이터 중심의 인공지능 개발, MLOps(Machine Learning Operations)를 이용하여 인공지능 시스템의 연속성, 확장성, 재현성을 실현하려는 노력이 지속되고 있다. 인공지능이 IOT 기술과 결합하여 대량의 데이터를 쉽게 수집, 저장, 유통, 분류할 수 있도록 발전하면서 빅데이터화 되었으며, 클라우드 기술에 힘입어 그동안 경험하지 못했던 많은 데이터를 운영할 수 있게 되었다. 국가별 인공지능 도입 수준에 따라 기대되는 경제적 효과의 격차, 수준의 차이

가 더욱 벌어지고 있다. 인공지능이 기존 시장에서는 음성, 이미지 인식, 자연어 처리 등을 적용하였으나, 새로운 시장에서는 시각지능, 복합지능, 지능형 에이전트 기술 등이 대세를 이루고 있다. 인공지능을 기술별로 분류한 현황<sup>5)</sup>은 [표 2-1]과 같다.

[표 2-1] 인공지능 기술별 분류 현황

| AI 기술       | 내 용                                                                                          |
|-------------|----------------------------------------------------------------------------------------------|
| 추론 및 머신러닝   | · 인간의 사고능력을 추론하고 모방하는 기계학습 기술                                                                |
| 지식표현 및 언어지능 | · 인간이 사용하는 자연어 처리를 기반으로 사람과 상호작용하는 기술                                                        |
| 청각 지능       | · 음성, 음악, 음향 분석 및 인식, 합성, 검색하는 기술                                                            |
| 시각 지능       | · 사물의 종류, 움직임, 위치, 주변과의 관계 등 시각 이해를 기반으로 지능화 기능을 구현하는 기술                                     |
| 복합 지능       | · 시공간 및 후각, 촉각 등 주변의 상황을 인지하고 예측하여 상황에 적합한 대응을 구현하는 기술                                       |
| 지능형 에이전트    | · 채팅 봇, 개인비서, 단위 서비스 등을 가상공간 환경에서 특별한 응용 프로그램을 사용자에게 서비스할 목적으로 반복적인 작업을 자동화시킬 수 있도록 하는 구현 기술 |
| 인간-기계 협업    | · 인간의 감성과 행동, 의도를 이해하고 인간의 뇌 활동과 기계가 연동되어 협동으로 작동하게 해 주는 기술                                  |
| AI 기반 하드웨어  | · 하드웨어 성능을 향상시킬 목적으로 초고속 지능정보처리 기술을 구현하여 제작된 하드웨어 기술                                         |

인공지능 주요 기술<sup>6)</sup>로는 글로벌테크 기업들이 대규모 모델을 개발하여 성능을 향상시키고 있는 초대규모 모델 GPT-3, AI 모델 학습 데이터를 통합·이동하면서 발생할 수 있는 개인정보보호 이슈 부담을 완화할 수 있는 연합학습(Federated Learning) 기술, 클라우드 중앙 집중식 관리 한계를 극복하기 위한 엣지 AI(Edge AI), 언어처리 병렬화를 통해 계산의 효율성을 향상시킬 수 있는 트랜스포머(Transformer), 추상적인

5) 정보통신기술진흥센터, 4차 산업혁명 기술 수준 평가 및 수준 향상 방안, 2018

6) 한국지능정보사회진흥원, 주목받은 인공지능(AI) 9대 핵심 기술 분석 및 주요 시사점, 2021

문제를 처리하며 인과관계 파악이 가능한 시스템2(System 2) 기술이 대표적이다.

인공지능 기술의 다양한 응용분야 사례는 [표 2-2]와 같이 금융, 의료 헬스케어, 국방, 제조, 교육, 공공, 물류 등 전 산업 분야에 적용한 사례들<sup>7)</sup>이다.

[표 2-2] 인공지능 적용 사례

| AI 기술   | 내 용                                                                                                                                       |
|---------|-------------------------------------------------------------------------------------------------------------------------------------------|
| 금융      | <ul style="list-style-type: none"> <li>· 챗봇과 가상 에이전트를 이용 고객 응대, 실시간 금융상품 상담</li> <li>· 금융상품 개발, 주식정보 분석 및 예측, 투자자 정보 지원</li> </ul>        |
| 교육      | <ul style="list-style-type: none"> <li>· 맞춤형 개인 적응학습 지원, 학령별 지식기반 학습 데이터 서비스</li> </ul>                                                   |
| 국방      | <ul style="list-style-type: none"> <li>· 무인 항공기, 전투 로봇, 인공지능 전략물자 예측 시스템</li> <li>· 전투 시뮬레이션, 인공지능 감시, 탐지시스템, CCTV 감시</li> </ul>          |
| 경영      | <ul style="list-style-type: none"> <li>· 인사 채용, 승진 시스템, 경영 분석 시스템</li> </ul>                                                              |
| 법률      | <ul style="list-style-type: none"> <li>· 자연어 처리와 법률 추론을 통한 형량 예측 및 판례 학습</li> <li>· 계약서 분석, 계약서 자동 생성</li> </ul>                          |
| 제조      | <ul style="list-style-type: none"> <li>· 생산관리, 공급망 관리, 스마트 팩토링, 품질관리 및 점검</li> <li>· 글로벌 공급망 예측 및 부품소요량 예측 및 자율적 발주</li> </ul>            |
| 의료 헬스케어 | <ul style="list-style-type: none"> <li>· 의료 기록분석, 이미지 분석을 이용한 치료 방법 추천 및 질병예측</li> <li>· 챗봇 기반 환자 상담, 신약개발 대량 데이터 활용, 임상데이터 응용</li> </ul> |
| 자율주행자동차 | <ul style="list-style-type: none"> <li>· 인공지능 센서, 예측, 탐색, 이미지 인식 기술 적용</li> <li>· 완전 자율주행자동차 인공지능 기술 적용, UAM(도심항공모빌리티)</li> </ul>         |
| 공공      | <ul style="list-style-type: none"> <li>· CCTV에 의한 범죄 예방, 교통 통제, 감시</li> <li>· 안전 재해 예방, 식품 안전관리 및 검사 서비스</li> </ul>                       |
| 서비스     | <ul style="list-style-type: none"> <li>· 챗봇, 매칭 서비스, 추천 서비스</li> <li>· 개인비서(Intelligent Virtual Assistant) 서비스</li> </ul>                 |
| 물류      | <ul style="list-style-type: none"> <li>· 재고 관리 및 매출 예측에 의한 자율 발주, 매장관리</li> <li>· 자율주행 로봇에 의한 물류 공급</li> </ul>                            |

7) 행정안전부(디지털정부국 공공지능정책과), 공공분야 인공지능 도입을 위한 실무자 안내서(안), 2021

## 2. 인공지능의 윤리적 이슈

이제는 일상생활에서 인공지능 제품이나 서비스를 누구나 이용하고 있으며, 상품으로서 가치를 높이기 위한 신제품, 서비스들은 대부분 인공지능 기술을 적용하여 개발하고 있다. 인공지능 기술이 발전하면서 인간은 사회생활이 더욱 편리해졌으며, 힘들고 반복적인 많은 일들을 인공지능에 맡길 수 있게 되었다. 오래전부터 로봇이 제조 현장에 투입되어 활용되었으며, 인간에게 가장 가깝게 활용되고 있는 휴머노이드는 점점 기술이 발전되어 인간과 상호작용하는데 어려움이 없을 정도로 발전하고 있다. 이에 따라 인간이 실생활 속에서 로봇 활용에 대한 거부감이 낮아지고 인간사회의 노령화에 따른 인공지능 로봇 활용이 증가하고 있다. 사회적으로 인간에게 인공지능이 얼마나 많은 유용함을 제공하는지에 관한 연구도 계속 진행되고 있으며, 새로운 인공지능 제품이나 서비스가 무수히 등장하고 있다. 인공지능이 인간에게 편의성과 유용성 측면에서 많은 기여를 하지만 역기능 또한 수많은 문제를 낳고 있다. 인공지능에 의하여 발생하는 문제점과 미래에 예상되는 이슈들을 정확하게 파악하여 대비할 필요성이 높아지고 있으며 인공지능 윤리가 새로운 연구 대상으로 두각 되고 있다. 이에 따라 인공지능의 악용 문제, 인공지능의 편향성 문제, 개인정보 보호 문제, 킬러 로봇 문제, 인공지능의 오류와 안전성 문제 등이 인공지능의 5대 윤리 문제로 제시되었다(한상기, 2016).

인공지능 윤리는 인공지능이 일으킬 수 있는 다양한 문제들을 미리 정확하게 인식하고 파악하여 대비함으로써 인공지능이 안전하게 이용될 수 있도록 하는 것을 목표로 기준을 정하고, 법제화하며 인간과 상호작용하는 데 어떠한 문제도 발생하지 않도록 하는 것이라 할 수 있다(김종세, 2020). 인공지능 기술이 발전하면서 윤리 문제도 두각 되었으며, 인공지능 기술 초기에는 윤리가 크게 문제 되지 않았다. 인간과 상호작용이 증가하면서 윤리에 관한 관심이 높아지고 문제점도 도출되기 시

작하였다. 인공지능은 인격권과 관련이 되어 있으며, 유럽, 미국, 일본 등 선진국에서 인공지능 윤리에 대한 가이드라인, 윤리 헌장이나 법·제도를 만들어 공표하고 있다. 기업에서도 윤리 헌장을 만들어 적용하고 있으며, 연구기관에서는 인공지능 윤리에 대한 심도 있는 연구가 진행되고 있다.

하버드대학교 버크만센터에서는 ‘윤리에 입각한 인공지능((Principled Artificial Intelligence)’ 연구를 통하여 36개의 인공지능 원칙을 분석하여 8가지 공통된 핵심 주제를 선정하였다. 8가지 핵심 주제는 안전 및 보안(Safety and Security), 책무(Accountability), 투명성 및 설명 가능성(Transparency and Explainability), 개인정보(Privacy), 공정성 및 비차별(Fairness and Non-discrimination), 전문가 책임(Professional responsibility), 인간의 기술 통제(Human control of Technology), 인간 가치 증진(Promotion of Human values)을 제시하였다(버크만센터, 2020). 인공지능의 다양한 윤리적 문제를 해결하기 위하여 유럽연합 집행위원회에서는 신뢰할 수 있는 인공지능 평가목록(ALTAI)을 2020년에 공표하였으며, 빅데이터협회에서는 인공지능 활용과 데이터 보호에 상충하는 문제들을 해결하는 방안으로 윤리적 지침과 기술적, 윤리적 표준 및 알고리즘 감사 등이 해결책이 될 것이라고 보았다(BDV, 2019). 또한 미국 연방거래위원회(FTC)에서는 인공지능과 알고리즘 이용에 대한 지침을 발표하였으며, 지침에는 의사결정에 대한 설명, 데이터와 모델의 타당성 보장, 투명성 제고, 책임, 결과의 공정성 보장 등의 5가지 내용을 포함하였다(FTC, 2020). 일본 내각부에서는 2018년에 인간 중심의 인공지능 사회 7원칙 안을 발표하였다. 7원칙에는 인간 중심의 원칙, 교육 및 교양의 원칙, 개인정보 확보의 원칙, 보안 확보의 원칙, 공정경쟁 확보의 원칙, 공정성과 책임 및 투명성의 원칙, 혁신의 원칙을 제시하였다(일본 내각부, 2018). 국내에서도 2020년, 인공지능 기술과 인공지능 사회 환경 변화에 대응하기 위하여 인공지능 개발과 활용의 모든 단계에서 정부와 공공기관, 인공지능 기술 개발자, 공급자 및 이용자 등 사회 구성원이 인간 중심의 인공지능 사회 구현을 위하여 기본적이고 포괄적인 윤리 기준을 제시하는 것을 목표로

과학기술정보통신부에서 ‘국가 인공지능 윤리 기준안’을 마련하여 발표하였다. 사람 중심의 인공지능 구현을 위하여 지향해야 할 최고의 가치로는 인간성(Humanity)을 설정하였으며, 모든 인공지능은 인간을 위해 인간성을 지향하고, 인간에게 유용해야 하고, 인간의 고유한 성품을 훼손하지 않으며, 보존 및 함양해야 한다는 내용을 중심으로 하는 인공지능 윤리 기준 3대 기본 원칙과 10대 핵심 요건으로 구성하였다. 3대 기본 원칙에는 인간 존엄성 원칙, 기술의 합목적성 원칙, 사회의 공공선 원칙을 제시하였다. 10대 핵심 요건에는 인권보장, 프라이버시 보호, 다양성 존중, 침해금지, 공공성, 연대성, 데이터관리, 책임성, 안전성, 투명성이 제시 되었다(과학기술정보통신부, 2020). 2021년에는 과학기술정보통신부에서 ‘신뢰할 수 있는 인공지능 실현 전략’을 발표하였다. 신뢰 구현을 위한 법·제도, 윤리적, 기술적 요구사항을 종합한 인공지능 개발 가이드북 제작과 보급, 인공지능 제품이나 서비스에 대한 민간 자율의 인증제 도입 및 지원, 인공지능 일괄 지원 플랫폼 운영, 설명 가능성·공정성·견고성 등을 향상시키기 위한 신뢰성 원천기술 개발 추진, 학습용 데이터의 신뢰성 확보를 위한 표준 기준 제시 및 데이터 개방, 고위험 인공지능에 대한 국민 안전·신뢰성 향상 방안 연구, 인공지능 윤리 기준 실천을 위한 윤리 교육 강화 및 개발자·이용자용 체크리스트 보급, 윤리·신뢰성 향상을 위한 공론의 윤리 정책 플랫폼 운영 등이 포함되어 2025년까지 단계적으로 추진할 계획이다(과학기술정보통신부, 2021).

인공지능 기술에 의하여 인간이 보다 풍요롭고 안전한 삶을 살기 위해서는 먼저 인공지능에 대한 신뢰성이 확보되어야 한다. 인간이 인공지능과 상호작용하면서 위험을 제거하기 위해서는 사회적 위험, 경제적 위험, 윤리적 위험, 통제 관련 위험, 인공지능 작동에 따른 위험, 보안에 대한 위험으로부터 안전을 확보해야 한다. 이를 위해서 사회학, 윤리학, 공학, 법학, 교육학, 경제학 등 전 분야의 학문과 산업체 및 공공기관·정부가 참여하여 인공지능 윤리적 문제를 해결하는 방안을 모색하고 대응할 수 있도록 해야 한다.

## 제 2 절 인공지능 윤리 기준 및 정책 추진 동향

### 1. 해외 인공지능 윤리 기준 및 정책 추진 동향

향후 인공지능이 국가역량과 경제적 패권 확보에 핵심적으로 작용할 것을 인지한 세계 각국은 인공지능 기술에 국가전략을 집중하고 있다. 국가별로 인공지능의 윤리적 문제점을 해결하기 위해 EU, 미국, 일본, 영국, 독일, 프랑스 등 세계 각국에서 인공지능 윤리 가이드라인, 인공지능 개발 지침, 윤리 헌장, 정책적 규제안 등을 꾸준히 제정하면서 발표하고 있다. 유럽로봇연구네트워크(EURON)에서 2004년에 ‘로봇윤리 13원칙’을 발표한 후 2016년부터는 보다 세부적인 인공지능 윤리 가이드라인을 제정하여 인공지능 제품이나 서비스 개발에 적용할 수 있도록 하고 있다. [표 2-3]은 해외 인공지능 윤리 가이드라인 및 정책 추진 주요 현황이다. 기업, 연구소, 대학 등 민간 차원에서도 인공지능의 안전성과 신뢰성을 확보하기 위하여 다양한 기술과 정책, 윤리 기준 적용 방안 등에 관한 연구가 본격적으로 이루어지고 있다.

미국 IBM에서는 인간처럼 보고 듣고 말할 수 있는 인공지능 ‘Advancing AI’과 신뢰할 수 있고 투명한 인공지능 ‘Trusting AI’, 그리고 추론 속도와 정확도가 향상

[표 2-3] 해외 인공지능 윤리 가이드라인 및 정책 추진 현황

| 국가 | 내 용                                                                                                                                                                                                                                                                                                                                                       |
|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| EU | 2004년, 로봇윤리 13원칙 (유럽로봇연구네트워크, EURON)<br>2007년, 로봇윤리 로드맵 (EURON Rotoethics Roadmap)<br>2014년, 로봇틱스 규제 가이드라인 (Guidelines on Regulating Robotics)<br>2018년, Coordinated Plan On AI<br>2019년, 신뢰할 수 있는 AI 윤리 가이드라인(Ethics Guidelines for Trustworthy AI)<br>2020년, 신뢰할 수 있는 인공지능 자체 평가목록(ALTAI) (유럽연합 집행위원회)<br>2021년, 인공지능법 제안 (Artificial Intelligence Act) |

|    |                                                                                                                                                                                                                                                                                                                                                                                                                                                |
|----|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 미국 | 2016년, 빅데이터 알고리즘의 윤리적 가이드라인<br>2016년, AI의 미래에 관한 준비 (Preparing for the future of AI)<br>2016년, 국가 인공지능 R&D 전략 계획 (The National AI R&D Strategic Plan)<br>2016년, Ethically Aligned Design (IEEE)<br>2017년, 아실로마 인공지능 23 원칙 (Asilomar AI Principles)<br>2017년, NHTSA 자율주행자동차 설계 지침(NHTSA. ADS-A Vision Safety 2.0)<br>2020년, 인공지능 규제 가이드라인 발표(Guidance for Regulation of AI Application)<br>2020년, 인공지능 및 알고리즘 이용지침(FTC, Using AI and algorithm) |
| 영국 | 2016년, 로봇과 인공지능 (UK House of Common)<br>2018년, 데이터 윤리 프레임워크 7원칙 (Data Ethics Framework)<br>2019년, 공공분야 인공지능 활용 지침 (A guide to using AI in the public sector)<br>2020년, 설명 가능한 인공지능 가이드라인 (ICO, Guidance on AI and Data protection)                                                                                                                                                                                                             |
| 독일 | 2017년, 자율주행자동차 윤리 가이드라인 (Ethics Commission Automated and Connected Driving)<br>2021년, 독일 Level 4 자율주행차량 정부안 발표                                                                                                                                                                                                                                                                                                                                 |
| 일본 | 2016년, 인공지능 R&D 안정성 확보 8대 원칙(Securing AI R&D stability)<br>2017년, 인공지능 연구 개발 가이드라인 (AI R&D Guidelines)<br>2018년, 인공지능 활용 원칙(안) (Principles of using Artificial intelligence)<br>2019년, 인간중심 인공지능 사회원칙(안) (Social Principles of Human-Centric AI)                                                                                                                                                                                               |
| 중국 | 2017년, 차세대 인공지능 발전계획<br>2019년, 베이징 AI 윤리 가이드라인 (Beijing AI Principles)                                                                                                                                                                                                                                                                                                                                                                         |
| 기타 | 1942년, 로봇 3원칙 (러시아 작가: 아이작 아시모프의 소설에서 언급)<br>1985년, 로봇 3원칙에 0 법칙 추가<br>2021년, 유네스코 인공지능 윤리 권고                                                                                                                                                                                                                                                                                                                                                  |

된 ‘Scaling AI’을 연구 개발하였다. 특히 ‘Trusting AI’ 구현은 인공지능 분야의 윤리적 측면에서 많은 관심을 끌고 있다. 인공지능 기술 발전 초창기에는 로봇 분야에 집중되었다. 산업용 로봇에서 시작하여 인간과 상호작용하는 로봇으로 발전하면서 로봇 분야에서 인공지능 윤리가 연구되고 윤리 가이드라인이 개발되었다. 이후 자율주행자동차, 개인비서, 챗봇, 헬스케어, 군사용 로봇, 메타버스, 인터넷 서비스 등 전 분야로 확대되고 있다.

인공지능 기술이 가장 발전하고 있는 미국은 정부 차원에서 매우 적극적으로 인공지능의 사회적 영향과 관련된 연구를 진행하고 있으며, 규범 수립과 기술 적용 방안은 기업과 학계에서 주로 이루어지고 있다. 2016년 3월 미국 백악관은 이른바 ‘빅데이터 알고리즘의 윤리적 가이드라인(Big Data: A Report on Algorithmic System, Opportunity and Civil Right)’이라는 보고서를 통하여 빅데이터 분석 및 머신러닝과 알고리즘 자체의 내부 작용에 의한 왜곡, 차별, 편견 등의 위험성을 경고하였다(미국 백악관, 2016). 미국의 자율주행자동차 운행과 관련하여 각 주마다 선제적으로 입법화를 추진하고 있으며, 윤리 가이드라인을 적용하는 방안을 모색하고 있다. 2017년에는 ‘NHTSA의 자율주행자동차 설계 지침’을 통하여 안전과 운영 설계 범위, 사이버 보안, 데이터 기록, 위기 상황 최소화, 인증 방법, 소비자 교육 및 훈련 등의 기준과 원칙을 제시하였다. IEEE SA에서는 수년 전부터 자동화 지능형 시스템을 위한 윤리 표준(The IEEE Global Initiative on Ethics of Autonomous and Intelligent Systems)을 P7000 시리즈로 개발 중이며, P7010은 2020년에 표준으로 공표되었다.

2019년 유럽연합은 ‘신뢰성 있는 AI의 윤리 가이드라인’을 발표하였다. 주요 내용으로는 인간 존엄성의 존중과 개인의 자유, 민주주의, 정의 및 법치 존중, 그리고 평등, 차별 금지 및 연대 배제 위험에 있는 사람의 권리에 대해 제시하였다. 인공지능을 훈련할 때 사용되는 데이터는 다른 표본 집단을 대표할 만큼 포괄적이어야 한다고 명시하고 있으며 윤리 4대 원칙으로 인간 자율성 존중, 피해 방지, 공정성, 설명 가능성을 들었다. 유럽 집행위원회는 유럽을 위한 인공지능의 실행계획을 적극적으로 발표하며, 무엇보다 유럽은 공공영역 분야에서 데이터 이동 및 재사용을 늘리고 있으며, 디지털 싱글 마케팅의 추진을 강화하고 있다. 유럽의 적극적인 추진 실행력은 유럽이 미국이나 중국에 비하여 인공지능 산업의 발전 속도가 떨어지고 있다는 현실적인 위기감이 상당히 반영되었다고 볼 수 있다(Factsheet, 2018). 2018년부터 2년 간 연구하여 2020년에 공개한 ‘신뢰할 수 있는 인공지능 자체 평가 목록(ALTAI)’은 인간과 인공지능 간의 상호작용에 의한 인간 존중과 감독, 사회적

영향, 알고리즘 투명성, 견고성, 개인정보 보호 및 데이터 거버넌스, 책무성, 소비자 보호 및 차별 금지, 안전성과 보안성 등 유럽연합 기본권 헌장에 미치는 영향을 고려하여 개발되었다(ALTAI, 2020). 특히 인공지능 개발을 견제하는 GDPR 준수 의무를 비롯하여 디지털 싱글 마켓과 인공지능 기반 데이터 공유, 인공지능 정책의 연계 확대 및 데이터 활용 활성화로 비용 절감을 추진하고 있다.

독일에서는 2017년에 연방 교통디지털인프라부에서 ‘자율주행자동차 윤리가이드라인’을 제정하여 발표하였으며, 2021년 2월에 ‘독일 자율주행차량 정부안’을 발표하였다. 독일은 평등대우법(Allgemeines Gleichbehandlungsgesetz, AGG)에 더하여 인공지능 알고리즘이 불러오는 차별에 대응하기 위한 ‘디지털 차별방지법(digitales Antidiskriminierungsgesetz)’의 입법을 추진한 바도 있다(선지원, 2019).

영국 정부는 2018년에 ‘민간과 인공지능 분야 협력(AI Sector Deal)’을 발표하면서 데이터 기반의 혁신으로 인공지능 산업을 육성하겠다는 비전을 제시하였다. 2018년에 ‘데이터 윤리 프레임워크 7원칙’과 2019년에 ‘공공분야 인공지능 활용지침’, 2020년에 ‘인공지능 및 데이터 보호에 대한 지침’을 발표하였다.

중국에서는 2017년에 ‘차세대 인공지능 발전 계획’을 발표하였으며, 강력한 의지와 비전으로 3단계 전략목표와 6대 중점 임무로 구성된 발전 계획이다. 6대 주요 임무로는 개방형·협동형 인공지능 기술 혁신 체계 구축, 고효율 스마트 경제의 육성, 안전하고 편리한 스마트 사회 건설, 인공지능 영역의 군민융합 강화, 안전하고 효율성 높은 스마트 인프라 체계 구축, 중대 과학기술 프로젝트 계획이 포함되었다(중국의 인공지능전략, 2017). 바이두, 알리바바, 텐센트 등 중국 3대 IT 기업들은 자율주행 자동차, 드론, 로봇, 인공지능 등과 같은 기술에 대규모 투자를 진행하면서 미래 혁신 분야에서 미국 기업들을 추월하였으며, 4차 산업에서 인공지능 특허출원이 미국을 추격하여 세계 1위 수준에 올랐다. 인공지능 윤리가 사회에 미치는 영향이 높기에 중국의 인공지능 윤리 정책과 지침, 법규 정비, 제품이나 서비스에 어떻게 반영되는지 각국의 관심 사항이 되고 있다.

## 2. 국내 인공지능 윤리 기준 및 정책 추진 동향

국내의 인공지능 기술은 원천기술보다는 응용 기술 분야에서 비약적인 발전을 하고 있으며, 정부 차원에서 인공지능 기술과 인간 중심의 신뢰할 수 있는 인공지능 전략을 추진하고 있다. 최근에는 인공지능의 응용 기술 개발을 위한 오픈소스 소프트웨어 활용 환경이 잘 구축되어 있어 기업에서 인공지능 제품이나 서비스를 개발하는데 비교적 쉽게 기술 개발이 가능해졌다. 이에 따라 인공지능과 관련된 서비스 제품, 앱, 웹 서비스 등이 다양한 분야에서 다량으로 개발되어 시장에 나오고 있으며, 그에 따른 위험과 부작용 또한 지속적으로 발생하고 있다.

스캐터랩은 2021년 1월 인공지능의 챗봇 서비스인 ‘이루다’가 정식 서비스 20일 만에 사회적 파장을 크게 일으키며 운영을 중단하는 사태가 발생하였다. 챗봇을 활용하는 사용자가 성희롱, 부적절한 단어, 차별적 발언, 혐오스러운 단어, 개인정보 유출 문제 등 심각한 부작용 문제가 도출되었다(전자신문, 2021). 이후 스캐터랩은 서비스 중단 1년 9개월 만인 2022년 10월, 새로운 버전으로 ‘이루다 2.0’을 출시하였다. 스캐터랩은 AI 챗봇 윤리 점검표<sup>8)</sup>를 공개하였으며, 이를 ‘이루다 2.0’에 적용해 인공지능 윤리 문제를 단계적으로 해결해 나가고 있다(인공지능신문, 2022). 국내에서도 인공지능 윤리에 대해 2018년에 카카오에서 알고리즘 윤리 현장을 발표하였으며, 카이스트에서도 ‘인공지능을 위한 윤리 현장’을 발표하였고, 2019년에는 국제인공지능&윤리협회에서 ‘인공지능 윤리 현장’을 발표한 바 있다. 그러나 아직 기업에서는 인공지능 윤리에 대한 관심도가 낮으며, 인공지능 시스템 설계 및 개발자의 인식 수준이 현저하게 낮은 상태이기 때문에 ‘이루다’ 챗봇 서비스 같은 사태가 발생하였다고 볼 수 있다.

2019년에 방송통신위원회에서는 ‘이용자 중심의 지능정보사회를 위한 원칙’을 발표하였으며, 과학기술정보통신부는 2020년 12월에 ‘국가 인공지능 윤리기준(안)’을

8) 스캐터랩 AI 윤리(AI 챗봇 윤리점검표), <https://team.luda.ai/ai-ethics>, 2022

발표하였다. 국가 인공지능 윤리 기준에는 3대 기본 원칙과 10대 핵심 요건이 포함되어 있다. 2021년 4월에는 대통령 직속 4차산업혁명위원회 제22차 전체회의에서 사람 중심의 인공지능 실현을 위한 ‘신뢰할 수 있는 인공지능 실현 전략’을 발표하였다. 추진전략에는 신뢰 가능한 인공지능 구현 환경조성, 안전한 인공지능 활용 기반 마련, 사회 전반 건전한 인공지능 의식 확산이 포함되어 있다(과학기술정보통신부, 2021). 2021년 7월에는 ‘인공지능 육성 및 신뢰 기반 조성 등에 관한 법률(안)’이 국회에서 발의되었다. 인공지능산업 육성을 도모하면서 인간이 인공지능 개발, 제공 및 이용에 있어서 지켜야 할 윤리적 원칙 등을 규정하였으며, 이를 바탕으로 인공지능을 신뢰할 수 있도록 기반을 마련하고자 하였다(국회입법조사처, 2021). 인공지능 윤리가 사회에 미치는 영향이 크기 때문에 국가 차원에서 정책 수립 및 법·제도를 만들 수 있도록 하고 있다. [표 2-4]는 국내 인공지능 윤리 가이드라인 및 정책 추진 현황이다.

[표 2-4] 국내 인공지능 윤리 가이드라인 및 정책 추진 현황

| 년 도  | 내 용                                                                                                                                                                                      |
|------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 2018 | <ul style="list-style-type: none"> <li>· 카카오, 알고리즘 윤리 헌장 발표</li> <li>· 카이스트, 인공지능을 위한 윤리 헌장 발표</li> <li>· 한국지능정보사회진흥원, 지능정보사회 윤리 가이드라인</li> </ul>                                        |
| 2019 | <ul style="list-style-type: none"> <li>· 한국인공지능&amp;윤리협회, 인공지능 윤리 헌장 발표</li> <li>· 방송통신위원회, 이용자중심의 지능정보사회를 위한 원칙 발표</li> </ul>                                                           |
| 2020 | <ul style="list-style-type: none"> <li>· 과학기술정보통신부, 국가 인공지능 윤리 기준(안)</li> <li>· 국토교통부, 자율주행자동차 윤리 가이드라인</li> </ul>                                                                       |
| 2021 | <ul style="list-style-type: none"> <li>· 한국인공지능&amp;윤리협회, 인공지능 윤리 헌장 개정 발표</li> <li>· 과학기술정보통신부, 신뢰할 수 있는 인공지능 실현 전략</li> <li>· 국회, 인공지능 육성 및 신뢰 기반 조성 등에 관한 법률(안) 발의(21.7.1)</li> </ul> |
| 2022 | <ul style="list-style-type: none"> <li>· 교육부, 교육분야 인공지능 윤리원칙</li> <li>· 국가인권위원회, 인공지능 개발과 활용에 관한 인권 가이드라인</li> <li>· 과학기술정보통신부, 2022 신뢰할 수 있는 인공지능 개발 안내서(안)</li> </ul>                  |

2022년에는 교육부에서 사람의 성장을 지원하는 ‘교육 분야 인공지능 윤리원칙’을 발표하였다. 교육부는 교육기본법 제17조의3 등에 근거하여 자발적 실천과 준수를 독려하는 도덕적 규범 및 자율규제가 가능하도록 대원칙을 사람의 성장을 지원하는 인공지능으로 하였으며, 세부 원칙은 10개 항목으로 구성하였다. 실천 과제로는 인공지능 교육과 역량을 강화하고 윤리 이슈 발굴 및 연구지원, 현장 적용 지원, 인공지능 개발 지원을 포함하였다. 국가인권위원회에서는 국가인권위원회법 제25조 제1항에 따라 인권적 관점에서 인공지능을 개발할 때부터 개인의 삶과 사회적 공익에 기여할 수 있도록 개발하고, 인간의 존엄성과 자기 결정권의 보장 및 차별받지 않을 권리 등 인권 기반하에 활용하며, 인공지능 기술로 발생할 수 있는 인권침해의 예방 및 권리 구제 절차를 마련하기 위한 인권 가이드라인을 만들었다. 주요 내용으로는 인간의 존엄성, 투명성과 설명 의무, 자기결정권의 보장, 차별금지, 인공지능 인권 영향평가 시행, 위험도 등급 및 관련 법제도 마련 등이 포함되었다. 인공지능 기술 개발과 관련해서는 과학기술정보통신부에서 ‘2022 신뢰할 수 있는 인공지능 개발 안내서’를 발간하였으며, 개발 안내서에는 14개의 요구사항 목록과 각 요구사항과 매칭되는 59개 정성·정량적 검증항목을 제시하였다.

한국인공지능&윤리협회에서는 2021년도에 ‘인공지능 윤리 헌장’을 개정하여 공표하였으며, 민간 차원에서 지속적인 인공지능 윤리에 대한 인식 제고 및 연구, 인증 및 개발 적용방안에 대하여 확대 사업을 진행하고 있다. 기업에서는 카카오가 2018년에 ‘알고리즘 윤리 헌장’을 발표하고 자사 홈페이지에 윤리 헌장을 게재하여 알리고 있으며, 네이버 또한 ‘인공지능 윤리 준칙’을 제정하여 인공지능 개발과 이용에 있어 인공지능 윤리 준칙을 준수할 수 있도록 자사 홈페이지에 게재하였다. 주요 내용으로는 사람을 위한 인공지능 개발, 다양성의 존중, 합리적인 설명과 편의성의 조화, 안전을 고려한 서비스 설계, 프라이버시 보호와 정보 보안을 포함하고 있다. SK텔레콤에서는 구성원과 이해관계자들이 함께 공유하고 지킬 수 있는 ‘SKT 인공지능 추구 가치’를 선포하였으며, 핵심 내용으로는 사회적 가치, 지속 혁신, 사생활 보호, 무해성, 투명성, 공정성, 기술 안정성을 담고 있다.

### 3. 국내외 인공지능 윤리 기준 및 정책 관련 주요 쟁점

인공지능 윤리에 대하여 본격적으로 관심을 갖고 정책 수립 및 연구를 시작한 시기는 10년이 채 되지 않는다. 주요 선진국을 중심으로 정부와 연구기관, 학계에서부터 시작하여 기업으로 확대되었다. 인공지능 윤리 문제는 사회체계에 미치는 영향이 높기 때문에 인공지능 기술과 윤리, 법·제도, 교육이 체계적으로 연결되어 발전되어야 효과를 높일 수 있다. 따라서 국가 차원에서 경쟁력 확보를 위한 인공지능 구축 전략이 필요하다. 이에 각국은 자국의 사회체제와 기술, 문화, 정치, 경제 등 다양한 사회적 환경의 특성을 바탕으로 발전하고 있다. 미국, EU, 영국, 프랑스, 독일, 일본 등 주요 선진국은 정부 및 유관 단체에서 인공지능 윤리 가이드라인, 윤리 원칙, 윤리 헌장, 개발 지침, 규범, 법제도, 추진 동향 등을 발표하면서 세부 추진전략을 수립하여 실행하고 있다. 학계에서는 인공지능 윤리와 관련된 특성을 중심으로 관련 편향성, 공정성, 책무성, 투명성, 안전성 등에 관한 논문 발표가 많아지고 있다. [표 2-5]는 국내외 인공지능 윤리 관련 문헌과 보고서, 법·제도, 제품 및 서비스 등을 분석하여 요약한 인공지능 윤리 주요 쟁점 현황이다.

인공지능 윤리에 대하여 가장 큰 쟁점으로는 인간 존중, 신뢰성, 인권보장, 안전성, 공정성, 투명성 등이 있다. 첫째, 인간 존중은 인공지능이 인간과 상호작용하면서 미치는 영향이 매우 크기 때문에 인간에게 자율성이 보장되어야 하며, 인공지능에 의한 의사결정이 인간에게 위협이나 위험, 피해가 가지 않도록 인간이 주체가 되어 의사결정권을 행사할 수 있도록 하는 내용이 포함된다. 둘째, 신뢰성은 인간이 인공지능을 사용하는데 의사결정의 오류, 통제권 상실, 편향적인 판단 등에 의하여 인간에게 피해가 가지 않도록 인공지능을 믿고 사용할 수 있도록 하는 내용이 포함된다. 셋째, 인권보장은 인간이 인공지능에 의하여 자기 결정권 상실, 사용의 제약, 차별 등으로 인하여 인격이 상실되거나 인간의 권리를 침해하지 않도록 해야 하는 내용이 포함된다. 넷째, 안전성은 인공지능을 사용하는 데 있어서 기술적, 물리적

결함으로 인한 위험, 개인정보 침해, 오용, 악의적인 공격으로부터의 위험 등 인간에게 안전성이 확보될 수 있도록 해야 하는 내용이 포함된다. 다섯째, 공정성은 인공지능이 데이터 처리 과정에서부터 인공지능 기능을 이용하는 모든 단계에서 특정 개인이나 인종, 집단, 성별, 사회체제 등에 차별되거나 편향되지 않도록 공정하게 보장할 수 있도록 해야 하는 내용이 포함된다. 여섯째, 투명성은 인공지능에 의하여 어떤 행위가 왜 발생했는지 혹은 어떤 행위가 왜 발생하지 않았는지를 명확하게 검증할 수 있도록 설명할 수 있어야 하고 문제 분석을 위한 추적이 가능해야 하며, 이해관계자에게 검증받을 수 있도록 해야 하는 내용이 포함된다.

[표 2-5] 국내외 인공지능 윤리 관련 주요 쟁점 현황

| 문헌 구분                       | 주요 윤리적 쟁점                                                                                                                                                                                  |
|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 해외 인공지능 윤리 가이드라인, 지침 (10 종) | <ul style="list-style-type: none"> <li>· 일반 원칙으로 투명성, 책무, 효과, 복지, 데이터 기관, 인권, 복지 항목이 쟁점으로 나타남</li> <li>· 윤리와 가치문제로는 안전, 책임, 위험, 개인 정보보호, 투명성, 프라이버시 보호, 통제, 공정, 신뢰 등이 쟁점으로 나타남</li> </ul>  |
| 국내 인공지능 윤리 가이드라인, 지침 (6 종)  | <ul style="list-style-type: none"> <li>· 인간 존중, 사회의 공공성, 연대성, 합목적성, 차별 금지, 편향 방지</li> <li>· 인권보장, 프라이버시 보호, 안전, 공정, 책임, 투명, 신뢰, 데이터 관리, 책무, 개발자 윤리, 소비자 윤리, 알고리즘 윤리 등이 쟁점으로 나타남</li> </ul> |
| 인공지능 윤리 관련 정책, 보고서 (15 종)   | <ul style="list-style-type: none"> <li>· 인간 존중, 인격권, 검증, 가치정렬, 책임식별, 표준성, 접근성 등</li> <li>· 안전하고 신뢰 가능한 인공지능, 사회의 공공성, 투명성, 안전성, 책임, 데이터 관리, 신뢰, 프라이버시 보호 등이 주요 쟁점으로 나타남</li> </ul>         |
| 인공지능 관련 논문, 서적 (20 종)       | <ul style="list-style-type: none"> <li>· 신뢰성, 안전성, 보안, 통제, 책임 식별, 법·제도, 평가, 검증 등</li> <li>· 인간의 존엄성, 프라이버시 보호, 투명성, 책임, 공정성, 편향성, 자율, 제어, 안전, 보안 등의 쟁점으로 나타남</li> </ul>                    |
| 인공지능 개발, 제품, 서비스 관련 (6 종)   | <ul style="list-style-type: none"> <li>· 개인정보보호 및 안전성, 보안, 통제, 책임, 책무, 공정한 서비스, 신뢰, 투명성, 위험, 행위 주체별 책임 등이 쟁점으로 나타남</li> </ul>                                                              |

해외 인공지능 윤리 가이드라인 및 지침 10종을 검토한 결과 일반원칙으로 투명성, 책무성, 복지, 효과성, 데이터 기관, 인권, 복지 항목이 쟁점으로 나타났으며, 윤리와 가치문제로는 안전성, 책임, 책무성, 위험, 개인 정보보호, 투명성, 프라이버시 보호, 통제성, 공정성, 신뢰성 등이 쟁점으로 나타났다. 해외의 가이드라인은 대부분 윤리원칙 기반하에 세부 지침으로 구성되어 있으며, 지속적인 업데이트를 통하여 인공지능 기술과 병행하여 윤리 가이드라인을 개정하고 있다. 국내 인공지능 윤리 가이드라인 및 지침 6종을 검토한 결과 인간 존중, 사회의 공공성, 연대성, 합목적성, 차별 금지, 편향 방지, 인권보장, 프라이버시 보호, 안전, 공정, 책임, 투명, 신뢰, 데이터관리, 책무, 개발자 윤리, 소비자 윤리, 알고리즘 윤리 등이 쟁점으로 나타났다. 국내의 인공지능 윤리 분야는 주요 선진국에서 선행연구, 발표된 윤리 가이드라인을 참조하여 국내 실정에 적합하도록 연구하여 윤리 가이드라인을 제정하였다.

최근 국내 정부 기관을 중심으로 기관별 특성에 맞는 인공지능 윤리 가이드라인이나 지침 개발을 연구용역으로 발주하는 사례가 증가하고 있으며, 인공지능 윤리 관련 법·제도 연구가 활발히 진행되고 있다. 그 결과로 인공지능 윤리 관련 정책 및 보고서가 꾸준히 증가하고 있다. 그중 15종을 검토한 결과 인간 존중, 인격권, 검증, 가치 정렬, 책임식별, 표준성, 접근성, 안전하고 신뢰 가능한 인공지능, 사회의 공공성, 투명성, 안전성, 책임, 데이터관리, 신뢰, 프라이버시 보호 등이 주요 쟁점으로 나타났다. 인공지능 기술이 급속도로 발전하고 있기에 인공지능 학습용 데이터 구축 가이드라인, 인공지능 개발 윤리 가이드라인, 인공지능 윤리 교육 지침 등이 발표되고 있으며, 각 원칙별 세부 지침과 목록까지 만들어지고 있다. 인공지능 관련 논문 및 서적 20종을 검토한 결과 신뢰성, 안전성, 보안, 통제, 책임식별, 법제도, 평가, 검증, 인간의 존엄성, 프라이버시 보호, 투명성, 책임, 공정성, 편향성, 자율성, 제어, 안전성, 보안 등이 쟁점으로 나타났다. 인공지능 개발 제품, 서비스 관련하여 6종을 검토한 결과 개인정보보호 및 안전성, 보안, 통제, 책임, 책무, 공정한 서비스, 신뢰, 투명성, 위험, 행위 주체별 책임 등이 쟁점으로 나타났다.

## 제 3 절 인공지능 윤리 관련 선행 연구

### 1. 인공지능의 윤리적 특성

가. 국내외 주요 인공지능 윤리 가이드라인의 윤리원칙 및 특징

인공지능 기술 발전과 함께 윤리적 문제가 대두되면서 인간과 인공지능의 상호작용, 인간 존중, 인격권 보장, 위험 회피, 안전성 확보, 신뢰성 확보, 보편적 활용 등 다양한 쟁점들을 윤리적 특성으로 정의하여 인공지능 원칙, 윤리원칙, 윤리헌장, 윤리 가이드라인, 개발 지침 등을 만들고 있다. [표 2-6]은 국내외 주요 인공지능 윤리원칙에 관한 내용 및 특징이다. 미국은 정부기관 및 민간단체, 기업을 중심으로 인공지능 원칙을 제정하여 인공지능의 활용 가치, 공익, 인간과의 가치 정렬, 자유와 번영 등을 제시하였으며, EU, 영국 등은 인간의 존엄, 인권, 평등, 거버넌스, 책임 등 인간의 인격을 중점적으로 제시하였다. 일본은 로봇산업이 발전한 관계로 인간중심의 인공지능과 혁신성을 강조하면서 인공지능과 관련된 윤리원칙이 만들어지고 있다. 중국은 인공지능이 사회와 인류 환경에 이롭게 하는 사회적 생태계를 만들고, 책임과 제어, 사용자에게 대한 원칙을 제시하면서 인공지능의 거버넌스와 장기적 계획이 포함된 원칙을 제정하였다. 우리나라는 이용자 중심의 지능정보사회를 위한 원칙에서 사람 중심의 서비스 제공을 중심으로 윤리원칙을 정하고 있으며, 현재는 각 정부 기관별 특성에 맞도록 인공지능 원칙을 개발하고 있다. 2021년에 유네스코에서 193개국이 찬성하여 인공지능 윤리 권고안이 만들어져 발표되었다. 인공지능 윤리가 세계적인 관심과 미래 사회에 미치는 영향이 크기 때문에 인공지능의 건전한 발전을 보장하는데 필요한 가치와 원칙에 의한 내용이 141개 항목으로 만들어졌으며, 인공지능 기술이 인간의 인권과 기본적 자유를 침해하지 않도록 세계 최초의 인공지능 윤리 글로벌 프레임워크를 만들었다.

[표 2-6] 국내외 인공지능 윤리원칙 및 특징

| 국가                       | 주 제 목                                                                  | 주요 원칙                                                                        | 특 징                                                                                                                                                                                                 |
|--------------------------|------------------------------------------------------------------------|------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| EU,<br>EURON             | Roboethics<br>Roadmap<br>(2007)                                        | 인간의 존엄성, 인권, 평등, 정의, 이익과 피해, 문화 다양성과 다원주의 존중, 차별 금지, 자율                      | <ul style="list-style-type: none"> <li>· Robotics R&amp;D와 관련된 윤리적 문제에 대한 체계적인 평가를 제공</li> <li>· 위험 문제에 대한 이해를 높이고 추가 연구 및 학제 간 연구 촉진</li> </ul>                                                    |
| 미국,<br>IEEE              | Ethically<br>Aligned Design<br>(2016, 2017)                            | 인권, 복지, 데이터 기관, 효과성, 투명성, 책임성, 오용에 대한 인식, 개발자의 능력                            | <ul style="list-style-type: none"> <li>· AI 윤리를 활용 가치와 필요성</li> <li>· AI 윤리의 지속 가능한 문화를 만들기 위한 권장 사항, 필요 기술, 직원 고용 방법</li> <li>· AI 윤리 준비 프레임워크, 도입 준비 확인</li> </ul>                                |
| 미국,<br>국가과<br>학기술<br>위원회 | Preparing for<br>the Future of<br>Artificial<br>Intelligence<br>(2016) | 공정성, 안전, 투명성, 이해 가능성, 공공선, 인간 가치, 선을 위한 AI                                   | <ul style="list-style-type: none"> <li>· 공익을 위한 AI의 응용과 규제 접근 방식</li> <li>· AI 발전에 의한 사회 및 공공 정책 제기</li> <li>· 연방기관 및 기타 행위자의 구체적 추가 조치에 대한 권장 사항 제시(23개 항목)</li> <li>· AI 연구 및 개발 전략 계획</li> </ul> |
| 미국,<br>민간단<br>체          | Asilomar AI<br>Principles<br>(2017)                                    | 안전, 투명성, 책임성, 가치정렬, 인간의 가치, 자유와 프라이버시, 이익 공유, 번영, 인간 통제                      | <ul style="list-style-type: none"> <li>· 연구 관련 쟁점(5개항), 윤리와 가치 (13개항), 장기적 이슈(5개항)</li> <li>· 민간 비영리 기관 차원에서 학계, 엔지니어, 기업, 저명인사가 참여함</li> </ul>                                                     |
| 일본,<br>총무성               | 인간 중심의 AI<br>사회원칙<br>(2019)                                            | 인간 중심, 보안, 공정경쟁, 공정성, 책무성, 투명성, 개인정보 보호, 교육 교양, 혁신, 보안                       | <ul style="list-style-type: none"> <li>· 일본이 처한 어려운 상황을 AI가 해결할 수 있을 것으로 상정하여 AI를 공공재로 활용</li> <li>· 지속 가능한 변화, 혁신, 발전 추구</li> <li>· 고령화, 지방 쇠퇴, 재해 재난, 저출산 해결</li> </ul>                           |
| EU,<br>집행위<br>원회         | Ethics<br>Guidelines for<br>Trustworthy AI<br>(2019)                   | 4원칙(자율성, 무해성, 공정, 설명가능성), 적법성, 윤리성, 견고성, 프라이버시, 투명성, 책임성, 다양성, 비차별성          | <ul style="list-style-type: none"> <li>· AI 윤리적 목적, AI가 준수할 기본권, 기본 원칙과 가치를 제안</li> <li>· 신뢰할 수 있는 인공지능 구현 방안</li> <li>· AI 신뢰성 평가목록 제시</li> </ul>                                                  |
| 중국,<br>BAAI              | Beijing AI<br>Principles<br>(2019)                                     | 이로움, 인류, 책임, 제어 위험, 윤리적, 다양과 포용, 개방과 공유, 적절한 사용, 고용 최적화, 사전 동의, 교육훈련, 조화와 협력 | <ul style="list-style-type: none"> <li>· AI의 연구 및 개발, 사용, 거버넌스, 적응 및 조정, 세분화 및 구현, 장기 계획을 위한 이니셔티브로 제안</li> <li>· 인간 커뮤니티의 건설 지원, 유익한 AI 실현 지원에 의한 AI의 건전한 개발 요구</li> <li>· 인간과 자연</li> </ul>       |

|                          |                                                             |                                                                                |                                                                                                                                                                                                |
|--------------------------|-------------------------------------------------------------|--------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 한국,<br>방송통신위원회           | 이용자 중심의<br>지능정보사회를<br>위한 원칙<br>(2019)                       | 사람 중심의 서비스 제<br>공, 책임성, 투명성, 설명<br>가능성, 안전성, 프라이<br>버시, 차별 금지, 참여,<br>데이터 거버넌스 | <ul style="list-style-type: none"> <li>· 이용자 중심의 지능정보사회 실현 목표</li> <li>· 이용자 보호 선제적 대응</li> <li>· ICT 기업과 전문가 의견 수렴</li> <li>· 모든 구성원이 고려할 공동 기본 원칙 제시</li> </ul>                              |
| 미국,<br>FTC               | Using Artificial<br>Intelligence and<br>Algorithm<br>(2020) | 투명성, 설명가능성, 공<br>정성, 견고성 및 실증적<br>타당성, 책임성                                     | <ul style="list-style-type: none"> <li>· 기업이 AI 및 알고리즘의 소비자 보호 위험<br/>을 관리할 수 있는 방법 제공</li> <li>· AI 도구의 사용이 투명하고, 설명 가능하고,<br/>공정하고, 경험적으로 건전과 책임 강조</li> </ul>                               |
| 영국,<br>정보위<br>원회         | Guidance on AI<br>and Data<br>Protection<br>(2020)          | 책임 및 거버넌스 합의,<br>적법성, 공정성 및 투명<br>성 보장, 보안 및 데이터<br>최소화, 개별 권리 준수              | <ul style="list-style-type: none"> <li>· 기업이 데이터 보호 관점에서 위험을 평가하<br/>고 완화할 수 있는 방법 프레임워크 제공</li> <li>· AI 개발 초기 단계부터 데이터 보호 및 위험<br/>완화 방법 제시</li> <li>· AI 관련 기술 전문가, 규정 준수 역할 수행자</li> </ul> |
| 한국,<br>과학기술<br>정보<br>통신부 | 국가 인공지능<br>윤리 기준(안)<br>(2020)                               | 인간 존엄성, 기술의 합<br>목적성, 사회의 공공선                                                  | <ul style="list-style-type: none"> <li>· 사람 중심의 인공지능 구현</li> <li>· 최고의 가치로 인간성(Humanity) 설정</li> <li>· 10대 핵심 요건과 기본 원칙 실현을 위한 세<br/>부 요건</li> </ul>                                           |
| UNESCO                   | 인공지능 윤리<br>권고<br>(2021)                                     | 데이터 보호 강화, 사회<br>적 점수 평가, 대량 감시<br>금지, 환경 보호, 모니터<br>링과 평가 지원                  | <ul style="list-style-type: none"> <li>· AI 기술이 인권·기본적 자유 침해 방지</li> <li>· AI의 건전한 발전을 보장하는데 필요한 가<br/>치와 원칙에 관한 내용 (141개 항목)</li> <li>· 최초의 글로벌 프레임워크로 193개국 찬성</li> </ul>                    |
| 한국,<br>교육부               | 교육 분야<br>인공지능<br>윤리원칙(안)<br>(2022)                          | 대원칙: 사람의 성장을<br>지원하는 인공지능, 10대<br>세부 원칙                                        | <ul style="list-style-type: none"> <li>· AI 발전에 따른 AI 교육 환경 변화와 윤리적<br/>이슈에 대응</li> <li>· 교육에 특화된 윤리 원칙</li> <li>· 자발적 실천과 준수를 독려하는 도덕적 규범<br/>및 자율 규제</li> </ul>                              |

#### 나. 아실로마 AI 원칙

2017년 미국의 아실로마에서 세계 유수의 인공지능 전문가들이 참여하여 ‘이로운 AI 회의(Beneficial AI Conference)’를 열고 ‘미래 인공지능 연구의 23가지 원칙’을 만들었으며 이것을 ‘아실로마 AI 원칙(Asilomar AI Principles)’이라 하였다. 이 행사에서 알파고의 개발책임자 데미스 허사비스 딥마인드 CEO, 테슬라 최고경영자

일론 머스크, 우주 물리학자 스티븐 호킹, 구글 기술이사 레이 커즈와일 등을 포함한 전문가 100여 명 이상이 참가하여 참가자 90% 이상의 동의를 받고 그 후 인공지능 및 로봇공학 연구자 등 2천여 명이 서명하였다(FLI, 2017). [표 2-7]은 아실로마 AI 원칙 23가지 항목 현황<sup>9)</sup>이다.

[표 2-7] 아실로마 AI 원칙 23항목

| 구 분         | 윤리 원칙      | 세부 지침                                |
|-------------|------------|--------------------------------------|
| 연구 관련<br>쟁점 | 연구 목표      | 인간에게 이로운 인공지능 개발                     |
|             | 연구비 지원     | 인공지능 투자는 인간에게 이익과 번영을 보장을 수반해야 함     |
|             | 과학정책 연계    | 인공지능 연구자와 정책 입안자 간 건설적이고 건강한 교류      |
|             | 연구문화       | 인공지능 개발자와 연구자 간 협력, 투명성, 신뢰성 문화 조성   |
|             | 경쟁 회피      | 인공지능 개발팀들은 부실한 안전기준을 피하기 위한 능동적 협력   |
| 윤리와<br>가치   | 안전         | 인공지능 전 수명 기간에 안전·안정적이며 적용·구현 검증 가능   |
|             | 장애의 투명성    | 인공지능이 피해 유발 시 그 이유를 확인할 수 있어야 함      |
|             | 사법적 투명성    | 권한이 있는 감사 당국에 만족할 만한 설명을 제공해야 함      |
|             | 책임성        | 인공지능 설계자 및 구축자는 인공지능의 책임과 기회를 가짐     |
|             | 가치 정렬      | 인공지능 작동은 목표와 행동이 인간의 가치와 일치하도록 설계    |
|             | 인간의 가치     | 인간의 존엄, 권리, 자유, 문화적 다양성에 적합하도록 설계·운용 |
|             | 개인정보 보호    | 사용자에게 데이터 접근, 관리, 통제의 권한 부여          |
|             | 자유와 프라이버시  | 개인 데이터에 대한 실제, 인지하는 자유를 부당하게 축소 제한   |
|             | 이익의 공유     | 인공지능 기술은 가능한 한 많은 사람에게 이로운 제공        |
|             | 번영의 공유     | 인공지능에 의한 경제적 번영은 모든 인류에게 혜택 공유       |
|             | 인간 통제      | 인간이 인공지능의 의사결정 선택과 목표를 달성할 수 있도록 함   |
|             | 사회 전복 방지   | 인공지능의 통제는 사회적, 시민적 절차를 존중하고 개선해야 함   |
|             | 인공지능 무기 경쟁 | 치명적인 자동 무기에 대한 군비 경쟁을 피해야 함          |
| 장기적<br>이슈   | 역량 경계      | 미래 인공지능 능력의 상한선에 관한 강한 가정을 피해야 함     |
|             | 중요성        | 지구 생명의 역사에 중대한 변화 방지를 위한 관심과 자원관리    |
|             | 위험성        | 인공지능의 실재·잠재적 위험 영향에 대한 계획과 완화 노력     |
|             | 반복적 자기 개선  | 반복적 자기 개선된 인공지능은 엄격한 안전과 통제 조치 필요    |
|             | 공동의 선      | 인공지능은 윤리적 이상과 모든 인류의 이익을 위해 개발되어야 함  |

9) Future of Life, <https://futureoflife.org/open-letter/ai-principles>, 2017

다. 지능정보사회 구현을 위한 공통원칙

한국지능정보사회에서 2018년도에 발간한 ‘지능정보사회 윤리 가이드라인’은 인간 중심의 지능정보사회를 구현하기 위하여 지능 정보기술 및 서비스 개발자·공급자의 책임 윤리 강화와 이용자의 오남용 방지를 위한 지침을 제공할 목적으로 작성되었다(한국정보사회진흥원, 2018). 윤리 가이드라인 기본 방향은 첫째, 인간중심의 지능정보사회 구현을 위한 인공지능 기술의 잠재적 위험과 사회시스템을 보호하기 위한 사전 예방 원칙 기반으로 인간의 권한, 복지, 자유 확대라는 측면에서 인공지능 기술로 인한 위험 요소들과 부작용을 경감 할 수 있는 윤리 규정을 제시하였다. 둘째, 윤리적 규율이 필요한 분야에서 구체적인 행위 지침과 관련 분야에서 자율적 규제 환경을 조성하여 연구 개발과 산업 성장에 저해되지 않도록 노력하며, 공급자 및 개발자에게 부당한 부담을 지우지 않은 기준을 제시하였다. 셋째, 시민이나 이용자들의 참여와 권한, 역량을 강화하는데 기여하고 도움이 되도록 개발해야 한다는 것을 제시하였다. 다섯째, 인공지능 기술이 인간의 도덕적 가치와 윤리원칙 기반에서 인간과 조화를 이루며, 궁극적으로 인공지능 기술은 인간에게 도움이 되어야 하는 원칙을 구현하도록 하였다.

지능정보기술의 복합적 특성(보편적 복지 기여, 사회 변화 야기, 자기 학습·진화 등)을 바탕으로 공통원칙을 공공성, 책무성, 통제성, 투명성 4가지로 분류하여 선정하였다. [표 2-8]은 지능정보사회 구현을 위한 공통원칙과 세부 지침 현황<sup>10)</sup>이다. 각 공통원칙을 개발자, 공급자, 이용자로 세분화하여 지침을 제시하였다.

[표 2-8] 지능정보사회 구현을 위한 공통원칙과 세부 지침 현황

| 공통원칙 | 구 분 | 세부 지침                                                                                                                                   |
|------|-----|-----------------------------------------------------------------------------------------------------------------------------------------|
| 공공성  | 개발자 | <ul style="list-style-type: none"> <li>· 기술 개발 시 사회적 차별 요소 배제</li> <li>· 사회적 약자를 보호하기 위한 접근성 보장</li> <li>· 지능정보기술의 공공성 확보 노력</li> </ul> |

10) 한국지능정보사회진흥원, 지능정보사회 윤리 가이드라인, 2018

|     |     |                                                                                                                                                                             |
|-----|-----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|     | 공급자 | <ul style="list-style-type: none"> <li>· 공공의 이익에 부합할 수 있는 제품 공급</li> <li>· 선한 의도를 가진 발주</li> <li>· 상업적 이익과 공적 기여 간의 조화</li> </ul>                                           |
|     | 이용자 | <ul style="list-style-type: none"> <li>· 악의적 이용 금액</li> <li>· 공공의 이익을 위한 제품 개선에 참여</li> <li>· 소비자 행동 원칙 준수의 일상화</li> </ul>                                                  |
| 책무성 | 개발자 | <ul style="list-style-type: none"> <li>· 책임의 공유</li> <li>· 개발자들 간 정보교류와 기술갱신에 지속 참여</li> <li>· 품질 인증 기준의 충족</li> <li>· 윤리적 절차를 충실하게 이행하여 연구 및 개발</li> </ul>                 |
|     | 공급자 | <ul style="list-style-type: none"> <li>· 책임 공유와 책임 및 보상 원칙의 마련</li> <li>· 이용자 권리 보장</li> <li>· 지능정보서비스의 자율적 의사결정 조건과 범위 확립</li> <li>· 위험 예방을 위하여 사회적인 공론화에 참여</li> </ul>    |
|     | 이용자 | <ul style="list-style-type: none"> <li>· 이용자의 윤리적 책임 숙지</li> <li>· 책임을 제거할 수 있는 권리</li> <li>· 안전에 관련된 정보공유와 제도화에 대한 요구의 권리</li> <li>· 이용 제품의 교체 및 갱신과 폐기 시 지침 준수</li> </ul> |
| 통제성 | 개발자 | <ul style="list-style-type: none"> <li>· 예외적 상황에 대한 종합적 검토</li> <li>· 지속적 품질관리 실시</li> <li>· 기술적 제어장치 마련</li> </ul>                                                         |
|     | 공급자 | <ul style="list-style-type: none"> <li>· 제품 유통과정에서의 위험 통제</li> <li>· 안전성 검증과 통제 조치를 위한 방안 마련</li> <li>· 이용자의 선택권 보장</li> </ul>                                              |
|     | 이용자 | <ul style="list-style-type: none"> <li>· 지능정보기술 이용역량 강화</li> <li>· 자의적 조작 금지</li> </ul>                                                                                     |
| 투명성 | 개발자 | <ul style="list-style-type: none"> <li>· 위급 상황 시 필요 데이터 제공</li> <li>· 은닉 기능 개발 금지</li> <li>· 위험에 대한 적극적인 예측과 공급자와 긴밀한 공유</li> </ul>                                         |
|     | 공급자 | <ul style="list-style-type: none"> <li>· 위험 관련 정보에 대하여 이용자와 공유</li> <li>· 이용자 정보의 부당한 이용 금지</li> <li>· 사회적 영향평가 결과의 반영</li> </ul>                                           |
|     | 이용자 | <ul style="list-style-type: none"> <li>· 설명을 요구할 권리</li> <li>· 개인정보 활용에 대한 감시자로서의 의무</li> <li>· 소비자 정보의 공유 의무</li> </ul>                                                    |

## 라. 인공지능 윤리기준 및 신뢰할 수 있는 인공지능 실현 전략

국내에서도 적극적인 인공지능 윤리 기준 마련과 실현 방안이 만들어지고 있다. 2020년에 대통령 직속 4차산업혁명위원회는 사람 중심의 ‘인공지능(AI) 윤리 기준’을 마련하여 관계부처 합동으로 발표하였다. 해외의 인공지능 윤리 이슈 사례와 규범, 인공지능 원칙, 윤리 가이드라인 등을 분석하여 인공지능 국가전략에 따라 사람 중심의 인공지능 구현을 위한 글로벌 기준과의 정합성을 갖춘 ‘인공지능 윤리기준’을 마련하였다. 이 윤리기준은 2018년에 정보문화포럼에서 ‘지능정보사회 윤리 가이드라인’과 2019년 방송통신위원회에서 만든 ‘이용자 중심의 지능정보사회를 위한 원칙’ 등이 범국가적인 인공지능 윤리 가이드라인에는 다소 제한적이었기 때문에 보다 확장된 인공지능 윤리기준을 마련하였다. 인공지능 윤리기준의 목표와 지향점은 모든 분야에서 모든 사람이 자율적으로 준수하여 지속인 발전이 이루어질 수 있도록 하는 것이다. 인공지능 전 과정에서 사회 구성원 모두가 참조할 수 있는 기준과 특정 분야에 제한되지 않고 범용성을 가진 일반 원칙과 법·지침이 아닌 자율 규범,



<그림 2-3> 인공지능 윤리 3대 기본 원칙과 10대 핵심 요건

새롭게 제기되는 인공지능 윤리 이슈를 논의·발전시키는 플랫폼 기능을 구축하는 것이다. <그림 2-3>은 인공지능 윤리 기준의 3대 기본 원칙과 10대 핵심 요건이다. 3대 기본 원칙에는 인간 존엄성 원칙, 기술의 합목적성 원칙, 사회의 공공선 원칙으로 되어 있으며, 10개 핵심 요건은 3대 기본 원칙을 실현하기 위한 세부적인 요건이다. 먼저 인간의 존엄성 원칙에서 인공지능은 인간의 생명은 물론 신체적, 정신적 건강에 피해가 되지 않는 범위에서 개발, 사용되어야 하며, 안전하고 견고하게 제작되어 인간에게 피해가 가지 않도록 해야 한다. 사회의 공공선 원칙은 인공지능은 사회적 약자나 취약계층이 쉽게 접근성 할 수 있도록 개발, 운용되어야 하며, 공익 증진을 위해 국가적, 사회적, 글로벌 관점에서 인류의 보편적인 복지향상을 이룰 수 있어야 한다. 기술의 합목적성 원칙은 인공지능은 인간이 생활하는데 필요한 도구라는 목적과 사용자의 의도에 부합되게 개발 및 운용되어야 하며, 그 과정에서도 윤리적이어야 하고 인간의 삶과 번영을 위해 진흥해야 한다는 내용이 담겨있다.

4차 산업혁명위원회 전체회의에서 발표한 ‘신뢰할 수 있는 인공지능 실현 전략’은 인공지능 강국으로 도약하기 위해 정부 차원에서 신뢰할 수 있는 인공지능 사회를 실현하기 위한 지원 정책이 신속하게 마련되어야 한다는 판단에서 2020년에 발표한 ‘인공지능 윤리 기준의 실천 방안’을 구체화하였고, 민간이 자율적으로 신뢰성을 확보할 수 있는 인공지능 산업 지원체계를 구축하여 기술적, 재정적으로 미약한 스타트업 등에 대한 지원책을 포함한 것이 특징이다. 이 전략은 누구나 신뢰할 수 있는 인공지능, 모두가 누릴 수 있는 인공지능 구현을 비전으로 하여 기술·제도·윤리 측면의 3대 전략과 10대 실행 과제를 통하여 2025년까지 단계적으로 추진되며 민간의 인공지능 서비스 구현을 체계적으로 지원하고, 이용자가 믿고 안전하게 사용할 수 있는 제도를 보완하며, 사회 전반에 건전한 인공지능 윤리를 확산하는 것이 중점 방향이다(과학기술정보통신부, 2021). <그림 2-4>는 신뢰할 수 있는 인공지능 실현 전략의 추진전략<sup>11)</sup>을 도표화 한 것이다. 추진전략으로 첫째, 신뢰 가능한 인공지능

11) 과학기술정보통신부, 신뢰할 수 있는 인공지능 실현 전략(안), 2021

|                      |                                                                           |                                                                          |                                                         |
|----------------------|---------------------------------------------------------------------------|--------------------------------------------------------------------------|---------------------------------------------------------|
| <b>비전</b>            | 누구나 신뢰할 수 있는 인공지능, 모두가 누릴 수 있는 인공지능 구현<br>- Trustworthy AI for Everyone - |                                                                          |                                                         |
| <b>목표</b><br>(~2025) | 책임있는 인공지능 활용<br>(세계 5위)                                                   | 신뢰 있는 사회<br>(세계 10위)                                                     | 안전한 사이버 국가<br>(세계 3위)                                   |
| <b>추진 전략</b>         | 신뢰 가능한 인공지능<br>구현 환경조성                                                    | 안전한 인공지능<br>활용을 위한 기반 마련                                                 | 사회 전반 건전한<br>인공지능 의식 확산                                 |
|                      | ① 인공지능 제품·서비스<br>신뢰 확보 체계 마련<br>② 민간 신뢰성 확보 지원<br>③ 인공지능 신뢰성 원천기술 개발      | ① 학습용 데이터 신뢰성 제고<br>② 고위험 인공지능 신뢰성 확보<br>③ 인공지능 영향평가 추진<br>④ 신뢰 강화 제도 개선 | ① 인공지능 윤리 교육 강화<br>② 주제별 체크리스트 마련<br>③ 인공지능 윤리정책 플랫폼 운영 |

<그림 2-4> 신뢰할 수 있는 인공지능 실현 전략 비전·목표·추진전략

구현환경 조성이며, 둘째, 안전하고 신뢰성 있는 인공지능 활용을 위한 기반 마련, 셋째, 사회 전반의 건전한 인공지능 의식 확산이다. 인공지능 제품·서비스 구현단계 별로 신뢰 확보 체계를 마련하여 개발 단계에서는 국내외 신뢰성 관련 윤리, 법·제도, 기술적 요구사항을 일괄적으로 확인할 수 있도록 개발 지침을 보급하고, 검증 단계에서는 신뢰성 확보 여부와 그 수준을 확인하고 평가할 수 있는 검증 절차, 검증항목 및 방법 등의 검증체계를 마련한다. 마지막 인증 단계에서는 기술·윤리적 요구사항을 충족하는 검증체계를 민간 자율 인증에 의하여 진행하고 공시한다. 인공지능 윤리와 관련하여 사회 전반 건전한 인공지능 의식 확산 추진전략에서 주제별 체크리스트 마련은 2022년까지 계획되어 있으나 아직 윤리 기준 요건이 명확하게 개발되어 있지 않다. 민간 기업인 카카오에서는 2018년에 ‘카카오 알고리즘 윤리헌장’을 발표하여 알고리즘의 기본 원칙 외 7가지를 포함하였다. 구글은 2019년에 ‘인공지능 7대 원칙’을 발표하였는데 비즈니스 의사결정에 영향을 주는 구체적인 기준 7가지를 명시하였다. 이제는 윤리원칙 수준에서 벗어나 인공지능 윤리원칙 및 특성에 적합한 기준을 마련하여 제품이나 서비스에 적용할 영역별 인공지능 측정지표 개발·적용으로 안전한 인공지능 사회환경 구축이 요구된다.

## 2. 인공지능 인증 시험 및 표준화

### 가. 인공지능 인증심사 및 시험기준

인공지능은 소프트웨어로 구현하기 때문에 인공지능 인증은 소프트웨어 품질인증과 함께 진행되며, 인공지능 기술이 적용된 모든 제품이나 서비스를 대상으로 인증심사한다. 인공지능은 품질평가 모델과 품질경영시스템 국제표준을 기반으로 인공지능의 신뢰성 및 안전성 등의 품질 확보를 목적으로 한다. 국내에서 진행되는 인증 심사 기준은 ISO 9001 품질경영시스템을 기반으로 품질 리스크관리와 PDCA (Plan, Do, Check, Action) 사이클을 통하여 제품이나 서비스의 품질을 지속적으로 개선하는지 확인하고, 인공지능 추가 요구사항을 통하여 고객 요구사항 정의, 품질 목표 관리, 기술력 향상, 데이터관리, 정보보안 및 법규 준수, 개발 산출물 관리, 테스트 기준, 릴리즈 및 업데이트 절차, VOC 관리 등 핵심 포인트를 확인한다(TTA, 2021). <그림 2-5>는 국내 인공지능 인증 시험 기준 구성도<sup>12)</sup>를 도식화한 것이다.



<그림 2-5> 인공지능 인증 시험 기준 구성도

12) 한국표준협회, [https://www.ksa.or.kr/ksa\\_kr/6962/subview.do](https://www.ksa.or.kr/ksa_kr/6962/subview.do), 2022

인증 시험은 국제표준 ISO/IEC 25023, ISO/IEC 25051과 기술에 대한 체계적인 품질 평가모델을 기반으로 인증 대상의 품질을 시험·평가한다. 인공지능 성능 평가 목록에는 정확도(Accuracy), 재현율(Recall), 정밀도(Precision), 평균 오차율 (MAPE), 특이도(Specificity), 평균 절대 오차 (MAE), 성능 효율성이 포함되며, 소프트웨어 제품 품질 평가목록에는 기능 적합성, 호환성, 성능 효율성, 사용성, 보안성, 유지 보수성, 이식성, 신뢰성, 일반적 요구사항이 포함되어 있다. 아직은 인공지능 윤리 기준을 적용하여 시험에 적용하고 있지 않은 상태이며, 인공지능 제품이나 서비스의 증가에 따라 인공지능 윤리 기준을 적용하여 시험 항목을 개발해야 할 필요성이 요구되고 있다.

#### 나. 소프트웨어 품질 시험 인증

국내 소프트웨어 진흥법 제20조에 의거한 소프트웨어 품질 인증은 국제 소프트웨어 품질 표준을 기반으로 소프트웨어 제품을 시험 및 평가하여 GS(Good Software) 인증을 부여하고 있다(TTA, 2022). GS 인증 대상은 임베디드, 컴포넌트, 패키지, 모바일, 게임, GIS, e-Biz, e-Learning, 운영체제, 디지털 콘텐츠, 보안용 SW, 웹 관리 도구, SW 개발도구, 유틸리티, 홈 네트워크, 스토리지, 바이오 매트릭스, 교육용 SW 등 소프트웨어가 적용된 전 분야의 제품 및 서비스에 적용한다. 소프트웨어 시험기준은 ISO/IEC 25023, 25041, 25051 국제표준을 기반으로 기능적합성, 성능효율성, 사용성, 신뢰성, 보안성 등에 대한 시험을 수행한다. <그림 2-6>은 소프트웨어 인증기준<sup>13)</sup> 구성도를 도식화한 것이다. 품질 측정을 위한 국제표준은 ISO/IEC 25023을 적용하며, 품질 요구사항과 시험에 관한 국제표준은 ISO/IEC 25051을 적용하고 품질 요구사항과 시험에 관한 국제표준은 ISO/IEC 25051을 적용한다. 소프트웨어 유형별 테스트 케이스를 개발·적용하고 결함 발견 시 결함에 대한 리포트와 보완 기회를 제공하여 결함을 해결할 수 있도록 회귀시험을 수행한다. 제품의 품질을 종합적으로 평가한 후 인증심의위원회를 통해 인증 여부를 결정하여 인증 통과 시 시험성적서 및 품질인증서를 제공하는 프로세스로 진행

13) 한국정보통신기술협회, GS시험인증(1등급) 소개, [https://sw.tta.or.kr/service/gsce\\_it.jsp](https://sw.tta.or.kr/service/gsce_it.jsp), 2022



<그림 2-6> 소프트웨어 인증기준 구성도

한다. 인증기준의 품질 주 특성에는 기능적합성, 성능효율성, 호환성, 사용성, 신뢰성, 보안성, 유지보수성, 이식성, 일반적 요구사항으로 구성되어 있다. 소프트웨어 인증기준의 주 특성과 부 특성에 대한 정의<sup>14)</sup>는 [표 2-9]과 같이 정의된다.

[표 2-9] 소프트웨어 인증기준의 품질 특성별 정의

| 품질 주 특성 | 품질 부 특성 | 개념 정의                                                             |
|---------|---------|-------------------------------------------------------------------|
| 기능적합성   | 기능 완전성  | · SW 제품이 지정된 작업과 사용자 목적에 적합한 기능을 제공하는 정도                          |
|         | 기능 정확성  | · SW 제품이 정확하게 결과를 제공하는지에 대한 정도                                    |
|         | 기능 적절성  | · SW 기능이 지정된 작업과 목적 달성을 용이성에 대한 정도                                |
| 성능효율성   | 시간 반응성  | · SW 기능 실행 시 제품의 처리시간, 응답시간 등의 요구사항 만족 정도                         |
|         | 자원 효율성  | · SW 기능 실행 시 제품이 사용하는 자원의 양 등의 요구사항 만족 정도                         |
|         | 용량성     | · SW 제품에서 매개변수 최고 한도가 요구사항을 만족하는 정도                               |
| 호환성     | 공존성     | · SW 제품이 다른 SW 제품과 공통 환경과 자원을 공유하면서 그 SW 제품에 유해적 영향과 효율적 기능 수행 정도 |
|         | 상호운용성   | · 두 개 이상의 SW 제품이 정보 교환과 교환 정보의 성공적 사용 정도                          |

14) 한국정보통신기술협회, GS시험인증(1등급) 안내서, 2022

|          |                |                                                                      |
|----------|----------------|----------------------------------------------------------------------|
| 사용성      | 적절 인식성         | · SW가 사용자 니즈(Needs)에 적절한지에 대한 사용자 인식 정도                              |
|          | 학습성            | · 지정된 사용 환경에서 사용자가 SW를 학습하기 위해 효율성, 무위험성, 만족성, 효과성을 가지고 제품을 사용하는 정도  |
|          | 운영성            | · SW 운영과 제어를 용이하게 한 속성을 제품에 제공하는 정도                                  |
|          | 사용자 오류 방지성     | · SW 제품이 사용 오류 발생을 방지하는 정도                                           |
|          | 사용자 인터페이스 심미성  | · 사용자 인터페이스가 사용자와의 상호작용을 만족스럽게 하는 정도                                 |
|          | 접근성            | · 특정 사용 문맥에서 지정된 목표 달성을 위해 다양한 범주의 특징, 능력을 가진 사용자가 SW를 사용할 수 있는 정도   |
| 신뢰성      | 성숙성            | · SW가 정상 운영 상황에서 신뢰성 요구사항을 만족하는 정도                                   |
|          | 가용성            | · SW 사용이 요구될 때 제품 운영, 접근이 가능한 정도                                     |
|          | 결합 허용성         | · HW나 SW 결합이 존재해도 SW가 의도된 대로 동작하는 정도                                 |
|          | 복구성            | · 시스템 중단이나 고장 발생 시 SW가 직접적으로 영향을 받는 데이터를 복구 및 시스템 적정 상태로 복구하는 정도     |
| 보안성      | 기밀성            | · SW가 인가된 사용자만 데이터 접속을 보장하는 정도                                       |
|          | 무결성            | · SW가 프로그램이나 데이터에 대해 비인가자 접근이나 수정을 방지하는 정도                           |
|          | 부인 방지성         | · 행위나 이벤트가 일어났음을 부인 못하게 증명하는 정도                                      |
|          | 책임성            | · 개체 행위를 유일하게 추적할 수 있도록 하는 정도                                        |
|          | 인증성            | · 주체나 자원의 신원을 주장하는 대로 증명 가능한 정도                                      |
| 유지보수성    | 분석성            | · SW의 의도적인 변경이 제품의 다른 부분에 미치는 영향을 평가하거나, 수정 부분을 식별할 수 있는 효율성, 효과성 정도 |
|          | 변경성            | · SW의 품질을 떨어뜨리지 않고 제품을 효율적, 효과적으로 수정 정도                              |
|          | 시험성            | · 수립된 테스트 기준에 따라 SW를 자체적으로 테스트하고 효율적, 효과적으로 적응하는 정도                  |
| 이식성      | 적응성            | · SW가 다른 HW, SW 및 운영환경에 효율적, 효과적으로 적응 정도                             |
|          | 설치성            | · SW가 특정 환경에서 성공적으로 설치나 삭제 될 수 있는 효율성, 효과성 정도                        |
|          | 대체성            | · SW가 같은 목적과 환경으로 사용된 타 SW 제품을 대신하는 정도                               |
| 일반적 요구사항 | 제품 설명서 요구사항    | · 제품설명서 등에 제품 식별과 제품 표시 정보를 제공하는 정도                                  |
|          | 사용자 취급설명서 요구사항 | · 사용자 취급설명서가 일관적, 정확하게 이해 가능하도록 제품 정보를 제공하는 정도                       |
|          | 품질특성별 정보제공     | · 사용자 취급설명서 등에 품질 특성별 제품 정보를 제공하는 정도                                 |

소프트웨어가 제품 및 서비스에 적용된 소프트웨어를 시험, 평가하여야 하므로 현재 소프트웨어의 시험 인증에 인공지능 윤리에 대한 측정지표를 개발하여 적용할 필요성이 높아지고 있다. 인공지능 제품이나 서비스에 인증제도가 만들어진 상태이기 때문에 소프트웨어 인증심사 정책을 보완하여 인공지능 윤리를 적용하게 할 수 있을 것이다.

#### 다. 인공지능 표준화 현황

인공지능 기술의 발전과 함께 인공지능에 관한 기술 표준화를 공적 표준화 그룹과 사실 표준화 그룹으로 진행한다. 공적 표준화 그룹인 ISO/IEC JTC1 SC42의 워킹그룹, ITU-T에서 진행되고 있는 연구그룹, 사실 표준화 그룹으로 AI 기반의 미디어 표준을 다루는 MPAA 표준화 그룹 및 IEEE SA에서 개발되고 있는 인공지능 윤리 표준에서 진행하는 현황을 검토하였다(최미란, 2021). 인공지능 국제 표준화는 ISO와 ITU-T가 중심이 되어 시작했으며, ITU와 JTC 1/SC42에서 2017년부터 인공지능 표준화 활동을 본격적으로 시작하였다. 인공지능 표준 기술 개발을 목표로 ISO/IEC JTC1는 SC42를 신설하여 인공지능 기반 표준, 신뢰성, 기계학습, 응용시스템, 유즈케이스 등 표준 개발에 들어갔다. 인공지능망 압축 표준화는 ISO/IEC JTC1 산하의 MPEG에서 시작하였으며, ITU-T에서는 클라우드 컴퓨팅 기반 머신러닝, 지능형 질의응답시스템, 헬스케어 머신러닝, 5G의 머신러닝 등 응용 서비스를 중심으로 표준화를 시작하였다. 표준화를 만드는 데 있어서 공적 표준화 그룹은 표준 주제가 기본 개념에서부터 시작하여 이론적 내용과 표준 절차가 상세하게 규정되어야 하므로 최종 승인 완료 될 때까지는 몇 년이 소요되는 경우가 많다. 반면 사실 표준화 그룹은 필요한 기술을 바로 산업현장에 적용해야 하기 때문에 이해관계자가 필요에 의하여 협의 후 빠른 기간 내에 결과물을 낼 수 있도록 하고 있다. 인공지능 관련 표준화 그룹별 대표 표준화 항목<sup>15)</sup>을 기구별로 [표 2-10]과 같이 정리하였다.

15) 한국전자통신연구원, 인공지능 표준화 현황(최미란), 2021

[표 2-10] 인공지능 표준화 그룹별 대표 표준화 항목

| 구 분       | 표준화 기구                 |      | 주요 표준화 항목                                                                                             |
|-----------|------------------------|------|-------------------------------------------------------------------------------------------------------|
| 공식<br>표준화 | ITU-T                  | SG13 | · Y.MLaaS-reqts, Y.IMT2020-ML-Arch 등 - 클라우드 컴퓨팅 및 통신 네트워크에서의 기계학습 응용 관련 표준                            |
|           |                        | SG16 | · F.746.3, F.746.5, F.746.7, F.746.9, F.VS-AIMC - 음성/비전 인식 등의 멀티미디어 서비스 관련 인공지능 응용서비스 표준              |
|           |                        | SG20 | · Y.SSC-AISE-arc, Y.Sup.AI4IoT - 스마트 시티에서의 인공지능 응용 서비스 표준                                             |
|           | ISO/IEC JTC1/SC42      |      | · DIS 22989, DIS 23053 인공지능 용어 및 기반 기술 표준<br>· DIS 23894 인공지능 위험 관리<br>· TR 24638 인공지능 윤리 및 사회적 이슈 사항 |
|           | ISO/IEC JTC1 SC29/WG11 |      | · NNR 압축 표현, 동작인식 등의 기술 표준                                                                            |
|           | ISO/IEC JTC1/SC35      |      | · 감성인식 기술 표준, 실시간 동시통역 표준                                                                             |
| 사실<br>표준화 | MAPI                   |      | · MMC - 멀티 모달 대화 표준<br>· EEC - AI 기반의 중단 간 비디오 코딩 표준                                                  |
|           | IEEE                   |      | · P7000 시리즈 - 인공지능 시스템 디자인 설계 시 필요한 윤리 표준                                                             |
|           | Khronos group          |      | · NNEF(Neural Network Exchange Format) 1.0 - 신경망 학습 데이터 교환 표준                                         |

SC42의 WG3 ISO/IEC TR 24028에서는 인공지능의 신뢰성 개요를 정의하는 표준을 인공지능의 설명 가능성, 투명성, 제어 능력을 통해 신뢰를 구축하는 접근 방법을 정의하였으며, 인공지능에서 나타날 수 있는 위험 요소와 관련된 공학적으로 미흡한 점을 정의하였다. 또한 인공지능의 안전성, 가용성, 적응성, 사생활 보호 등의 특성을 평가구축 하는 접근 방법 정의를 표준의 범위로 하였다.

인공지능 윤리 표준화를 가장 적극적으로 진행하는 기구는 IEEE SA(Standards Association)이며 2017년에 ‘윤리적으로 조성된 디자인(EAD1e. Ethically Aligned Design: A vision for prioritizing Human Well-being with Autonomous and

Intelligent Systems)’을 발표하였다. 자율적 시스템은 인간 사회의 안전, 이익, 복지를 증진하도록 윤리적 고려사항을 구체화하였으며, 인공지능 기술의 개발 방향으로 유도할 수 있도록 한다. 윤리적 고려사항의 일반원칙은 인권(Human Rights), 복리(Well-being), 책무성(Accountability), 투명성(Transparency), 오남용에 대한 인식(Awareness of Misuse)으로 정의 하였다. IEEE SA에서 진행하는 인공지능 윤리 관련 표준화 현황<sup>16)</sup>은 [표 2-11]과 같다.

[표 2-11] IEEE SA에서 진행하는 인공지능 윤리 관련 표준화 현황

| 표준번호      | 표 준 명                                                               | 비 고        |
|-----------|---------------------------------------------------------------------|------------|
| 7000-2021 | · 시스템 설계 중 윤리적 문제를 해결하기 위한 모델 프로세스                                  | 2021년에 공표  |
| 7001-2021 | · 자율 시스템의 투명성                                                       | 2022년에 공표  |
| 7002-2022 | · 데이터 개인 정보 보호 프로세스                                                 | 2022년에 공표  |
| P7003     | · 알고리즘 편향 고려 사항                                                     | 산업 분야별로 진행 |
| P7004     | · 아동 및 학생 데이터 거버넌스에 대한 표준                                           | 산업 분야별로 진행 |
| P7004.1   | · 가상 교실 보안, 개인 정보 보호 및 데이터 거버넌스에 대한 권장 사례                           | 진행 중       |
| 7005-2021 | · 고용주 데이터 거버넌스에 대한 표준                                               | 2021년에 공표  |
| 7007-2021 | · 윤리적으로 구동되는 로봇 공학 및 자동화 시스템을 위한 존재론적 표준                            | 2021년에 공표  |
| P7008     | · 로봇, 지능형 및 자율 시스템을 위한 윤리적으로 주도되는 네티지에 대한 표준                        | 산업 분야별로 진행 |
| P7009     | · 자율 및 반자율 시스템의 페일 세이프 설계 표준                                        | 산업 분야별로 진행 |
| 7010-2020 | · 자율 및 지능형 시스템이 인간 복지에 미치는 영향을 평가하기 위한 IEEE 권장 사례                   | 2020년에 공표  |
| P7010.1   | · 환경 사회 거버넌스 (ESG) 및 사회 개발 목표 (SDG) 행동 이행 및 기업의 사회적 책임 증진을 위한 권장 실천 | 진행 중       |
| P7011     | · 뉴스 소스의 신뢰성을 식별하고 평가하는 프로세스의 표준                                    | 산업 분야별로 진행 |
| P7012     | · 기계 판독 가능한 개인 정보 보호 약관에 대한 표준                                      | 진행 중       |
| P7014     | · 자율 및 지능형 시스템에서 에몰레이트된 공감의 윤리적 고려 사항에 대한 표준                        | 진행 중       |
| P7015     | · 데이터 및 인공지능 문해력, 기술 및 준비에 대한 표준                                    | 진행 중       |

16) IEEE, <https://ethicsinaction.ieee.org/p7000>, 2022

IEEE SA P7000 시리즈는 인공지능 윤리에 대한 범용적이고 광범위한 영역까지 인공지능 윤리를 적용하기 위해 국내외 조직 간의 협력을 통하여 진행하고 있다. 2020년에 공표한 P7010 표준은 인공지능이나 자율지능 시스템(A/IS)이 인간에 미치는 영향을 평가하기 위해 만들어졌다. 이 표준은 인공지능에 의하여 인간이 건강한 생활(웰빙)에 미치는 영향을 인적요소와 관련된 기준을 설정하여 인간의 건강한 생활이 적극적으로 향상할 수 있는 요소들을 포함하였다. 인공지능 개발 지침, 개선 영역 식별, 위험 관리, 성능 평가, 의도된 사용자 및 의도하지 않은 사용자 식별, A/IS 사용 및 인간 복지에 대한 영향을 측정하기 위한 지표가 개발되었다. 웰빙 영향평가와 웰빙 지표 대시보드 활동 단계에서는 내부 사용자 및 이해관계자 영향평가, 웰빙 지표 대시보드, 데이터 수집 계획 및 데이터 수집, 웰빙 데이터 분석 및 웰빙 데이터 사용, 반복에 대한 내용을 수록하였다. 또한 웰빙 영역 및 지표에서는 일반, 삶의 만족도, 영향, 심리적 웰빙, 커뮤니티, 문화, 교육, 경제, 환경, 정부, 건강, 인간 정착, 작업 영역으로 구분하였다. 인간의 웰빙과 관련하여 인공지능에 요구해야 할 내용에 대한 정의, 요건, 체크리스트로 구분하여 P7010 표준이 개발되었으나 이 내용을 바탕으로 인공지능 윤리를 적용하기 위한 인공지능 윤리 측정지표는 각국의 특성에 맞도록 개발하여 적용해야 할 필요성이 요구된다.

2019년 카네기멜런대학교에서 제시한 윤리적인 인공지능 경험 설계(체크리스트 및 동의)에서는 인공지능 시스템 설계 시 참여한 사람은 모든 결정과 결과에 대해 궁극적인 책임을 지며, 인공지능이 내리는 중요한 결정은 설명, 재정의가 가능하고 되돌릴 수 있도록 한다. 인공지능의 위험과 유익을 식별할 수 있어야 하고 오남용에 대한 계획을 세우고 인공지능에 영향을 받은 모든 사람과 관련 정보공유를 위한 커뮤니케이션 계획으로 위험 관리하며, 인간 존중과 보안의 중요성 인식, 신뢰 구축, 편향 방지, 알고리즘과 모델에 대한 검증 가능, 인간에 의한 의사결정권 제공, 모니터링 제공, 인간과 상호작용 식별, 인공지능의 의사결정 추적 가능, 인간의 요구와 기술 표준을 충족할 수 있도록 정기적으로 개선한다는 것을 제시하였다.

### 3. 인공지능 기술이 적용된 분야별 인공지능 윤리

#### 가. 인공지능 로봇과 로봇 윤리


인공지능 분야에서 로봇은 인류에게 가장 큰 관심의 대상이 되었으며, 향후에도 가장 급속하게 발전하면서 인류에게 큰 유익과 위협이 될 것으로 예상된다. 과거에는 제조 현장에서 단순한 반복 작업만 프로그램에 의하여 수행하였다면 이제는 인간과 유사한 감성과 지식, 학습 능력을 보유한 로봇이 연구되고 있으며 일부 제품은 생산되어 판매되고 있다. 휴머노이드는 인간에게 친구가 되어주고 도우미가 되어주고, 인간이 하기 힘든 어려운 일을 빠르고 정확하게 처리할 수 있게 하고 있다. 인공지능 기술의 발전으로 인하여 로봇은 다양한 용도로 발전하고 있다. 아직까지는 다양한 산업 분야에서 지능형 로봇이 주를 이루고 있다. 지능형 로봇이란 인공지능 등 ICT 기술을 바탕으로 인간과 상호작용하면서 가사 지원, 엔터테인먼트, 교육 등 다양한 형태의 서비스를 제공하는 인간 지향적인 로봇을 의미한다(최혜진, 2015). 지능형 로봇은 IOT 기술의 발전, 빅데이터 증가, 인공지능 알고리즘의 오픈소스화, 머신러닝 기술 등 기반 기술의 발전으로 데이터 학습 능력이 향상되면서 지능이 지속적으로 높아져 로봇이 자율적으로 의사결정을 할 수 있도록 하게 된다. 따라서 기술적 발전에 의하여 산업현장에 먼저 적용되어 사용되고 있으며, 가정과 일상생활에도 보급이 확대되고 있다. 제조 현장뿐 아니라 교육, 의료, 해양, 물류, 금융, 군사, 서비스 등에 상용화하여 판매되고 있다. 미국을 비롯하여 일본, 유럽, 중국 등 세계 각국에서도 지능형 로봇 기술 경쟁이 심화되고 있으며 국가경쟁 전략 제품으로 정책화하여 발전시키고 있다. 2021년 OECD 과학기술산업정책위에서 ‘로봇의 미래를 위한 공공정책의 역할’을 발표하였으며, 주요 내용으로는 로봇의 정의와 로봇의 전략적 중요성, 미래의 로봇 기능, 로봇의 현재와 미래의 역할, 로봇 관련 공공정책의 논리와 설계 영향 검토 등이 포함되었다. [표 2-12]는 로봇을 분류<sup>17)</sup>

17) 한국로봇산업협회, 2019년 기준 로봇산업 실태조사 결과보고서, 2020

[표 2-12] 로봇 분류

| 대분류       | 중분류                                                                                                                                                                                                                                          |
|-----------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 제조용 로봇    | <ul style="list-style-type: none"> <li>· 이적재용 및 핸들링용</li> <li>· 공작물 장착 및 탈착용</li> <li>· 용접 및 납땜용</li> <li>· 조립, 분해, 집착, 마킹 및 라벨링용</li> <li>· 물품 연마, 절단 등 가공 및 표면처리용</li> <li>· 생명공학기술 공정용</li> <li>· 측정, 검사 시험용</li> <li>· 기타 제조용</li> </ul> |
| 전문 서비스 로봇 | <ul style="list-style-type: none"> <li>· 사업시설 관리용</li> <li>· 안전 및 극한 직업용</li> <li>· 여가 및 오락 서비스용</li> <li>· 군사용</li> <li>· 농림어업용</li> <li>· 기타 전문서비스용</li> <li>· 의료용</li> <li>· 건설용</li> </ul>                                               |
| 개인 서비스 로봇 | <ul style="list-style-type: none"> <li>· 가사용</li> <li>· 개인 건강관리용</li> <li>· 채팅봇</li> <li>· 교육용</li> <li>· 개인 여가, 오락, 취미 및 감성 교감 로봇</li> <li>· 기타 개인 서비스용</li> </ul>                                                                          |

한 것이다. 로봇산업이 발전하면서 로봇윤리에 대한 다양한 연구가 진행되고 있다. 로봇 윤리연구는 대부분 제품이나 서비스를 대상별로 윤리를 연구하고 있으며 특히 로봇 윤리에는 도덕성에 관한 연구가 많은 것이 특징이다. 아이작 아시모프는 1942년에 자신의 소설 아이로봇에서 ‘로봇 3원칙’을 제시하였다. ‘로봇 3원칙’은 로봇과 인공지능의 윤리를 논할 때 언제나 쉽게 떠오르는 유명한 개념이 되었다. [그림 2-7] 아시모프의 로봇 3원칙<sup>18)</sup>이다.




[그림 2-7] 아시모프의 로봇 3원칙

18) 런어라운드(아이작 아시모프), 1945

로봇윤리(Robot ethics)는 최근에 Roboethics로 많이 사용하고 있으며, 로봇윤리 연구는 실제로 로봇의 적용에서 발생하는 윤리적 쟁점들에 대한 철학적 연구와 로봇에 입력된 프로그램에 따라 로봇 자체가 임무를 수행하는 가운데 도덕적 규약에 얼마나 준수할 수 있는지에 대한 연구, 그리고 로봇이 완전한 도덕적 행위자로서 윤리적 추론을 할 수 있는 능력, 자신의 행위들에 대한 자의식적 선택과 책임을 개별적으로 가질 수 있는지에 대한 연구를 진행하고 있다(박진수, 2019). 로봇윤리의 기본적 특성은 첫째, 연구 분야별로 로봇 기술의 발전에 따라 좌우되는 경향이 있고, 로봇 분야별 문제들에 대한 규범적, 처방적 접근이 주를 이룬다. 둘째, 인공지능과 함께 인공 정서가 로봇에 주입되므로 로봇 공학적 측면에서 준자율적이며, 도덕적인 행위자로 간주하는 경향이 나타난다. 셋째, 휴머노이드 로봇과 같은 3세대 미래 로봇 기술이 인간의 삶에 미치는 영향을 어느 정도 상상해야하기 때문에, 로봇윤리는 현재 발생한 문제에 대한 대응 보다는 미래에 대한 윤리적 성찰이 필요한 경향이 있다(변순용, 2019).

가정용 헬스케어 AI 로봇의 개발자용 윤리 체크리스트 개발에 대한 연구에서는 홈 헬스케어 인공지능 로봇의 자기점검 윤리 문항을 3개의 기본원칙과 6개의 실천 원칙으로 구성하여 제시하였다(이청호 외, 2021). 최근 의료분야에 인공지능 기술이 적용된 홈 헬스케어 로봇 개발이 증가하고 있다. 개인 맞춤형 질병 예방과 치료에 최적화된 의료로봇으로 개발하여 가정에서 쉽게 활용할 수 있도록 하기 때문에 많은 주목을 받는 분야이기도 하다. 이 연구에서는 홈 헬스케어 인공지능 로봇이 상용화됨에 따라 잠재적인 위험 요소와 윤리적인 문제를 개발자가 설계, 제작 과정에서 사전에 최소화할 수 있는 윤리원칙을 연구하고자 하였으며, 향후 인공지능 로봇의 윤리인증에 활용될 수 있도록 하였다. <그림 2-8>은 홈 헬스케어 인공지능 로봇의 자기 점검 윤리 문항 구성<sup>19)</sup>을 도식화한 것이다. 기본 원칙에는 존엄성, 공공선, 행복 추구의 3가지 원칙으로 구성하였으며, 실천 원칙에는 안전성, 정보 보안성,

19) 이청호 외, 가정용 헬스케어 AI 로봇의 개발자용 윤리체크리스트 개발에 대한 연구, 2021



<그림 2-8> 자기 점검 윤리 문항의 구성

책임성, 제어가능성, 투명성, 편향성과 공정성 등 6가지 특성으로 구성하였다.

COVID-19의 영향으로 인하여 최근 원격진료가 급격하게 증가하고 있는 가운데 의료분야의 인공지능 활용 또한 증가하고 있다. 의료분야는 인간의 생명과 가장 밀접한 서비스 분야이기 때문에 매우 중요도가 높다고 할 수 있다. 따라서 인공지능은 프라이버시 보호를 강화하고 알고리즘의 차별 방지와 인공지능의 의사결정 오류에 대한 추적, 검증, 설명이 가능한 특성이 포함된 윤리 체크리스트를 개발하여 보완한다면 더욱 활용도가 높을 것으로 보인다.

#### 나. 자율주행자동차와 윤리

자동차산업의 발전은 인류에게 이동 수단의 혁신을 이룰 수 있도록 하였다. 최근 자동차는 소프트웨어 발전과 인공지능, 모빌리티 기술 발전으로 인하여 자율주행자동차로 변화를 거듭하며 이동 수단 그 이상의 가치와 활용성을 가지고 있다 (Samuel D, 2018). 현재 인간이 만든 제조 물품 중에서 자율주행자동차는 인공지능 기술이 가장 많이 적용된 제품이며, 자동차에서 사용되는 에너지를 전기로 전환하면서 세계 각국은 경쟁적으로 자율주행 제품을 인공지능 기술과 결합하여 개발하고

있다(박주희, 2021). 자율주행자동차에는 인공지능 기술이 많이 적용되어 있기 때문에 각국은 자율주행자동차에 대한 인공지능 윤리 가이드라인을 만들어 법제화하고 있다. 독일은 자율주행 레벨4 시대를 맞이하고 있으며, 세계 최초로 자율주행 4단계에 대한 법안을 2021년에 발의하여 윤리에 대한 기준을 법적으로 상당 부분 마련하였다(KOTRA, 2021). 이에 앞서 2017년에 독일에서는 세계 최초로 자율주행자동차

[표 2-13] 자율주행자동차 저장의무 데이터 종류

| 데이터 종류                                   | 저장 의무 이유                                                             |
|------------------------------------------|----------------------------------------------------------------------|
| 차량 식별번호                                  | · 담당 당국이 운영 허가 및 차량 승인 관련하여 차량 및 운행에 적용되는 기술과 구성 요구사항 이행을 모니터링하는데 필요 |
| 위치 데이터                                   | · 상황 발생 시 차량에 대한 지리적인 위치 정보 필요                                       |
| 자율주행 기능의 비활성화, 활성 횟수                     | · 자율주행 기능 사용 시간 중 상황이 발생하는지 여부를 명확하게 확인하기 위하여 필요                     |
| 대체 운전 기동 승인 회수                           | · 운전 시간 경과에 따른 대체 운전 기동의 누적 평가를 위해 필요                                |
| 소프트웨어 버전, 시스템 모니터링 데이터                   | · 시스템 보안, 신뢰성 및 기술적 오류 발생 원인 평가를 위해 필요                               |
| 환경, 기상 조건 데이터                            | · 차량 외부 운행 조건 식별을 위해 필요                                              |
| 네트워킹 매개 변수 데이터                           | · 차량 외부 운행 조건 식별을 위해 필요                                              |
| 활성·비활성화된 수동, 활성 안전 시스템 이름, 안전 시스템 상태 데이터 | · 차량의 전체 및 개별 시스템의 신뢰성, 안전성 평가를 위해 필요                                |
| 차량의 횡·종 가속도 데이터                          | · 차량 운행 현상을 분류하고 시스템 안전 관련된 시스템의 반응을 평가하기 위해 필요                      |
| 차량 속도 데이터                                | · 차량 운행 현상을 분류하고 시스템 안전 관련된 시스템의 반응을 평가하기 위해 필요                      |
| 조명장비 상태 데이터                              | · 차량 시스템 안전 평가를 위해 필요                                                |
| 차량 자율주행 기능 전원공급 데이터                      | · 차량 전체 시스템의 신뢰성과 안전성 평가를 위해 필요                                      |
| 차량 외부로 전송되는 명령 및 정보 데이터                  | · 차량 전체 시스템의 신뢰성과 안전성 평가를 위해 필요, 특히 외부로부터 개입 배경을 확인하기 위해 필요          |

에 관한 20개의 핵심 항목으로 구성된 윤리 강령을 발표한 바 있다. 2021년에 발의한 법안은 운행 주체를 운전자, 생산자, 기술 감독자로 확대했으며 주체별로 법규 준수와 사고, 보호 등에 대한 의무를 나누어 규정하였다. 독일은 정부가 주도적으로 자율주행 빅데이터를 직접 관리하고 구축하는데 기업이 민감한 개인정보를 관리하지 않고 정부가 직접 관리함으로써 투명한 데이터 수집을 이행하겠다는 의지가 담겨있다. 자동차 운행에서 발생한 데이터를 의무적으로 수집·저장할 수 있도록 법제화하여 [표 2-13]과 같이 구체적으로 데이터 종류를 명시하고 저장 의무 이유를 제시<sup>20)</sup>하였다. 이러한 데이터는 인공지능 윤리원칙과 특성에 적용할 수 있는 추적가능성, 설명가능성, 검증가능성, 식별가능성, 준법성, 공공성, 알고리즘 차별성, 모니터링, 제어가능성, 책무성, 투명성 등을 확보하는 데 유용할 것으로 판단된다.

국내에서는 2020년도에 국토교통부에서 ‘자율주행자동차 윤리 가이드라인’을 제정하여 발표하였다. 자율주행자동차 발전과 함께 위험에 노출되는 이슈들을 인간의 생명과 신체의 안전 보호 차원에서 획기적으로 개선하기 위해 자율주행자동차 행위 주체들이 참고, 활용할 수 있도록 국내외 인공지능 및 자율주행자동차 가이드라인, 설문조사, 빅데이터 분석 등을 통하여 윤리 가이드라인을 마련하였다. 가이드라인을 통하여 자율주행자동차의 기본가치와 행동 원칙을 제시하고 설계자·제작자·관리자·서비스 제공자·이용자 등 행위 주체들이 윤리 수준에 따라 제작·운행될 수 있게 하여 자발적으로 책임성을 확보할 수 있도록 하였다. [표 2-14]는 자율주행자동차 윤리 가이드라인의 공통원칙과 행위 주체별 책임<sup>21)</sup>에 대한 내용이다. 공통원칙에는 기본가치와 행동 원칙을 제시하였으며, 행위 주체별 책임은 설계자, 제작자, 관리자, 서비스 제공 및 이용자로 구분하여 책임 사항을 부여하였다. 법적으로 강제화된 내용은 아니지만 자율주행자동차 증가에 따른 윤리 가이드를 제정했다는 것에 대해 큰 의미가 있으며, 독일의 자율주행자동차 관련 법안을 참조하여 지속적인 업그레이드가 되어야 할 것이

20) KOTRA, 독일 정부의 자율주행 레벨 4 상정안 분석 및 시사점, 2021

21) 국토교통부, 자율주행자동차 윤리 가이드라인, 2020

[표 2-14] 자율주행자동차 윤리 가이드라인

| 구 분       |              | 세 부 내 용                                                                                                                                                                                                                                       |
|-----------|--------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 공통        | 기본가치         | ① 인간의 존엄성, 인권과 자유, 프라이버시 및 문화적 다양성 존중, 차별 방지<br>② 인간의 법과 관습에 의한 판단과 통제가 보장되도록 설계·제작·관리<br>③ 인간의 안전과 편익, 자유로운 이동권, 타인의 권리와 자유 침해 방지<br>④ 사고에 의한 피해 최소화, 인간의 생명 우선주의, 차별 방지와 약자 고려<br>⑤ 지구 온난화, 교통체증 등 사회환경 고려, 지속 발전 증진                        |
|           | 원칙           | ① 운행 중 발생 정보 기록시스템 마련으로 투명성, 추적 가능성 확보, 기록정보 차량 보유자 보관, 사고 대응 및 사고처리 필요시 관계자에게 제공<br>② 사용자 의사결정에 의한 제어권 및 기능 제공, 법적 권한자 위임 관리·감독<br>③ 운행과정에서 문제 발생 시 행위 주체별 문제에 상응한 책임<br>④ 안전을 위한 사고 예방, 충돌회피 기술 적용, 안내, 교육, 훈련 실시<br>⑤ 개인정보보호 및 사이버보안 규정 준수 |
| 행위 주체별 책임 | 설계자          | ① 운행 기록 보관 기능 설계 반영<br>② 운행 관련 제반 법규 준수, 윤리 가이드라인 기본 가치 원칙 설정<br>③ 탑승자/자동차 및 차량 외부/자동차 간 상호작용 고려, 사고 대비 안전 기능<br>④ 사전 사고 예방 및 사고 시 피해 최소화<br>⑤ 자동차 보유자나 이용자가 자율시스템 불법개조, 변경 방지<br>⑥ 해킹, 개인정보나 사생활 침해, 불법적 실험 대응 방안 마련, 설계 오류 책임               |
|           | 제작자          | ① 투명성 확보를 위하여 운행기록 관련 기록 보관<br>② 관련 법규·인증기준, 생명 윤리, 정보통신 윤리, 공학 윤리 준수<br>③ 제작상의 결함으로 인해 발생한 피해에 대한 책임<br>④ 사용자에게 대한 기능 사용, 유의사항, 안전 설명 의무, 문서화 제공, 설명 요구응대<br>⑤ 사이버 보안시스템을 갖추고 항상 변경 내용 제공                                                    |
|           | 관리자          | ① 사고의 사후 조치를 위한·관리 감독 의무, 제도·조치사항 마련 및 보완 의무<br>② 물리적 인프라 재정비, 자율주행 기능과 관련된 인력에 대한 홍보, 교육, 훈련, 교통 체계, 정비 서비스, 사회적 인프라 확충에 노력<br>③ 데이터 보관 및 폐기 지침을 이해관계자에게 제공, 사이버 보안 제도·조치 마련                                                                 |
|           | 서비스 제공 및 이용자 | ① 이용자 안전 도모, 타인의 이익이나 공익 침해 방지, 소프트웨어 최신상태 유지<br>② 정해진 목적과 기능에 따라 운행<br>③ 불법적 사용, 오남용 최소화 노력 및 그에 따른 문제에 대해 책임<br>④ 임의 및 불법 개조 금지, 안전을 위한 충분한 교육 이수<br>⑤ 서비스제공자는 서비스 과정에서 생성되는 개인정보 보호                                                        |

다.

자율주행자동차는 운행기록이 매우 중요하기 때문에 차량 소유자가 보관하지만 위·변조가 불가능하도록 설계에 반영되어야 하며, 운행기록에 대한 구체적인 정보 수집 항목을 정의할 필요성이 있다. 자동차, 드론 등 모빌리티 기반의 자율주행 이동체는 센서, 카메라, 레이더, 라이다, 운전자 습관 등의 정보를 수집할 수 있기 때문에 대량의 빅데이터를 확보할 수 있다는 장점이 있다. 빅데이터를 이용하여 인공지능 머신러닝 기술을 적용하므로 자율주행 이동체는 커다란 인공지능 제품이 될 것이며, 개인 맞춤형 서비스가 이루어질 수 있을 것이다. 모빌리티 기반에서 운행되는 자율주행 제품은 지속적으로 소프트웨어 및 학습용 데이터를 업데이트하기 때문에 항상 최신상태를 유지할 수 있게 될 것이다.

인공지능 제품이나 서비스에는 알고리즘에 대한 이슈가 매우 많다. 알고리즘에 대한 중요 쟁점은 알고리즘의 투명성과 알고리즘의 차별성이라 할 수 있다(선지원, 2019). 알고리즘의 투명성은 알고리즘의 설계과정에서부터 개발, 테스트 결과, 오류 수정 등 전 단계에서 이루어진 작업에 대하여 명확하게 설명할 수 있어야 한다. 알고리즘의 수학적인 문제가 왜곡될 수 있으며, 알고리즘 개발에서 설계와 다르게 개발자가 임의로 변경하거나 누락시켜서 설계 의도와 맞지 않은 결과를 초래할 수 있다. 인공지능이 최종 의사결정을 내릴 수 있도록 하는 프로세스에 예상하지 못한 오류나 데이터가 관여될 수 있다. 이러한 수많은 이슈가 알고리즘에서 발생할 수 있기 때문에 알고리즘에 대한 명확한 설명과 검증, 책임에 대한 식별이 가능하도록 투명성이 확보되어야 한다. 알고리즘 차별성은 설계나 개발과정에서 알고리즘이 의사결정 시 분류, 우선순위 결정, 필터링, 불필요하거나 특정 데이터 활용이 가능하도록 설계·개발하거나 임의 조작함으로써 발생할 수 있다. 알고리즘의 투명성 확보와 차별 방지를 위해서는 법적 규제와 윤리적 교육, 이해관계자의 책임 문제를 명확하게 규정 할 수 있도록 해야 할 것이다.

## 4. 측정지표 및 윤리 평가

### 가. 인공지능 서비스 품질 측정지표 개발

소프트웨어 제품이나 서비스의 품질을 높이는 방법으로 품질인증 및 시험 제도를 만들었으며, 품질 시험에 사용하는 도구로 대부분 소프트웨어 품질 측정지표를 사용하게 된다. 측정지표는 측정 목적과 대상, 범위, 기준을 명확하게 규정하여 측정 대상의 상태정도, 기능수준, 완성도 등이 개념적, 실제적으로 존재하는지를 구체적으로 검증 가능하도록 하는 역할을 한다(변준석 외, 2017). 측정지표 개발을 위해서는 무엇을 대상으로 측정할 것인지에 대한 개념을 명확하게 하고 추상적인 개념에 대해서는 일반화를 해야 하며, 측정 개념에 대한 근거를 명확하게 제시해야 한다(Churnchill, 1979). 측정지표를 개발할 때는 전문가를 대상으로 설문, 정성적, 정량적 연구 방법을 적용할 수 있으며, 전문가에게 지표에 대한 신뢰성과 타당성을 검증하기 위한 계량학적인 개발과 평가 과정이 필요하다(임성범 외, 2014).

인공지능에 대한 품질 측정항목을 연구한 논문 중 2018년에 게재된 인공지능 서비스 특징 및 품질 측정항목의 고찰과 제안의 연구에서는 인공지능 특징을 6가지로 나누었고, 각 인공지능 특징에 대한 세부 항목 50개를 도출하여 측정항목으로 제안하였다(백창화 외, 2018). 인공지능의 6가지 특징은 신속성, 고객별 개인맞춤화, 전문성, 고객 감성, 편의성, 안전성으로 구분하여 세부 측정항목을 도출하여 적용하였다. [표 2-15]는 인공지능 서비스 품질 측정항목<sup>22)</sup>을 제시한 것이다. 신속성에 대한 측정항목은 고객들이 서비스에 대한 신속성을 요구하는 항목으로 실시간, 즉각 대응, 약속 시간 준수, 사전 알림이나 피드백을 줄 수 있는 6개 항목으로 구성되었다. 고객별 개인맞춤화에 대한 측정항목은 고객의 개인적인 관심과 최대 혜택, 고객 특성, 요구사항 이해, 커스터마이징 등 9개 항목으로 구성하였다. 전문성에 대한 측정항목은 정확한 배송, 완벽, 안전성, 현장 전문성 등 8개 항목으로 구성하였다.

22) 백창화 외, 인공지능 서비스 특징 및 품질측정항목의 고찰과 제안, 2018

[표 2-15] 인공지능 서비스 품질 측정항목

| Item   | Key Metrics                                                                                                                                                                                                 | Item  | Key Metrics                                                                                                                                                                                                  |
|--------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 신속성    | <ul style="list-style-type: none"> <li>· 시간 준수</li> <li>· 신속</li> <li>· 즉각적 반영</li> <li>· 사전 피드백</li> <li>· 언제나 서비스</li> <li>· 실시간</li> </ul>                                                               | 고객 감성 | <ul style="list-style-type: none"> <li>· 친절함</li> <li>· 편안함</li> <li>· 즐거움</li> <li>· 성실한 태도</li> <li>· 상호 간의 소통</li> <li>· 감정</li> <li>· 친근함</li> <li>· 차별화</li> <li>· 공손한 서비스</li> </ul>                   |
| 개인 맞춤화 | <ul style="list-style-type: none"> <li>· 고객의 개인적 관심사</li> <li>· 최대의 혜택</li> <li>· 고객 특성</li> <li>· 요구사항 이해</li> <li>· 커스터마이징</li> <li>· 예측</li> <li>· 선호도 정보 제공</li> <li>· 최신 트렌드</li> <li>· 다양성</li> </ul> | 편의성   | <ul style="list-style-type: none"> <li>· 어디서나 서비스</li> <li>· 사용하기 쉬움</li> <li>· 직관성</li> <li>· 사용성</li> <li>· 거부감</li> <li>· 단순함</li> <li>· 불편감</li> <li>· 절절한 표현</li> <li>· 호환성</li> <li>· 동시 처리</li> </ul> |
| 전문성    | <ul style="list-style-type: none"> <li>· 정확한 제공</li> <li>· 완벽한 대응</li> <li>· 정확한 답변</li> <li>· 분야별 전문성</li> <li>· 민원 대응</li> <li>· 적절한 대처</li> <li>· 합리성</li> <li>· 가치</li> </ul>                           | 안전성   | <ul style="list-style-type: none"> <li>· 안전한 시스템</li> <li>· 고객정보 관리</li> <li>· 정보보호</li> <li>· 신뢰성</li> <li>· 일관성</li> <li>· 개인정보 보호</li> <li>· 정보 품질관리</li> <li>· 빠른 응답</li> </ul>                          |

고객 감성에 대한 측정항목은 친절과 편안함, 즐거움, 성실함, 상호 간의 소통, 감정, 친근함과 차별함, 공손함 등 9개 항목으로 구성하였다. 편의성에 대한 측정항목은 어디에서나 간편한 사용, 직관적, 사용성, 거부감 등 10개 항목으로 구성하였다. 안전성에 대한 측정항목은 안전한 시스템, 고객정보 관리, 정보보호, 신뢰성, 일관성, 개인정보보호, 정보 품질관리, 빠른 응답 등 8개 항목으로 구성하였다. 이 연구에서는 품질 측정항목에 대한 적절한 타당성 검증이 제시되지 않았다. 측정항목에 대한 측정지표 개발이 이루어져야 인공지능 품질 측정이 가능할 것으로 보인다.

#### 나. 국내 인공지능 개발에 따른 윤리 검증 실행

인공지능의 신뢰성은 전 세계적인 관심 대상이며 인간과 인공지능 간 상호작용에 있어서 신뢰가 낮아지면 인공지능에 대한 발전은 기대하기 어려울 것이다. 하지만 인공지능 기술은 급격하게 발전하고 인공지능이 사용되지 않은 분야가 없을 정도로 광범위하게 적용되고 있기 때문에 인공지능 개발에는 필수적으로 신뢰성이 포함되어야 한다(한상기, 2016). 2022년에 과학기술정보통신부에서 발간한 ‘2022 신뢰할 수 있는 인공지능 개발안내서’는 개발자, 기획자와 같은 인공지능 서비스 개발 현장 실무자들의 의견을 최대한 반영하였고, 개발 프로젝트 리더, 교수, 연구원, 정책담당자 등 다수의 인공지능 분야 전문가에 의하여 검토와 자문을 받고 다양한 의견을 수렴하여 신뢰성을 확보하였다(과학기술정보통신부, 2022). 개발 안내서를 만들기 위해서 미국, 유럽 등 주요 선진국과 국제기구들에서 발표한 인공지능 윤리 권고안, 가이드를 참고하여 자율적으로 점점이 가능한 16개의 개발 요구사항과 59개의 정성적·정

[표 2-16] 인공지능 신뢰성 확보를 위한 기술적 요구사항과 윤리 요건

| 요구사항 |                               | 다양성 존중 | 책임성 | 안전성 | 투명성 |
|------|-------------------------------|--------|-----|-----|-----|
| 01   | 인공지능 시스템에 대한 위험 관리 계획 및 수행    |        | ○   |     | ○   |
| 02   | 데이터의 활용을 위한 상세 정보제공           |        | ○   |     | ○   |
| 03   | 데이터 강건성 확보를 위한 이상 데이터 제거      |        |     | ○   |     |
| 04   | 수집 및 가공된 학습 데이터의 편향 제거        | ○      | ○   |     | ○   |
| 05   | 오픈소스 라이브러리의 보안성 및 호환성 확보      |        | ○   | ○   |     |
| 06   | 인공지능 모델의 편향 제거                | ○      |     |     |     |
| 07   | 인공지능 모델 공격에 대한 방어 대책 수립       |        |     | ○   |     |
| 08   | 인공지능 모델 명세 및 출력 결과에 대한 설명 제공  |        | ○   |     | ○   |
| 09   | 인공지능 모델 출력에 대한 신뢰도 제공         |        |     |     | ○   |
| 10   | 인공지능 시스템 구현 시 발생 가능한 편향 제거    | ○      |     |     |     |
| 11   | 인공지능 시스템의 안전 모드 구현            |        | ○   | ○   | ○   |
| 12   | 인공지능 시스템의 설명에 대한 사용자의 이해도 제고  |        |     |     | ○   |
| 13   | 인공지능 시스템의 추적 가능성 확보           |        |     | ○   | ○   |
| 14   | 서비스 제공 범위 및 상호작용 대상에 대한 설명 제공 |        | ○   |     | ○   |

량적 검증항목이 포함되어 있다. 인공지능 신뢰성에 필요한 요건을 정의하기 위해 ‘인공지능 윤리기준’의 핵심 요건을 준용하였으며, 기술적 관점에서 요구사항과 함께 검증항목을 다양성 존중, 책임성, 안전성, 투명성으로 도출하여 [표 2-16]과 같이 인공지능 신뢰성 확보를 위한 기술적 요구사항과 윤리 요건<sup>23)</sup>을 매칭하여 개발안내서에 적용하였다. 업무상 기술적으로 신뢰성을 고려해야 할 기획자, 데이터 수집 및 가공자, 인공지능 모델 개발자, 시스템 및 소프트웨어 개발자, 테스터 등의 이해관계자들을 대상으로 작성하였기 때문에 인공지능 생명주기 각 단계별 신뢰성 확보를 위한 요구사항을 확인하고 검증하는 주체가 될 수 있도록 하여야 한다(신예진, 2020). [표 2-17]은 인공지능 생명주기 단계별 요구사항의 확인 및 검증 주체<sup>24)</sup>를 정리한 것이다. 안내서를 활용하는 절차는 크게 3단계로 구성되어 있다.

[표 2-17] 인공지능 생명주기 단계별 요구사항 확인 및 검증 주체

| 생명 주기 단계    | 해당 요구사항      | 확인 및 검증 행위자                                                                                                            |
|-------------|--------------|------------------------------------------------------------------------------------------------------------------------|
| 기획 및 설계     | 요구사항 : 01    | <ul style="list-style-type: none"> <li>· 비즈니스 결정권자</li> <li>· 시스템 기획자</li> <li>· 데이터 과학자</li> <li>· 시스템 운영자</li> </ul> |
| 데이터 수집 및 처리 | 요구사항 : 02~04 | <ul style="list-style-type: none"> <li>· 데이터 공급자</li> <li>· 데이터 과학자</li> <li>· 도메인 전문가</li> </ul>                      |
| 인공지능 모델 개발  | 요구사항 : 05~09 | <ul style="list-style-type: none"> <li>· 데이터 과학자</li> <li>· 인공지능 모델 개발자</li> <li>· 시스템 엔지니어</li> </ul>                 |
| 시스템 구현      | 요구사항 : 10~12 | <ul style="list-style-type: none"> <li>· 인공지능 모델 개발자</li> <li>· 시스템 엔지니어</li> </ul>                                    |
| 운영 및 모니터링   | 요구사항 : 13~14 | <ul style="list-style-type: none"> <li>· 비즈니스 결정권자</li> <li>· 인공지능 모델 개발자</li> <li>· 시스템 운영자</li> </ul>                |

23) 과학기술정보통신부(한국정보통신기술협회), 2022 신뢰할 수 있는 인공지능 개발 안내서(안), 2022

24) 한국정보통신기술협회(신예진), 2022 신뢰할수 있는 개발 안내서, 2022

먼저 인공지능 서비스 유형을 검토하는 단계이며, 다음 단계는 요구사항 세부항목에 맞추어 확인 및 검증해야 할 대상을 선별하는 단계이다. 마지막으로 선별된 요구사항을 검증하는 단계로 진행된다. 개발 안내서 외에도 과학기술정보통신부에서 공표한 ‘인공지능 윤리 자율점검표’, 개인정보위원회에서 발표한 ‘인공지능 개인정보 보호 자율점검표’ 등 다양한 인공지능 윤리 점검항목을 활용하여야 할 것이다.

#### 다. 해외 인공지능 윤리 평가 실행

인공지능 분야에서 신뢰성(Trustworthiness)을 ISO/IEC TR 24028 Overview of Trustworthiness in Artificial intelligence에서는 “검증 가능한 방식으로 이해관계자의 기대에 부응하는 능력”이라고 정의했다(ISO/IEC TR 24028, 2020). 유럽연합 집행위원회에서 공개한 ‘신뢰할 수 있는 인공지능 평가목록(ALTAI, The Assessment List for Trustworthy Artificial Intelligence(ALTAI) for Self Assessment)’는 2020년 7월에 공개되었다. 집행위원회가 2019년 수행한 ‘신뢰할 수 있는 인공지능을 위한 윤리 지침’을 기반으로 2018년 6월부터 2020년 6월까지 2년에 걸쳐 개발되었다. 2년 동안 ALTAI를 시범단계, 파일럿 단계에서 선택된 기업과 50개의 심층 인터뷰를 통하여 인공지능 분야에 대한 광범위한 윤리적 요소가 적용되었다. 평가목록은 유럽 각국에서 모인 52명의 인공지능 전문가 그룹(High-Level Expert Group on AI)이 참여하여 만들어진 ALTAI 자체평가 도구이다. 신뢰할 수 있는 인공지능을 위해 인공지능이 충족시켜야 할 7개 요구사항과 각 요구사항에 포함된 평가목록으로 구성된 윤리적 조건이다. 7개 요구사항의 핵심은 인간의 자율성 존중, 위해 방지, 공정성, 설명가능성이라 할 수 있다. ALTAI는 유럽연합에서 구속력을 지닌 법률안은 아니지만 인공지능 개발과 사용에 대한 중요한 가이드라인과 고려사항을 제시하여 실용적인 도구가 될 수 있으며, 향후 인공지능 윤리 관련 법률안 마련 시 구체화할 수 있는 기본 틀로 활용할 수 있을 것이다. 유럽연합은 최초로 다국적 논의를 통하여 만들어진 ALTAI를 이용하여 향후 유럽이 인공지능 경쟁에서 우위를

확보하고 인공지능 분야 리더가 되기 위한 차원이기도 하다. 유럽은 인공지능 분야에서 미국이나 중국에 뒤진 상황이지만 개인정보보호규정(GDRP)의 강력한 프라이버시 설명을 요구할 권리, 잊힐 권리 등을 앞세워 인공지능 윤리연구와 인공지능 분야의 경쟁력을 확보하기 위한 노력을 하고 있다. ALTAI의 7가지 요구사항과 주 평가목록 및 항목 수<sup>25)</sup>는 [표 2-18]과 같이 요약하였다.

[표 2-18] ALTAI의 요구사항 및 평가목록 항목 수 현황

| 요구사항                     | 요구사항별 핵심 내용                                                                                                                     | 주 평가목록 |
|--------------------------|---------------------------------------------------------------------------------------------------------------------------------|--------|
| #1. 인간의 기본권, 자율성, 존엄성 존중 | <ul style="list-style-type: none"> <li>· 인간의 주체와 자율성</li> <li>· 인간의 감독</li> </ul>                                               | 11개 항목 |
| #2. 기술적 견고성과 안전성         | <ul style="list-style-type: none"> <li>· 일반 안전</li> <li>· 정확성</li> <li>· 공격 및 보안에 대한 복원력</li> <li>· 신뢰성, 대체 계획 및 재현성</li> </ul> | 21개 항목 |
| #3. 개인정보 보호 및 데이터 거버넌스   | <ul style="list-style-type: none"> <li>· 프라이버시</li> <li>· 데이터 거버넌스</li> </ul>                                                   | 6개 항목  |
| #4. 투명성                  | <ul style="list-style-type: none"> <li>· 추적성</li> <li>· 설명 가능성</li> <li>· 의사 소통</li> </ul>                                      | 5개 항목  |
| #5. 다양성, 차별금지 및 공정성      | <ul style="list-style-type: none"> <li>· 불공정한 편견 방지</li> <li>· 접근성과 보편적 디자인</li> <li>· 이해관계자 참여</li> </ul>                      | 10개 항목 |
| #6. 사회 및 환경에 미치는 영향      | <ul style="list-style-type: none"> <li>· 환경 웰빙</li> <li>· 업무 및 기술에 미치는 영향</li> <li>· 사회 전체 또는 민주주의에 미치는 영향</li> </ul>           | 8개 항목  |
| #7. 책무성                  | <ul style="list-style-type: none"> <li>· 감사 가능성</li> <li>· 위기 관리</li> </ul>                                                     | 8개 항목  |

ALTAI를 통하여 인공지능 소프트웨어의 잠재적 취약성과 위험성을 사전에 파악할 수 있도록 지원하며, 인간의 자율성을 보장하고 인공지능의 모든 의사결정에 대하여 인간이 감독하며 개입할 수 있어야 하는 조건을 포함하였고 친환경성과 사회

25) 유럽연합 집행위원회, 신뢰할 수 있는 인공지능 자체 평가목록, 2020

적 웰빙, 책무성, 프라이버시와 데이터 통제, 투명성, 다양성 및 비차별성, 공공성, 기술적 견고성과 안전성을 이룰 수 있도록 하는 데 목적을 두었다. ALTAI의 사용 주체는 인공지능 시스템 디자이너 및 개발자, 데이터 과학자, 조달 담당자 및 전문가, 인공지능 사용자, 법률 및 준법 관리 담당자, 관리자 등이다. ALTAI는 국내에서 신뢰할 수 있는 인공지능을 위한 정책 및 인공지능 윤리 가이드, 윤리원칙, 지침, 평가항목 개발에 많이 참고하고 있다. ALTAI는 인공지능의 기술적 영역뿐만 아니라 인간에 대한 존중, 자율, 인권 및 사회 환경에 미치는 영향까지 폭넓게 인공지능 윤리를 적용하였다.

영국의 ICO에서는 2020년에 개발한 ‘인공지능과 데이터 보호 안내 지침(Guidance on Artificial Intelligence and Data Protection)’을 개발하여 인공지능 개발에 적용할 수 있도록 하였다. 인공지능의 응용프로그램이 점차 인간의 삶에 깊이 관여되고 있는 상황에서 개인의 권리와 자유를 보호하고 인공지능으로부터 위험을 최소화하기 위해 데이터 보호 규정을 만들었다(영국 ICO, 2020). 안내 지침 사용 대상은 데이터 보호 책임자(DPD), 법률 고문, 위험 관리자, 고위 경영진 및 ICO 자체 감사관, 기계 학습 전문가, 데이터 과학자, 소프트웨어 개발 및 엔지니어, 사이버보안 및 IT 위험 관리자를 포함한 기술 전문가를 사용 주체로 보았다. 주요 구성 내용은 첫째, 데이터 보호 영향평가를 포함하여 인공지능 책임과 거버넌스 문제를 체크 할 수 있도록 구성되었다. 둘째, 데이터 처리의 적법한 근거와 평가 및 개선을 포함하여 공정성과 투명성을 확보할 수 있도록 하는 체크 문항으로 구성되었다. 셋째, 데이터 보안 및 개인정보 처리의 최소화를 다룰 수 있도록 하는 체크 문항을 포함하여 구성되었다. 넷째, 자동화된 의사결정과 관련된 권리를 포함하여 개인정보와 관련된 권리보장을 규정과 법에 근거하여 받을 수 있도록 구성되었다. 안내 지침은 인공지능이 데이터 보호 의무를 준수할 수 있도록 하는 감사 프레임워크로 개발되었다. 각국은 인공지능 윤리 가이드라인 및 원칙 수준을 벗어나 인공지능 개발에 적용할 윤리 체크리스트를 개발하여 이해관계자에게 제공하고 있다(방정미, 2021).

## 제 3 장 인공지능 윤리원칙 및 윤리 측정지표

### 제 1 절 인공지능 윤리원칙 분류 모형 및 구성요소

#### 1. 인공지능 윤리원칙 분류 및 구성요소

세계 각국은 인공지능 윤리에 대한 관심도가 높아지면서 인공지능 윤리 가이드, 지침, 원칙, 개발 지침, 평가목록 등 다양한 규정이나 지침을 개발하여 현장에 사용하고 있다. 하지만 아직도 인공지능 윤리원칙과 그 구성요소가 명확하게 분류되지 않아 인공지능 윤리를 적용하는데 어려움이 존재하고 있다. 따라서 인공지능 전 분야에 활용할 수 있는 범용적인 인공지능의 윤리원칙 정의와 분류를 체계화하기 위하여 인공지능 윤리원칙 분류 모형에 관한 연구에서 5개의 윤리원칙을 정의하고 분류하였다(소순주·안성진, 2021). 또한 인공지능 윤리원칙에 해당하는 윤리적 특성을 구성요소로 정의하여 인공지능 윤리원칙 분류 모형 및 구성요소를 개발하였다(소순주·안성진, 2021). 원칙의 의미는 가치가 다양한 현상들에 적용될 수 있는 규범으로 사실 요소, 규칙, 기준 및 지침을 도덕적 또는 정치적으로 정당화하는 기능을 하지만 법적 구속력은 없다(Sunstein, 1995). 인공지능 윤리원칙 분류 모형과 구성요소를 연구하기 위하여 국내외 인공지능 윤리 가이드라인, 윤리원칙, 윤리 현장, 개발 지침, 연구보고서, 학술지 및 학위 논문, 제품 및 서비스 등 40여 종의 문헌에서 윤리원칙, 특성, 문제점, 준거, 요소, 기준 등을 중점적으로 분석하였다. 분석된 문헌을 바탕으로 15명이 참여한 인공지능 윤리 관련 전문가 그룹에 의하여 전문가 심층 면접(FGI: Focus Group Interview)을 3차로 실시하였다. FGI에서 윤리원칙에 대한 정의 검토와 각 원칙에 해당하는 구성요소를 도출하여 정의하였다. 최종적으로 도출된 윤리원칙은 5개로 분류되었으며, 각 원칙별 구성요소는 총 20개가 정의되었다.

FGI에서 최종적으로 도출된 윤리원칙과 구성요소 검증을 위하여 53명을 대상으로 설문조사를 실시하고 설문 분석에 의하여 연구 결과를 정리하였다. [표 3-1]은 인공지능 윤리원칙을 5개로 정의한 것이다. 5개의 윤리원칙과 구성요소는 투명성에 설명가능성, 추적가능성, 검증가능성, 식별가능성이며, 책무성에는 준법성, 이용자 책임성, 책임 식별성, 개발 표준성이며, 공정성에는 접근성, 데이터 편향성, 알고리즘 차별성, 공공성으로 되어 있다.

[표 3-1] 인공지능 윤리원칙 정의

| 윤리원칙                     | 윤리원칙 정의                                                                                                                                              | 참고문헌                                                                                                                                                                                                                                                               |
|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 투명성<br>(Transparency)    | 인공지능에 의하여 어떤 행위가 왜 발생했는지 혹은 어떤 행위가 왜 발생하지 않았는지를 명확하게 검증이 가능한 원칙                                                                                      | AI HLEG(2019),<br>BDV(2019),<br>Binns, R(2018),<br>Berkman Klein center(2020),<br>Cabinet Office (2019),<br>Cowls, J., & Floridi, L(2018),<br>Erik, b. Daniel. R., & Chad. S(2017),<br>FLI(2017),<br>IEEE(2022),<br>KISDI(2018),<br>UNESCO(2021),<br>한국표준협회 (2022) |
| 책무성<br>(Accountability)  | 인공지능 기술 및 서비스에 대한 정보공유, 사고 등의 책임 (Responsibility) 분배를 명확하게 규정하고, 배상의 정도를 정확하게 측정하여 문제 발생 시 원인을 객관적, 상세화에 의하여 그 결과를 누구에게 물어야 하는가에 대한 행위 주체별 책임에 대한 원칙 |                                                                                                                                                                                                                                                                    |
| 공정성<br>(Fairness)        | 인공지능이 데이터를 처리하는 과정에서부터 인공지능 기능을 이용하는 단계에 이르기까지 특정 개인이나 집단에 차별, 편향되지 않도록 공정하게 보장되어야 하는 원칙                                                             |                                                                                                                                                                                                                                                                    |
| 통제성<br>(Controllability) | 인공지능기술 및 서비스에 대한 인간의 제어 가능성 및 오작동에 대한 대비책을 미리 마련하고, 이용자의 이용 선택권은 최 대한 보장 하며, 인공지능 모니터링에 의하여 사전에 위험을 방지할 수 있는 원칙                                      |                                                                                                                                                                                                                                                                    |
| 안전성<br>(Safety)          | 인공지능 시스템의 판단, 예측 결과에 따라 시스템 오작동과 위험, 부작용 등이 발생하여 이용자와 환경에 악영향이 미치지 않도록 인공지능 수명 전반에 걸쳐 안전하게 유지, 예방할 수 있는 원칙                                           |                                                                                                                                                                                                                                                                    |

\* 참고문헌 기술 방법 : 영문은 알파벳 순, 한글은 가나다 순으로 기술함

통제성에는 제어 가능성, 모니터링, 이용자 주도성으로 되어 있으며, 마지막으로 안전성에는 상태 인식성, 견고성, 보안성, 프라이버시 보호, 가치정렬로 되어 있다. [표 3-2]~[표 3-6]은 인공지능 윤리원칙별 각 구성요소를 정의한 것이다.

[표 3-2] 투명성 윤리원칙에 포함된 구성요소 정의

| 구성요소                        | 구성요소 정의                                                                              | 참고문헌                                                                                                                                                                                     |
|-----------------------------|--------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 설명가능성<br>(Explainability)   | AI의 판단·예측에 대한 근거와 결과 과정을 이해관계자가 쉽게 이해할 수 있도록 단어나 문장, 그림, 데이터 등으로 표현하여 설명할 수 있게 하는 요소 | AI HLEG(2019),<br>Berkman Klein center(2020),<br>Binns, R(2018),<br>IEEE(2022),<br>Joshua A. Kroll (2017),<br>Leslie, D(2019),<br>UNESCO(2021),<br>김효은(2018),<br>백수원(2021),<br>양종모(2020) |
| 추적가능성<br>(Traceability)     | AI에 문제가 발생 시 필요한 각종 데이터에 신속하게 접근하여 문제 발생 원인을 추적할 수 있도록 하는 요소                         |                                                                                                                                                                                          |
| 검증가능성<br>(Verifiability)    | AI는 기술과 기능, 역할이 구별되어 있기 때문에 안전성을 보장하기 위하여 일정한 기준의 시험과 검증이 가능해야 하는 요소                 |                                                                                                                                                                                          |
| 식별가능성<br>(Discriminability) | AI의 작동과정을 구현하기 위한 소프트웨어의 기능과 내용을 이해관계자가 쉽게 식별하여 확인할 수 있는 요소                          |                                                                                                                                                                                          |

[표 3-3] 책무성 윤리원칙에 포함된 구성요소 정의

| 구성요소                                      | 구성요소 정의                                                                                            | 참고문헌                                                                                                                                                                                                        |
|-------------------------------------------|----------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 준법성<br>(Compliance)                       | AI 이해관계자와 사용자는 사고 발생 시 책임을 명확 하게하기 위하여 제반 법규와 윤리 가이드라인을 준수해야 하는 요소                                 | AI HLEG(2018),<br>BDV(2019),<br>Leslie, D(2019),<br>Joshua A. Kroll(2017),<br>Michael Butterworth (2018),<br>Steven F(2019),<br>Sung.T(2019),<br>UNESCO(2021),<br>정원섭(2020),<br>최미란(2021),<br>한국표준협회 (2022) |
| 책임 식별성<br>(Responsibility Identification) | AI는 법적, 윤리적 기준으로 이해관계자가 책임을 질 수 있도록 모든 과정을 기록, 보관하여 문제 발생 시 그 행위 주체가 누구인지 명확하게 책임을 식별할 수 있어야 하는 요소 |                                                                                                                                                                                                             |
| 이용자 책임성<br>(User Responsibility)          | AI 이용자는 AI 소프트웨어를 최신 상태로 유지(업데이트)하며, AI를 정해진 목적과 서비스 약관 규정에 의하여 사용해야 하는 책임 요소                      |                                                                                                                                                                                                             |
| 개발 표준성<br>(Development Standardity)       | AI 설계와 개발은 AI 윤리를 준수하며, 시스템 간의 상호연결성, 운용성이 가능하도록 국제표준이나 인증규격을 준용하여 개발, 배포하여야 하는 책임 요소              |                                                                                                                                                                                                             |

[표 3-4] 공정성 윤리원칙에 포함된 구성요소 정의

| 구성요소                                       | 구성요소 정의                                                                                                            | 참고문헌                                                                                                                                                                                     |
|--------------------------------------------|--------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 접근성<br>(Accessibility)                     | AI는 누구나 공평하게 이용, 통제할 수 있어야 하며, 개인이나 소수집단, 취약계층이 차별받지 않도록 공평하게 분배되어 교육, 재화, 서비스, 기술에 대한 접근기회를 동등하게 제공할 수 있어야 하는 요소  | BDV(2019),<br>Binns, R(2018),<br>CIPL(2020),<br>EU(2020),<br>FTC(2020),<br>IEEE(2022),<br>Joshua A. Kroll(2017),<br>UNESCO(2021),<br>박미정(2019),<br>변순용(2019),<br>양종모(2017),<br>정원섭(2020) |
| 알고리즘 차별성<br>(Algorithmic Differentiations) | AI 알고리즘을 인위적 또는 의도적으로 조작하여 알고리즘 처리결과가 편향되게 나타남으로써 공정성과 투명성, 정확성을 훼손하게 되는 요소                                        |                                                                                                                                                                                          |
| 데이터 편향성<br>(Data Bias)                     | AI 학습용 데이터를 수집, 가공, 반영하는 과정에서 인위적 또는 의도적으로 개입하거나 조작하여 AI 처리결과가 편향되게 나타남으로써 공정성과 신뢰성을 훼손하게 되는 요소                    |                                                                                                                                                                                          |
| 공공성<br>(Publicness)                        | AI 기술은 가능한 많은 사람에게 도움을 주어야 하며, AI에 의하여 창출된 경제적 이익과 혜택은 모든 인류와 광범위하게 공유되어야 하고, AI로 인한 위험과 부작용 등의 피해가 발생하지 않도록 하는 요소 |                                                                                                                                                                                          |

[표 3-5] 통제성 윤리원칙에 포함된 구성요소 정의

| 구성요소                                | 구성요소 정의                                                                                                                  | 참고문헌                                                                                                                      |
|-------------------------------------|--------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| 제어 가능성<br>(Machine Controllability) | AI 이용자가 AI 오작동으로 인하여 위험 상황 발생, 법규 위반, 사회적 규범 저해 등 이상 징후를 발생 시 그 작동을 즉각적으로 제어 또는 정지시킬 수 있어야 하는 요소                         | AI HLEG(2018),<br>Berkman Klein center(2020),<br>FTC(2020),<br>IEEE(2022),<br>Leslie, D(2019),<br>박소영(2019),<br>임경숙(2019) |
| 모니터링<br>(Monitoring)                | AI의 위험 요소를 사전에 예측하기 위하여 학습용 입력데이터의 적절성, 법규적용의 적절성, 서비스 이상 징후, 오작동에 의한 결과, 정상 작동 여부 등을 상시 감시하여 위험, 부작용 등을 예방할 수 있도록 하는 요소 |                                                                                                                           |
| 이용자 주도성<br>(User Initiative)        | AI 이용자가 AI 서비스 범위 내에서 그 기능을 자율적으로 조작하여 편의성 향상, 위험 회피, 법규 준수, 사회적 규범 준수 등이 가능하도록 하는 요소                                    |                                                                                                                           |

[표 3-6] 안전성 윤리원칙에 포함된 구성요소 정의

| 구성요소                             | 구성요소 정의                                                                                                                      | 참고문헌                                                                                                                                                                                                                                                                   |
|----------------------------------|------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 상태 인식성<br>(Condition Awareness)  | AI 이용자는 AI가 안전하게 작동되고 있는지 상태를 확인(검증)할 수 있어야 하며, 위험, 부작용 발생 시 이용자에게 즉시 상황을 제공하여 사용자가 예방, 대처할 수 있도록 하는 요소                      | Adamson, G. (2019),<br>Ayre C(2014),<br>CIPL(2020),<br>EU(2020),<br>FLI(2017),<br>FTC(2020),<br>Google(2021),<br>IEEE(2022).<br>Leslie, D(2019),<br>Michael Butterworth (2018),<br>Samuel D(2018),<br>UNESCO(2021),<br>과학기술정보통신부(2021),<br>김중세(2020),<br>허준,안성진 (2020) |
| 견고성<br>(Robust)                  | AI는 외부의 간섭 및 극한적인 운영환경에서도 이용자가 의도한 수준의 AI 성능과 기능을 유지할 수 있도록 하는 요소                                                            |                                                                                                                                                                                                                                                                        |
| 보안성<br>(Security)                | AI 시스템은 이용자로부터 비인가된 정보를 수집할 수 없어야 하며, 해킹 등 외부 공격으로부터 보호해야 하고, 기밀성, 무결성, 가용성을 확보할 수 있도록 보안 검증이나 타당성이 확인되어야 하는 요소              |                                                                                                                                                                                                                                                                        |
| 프라이버시 보호<br>(Privacy Protection) | AI는 이용자와 제3자의 사생활 안전과 개인정보보호 및 통신 비밀 등이 포함된 프라이버시 침해가 되지 않도록 해야 하며, 프라이버시 침해 영향평가를 받아 AI 이용 전 과정에서 개인의 프라이버시를 보호할 수 있게 하는 요소 |                                                                                                                                                                                                                                                                        |
| 가치정렬<br>(Value Alignment)        | 고도로 자율적인 AI 시스템은 작동하는 동안 그의 목표와 행동이 인간의 가치와 일치하도록 설계, 개발되어야 한다는 요소                                                           |                                                                                                                                                                                                                                                                        |

## 2. 인공지능 윤리원칙 분류 모형 및 구성요소 검증

FGI에 의하여 최종적으로 도출된 윤리원칙과 구성요소를 바탕으로 분류 모형을 개발하기 위하여 설문조사와 설문 분석을 통하여 신뢰성과 상관관계를 검증하였다. 설문에 참여한 표본은 53명이었으며, 인공지능 윤리 전문가, 인공지능 개발자, 설계자, 컨설턴트, 운영자, 법률가, 인공지능 교육자, 일반 사용자를 대상으로 설문조사를 실시하였다. 설문지 설계는 윤리원칙 분류와 각 구성 요소별로 작성되었으며, 측정 도구는 Likert 5점 척도로 구성하였다. 설문 분석은 기술통계량 분석, 신뢰도 분석, 상관관계를 분석하였다. 인공지능 윤리원칙 분류에 대한 신뢰도 분석 결과는 [표 3-7]과 같이 나타났다.

[표 3-7] 인공지능 윤리원칙 분류의 신뢰도 분석 결과

| 윤리 원칙 | 항목제거 시 Cronbach $\alpha$ | Cronbach $\alpha$ | 항목수 |
|-------|--------------------------|-------------------|-----|
| 투명성   | .923                     | .951              | 53  |
| 책임성   | .933                     |                   |     |
| 공정성   | .926                     |                   |     |
| 통제성   | .938                     |                   |     |
| 안전성   | .932                     |                   |     |

윤리원칙 분류의 신뢰도 분석 결과 전체 Cronbach  $\alpha$  값이 0.951로 나타났으며, 각 항목별 항목 제거 시 값은 Cronbach  $\alpha$  값이 0.951보다 낮게 나타났기 때문에 항목을 제거하면 신뢰수준이 낮아지므로 윤리원칙 각 항목은 신뢰수준을 저해하는 항목이 없다고 볼 수 있다(송지준, 2010). 이어서 윤리원칙 분류에 대한 상관관계분석 결과는 [표 3-8]과 같이 나타났다. 상관관계분석 결과에서는 모든 항목이 상관계수 0.01 유의수준 하에서 유의하게 분석되었다. 투명성은 책임성, 공정성과 0.701 이상으로 높은 상관관계이며, 통제성과 안전성과는 0.638 이상으로 다소 높은 상관관계이며, 책임성은 공정성, 통제성, 안전성과 0.816 이상의 상관관계로 나타났다.

[표 3-8] 인공지능 윤리원칙 분류의 상관관계분석 결과

| 분류  | 평균   | 표준 편차 | 구성개념 간 상관관계 |        |        |        |     |
|-----|------|-------|-------------|--------|--------|--------|-----|
|     |      |       | 투명성         | 책임성    | 공정성    | 통제성    | 안전성 |
| 투명성 | 4.31 | .676  | 1           |        |        |        |     |
| 책임성 | 4.23 | .740  | .701**      | 1      |        |        |     |
| 공정성 | 4.35 | .752  | .705**      | .893** | 1      |        |     |
| 통제성 | 4.28 | .834  | .679**      | .816** | .865** | 1      |     |
| 안전성 | 4.40 | .711  | .638**      | .877** | .921** | .854** | 1   |

\*\* : 상관계수는 0.01 수준(양쪽)에서 유의합니다.

공정성은 통제성과 0.865, 안전성과 0.921로 매우 높은 상관관계로 나타났다. 통제성과 안전성은 0.854로 높은 상관관계로 분석되었다. [표 3-9]는 인공지능 윤리원칙의 구성 요소에 대한 신뢰도 분석 결과이다.

[표 3-9] 인공지능 윤리원칙의 구성요소 신뢰도분석 결과

| 윤리원칙 | 구성요소     | 항목제거 시 Cronbach α | Cronbach α |
|------|----------|-------------------|------------|
| 투명성  | 설명가능성    | .831              | .834       |
|      | 추적가능성    | .767              |            |
|      | 검증가능성    | .717              |            |
|      | 식별가능성    | .818              |            |
| 책임성  | 준법성      | .798              | .843       |
|      | 책임 식별성   | .751              |            |
|      | 이용자 책임성  | .805              |            |
|      | 개발 표준성   | .841              |            |
| 공정성  | 접근성      | .882              | .886       |
|      | 알고리즘 차별성 | .833              |            |
|      | 데이터 편향성  | .832              |            |
|      | 공공성      | .856              |            |
| 통제성  | 제어 가능성   | .824              | .834       |
|      | 모니터링     | .724              |            |
|      | 이용자 주도성  | .753              |            |
| 안전성  | 상태 인식성   | .868              | .896       |
|      | 견고성      | .870              |            |
|      | 보안성      | .859              |            |
|      | 프라이버시 보호 | .877              |            |
|      | 가치정렬     | .894              |            |

전체 Cronbach  $\alpha$  값이 0.8 이상의 높은 신뢰계수로 윤리원칙에 해당하는 구성요소 간의 신뢰도는 별문제 없는 것으로 나타났다. 투명성에 포함된 구성요소 간의 상관관계분석은 [표 3-10]와 같이 나타났다. 투명성의 구성요소 간 상관관계수는 0.01 유의수준 하에 모두 유의하였으며, 설명가능성과 식별가능성은 낮은 상관관계를 가지고 있으나 나머지는 0.513 이상으로 다소 높은 상관관계로 분석되었다.

[표 3-10] 투명성 원칙의 구성요소 상관관계분석 결과

| 구성요소  | 평균   | 표준편차 | 구성개념 간 상관관계 |        |        |       |
|-------|------|------|-------------|--------|--------|-------|
|       |      |      | 설명가능성       | 추적가능성  | 검증가능성  | 식별가능성 |
| 설명가능성 | 4.51 | .639 | 1.00        |        |        |       |
| 추적가능성 | 4.43 | .721 | .513**      | 1.00   |        |       |
| 검증가능성 | 4.26 | .984 | .577**      | .757** | 1.00   |       |
| 식별가능성 | 3.96 | .940 | .385**      | .536** | .635** | 1.00  |

책무성의 구성요소 간 상관관계분석은 [표 3-11]과 같으며, 공정성의 구성요소 간 상관관계분석은 [표 3-12], 통제성의 구성요소 간 상관관계분석은 [표 3-13], 안전성의 구성요소 간 상관관계분석은 [표 3-14]과 같다. 원칙별 구성요소 간의 상관관계수는 0.01 유의수준 하에 모두 유의하였다. 상관관계분석 결과 또한 모든 구성요소 간 상관관계가 0.452 이상으로 다소 높거나, 높은 것으로 나타났다.

[표 3-11] 책무성 원칙의 구성요소 상관관계분석 결과

| 구성요소    | 평균   | 표준편차 | 구성개념 간 상관관계 |        |         |        |
|---------|------|------|-------------|--------|---------|--------|
|         |      |      | 준법성         | 책임식별성  | 이용자 책임성 | 개발 표준성 |
| 준법성     | 4.36 | .811 | 1.00        |        |         |        |
| 책임식별성   | 4.36 | .901 | .821**      | 1.00   |         |        |
| 이용자 책임성 | 4.26 | .923 | .488**      | .647** | 1.00    |        |
| 개발 표준성  | 3.94 | .949 | .452**      | .497** | .566**  | 1.00   |

[표 3-12] 공정성 원칙의 구성요소 상관관계분석 결과

| 구성요소     | 평균   | 표준편차 | 구성개념 간 상관관계 |          |         |      |
|----------|------|------|-------------|----------|---------|------|
|          |      |      | 접근성         | 알고리즘 차별성 | 데이터 편향성 | 공공성  |
| 접근성      | 4.40 | .862 | 1.00        |          |         |      |
| 알고리즘 차별성 | 4.28 | .928 | .602**      | 1.00     |         |      |
| 데이터 편향성  | 4.43 | .821 | .622**      | .795**   | 1.00    |      |
| 공공성      | 4.30 | .845 | .545**      | .747**   | .750**  | 1.00 |

[표 3-13] 통제성 원칙의 구성요소 상관관계분석 결과


| 구성요소    | 평균   | 표준편차 | 구성개념 간 상관관계 |        |         |
|---------|------|------|-------------|--------|---------|
|         |      |      | 제어가능성       | 모니터링   | 이용자 주도성 |
| 제어 가능성  | 4.40 | .884 | 1.00        |        |         |
| 모니터링    | 4.32 | .894 | .688**      | 1.00   |         |
| 이용자 주도성 | 4.11 | .913 | .658**      | .766** | 1.00    |

[표 3-14] 안전성 원칙의 구성요소 상관관계분석 결과

| 구성요소     | 평균   | 표준편차 | 구성개념 간 상관관계 |        |        |         |      |
|----------|------|------|-------------|--------|--------|---------|------|
|          |      |      | 상태인식성       | 견고성    | 보안성    | 프라이버시보호 | 가치정렬 |
| 상태 인식성   | 4.42 | .663 | 1.00        |        |        |         |      |
| 견고성      | 4.38 | .765 | .784**      | 1.00   |        |         |      |
| 보안성      | 4.49 | .869 | .641**      | .700** | 1.00   |         |      |
| 프라이버시 보호 | 4.49 | .891 | .593**      | .541** | .876** | 1.00    |      |
| 가치정렬     | 4.21 | .968 | .672**      | .593** | .608** | .638**  | 1.00 |

### 3. 인공지능 윤리원칙 분류 모형 및 구성요소 연구 결과

인공지능의 다양한 특성과 윤리, 인간 존중, 기술, 보안, 인권, 사회적 책임, 공공성, 안전, 이해관계자 간의 책임, 편향성, 표준화 등 쟁점이 되는 모든 사항을 고려하여 인공지능 윤리원칙을 정의하고 5개로 분류하였다. 인공지능 윤리원칙을 먼저 정의하고 분류한 후 각 윤리원칙에 포함된 구성요소는 20개로 정의하여 윤리원칙 분류 모형과 구성요소를 개발하였다. 인공지능 윤리원칙 분류 모형과 구성요소를 <그림 3-1>과 같이 도식화하였다. 그동안 윤리원칙은 국내외에서 다양한 윤리 기준과 가이드라인, 지침들을 통하여 발표되고 있으나 명확하게 윤리원칙별로 윤리적 특성을 분석하여 체계적으로 구성요소를 제시한 것은 없었다. 이 연구 결과는 인공



<그림 3-1> 인공지능 윤리원칙 분류 모형 및 구성요소

지능 설계, 개발, 운영 및 사용 시 윤리적인 쟁점을 원칙과 구성 요소별로 명확하게 적용할 수 있는 기틀이 될 수 있을 것이다.

윤리원칙 분류 모형과 구성요소를 이용하여 인공지능 윤리 측정지표와 측정지표별 점검항목을 개발하여 인공지능 윤리인증 및 심사에 활용할 수 있을 것이다. 인공지능 로봇이나 지능형 자율주행 이동체, 인공지능 서비스 등은 윤리 적용을 위한 개념 정립이 상당한 수준에서 이루어지고 있으나 인간 존중, 신뢰성, 투명성, 공정성, 안전성 등에 대한 이론적 개념과 책임 문제에 초점을 맞추고 있기 때문에 체계적으로 개발된 윤리원칙 분류 모형과 구성요소를 기반으로 인공지능 관련 각 산업 분야에 적용한다면 보다 신뢰할 수 있는 인공지능 사회를 만들 수 있을 것이다. 인공지능 윤리원칙에 포함된 각 구성요소에 대한 세부적인 윤리 측정지표를 인공지능 적용 산업 분야별로 개발할 수 있는 기틀이 마련되었다는데 중요한 연구 결과라 할 수 있다.

## 제 2 절 인공지능 윤리 측정지표

### 1. 인공지능 윤리 측정지표

인공지능 개발이 활성화되면서 인공지능 학습용 데이터 구축, 빅데이터 수집, 모빌리티 플랫폼, 자율주행자동차, 자율이동체, 지능형 드론, 챗봇 서비스, 헬스케어 서비스, 군사용 드론, 비대면 서비스, 마이데이터에 의한 맞춤형 개인서비스, 메타버스 등 전 산업 분야에서 급속하게 인공지능이 발전하고 있다(Orawar, 2021). 인공지능개발이 증가하면서 더욱 인공지능 윤리 문제가 대두되고 있으며, 윤리문제를 해결하기 위하여 윤리 평가목록, 체크리스트, 개발 지침 안내서 등이 윤리원칙을 기반으로 개발되어 현장에 적용되고 있다(박정하, 2022). 2021년에 인공지능 윤리원칙 분류 모형 및 구성요소를 개발한 후 개발 결과를 바탕으로 국내외 인공지능 윤리 체크리스트, 개발 지침, 평가목록, 가이드라인, 정책, 소프트웨어 인증, 품질인증, 다양한 평가지표 등 관련 문헌 분석과 전문가 그룹 인터뷰(FGI) 및 설문조사, 설문 분석에 의하여 인공지능과 인간 간 상호작용 시 인간의 인격권 및 재산을 보호하기 위한 인공지능 윤리 측정지표를 개발하였다(소순주·안성진, 2022).

윤리 측정지표 개발은 인공지능 윤리원칙 분류 모형과 구성요소를 기반으로 우선 인간의 생명과 재산을 보호할 수 있는 영역에 중점을 두고 개발하였다. 따라서 윤리원칙 5개와 구성요소 20개 중 윤리원칙 5개와 구성요소 10개에 대한 윤리 측정지표가 개발되어 인공지능 전 산업 분야에 범용적으로 활용할 수 있도록 하였다. 윤리 측정지표 개발을 위하여 인공지능 관련 전문가 20명으로 전문가 그룹을 구성하고 전문가 심층 면접(FGI)을 3회, 전화이 조사 2회를 실시하여 [표 3-15]와 같이 구성 요소별 윤리 측정지표 도출과 검증 대상을 선정하였다. 도출된 윤리 측정지표 항목은 82개였으며, 전화이 조사에 의하여 43개 검증 대상 항목을 선정하였다. 투명성 원칙에서는 설명가능성에 7개, 추적가능성에 5개, 검증가능성에 5개를 도출하였

[표 3-15] 인공지능 윤리원칙 구성요소별 측정지표 검증 대상 항목 현황

| 윤리원칙 | 구성요소     | 도출된 측정 항목 수 | 선정된 측정항목 수 |
|------|----------|-------------|------------|
| 투명성  | 설명가능성    | 7           | 5          |
|      | 추적가능성    | 5           | 3          |
|      | 검증가능성    | 5           | -          |
| 책임성  | 준법성      | 4           | 3          |
|      | 책임식별성    | 6           | 4          |
| 공정성  | 알고리즘 차별성 | 7           | 5          |
|      | 데이터 편향성  | 11          | 7          |
|      | 공공성      | 7           | -          |
| 통제성  | 제어가능성    | 5           | 4          |
|      | 이용자 주도성  | 6           | -          |
| 안전성  | 견고성      | 7           | 3          |
|      | 보안성      | 5           | 4          |
|      | 프라이버시 보호 | 7           | 5          |
| 합 계  |          | 82          | 43         |

으며, 책임성에서는 준법성에 4개, 책임식별성에 6개 항목을 도출, 공정성에서는 알고리즘 차별성에 7개, 데이터 편향성에 11개, 공공성에 7개, 통제성에서는 제어가능성에 5개, 이용자 주도성에 6개 항목 도출, 안전성에서는 견고성에 7개, 보안성에 5개, 프라이버시 보호에 7개 총 82개 항목을 도출하고 그중 43개 항목을 선정하여 측정지표로 활용하기 위한 검증을 실시하였다. 선정된 43개 측정지표 항목에 대한 정의는 투명성 원칙의 설명가능성, 추적가능성에 대한 측정지표로는 [표 3-16]과 같다.

[표 3-16] 투명성 원칙에 포함된 윤리 측정지표 항목 정의

| 윤리원칙 구성요소 | 측정지표           | 측정지표 정의                                                                                | 참고문헌                           |
|-----------|----------------|----------------------------------------------------------------------------------------|--------------------------------|
| 설명가능성     | 최종 사용자를 위한 투명성 | AI가 하는 기능과 이유를 최종 사용자가 쉽게 이해할 수 있도록 간단한 방법으로 제공하여, 사용자로 하여금 AI에 대한 신뢰를 구축할 수 있도록 하는 지표 | AI HLEG(2019), Binns, R(2018), |

|       |                      |                                                                                                                                               |                                                                                                                                                                                  |
|-------|----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|       | 사고조사자를 위한 투명성        | AI가 예기치 않는 사고 또는 문제를 발생하여 사용자나 사회에 해를 끼쳤을 경우 그 발생 원인을 파악하기 위한 사고 조사자에게 사고 중 발생 상황과 세부 사항, AI가 의사결정에 사용한 데이터(로그, 정보), 처리 프로세스를 제공할 수 있도록 하는 지표 | FLI(2017), IEEE(2022), Joshua A. Kroll (2017), Leslie, D(2019), Michael Butterworth (2018), Steven F(2019), UNESCO(2021), 고학수외(2020), 과학기술정책연구원(2018), 권허영(2019), 이한슬, 천현득(2021) |
|       | 변호사 및 전문가 증인을 위한 투명성 | AI 사고에 따른 대응으로 변호사 또는 기타 전문가 증인에 의하여 사고와 관련하여 AI의 다양한 관련 자료(품질관리 프로세스, 윤리적 위험평가 수행 등)를 증거로 법원, 보험사 등에 제공하여 사고 발생에 대한 해석을 할 수 있도록 하는 지표        |                                                                                                                                                                                  |
|       | 이용 범위 고지 투명성         | AI 기능과 사용범위, 기능의 한계, 예상되는 위험, 사용자가 AI에 제공하는 학습 데이터 범위에 대하여 최종 사용자에게 명확하게 고지하여 AI 고유의 기능을 안전하게 사용할 수 있도록 하는 지표                                 |                                                                                                                                                                                  |
|       | 이용자 데이터 수집 투명성       | AI가 사용하는 학습용 데이터의 수집 방법, 항목, 출처, 기준 등에 대한 프로세스와 정책이 AI와 관련된 이해관계자에게 설명될 수 있도록 하는 지표                                                           |                                                                                                                                                                                  |
| 추적가능성 | 문제 분석을 위한 데이터 제공     | AI 제조 또는 운영자는 AI가 예기치 않거나, 원하지 않는 방식으로 행동하여 사고 또는 문제가 발생하였을 경우 그 원인을 찾을 수 있도록 AI가 의사결정에 적용한 데이터(정보)를 제공하는 지표                                  | AI HLEG(2019), Binns, R(2018), FLI(2017), IEEE(2022), Joshua A. Kroll (2017), KISDI(2018), Leslie, D(2019), UNESCO(2021)                                                         |
|       | 제작 과정의 기록 보관         | AI를 제작하기 위한 설계, 개발, 판매, 운용 과정에서 도출된 기록들을 보관하여 AI가 문제 발생 시 그 원인을 추적하기 위하여 제공 가능한 지표                                                            |                                                                                                                                                                                  |
|       | 사고 발생 이력 보관          | AI를 운영 및 서비스 시 발생했던 각종 문제점 및 사고에 대하여 기록 보관하고, 그에 따른 해결 결과를 기록으로 남겨 향후 유사 사례 발생 시 확인, 검토할 수 있는 자료로 제공하는 지표                                     |                                                                                                                                                                                  |

인공지능 책무성 윤리원칙에 포함된 각 구성 요소별 측정지표 세부 내용은 [표 3-17] 과 같다.

[표 3-17] 책무성 원칙에 포함된 윤리 측정지표 항목 정의

| 윤리원칙<br>구성요소 | 측정지표                  | 측정지표 정의                                                                                                                                                            | 참고문헌                                                                                                                                                                                             |
|--------------|-----------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 준법성          | 법·제도 준수               | 개발된 AI 제품이나 서비스가 설계단계에서부터 관련 법규를 준수하고, 관련 법규에 위배되지 않았다는 근거를 제시할 수 있는 지표                                                                                            | BDV(2019),<br>Binns, R(2018),<br>CIPL(2020),<br>EU(2020),<br>FTC(2020),<br>IEEE(2022),<br>Joshua A.<br>Kroll(2017),<br>Lepri, B(2018).<br>UNESCO(2021),<br>박미정(2019),<br>양종모(2017),<br>정원섭(2020) |
|              | 개인정보<br>제공 동의<br>획득   | 학습용 원시데이터 수집 시 개인정보가 포함된 데이터를 수집하는 경우에는 반드시 수집에 대한 동의와 활용, 제3자 제공 등에 대한 동의를 받아야 하는 지표                                                                              |                                                                                                                                                                                                  |
|              | 데이터 사용<br>사전 허가<br>획득 | 인공지능에 사용하는 데이터가 공적, 보안, 지적재산권, 안전 등에 해당하는 경우 이해관계자에게 관련 법·제도상의 규정에 따라 사전 허가를 받아야 하는 지표                                                                             |                                                                                                                                                                                                  |
| 책임식별성        | 설계자<br>책임식별           | AI 설계자는 제반 법규를 적용하여 기획, 설계하여야 하며, 사용자의 안전을 최우선적으로 보호할 수 있도록 설계자의 책임 범위를 명확하게 규정하여 식별할 수 있도록 하는 지표                                                                  |                                                                                                                                                                                                  |
|              | 제작자<br>책임식별           | AI 제작자는 윤리적, 법적 기준에 대한 투명성을 확보하기 위하여 AI 제작에 적용된 관련 인증기준, 법규, 생명 윤리, 공학 윤리, 정보통신 윤리를 준수하며, 제작자가 책임져야 할 범위를 명확하게 규정하여 식별할 수 있도록 하는 지표                                |                                                                                                                                                                                                  |
|              | 운영자<br>책임식별           | AI 제품이나 서비스를 운영하는 주체가 지속적인 모니터링, 관리, 예측 가능한 위험 관리 등에 대하여 수행해야 할 범위를 명확하게 규정하여 식별할 수 있도록 하는 지표                                                                      |                                                                                                                                                                                                  |
|              | 이용자<br>책임식별           | AI 제품이나 서비스 이용자가 본인 안전과 타인의 이익이나 공익을 침해하지 않도록 하며, 최신 상태의 소프트웨어를 유지하는 등 이용자 의무 준수 사항을 숙지할 수 있도록 하여 AI 이용에 따른 문제, 위험 발생 시 그에 따른 이용자 책임 범위를 명확하게 규정하여 식별할 수 있도록 하는 지표 |                                                                                                                                                                                                  |

인공지능 공정성 윤리원칙에 포함된 각 구성 요소별 측정지표 세부 내용은 [표 3-18] 과 같다.

[표 3-18] 공정성 원칙에 포함된 윤리 측정지표 항목 정의

| 윤리원칙<br>구성요소 | 측정지표                | 측정지표 정의                                                                                     | 참고문헌                                                                                                                                                                                             |
|--------------|---------------------|---------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 알고리즘<br>차별성  | 알고리즘의<br>의사결정<br>설명 | 알고리즘 처리 시 의사결정에 포함되는 분류, 우선 순위 결정, 필터링, 적용 항목, 관련 데이터 등에 대한 속성에 대하여 이해관계자에게 설명할 수 있도록 하는 지표 | BDV(2019),<br>Binns, R(2018),<br>CIPL(2020),<br>EU(2020),<br>FTC(2020),<br>IEEE(2022),<br>Joshua A.<br>Kroll(2017),<br>Lepri, B(2018).<br>UNESCO(2021),<br>박미정(2019),<br>양종모(2017),<br>정원섭(2020) |
|              | 의도적 차별<br>요소 제한     | 인공지능 개발 시 알고리즘 설계나 개발 단계에서 의도적으로 차별적인 요소를 삽입하지 않도록 하는 지표                                    |                                                                                                                                                                                                  |
|              | 개인 편향적<br>차별 제한     | 불가피한 사고 예측 상황에서 개인적인 요소 (성별, 나이, 관계, 신체적 정신적 체질)에 따른 편향적 차별이 이루어지지 않도록 하는 지표                |                                                                                                                                                                                                  |
|              | 불공정한<br>알고리즘        | AI 알고리즘이 인위적으로 특정 인종, 집단, 계층, 소수자 등을 제외시키지 않도록 개발되어 공정성을 훼손하지 않도록 하는 지표                     |                                                                                                                                                                                                  |
|              | 인간의 생명<br>위협 방지     | AI로 인하여 인간이 생명의 위협을 받거나 사망에 이르게 할 수 있는 알고리즘을 방지할 수 있도록 하는 지표                                |                                                                                                                                                                                                  |

|         |                   |                                                                                            |                                                                                                                                                                                          |
|---------|-------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 데이터 편향성 | 편향적 특성 제거         | 원시데이터는 지역, 사회 및 인종적 편견, 성별, 연령 등 활용 의도와 무관한 편향적인 특성이 제거될 수 있도록 하는 지표                       | BDV(2019),<br>Binns, R(2018),<br>CIPL(2020),<br>EU(2020),<br>FTC(2020),<br>IEEE(2022),<br>Joshua A. Kroll(2017),<br>UNESCO(2021),<br>박미정(2019),<br>변순용(2019),<br>양종모(2017),<br>정원섭(2020) |
|         | 데이터의 사실성          | 원시데이터를 인위적인 환경과 조건 하에 획득해야 하는 경우에는 반드시 실제 환경과 상황, 특성을 반영할 수 있도록 하는 지표                      |                                                                                                                                                                                          |
|         | 학습용 데이터 설명        | AI 학습에 적용한 모든 데이터는 이해관계자에게 설명할 수 있도록 하는 지표                                                 |                                                                                                                                                                                          |
|         | 학습용 데이터의 수량       | AI 학습을 위하여 적용한 데이터는 분류체계별 균일성과 비율을 고려하여 적정한 수량을 반영할 수 있도록 하는 지표                            |                                                                                                                                                                                          |
|         | 데이터의 유효성 검사       | 학습용 데이터를 이용하여 AI 알고리즘을 훈련시켰을 때 목표로 했던 수준의 성능을 달성하는지 확인하는 유효성 검사 지표                         |                                                                                                                                                                                          |
|         | 학습용 데이터 품질관리      | 학습용 데이터의 정확성과 적합성, 안전성, 품질 확보를 위한 데이터 품질관리 정책을 수립하고 품질 관리 활동에 의하여 양질의 데이터를 적용할 수 있도록 하는 지표 |                                                                                                                                                                                          |
|         | 데이터 편향 방지 알고리즘 적용 | 학습용 데이터를 수집할 때 데이터 편향성을 방지하기 위한 기준, 정책을 수립하여 알고리즘에 적용할 수 있도록 하는 지표                         |                                                                                                                                                                                          |

인공지능 통제성 윤리원칙에 포함된 각 구성 요소별 측정지표 세부 내용은 [표 3-19] 과 같다.

[표 3-19] 통제성 원칙에 포함된 윤리 측정지표 항목 정의

| 윤리원칙<br>구성요소 | 측정지표             | 측정지표 정의                                                                                        | 참고문헌                                                                                                                      |
|--------------|------------------|------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| 제어가능성        | 정책적 통제권<br>이양    | AI 제품이나 서비스를 사용자 또는 운영자가 통제 불가능할 경우 법·제도적 정책에 의하여 국가(공적기관) 차원에서 통제가 가능하도록 통제권을 이양할 수 있도록 하는 지표 | AI HLEG(2018),<br>Berkman Klein center(2020),<br>FTC(2020),<br>IEEE(2022),<br>Leslie, D(2019),<br>박소영(2019),<br>임경숙(2019) |
|              | 이용자에게<br>제어장치 제공 | AI 이용자가 직접 AI의 사용, 정지, 이용자의 의도에 따라 AI를 이용할 수 있게 하는 장치나 서비스를 이용자에게 제공할 수 있도록 하는 지표              |                                                                                                                           |
|              | 생명 위협 시<br>자동 종료 | AI가 기능을 수행하는 중 인간에게 생명의 위협이 예측될 때는 즉시 자동으로 그 기능을 정지, 차단, 종료할 수 있도록 하는 지표                       |                                                                                                                           |
|              | 운영자의 통제<br>및 제어  | AI를 운영하는 주체는 AI의 오작동, 위험 상황 발생, 이상 징후 발생 등 의도하지 않는 상태가 되었을 경우 즉시 통제, 제어할 수 있도록 하는 지표           |                                                                                                                           |

인공지능 안전성 윤리원칙에 포함된 각 구성 요소별 측정지표 세부 내용은 [표 3-20]과 같다.

[표 3-20] 안전성 원칙에 포함된 윤리 측정지표 항목 정의

| 윤리원칙<br>구성요소 | 측정지표             | 측정지표 정의                                                                       | 참고문헌                                                                                                                        |
|--------------|------------------|-------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|
| 견고성          | 인간의 보호<br>우선     | 모든 AI 제품이나 서비스는 인간의 생명 보호를 최우선 순위에 두고 제작될 수 있도록 하는 지표                         | Adamson, G (2019),<br>Ayre C(2014),<br>CIPL(2020),<br>EU(2020),<br>FLI(2017),<br>FTC(2020),<br>Google(2021),<br>IEEE(2022), |
|              | 알고리즘의<br>오류 관리   | AI 사용 중 예측하지 못한 오류로 인하여 AI 고유의 기능을 수행하지 못하거나, 사용자에게 피해가 발생한 사례가 존재하는지 관리하는 지표 |                                                                                                                             |
|              | 외부 공격에<br>대한 견고성 | AI는 외부로부터 물리적, 기술적 해킹이나 공격을 받을 경우 이를 차단, 방지하여 고유의 기능이 지속적으로 유지될 수 있도록 하는 지표   |                                                                                                                             |

|          |               |                                                                                                       |                                                                                                                                                                                        |
|----------|---------------|-------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 보안성      | 보안성 인증        | AI는 기술적, 정책적 법규에 따라 기밀성, 무결성, 가용성을 확보할 수 있도록 보안성 검증이나 타당성이 확인될 수 있도록 하는 지표                            | Leslie, D(2019), Michael Butterworth (2018), Samuel D(2018), UNESCO(2021), 개인정보보호위원회(2021), 과학기술정보통신부(2021), 김종세(2020), 남정아(2019), 양종모(2020), 장철호, 차윤호(2021), 조수영(2018), 허준, 안성진(2020) |
|          | 사용자 인증        | 사용자 인증이 필요한 AI는 사용하기 전 인가자임을 확인하기 위하여 사용자 인증 정책에 따라 AI에 접속하여 인증을 받은 후 사용할 수 있도록 하는 지표                 |                                                                                                                                                                                        |
|          | 상호작용 데이터 보안   | AI와 이용자 간의 상호작용으로 축적된 데이터, 지식은 이용자의 동의 없이 AI 운영자 또는 제3자에게 제공되지 않도록 하는 지표                              |                                                                                                                                                                                        |
|          | 보안 이벤트 사용자 제공 | AI 사용 중 발생한 보안 이벤트 정보를 사용자에게 제공하여 AI에 관련된 보안 상태를 인지할 수 있도록 하는 지표                                      |                                                                                                                                                                                        |
| 프라이버시 보호 | 개인정보보호 영향평가   | AI 제품이나 서비스가 개인정보보호를 위한 조치가 필요한 경우 개인정보보호 영향평가를 받을 수 있도록 하는 지표                                        |                                                                                                                                                                                        |
|          | 개인정보 수집고지     | AI가 학습용 데이터로 사용하기 위해 수집한 개인정보가 있을 경우 사용자에게 개인정보 수집항목, 보관기간, 사용 목적 및 적용 범위, 폐기 등을 명확하게 고지할 수 있도록 하는 지표 |                                                                                                                                                                                        |
|          | 개인정보 가명화      | AI가 수집하는 개인정보 데이터는 개인정보보호 관련 법규에 따라 가명화, 암호화 등으로 보호가 될 수 있도록 하는 지표                                    |                                                                                                                                                                                        |
|          | 개인 민감정보 수집차단  | AI 알고리즘은 이해관계자로부터 승인되지 않는 개인 민감정보 수집을 차단할 수 있도록 하는 지표                                                 |                                                                                                                                                                                        |
|          | 개인정보 활용       | AI는 개인정보를 적법하게 특정 목적을 위하여 수집, 활용할 수 있게 하며, 해당 목적에 부합하지 않은 추가적인 처리나 활용을 하지 않도록 하는 지표                   |                                                                                                                                                                                        |

## 2. 인공지능 윤리 측정지표 검증

FGI에 의하여 최종적으로 선정된 43개 인공지능 윤리 측정지표를 바탕으로 설문 조사와 설문분석을 통하여 신뢰성과 상관관계를 검증하였다. 설문에 참여한 표본은 55명이었으며, 인공지능 윤리전문가, 법률가, 교육자, 설계자, 개발자, 제작자, 일반사용자였다. 설문지 설계는 윤리원칙 분류 모형과 구성요소를 기반으로 각 구성요소에 해당하는 측정지표로 작성되었으며, 측정도구는 Likert 5점 척도로 구성하였다. 설문 분석은 기술통계량 분석, 신뢰도 분석, 상관관계를 분석하였다. 윤리 측정지표에 대한 신뢰도 분석 결과는 [표 3-21]과 같이 나타났다. 인공지능 윤리 측정지표 신뢰도 분석 결과 Cronbach  $\alpha$  값이 보안성의 구성요소는 0.739, 나머지 구성요소는 0.8 이상으로 나타났다.

[표 3-21] 인공지능 윤리 측정지표 신뢰도 분석 결과

| 윤리원칙 구성요소 | 측정지표                 | 항목제거 시 Cronbach $\alpha$ | Cronbach $\alpha$ |
|-----------|----------------------|--------------------------|-------------------|
| 설명가능성     | 최종 사용자를 위한 투명성       | .847                     | .882              |
|           | 사고조사자를 위한 투명성        | .875                     |                   |
|           | 변호사 및 전문가 증인을 위한 투명성 | .840                     |                   |
|           | 이용 범위 고지 투명성         | .863                     |                   |
|           | 이용자 데이터 수집 투명성       | .855                     |                   |
| 추적가능성     | 문제 분석을 위한 데이터 제공     | .820                     | .852              |
|           | 제작 과정의 기록 보관         | .743                     |                   |
|           | 사고 발생 이력 보관          | .812                     |                   |
| 준법성       | 법·제도 준수              | .730                     | .850              |
|           | 개인정보 제공 동의 획득        | .767                     |                   |
|           | 데이터 사용 사전 허가 획득      | .872                     |                   |
| 책임 식별성    | 설계자 책임 식별            | .828                     | .870              |
|           | 제작자 책임 식별            | .830                     |                   |
|           | 운영자 책임 식별            | .834                     |                   |
|           | 이용자 책임 식별            | .843                     |                   |

|          |                   |      |      |
|----------|-------------------|------|------|
| 알고리즘 차별성 | 알고리즘의 의사결정 설명     | .867 | .804 |
|          | 의도적 차별 요소 제한      | .750 |      |
|          | 개인 편향적 차별 제한      | .756 |      |
|          | 불공정한 알고리즘         | .708 |      |
|          | 인간의 생명 위협 방지      | .693 |      |
| 데이터 편향성  | 편향적 특성 제거         | .847 | .864 |
|          | 데이터의 사실성          | .851 |      |
|          | 학습용 데이터 설명        | .915 |      |
|          | 학습용 데이터의 수량       | .872 |      |
|          | 데이터의 유효성 검사       | .866 |      |
|          | 학습용 데이터 품질관리      | .855 |      |
|          | 데이터 편향 방지 알고리즘 적용 | .844 |      |
| 제어 가능성   | 정책적 통제권 이양        | .888 | .912 |
|          | 이용자에게 제어장치 제공     | .890 |      |
|          | 생명 위협 시 자동 종료     | .889 |      |
|          | 운영자의 통제 및 제어      | .877 |      |
| 견고성      | 인간의 보호 우선         | .815 | .872 |
|          | 알고리즘의 오류 관리       | .890 |      |
|          | 외부 공격에 대한 견고성     | .746 |      |
| 보안성      | 보안성 인증            | .751 | .739 |
|          | 사용자 인증            | .626 |      |
|          | 상호작용 데이터 보안       | .612 |      |
|          | 보안 이벤트 사용자 제공     | .811 |      |
| 프라이버시 보호 | 개인정보보호 영향평가       | .803 | .901 |
|          | 개인정보 수집 고지        | .876 |      |
|          | 개인정보 가명화          | .892 |      |
|          | 개인 민감정보 수집 차단     | .881 |      |
|          | 개인정보 활용           | .877 |      |

따라서 사회과학 분야에서 일반적인 Cronbach  $\alpha$  값이 0.6 이상이면 신뢰도가 있다고 보기 때문에 신뢰성에는 문제가 없다고 볼 수 있다(송지준, 2010).

투명성에 포함된 설명가능성의 측정지표에 대한 상관관계분석은 [표 3-22]와 같이 나타났다. 설명가능성의 측정지표 간 상관계수는 0.01 유의수준 하에 모두 유의하였으며, 설명가능성에 대한 측정지표 간의 상관계수가 모두 0.441 이상이므로 다소 높은 상관관계를 가지고 있었다. 또한 모든 구성요소에 포함된 측정지표 간의 상관계수는 0.01 유의수준 하에 모두 유의하였다. [표 3-23]부터 [표 3-31]까지 각 구성요소에 대한 측정지표의 상관관계분석 결과이다.

[표 3-22] 설명가능성의 측정지표 상관관계분석 결과

| 구성요소                 | 평균   | 표준편차 | 구성개념 간 상관관계 |       |       |       |      |
|----------------------|------|------|-------------|-------|-------|-------|------|
|                      |      |      | 1           | 2     | 3     | 4     | 5    |
| 최종 사용자를 위한 투명성       | 4.33 | .747 | 1.00        |       |       |       |      |
| 사고조사자를 위한 투명성        | 4.29 | .916 | .589*       | 1.00  |       |       |      |
| 변호사 및 전문가 증인을 위한 투명성 | 4.44 | .977 | .664*       | .600* | 1.00  |       |      |
| 이용 범위 고지 투명성         | 4.40 | .807 | .557*       | .441* | .737* | 1.00  |      |
| 이용자 데이터 수집 투명성       | 4.13 | .944 | .728*       | .556* | .601* | .564* | 1.00 |

[표 3-23] 추적가능성의 측정지표 상관관계분석 결과

| 구성요소             | 평균   | 표준편차 | 구성개념 간 상관관계 |       |      |
|------------------|------|------|-------------|-------|------|
|                  |      |      | 1           | 2     | 3    |
| 문제 분석을 위한 데이터 제공 | 4.29 | .685 | 1.00        |       |      |
| 제작 과정의 기록 보관     | 4.27 | .870 | .703*       | 1.00  |      |
| 사고 발생 이력 보관      | 4.45 | .978 | .628*       | .700* | 1.00 |

[표 3-24] 준법성의 측정지표 상관관계분석 결과

| 구성요소            | 평균   | 표준편차 | 구성개념 간 상관관계 |       |      |
|-----------------|------|------|-------------|-------|------|
|                 |      |      | 1           | 2     | 3    |
| 법·제도 준수         | 4.45 | .919 | 1.00        |       |      |
| 개인정보 제공 동의 획득   | 4.42 | .786 | .783*       | 1.00  |      |
| 데이터 사용 사전 허가 획득 | 4.15 | .951 | .622*       | .586* | 1.00 |

[표 3-25] 책임식별성의 측정지표 상관관계분석 결과

| 구성요소     | 평균   | 표준편차 | 구성개념 간 상관관계 |       |       |      |
|----------|------|------|-------------|-------|-------|------|
|          |      |      | 1           | 2     | 3     | 4    |
| 설계자 책임식별 | 4.31 | .879 | 1.00        |       |       |      |
| 제작자 책임식별 | 4.40 | .852 | .623*       | 1.00  |       |      |
| 운영자 책임식별 | 4.45 | .789 | .594*       | .716* | 1.00  |      |
| 이용자 책임식별 | 4.13 | .982 | .683*       | .580* | .593* | 1.00 |

[표 3-26] 알고리즘 차별성의 측정지표 상관관계분석 결과

| 구성요소          | 평균   | 표준편차 | 구성개념 간 상관관계 |       |       |       |      |
|---------------|------|------|-------------|-------|-------|-------|------|
|               |      |      | 1           | 2     | 3     | 4     | 5    |
| 알고리즘의 의사결정 설명 | 2.18 | .475 | 1.00        |       |       |       |      |
| 의도적 차별 요소 제한  | 4.49 | .717 | .059        | 1.00  |       |       |      |
| 개인 편향적 차별 제한  | 4.42 | .832 | .132        | .457* | 1.00  |       |      |
| 불공정한 알고리즘     | 4.55 | .789 | .126        | .664* | .520* | 1.00  |      |
| 인간의 생명 위협 방지  | 4.51 | .836 | .042        | .626* | .673* | .778* | 1.00 |

[표 3-27] 데이터 편향성의 측정지표 상관관계분석 결과

| 구성요소              | 평균   | 표준편차 | 구성개념 간 상관관계 |       |      |       |       |       |      |
|-------------------|------|------|-------------|-------|------|-------|-------|-------|------|
|                   |      |      | 1           | 2     | 3    | 4     | 5     | 6     | 7    |
| 편향적 특성 제거         | 4.35 | .865 | 1.00        |       |      |       |       |       |      |
| 데이터의 사실성          | 4.40 | .852 | .663*       | 1.00  |      |       |       |       |      |
| 학습용 데이터 설명        | 2.11 | .567 | .148        | .061  | 1.00 |       |       |       |      |
| 학습용 데이터의 수량       | 4.44 | .764 | .496*       | .637* | .059 | 1.00  |       |       |      |
| 데이터의 유효성 검사       | 4.09 | .908 | .645*       | .574* | .160 | .475* | 1.00  |       |      |
| 학습용 데이터 품질관리      | 4.25 | .844 | .917*       | .603* | .173 | .485* | .549* | 1.00  |      |
| 데이터 편향 방지 알고리즘 적용 | 4.49 | .920 | .713*       | .926* | .073 | .690* | .588* | .647* | 1.00 |

[표 3-28] 제어가능성의 측정지표 상관관계분석 결과

| 구성요소          | 평균   | 표준편차 | 구성개념 간 상관관계 |       |       |      |
|---------------|------|------|-------------|-------|-------|------|
|               |      |      | 1           | 2     | 3     | 4    |
| 정책적 통제권 이양    | 4.47 | .858 | 1.00        |       |       |      |
| 이용자에게 제어장치 제공 | 4.07 | .920 | .589*       | 1.00  |       |      |
| 생명 위협 시 자동 종료 | 4.44 | .856 | .950*       | .594* | 1.00  |      |
| 운영자의 통제 및 제어  | 4.15 | .951 | .641*       | .940* | .626* | 1.00 |

[표 3-29] 견고성의 측정지표 상관관계분석 결과

| 구성요소         | 평균   | 표준편차 | 구성개념 간 상관관계 |       |      |
|--------------|------|------|-------------|-------|------|
|              |      |      | 1           | 2     | 3    |
| 인간의 보호 우선    | 4.44 | .856 | 1.00        |       |      |
| 알고리즘의 오류 관리  | 4.31 | .858 | .595*       | 1.00  |      |
| 외부공격에 대한 견고성 | 4.51 | .858 | .802*       | .688* | 1.00 |

[표 3-30] 보안성의 측정지표 상관관계분석 결과

| 구 성 요 소       | 평균   | 표준편차 | 구성개념 간 상관관계 |       |      |      |
|---------------|------|------|-------------|-------|------|------|
|               |      |      | 1           | 2     | 3    | 4    |
| 보안성 인증        | 4.51 | .767 | 1.00        |       |      |      |
| 사용자 인증        | 4.02 | .892 | .609*       | 1.00  |      |      |
| 상호작용 데이터 보안   | 4.31 | .879 | .586*       | .583* | 1.00 |      |
| 보안 이벤트 사용자 제공 | 2.07 | .378 | .118        | .051  | .154 | 1.00 |

[표 3-31] 프라이버시 보호 측정지표 상관관계분석 결과

| 구성요소         | 평균   | 표준편차 | 구성개념 간 상관관계 |       |       |       |      |
|--------------|------|------|-------------|-------|-------|-------|------|
|              |      |      | 1           | 2     | 3     | 4     | 5    |
| 개인정보보호 영향평가  | 4.45 | .919 | 1.00        |       |       |       |      |
| 개인정보 수집고지    | 4.45 | .789 | .807*       | 1.00  |       |       |      |
| 개인정보 가명화     | 4.09 | .908 | .615*       | .613* | 1.00  |       |      |
| 개인 민감정보 수집차단 | 4.33 | .695 | .632*       | .601* | .626* | 1.00  |      |
| 개인정보 활용      | 4.29 | .875 | .684*       | .609* | .595* | .754* | 1.00 |

상관관계분석 결과 43개의 측정지표 중 알고리즘의 의사결정 설명, 학습용 데이터 설명, 보안 이벤트 사용자 제공 등 3개의 측정지표가 해당 구성요소에서 관계 계수가 낮은 것으로 분석되었다. 따라서 최종적으로 윤리 측정지표는 43개 중 40개를 확정하여 인공지능 윤리 측정지표로 개발되었다.

### 3. 인공지능 윤리 측정지표 연구 결과

인공지능 윤리원칙과 구성요소를 기반으로 인공지능 개발에 우선적으로 적용할 인간의 인격권과 재산을 보호할 수 있는 인공지능 윤리 측정지표 40개를 개발하였다. 최종 개발된 윤리 측정지표 현황은 [표 3-32]와 같다. 개발된 윤리 측정지표는 인공지능 개발 및 도입, 운영, 사용을 위하여 범용적으로 사용할 수 있을 것이다.

[표 3-32] 인공지능 윤리 측정지표 현황

| 윤리원칙 | 구성요소 (항목 수)  | 측정지표                 |
|------|--------------|----------------------|
| 투명성  | 설명가능성<br>(5) | 최종 사용자를 위한 투명성       |
|      |              | 사고조사자를 위한 투명성        |
|      |              | 변호사 및 전문가 증인을 위한 투명성 |
|      |              | 이용 범위 고지 투명성         |
|      |              | 이용자 데이터 수집 투명성       |
|      | 추적가능성<br>(3) | 문제 분석을 위한 데이터 제공     |
|      |              | 제작 과정의 기록 보관         |
|      |              | 사고 발생 이력 보관          |
| 책임성  | 준법성<br>(3)   | 법·제도 준수              |
|      |              | 개인정보 제공 동의 획득        |
|      |              | 데이터 사용 사전 허가 획득      |

|     |                 |                   |
|-----|-----------------|-------------------|
|     | 책임 식별성<br>(4)   | 설계자 책임 식별         |
|     |                 | 제작자 책임 식별         |
|     |                 | 운영자 책임 식별         |
|     |                 | 이용자 책임 식별         |
| 공정성 | 알고리즘 차별성<br>(4) | 의도적 차별 요소 제한      |
|     |                 | 개인 편향적 차별 제한      |
|     |                 | 불공정한 알고리즘         |
|     |                 | 인간의 생명 위협 방지      |
|     | 데이터 편향성<br>(6)  | 편향적 특성 제거         |
|     |                 | 데이터의 사실성          |
|     |                 | 학습용 데이터의 수량       |
|     |                 | 데이터의 유효성 검사       |
|     |                 | 학습용 데이터 품질관리      |
|     |                 | 데이터 편향 방지 알고리즘 적용 |
| 통제성 | 제어 가능성<br>(4)   | 정책적 통제권 이양        |
|     |                 | 이용자에게 제어장치 제공     |
|     |                 | 생명 위협 시 자동 종료     |
|     |                 | 운영자의 통제 및 제어      |
| 안전성 | 견고성<br>(3)      | 인간의 보호 우선         |
|     |                 | 알고리즘의 오류 관리       |
|     |                 | 외부 공격에 대한 견고성     |
|     | 보안성<br>(3)      | 보안성 인증            |
|     |                 | 사용자 인증            |
|     |                 | 상호작용 데이터 보안       |
|     | 프라이버시 보호<br>(5) | 개인정보보호 영향평가       |
|     |                 | 개인정보 수집 고지        |
|     |                 | 개인정보 가명화          |
|     |                 | 개인 민감 정보 수집 차단    |
|     |                 | 개인정보 활용           |

### 제 3 절 인공지능 윤리 측정지표 확장 개발

#### 1. 인공지능 윤리 측정지표 항목 확장 개발 연구 방법

인공지능 윤리 측정지표는 최초에 2022년 6월 인공지능 윤리원칙 분류 모형 및 구성요소를 바탕으로 인격권 및 재산 보호를 위한 윤리 측정지표로 40개 항목을 개발하였다(소순주·안성진, 2022). 본 연구에서는 인공지능 윤리원칙 5개와 구성요소 20개 중 윤리원칙 5개와 구성요소 15개를 대상으로 신뢰성 확보를 위한 인공지능 윤리 측정지표를 확장 개발하여 인공지능 제품이나 서비스에 적용할 수 있도록 하는 데 중점을 두고 연구 개발하였다. 인공지능 윤리 측정지표 확장 개발은 전문가 심층 면접과 델파이 설문조사를 통하여 진행하였다. 인공지능 윤리 측정지표를 연구하기 위하여 인공지능 윤리원칙 분류와 구성요소를 바탕으로 국내외 다양한 인공지능 관련 문헌, 선행연구, 정책, 윤리 지침 등에 의하여 인공지능 윤리에 적용할 측정항목을 도출하였다. 도출된 윤리 측정지표 항목은 인공지능 사회 실현을 위하여 신뢰할 수 있는 인공지능 윤리 측정지표로 활용할 수 있도록 하는 기준을 마련하고자 하였다. 인공지능 윤리원칙과 구성요소에서 15개의 구성요소를 선정하고 해당 구성요소의 측정지표 개발을 위해 30명의 전문가 심층 면접 3회와 델파이 설문조사 2회를 실시하였다. 전문가 심층 면접에서는 브레인스토밍으로 진행하고, 산출물 작성 도구는 마인드맵(MindMap)을 사용하여 측정 대상 항목과 의견을 정리하였으며, 델파이 설문조사에 의하여 내용 타당도 분석을 실시하였다. 전문가 심층 면접에서 최종적으로 도출된 인공지능 윤리 측정지표에 대한 상관관계를 검증하기 위해 FGI에 참여한 전문가 30명을 대상으로 8일 동안 설문조사를 실시하였다. 설문 데이터를 이용하여 신뢰도 분석, 기술통계량 분석, 인공지능 윤리원칙의 구성요소와 측정지표 간 상관관계분석(Correlation Analysis)을 통하여 인공지능 윤리 측정지표를 검증하고 해당 지표에 대한 정의를 제시하였다.

## 2. 전문가 심층 면접(FGI)과 델파이 설문조사

전문가 심층 면접과 델파이 설문조사에 참여한 다양한 분야의 인공지능 기술과 인공지능 윤리 관련 업무에 종사한 전문가 그룹은 총 30명이었으며, 3차에 걸쳐 FGI를 진행하고, 델파이 설문조사는 2회 실시하였다. [표 3-33]은 FGI와 델파이 설문조사에 참여한 전문가 그룹 현황이다.

[표 3-33] 전문가 그룹 참여자 현황

| 직업 (직무)      | 인원수       | 인원 비율(%)   | 평균 경력연수    | 평균 연령       |
|--------------|-----------|------------|------------|-------------|
| AI 윤리전문가     | 5         | 16.7       | 4.7        | 46.2        |
| AI 관련 법률전문가  | 4         | 13.3       | 5.2        | 51.3        |
| 사회학자         | 2         | 6.7        | 10.2       | 53.4        |
| AI 교육자       | 3         | 10.0       | 5.3        | 42.3        |
| AI 설계자(컨설턴트) | 4         | 13.3       | 4.7        | 43.8        |
| AI 개발자       | 3         | 10.0       | 4.1        | 38.3        |
| AI 제작자(기관)   | 2         | 6.7        | 4.8        | 48.9        |
| AI 운영(도입)자   | 2         | 6.7        | 4.2        | 46.2        |
| AI 일반 사용자    | 2         | 6.7        | 4.7        | 42.1        |
| AI 윤리 교육자    | 3         | 10.0       | 3.1        | 48.3        |
| <b>합 계</b>   | <b>30</b> | <b>100</b> | <b>5.1</b> | <b>46.1</b> |

FGI와 델파이 설문조사에 참여한 전문가 그룹의 직무는 AI 윤리전문가 5명, AI 관련 법률가 전문가 4명, 사회학자 2명, AI 교육자 3명, AI 설계자(컨설턴트 포함) 4명, AI 개발자 3명, AI 제작자(기관) 2명, AI 운영(도입)자 2명, AI 일반 사용자 2명, AI 윤리 교육자 3명으로 총 30명이 참여하였다. 참여자의 직무 평균 경력연수는 5.1년이며, 참여자의 평균 연령은 46.1세였다.

인공지능 윤리원칙의 구성요소에서 15개의 구성요소를 기준으로 1차 FGI를 15명이 참석한 가운데 실시하여 80분 동안 인공지능 윤리원칙과 구성요소, 2022년 6월

에 개발한 인공지능 윤리 측정지표, 인공지능 윤리 가이드라인, SW 인증제도, 국제 표준화, IEEE SA에서 추진하는 인공지능 윤리 표준화, 인공지능 윤리 문제점에 대하여 설명하였다. 70분 동안은 사전에 준비한 윤리 측정지표 도출 자료를 바탕으로 참석자 의견과 추가 윤리 측정항목을 도출하였다. 인공지능 윤리원칙의 구성요소에 대한 측정지표 항목은 투명성 윤리원칙에서 설명가능성에 해당하는 항목 3개, 추적가능성에 해당하는 항목 3개, 검증가능성에 해당하는 항목 7개가 도출되었다. 책무성 윤리원칙에서는 준법성 구성요소에 포함되는 측정항목으로 10개, 책임식별성 4개가 도출되었다. 공정성의 원칙에서 알고리즘 차별성 구성요소에 포함되는 측정항목은 4개, 데이터 편향성에 해당하는 항목 5개, 접근성에 해당하는 항목은 6개, 공공성에 해당하는 항목은 13개가 도출되었다. 통제성 윤리원칙에서 제어가능성에 해당하는 측정항목은 3개, 이용자 주도성에 해당하는 항목은 7개, 모니터링에 해당하는 항목은 3개가 도출되었다. 마지막으로 안전성 윤리원칙에서 견고성에 해당하는 항목은 7개, 보안성에 해당하는 항목 5개, 프라이버시 보호에 4개 항목이 도출되었다. 1차 FGI에서 총 84개 항목의 윤리 측정지표가 도출되는 성과를 얻었다.

2차 FGI는 12명이 참석하여 1차 FGI에서 도출된 윤리 측정지표 항목을 바탕으로 추가적인 브레인스토밍을 진행하였다. 도출된 윤리 측정지표 항목에 대한 내용 정의와 추가로 도출된 측정지표 항목과 기 도출한 항목 중에서 논란의 여지가 있는 항목들을 제거하였다. 또한 신뢰할 수 있는 인공지능 평가 목록(ALTAI)에 대하여 참석자에게 설명하고 7가지 요구사항의 신뢰성 변수에 대하여 3차 FGI에서 논의하고 신뢰성 변수를 정의하였다.

3차 FGI는 15명이 참석하여 1차, 2차에서 도출된 측정지표를 대상으로 논의를 진행하였다. 중복된 측정지표 항목을 조정과 추가, 용어나 측정지표에 대한 정의가 명확하지 않은 부분을 명확하게 정의하였다. 최종적으로 측정지표 항목을 도출하였다. 그 결과 설명 가능성에 2개 항목이 확정되었으며, 추적 가능성에 2개 항목, 검증가능성에 5개 항목, 준법성에 6개 항목, 책임 식별성에 2개 항목, 알고리즘 차별성에

2개 항목, 데이터 편향성에 3개 항목, 접근성에 4개 항목, 공공성에 10개 항목, 제어 가능성에 2개 항목, 이용자 주도성에 5개 항목, 모니터링에 2개 항목, 견고성에 5개

[표 3-34] 투명성 원칙에 속하는 윤리 측정지표 정의

| 구성요소  | 윤리 측정지표            | 측정지표 항목 정의                                                                                         | 참고문헌                                                                                                                                                                                                                                                   |
|-------|--------------------|----------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 설명가능성 | 안전 인증자를 위한 투명성     | 안전 인증을 평가, 보증하는 안전 인증자에게 AI의 의사결정 프로세스, 작동 기능에 대하여 검증할 수 있도록 안전 관련 소스코드와 필요한 자료를 설명, 제공하는 지표       | AI HLEG(2019),<br>Binns, R(2018),<br>FLI(2017),<br>IEEE(2022),<br>Joshua A. Kroll (2017),<br>Leslie, D(2019),<br>Michael Butterworth (2018),<br>Steven F(2019),<br>UNESCO(2021),<br>고학수외(2020),<br>과학기술정책연구원(2018),<br>권허영(2019),<br>이한슬,<br>천현득(2021) |
|       | 대중 및 이해관계자를 위한 투명성 | 공적인 AI는 사회에 미치는 영향이 중대하기 때문에 사회 전체가 해당 AI의 작동 방식, 기술, 기능을 이해할 수 있도록 대중 및 이해관계자에게 충분한 설명이 되어야 하는 지표 |                                                                                                                                                                                                                                                        |
| 추적가능성 | 상시 운영 감시           | AI 운영에 대한 상시 모니터링 감시로 AI가 문제 발생 시 이해관계자에게 언제라도 관련 자료를 제공하는 지표                                      |                                                                                                                                                                                                                                                        |
|       | 정기 운영 감사           | AI 운영에 대한 정기적인 감사 정책을 수립하여 감사를 실시하고, AI가 문제 발생 시 이해관계자에게 언제라도 관련 자료를 제공하는 지표                       |                                                                                                                                                                                                                                                        |
| 검증가능성 | 안전성 시험기준 적용        | AI는 안전성 확보를 위하여 안전성 시험기준을 마련하고, 시험기준에 충족하도록 제작, 운영될 수 있게 해야하는 지표                                   |                                                                                                                                                                                                                                                        |
|       | 알고리즘의 투명성 확보       | AI가 어떠한 처리 과정을 거쳐 프로파일링을 생성하였는지 검증하는 과정이 투명하게 설명될 수 있어야 하는 지표                                      |                                                                                                                                                                                                                                                        |
|       | 데이터의 신뢰성           | AI가 학습용으로 획득한 데이터 출처를 명확하게 제시하고, 이해관계자가 요구 시 해당 데이터를 제공하여 검증할 수 있도록 하는 지표                          |                                                                                                                                                                                                                                                        |
|       | 학습용 데이터의 충분성       | AI 개발 시 의도한 기능을 정확하게 수행하기 위하여 충분한 학습용 데이터 수량과 기준을 마련하여 적용하는 지표                                     |                                                                                                                                                                                                                                                        |
|       | 시험, 인증 결과 제시       | AI에 적용된 기술요소를 이해관계자가 공개 요구 시 공인기관의 시험, 인증 결과를 제시하는 지표                                              |                                                                                                                                                                                                                                                        |

항목, 보안성에 3개 항목, 프라이버시 보호에 2개 항목으로 총 55개가 연구 대상 항목으로 확정하여 윤리 측정지표를 정의 하였다. [표 3-34]는 도출한 윤리 측정지표 중 투명성 원칙에 속하는 윤리 측정지표를 정의한 것이다. [표 3-35]는 도출한 윤리 측정지표 중 책무성 원칙에 속하는 측정지표를 정의한 것이다.

[표 3-35] 책무성 원칙에 속하는 윤리 측정지표 정의

| 구성요소   | 윤리 측정지표         | 측정지표 항목 정의                                                                                                | 참고문헌                                                                                                                                                                                      |
|--------|-----------------|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 준법성    | 법적 근거 확보와 제시    | AI는 설계, 개발, 유통, 운영 전 과정에서 AI 관련 법규, 윤리, 기준에 위배되지 않는다는 근거를 명확하게 제시할 수 있도록 하는 지표                            | AI HLEG(2018), BDV(2019), Joshua A. Kroll (2017), Leslie, D(2019), Michael Butterworth (2018), UNESCO(2021), Sung.T(2019), Steven F(2019), 계승균(2017), 정원섭(2020), 최미란(2021), 학국표준협회 (2022) |
|        | 사용 설명서와 기능 일치성  | AI는 이용자에게 제공되는 AI 기능과 사용 설명서 내용이 일치한다는 것을 증명할 수 있도록 하는 지표                                                 |                                                                                                                                                                                           |
|        | 사용범위 법적기준 문서화   | AI는 사용범위, 이용자 보호, 위험 방지, 작동 방법, 이용자 책임 범위 등을 법적 기준에 맞도록 명확하게 문서화하여 이용자에게 제공해야 하는 지표                       |                                                                                                                                                                                           |
|        | 이용자 안전 우선 보호    | AI는 이용자가 AI 사용에 미숙하거나, AI 사용 시 위험상황이 발생할 경우 이용자의 안전을 최우선으로 보호해야 하는 지표                                     |                                                                                                                                                                                           |
|        | 신고자에 대한 법적 보호   | AI에 대한 이슈, 윤리 문제 등의 발견, 잠재적 위험이 예측될 경우 이를 신고하거나 개선을 요구하는 이용자에 법적인 안전이 보호되어야 하는 지표                         |                                                                                                                                                                                           |
|        | 이용자 요구사항 대응     | AI 이용자가 본인에게 부정적인 영향이 미칠 수 있다는 것을 인지하고 기능 변경 요청이나 이의 제기 시 AI 제공자는 이용자에게 적절한 대응 방안을 제시해야 하는 지표             |                                                                                                                                                                                           |
| 책임 식별성 | 개발자 책임식별        | AI 개발자는 설계를 기반으로 소프트웨어를 개발하여야 하며, 소스코드 개발 및 관리, 추가, 변경, 오류 제거 등 개발자의 역할과 책임 범위를 명확하게 규정하여 식별할 수 있도록 하는 지표 |                                                                                                                                                                                           |
|        | 학습 데이터 이해관계자 식별 | AI 학습에 사용된 데이터 분류 기준, 데이터 적용 기준 등의 의사결정에 참여한 이해관계자가 누구였는지 식별할 수 있도록 관리하는 지표                               |                                                                                                                                                                                           |

[표 3-36]은 도출한 윤리 측정지표 중 공정성 원칙에 속하는 측정지표를 정의한 것이다.

[표 3-36] 공정성 원칙에 속하는 윤리 측정지표 정의

| 구성요소     | 윤리 측정지표            | 측정지표 항목 정의                                                                                  | 참고문헌                                                                                                                                                                                           |
|----------|--------------------|---------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 알고리즘 차별성 | 알고리즘의 의사결정 프로세스 제공 | AI의 알고리즘이 의사결정에 포함되는 분류, 우선순위 결정, 필터링, 적용 데이터 항목 등에 대한 처리 프로세스를 이해관계자가 요구 시 제공할 수 있어야 하는 지표 | BDV(2019),<br>Binns, R(2018),<br>CIPL(2020),<br>EU(2020),<br>FTC(2020),<br>IEEE(2022),<br>Joshua A. Kroll (2017),<br>Lepri, B(2018),<br>UNESCO(2021),<br>박미정(2019),<br>양종모(2017),<br>정원섭(2020) |
|          | 차별적 불이익 방지         | AI의 알고리즘은 이용자가 특정 부류나 계층 또는 개인에게 손해, 차별, 불이익이 발생하지 않도록 개발되어야 하는 지표                          |                                                                                                                                                                                                |
| 데이터 편향성  | 데이터 분류 기준 정의 및 적용  | AI 학습용 데이터 분류는 관련 산업의 표준분류 체계를 적용하며, 각 분류별로 균일한 수량을 적용할 수 있도록 기준을 마련하여 적용해야 하는 지표           |                                                                                                                                                                                                |
|          | 데이터 균일성 확보         | AI 학습용 데이터는 분류, 탐지, 인식, 이해, 예측 등 카테고리별 인스턴스 수량의 균일성과 적정 비율을 확보하여 적용해야 하는 지표                 |                                                                                                                                                                                                |
|          | 기존 사회의 편향성 방지      | AI 학습용 데이터는 편향성을 방지하기 위하여 기존 사회가 가지는 사회적 데이터를 그대로 사용하지 않고 시대적 상황을 반영하여 생성해야 하는 지표           |                                                                                                                                                                                                |
| 접근성      | 접근성 보장             | AI는 성별, 연령, 장애 여부를 막론하고 소외 계층 없이 누구나 이용할 수 있도록 사용자 인터페이스 기술을 적용하여 접근성을 보장해야 하는 지표           |                                                                                                                                                                                                |
|          | 보편적 사용자 지원         | AI는 이용자 특성에 따라 제작된 것 외에는 인종, 지역, 성별, 연령, 계층 등 차별 없이 모든 시민이 보편적으로 사용할 수 있도록 제작되어야 하는 지표      |                                                                                                                                                                                                |
|          | 사용자 접근 제한 방지       | AI는 특정 계층이나 폐쇄된 영역에서만 혜택을 받을 수 있도록 인위적 조작, 통제로 사용자 접근을 제한해서는 안 된다는 지표                       |                                                                                                                                                                                                |
|          | 이용자의 쉬운 접근성        | AI는 이용자가 AI 기능을 쉽게 동작시킬 수 있도록 접근성과 이용 가이드를 제공해야 하는 지표                                       |                                                                                                                                                                                                |

|     |                       |                                                                                                             |                                                                                                                                                                                                                      |
|-----|-----------------------|-------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 공공성 | 공공데이터 제공              | AI는 운영 시 일반 시민으로부터 수집한 데이터는 이해관계자가 공개 요구 시 투명하게 공개해야 하는 지표                                                  | AI HLEG(2018),<br>Leslie, D(2019),<br>Leslie, D(2019),<br>Berkman Klein center(2020),<br>IEEE(2022),<br>FTC(2020),<br>Joshua A. Kroll(2017),<br>UNESCO(2021),<br>목광수(2019),<br>박미정(2019),<br>양종모(2017),<br>정원섭(2020) |
|     | 공공데이터 수집<br>공지        | 모든 시민을 대상으로 데이터를 수집, 분석, 활용하는 AI는 수집되는 장소, 시간, 데이터 항목에 대하여 적법성, 관리 책임, 개인 정보 관리 및 보호 정책, 안전성에 대해 공지해야 하는 지표 |                                                                                                                                                                                                                      |
|     | 데이터 활용<br>제한          | AI가 수집한 데이터는 원래 사용하고자 하는 목적 이외에는 사용하지 않도록 관리되어야 하는 지표                                                       |                                                                                                                                                                                                                      |
|     | 개인정보 수집<br>제한         | AI는 어떠한 경우에도 개인에게 동의를 받지 않은 개인정보를 수집해서는 안 된다는 지표                                                            |                                                                                                                                                                                                                      |
|     | 사회환경에<br>미치는 영향<br>배제 | 일반 시민이 사용하는 AI는 사회적, 정치적, 역사적, 문화적 환경에 미치는 영향이 없어야 하며, 인간의 인격권을 훼손하지 않도록 해야 하는 지표                           |                                                                                                                                                                                                                      |
|     | 인간의 생명<br>위협 방지       | AI는 어떠한 경우에도 인간이 생명의 위협을 받거나 사망에 이르게 할 수 있도록 하는 알고리즘을 적용해서는 안 된다는 지표                                        |                                                                                                                                                                                                                      |
|     | 이해관계자의<br>의견 반영       | AI는 다양한 이해관계자 의견과 영향도를 반영하여 개발하고, 운영에서 발생된 이슈나 문제점을 이용자로부터 적극적으로 수렴하여 신속하게 개선, 배포해야 하는 지표                   |                                                                                                                                                                                                                      |
|     | 친환경 에너지<br>활용         | AI를 운영하는 에너지는 친환경 에너지를 활용하여 탄소 배출을 최소화할 수 있도록 해야 하는 지표                                                      |                                                                                                                                                                                                                      |
|     | 폐기 제품 관리              | 사용이 끝난 AI 제품은 지구 환경에 오염되지 않도록 회수 프로세스, 폐기 방법을 이용자에게 공지하여야 하는 지표                                             |                                                                                                                                                                                                                      |
|     | 모든 인류에게<br>공정한 제공     | AI는 모든 인류, 국가, 체제, 계층에 사회적, 문화적, 정치적 영향이 미치지 않도록 공정하게 제공되어야 하는 지표                                           |                                                                                                                                                                                                                      |

[표 3-37]은 도출한 윤리 측정지표 중 통제성 원칙에 속하는 측정지표를 정의한 것이다.

[표 3-37] 통제성 원칙에 속하는 윤리 측정지표 정의

| 구성요소       | 윤리 측정지표                 | 측정지표 항목 정의                                                                      | 참고문헌                                                                                                                                                                                                                                               |
|------------|-------------------------|---------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 제어<br>가능성  | 강제적 통제권<br>이양 배제        | AI가 기능을 수행(자율 시스템)하는 중 이용자(인<br>간)에게 강제로 통제권을 넘길 수 없도록 하는 지표                    | Adamson, G<br>(2019),<br>Ayre C(2014),<br>CIPL(2020),<br>EU(2020),<br>FLI(2017),<br>FTC(2020),<br>Google(2021),<br>IEEE(2022),<br>Leslie, D(2019),<br>Michael<br>Butterworth<br>(2018),<br>Samuel D(2018),<br>UNESCO(2021),<br>과학기술정보통<br>신부(2021) |
|            | 위험 발생 시<br>쉬운 접근성<br>제공 | AI는 이용자가 AI 기능사용 중 위험 상황 발생 시<br>쉽게 AI를 제어할 수 있도록 사전에 이용 가이드나<br>방법을 제공해야 하는 지표 |                                                                                                                                                                                                                                                    |
| 이용자<br>주도성 | 이용자<br>위험회피             | AI를 이용하는 중 위험한 상황이 발생하면 즉시 위<br>험 상황을 회피할 수 있도록 하는 제어기능을 제공<br>하는 지표            |                                                                                                                                                                                                                                                    |
|            | 자율적 조작                  | AI는 AI 이용자에게 자율적으로 AI 작동 기능을 조<br>작할 수 있도록 하는 기능을 제공해야 한다는 지표                   |                                                                                                                                                                                                                                                    |
|            | 이용자 데이터<br>선택적 제공       | AI 이용자가 본인의 데이터를 AI에게 제공해야 할<br>경우 이용자는 제공할 데이터를 선택적으로 지정할<br>수 있게 하는 지표        |                                                                                                                                                                                                                                                    |
|            | 이용자 데이터<br>삭제           | AI는 AI 이용자로부터 수집, 저장한 이용자 데이터<br>를 이용자 본인이 직접 삭제할 수 있도록 하는 기능<br>을 제공해야 하는 지표   |                                                                                                                                                                                                                                                    |
|            | 작동상태 제공                 | AI는 이용자가 AI의 작동상태를 상시 확인할 수 있<br>도록 작동상태를 숫자, 문자, 이미지 등으로 표현하<br>여 제공해야 하는 지표   |                                                                                                                                                                                                                                                    |
| 모니터링       | 위험 예측 상태<br>제공          | AI는 작동 중에 이용자가 위험한 상황이 예측 될 경<br>우 즉시 위험 예측 정보나 메시지를 이용자에게 제<br>공해야 하는 지표       |                                                                                                                                                                                                                                                    |
|            | 운영상태 상시<br>모니터링         | AI를 제공하는 기관(사업자)은 AI 운영상태, 현황을<br>상시 모니터링할 수 있는 체계를 구축하여 운영해야<br>한다는 지표         |                                                                                                                                                                                                                                                    |

[표 3-38]은 도출한 윤리 측정지표 중 안전성 원칙에 속하는 측정지표를 정의한 것이다.

[표 3-38] 안전성 원칙에 속하는 윤리 측정지표 정의

| 구성요소     | 윤리 측정지표           | 측정지표 항목 정의                                                             | 참고문헌                                                                                                                                                                                                                                                                                                                       |
|----------|-------------------|------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 견고성      | 예측 결과의 동일성        | AI는 동일한 조건으로 기능을 재현 시 동일한 결과를 제공할 수 있도록 보장되어야 하는 지표                    | Adamson, G (2019),<br>Ayre C(2014),<br>CIPL(2020),<br>EU(2020),<br>FLI(2017),<br>FTC(2020),<br>Google(2021),<br>IEEE(2022),<br>Leslie, D(2019),<br>Michael Butterworth (2018),<br>Samuel D(2018),<br>UNESCO(2021),<br>개인정보보호위원회(2021),<br>과학기술정보통신부(2021),<br>김종세(2020),<br>양종모(2020),<br>장철호,차윤호 (2021),<br>허준,안성진 (2020) |
|          | 품질기준 보장           | AI는 이용자에게 제공하기로 계획된 품질기준을 보장하며, 지속적으로 목표한 품질이 유지될 수 있도록 해야 하는 지표       |                                                                                                                                                                                                                                                                                                                            |
|          | 학습 데이터의 정확성       | AI 학습용 데이터는 정확하고 일관성 있게 가공하여 AI 모델 성능이 품질 검증 기준의 일정 목표 수준에 부합하여야 하는 지표 |                                                                                                                                                                                                                                                                                                                            |
|          | 기능의 지속적 업데이트 및 배포 | AI는 최신 데이터 적용과 기술을 적용하여 지속적인 업데이트와 배포가 이루어질 수 있도록 해야 하는 지표             |                                                                                                                                                                                                                                                                                                                            |
|          | 기능 프로세스의 정확한 정의   | AI 제공자는 이용자가 기능의 정확도를 인지할 수 있도록 AI의 의사결정 프로세스를 명확하게 정의하여 제공해야 하는 지표    |                                                                                                                                                                                                                                                                                                                            |
| 보안성      | 비인가자 연결 방지        | AI는 이용자 승인 없이 타인이나 다른 기기에 스스로 또는 고의로 연결(접속)하지 않도록 해야 하는 지표             |                                                                                                                                                                                                                                                                                                                            |
|          | 알고리즘 시큐어 코딩       | AI는 알고리즘 개발 시 시큐어코딩에 의하여 네트워크, 해킹, 백도어 등으로부터 안전을 보장받을 수 있도록 하여야 하는 지표  |                                                                                                                                                                                                                                                                                                                            |
|          | 이용 종료 시 정보 삭제     | AI 이용자가 AI를 폐기하거나 영구적으로 이용을 중단할 때는 이용자 전체 정보를 삭제할 수 있도록 하여야 하는 지표      |                                                                                                                                                                                                                                                                                                                            |
| 프라이버시 보호 | 미동의 데이터 수집 방지     | AI는 사용자의 동의 없이 어떠한 데이터도 임의로 수집할 수 없도록 방지 대책을 수립, 적용하여야 하는 지표           |                                                                                                                                                                                                                                                                                                                            |
|          | 데이터 주권 보장         | AI와 이용자 간의 상호작용에 의하여 생성된 모든 데이터는 이용자에게 귀속시킬 수 있도록 하여야 하는 지표            |                                                                                                                                                                                                                                                                                                                            |

전문가 그룹에 의한 델파이 설문조사는 인공지능 윤리원칙의 구성요소를 바탕으로 인공지능 제품이나 서비스를 대상으로 신뢰성 확보를 위한 인공지능 윤리 측정지표를 적용하기 위하여 측정지표 항목을 확장 개발하는 설문조사를 진행하였다. 설문지는 Likert 5점 척도를 사용하여 작성하였다.

### 3. 델파이 설문조사 결과 분석

델파이 설문조사에 응답한 30명의 설문지를 회수하여 타당도 분석을 실시하였다.

[표 3-39] 인공지능 윤리 측정지표 내용타당도 분석 결과 및 선정 현황

| 윤리 원칙 | 구성 요소    | 윤리 측정지표 항목         | 유효 수 | 최솟 값 | 최대 값 | 평균   | 표준 편차 | CVR 값 | 선정 여부 |
|-------|----------|--------------------|------|------|------|------|-------|-------|-------|
| 투명성   | 설명 가능성   | 안전 인증자를 위한 투명성     | 30   | 3.00 | 5.00 | 4.33 | .661  | 0.80  | ○     |
|       |          | 대중 및 이해관계자를 위한 투명성 | 30   | 3.00 | 5.00 | 4.40 | .621  | 0.87  | ○     |
|       | 추적 가능성   | 상시 운영 감시           | 30   | 3.00 | 5.00 | 4.50 | .630  | 0.87  | ○     |
|       |          | 정기 운영 감사           | 30   | 3.00 | 5.00 | 4.50 | .572  | 0.93  | ○     |
|       | 검증 가능성   | 안전성 시험기준 적용        | 30   | 3.00 | 5.00 | 4.67 | .547  | 0.93  | ○     |
|       |          | 알고리즘의 투명성 확보       | 30   | 3.00 | 5.00 | 4.40 | .724  | 0.73  | ○     |
|       |          | 데이터의 신뢰성           | 30   | 3.00 | 5.00 | 4.47 | .629  | 0.87  | ○     |
|       |          | 학습용 데이터의 충분성       | 30   | 3.00 | 5.00 | 4.37 | .669  | 0.80  | ○     |
|       |          | 시험, 인증 결과 제시       | 30   | 3.00 | 5.00 | 4.27 | .740  | 0.67  | ○     |
| 책임성   | 준법성      | 법적 근거 확보와 제시       | 30   | 4.00 | 5.00 | 4.47 | .507  | 1.00  | ○     |
|       |          | 사용 설명서와 기능 일치성     | 30   | 4.00 | 5.00 | 4.63 | .490  | 1.00  | ○     |
|       |          | 사용범위 법적 기준 준수 명문화  | 30   | 3.00 | 5.00 | 4.47 | .571  | 0.93  | ○     |
|       |          | 이용자 안전 우선 준수       | 30   | 4.00 | 5.00 | 4.80 | .407  | 1.00  | ○     |
|       |          | 신고자에 대한 법적 보호      | 30   | 3.00 | 5.00 | 4.50 | .630  | 0.87  | ○     |
|       |          | 이용자 요구사항 대응        | 30   | 4.00 | 5.00 | 4.37 | .490  | 1.00  | ○     |
|       | 책임 식별성   | 개발자 책임 식별          | 30   | 4.00 | 5.00 | 4.43 | .504  | 1.00  | ○     |
|       |          | 학습 데이터 이해관계자 식별    | 30   | 2.00 | 5.00 | 3.70 | .651  | 0.20  | X     |
| 공정성   | 알고리즘 차별성 | 알고리즘의 의사결정 프로세스 제공 | 30   | 3.00 | 5.00 | 4.40 | .621  | 0.87  | ○     |
|       |          | 차별적 불이익 방지         | 30   | 3.00 | 5.00 | 4.47 | .629  | 0.87  | ○     |

|            |              |                       |                   |                        |      |       |      |       |      |   |
|------------|--------------|-----------------------|-------------------|------------------------|------|-------|------|-------|------|---|
| 공정성        | 데이터<br>편향성   | 데이터 분류 기준 정의 및 적용     | 30                | 3.00                   | 5.00 | 4.20  | .664 | 0.73  | ○    |   |
|            |              | 데이터 균일성 확보            | 30                | 3.00                   | 5.00 | 4.33  | .802 | 0.60  | ○    |   |
|            |              | 기존 사회의 편향성 방지         | 30                | 2.00                   | 5.00 | 3.80  | .805 | 0.27  | X    |   |
|            | 접근성          | 접근성 보장                | 30                | 3.00                   | 5.00 | 4.57  | .568 | 0.93  | ○    |   |
|            |              | 보편적 사용자 지원            | 30                | 3.00                   | 5.00 | 4.60  | .563 | 0.93  | ○    |   |
|            |              | 사용자 접근 제한 방지          | 30                | 3.00                   | 5.00 | 4.43  | .626 | 0.87  | ○    |   |
|            |              | 이용자의 쉬운 접근성           | 30                | 3.00                   | 5.00 | 4.30  | .702 | 0.73  | ○    |   |
|            | 공공성          | 공공데이터 제공              | 30                | 2.00                   | 5.00 | 3.73  | .691 | 0.20  | X    |   |
|            |              | 공공데이터 수집 공지           | 30                | 2.00                   | 5.00 | 4.43  | .728 | 0.87  | ○    |   |
|            |              | 데이터 활용 제한             | 30                | 3.00                   | 5.00 | 4.67  | .547 | 0.93  | ○    |   |
|            |              | 개인정보 수집 제한            | 30                | 3.00                   | 5.00 | 4.57  | .679 | 0.80  | ○    |   |
|            |              | 사회환경에 미치는 영향 배제       | 30                | 3.00                   | 5.00 | 4.60  | .621 | 0.87  | ○    |   |
|            |              | 인간의 생명 위협 방지          | 30                | 3.00                   | 5.00 | 4.70  | .535 | 0.93  | ○    |   |
|            |              | 이해관계자의 의견 반영          | 30                | 3.00                   | 5.00 | 4.47  | .571 | 0.93  | ○    |   |
|            |              | 친환경 에너지 활용            | 30                | 3.00                   | 5.00 | 4.00  | .587 | 0.67  | ○    |   |
|            |              | 폐기 제품 관리              | 30                | 3.00                   | 5.00 | 4.07  | .640 | 0.67  | ○    |   |
|            |              | 모든 인류에게 공정한 제공        | 30                | 4.00                   | 5.00 | 4.60  | .498 | 1.00  | ○    |   |
|            | 통제성          | 제어<br>가능성             | 강제적 통제권 이양 배제     | 30                     | 1.00 | 4.00  | 3.43 | 1.040 | 0.13 | X |
|            |              |                       | 위험 발생 시 쉬운 접근성 제공 | 30                     | 1.00 | 5.00  | 4.27 | .828  | 0.67 | ○ |
| 이용자<br>주도성 |              | 이용자 위험 회피             | 30                | 2.00                   | 5.00 | 4.23  | .817 | 0.67  | ○    |   |
|            |              | 자율적 조작                | 30                | 2.00                   | 5.00 | 4.03  | .964 | 0.53  | ○    |   |
|            |              | 이용자 데이터 선택적 제공        | 30                | 2.00                   | 5.00 | 4.10  | .885 | 0.60  | ○    |   |
|            |              | 이용자 데이터 삭제            | 30                | 2.00                   | 5.00 | 4.07  | .944 | 0.47  | ○    |   |
|            |              | 작동상태 제공               | 30                | 2.00                   | 5.00 | 4.17  | .874 | 0.53  | ○    |   |
| 모니터링       |              | 위험 예측 상태 제공           | 30                | 2.00                   | 5.00 | 4.30  | .794 | 0.73  | ○    |   |
|            | 운영상태 상시 모니터링 | 30                    | 2.00              | 5.00                   | 4.07 | 1.048 | 0.53 | ○     |      |   |
| 안전성        | 견고성          | 예측 결과의 동일성            | 30                | 3.00                   | 5.00 | 4.30  | .794 | 0.87  | ○    |   |
|            |              | 품질기준 보장               | 30                | 1.00                   | 5.00 | 3.70  | .877 | 0.27  | X    |   |
|            |              | 학습 데이터의 정확성(accuracy) | 30                | 3.00                   | 5.00 | 4.43  | .626 | 0.87  | ○    |   |
|            |              | 기능의 지속적 업그레이드 및 배포    | 30                | 2.00                   | 5.00 | 4.13  | .776 | 0.67  | ○    |   |
|            |              | 기능 프로세스의 정확한 정의       | 30                | 3.00                   | 5.00 | 4.37  | .718 | 0.73  | ○    |   |
|            | 보안성          | 비인가자 연결 방지            | 30                | 4.00                   | 5.00 | 4.57  | .504 | 1.00  | ○    |   |
|            |              | 알고리즘 시큐어 코딩           | 30                | 3.00                   | 5.00 | 4.67  | .547 | 0.93  | ○    |   |
|            |              | 이용 종료 시 정보 삭제         | 30                | 3.00                   | 5.00 | 4.53  | .629 | 0.87  | ○    |   |
|            | 프라이버<br>시 보호 | 미동의 데이터 수집 방지         | 30                | 4.00                   | 5.00 | 4.70  | .466 | 1.00  | ○    |   |
|            |              | 데이터 주권 보장             | 30                | 3.00                   | 5.00 | 4.50  | .682 | 0.80  | ○    |   |
|            | 전체 : 55 개 항목 |                       |                   | 선정여부=> 선정: 50, 미선정 : 5 |      |       |      |       |      |   |

설문 결과 Likert 4(타당함)와 5(매우 타당함)에 응답한 패널 수를 적용하여 내용 타당도 비율(CVR) 값을 산정하여 적용하였다. [표 3-39]은 인공지능 윤리 측정지표에 적용할 인공지능 윤리 측정지표 항목 내용타당도 분석 결과 및 선정 현황이다.

FGI를 진행 후 텔파이 설문조사 결과 인공지능 윤리 측정지표 55개 중 50개가 선정되었다. 선정 기준은 패널 수가 30명일 경우 타당성을 갖기 위한 CVR의 최솟값이 0.33이기 때문에 0.40 이상의 CVR 값을 갖는 윤리 측정지표 항목을 선정하였다(Ayre C., Scally AJ, 2014).

텔파이 설문조사는 3차 FGI에서 도출된 55개 측정지표 항목에 대하여 검증을 진행할 수 있도록 하였다. 설문조사는 도출된 55개 측정지표 항목에 대하여 인공지능 제품이나 서비스에 대한 신뢰성 확보를 위하여 측정지표 항목으로 타당할지에 대한 타당성 분석을 수행하기 위해 진행하였다. 설문조사 대상은 FGI 1차부터 3차에 참여한 전문가 그룹을 대상으로 30명에게 설문조사를 실시하였다. 측정지표로 도출된 55개 측정지표 항목에서 50개 항목이 인공지능 윤리 측정지표로 적용하는데 타당하다는 결과를 검증하였다. [표 3-40]은 윤리원칙 구성요소별 측정지표 타당성 설문조사에 의하여 확정된 측정지표 항목 수를 나타내는 현황이다. 3차 FGI에서 설문조사 대상 항목을 면밀하게 브레인스토밍하여 최소화함으로써 타당성에 미달하는 항목이 5개로 나타나 비교적 양호한 수준의 윤리 측정지표를 도출한 성과를 얻었다. 타당성에 미달한 항목은 책임식별성 구성요소에서 학습 데이터 이해관계자 식별 항목이었으며, 데이터 편향성 구성요소에서 기존 사회의 편향성 방지 항목, 공공성 구성요소에서 공공데이터 제공 항목, 제어가능성 구성요소에서 강제적 통제권 이양 배제 항목, 견고성 구성요소에서 품질기준 보장 항목이었다.

확장 개발한 인공지능 윤리 측정지표 50개 항목은 설명가능성 구성요소에 안전 인증자를 위한 투명성, 대중 및 이해관계자를 위한 투명성으로 2개 항목이며, 추적가능성 구성요소에 상시 운영 감시, 정기 운영 감사로 2개 항목이다. 검증가능성 구성요소에 안전성 시험기준 적용, 알고리즘의 투명성 확보, 데이터의 신뢰성, 학습용

[표 3-40] 윤리원칙 구성 요소별 측정지표 타당성 항목 수 현황

| 윤리원칙 | 구성요소     | 도출된 측정 항목 수 | 선정된 측정항목 수 |
|------|----------|-------------|------------|
| 투명성  | 설명가능성    | 2           | 2          |
|      | 추적가능성    | 2           | 2          |
|      | 검증가능성    | 5           | 5          |
| 책임성  | 준법성      | 6           | 6          |
|      | 책임식별성    | 2           | 1          |
| 공정성  | 알고리즘 차별성 | 2           | 2          |
|      | 데이터 편향성  | 3           | 2          |
|      | 접근성      | 4           | 4          |
|      | 공공성      | 10          | 9          |
| 통제성  | 제어가능성    | 2           | 1          |
|      | 이용자 주도성  | 5           | 5          |
|      | 모니터링     | 2           | 2          |
| 안전성  | 견고성      | 5           | 4          |
|      | 보안성      | 3           | 3          |
|      | 프라이버시 보호 | 2           | 2          |
| 합 계  |          | 55          | 50         |

데이터의 충분성, 시험, 인증결과 제시 항목으로 5개 항목이다. 준법성 구성요소에 법적 근거 확보와 제시, 사용 설명서와 기능 일치성, 사용범위 법적기준 준수 명문화, 이용자 안전 우선 준수, 신고자에 대한 법적 보호, 이용자 요구사항 대응으로 6개 항목이다. 책임식별성 구성요소에서는 개발자 책임식별 1개 항목이다. 알고리즘 차별성 구성요소에는 알고리즘의 의사결정 프로세스 제공, 차별적 불이익 방지 2개 항목이다. 데이터 편향성 구성요소에는 데이터 분류 기준 정의 및 적용, 데이터 균

일성 확보 2개 항목이다. 접근성 구성요소에는 접근성 보장, 보편적 사용자 지원, 사용자 접근 제한 방지, 이용자의 쉬운 접근성 4개 항목이다. 공공성 구성요소에는 공공데이터 수집 금지, 데이터 활용 제한, 개인정보 수집 제한, 사회환경에 미치는 영향 배제, 인간의 생명 위협 방지, 이해관계자의 의견 반영, 친환경 에너지 활용, 폐기 제품 관리, 모든 인류에게 공정한 제공 9개 항목이다. 제어가능성 구성요소에는 위험 발생 시 쉬운 접근성 제공 1개 항목이다. 이용자 주도성 구성요소에는 이용자 위험 회피, 자율적 조작, 이용자 데이터 선택적 제공, 이용자 데이터 삭제, 작동상태 제공 5개 항목이다. 모니터링 구성요소에는 위험 예측 상태 제공, 운영상태 상시 모니터링 2개 항목이다. 견고성 구성요소에는 예측 결과의 동일성, 학습 데이터의 정확성, 기능의 지속적 업그레이드 및 배포, 기능 프로세스의 정확한 정의 4개 항목이다. 보안성 구성요소에는 비인가자 연결 방지, 알고리즘 시큐어 코딩, 이용 종료 시 정보 삭제 3개 항목이다. 프라이버시 보호 구성요소에는 미동의 데이터 수집 금지, 데이터 주권 보장 2개 항목으로 확정되었다.

#### 4. 신뢰성 확보를 위한 인공지능 윤리 측정지표

전문가 그룹의 FGI와 델파이 설문조사 결과에 따라 윤리 측정지표 50개 항목의 내용 타당도 확인 후 인공지능 윤리 측정지표 50개 항목을 확정하였다. [표 3-41]은 신뢰성 확보를 위한 인공지능 윤리 측정지표 항목 현황이다. 최초에 개발한 윤리 측정지표는 인격권과 재산 보호를 위한 측정지표 개발에 중점을 두었으며, 본 연구에서는 신뢰성 확보를 위한 인공지능 윤리 측정지표 확장 개발에 중점을 두었다. 확장 개발된 50개 윤리 측정지표는 인공지능 윤리원칙의 구성요소 20개 중 15개에 해당하는 항목들이다. 선행 개발된 윤리 측정지표와 확장 개발한 윤리 측정지표를 통합하여 인공지능 제품이나 서비스 개발에 유용하게 활용될 수 있을 것이다.

[표 3-41] 신뢰성 확보를 위한 인공지능 윤리 측정지표 항목 현황

| 윤리원칙 | 구성요소     | 윤리 측정지표 항목         |
|------|----------|--------------------|
| 투명성  | 설명가능성    | 안전 인증자를 위한 투명성     |
|      |          | 대중 및 이해관계자를 위한 투명성 |
|      | 추적가능성    | 상시 운영 감시           |
|      |          | 정기 운영 감사           |
|      | 검증가능성    | 안전성 시험기준 적용        |
|      |          | 알고리즘의 투명성 확보       |
|      |          | 데이터의 신뢰성           |
|      |          | 학습용 데이터의 충분성       |
|      |          | 시험, 인증결과 제시        |
| 책임성  | 준법성      | 법적 근거 확보와 제시       |
|      |          | 사용 설명서와 기능 일치성     |
|      |          | 사용범위 법적기준 준수 명문화   |
|      |          | 이용자 안전 우선 준수       |
|      |          | 신고자에 대한 법적 보호      |
|      |          | 이용자 요구사항 대응        |
|      | 책임식별성    | 개발자 책임식별           |
| 공정성  | 알고리즘 차별성 | 알고리즘의 의사결정 프로세스 제공 |
|      |          | 차별적 불이익 방지         |
|      | 데이터 편향성  | 데이터 분류 기준 정의 및 적용  |
|      |          | 데이터 균일성 확보         |
|      | 접근성      | 접근성 보장             |
|      |          | 보편적 사용자 지원         |
|      |          | 사용자 접근 제한 방지       |
|      |          | 이용자의 쉬운 접근성        |

|     |          |                       |
|-----|----------|-----------------------|
|     | 공공성      | 공공데이터 수집 공지           |
|     |          | 데이터 활용 제한             |
|     |          | 개인정보 수집 제한            |
|     |          | 사회환경에 미치는 영향 배제       |
|     |          | 인간의 생명 위협 방지          |
|     |          | 이해관계자의 의견 반영          |
|     |          | 친환경 에너지 활용            |
|     |          | 폐기 제품 관리              |
|     |          | 모든 인류에게 공정한 제공        |
| 통제성 | 제어가능성    | 위험 발생 시 쉬운 접근성 제공     |
|     | 이용자 주도성  | 이용자 위험 회피             |
|     |          | 자율적 조작                |
|     |          | 이용자 데이터 선택적 제공        |
|     |          | 이용자 데이터 삭제            |
|     |          | 작동상태 제공               |
|     | 모니터링     | 위험 예측 상태 제공           |
|     |          | 운영상태 상시 모니터링          |
| 안전성 | 견고성      | 예측 결과의 동일성            |
|     |          | 학습 데이터의 정확성(Accuracy) |
|     |          | 기능의 지속적 업그레이드 및 배포    |
|     |          | 기능 프로세스의 정확한 정의       |
|     | 보안성      | 비인가자 연결 방지            |
|     |          | 알고리즘 시큐어 코딩           |
|     |          | 이용 종료 시 정보 삭제         |
|     | 프라이버시 보호 | 미동의 데이터 수집 방지         |
|     |          | 데이터 주권 보장             |

## 제 4 장 인공지능 윤리 측정지표와 신뢰성 탐색


### 제 1 절 인공지능 윤리 측정지표 신뢰성 연구 방법 및 절차

#### 1. 인공지능 윤리 측정지표 신뢰성 연구 방법

본 연구에서는 다양한 분야의 인공지능 제품이나 서비스에 적용하기 위하여 확장 개발한 인공지능 윤리 측정지표 50개 항목과 선행 개발된 40개 항목의 인공지능 윤리 측정지표를 통합하여 90개의 인공지능 윤리 측정지표로 재구성하였다. 90개 항목의 윤리 측정지표를 대상으로 신뢰성 확보를 위한 인공지능 윤리 측정지표 연구를 진행하였다. 인공지능의 신뢰성(Trustworthiness)은 인공지능이 모든 해당 법률을 준수하며 합법적이어야 하고, 규정은 윤리적이어야 하며, 윤리적 원칙과 좋은 의도가 있더라도 기술과 사회적 관점에서 견고해야 한다(AI HLEG, 2019). 인공지능 윤리 측정지표의 신뢰성을 확보하기 위하여 FGI에서 신뢰성 변수를 정의하고, 90개 항목의 윤리 측정지표에 신뢰성 변수를 적용하여 신뢰성 검증을 위한 설문지 설계와 설문조사를 실시하였다. 또한 유럽연합에서 공표한 ALTAI를 탐색하여 EMI-AI와 관계성을 검증하는 연구를 진행하였다. 설문조사는 Likert 5점 척도를 적용하였으며, 200명을 대상으로 설문지를 배포하여 164명으로부터 설문지를 회수하였다. 164명의 모든 표본은 유의미한 응답으로 판단하여 설문 분석에 활용되었다. 설문 결과 분석은 SPSS를 이용하여 통계분석 및 검증을 진행하였다. 주요 분석 내용은 타당성 분석, 기술통계량 분석, 신뢰도 분석, 상관관계분석, 인구통계학적 분석을 진행하였다. 분석 결과로 나온 윤리 측정지표를 정리하여 연구 결과로 완성하였다. 또한 ALTAI와 EMI-AI 간의 관계성을 전문가 델파이 조사를 통하여 분석하였으며, EMI-AI에 대한 차별성과 특징을 도출하고, EMI-AI에 대한 신뢰도를 높일 수 있도록 하였다.

## 2. 인공지능 윤리 측정지표 신뢰성 연구 절차

본 연구는 인공지능의 신뢰성 확보를 위한 윤리 측정지표를 개발하는 것이다. 따라서 선행 개발된 인공지능 윤리 측정지표 40개 항목과 확장 개발한 윤리 측정지표 50개 항목을 통합하여 90개 항목의 인공지능 윤리 측정지표로 만들었다. 신뢰성 확보를 위하여 통제성, 안전성, 보안성, 투명성, 공정성, 사회적영향, 책무성으로 정의한 신뢰성 변수 7개를 적용하여 신뢰성 연구를 진행하였다. <그림 4-1>은 인공지능 윤리 측정지표 신뢰성 연구 절차와 실행 내용이다. 90개 항목의 인공지능 윤리 측정지표와 신뢰성 변수를 적용하여 연구 설문지를 설계하였으며, 설문조사 전 설



<그림 4-1> 인공지능 윤리 측정지표 신뢰성 연구 절차와 실행 내용

문지에 대한 시뮬레이션을 실시하여 설문 항목의 문제점 제거와 보완으로 설문지를 완성도를 높였다. 설문의 신뢰성을 높이기 위하여 설문 대상자 200명은 다양한 분야의 인공지능 관련 업무 종사자로 선정하여 설문지를 배포하였다. 설문조사는 2022년 6월에 15일간 진행하였으며, 164명이 설문조사에 응답하였다. 설문조사 결과

는 실시간으로 시스템에서 확인할 수 있도록 하였으며, 설문조사 시스템을 통하여 데이터 수집 및 다운로드로 원시데이터를 생성하고 통계분석에 활용하였다. 설문 응답한 164명의 설문 결과 데이터는 모두 유의미하여 분석 데이터로 활용하는데 문제가 없었다. 설문 분석과 신뢰성 검증 단계에서는 SPSS 도구를 사용하여 통계분석을 실시하였다. 통계분석은 인구통계학적 분석, 기술통계량 분석, 신뢰도 분석, 탐색적 요인분석, 상관관계분석을 진행하였다. 완료된 통계분석 결과에 의하여 인공지능 윤리 측정지표 90개 항목 중 86개 항목에 대하여 신뢰성이 확보된 인공지능 윤리 측정지표[EMI-AI]로 제시하였다.

EMI-AI와 ALTAI 간의 관계성 검증을 위해 ALTAI의 요구사항 7개 항목에 대하여 평가 목록별로 인공지능 윤리원칙과 구성요소를 매핑하고, 각 요구사항별 핵심 내용에 대한 윤리적 특성을 탐색하였다. EMI-AI와 ALTAI 간의 관계성 검증은 전문가 델파이 설문조사를 통하여 진행하였다. EMI-AI의 측정지표 항목과 ALTAI의 평가목록이 같거나 유사한 항목으로 매핑하여 설문지 설계와 설문조사를 진행하였다. 설문조사에 참여한 전문가는 인공지능 윤리 관련 분야에 종사한 16명이었다. 전문가 델파이 조사 결과를 이용하여 내용 타당도 분석을 실시하였다. 내용 타당도 분석 결과에 의하여 EMI-AI와 ALTAI 간의 관계성을 검증하였으며, EMI-AI에 ALTAI 평가목록이 포함된 관계를 제시하였다.

본 연구 결과로 EMI-AI를 제시하여 인공지능 제품이나 서비스 개발 및 운영 시 인공지능의 신뢰성을 높일 수 있는 인공지능 윤리 측정지표로 적용할 수 있도록 제안하였다. 또한 향후 인공지능의 모든 분야에 인공지능 윤리 측정지표를 활용할 수 있는 활용방안도 제시하였다.

## 제 2 절 인공지능 윤리원칙과 신뢰할 수 있는 평가목록

### 1. 신뢰할 수 있는 인공지능 평가목록 탐색

신뢰할 수 있는 인공지능 평가목록(ALTAI)에 대한 인공지능 윤리원칙을 정의하여 윤리 측정지표와 관계성을 검증할 수 있도록 하였다. ALTAI에서 요구하는 7개 항목의 요구사항에 각각 인공지능 윤리원칙과 구성요소를 적용하였으며, ALTAI의 요구사항에 대한 윤리적 특성과 주요 평가목록 현황을 탐색하였다.

가. 인간의 기본권, 자율성, 존엄성 존중(Human Agency and Oversight)

[표 4-1] 인간의 기본권, 자율성, 존엄성 존중 요구사항

| 요구사항별<br>핵심 내용                                   | 세부 설명                                                                                                                          | 윤리적 특성<br>(목록 수) | 윤리원칙 | 구성요소               |
|--------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------|------------------|------|--------------------|
| 인간의 주체와<br>자율성<br>(Human Agency and<br>Autonomy) | AI 시스템은 의사결정 과정에서 인간이 주체가 될 수 있도록 하며, 인간 또는 사회적 상호작용에서 인간의 자율성에 영향이 미치지 않도록 함                                                  | 통제성<br>( 6 )     | 통제성  | 이용자<br>주도성         |
| 인간의 감독<br>(Human Oversight)                      | 인간은 AI 시스템의 모든 의사결정에 개입할 수 있어야 하며, 설계, 개발, 작동을 모니터링하고, AI가 내린 결정을 무시할 수 있도록 보장하여 특정 상황에서 AI 시스템 사용을 정지할 수 있도록 통제하는 것을 포함할 수 있음 | 통제성<br>( 5 )     | 통제성  | 모니터링,<br>제어<br>가능성 |

나. 기술적 견고성과 안전성(Technical Robustness and Safety)

[표 4-2] 기술적 견고성과 안전성 요구사항

| 요구사항별<br>핵심 내용                                                               | 세부 설명                                                                                                                                  | 윤리적 특성<br>(목록 수) | 윤리원칙 | 구성요소      |
|------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|------------------|------|-----------|
| 일반 안전<br>(General Safety)                                                    | AI 시스템의 특정 사용 사례에서 위험(Risk), 위험 매트릭스, 위험 수준을 측정 평가할 수 있도록 하며, 잠재적 위험(설계 결함, 기술 결함, 환경) 발생에 대한 안전 수준을 정의, 평가하여 지속적인 신뢰와 안정이 확보될 수 있도록 함 | 안전성<br>( 5 )     | 안전성  | 견고성       |
| 정확성 (Accuracy)                                                               | AI 시스템이 목표로 하고 있는 기능 작동이 정확하게 될 수 있도록 고품질의 학습용 데이터 적용, 완벽한 시스템 배포 환경 마련, 모니터링, 문서화하여 정확도 수준을 높일 수 있도록 프로세스를 마련하여야 함                    | 안전성<br>( 5 )     | 안전성  | 견고성       |
| 공격 및 보안에 대한<br>복원력 (Resilience to<br>Attack and Security)                    | AI 시스템이 설계 또는 기술적 결함, 정전, 공격, 오용, 부적절하거나 악의적인 사용, 위험이나 위협으로부터 안전하게 하며, 사이버 공격에 대한 대책 마련과 공격에 대한 무결성, 보안성을 보장할 수 있도록 함                  | 보안성<br>( 6 )     | 안전성  | 보안성       |
| 신뢰성, 대체 계획 및<br>재현성 (Reliability,<br>Fall-back plans and<br>Reproducibility) | AI 시스템이 인간에 대하여 적대적이거나 치명적인 해로운 결과를 초래하지 않도록 신뢰성을 확보하고, 재현성을 보장하며, 출처에 관계없이 AI 시스템 오류를 해결하기 위한 폴백 계획을 수립함                              | 안전성<br>( 5 )     | 투명성  | 검증<br>가능성 |

다. 개인정보 보호 및 데이터 거버넌스(Privacy and Data Governance)

[표 4-3] 개인정보 보호 및 데이터 거버넌스 요구사항

| 요구사항별<br>핵심 내용                | 세부 설명                                                   | 윤리적 특성<br>(목록 수) | 윤리원칙 | 구성요소        |
|-------------------------------|---------------------------------------------------------|------------------|------|-------------|
| 프라이버시<br>(Privacy)            | AI 시스템은 개인정보보호 및 데이터 보호에 대한 AI 시스템의 영향을 자체 평가할 수 있도록 함  | 보안성<br>( 2 )     | 안전성  | 프라이버시<br>보호 |
| 데이터 거버넌스<br>(Data Governance) | AI 시스템이 개인 데이터 및 데이터 보호 관련된 다양한 요소를 준수하고 자체 평가할 수 있도록 함 | 보안성<br>( 4 )     | 안전성  | 프라이버시<br>보호 |

라. 투명성 (Transparency)

[표 4-4] 투명성 요구사항

| 요구사항별<br>핵심 내용             | 세부 설명                                                                                                                  | 윤리적 특성<br>(목록 수)       | 윤리원칙 | 구성요소  |
|----------------------------|------------------------------------------------------------------------------------------------------------------------|------------------------|------|-------|
| 추적성<br>(Traceability)      | AI 시스템의 개발 프로세스에서 의사결정을 내리는 데이터와 프로세스가 추적 가능성을 허용하고 투명성을 높이며, 궁극적으로 사회에서 AI에 대한 신뢰를 구축할 수 있도록 적절하게 문서화 되어 있는지를 자체 평가 함 | 투명성<br>( 1 )<br>(세부:5) | 투명성  | 추적가능성 |
| 설명 가능성<br>(Explainability) | AI 시스템의 기술적 프로세스와 AI 시스템이 내리는 의사결정 또는 예측에 대한 추론을 설명할 수 있도록 한다.                                                         | 투명성<br>( 2 )           | 투명성  | 설명가능성 |
| 의사 소통<br>(Communication)   | AI 시스템을 사용자에게 적절한 방식으로 기능과 한계, 사용 방법에 대하여 전달 할 수 있도록 함                                                                 | 투명성<br>( 2 )           | 투명성  | 설명가능성 |

마. 다양성, 차별금지 및 공정성(Diversity, Non-discrimination and Fairness)

[표 4-5] 다양성, 차별금지 및 공정성 요구사항

| 요구사항별<br>핵심 내용                                          | 세부 설명                                                           | 윤리적 특성<br>(목록 수) | 윤리원칙 | 구성요소              |
|---------------------------------------------------------|-----------------------------------------------------------------|------------------|------|-------------------|
| 불공정한 편견 방지<br>(Avoidance of Unfair Bias)                | AI 시스템은 데이터의 편향성과 알고리즘의 편향성을 방지할 수 있도록 함                        | 공정성<br>( 5 )     | 공정성  | 데이터 편향성, 알고리즘 차별성 |
| 접근성과<br>보편적 디자인<br>(Accessibility and Universal Design) | AI 시스템은 사용자 중심이어야 하며, 접근성 표준에 따라 가능한 한 가장 광범위한 사용자를 수용할 수 있도록 함 | 공정성<br>( 4 )     | 공정성  | 접근성               |
| 이해관계자 참여<br>(Stakeholder Participation)                 | AI 시스템의 수명주기 전반에 걸쳐 직간접적으로 영향을 받을 수 있는 이해관계자를 폭넓게 참여시켜 협의함      | 공정성<br>( 1 )     | 공정성  | 공공성               |

바. 사회 및 환경에 미치는 영향(Societal and Environmental Well-being)

[표 4-6] 사회 및 환경에 미치는 영향 요구사항

| 요구사항별<br>핵심 내용                                    | 세부 설명                                                                                            | 윤리적 특성<br>(목록 수)   | 윤리원칙 | 구성요소 |
|---------------------------------------------------|--------------------------------------------------------------------------------------------------|--------------------|------|------|
| 환경 웰빙<br>(Environmental Well-being)               | AI 시스템을 개발, 배포, 사용하는 전체적인 프로세스에서 환경친화적 방식으로 작동될 수 있도록 메커니즘을 설정함                                  | 사회적<br>영향<br>( 2 ) | 공정성  | 공공성  |
| 업무 및 기술에<br>미치는 영향<br>(Impact on Work and Skills) | AI 시스템은 작업환경 및 기술에 영향을 끼치므로 AI 시스템을 사용하는 근로자, 근로자와 고용주 간의 관계 등에 대한 작업환경, 기술에 미치는 영향을 평가할 수 있도록 함 | 사회적<br>영향<br>( 5 ) | 책무성  | 준법성  |

|                                                                    |                                                           |                           |     |     |
|--------------------------------------------------------------------|-----------------------------------------------------------|---------------------------|-----|-----|
| 사회 전체 또는 민주주의에 미치는 영향<br>(Impact on Society at Large or Democracy) | AI 시스템이 사회적 관점에서 사회 전체 또는 민주적 절차와 관련된 영향에 미치는 영향에 대하여 평가함 | 사회적 영향<br>( 1 )<br>(세부:3) | 공정성 | 공공성 |
|--------------------------------------------------------------------|-----------------------------------------------------------|---------------------------|-----|-----|

#### 사. 책무성 (Accountability)


[표 4-7] 책무성 요구사항

| 요구사항별<br>핵심 내용             | 세부 설명                                                                                                | 윤리적 특성<br>(목록 수) | 윤리원칙 | 구성요소          |
|----------------------------|------------------------------------------------------------------------------------------------------|------------------|------|---------------|
| 감사 가능성<br>(Auditability)   | AI 시스템은 내외부 감사자가 독립적으로 감사할 수 있어야 함                                                                   | 책무성<br>( 2 )     | 투명성  | 추적가능성         |
| 위기 관리<br>(Risk Management) | AI 시스템의 결과에 기여하는 행동이나 결정에 대한 보고, 결과 대응, 영향 식별, 평가, 문서화 등 작업자 또는 보고자가 정당한 우려 사항을 보고할 때는 적절한 보호를 받아야 함 | 책무성<br>( 6 )     | 책무성  | 준법성,<br>책임식별성 |

## 2. 신뢰할 수 있는 인공지능 평가목록의 윤리적 신뢰성 관계 정의

ALTAI의 평가목록을 바탕으로 인공지능 윤리적 신뢰성을 통제성, 안전성, 보안성, 투명성, 공정성, 사회적영향, 책무성으로 나누어 정의하였으며, 윤리적 신뢰성 정의는 인공지능 윤리원칙 분류 모형과 구성요소를 기반으로 <그림 4-2>와 같이 하였다. 윤리적 신뢰성 중 사회적영향이라 함은 인공지능이 사회 전반에 걸쳐 다양하게 사용되며, 국가, 조직, 체제, 인종, 계층 및 사회, 정치, 문화, 기술, 환경 등에

부정적인 영향이 미치지 않도록 사용되어야 함을 의미한다(ALTAI, 2020). ALTAI의 각 요구사항에 포함된 평가목록을 윤리적 신뢰성으로 재정의하여 인공지능 윤리 측정지표와 관계성을 탐색하고자 하였다.



<그림 4-2> 신뢰할 수 있는 인공지능 평가목록의 윤리적 신뢰성 관계 정의

### 3. 신뢰할 수 있는 인공지능 평가목록에 대한 시사점

인공지능 기술은 모든 산업에서 핵심적인 기술로 발전하게 되면서 인공지능 윤리가 이슈화되고 있다. 이러한 시대적 상황에서 인간에게 안전하고 편리한 도구로서 활용성이 높아 세계 각국에서 인공지능에 대한 윤리를 쟁점으로 정책 수립과 연구, 제품이나 서비스에 적용하고 있다. ALTAI를 개발하는 데 큰 들었기 때문에 유럽연합에 속한 국가에 적용하는 데는 무리가 없겠지만 모든 국가에 적용하기에는 한계가 따른다. 국가마다 사회, 문화, 정치, 기술, 윤리, 도덕, 교육, 노동환경 등이 상이한 관계로 우리나라에 적용할 인공지능 윤리 측정지표는 우리나라 특성에 맞도록 개발하여 사용할 필요성이 다음과 같이 요구된다.

첫째, 기술적으로 강점을 가지는 인공지능 분야에 먼저 적용할 인공지능 윤리 측정지표가 개발되어야 한다, 둘째, 인공지능 기술은 소프트웨어를 이용하여 개발되고 제품, 서비스로 제공한다. 따라서 인공지능 기술이 적용된 모든 소프트웨어 제품이나 서비스에는 소프트웨어 인증과 함께 인공지능 윤리인증이 필요하다. 이러한 인공지능 윤리인증에 활용하기 위한 인공지능 윤리 측정지표가 신속하게 개발되어야 한다. 셋째, 경제와 국가 체제 환경에 따라 인공지능은 근로자에게 제공할 서비스의 제약을 받을 수 있다. 특히 국가 체제에 따라 민주주의, 사회주의, 종교적 특성에 따라 적용하는 윤리적 기준이 상이하기에 차별화된 인공지능 윤리 측정지표가 필요하다. 넷째, 다양한 인공지능 기술이 개발되고 있기 때문에 산업 전반에 반영할 수 있는 윤리 측정지표가 필요하다. 마지막으로 법·제도 적용 수준에 따라 우선순위에 의하여 인공지능 윤리 측정지표를 개발하여야 한다. 윤리 측정지표가 엄격하게 적용되어 인간에게 신뢰와 안전을 보장하기 위해서는 최종적으로 법 적용이 가장 중요하기 때문이다. 본 논문에서는 위에 열거한 내용이 적용될 수 있는 인공지능 윤리 측정지표를 개발하고자 하였다.

### 제 3 절 인공지능 윤리원칙에 기반한 윤리 측정지표


#### 1. 인공지능 윤리원칙 및 구성요소별 윤리 측정지표 현황

인공지능 윤리원칙 기반의 인격권 및 재산 보호를 위한 인공지능 윤리 측정지표 연구 결과에 따라 도출된 윤리 측정지표와 신뢰성 확보를 위해 본 연구에서 전문가 그룹을 통하여 확장 개발한 인공지능 윤리 측정지표를 통합하여 만든 인공지능 윤리원칙 및 구성요소별 윤리 측정지표 항목 수 현황은 [표 4-8]과 같다.


[표 4-8] 인공지능 윤리원칙 및 구성요소별 윤리 측정지표 항목 현황

| 윤리원칙 | 구성요소     | 기존 개발 항목수 | 확장 개발 항목수 | 전체 항목수 |
|------|----------|-----------|-----------|--------|
| 투명성  | 설명가능성    | 5         | 2         | 7      |
|      | 추적가능성    | 3         | 2         | 5      |
|      | 검증가능성    | -         | 5         | 5      |
| 책임성  | 준법성      | 3         | 6         | 9      |
|      | 책임 식별성   | 4         | 1         | 5      |
| 공정성  | 알고리즘 차별성 | 4         | 2         | 6      |
|      | 데이터 편향성  | 6         | 2         | 8      |
|      | 접근성      | -         | 4         | 4      |
|      | 공공성      | -         | 9         | 9      |
| 통제성  | 제어 가능성   | 4         | 1         | 5      |
|      | 이용자 주도성  | -         | 5         | 5      |
|      | 모니터링     | -         | 2         | 2      |
| 안전성  | 견고성      | 3         | 4         | 7      |
|      | 보안성      | 3         | 3         | 6      |
|      | 프라이버시 보호 | 5         | 2         | 7      |
| 합 계  |          | 40        | 50        | 90     |

인공지능 윤리 측정지표 항목 90개는 선행 개발된 항목 40개(소순주·안성진, 2021)와 본 연구에서 전문가 그룹의 FGI 및 델파이 설문조사에 의하여 확장 개발된 50개 항목을 통합하여 구성하였다. <그림 4-3>은 인공지능 윤리원칙별 윤리 측정지표 현황을 나타낸 그래프이다. 또한 <그림 4-4>는 인공지능 윤리원칙 구성 요소별 윤리 측정지표 현황을 나타낸 그래프이다.



<그림 4-3> 인공지능 윤리원칙별 윤리 측정지표 항목 분포도



<그림 4-4> 인공지능 윤리원칙 구성요소별 윤리 측정지표 항목 분포도

## 2. 인공지능 윤리 측정지표 최종 항목

개발된 인공지능 윤리 측정지표 항목은 [표 4-9]이며, 선행 개발된 윤리 측정지표와 신규로 확장하여 개발한 윤리 측정지표를 통합하여 작성된 인공지능 윤리 측정지표 90개의 최종 항목이다.

[표 4-9] 인공지능 윤리 측정지표 최종 항목

| 윤리원칙 | 구성요소 (항목 수)    | 윤리 측정지표 항목           | 항목코드 |
|------|----------------|----------------------|------|
| 투명성  | 설명가능성<br>( 7 ) | 최종 사용자를 위한 투명성       | A01  |
|      |                | 사고조사자를 위한 투명성        | A02  |
|      |                | 변호사 및 전문가 증인을 위한 투명성 | A03  |
|      |                | 이용 범위 고지 투명성         | A04  |
|      |                | 이용자 데이터수집 투명성        | A05  |
|      |                | 안전 인증자를 위한 투명성       | A06  |
|      |                | 대중 및 이해관계자를 위한 투명성   | A07  |
|      | 추적가능성<br>( 5 ) | 문제 분석을 위한 데이터 제공     | A08  |
|      |                | 제작 과정의 기록 보관         | A09  |
|      |                | 사고 발생 이력 보관          | A10  |
|      |                | 상시 운영 감시             | A11  |
|      |                | 정기 운영 감사             | A12  |
|      | 검증가능성<br>( 5 ) | 안전성 시험기준 적용          | A13  |
|      |                | 알고리즘의 투명성 확보         | A14  |
|      |                | 학습용 데이터의 신뢰성         | A15  |
|      |                | 학습용 데이터의 충분성         | A16  |
|      |                | 시험, 인증 결과 제시         | A17  |
| 책임성  | 준법성<br>( 9 )   | 법·제도 준수              | B01  |
|      |                | 개인정보 제공 동의 획득        | B02  |
|      |                | 데이터 사용 사전 허가 획득      | B03  |
|      |                | 법적 근거 확보와 제시         | B04  |
|      |                | 사용 설명서와 기능 일치성       | B05  |
|      |                | 사용범위 법적 기준 준수 명문화    | B06  |
|      |                | 이용자 안전 우선 준수         | B07  |
|      |                | 신고자에 대한 법적 보호        | B08  |
|      |                | 이용자 요구사항 대응          | B09  |

| 윤리원칙 | 구성요소 (항목 수)       | 윤리 측정지표 항목         | 항목코드 |
|------|-------------------|--------------------|------|
| 책임성  | 책임식별성<br>( 5 )    | 설계자 책임 식별          | B10  |
|      |                   | 제작자 책임 식별          | B11  |
|      |                   | 운영자 책임 식별          | B12  |
|      |                   | 이용자 책임 식별          | B13  |
|      |                   | 개발자 책임 식별          | B14  |
| 공정성  | 알고리즘 차별성<br>( 6 ) | 의도적 차별 요소 제한       | C01  |
|      |                   | 개인 편향적 차별 제한       | C02  |
|      |                   | 불공정한 알고리즘          | C03  |
|      |                   | 인간의 생명 위협 방지       | C04  |
|      |                   | 알고리즘의 의사결정 프로세스 제공 | C05  |
|      |                   | 차별적 불이익 방지         | C06  |
|      | 데이터 편향성<br>( 8 )  | 편향적 특성 제거          | C07  |
|      |                   | 데이터의 사실성           | C08  |
|      |                   | 학습용 데이터의 수량        | C09  |
|      |                   | 데이터의 유효성 검사        | C10  |
|      |                   | 학습용 데이터 품질관리       | C11  |
|      |                   | 데이터 편향 방지 알고리즘 적용  | C12  |
|      |                   | 데이터 분류 기준 정의 및 적용  | C13  |
|      |                   | 데이터 균일성 확보         | C14  |
|      | 접근성<br>( 4 )      | 접근성 보장             | C15  |
|      |                   | 보편적 사용자 지원         | C16  |
|      |                   | 사용자 접근 제한 방지       | C17  |
|      |                   | 이용자의 쉬운 접근성        | C18  |
|      | 공공성<br>( 9 )      | 공공데이터 수집 금지        | C19  |
|      |                   | 데이터 활용 제한          | C20  |
|      |                   | 개인정보 수집 제한         | C21  |
|      |                   | 사회환경에 미치는 영향 배제    | C22  |
|      |                   | 인간의 생명 위협 방지       | C23  |
|      |                   | 이해관계자의 의견 반영       | C24  |
|      |                   | 친환경 에너지 활용         | C25  |
|      |                   | 폐기 제품 관리           | C26  |
|      |                   | 모든 인류에게 공정한 제공     | C27  |

| 윤리원칙  | 구성요소 (항목 수)       | 윤리 측정지표 항목            | 항목코드 |
|-------|-------------------|-----------------------|------|
| 통제성   | 제어 가능성<br>( 5 )   | 정책적 통제권 이양            | D01  |
|       |                   | 이용자 제어장치 제공           | D02  |
|       |                   | 생명 위협 시 자동 종료         | D03  |
|       |                   | 운영자 통제 및 제어           | D04  |
|       |                   | 위험 발생 시 쉬운 접근성 제공     | D05  |
|       | 이용자 주도성<br>( 5 )  | 이용자 위험 회피             | D06  |
|       |                   | 자율적 조작                | D07  |
|       |                   | 이용자 데이터 선택적 제공        | D08  |
|       |                   | 이용자 데이터 삭제            | D09  |
|       |                   | 작동상태 제공               | D10  |
|       | 모니터링 ( 2 )        | 위험 예측 상태 제공           | D11  |
|       |                   | 운영상태 상시 모니터링          | D12  |
| 안전성   | 견고성<br>( 7 )      | 인간의 생명 보호 우선          | E01  |
|       |                   | 알고리즘의 오류 관리           | E02  |
|       |                   | 외부 공격에 대한 견고성         | E03  |
|       |                   | 예측 결과의 동일성            | E04  |
|       |                   | 학습 데이터의 정확성(accuracy) | E05  |
|       |                   | 기능의 지속적 업그레이드 및 배포    | E06  |
|       |                   | 기능 프로세스의 정확한 정의       | E07  |
|       | 보안성<br>( 6 )      | 보안성 인증                | E08  |
|       |                   | 사용자 인증                | E09  |
|       |                   | 상호작용 데이터 보안           | E10  |
|       |                   | 비인가자 연결 방지            | E11  |
|       |                   | 알고리즘 시큐어 코딩           | E12  |
|       |                   | 이용 종료 시 정보 삭제         | E13  |
|       | 프라이버시 보호<br>( 7 ) | 개인정보보호 영향평가           | E14  |
|       |                   | 개인정보 수집 고지            | E15  |
|       |                   | 개인정보 가명화              | E16  |
|       |                   | 개인 민감정보 수집 차단         | E17  |
|       |                   | 개인정보 활용               | E18  |
|       |                   | 미동의 데이터 수집 방지         | E19  |
|       |                   | 데이터 주권 보장             | E20  |
| 총 항목수 | 90 개              |                       |      |

개발된 최종 인공지능 윤리 측정지표 90개 항목은 <그림 4-5>와 같이 인공지능 윤리 원칙과 각 구성요소에 해당하는 인공지능 윤리 측정지표 항목 수 현황을 도형화 하였다.



<그림 4-5> 인공지능 윤리 측정지표 항목 수 현황

## 제 4 절 인공지능 윤리 측정지표와 신뢰성 간의 관계 설정

### 1. 인공지능 윤리 측정지표와 신뢰성 간의 관계 정의

FGI를 통하여 정의한 인공지능 신뢰성 변수 7개 항목에 통합 개발된 윤리 측정지표 90개 항목을 [표 4-10]과 같이 윤리 측정지표와 신뢰성 간의 관계를 정의하고, 90개에 해당하는 윤리 측정지표의 신뢰성을 검증하기 위한 설문지를 설계하였다.

[표 4-10] 인공지능 윤리 측정지표와 신뢰성 간의 관계 정의

| 신뢰성변수 | 윤리 측정지표 항목         | 종속변수 코드 | 윤리측정 지표 코드 |
|-------|--------------------|---------|------------|
| 통제성   | 이용자 위험 회피          | A-01    | D06        |
|       | 자율적 조작             | A-02    | D07        |
|       | 이용자 데이터 선택적 제공     | A-03    | D08        |
|       | 이용자 데이터 삭제         | A-04    | D09        |
|       | 작동상태 제공            | A-05    | D10        |
|       | 위험 예측 상태 제공        | A-06    | D11        |
|       | 운영상태 상시 모니터링       | A-07    | D12        |
|       | 정책적 통제권 이양         | A-08    | D01        |
|       | 이용자 제어장치 제공        | A-09    | D02        |
|       | 생명 위험시 자동 종료       | A-10    | D03        |
|       | 운영자 통제 및 제어        | A-11    | D04        |
|       | 위험 발생 시 쉬운 접근성 제공  | A-12    | D05        |
| 안전성   | 인간의 생명 보호 우선       | B-01    | E01        |
|       | 알고리즘의 오류 관리        | B-02    | E02        |
|       | 외부 공격에 대한 견고성      | B-03    | E03        |
|       | 예측 결과의 동일성         | B-04    | E04        |
|       | 학습 데이터의 정확성        | B-05    | E05        |
|       | 기능의 지속적 업그레이드 및 배포 | B-06    | E06        |
|       | 기능 프로세스의 정확한 정의    | B-07    | E07        |
|       | 안전성 시험기준 적용        | B-08    | A13        |
|       | 알고리즘의 투명성 확보       | B-09    | A14        |
|       | 학습용 데이터의 신뢰성       | B-10    | A15        |
|       | 학습용 데이터의 충분성       | B-11    | A16        |
|       | 시험, 인증 결과 제시       | B-12    | A17        |

|     |                      |      |     |
|-----|----------------------|------|-----|
| 투명성 | 문제 분석을 위한 데이터 제공     | C-01 | A08 |
|     | 제작 과정의 기록 보관         | C-02 | A09 |
|     | 사고 발생 이력 보관          | C-03 | A10 |
|     | 최종 이용자를 위한 투명성       | C-04 | A01 |
|     | 사고조사자를 위한 투명성        | C-05 | A02 |
|     | 변호사 및 전문가 증인을 위한 투명성 | C-06 | A03 |
|     | 이용 범위 고지 투명성         | C-07 | A04 |
|     | 이용자 데이터수집 투명성        | C-08 | A05 |
|     | 안전 인증자를 위한 투명성       | C-09 | A06 |
|     | 대중 및 이해관계자를 위한 투명성   | C-10 | A07 |
| 공정성 | 의도적 차별 요소 제한         | D-01 | C01 |
|     | 개인 편향적 차별 제한         | D-02 | C02 |
|     | 불공정한 알고리즘 방지         | D-03 | C03 |
|     | 인간의 생명 위협 방지         | D-04 | C04 |
|     | 알고리즘의 의사결정 프로세스 제공   | D-05 | C05 |
|     | 차별적 불이익 방지           | D-06 | C06 |
|     | 편향적 특성 제거            | D-07 | C07 |
|     | 데이터의 사실성             | D-08 | C08 |
|     | 학습용 데이터의 수량          | D-09 | C09 |
|     | 데이터의 유효성 검사          | D-10 | C10 |
|     | 학습용 데이터 품질관리         | D-11 | C11 |
|     | 데이터 편향 방지 알고리즘 적용    | D-12 | C12 |
|     | 데이터 분류 기준 정의 및 적용    | D-13 | C13 |
|     | 데이터 균일성 확보           | D-14 | C14 |
|     | 접근성 보장               | D-15 | C15 |
|     | 보편적 사용자 지원           | D-16 | C16 |
|     | 사용자 접근 제한 방지         | D-17 | C17 |
|     | 이용자의 쉬운 접근성          | D-18 | C18 |
|     | 공공데이터 수집 공지          | D-19 | C19 |
|     | 데이터 활용 제한            | D-20 | C20 |
|     | 개인정보 수집 제한           | D-21 | C21 |
|     | 사회환경에 미치는 영향 배제      | D-22 | C22 |
|     | 인간의 생명 위협 방지         | D-23 | C23 |
|     | 이해관계자의 의견 반영         | D-24 | C24 |

|       |                 |      |     |
|-------|-----------------|------|-----|
| 보안성   | 보안성 인증          | E-01 | E08 |
|       | 사용자 인증          | E-02 | E09 |
|       | 상호작용 데이터 보안     | E-03 | E10 |
|       | 비인가자 연결 방지      | E-04 | E11 |
|       | 알고리즘 시큐어 코딩     | E-05 | E12 |
|       | 이용 종료 시 정보 삭제   | E-06 | E13 |
|       | 개인 정보보호 영향평가    | E-07 | E14 |
|       | 개인정보 수집 고지      | E-08 | E15 |
|       | 개인정보 가명화        | E-09 | E16 |
|       | 개인 민감정보 수집 차단   | E-10 | E17 |
|       | 개인정보 활용         | E-11 | E18 |
|       | 미동의 데이터 수집 방지   | E-12 | E19 |
|       | 데이터 주권 보장       | E-13 | E20 |
| 사회적영향 | 친환경 에너지 활용      | F-01 | C25 |
|       | 폐기 제품 관리        | F-02 | C26 |
|       | 법·제도 준수         | F-03 | B01 |
|       | 개인정보 제공 동의 획득   | F-04 | B02 |
|       | 데이터 사용 사전 허가 획득 | F-05 | B03 |
|       | 법적 근거 확보와 제시    | F-06 | B04 |
|       | 사용 설명서와 기능 일치성  | F-07 | B05 |
|       | 사용범위 법적 기준 문서화  | F-08 | B06 |
|       | 이용자 안전 우선 보호    | F-09 | B07 |
|       | 모든 인류에게 공정한 제공  | F-10 | C27 |
| 책무성   | 상시 운영 감시        | G-01 | A11 |
|       | 정기 운영 감사        | G-02 | A12 |
|       | 신고자에 대한 법적 보호   | G-03 | B08 |
|       | 이용자 요구사항 대응     | G-04 | B09 |
|       | 설계자 책임 식별       | G-05 | B10 |
|       | 제작자 책임 식별       | G-06 | B11 |
|       | 운영자 책임 식별       | G-07 | B12 |
|       | 이용자 책임 식별       | G-08 | B13 |
|       | 개발자 책임 식별       | G-09 | B14 |

## 2. ALTAI의 요구사항별 평가목록 변수 정의

유럽연합 집행위원회에서 발표한 신뢰할 수 있는 인공지능 평가목록(ALTAI)은 인공지능 시스템의 디자이너 및 개발자, 데이터 과학자, 조달 담당이나 전문가, 시스템을 사용하는 프론트엔드 사용자, 법률 관련 담당자 및 관리자들이 활용할 수 있도록 개발되었다(ALTAI, 2020). ALTAI에서 요구하는 7개 요구사항에 포함된 69개의 목록에 대하여 본 논문에서 개발된 인공지능 윤리 측정지표를 활용하여 관계성에 관한 연구를 진행하였다. 인공지능 윤리 측정지표와 관계성 탐색을 위하여 7개 요구사항에 포함된 평가목록을 요약하여 재정의하였으며, 신뢰성 변수는 FGI에서 정의된 것을 적용하였다. 재정의된 평가목록은 본 연구에서 개발한 EMI-AI와 ALTAI 평가목록 간의 관계성을 탐색하는 데 활용되었다. 평가목록의 항목 정의는 연구자의 조작적 정의에 의하여 작성되었다.

[표 4-11] ALTAI의 요구사항 1번의 변수정의 및 평가목록

| 핵심 내용                                      | 신뢰성 변수 | 평가목록                   | 목록 코드 |
|--------------------------------------------|--------|------------------------|-------|
| 인간의 주체와 자율성<br>(Human Agency and Autonomy) | 통제성    | 최종사용자 권리보장             | a01   |
|                                            |        | 사용주체와 AI 간 상호작용        | a02   |
|                                            |        | 인간의 자율성 보장             | a03   |
|                                            |        | 인간의 자율성 침해 방지          | a04   |
|                                            |        | AI와 사용주체 간 사회적 상호작용 기능 | a05   |
|                                            |        | AI가 인간의 자율성 통제 위험 배제   | a06   |
| 인간의 감독 (Human Oversight)                   |        | 인간의 AI 의사결정 개입 범위      | a07   |
|                                            |        | 인간이 AI에 개입하는 훈련 여부     | a08   |
|                                            |        | AI 작동상태 제공             | a09   |
|                                            |        | 사용자의 강제적 조작 (사용 중지)    | a10   |
|                                            |        | 인간이 AI 자율성 통제 가능       | a11   |

[표 4-11]은 신뢰할 수 있는 인공지능 평가목록에서 요구사항 1번인 인간의 기본권, 자율성, 존엄성 존중(Human Agency and Oversight)에 대한 변수 정의와 요구사항의 평가목록을 재정의한 것이다.

신뢰할 수 있는 인공지능 평가목록에서 요구사항 2번인 기술적 견고성과 안전성(Technical Robustness and Safety)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-12]와 같이 재정의하였다.

[표 4-12] ALTAI의 요구사항 2번의 변수정의 및 평가목록

| 핵심 내용                                                                        | 신뢰성 변수 | 평가목록                    | 목록 코드 |
|------------------------------------------------------------------------------|--------|-------------------------|-------|
| 일반 안전<br>(General Safety)                                                    | 안전성    | AI의 위험 수준 정의 및 관리       | b01   |
|                                                                              |        | AI의 위협과 발생 결과 확인        | b02   |
|                                                                              |        | AI의 의사결정 의존성 평가         | b03   |
|                                                                              |        | AI와 연계된 시스템 내결함성 계획     | b04   |
|                                                                              |        | AI의 견고성과 안전성 가치평가 개발    | b05   |
| 정확성 (Accuracy)                                                               |        | AI의 정확도 확인 결과 관리        | b06   |
|                                                                              |        | 학습용 데이터의 완전성 관리         | b07   |
|                                                                              |        | AI의 모니터링 및 문서화          | b08   |
|                                                                              |        | AI가 학습용 데이터 무효화에 따른 대응  | b09   |
|                                                                              |        | AI 의사결정 프로세스 정의         | b10   |
| 신뢰성, 대체 계획 및<br>재현성 (Reliability,<br>Fall-back plans and<br>Reproducibility) |        | AI가 신뢰성, 재현성이 낮은 경우 영향도 | b11   |
|                                                                              |        | AI의 신뢰성 검증 및 문서화        | b12   |
|                                                                              |        | AI 오류 해결을 위한 거버넌스 절차 마련 | b13   |
|                                                                              |        | AI의 낮은 신뢰도 결과에 대책 마련    | b14   |
|                                                                              |        | AI의 지속적 학습 여부           | b15   |
| 공격 및 보안에 대한<br>복원력 (Resilience to<br>Attack and Security)                    | 보안성    | AI의 기술적 결함 및 위협에 대응     | c01   |
|                                                                              |        | AI의 보안인증 및 표준화 준수       | c02   |
|                                                                              |        | 외부 공격으로 부터 취약점 대책       | c03   |
|                                                                              |        | AI에 대한 전반적인 보안 대책       | c04   |
|                                                                              |        | 내외부 취약점 테스트 여부          | c05   |
|                                                                              |        | 사용자에게 보안 범위, 업데이트 기간 제공 | c06   |

신뢰할 수 있는 인공지능 평가목록에서 요구사항 3번인 개인정보보호와 데이터 거버넌스(Privacy and Data Governance)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-13]과 같이 재정의하였다.

[표 4-13] ALTAI의 요구사항 3번의 변수 정의 및 평가목록

| 핵심 내용                      | 신뢰성 변수 | 평가목록                     | 목록 코드 |
|----------------------------|--------|--------------------------|-------|
| 프라이버시 (Privacy)            | 보안성    | 인간의 인격권에 미치는 영향 고려       | c07   |
|                            |        | AI 활용사례별 사생활 문제 허용 계획 수립 | c08   |
| 데이터 거버넌스 (Data Governance) |        | AI가 사용하는 개인 데이터 여부       | c09   |
|                            |        | 일반 데이터 보호 규정(GDPR) 적용    | c10   |
|                            |        | 비개인 데이터 보호 영향 고려         | c11   |
|                            |        | AI 시스템의 표준화, 거버넌스 준수     | c12   |

신뢰할 수 있는 인공지능 평가목록에서 요구사항 4번인 투명성 (Transparency)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-14]와 같이 재정의하였다.

[표 4-14] ALTAI의 요구사항 4번의 변수 정의 및 평가목록

| 핵심 내용                      | 신뢰성 변수 | 평가목록                                              | 목록 코드 |
|----------------------------|--------|---------------------------------------------------|-------|
| 추적성 (Traceability)         | 투명성    | AI의 전주기 동안 추적 가능성 시행<br>(데이터 품질, 알고리즘, 데이터 이력 포함) | d01   |
| 설명 가능성<br>(Explainability) |        | 의사결정 프로세스를 사용자에게 설명                               | d02   |
|                            |        | AI의 의사결정을 사용자가 이해하는지<br>지속적 조사                    | d03   |
| 의사 소통<br>(Communication)   |        | 사용자가 AI와 상호작용하고 있음을 인지<br>여부                      | d04   |
|                            |        | 사용자에게 AI 기능 안내, 설명 지원                             | d05   |

신뢰할 수 있는 인공지능 평가목록에서 요구사항 5번인 다양성, 차별금지 및 공정성 (Diversity, Non-discrimination and Fairness)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-15]와 같이 재정의하였다.

[표 4-15] ALTAI의 요구사항 5번의 변수 정의 및 평가목록

| 핵심 내용                                                | 신뢰성 변수 | 평가목록                                                 | 목록 코드                      |
|------------------------------------------------------|--------|------------------------------------------------------|----------------------------|
| 불공정한 편견 방지<br>(Avoidance of Unfair Bias)             | 공정성    | 데이터 및 알고리즘 편향성 방지 대책 수립                              | e01                        |
|                                                      |        | 학습용 데이터의 다양성과 대표성 고려<br>(편향성 파악, 최신 기술 공개 포함)        | e02                        |
|                                                      |        | AI 설계, 개발자에 대한 편향성 교육 시행                             | e03                        |
|                                                      |        | AI의 편향성 및 성능 이슈 표시 허용 보장                             | e04                        |
|                                                      |        | 공정성 보장을 위한 정의와 측정, 분석 기준 마련 (이해관계자 상담, 방법 수립 포함)     | e05                        |
| 접근성과 보편적 디자인<br>(Accessibility and Universal Design) |        | AI의 사회적 활용성 확인                                       | e06                        |
|                                                      |        | 사용자 접근성 평가 및 보장                                      | e07                        |
|                                                      |        | 인터페이스 개발 시 보편적 디자인 원칙 고려                             | e08                        |
|                                                      |        | AI가 사용자에게 미치는 불공정성 영향 평가<br>(사용자와 협력, 불균형, 위험 평가 포함) | e09                        |
| 이해관계자 참여<br>(Stakeholder Participation)              |        |                                                      | AI 설계, 개발자에 이해관계자 참여 방법 고려 |

신뢰할 수 있는 인공지능 평가목록에서 요구사항 6번인 사회 및 환경에 미치는 영향 (Societal and Environmental Well-being)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-16]과 같이 재정의하였다.

[표 4-16] ALTAI의 요구사항 6번의 변수정의 및 평가목록

| 핵심 내용                                                           | 신뢰성변수 | 평가목록                                                            | 목록 코드 |
|-----------------------------------------------------------------|-------|-----------------------------------------------------------------|-------|
| 환경 웰빙<br>(Environmental Well-being)                             | 사회적영향 | AI가 환경에 미치는 부정적 영향 여부                                           | f01   |
|                                                                 |       | AI 전 주기에서 환경적 영향평가 정의 및 방법 수립                                   | f02   |
| 업무 및 기술에 미치는 영향 (Impact on Work and Skills)                     |       | AI가 인간의 업무와 배치에 미치는 영향 여부                                       | f03   |
|                                                                 |       | AI 도입을 위한 이해관계자와 협의 방법 마련 여부                                    | f04   |
|                                                                 |       | AI가 근로자의 업무에 미치는 영향 이해하도록 조치 여부                                 | f05   |
|                                                                 |       | 노동력의 비숙련화 위험 발생 여부                                              | f06   |
|                                                                 |       | AI가 새로운 기술 촉진, 필요 여부                                            | f07   |
| 사회 전체 또는 민주주의에 미치는 영향 (Impact on Society at Large or Democracy) |       | AI가 사회 전반 또는 민주주의에 부정적 영향을 미치는지 여부 (사회적 영향평가, 피해 최소화, 조치 여부 포함) | f08   |

신뢰할 수 있는 인공지능 평가목록에서 요구사항 7번인 책무성(Accountability)에 대한 변수 정의와 요구사항의 평가목록을 [표 4-17]과 같이 재정의하였다.

[표 4-17] ALTAI의 요구사항 7번의 변수정의 및 평가목록

| 핵심 내용                      | 신뢰성 변수 | 평가목록                                       | 목록 코드 |
|----------------------------|--------|--------------------------------------------|-------|
| 감사 가능성<br>(Auditability)   | 책무성    | AI의 감사 가능성 촉진 방법 수립 여부                     | g01   |
|                            |        | AI를 독립적 제3자에게 감사 가능 여부                     | g02   |
| 위기 관리<br>(Risk Management) |        | 윤리, 책임 측정을 제3자가 감사 할 수 있는 프로세스 여부          | g03   |
|                            |        | AI의 위험 교육을 잠재적인 법적 틀에서 알려주는지 여부            | g04   |
|                            |        | AI 윤리 검토 위원회 또는 유사한 기능조직 설립을 고려하는지 여부      | g05   |
|                            |        | ALTAI 준수 모니터링 및 평가 프로세스 수립 여부              | g06   |
|                            |        | AI의 잠재적 역기능에 대하여 제3자가 보고 할 수 있는 프로세스 수립 여부 | g07   |
|                            |        | 개인에게 미치는 악영향을 설계에 반영하는지 여부                 | g08   |


## 제 5 절 인공지능 윤리 측정지표와 신뢰성에 관한 설문조사 결과 분석

### 1. 설문 대상 표본의 특성

본 연구를 위해 선정된 설문 참여자 약 200명에게 설문지를 배포하고, 회수한 설문지 164명의 응답자의 특성은 [표 4-18]과 같다.

[표 4-18] 표본의 인구 통계적 특성

| 구분              |              | 빈도수(명) | 구성 비율(%) | 누적 비율(%) |
|-----------------|--------------|--------|----------|----------|
| 성별              | 남            | 117    | 71.3     | 71.3     |
|                 | 여            | 47     | 28.7     | 100.0    |
| 연령              | 20 ~ 29세     | 21     | 12.8     | 12.8     |
|                 | 30 ~ 39세     | 48     | 29.3     | 42.1     |
|                 | 40 ~ 49세     | 68     | 41.5     | 83.5     |
|                 | 50세 이상       | 27     | 16.5     | 100.0    |
| 직업(직무)<br>분류    | AI 윤리 전문가    | 22     | 13.4     | 13.4     |
|                 | AI 관련 법률가    | 9      | 5.5      | 18.9     |
|                 | 사회학자         | 5      | 3.0      | 22.0     |
|                 | AI 교육자       | 19     | 11.6     | 33.5     |
|                 | AI 설계자(컨설턴트) | 24     | 14.6     | 48.2     |
|                 | AI 개발자       | 16     | 9.8      | 57.9     |
|                 | AI 제작자       | 12     | 7.3      | 65.2     |
|                 | AI 운영(도입)자   | 14     | 8.5      | 73.8     |
|                 | AI 윤리 교육자    | 8      | 4.9      | 78.7     |
|                 | 윤리 교육자       | 5      | 3.0      | 81.7     |
|                 | 일반 SW 종사자    | 18     | 11.0     | 92.7     |
|                 | AI 사용 일반인    | 12     | 7.3      | 100.0    |
| 직업(직무)<br>경력 년수 | 2년 이하        | 19     | 11.6     | 11.6     |
|                 | 3년 ~ 5년      | 65     | 39.6     | 51.2     |
|                 | 6년 ~ 10년     | 42     | 25.6     | 76.8     |
|                 | 11년 ~ 15년    | 26     | 15.2     | 92.1     |
|                 | 16년 이상       | 13     | 7.9      | 100.0    |



<그림 4-6> 직업(직무)별 참여 인원 분포도

<그림 4-6>과 같이 설문 응답자의 표본 수는 전체 164명이었으며, 이를 성별 분포로 살펴보면 남자가 117명으로 전체의 71.3%이고 여자가 47명으로 전체의 28.7%를 차지하였다. 연령별 분포로는 20~29세가 21명(12.8%), 30~39세가 48명(29.3%), 40~49세가 68명(41.5%), 50세 이상이 27명(16.5%)으로 30대~40대가 약 70%로 나타났다. 직무별 분포는 AI 윤리 전문가가 22명(13.4%), AI 관련 법률가가 9명(5.5%), 사회학자가 5명(3.3%), AI 교육자가 19명(11.6%), AI 설계자(컨설턴트 포함)가 24명(14.6%), AI 개발자가 16명(9.8%), AI 제작자가 12명(7.3%), AI 운영(도입)자가 14명(8.5%), AI 윤리 교육자가 8명(4.9%), 윤리 교육자가 5명(3.0%), 일반 SW 종사자가 18명(11.0%), AI 사용 일반인 12명(7.3%)이 응답자로 참여하였다.

본 연구를 위하여 인공지능과 윤리, 법률, 교육, 사회학, SW 개발, AI 개발, 일반 사용자 등 다양한 직업과 직무를 수행하는 자를 설문 참여자로 선정하여 설문 조사를 실시하였다. 직업이나 직무에 종사했던 업무경력 분포로는 2년 이하가 19명

(11.6%), 3년~5년이 65명(39.6%), 6년~10년이 42명(25.6%), 11년~15년이 26명(15.2%), 16년 이상이 13명(7.9%)으로 3년~10년의 경력을 보유한 응답자가 약 65%로 인공지능 기술이나 인공지능 윤리에 대한 직무를 수행한 경력이 비교적 많지 않은 것은 인공지능 기술이 신기술에 해당하여, 인공지능 윤리 역시 학문적으로나 사회적으로 아직 성숙하지 않은 분야인 것으로 보인다.

인공지능 윤리 분야는 2016년 이후부터 국내외에서 많은 관심을 끌게 되었기 때문에 인공지능 윤리 분야 전문가가 매우 적다. 인공지능 윤리와 관련해서는 법률적인 문제, 사회적인 문제, 기술적인 문제, 도덕적인 문제 등 사회 전반에 미치는 영향이 크기 때문에 다양한 학문, 기술, 교육 전문가가 참여할 수 있도록 하였다. [표 4-19]는 설문조사에 참여한 직업(직무)별로 참여 비율과 경력, 평균연령에 대한 특성을 분석 결과에 의하면 인공지능 기술이 최근에 급속하게 발전하면서 산업과 교육, 일반인에게 활용되고 있기 때문에 경력 기간이 5.5년으로 비교적 짧으며, 평균 연령 또한 44.1년으로 분석되었다.

[표 4-19] 직업 (직무)별 경력 및 평균연령 분석 결과

| 직업(직무)       | 인원수 | 인원 비율 | 경력 기간(년) | 평균 연령(년) |
|--------------|-----|-------|----------|----------|
| AI 윤리 전문가    | 22  | 13.4% | 4.4      | 44.8     |
| AI 관련 법률가    | 9   | 5.5%  | 4.6      | 48.7     |
| 사회학자         | 5   | 3.0%  | 12.3     | 54.2     |
| AI 교육자       | 19  | 11.6% | 4.7      | 43.3     |
| AI 설계자(컨설턴트) | 24  | 14.6% | 4.8      | 42.2     |
| AI 개발자       | 16  | 9.8%  | 4.9      | 36.8     |
| AI 제작자       | 12  | 7.3%  | 4.5      | 49.9     |
| AI 운영(도입)자   | 14  | 8.5%  | 4.6      | 44.8     |
| AI 윤리 교육자    | 8   | 4.9%  | 4.3      | 43.5     |
| 윤리 교육자       | 5   | 3.0%  | 3.9      | 43.6     |
| 일반 SW 종사자    | 18  | 11.0% | 8.8      | 41.2     |
| AI 사용 일반인    | 12  | 7.3%  | 4.7      | 36.7     |
| 합계           | 164 | 100%  | 5.5      | 44.1     |

## 2. 기술 통계량 분석

인공지능 윤리 측정지표와 신뢰성 간의 기술통계량 분석 결과는 [표 4-20]과 같이 산출되었다. 분석에 적용된 표본 90개 항목 전체가 모두 유효하게 사용되었다. 기술 통계량 분석 결과는 최솟값이 1이며, 최댓값은 5로 산출되었다. 평균 3.0 이하는 4개 항목이었으며, 평균 3.0 이상은 86개 항목으로 산출되었다.

[표 4-20] 기술통계량분석 결과

| 독립변수 | 종속변수 | 분석 수 | 최솟값 | 최댓값 | 평균   | 표준편차  |
|------|------|------|-----|-----|------|-------|
| 통제성  | A-01 | 164  | 1   | 5   | 4.18 | .867  |
|      | A-02 | 164  | 1   | 5   | 4.14 | .906  |
|      | A-03 | 164  | 2   | 5   | 4.25 | .802  |
|      | A-04 | 164  | 1   | 5   | 4.18 | .823  |
|      | A-05 | 164  | 2   | 5   | 4.26 | .748  |
|      | A-06 | 164  | 1   | 5   | 4.32 | .767  |
|      | A-07 | 164  | 1   | 5   | 4.04 | .993  |
|      | A-08 | 164  | 1   | 5   | 2.84 | 1.070 |
|      | A-09 | 164  | 1   | 5   | 2.93 | 1.069 |
|      | A-10 | 164  | 2   | 5   | 4.29 | .843  |
|      | A-11 | 164  | 2   | 5   | 4.13 | .815  |
|      | A-12 | 164  | 1   | 5   | 4.24 | .798  |
| 안전성  | B-01 | 164  | 1   | 5   | 4.40 | .826  |
|      | B-02 | 164  | 2   | 5   | 4.34 | .722  |
|      | B-03 | 164  | 2   | 5   | 4.30 | .649  |
|      | B-04 | 164  | 1   | 5   | 4.28 | .803  |
|      | B-05 | 164  | 2   | 5   | 4.42 | .655  |
|      | B-06 | 164  | 2   | 5   | 4.29 | .700  |
|      | B-07 | 164  | 1   | 5   | 4.26 | .764  |
|      | B-08 | 164  | 2   | 5   | 4.33 | .736  |
|      | B-09 | 164  | 2   | 5   | 4.36 | .734  |
|      | B-10 | 164  | 2   | 5   | 4.41 | .635  |
|      | B-11 | 164  | 2   | 5   | 4.38 | .667  |
|      | B-12 | 164  | 3   | 5   | 4.41 | .663  |

|     |      |     |   |   |      |      |
|-----|------|-----|---|---|------|------|
| 투명성 | C-01 | 164 | 1 | 5 | 4.37 | .719 |
|     | C-02 | 164 | 2 | 5 | 4.40 | .679 |
|     | C-03 | 164 | 1 | 5 | 4.38 | .704 |
|     | C-04 | 164 | 2 | 5 | 4.41 | .699 |
|     | C-05 | 164 | 2 | 5 | 4.38 | .668 |
|     | C-06 | 164 | 2 | 5 | 4.47 | .640 |
|     | C-07 | 164 | 2 | 5 | 4.43 | .736 |
|     | C-08 | 164 | 2 | 5 | 4.40 | .661 |
|     | C-09 | 164 | 1 | 5 | 4.28 | .748 |
|     | C-10 | 164 | 1 | 5 | 4.27 | .786 |
| 공정성 | D-01 | 164 | 2 | 5 | 4.43 | .675 |
|     | D-02 | 164 | 2 | 5 | 4.32 | .781 |
|     | D-03 | 164 | 3 | 5 | 4.44 | .657 |
|     | D-04 | 164 | 2 | 5 | 4.49 | .641 |
|     | D-05 | 164 | 1 | 5 | 4.28 | .697 |
|     | D-06 | 164 | 1 | 5 | 4.33 | .784 |
|     | D-07 | 164 | 1 | 5 | 4.30 | .852 |
|     | D-08 | 164 | 2 | 5 | 4.32 | .709 |
|     | D-09 | 164 | 3 | 5 | 4.32 | .653 |
|     | D-10 | 164 | 2 | 5 | 4.35 | .689 |
|     | D-11 | 164 | 2 | 5 | 4.36 | .700 |
|     | D-12 | 164 | 2 | 5 | 4.37 | .751 |
|     | D-13 | 164 | 1 | 5 | 4.32 | .767 |
|     | D-14 | 164 | 2 | 5 | 4.38 | .754 |
|     | D-15 | 164 | 3 | 5 | 4.47 | .591 |
|     | D-16 | 164 | 2 | 5 | 4.46 | .668 |
|     | D-17 | 164 | 3 | 5 | 4.57 | .577 |
|     | D-18 | 164 | 2 | 5 | 4.43 | .693 |
|     | D-19 | 164 | 2 | 5 | 4.48 | .713 |
|     | D-20 | 164 | 2 | 5 | 4.59 | .672 |
|     | D-21 | 164 | 2 | 5 | 4.58 | .636 |
|     | D-22 | 164 | 3 | 5 | 4.55 | .630 |
|     | D-23 | 164 | 2 | 5 | 4.55 | .649 |
|     | D-24 | 164 | 2 | 5 | 4.47 | .611 |

|       |      |     |   |   |      |      |
|-------|------|-----|---|---|------|------|
| 보안성   | E-01 | 164 | 2 | 5 | 4.50 | .755 |
|       | E-02 | 164 | 2 | 5 | 4.63 | .577 |
|       | E-03 | 164 | 2 | 5 | 4.48 | .687 |
|       | E-04 | 164 | 3 | 5 | 4.57 | .565 |
|       | E-05 | 164 | 2 | 5 | 4.54 | .677 |
|       | E-06 | 164 | 3 | 5 | 4.53 | .650 |
|       | E-07 | 164 | 2 | 5 | 4.38 | .720 |
|       | E-08 | 164 | 2 | 5 | 4.51 | .631 |
|       | E-09 | 164 | 3 | 5 | 4.54 | .620 |
|       | E-10 | 164 | 2 | 5 | 4.65 | .562 |
|       | E-11 | 164 | 3 | 5 | 4.56 | .578 |
|       | E-12 | 164 | 2 | 5 | 4.48 | .650 |
|       | E-13 | 164 | 1 | 5 | 4.42 | .814 |
| 사회적영향 | F-01 | 164 | 1 | 5 | 2.95 | .816 |
|       | F-02 | 164 | 1 | 5 | 2.96 | .949 |
|       | F-03 | 164 | 3 | 5 | 4.55 | .589 |
|       | F-04 | 164 | 2 | 5 | 4.62 | .569 |
|       | F-05 | 164 | 2 | 5 | 4.49 | .591 |
|       | F-06 | 164 | 2 | 5 | 4.40 | .653 |
|       | F-07 | 164 | 3 | 5 | 4.61 | .548 |
|       | F-08 | 164 | 2 | 5 | 4.44 | .676 |
|       | F-09 | 164 | 2 | 5 | 4.56 | .638 |
|       | F-10 | 164 | 2 | 5 | 4.45 | .658 |
| 책무성   | G-01 | 164 | 1 | 5 | 4.42 | .775 |
|       | G-02 | 164 | 2 | 5 | 4.39 | .722 |
|       | G-03 | 164 | 2 | 5 | 4.42 | .700 |
|       | G-04 | 164 | 2 | 5 | 4.29 | .672 |
|       | G-05 | 164 | 2 | 5 | 4.38 | .686 |
|       | G-06 | 164 | 2 | 5 | 4.55 | .648 |
|       | G-07 | 164 | 2 | 5 | 4.45 | .737 |
|       | G-08 | 164 | 1 | 5 | 4.38 | .771 |
|       | G-09 | 164 | 2 | 5 | 4.26 | .772 |

### 3. 타당성 검증

윤리 측정지표의 타당도를 분석하기 위하여 개념 타당도(Construct Validity)를 적용하였다. 타당도(Validity)는 내용 타당도, 개념 타당도, 기준 타당도로 구분하는데 개념 타당도는 연구자가 측정하고자 하는 추상적인 개념이 측정도구에 의하여 얼마나 적절하게 측정되었는지에 대한 사항을 분석하기 위하여 이론 연구 시 매우 중요하게 사용된다(채서일, 1998). 개념 타당도를 평가하기 위하여 요인분석 방법을 적용하였는데 이는 상이한 개념들의 측정항목을 개발 후 수집된 데이터가 동일한 요인으로 그룹을 형성하는지를 평가하는 방법이다. 따라서 측정 항목들 간의 상관관계가 높은 항목끼리 하나의 요인으로 형성하여 요인들 간에 상호 독립성을 유지할 수 있도록 하는 것이다. 하나의 요인으로 형성된 항목들은 동일한 개념을 측정하는 것으로 정할 수 있으며, 요인들 간에는 상호 상관관계가 없는 것으로 전제되기 때문에 각 요인은 상이한 개념이라고 판단할 수 있다(송지준, 2010). 즉, 본 연구에서는 통제성, 안전성, 투명성, 공정성, 보안성, 사회적영향, 책무성에 대한 요인을 적용하여 연구에 사용하였다.

본 연구에서는 개념 타당도 검증을 요인분석 방법으로 하였으며, 선행으로 전체 모형의 유의성을 KMO(Kaiser-Meyer-Olkin) 값과 Bartlett의 검증으로 실시하였다. 본 연구의 요인분석에 이용된 표본은 [표 4-21]과 같이 KMO 값과 Bartlett의 검증한 결과로서 KMO 값이 0.914로서 매우 높은 수준으로 나타났으며, Bartlett 값이 유의수준 0.000에서 유의한 것으로 나타나 요인분석의 적합성이 검증되었다고 볼 수 있다.

[표 4-21] KMO와 Bartlett의 검증 결과

|                                 |         |          |
|---------------------------------|---------|----------|
| 표준형성 적절성의 Kaiser-Meyer-Olkin 측도 |         | 0.914    |
| Bartlett의 구형성 검증                | 근사 카이제곱 | 5816.421 |
|                                 | 자유도     | 1061     |
|                                 | 유의확률    | 0.000    |

KMO 값이 1에 근접 할수록 상관관계가 좋다는 것을 의미하며, Bartlett의 검증 값이 유의수준 0.05 미만이면 적합하다는 것을 의미한다(송지준, 2010).

요인분석은 SPSS에서 탐색적 요인분석을 실시하였으며, 요인분석에서 요인 적재치 변수들의 수치가 낮을 수록 중요도가 낮다는 것을 의미한다. 보편적으로 사회과학 분야에서 선택 기준은 요인과 문항의 고윳값(Eigen Value)이 1.0 이상, 요인 적재치는 0.40 이상인 경우 유의한 변수로 간주하고 0.50이 넘으면 매우 중요한 변수로 본다고 제시하였다(송지준, 2010). 따라서 본 연구에서는 보편적인 기준에 따라 고윳값이 1.0 이상과 요인 적재치는 0.40 이상을 기준으로 하였다. 또한 본 연구에서는 공통성의 값이 0.40 미만인 경우 요인을 설명하는 항목의 설득력이 미흡하다고 판단하여 이를 제거하여 내용적으로 타당도를 확보하였다. 그 결과 총 90개 종속변수 중 4개 변수가 이론 구조에 맞지 않게 적재되었으며, 4개 변수는 제거하였다. 따라서 최종적으로 통제성의 10개 변수, 안전성의 12개 변수, 투명성의 10개 변수, 공정성의 24개 변수, 보안성의 13개 변수, 사회적영향의 8개 변수, 책무성의 9개 변수 총 86개 변수가 관계성에 적용되었다. 탐색적 요인분석 결과는 [표 4-22]와 같이 나타났다.

[표 4-22] 탐색적 요인분석 결과

| 독립변수 | 종속변수 코드 | 요인적재량 | 공통성  | 고윳값   | 분산 설명력 |
|------|---------|-------|------|-------|--------|
| 통제성  | A-01    | .787  | .786 | 4.138 | 11.824 |
|      | A-02    | .727  | .713 |       |        |
|      | A-03    | .713  | .712 |       |        |
|      | A-04    | .712  | .678 |       |        |
|      | A-05    | .678  | .655 |       |        |
|      | A-06    | .655  | .651 |       |        |
|      | A-07    | .651  | .642 |       |        |
|      | A-10    | .528  | .780 |       |        |
|      | A-11    | .522  | .735 |       |        |
|      | A-12    | .501  | .628 |       |        |

|     |      |      |      |       |        |
|-----|------|------|------|-------|--------|
| 안전성 | B-01 | .799 | .713 | 2.801 | 8.002  |
|     | B-02 | .763 | .712 |       |        |
|     | B-03 | .748 | .678 |       |        |
|     | B-04 | .733 | .655 |       |        |
|     | B-05 | .730 | .697 |       |        |
|     | B-06 | .727 | .780 |       |        |
|     | B-07 | .713 | .735 |       |        |
|     | B-08 | .712 | .628 |       |        |
|     | B-09 | .674 | .642 |       |        |
|     | B-10 | .667 | .533 |       |        |
|     | B-11 | .642 | .528 |       |        |
|     | B-12 | .533 | .533 |       |        |
| 투명성 | C-01 | .727 | .713 | 4.079 | 13.099 |
|     | C-02 | .713 | .712 |       |        |
|     | C-03 | .712 | .678 |       |        |
|     | C-04 | .678 | .655 |       |        |
|     | C-05 | .655 | .651 |       |        |
|     | C-06 | .651 | .642 |       |        |
|     | C-07 | .642 | .786 |       |        |
|     | C-08 | .533 | .697 |       |        |
|     | C-09 | .528 | .780 |       |        |
|     | C-10 | .511 | .611 |       |        |
| 공정성 | D-01 | .835 | .817 | 4.909 | 14.025 |
|     | D-02 | .800 | .761 |       |        |
|     | D-03 | .798 | .758 |       |        |
|     | D-04 | .797 | .804 |       |        |
|     | D-05 | .796 | .811 |       |        |
|     | D-06 | .799 | .802 |       |        |
|     | D-07 | .763 | .721 |       |        |
|     | D-08 | .748 | .689 |       |        |
|     | D-09 | .733 | .692 |       |        |
|     | D-10 | .730 | .772 |       |        |
|     | D-11 | .727 | .780 |       |        |
|     | D-12 | .713 | .735 |       |        |
|     | D-13 | .712 | .628 |       |        |
|     | D-14 | .674 | .642 |       |        |
|     | D-15 | .667 | .533 |       |        |
|     | D-16 | .642 | .528 |       |        |

|       |      |      |      |       |        |
|-------|------|------|------|-------|--------|
|       | D-17 | .573 | .697 |       |        |
|       | D-18 | .568 | .780 |       |        |
|       | D-19 | .551 | .611 |       |        |
|       | D-20 | .543 | .697 |       |        |
|       | D-21 | .528 | .780 |       |        |
|       | D-22 | .511 | .611 |       |        |
|       | D-23 | .428 | .780 |       |        |
|       | D-24 | .411 | .611 |       |        |
| 보안성   | E-01 | .763 | .721 | 4.079 | 13.099 |
|       | E-02 | .748 | .689 |       |        |
|       | E-03 | .733 | .692 |       |        |
|       | E-04 | .730 | .772 |       |        |
|       | E-05 | .727 | .780 |       |        |
|       | E-06 | .713 | .735 |       |        |
|       | E-07 | .712 | .628 |       |        |
|       | E-08 | .674 | .642 |       |        |
|       | E-09 | .667 | .533 |       |        |
|       | E-10 | .642 | .528 |       |        |
|       | E-11 | .573 | .697 |       |        |
|       | E-12 | .568 | .780 |       |        |
|       | E-13 | .428 | .780 |       |        |
| 사회적영향 | F-03 | .748 | .689 | 4.138 | 11.824 |
|       | F-04 | .733 | .692 |       |        |
|       | F-05 | .730 | .772 |       |        |
|       | F-06 | .727 | .780 |       |        |
|       | F-07 | .713 | .735 |       |        |
|       | F-08 | .712 | .628 |       |        |
|       | F-09 | .674 | .642 |       |        |
|       | F-10 | .667 | .533 |       |        |
| 책무성   | G-01 | .763 | .712 | 4.909 | 14.025 |
|       | G-02 | .748 | .678 |       |        |
|       | G-03 | .733 | .655 |       |        |
|       | G-04 | .730 | .697 |       |        |
|       | G-05 | .727 | .780 |       |        |
|       | G-06 | .713 | .735 |       |        |
|       | G-07 | .712 | .628 |       |        |
|       | G-08 | .674 | .642 |       |        |
|       | G-09 | .667 | .533 |       |        |

#### 4. 신뢰도 분석

측정 대상의 신뢰도(Reliability)는 어떤 검사나 측정도구가 검사 실시 방법, 질문 항목, 형식, 시간, 평가자와 관계없이 일관성이 있어야 하고, 믿을 수 있는 안정적인 측정 결과를 산출해 낼 수 있는 정도를 말하며, 측정의 안정성(Stability)과 정확성(Accuracy), 일관성(Consistency), 예측 가능성(Predictability)등의 개념이 포함되어야 하고 타당성 분석을 통해 추출된 요인들의 동질적인 변수가 제대로 구성되어 있는지를 확인하는 데 사용하는 방법이다(Thorndike, 1988). 신뢰도의 검증 방법은 크게 재검사 신뢰도(Test-retest Reliability)와 동형검사 신뢰도(Parallel-form Reliability), 내적일관성 신뢰도(Internal Consistency Reliability)로 구분된다. 그중 내적일관성 신뢰도(Internal Consistency Reliability)는 검사를 방법을 두 번 실시하지 않고 신뢰도를 추정할 수 있으며, 문항 내적 일관성 신뢰도와 반분 검사 신뢰도로 나누어지고 문항 내적 일관성 신뢰도는 문항 간의 측정에 대한 일관성에 의하여 추정하는 방법으로써 Cronbach  $\alpha$ , Hoyt 신뢰도, KR-20가 있다(성태제, 2019). 보편적으로 사회과학 연구에서는 Cronbach  $\alpha$ 가 신뢰도 추정에 많이 사용되는데 그 이유는 연속적으로 점수가 부여되는 문항과 이분 문항들의 신뢰도 추정이 가능하고, 신뢰도 계산 공식의 유도과정과 개념이 간단하게 되어 있기 때문이다(성태제, 2019).

본 연구에서는 사용된 측정변수들의 신뢰도 분석을 위하여 변수들의 문항 내적 일관성을 나타내는 크론바흐 알파계수(Cronbach  $\alpha$ )를 [표 4-23]과 같이 구하였으며 Cronbach  $\alpha$ 는 동일한 개념의 측정을 위해 다수의 항목을 이용할 경우 신뢰도를 저해하는 항목을 도출하여 측정도구에서 제외함으로써 측정도구의 신뢰도를 높이는 방법이다. 일반적으로 사회과학 분야에서는 Cronbach  $\alpha$ 가 0.6 이상이면 신뢰도가 있다고 보았다(송지준, 2010). 따라서 본 연구에서는 Cronbach  $\alpha$ 에 의하여 신뢰도분석을 실시하였고, 그 결과 모든 서비스 변수들의 신뢰도 계수가 0.8 이상의 높은 신뢰계수를 보임으로써 측정항목의 신뢰도에는 별문제가 없는 것으로 나타났다.

[표 4-23] 신뢰도 분석 결과

| 독립변수 | 종속변수 | 항목 수 | 항목이 삭제된 경우<br>Cronbach 알파 | Cronbach의<br>알파 |
|------|------|------|---------------------------|-----------------|
| 통제성  | A-01 | 12   | .645                      | 0.655           |
|      | A-02 |      | .623                      |                 |
|      | A-03 |      | .626                      |                 |
|      | A-04 |      | .602                      |                 |
|      | A-05 |      | .608                      |                 |
|      | A-06 |      | .609                      |                 |
|      | A-07 |      | .637                      |                 |
|      | A-08 |      | .717                      |                 |
|      | A-09 |      | .678                      |                 |
|      | A-10 |      | .624                      |                 |
|      | A-11 |      | .624                      |                 |
|      | A-12 |      | .614                      |                 |
| 안전성  | B-01 | 12   | .847                      | 0.856           |
|      | B-02 |      | .839                      |                 |
|      | B-03 |      | .843                      |                 |
|      | B-04 |      | .852                      |                 |
|      | B-05 |      | .848                      |                 |
|      | B-06 |      | .848                      |                 |
|      | B-07 |      | .837                      |                 |
|      | B-08 |      | .842                      |                 |
|      | B-09 |      | .839                      |                 |
|      | B-10 |      | .847                      |                 |
|      | B-11 |      | .851                      |                 |
|      | B-12 |      | .846                      |                 |

|     |      |    |      |       |
|-----|------|----|------|-------|
| 투명성 | C-01 | 10 | .841 | 0.864 |
|     | C-02 |    | .850 |       |
|     | C-03 |    | .851 |       |
|     | C-04 |    | .854 |       |
|     | C-05 |    | .857 |       |
|     | C-06 |    | .852 |       |
|     | C-07 |    | .851 |       |
|     | C-08 |    | .857 |       |
|     | C-09 |    | .851 |       |
|     | C-10 |    | .853 |       |
| 공정성 | D-01 | 24 | .894 | 0.895 |
|     | D-02 |    | .897 |       |
|     | D-03 |    | .893 |       |
|     | D-04 |    | .893 |       |
|     | D-05 |    | .892 |       |
|     | D-06 |    | .892 |       |
|     | D-07 |    | .893 |       |
|     | D-08 |    | .890 |       |
|     | D-09 |    | .892 |       |
|     | D-10 |    | .891 |       |
|     | D-11 |    | .890 |       |
|     | D-12 |    | .887 |       |
|     | D-13 |    | .889 |       |
|     | D-14 |    | .889 |       |
|     | D-15 |    | .890 |       |
|     | D-16 |    | .890 |       |
|     | D-17 |    | .892 |       |
|     | D-18 |    | .889 |       |
|     | D-19 |    | .892 |       |
|     | D-20 |    | .892 |       |
|     | D-21 |    | .891 |       |
|     | D-22 |    | .891 |       |
|     | D-23 |    | .894 |       |
|     | D-24 |    | .896 |       |

|       |      |    |      |       |
|-------|------|----|------|-------|
| 보안성   | E-01 | 13 | .865 | 0.872 |
|       | E-02 |    | .862 |       |
|       | E-03 |    | .864 |       |
|       | E-04 |    | .871 |       |
|       | E-05 |    | .853 |       |
|       | E-06 |    | .869 |       |
|       | E-07 |    | .863 |       |
|       | E-08 |    | .865 |       |
|       | E-09 |    | .862 |       |
|       | E-10 |    | .858 |       |
|       | E-11 |    | .858 |       |
|       | E-12 |    | .860 |       |
|       | E-13 |    | .870 |       |
| 사회영향성 | F-01 | 10 | .789 | 0.740 |
|       | F-02 |    | .785 |       |
|       | F-03 |    | .716 |       |
|       | F-04 |    | .702 |       |
|       | F-05 |    | .720 |       |
|       | F-06 |    | .680 |       |
|       | F-07 |    | .703 |       |
|       | F-08 |    | .688 |       |
|       | F-09 |    | .706 |       |
|       | F-10 |    | .689 |       |
| 책무성   | G-01 | 9  | .883 | 0.887 |
|       | G-02 |    | .870 |       |
|       | G-03 |    | .877 |       |
|       | G-04 |    | .883 |       |
|       | G-05 |    | .870 |       |
|       | G-06 |    | .874 |       |
|       | G-07 |    | .863 |       |
|       | G-08 |    | .882 |       |
|       | G-09 |    | .872 |       |

## 5. 상관관계분석

상관관계(Correlation)란 측정 대상 변수 간의 관계로써 두 개 이상의 변수가 있어야 하고 한 변수가 변하면 다른 변수가 어떻게 변하는지에 대한 강도와 방향을 의미하며, 상관관계의 정도를 0에서  $\pm 1$  사이로 나타내고  $\pm 1$ 에 가까울수록 상관관계는 높아지고 0에 근접 할수록 상관관계가 낮아진다. 변화의 강도는 절대값이 1에 근접 할수록 높고, 변화의 방향으로 +는 정의 방향, -는 음의 방향이라 한다. 상관관계분석으로 산출된 상관계수 판단 기준은  $\pm 0.9$  이상인 경우 매우 높은 상관관계라 하며,  $\pm 0.7 \sim \pm 0.9$  미만인 경우는 높은 상관관계,  $\pm 0.4 \sim \pm 0.7$  미만인 경우 다소 높은 상관관계,  $\pm 0.2 \sim \pm 0.4$  미만인 경우 낮은 상관관계,  $\pm 0.2$  미만이면 상관관계가 거의 없다고 하였다(송지준, 2010).

본 연구에서 인공지능 윤리원칙 구성요소를 기반으로 최종 개발된 윤리 측정지표 90개 항목과 신뢰성 간에 어느 정도 상관관계를 보여주고 있는지 검증하였다. 신뢰성을 7개의 독립변수로 구성하였고, 윤리 측정지표를 종속변수로 설계하여 변수들 간의 관련성을 분석, 검증하였다. 먼저 인공지능 윤리 측정지표 변수와 신뢰성 변수 중 통제성에 관련된 변수 간의 상관관계분석 결과는 [표 4-24]과 같이 분석되었다. 통제성에 포함된 측정지표 변수의 상관관계분석 결과 12개 변수 중 10개의 변수가 상관계수 0.401~0.676으로 다소 높은 상관관계로 분석되었으며, 정책적 통제권 이양(A-08)과 이용자 제어장치 제공(A-09)은 0.023~0.181로 2개의 변수는 상관관계가 거의 없는 것으로 분석되었다.

인공지능 윤리 측정지표 변수와 신뢰성 변수 중 안전성에 관련된 변수 간의 상관관계분석 결과는 [표 4-25]와 같이 분석되었다. 안전성에 포함된 측정지표 변수의 상관관계분석 결과 12개 변수 모두가 상관계수 0.414~0.682로 다소 높은 상관관계로 분석되었다. 따라서 안전성과 관련된 인공지능 윤리 측정지표는 신뢰성 변수와 관련성이 다소 높게 분석된 것을 알 수 있다. 또한, 인공지능 윤리 측정지표 변수와

[표 4-24] 통제성 상관관계분석 결과

| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |      |      |       |       |    |
|----------|------|----------|--------------------------------------------|-------|-------|-------|-------|-------|-------|------|------|-------|-------|----|
|          |      |          | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8    | 9    | 10    | 11    | 12 |
| A-01     | 4.18 | .867     | 1                                          |       |       |       |       |       |       |      |      |       |       |    |
| A-02     | 4.14 | .906     | .554*                                      | 1     |       |       |       |       |       |      |      |       |       |    |
| A-03     | 4.25 | .802     | .479*                                      | .649* | 1     |       |       |       |       |      |      |       |       |    |
| A-04     | 4.18 | .823     | .589*                                      | .545* | .585* | 1     |       |       |       |      |      |       |       |    |
| A-05     | 4.26 | .748     | .401*                                      | .474* | .422* | .464* | 1     |       |       |      |      |       |       |    |
| A-06     | 4.32 | .767     | .669*                                      | .459* | .445* | .605* | .516* | 1     |       |      |      |       |       |    |
| A-07     | 4.04 | .993     | .476*                                      | .468* | .576* | .586* | .523* | .676* | 1     |      |      |       |       |    |
| A-08     | 2.84 | 1.070    | .071                                       | .027  | .024  | .027  | .181* | .059  | .027  | 1    |      |       |       |    |
| A-09     | 2.93 | 1.069    | .023                                       | .042  | .155  | .075  | .057  | .027  | .073  | .031 | 1    |       |       |    |
| A-10     | 4.29 | .843     | .447*                                      | .527* | .579* | .477* | .402* | .549* | .560* | .042 | .011 | 1     |       |    |
| A-11     | 4.13 | .815     | .556*                                      | .459* | .445* | .605* | .422* | .464* | .649* | .132 | .053 | .516* | 1     |    |
| A-12     | 4.24 | .798     | .459*                                      | .445* | .605* | .476* | .468* | .401* | .459* | .018 | .027 | .564* | .521* | 1  |

\* 상관계수는 0.01 수준(양쪽)에서 유의

[표 4-25] 안전성 상관관계분석 결과

| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |       |       |       |    |
|----------|------|----------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----|
|          |      |          | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8     | 9     | 10    | 11    | 12 |
| B-01     | 4.40 | .826     | 1                                          |       |       |       |       |       |       |       |       |       |       |    |
| B-02     | 4.34 | .722     | .661*                                      | 1     |       |       |       |       |       |       |       |       |       |    |
| B-03     | 4.30 | .649     | .568*                                      | .583* | 1     |       |       |       |       |       |       |       |       |    |
| B-04     | 4.28 | .803     | .512*                                      | .531* | .400* | 1     |       |       |       |       |       |       |       |    |
| B-05     | 4.42 | .655     | .477*                                      | .452* | .530* | .599* | 1     |       |       |       |       |       |       |    |
| B-06     | 4.29 | .700     | .438*                                      | .623* | .629* | .479* | .598* | 1     |       |       |       |       |       |    |
| B-07     | 4.26 | .764     | .431*                                      | .530* | .511* | .642* | .657* | .521* | 1     |       |       |       |       |    |
| B-08     | 4.33 | .736     | .480*                                      | .527* | .495* | .427* | .545* | .560* | .484* | 1     |       |       |       |    |
| B-09     | 4.36 | .734     | .550*                                      | .527* | .409* | .565* | .414* | .519* | .647* | .682* | 1     |       |       |    |
| B-10     | 4.41 | .635     | .521*                                      | .456* | .566* | .595* | .592* | .540* | .627* | .501* | .647* | 1     |       |    |
| B-11     | 4.38 | .667     | .450*                                      | .465* | .442* | .499* | .509* | .474* | .618* | .582* | .647* | .418* | 1     |    |
| B-12     | 4.41 | .663     | .419*                                      | .458* | .536* | .556* | .465* | .483* | .625* | .589* | .677* | .503* | .625* | 1  |

신뢰성 변수 중 투명성에 관련된 변수 간의 상관관계분석 결과는 [표 4-26]과 같이 분석되었다. 투명성에 포함된 측정지표 변수의 상관관계분석 결과 10개 변수 모두 상관계수 0.450~0.788로 다소 높거나 높은 상관관계로 분석되었다.

[표 4-26] 투명성 상관관계분석 결과

| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |       |    |
|----------|------|----------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|-------|----|
|          |      |          | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8     | 9     | 10 |
| C-01     | 4.37 | .719     | 1                                          |       |       |       |       |       |       |       |       |    |
| C-02     | 4.40 | .679     | .562*                                      | 1     |       |       |       |       |       |       |       |    |
| C-03     | 4.38 | .704     | .467*                                      | .688* | 1     |       |       |       |       |       |       |    |
| C-04     | 4.41 | .699     | .504*                                      | .619* | .652* | 1     |       |       |       |       |       |    |
| C-05     | 4.38 | .668     | .516*                                      | .579* | .562* | .476* | 1     |       |       |       |       |    |
| C-06     | 4.47 | .640     | .524*                                      | .788* | .655* | .450* | .550* | 1     |       |       |       |    |
| C-07     | 4.43 | .736     | .494*                                      | .493* | .659* | .558* | .596* | .599* | 1     |       |       |    |
| C-08     | 4.40 | .661     | .489*                                      | .617* | .471* | .671* | .661* | .540* | .514* | 1     |       |    |
| C-09     | 4.28 | .748     | .501*                                      | .459* | .470* | .613* | .599* | .513* | .647* | .570* | 1     |    |
| C-10     | 4.27 | .786     | .470*                                      | .570* | .585* | .631* | .682* | .489* | .587* | .639* | .628* | 1  |

인공지능 윤리 측정지표 변수와 신뢰성 변수 중 공정성에 관련된 변수 간의 상관관계분석 결과는 [표 4-27]과 같이 분석되었다. 공정성과 윤리 측정지표 변수의 상관관계분석 결과 24개 변수 모두가 상관계수 0.403~0.797로 다소 높은 상관관계로 분석되었다. 따라서 공정성과 관련된 인공지능 윤리 측정지표는 신뢰성 변수와 관련성이 다소 높게 분석된 것을 알 수 있다. 인공지능 윤리 측정지표 변수와 신뢰성 변수 중 보안성과 관련된 변수 간의 상관관계분석 결과는 [표 4-28]과 같이 분석되었다. 보안성과 관련된 윤리 측정지표 변수의 상관관계분석 결과 13개 변수 모두가 상관계수 0.510~0.896으로 다소 높거나 높은 상관관계로 분석되었다.

[표 4-27] 공정성 상관관계분석 결과

| 측정 지표 | 평균   | 표준 편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |       |       |       |       |
|-------|------|-------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
|       |      |       | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8     | 9     | 10    | 11    | 12    |
| D-01  | 4.43 | .675  | 1                                          |       |       |       |       |       |       |       |       |       |       |       |
| D-02  | 4.32 | .781  | .403*                                      | 1     |       |       |       |       |       |       |       |       |       |       |
| D-03  | 4.44 | .657  | .440*                                      | .408* | 1     |       |       |       |       |       |       |       |       |       |
| D-04  | 4.49 | .641  | .495*                                      | .412* | .529* | 1     |       |       |       |       |       |       |       |       |
| D-05  | 4.28 | .697  | .416*                                      | .475* | .599* | .647* | 1     |       |       |       |       |       |       |       |
| D-06  | 4.33 | .784  | .567*                                      | .559* | .454* | .685* | .623* | 1     |       |       |       |       |       |       |
| D-07  | 4.30 | .852  | .458*                                      | .419* | .403* | .567* | .764* | .537* | 1     |       |       |       |       |       |
| D-08  | 4.32 | .709  | .419*                                      | .558* | .534* | .595* | .687* | .726* | .578* | 1     |       |       |       |       |
| D-09  | 4.32 | .653  | .574*                                      | .647* | .517* | .510* | .662* | .478* | .680* | .573* | 1     |       |       |       |
| D-10  | 4.35 | .689  | .557*                                      | .478* | .497* | .513* | .678* | .762* | .605* | .480* | .526* | 1     |       |       |
| D-11  | 4.36 | .700  | .501*                                      | .472* | .662* | .585* | .771* | .686* | .589* | .419* | .699* | .658* | 1     |       |
| D-12  | 4.37 | .751  | .482*                                      | .442* | .419* | .559* | .711* | .715* | .679* | .491* | .775* | .712* | .542* | 1     |
| D-13  | 4.32 | .767  | .585*                                      | .566* | .404* | .535* | .646* | .742* | .699* | .461* | .633* | .605* | .677* | .549* |
| D-14  | 4.38 | .754  | .495*                                      | .402* | .558* | .457* | .529* | .586* | .687* | .567* | .503* | .726* | .576* | .426* |
| D-15  | 4.47 | .591  | .495*                                      | .554* | .530* | .643* | .574* | .481* | .641* | .539* | .548* | .553* | .587* | .657* |
| D-16  | 4.46 | .668  | .430*                                      | .567* | .555* | .443* | .497* | .767* | .544* | .521* | .514* | .520* | .655* | .771* |
| D-17  | 4.57 | .577  | .585*                                      | .787* | .681* | .407* | .421* | .636* | .640* | .484* | .553* | .533* | .536* | .611* |
| D-18  | 4.43 | .693  | .461*                                      | .540* | .513* | .634* | .517* | .667* | .554* | .663* | .510* | .594* | .698* | .719* |
| D-19  | 4.48 | .713  | .518*                                      | .508* | .432* | .403* | .499* | .480* | .538* | .677* | .435  | .493* | .680* | .683* |
| D-20  | 4.59 | .672  | .495*                                      | .566* | .514* | .543* | .428* | .743* | .586* | .463* | .471* | .687* | .588* | .637* |
| D-21  | 4.58 | .636  | .598*                                      | .448* | .507* | .567* | .626* | .630* | .690* | .495* | .475* | .741* | .673* | .698* |
| D-22  | 4.55 | .630  | .532*                                      | .531* | .441* | .452* | .606* | .566* | .596* | .533* | .531* | .543* | .657* | .638* |
| D-23  | 4.55 | .649  | .571*                                      | .418* | .465* | .600* | .505* | .585* | .412* | .466* | .494* | .508* | .511* | .515* |
| D-24  | 4.47 | .611  | .484*                                      | .520* | .464* | .587* | .507* | .472* | .435* | .557* | .578* | .571* | .462* | .552* |

| 측정 지표 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |       |       |       |    |
|-------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----|
|       | 13                                         | 14    | 15    | 16    | 17    | 18    | 19    | 20    | 21    | 22    | 23    | 24 |
| D-13  | 1                                          |       |       |       |       |       |       |       |       |       |       |    |
| D-14  | .650*                                      | 1     |       |       |       |       |       |       |       |       |       |    |
| D-15  | .640*                                      | .495* | 1     |       |       |       |       |       |       |       |       |    |
| D-16  | .728*                                      | .674* | .632* | 1     |       |       |       |       |       |       |       |    |
| D-17  | .493*                                      | .651* | .630* | .742* | 1     |       |       |       |       |       |       |    |
| D-18  | .762*                                      | .760* | .785* | .718* | .688* | 1     |       |       |       |       |       |    |
| D-19  | .612*                                      | .762* | .755* | .665* | .739* | .699* | 1     |       |       |       |       |    |
| D-20  | .474*                                      | .558* | .639* | .696* | .716* | .756* | .605* | 1     |       |       |       |    |
| D-21  | .743*                                      | .621* | .715* | .727* | .603* | .797* | .690* | .599* | 1     |       |       |    |
| D-22  | .578*                                      | .697* | .626* | .690* | .620* | .549* | .754* | .645* | .673* | 1     |       |    |
| D-23  | .422*                                      | .588* | .600* | .681* | .545* | .655* | .555* | .675* | .714* | .730* | 1     |    |
| D-24  | .512*                                      | .445* | .652* | .592* | .597* | .598* | .545* | .676* | .622* | .551* | .528* | 1  |

[표 4-28] 보안성 상관계분 분석 결과

| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |       |       |       |       |    |
|----------|------|----------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----|
|          |      |          | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8     | 9     | 10    | 11    | 12    | 13 |
| E-01     | 4.50 | .755     | 1                                          |       |       |       |       |       |       |       |       |       |       |       |    |
| E-02     | 4.63 | .577     | .731*                                      | 1     |       |       |       |       |       |       |       |       |       |       |    |
| E-03     | 4.48 | .687     | .802*                                      | .815* | 1     |       |       |       |       |       |       |       |       |       |    |
| E-04     | 4.57 | .565     | .645*                                      | .850* | .732* | 1     |       |       |       |       |       |       |       |       |    |
| E-05     | 4.54 | .677     | .868*                                      | .751* | .888* | .717* | 1     |       |       |       |       |       |       |       |    |
| E-06     | 4.53 | .650     | .694*                                      | .766* | .697* | .669* | .639* | 1     |       |       |       |       |       |       |    |
| E-07     | 4.38 | .720     | .526*                                      | .755* | .650* | .648* | .699* | .634* | 1     |       |       |       |       |       |    |
| E-08     | 4.51 | .631     | .519*                                      | .774* | .662* | .535* | .715* | .735* | .781* | 1     |       |       |       |       |    |
| E-09     | 4.54 | .620     | .582*                                      | .745* | .704* | .510* | .739* | .732* | .882* | .845* | 1     |       |       |       |    |
| E-10     | 4.65 | .562     | .676*                                      | .856* | .701* | .594* | .850* | .799* | .869* | .710* | .648* | 1     |       |       |    |
| E-11     | 4.56 | .578     | .623*                                      | .727* | .604* | .524* | .896* | .730* | .846* | .735* | .681* | .726* | 1     |       |    |
| E-12     | 4.48 | .650     | .562*                                      | .676* | .635* | .588* | .817* | .698* | .747* | .864* | .721* | .730* | .743* | 1     |    |
| E-13     | 4.42 | .814     | .864*                                      | .552* | .769* | .526* | .834* | .655* | .667* | .551* | .565* | .587* | .669* | .789* | 1  |

인공지능 윤리 측정지표 변수와 신뢰성 변수 중 사회적영향에 관련된 변수 간의 상관관계분석 결과는 [표 4-29]와 같이 분석되었다. 사회적영향에 포함된 측정지표 변수의 상관관계분석 결과 10개 변수 중 8개의 변수가 상관계수 0.440~0.777로 다소 높은 상관관계로 분석되었으며, 친환경 에너지 활용(F-01)과 폐기 제품 관리(F-02)는 0.011~0.193로 2개의 변수는 상관관계가 거의 없는 것으로 분석되었다.

[표 4-29] 사회적영향 상관계분 분석 결과

| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |      |       |       |       |       |       |       |       |    |
|----------|------|----------|--------------------------------------------|------|-------|-------|-------|-------|-------|-------|-------|----|
|          |      |          | 1                                          | 2    | 3     | 4     | 5     | 6     | 7     | 8     | 9     | 10 |
| F-01     | 2.95 | .816     | 1                                          |      |       |       |       |       |       |       |       |    |
| F-02     | 2.96 | .949     | .022                                       | 1    |       |       |       |       |       |       |       |    |
| F-03     | 4.55 | .589     | .025                                       | .041 | 1     |       |       |       |       |       |       |    |
| F-04     | 4.62 | .569     | .029                                       | .046 | .673* | 1     |       |       |       |       |       |    |
| F-05     | 4.49 | .591     | .065                                       | .035 | .587* | .633* | 1     |       |       |       |       |    |
| F-06     | 4.40 | .653     | .050                                       | .084 | .497* | .490* | .650* | 1     |       |       |       |    |
| F-07     | 4.61 | .548     | .193                                       | .159 | .629* | .672* | .777* | .705* | 1     |       |       |    |
| F-08     | 4.44 | .676     | .011                                       | .042 | .582* | .625* | .631* | .553* | .635* | 1     |       |    |
| F-09     | 4.56 | .638     | .037                                       | .021 | .535* | .524* | .506* | .493* | .647* | .527* | 1     |    |
| F-10     | 4.45 | .658     | .197                                       | .106 | .570* | .440* | .468* | .486* | .514* | .486* | .561* | 1  |

인공지능 윤리 측정지표 변수와 신뢰성 변수 중 책무성에 관련된 변수 간의 상관관계분석 결과는 [표 4-30]과 같이 분석되었다. 책무성에 포함된 측정지표 변수의 상관관계분석 결과 10개 변수 모두가 상관계수 0.532~0.928로 다소 높거나 매우 높은 상관관계로 분석되었다.

[표 4-30] 책무성 상관관계분석 결과


| 측정<br>지표 | 평균   | 표준<br>편차 | 구성개념 간 상관관계 (Inter-Construct Correlations) |       |       |       |       |       |       |       |   |
|----------|------|----------|--------------------------------------------|-------|-------|-------|-------|-------|-------|-------|---|
|          |      |          | 1                                          | 2     | 3     | 4     | 5     | 6     | 7     | 8     | 9 |
| G-01     | 4.42 | .775     | 1                                          |       |       |       |       |       |       |       |   |
| G-02     | 4.39 | .722     | .603*                                      | 1     |       |       |       |       |       |       |   |
| G-03     | 4.42 | .700     | .682*                                      | .786* | 1     |       |       |       |       |       |   |
| G-04     | 4.29 | .672     | .562*                                      | .549* | .772* | 1     |       |       |       |       |   |
| G-05     | 4.38 | .686     | .732*                                      | .825* | .891* | .825* | 1     |       |       |       |   |
| G-06     | 4.55 | .648     | .685*                                      | .652* | .655* | .734* | .711* | 1     |       |       |   |
| G-07     | 4.45 | .737     | .643*                                      | .928* | .862* | .834* | .842* | .846* | 1     |       |   |
| G-08     | 4.38 | .771     | .682*                                      | .690* | .840* | .660* | .543* | .532* | .675* | 1     |   |
| G-09     | 4.26 | .772     | .664*                                      | .801* | .655* | .661* | .684* | .723* | .850* | .601* | 1 |

인공지능 윤리 측정지표 변수와 신뢰성 변수 관계성을 분석한 결과 통제성 10개 변수에서 2개인 정책적 통제권 이양(A-08)과 이용자 제어장치 제공(A-09)이 관계성이 거의 없다고 분석되었으며, 안전성의 12개 변수, 투명성의 10개 변수, 공정성의 24개 변수, 보안성의 13개 변수, 책무성의 9개 변수는 관계성이 다소 높거나 높은 것으로 분석되었다. 마지막으로 사회적영향의 10개 변수 중 친환경 에너지 활용(F-01)과 폐기 제품 관리(F-02)의 2개 변수가 관계성이 거의 없는 것으로 분석되었다. 따라서 인공지능 윤리 측정지표 90개 변수 중 신뢰성 변수와 관련하여 86개 변수가 인공지능 윤리 측정지표와 관련성이 높은 것으로 분석되었으며, 4개 변수는 신뢰성 변수와 관련이 없는 것으로 분석되었다.

제 6 절 인공지능 윤리 측정지표에 대한 신뢰성 연구 결과

1. 신뢰성 검증이 완료된 인공지능 윤리 측정지표

본 연구에서 확장 개발된 인공지능 윤리 측정지표 50개 항목과 선행 연구된 윤리 측정지표 40개 항목을 통합하여 총 90개 항목의 윤리 측정지표에 대한 신뢰성 검증을 실시한 결과 최종적으로 86개 항목의 인공지능 윤리 측정지표가 개발되었다.



<그림 4-7> EMI-AI 항목 현황

최종적으로 개발된 윤리 측정지표는 신뢰성 검증이 완료되어 신뢰성이 확보되었다.

연구 결과 최종적으로 신뢰성이 확보된 인공지능 윤리 측정지표 86개 항목 현황은 <그림 4-7>과 같으며, 이후에는 신뢰성이 확보된 인공지능 윤리 측정지표를 EMI-AI(Ethical Measurement indicators of Artificial Intelligence)로 표기하여 사용하도록 한다.

[표 4-31]은 EMI-AI의 86개 항목이다. 윤리원칙 구성 요소별로 살펴보면 설명가능성에 7개 항목, 추적가능성에 5개 항목, 검증가능성에 5개 항목, 준법성에 9개 항목, 책임 식별성에 5개 항목, 알고리즘 차별성에 6개 항목, 데이터 편향성에 8개 항목, 접근성에 4개 항목, 공공성에 7개 항목, 제어 가능성에 3개 항목, 이용자 주도성에 5개 항목, 모니터링에 2개 항목, 견고성에 7개 항목, 보안성에 6개 항목, 프라이버시 보호에 7개 항목이다.

[표 4-31] EMI-AI 항목

| 윤리원칙 | 구성요소 (항목 수)    | 윤리 측정지표 항목           |
|------|----------------|----------------------|
| 투명성  | 설명가능성<br>( 7 ) | 최종 사용자를 위한 투명성       |
|      |                | 사고조사자를 위한 투명성        |
|      |                | 변호사 및 전문가 증인을 위한 투명성 |
|      |                | 이용 범위 고지 투명성         |
|      |                | 이용자 데이터 수집 투명성       |
|      |                | 안전 인증자를 위한 투명성       |
|      |                | 대중 및 이해관계자를 위한 투명성   |
|      | 추적가능성<br>( 5 ) | 문제 분석을 위한 데이터 제공     |
|      |                | 제작 과정의 기록 보관         |
|      |                | 사고 발생 이력 보관          |
|      |                | 상시 운영 감시             |
|      |                | 정기 운영 감사             |
|      | 검증가능성<br>( 5 ) | 안전성 시험기준 적용          |
|      |                | 알고리즘의 투명성 확보         |
|      |                | 학습용 데이터의 신뢰성         |
|      |                | 학습용 데이터의 충분성         |
|      |                | 시험, 인증 결과 제시         |

|     |                   |                    |
|-----|-------------------|--------------------|
| 책임성 | 준법성<br>( 9 )      | 법·제도 준수            |
|     |                   | 개인정보 제공 동의 획득      |
|     |                   | 데이터 사용 사전 허가 획득    |
|     |                   | 법적 근거 확보와 제시       |
|     |                   | 사용 설명서와 기능 일치성     |
|     |                   | 사용범위 법적 기준 준수 명문화  |
|     |                   | 이용자 안전 우선 준수       |
|     |                   | 신고자에 대한 법적 보호      |
|     |                   | 이용자 요구사항 대응        |
| 책임성 | 책임식별성<br>( 5 )    | 설계자 책임 식별          |
|     |                   | 제작자 책임 식별          |
|     |                   | 운영자 책임 식별          |
|     |                   | 이용자 책임 식별          |
|     |                   | 개발자 책임 식별          |
| 공정성 | 알고리즘 차별성<br>( 6 ) | 의도적 차별 요소 제한       |
|     |                   | 개인 편향적 차별 제한       |
|     |                   | 불공정한 알고리즘          |
|     |                   | 인간의 생명 위협 방지       |
|     |                   | 알고리즘의 의사결정 프로세스 제공 |
|     |                   | 차별적 불이익 방지         |
|     | 데이터 편향성<br>( 8 )  | 편향적 특성 제거          |
|     |                   | 데이터의 사실성           |
|     |                   | 학습용 데이터의 수량        |
|     |                   | 데이터의 유효성 검사        |
|     |                   | 학습용 데이터 품질관리       |
|     |                   | 데이터 편향 방지 알고리즘 적용  |
|     |                   | 데이터 분류 기준 정의 및 적용  |
|     |                   | 데이터 균일성 확보         |
|     | 접근성<br>( 4 )      | 접근성 보장             |
|     |                   | 보편적 사용자 지원         |
|     |                   | 사용자 접근 제한 방지       |
|     |                   | 이용자의 쉬운 접근성        |

|        |                   |                       |
|--------|-------------------|-----------------------|
|        | 공공성<br>( 7 )      | 공공데이터 수집 공지           |
|        |                   | 데이터 활용 제한             |
|        |                   | 개인정보 수집 제한            |
|        |                   | 사회환경에 미치는 영향 배제       |
|        |                   | 인간의 생명 위협 방지          |
|        |                   | 이해관계자의 의견 반영          |
|        |                   | 모든 인류에게 공정한 제공        |
| 통제성    | 제어 가능성<br>( 3 )   | 생명 위협 시 자동 종료         |
|        |                   | 운영자 통제 및 제어           |
|        |                   | 위험 발생 시 쉬운 접근성 제공     |
|        | 이용자 주도성<br>( 5 )  | 이용자 위험 회피             |
|        |                   | 자율적 조작                |
|        |                   | 이용자 데이터 선택적 제공        |
|        |                   | 이용자 데이터 삭제            |
|        |                   | 작동상태 제공               |
|        | 모니터링<br>( 2 )     | 위험 예측 상태 제공           |
|        |                   | 운영상태 상시 모니터링          |
| 안전성    | 견고성<br>( 7 )      | 인간의 생명 보호 우선          |
|        |                   | 알고리즘의 오류 관리           |
|        |                   | 외부 공격에 대한 견고성         |
|        |                   | 예측 결과의 동일성            |
|        |                   | 학습 데이터의 정확성(accuracy) |
|        |                   | 기능의 지속적 업그레이드 및 배포    |
|        |                   | 기능 프로세스의 정확한 정의       |
|        | 보안성<br>( 6 )      | 보안성 인증                |
|        |                   | 사용자 인증                |
|        |                   | 상호작용 데이터 보안           |
|        |                   | 비인가자 연결 방지            |
|        |                   | 알고리즘 시큐어 코딩           |
|        | 프라이버시 보호<br>( 7 ) | 이용 종료 시 정보 삭제         |
|        |                   | 개인정보보호 영향평가           |
|        |                   | 개인정보 수집 고지            |
|        |                   | 개인정보 가명화              |
|        |                   | 개인 민감정보 수집 차단         |
|        |                   | 개인정보 활용               |
|        |                   | 미동의 데이터 수집 방지         |
|        |                   | 데이터 주권 보장             |
| 총 항목 수 | 86 개              |                       |

## 2. EMI-AI와 ALTAI 간의 관계 검증

### 가. EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사

EMI-AI에 ALTAI의 평가목록을 신뢰성 변수로 정의한 기준을 바탕으로 매핑하여 ALTAI의 평가목록이 EMI-AI에 포함되어 있는지를 알아보기 위하여 전문가 델파이 설문조사를 실시하였다. EMI-AI의 항목과 ALTAI의 평가목록 간의 내용이 동일하거나 유사한 항목을 매핑하여 설문지를 작성하였다. 전문가를 대상으로 설문지를 배포하였으며, 일부는 직접 면접하면서 설문조사를 실시하였다. 델파이 설문조사에 참여 인원은 인공지능과 인공지능 윤리 관련 업무 종사자 16명이었으며, [표 4-32]는 델파이 설문조사에 참여한 전문가 현황이다.

[표 4-32] EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 참여자 현황

| 직업 (직무)      | 인원수       | 인원 비율(%)   | 평균 경력 (년)  |
|--------------|-----------|------------|------------|
| AI 윤리 전문가    | 4         | 25.0       | 4.9        |
| AI 관련 법률 전문가 | 2         | 12.5       | 5.5        |
| 사회학자         | 1         | 6.3        | 11.4       |
| AI 교육자       | 2         | 12.5       | 5.1        |
| AI 설계자       | 2         | 12.5       | 5.1        |
| AI 개발자       | 1         | 6.3        | 5.4        |
| AI 제작자       | 1         | 6.3        | 5.2        |
| AI 운영(도입)자   | 1         | 6.3        | 4.4        |
| AI 윤리 교육자    | 2         | 12.5       | 3.4        |
| <b>합 계</b>   | <b>16</b> | <b>100</b> | <b>5.6</b> |

델파이 설문조사에 참여한 전문가의 특징은 그동안 연구자가 인공지능 윤리를 연구하는 동안 전문가, 설문조사 참여자가 대부분이며 인공지능 윤리에 대한 이해도가 높은 편에 속한 전문가 그룹이다. 직무는 AI 윤리 전문가 4명, AI 관련 법률전문가 2명, 사회학자 1명, AI 교육자 2명, AI 설계 (컨설턴트 포함) 2명, AI 개발자 1명, AI

제작자 1명, AI 운영자 1명, AI 윤리 교육자 2명이 참여하였으며, 평균 경력은 5.6년이다. 델파이 설문조사지는 Likert 5점 척도를 사용하여 작성하였다.

#### 나. EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 결과 분석


델파이 설문조사에 응답한 16명의 설문지를 회수하여 타당도 분석을 실시하였다. 설문 결과 Likert 4(타당함)와 5(매우 타당함)에 응답한 패널 수를 적용하여 내용타당도 비율(CVR) 값을 산정하여 적용하였다. [표 4-33]은 EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 분석 결과 현황이다. 델파이 설문조사 결과에서 EMI-AI의 86개 항목 중 ALTAI의 평가목록이 얼마나 포함되어 있는지를 분석하였다. 선정 기준은 패널 수가 15일 경우 타당성을 갖기 위한 CVR의 최솟값이 0.49이기 때문에 0.50 이상의 CVR 값을 ALTAI의 평가목록이 EMI-AI에 포함된 항목으로 선정하였다(Ayre C. Scally AJ, 2014).

[표 4-33] EMI-AI와 ALTAI 간의 포함 관계 델파이 설문조사 분석 결과

| 윤리 원칙 | 구성 요소  | 윤리 측정지표 항목           | 유효 수 | 최소 값 | 최대 값 | 평균   | 표준 편차 | CVR 값 | 선정 여부 | EMI-AI 만존재 |
|-------|--------|----------------------|------|------|------|------|-------|-------|-------|------------|
| 투명성   | 설명 가능성 | 최종 사용자를 위한 투명성       | 16   | 2.00 | 5.00 | 4.13 | .661  | 0.75  | ○     |            |
|       |        | 사고조사자를 위한 투명성        | 16   | 3.00 | 5.00 | 4.38 | .641  | 0.88  | ○     |            |
|       |        | 변호사 및 전문가 증인을 위한 투명성 | 16   | 2.00 | 5.00 | 4.19 | .724  | 0.75  | ○     |            |
|       |        | 이용 범위 고지 투명성         | 16   | 3.00 | 5.00 | 4.06 | .621  | 0.63  | ○     |            |
|       |        | 이용자 데이터 수집 투명성       | 16   |      |      |      |       |       |       | ○          |
|       |        | 안전 인증자를 위한 투명성       | 16   | 3.00 | 5.00 | 4.31 | .724  | 0.75  | ○     |            |
|       |        | 대중 및 이해관계자를 위한 투명성   | 16   | 2.00 | 5.00 | 4.44 | .699  | 0.88  | ○     |            |
|       | 추적 가능성 | 문제 분석을 위한 데이터 제공     | 16   | 3.00 | 5.00 | 4.25 | .669  | 0.75  | ○     |            |
|       |        | 제작 과정의 기록 보관         | 16   | 3.00 | 5.00 | 4.31 | .572  | 0.63  | ○     |            |
|       |        | 사고 발생 이력 보관          | 16   | 4.00 | 5.00 | 4.63 | .562  | 0.88  | ○     |            |
|       |        | 상시 운영 감시             | 16   | 3.00 | 5.00 | 4.19 | .629  | 0.75  | ○     |            |
|       |        | 정기 운영 감사             | 16   | 3.00 | 5.00 | 4.25 | .722  | 0.75  | ○     |            |

|     |             |                    |    |      |      |      |      |      |   |   |
|-----|-------------|--------------------|----|------|------|------|------|------|---|---|
| 투명성 | 검증<br>가능성   | 안전성 시험기준 적용        | 16 | 3.00 | 5.00 | 4.67 | .547 | 0.75 | ○ |   |
|     |             | 알고리즘의 투명성 확보       | 16 | 3.00 | 5.00 | 4.06 | .723 | 0.63 | ○ |   |
|     |             | 학습용 데이터의 신뢰성       | 16 | 3.00 | 5.00 | 4.47 | .629 | 0.88 | ○ |   |
|     |             | 학습용 데이터의 충분성       | 16 | 3.00 | 5.00 | 4.44 | .869 | 0.88 | ○ |   |
|     |             | 시험, 인증 결과 제시       | 16 | 2.00 | 5.00 | 4.06 | .740 | 0.50 | ○ |   |
| 책임성 | 준법성         | 법·제도 준수            | 16 | 4.00 | 5.00 | 4.47 | .507 | 0.75 | ○ |   |
|     |             | 개인정보 제공 동의 획득      | 16 | 4.00 | 5.00 | 4.44 | .590 | 0.88 | ○ |   |
|     |             | 데이터 사용 사전 허가 획득    | 16 | 3.00 | 5.00 | 4.50 | .551 | 0.88 | ○ |   |
|     |             | 법적 근거 확보와 제시       | 16 | 2.00 | 5.00 | 4.25 | .607 | 0.75 | ○ |   |
|     |             | 사용 설명서와 기능 일치성     | 16 |      |      |      |      |      |   | ○ |
|     |             | 사용범위 법적기준 준수 명문화   | 16 | 2.00 | 5.00 | 4.19 | .711 | 0.75 | ○ |   |
|     |             | 이용자 안전 우선 준수       | 16 | 3.00 | 5.00 | 4.44 | .631 | 0.88 | ○ |   |
|     |             | 신고자에 대한 법적 보호      | 16 | 3.00 | 5.00 | 4.56 | .669 | 0.88 | ○ |   |
|     |             | 이용자 요구사항 대응        | 16 | 3.00 | 5.00 | 4.67 | .547 | 0.75 | ○ |   |
|     | 책임<br>식별성   | 설계자 책임 식별          | 16 | 4.00 | 5.00 | 4.38 | .504 | 0.88 | ○ |   |
|     |             | 제작자 책임 식별          | 16 | 3.00 | 5.00 | 4.56 | .543 | 0.88 | ○ |   |
|     |             | 운영자 책임 식별          | 16 | 3.00 | 5.00 | 4.50 | .624 | 0.88 | ○ |   |
|     |             | 이용자 책임 식별          | 16 | 2.00 | 5.00 | 4.19 | .612 | 0.75 | ○ |   |
|     |             | 개발자 책임 식별          | 16 |      |      |      |      |      |   | ○ |
| 공정성 | 알고리즘<br>차별성 | 의도적 차별 요소 제한       | 16 |      |      |      |      |      |   | ○ |
|     |             | 개인 편향적 차별 제한       | 16 | 3.00 | 5.00 | 4.56 | .513 | 0.88 | ○ |   |
|     |             | 불공정한 알고리즘 방지       | 16 | 3.00 | 5.00 | 4.67 | .547 | 0.75 | ○ |   |
|     |             | 인간의 생명 위협 방지       | 16 | 3.00 | 5.00 | 4.50 | .703 | 0.88 | ○ |   |
|     |             | 알고리즘의 의사결정 프로세스 제공 | 16 | 3.00 | 5.00 | 4.67 | .547 | 0.75 | ○ |   |
|     |             | 차별적 불이익 방지         | 16 | 2.00 | 5.00 | 4.13 | .631 | 0.75 | ○ |   |
|     | 데이터<br>편향성  | 편향적 특성 제거          | 16 | 2.00 | 5.00 | 4.19 | .612 | 0.75 | ○ |   |
|     |             | 데이터의 사실성           | 16 | 2.00 | 5.00 | 4.31 | .843 | 0.50 | ○ |   |
|     |             | 학습용 데이터의 수량        | 16 |      |      |      |      |      |   | ○ |
|     |             | 데이터의 유효성 검사        | 16 | 2.00 | 5.00 | 4.19 | .727 | 0.75 | ○ |   |
|     |             | 학습용 데이터 품질관리       | 16 |      |      |      |      |      |   | ○ |
|     |             | 데이터 편향 방지 알고리즘 적용  | 16 | 3.00 | 5.00 | 4.44 | .511 | 0.88 | ○ |   |
|     |             | 데이터 분류 기준 정의 및 적용  | 16 | 3.00 | 5.00 | 4.50 | .619 | 0.88 | ○ |   |
|     |             | 데이터 균일성 확보         | 16 | 2.00 | 5.00 | 4.31 | .702 | 0.75 | ○ |   |
|     | 접근성         | 접근성 보장             | 16 | 3.00 | 5.00 | 4.50 | .568 | 0.88 | ○ |   |
|     |             | 보편적 사용자 지원         | 16 | 3.00 | 5.00 | 4.56 | .663 | 0.88 | ○ |   |
|     |             | 사용자 접근 제한 방지       | 16 | 2.00 | 5.00 | 4.25 | .864 | 0.75 | ○ |   |
|     |             | 이용자의 쉬운 접근성        | 16 | 3.00 | 5.00 | 4.44 | .662 | 0.88 | ○ |   |

|             |                 |                       |    |      |      |      |      |      |   |    |
|-------------|-----------------|-----------------------|----|------|------|------|------|------|---|----|
| 공정성         | 공공성             | 공공데이터 수집 공지           | 16 |      |      |      |      |      |   | ○  |
|             |                 | 데이터 활용 제한             | 16 |      |      |      |      |      |   | ○  |
|             |                 | 개인정보 수집 제한            | 16 |      |      |      |      |      |   | ○  |
|             |                 | 사회환경에 미치는 영향 배제       | 16 | 2.00 | 5.00 | 4.25 | .698 | 0.75 | ○ |    |
|             |                 | 인간의 생명 위협 방지          | 16 | 3.00 | 5.00 | 4.60 | .621 | 0.88 | ○ |    |
|             |                 | 이해관계자의 의견 반영          | 16 | 3.00 | 5.00 | 4.31 | .555 | 0.75 | ○ |    |
|             |                 | 모든 인류에게 공정한 제공        | 16 | 3.00 | 5.00 | 4.19 | .573 | 0.75 | ○ |    |
| 통제성         | 제어<br>가능성       | 생명 위협 시 자동 종료         | 16 | 1.00 | 4.00 | 3.43 | .940 | 0.50 | ○ |    |
|             |                 | 운영자 통제 및 제어           | 16 | 3.00 | 5.00 | 4.50 | .563 | 0.88 | ○ |    |
|             |                 | 위험 발생 시 쉬운 접근성 제공     | 16 | 3.00 | 5.00 | 4.13 | .626 | 0.75 | ○ |    |
|             | 이용자<br>주도성      | 이용자 위험 회피             | 16 |      |      |      |      |      |   | ○  |
|             |                 | 자율적 조작                | 16 | 2.00 | 5.00 | 4.13 | .884 | 0.75 | ○ |    |
|             |                 | 이용자 데이터 선택적 제공        | 16 |      |      |      |      |      |   | ○  |
|             |                 | 이용자 데이터 삭제            | 16 |      |      |      |      |      |   | ○  |
|             | 모니터<br>링        | 작동상태 제공               | 16 | 2.00 | 5.00 | 3.93 | .847 | 0.63 | ○ |    |
| 위험 예측 상태 제공 |                 | 16                    |    |      |      |      |      |      | ○ |    |
|             |                 | 운영상태 상시 모니터링          | 16 | 2.00 | 5.00 | 4.25 | .942 | 0.75 | ○ |    |
| 안전성         | 견고성             | 인간의 생명 보호 우선          | 16 |      |      |      |      |      |   | ○  |
|             |                 | 알고리즘의 오류 관리           | 16 | 2.00 | 5.00 | 4.31 | .877 | 0.63 | ○ |    |
|             |                 | 외부 공격에 대한 견고성         | 16 | 3.00 | 5.00 | 4.25 | .626 | 0.88 | ○ |    |
|             |                 | 예측 결과의 동일성            | 16 | 2.00 | 5.00 | 4.06 | .736 | 0.63 | ○ |    |
|             |                 | 학습 데이터의 정확성(accuracy) | 16 | 3.00 | 5.00 | 4.13 | .622 | 0.75 | ○ |    |
|             |                 | 기능의 지속적 업그레이드 및 배포    | 16 | 3.00 | 5.00 | 4.25 | .714 | 0.75 | ○ |    |
|             |                 | 기능 프로세스의 정확한 정의       | 16 | 3.00 | 5.00 | 4.44 | .521 | 0.88 | ○ |    |
|             | 보안성             | 보안성 인증                | 16 | 3.00 | 5.00 | 4.50 | .584 | 0.88 | ○ |    |
|             |                 | 사용자 인증                | 16 | 3.00 | 5.00 | 4.25 | .547 | 0.83 | ○ |    |
|             |                 | 상호작용 데이터 보안           | 16 | 2.00 | 5.00 | 4.03 | .964 | 0.63 | ○ |    |
|             |                 | 비인가자 연결 방지            | 16 |      |      |      |      |      |   | ○  |
|             |                 | 알고리즘 시큐어 코딩           | 16 | 3.00 | 5.00 | 4.30 | .702 | 0.73 | ○ |    |
|             |                 | 이용 종료 시 정보 삭제         | 16 |      |      |      |      |      |   | ○  |
|             | 프라이<br>버시<br>보호 | 개인정보보호 영향평가           | 16 | 3.00 | 5.00 | 4.43 | .626 | 0.88 | ○ |    |
|             |                 | 개인정보 수집 고지            | 16 | 3.00 | 5.00 | 4.30 | .702 | 0.75 | ○ |    |
|             |                 | 개인정보 가명화              | 16 |      |      |      |      |      |   | ○  |
|             |                 | 개인 민감정보 수집 차단         | 16 | 2.00 | 5.00 | 3.94 | .864 | 0.63 | ○ |    |
|             |                 | 개인정보 활용               | 16 | 3.00 | 5.00 | 4.31 | .702 | 0.75 | ○ |    |
|             |                 | 미동의 데이터 수집 방지         | 16 |      |      |      |      |      |   | ○  |
|             |                 | 데이터 주권 보장             | 16 | 3.00 | 5.00 | 4.50 | .625 | 0.88 | ○ |    |
|             | 전체 : 86개 항목     |                       |    |      |      |      |      |      |   | 68 |



<그림 4-8> EMI-AI와 ALTIA 평가목록 간의 관계성


EMI-AI와 ALTAI의 평가목록을 설문조사하여 분석한 결과 EMI-AI의 86개 항목에 ALTAI의 평가목록 69개 항목이 포함된 항목 수는 61개였으며, ALTAI의 8개 평가목록은 EMI-AI에 포함되지 않는 평가목록으로 도출되었다. <그림 4-8>은 EMI-AI와 ALTAI 평가목록 간의 관계성을 도식화 한 것이다. EMI-AI에 포함되지 않는 ALTAI의 8개 평가목록 코드는 a05, b09, d03, f02, f07, g04, g05, g06이었으며, 포함되지 않는 평가목록의 특징은 사회적 상호작용에 대한 부분이 많은 것으로 분석된다. 또한 EMI-AI에만 존재한 윤리 측정지표 항목 수는 18개로 분석되었으며, [표 4-34]는 EMI-AI에만 존재하는 인공지능 윤리 측정지표 18개 항목이다.

[표 4-34] EMI-AI에만 존재하는 인공지능 윤리 측정지표 18개 항목

| 윤리원칙 | 구성요소     | 윤리 측정지표 항목     |
|------|----------|----------------|
| 투명성  | 설명가능성    | 이용자 데이터 수집 투명성 |
| 책임성  | 준법성      | 사용 설명서와 기능 일치성 |
|      | 책임식별성    | 개발자 책임 식별      |
| 공정성  | 알고리즘 차별성 | 의도적 차별 요소 제한   |
|      | 데이터 편향성  | 학습용 데이터의 수량    |
|      |          | 학습용 데이터 품질관리   |
| 공정성  | 공공성      | 공공데이터 수집 금지    |
|      |          | 데이터 활용 제한      |
|      |          | 개인정보 수집 제한     |
| 통제성  | 이용자 주도성  | 이용자 위험 회피      |
|      |          | 이용자 데이터 선택적 제공 |
|      |          | 이용자 데이터 삭제     |
| 안전성  | 모니터링     | 위험 예측 상태 제공    |
|      | 견고성      | 인간의 생명 보호 우선   |
|      | 보안성      | 비인가자 연결 방지     |
|      |          | 이용 종료 시 정보 삭제  |
|      | 프라이버시 보호 | 개인정보 가명화       |
|      |          | 미동의 데이터 수집 방지  |

#### 다. EMI-AI에 ALTAI의 간 포함 관계

EMI-AI 항목 86개와 ALTAI의 평가목록 69개의 윤리적 특성을 분석하여 매핑하고 매핑 결과를 전문가 델파이 설문조사를 통하여 검증한 결과 <그림 4-9>와 같이



<그림 4-9> EMI-AI와 ALTAI 평가목록 간의 포함 관계

EMI-AI와 ALTAI의 평가목록 간의 포함 관계가 도식화되었다. ALTAI의 평가목록이 EMI-AI 항목에 포함하는 항목 수는 68개였으며, 68개 항목에는 ALTAI 평가목록이 중복으로 EMI-AI에 포함된 내용까지 반영한 항목 수이다. ALTAI 평가목록에만 존재한 평가목록은 8개로 나타났다. 또한 EMI-AI의 18개 항목은 ALTAI 요구사항에 없는 항목으로 개발되었다. 특히 인공지능 관련 교육 및 신기술에 대한 능동적인 준비가 마련될 수 있도록 하는 평가목록이 중요하게 보인다. EMI-AI와 ALTAI를 종합적으로 분석해 보면 EMI-AI는 ALTAI보다 범용적으로 개발하였기 때문에 어느 국가에서나 활용이 가능하다는 장점이 있다. 국내 인공지능 산업에 우선적으로 적용 가능한 분야는 지능형 로봇 개발, 안전관리 CCTV, 인적 자원관리 시스템의 인공지능 기능, 채팅 봇, 자율주행 이동체, 지능형 헬스케어 시스템, 개인 비서 서비스 등에 인공지능 윤리 측정지표를 활용할 수 있을 것이다. 급속하게 발전하는 인공지능 기술과 함께 법·제도 정비가 진행되는 시점에서 인공지능 윤리 측정지표가 크게 기여할 수 있을 것이다.

## 제 5 장 결 론

인공지능 기술은 4차 산업혁명과 디지털 트랜스포메이션에서 가장 핵심이 되는 기술 영역이기 때문에 모든 국가에서 경쟁적으로 기술 개발과 비즈니스 전략에 심혈을 기울이고 있다. 인공지능이 인간의 삶과 전 산업에 걸쳐 깊숙하게 스며들어 이제는 인공지능이 특별한 기술이 아니라고 생각할 만큼 인간과 상호작용하면서 우리 생활에 많은 영향을 끼치고 있다. 이렇듯 인공지능 활용과 기술 발전이 가속화되는 가운데 인공지능의 편익과 더불어 역기능이 증가하고 있다. 이러한 사회적 상황에서 주요 선진국을 중심으로 인공지능 윤리 문제에 대한 높은 관심과 해결 방안을 모색하여 인공지능 윤리원칙, 가이드라인, 헌장, 개발 지침, 평가목록, 인증 및 시험 방법 등을 선제적으로 개발하여 산업현장에 적용하고 있다. 인공지능 윤리 문제가 중요하게 대두되어 이슈화된 것은 채 10년이 되지 않지만, 인간과 사회에 미치는 영향이 측정하기 어려울 정도로 증가하고 있기 때문에 인공지능 기술과 함께 인공지능 윤리 문제에 대한 적극적인 대응이 절실하게 필요하다.

본 연구는 이러한 시대적 상황에서 인공지능 산업 전 분야에 범용적으로 활용이 가능할 수 있게 신뢰성이 확보된 인공지능 윤리 측정지표(EMI-AI)를 개발하였다. EMI-AI를 개발하기 위하여 연구자가 사전에 연구한 ‘인공지능 윤리원칙 분류 모형 및 구성요소’와 ‘인공지능 윤리원칙 기반의 인격권 및 재산 보호를 위한 인공지능 윤리 측정지표’를 바탕으로 확장된 인공지능 윤리 측정지표 50개 항목을 개발하였다. 확장된 윤리 측정지표를 개발하기 위하여 윤리원칙 분류 모형과 구성요소가 기준이 되었으며, 국내외 인공지능 윤리 관련 가이드라인, 헌장, 지침, 규정, 정책, 법·제도 등 다양한 문헌을 분석하여 윤리 측정지표를 정의하고 인공지능 윤리 관련 전문가 30명을 대상으로 FGI를 3회에 걸쳐 실시하여 55개의 윤리 측정지표를 정의하였다. FGI에 참여한 전문가의 직업(직무)은 인공지능 윤리 전문가, 법률가, 사회학

자, 인공지능 교육자, 설계자, 개발자, 제작자, 운영자, 일반 사용자 및 윤리 교육자가 포함된 전문가 그룹이었다. 인공지능 윤리에 대한 인식이 아직은 높지 않기 때문에 전문가 섭외가 쉽지 않았으나 다행히 최근 챗봇, 자율주행자동차, 드론, 로봇, 인공지능 기술을 적용한 응용시스템 등에서 윤리 문제가 증가하고 있어 본 연구에 많은 관심을 보이며 참여하였다. FGI에서 도출된 윤리 측정지표 55개 항목에 대한 전문가 델파이 설문조사와 설문 데이터로 타당도 분석을 통하여 50개 항목의 인공지능 윤리 측정지표를 확장하여 개발하였다. 확장하여 개발한 50개 항목의 윤리 측정지표와 연구자가 선행 개발한 40개 항목의 윤리 측정지표를 통합하여 신뢰성 확보를 위한 윤리 측정지표 개발 연구를 진행하였다. 연구 개발을 위하여 유럽연합에서 공표한 ‘신뢰할 수 있는 인공지능 평가목록(ALTAI)’을 참고하여 7개의 신뢰성 변수를 정의하고 신뢰성 검증을 위하여 설문지를 설계하였다. 신뢰성 변수에 대한 정의와 타당성 검증은 FGI를 통하여 진행하였으며, 신뢰성 변수는 통제성, 안전성, 책무성, 투명성, 공공성, 사회적영향, 보안성으로 정의하였다. 7개의 신뢰성 변수 중 사회적영향은 ALTAI를 참고하였으며, 나머지는 연구자가 선행 개발한 인공지능 윤리원칙 분류 모형 및 구성요소를 적용하였다.

통합된 윤리 측정지표 90개 항목에 신뢰성 변수를 적용하여 설문지를 설계하고, 200명을 대상으로 설문지를 배포하였으며, 164명으로부터 설문지를 회수하였다. 다양한 설문 대상 표본을 확보하여 설문의 품질을 높일 수 있도록 설문 대상자 직업(직무)을 인공지능 윤리와 밀접하게 관련이 높은 표본으로 선정하여 진행하였다. 설문 데이터 통계분석은 SPSS를 사용하였으며, 인구통계학적 분석, 기술통계량 분석, 신뢰성 분석, 탐색적 요인분석, 상관관계분석을 통하여 윤리 측정지표 90개 항목의 신뢰성 검증을 실시하였다.

통계분석 결과 윤리 측정지표 90개 항목에 대한 타당성 검정에서는 KMO 값이 0.914로서 매우 높은 수준으로 나타났으며, Bartlett 값이 유의수준 0.000에서 유의한 것으로 나타나 요인분석의 적합성이 검증되었다. 탐색적 요인분석에서는 공통성의

값이 0.40 미만인 경우의 요인을 제거하고 86개 항목의 변수를 적재하여 타당도를 확보하였다. 신뢰도 분석에서는 Cronbach  $\alpha$ 에 의하여 신뢰도 분석을 실시하였고, 그 결과 모든 항목 변수들의 신뢰도 계수가 0.8 이상의 높은 신뢰계수를 보임으로써 측정항목의 신뢰도에는 별문제가 없는 것으로 나타났다. 상관관계분석에 의하여 신뢰성 변수 상관성을 분석한 결과 4개 항목의 윤리 측정지표가 낮은 상관계수로 나타나 관계성이 거의 없는 것으로 분석되었다. 따라서 윤리 측정지표의 신뢰성에 대한 관계성 검증에서는 윤리 측정지표 90개 항목 중 86개 항목이 높은 상관계수로 나타나 관계성이 있는 것으로 분석되었다. 최종적으로 윤리 측정지표 항목 86개가 신뢰성이 확보된 인공지능 윤리 측정지표(EMI-AI)로 개발되었다.

또한 EMI-AI와 ALTAI 간의 관계 검증을 위하여 전문가 16명을 대상으로 델파이 설문조사를 실시하였다. EMI-AI의 항목과 ALTAI의 평가목록 간의 유사한 내용을 포함 관계로 정의하여 설문지를 설계하였으며, 설문조사 결과 EMI-AI의 86개 항목에 ALTAI의 평가목록 69개 항목 중 포함된 항목 수는 61개였으며, ALTAI의 8개 평가목록은 EMI-AI에 포함되지 않는 것으로 나타났다. ALTAI에는 없고 EMI-AI에만 존재하는 윤리 측정지표는 18개 항목으로 분석되었다. EMI-AI에만 존재하는 윤리 측정지표는 국내 인공지능 윤리 측정지표에 특화하여 활용할 수 있는 인공지능 윤리 측정지표라 할 수 있다.

본 연구에서 최종적으로 확정된 86개 항목의 EMI-AI는 신뢰성을 검증하여 신뢰성이 확보된 범용성이 높은 인공지능 윤리 측정지표이다. 따라서 국내는 물론 해외에서도 인공지능 윤리 문제에 대응하기 위하여 다양한 인공지능 분야에 활용될 수 있을 것이다. 신뢰 가능한 인공지능 사회를 만들고자 세계 각국은 인공지능 윤리와 관련된 많은 정책과 법·제도, 표준화, 규범, 지침 및 점검 목록 등에 대한 개발이 진행되고 있으며, 인공지능 제품이나 서비스 개발이 급속하게 이루어지는 현 시점에서 EMI-AI는 활용성이 매우 높을 것으로 기대된다.

본 연구에서 개발된 EMI-AI는 인공지능 기술과 더불어 발생할 수 있는 윤리적 문

제를 선제적으로 대응하기 위하여 인간의 존엄성과 사회적 안전을 보장할 수 있도록 하며, 인간에게 미치는 영향을 최소화할 수 있도록 인공지능 윤리 관련 다양한 분야의 전문가 의견이 반영된 고품질의 인공지능 윤리 측정지표라는 데 큰 의의가 있다.

본 연구로 개발된 EMI-AI의 주요 활용은 첫째, 기술적으로 우위에 있거나 강점이 있는 인공지능 분야에 우선적으로 적용할 윤리 평가 점검 목록을 개발하는 데 활용할 수 있을 것이다. 둘째, 인공지능은 소프트웨어로 개발하여 제품이나 서비스로 제공되기 때문에 인공지능이 적용된 모든 소프트웨어에 윤리 인증이 적용될 수 있도록 시험평가 리스트를 개발하는 데 활용할 수 있을 것이다. 셋째, 경제 수준과 국가 체제 환경(민주주의, 사회주의, 종교적 특성)에 따라 윤리적 기준이 상이하기 때문에 인공지능에 의한 인격권을 보장할 수 있는 윤리 측정지표로 활용할 수 있을 것이다. 넷째, 다양한 인공지능 기술이 개발되고 있기 때문에 인공지능 분야별 윤리 표준화, 이해관계자별 윤리기준, 인공지능 관련 윤리 교육 지침 등을 개발하는 데 활용할 수 있을 것이다. 마지막으로 인공지능 관련 법·제도 입안, 기술 정책, 교육 정책, 사회과학 등 다양한 분야에 활용될 수 있을 것이다.

본 연구에 따른 시사점으로는 첫째, 인공지능 기술 발전과 함께 인간에게 안전 위협, 인격권 침해, 편향적 의사결정, 재산 훼손 등 역기능에 대한 선제적 대응이 가능하도록 윤리 측정지표 기틀을 마련한 것이다. 둘째, 인공지능 윤리원칙 분류 모형과 구성요소, 측정지표를 이용하여 신뢰할 수 있는 인공지능 사회구현 실현에 기여한 것이다. 셋째, 우선적으로 적용해야 할 인공지능 분야에 적절하게 활용할 수 있는 인공지능 윤리 측정지표를 개발한 것이다. 넷째, 인공지능 윤리 분야 연구 및 교육, 정책, 법·제도 마련에 적용할 수 있는 인공지능 윤리원칙 분류 및 구성요소, 측정지표가 개발된 것이다. 다섯째, 4차 산업혁명 시대에 선제적으로 인공지능 사회를 구현하기 위해 인공지능 윤리 의식을 높이고 강화하는 데 기여한 것이다. 마지막으로 국내외에서 범용적으로 활용할 수 있으며, 국내 인공지능 기술과 사회체계의 실정에 적합한 인공지능 윤리원칙과 측정지표를 개발한 것이라 할 수 있다.

본 연구 결과를 바탕으로 향후 과제로는 먼저, 인공지능 윤리원칙 분류 모형과 구성요소를 바탕으로 다양한 인공지능 분야에 지속적으로 인공지능 윤리 측정지표와 세부 점검 목록을 개발하여 인공지능 제품이나 서비스에 적용할 수 있도록 해야 할 것이다. 그리고 EMI-AI를 바탕으로 인공지능 개발 및 운영 시 적용할 세부적인 윤리 평가리스트나 점검 목록을 개발하여 적용할 수 있도록 해야 할 것이다. 마지막으로 인공지능 윤리원칙, 구성요소, 측정지표를 바탕으로 인공지능 윤리와 관련된 법·제도 마련 시 적용할 수 있도록 지속적인 인공지능 윤리 연구가 필요하다.

## 참 고 문 헌

- 개인정보보호위원회 (2021). 가명정보 처리 가이드라인.
- 개인정보보호위원회 (2021). 인공지능(AI) 개인정보보호 자율점검표.
- 계승균 (2017). 법규범에서 인공지능의 주체성 여부. 법조, 66(4), 158-196.
- 고영화, 임춘성 (2021). 인공지능 기술수용과 윤리적 인식이 이용의도에 미치는 영향. 디지털융복합연구 논문지, 19(3), 217-225.
- 고인석 (2014). 로봇윤리의 기본 원칙: 로봇 존재론으로부터. 범한철학, 75(4), 401-426.
- 고학수, 박도현, 이나래 (2020). 인공지능 윤리규범과 규제 거버넌스의 현황과 과제. 경제규제와 법 논문지, 13(1), 9-17.
- 과학기술정책연구원 (2018, 2019). 인공지능 기술 전망과 혁신정책 방향(1, 2차년도).
- 과학기술정보통신부 (2020). 국가 인공지능 윤리기준(안).
- 과학기술정보통신부 (2021). 신뢰할 수 있는 인공지능 실현 전략(안).
- 과학기술정보통신부, 한국정보통신기술협회 (2022). 2022 신뢰할 수 있는 인공지능 개발 안내서(안).
- 곽영운 (2019). 편견에 대한 아도르노의 비판적 성찰, 현대유럽철학연구, 52, 88-103.
- 국회입법조사처 (2021). 인공지능 육성 및 신뢰 기반 조성 등에 관한 법률(안).
- 권정인, 이성철, 안성진 (2011). 사회현상학 관점에서의 인터넷역기능 분류체계 표준화 연구. 컴퓨터교육학회 논문지, 14(6), 1-10.
- 권현영 (2019). 인공지능(AI) 법조 분야: 윤리적·규제적 고려사항. 경제규제와 법 논문지, 12(2), 69-80.
- 국가인권위원회 (2022). 인공지능 개발과 활용에 관한 인권 가이드라인.
- 국토교통부 (2020). 자율주행자동차 윤리 가이드라인.

- 김나루 (2017). 유럽연합의 새로운 개인정보보호 법제에 관한 소고. 고려법학 논문지, 86, 327-329.
- 김명식 (2018). 인공지능과 환경윤리 - 인공지능의 도덕적, 법적 권리 -. 환경철학, 25, 5-30.
- 김명주 (2017). 인공지능 윤리의 필요성과 국내외 동향. 정보와통신, 34(10), 45-54.
- 김미리, 윤상필, 권현영 (2020). 인공지능 전문가 윤리의 역할과 윤리 기준의 지향점, 법학논총, 32(3), 9-53.
- 김성용, 정관영 (2019). 인공지능의 개인정보 자동화 처리가 야기하는 차별 문제에 관한 연구. 서울대학교 법학, 60(2), 311-362.
- 김용주 (2016). 인공지능 창작물에 대한 저작물로서의 보호가능성. 법학연구, 27(3).
- 김익현 (2020). 윤리적 인공지능 개발을 위한 시험평가검증확인(TEVV) 전략. 한국국방기술학회 논문지, 2(1). 1-4.
- 김재현 (2021). 중등 교원양성대학 SW·AI 교육 강화 방안 -성균관대학교 사범대학 사례 중심으로-. 정보과학회지, 39(9), 35-40.
- 김종세 (2020). 인공지능의 안전성과 인간윤리에 대한 법정책적 고찰. 법학연구, 20(1), 1-35.
- 김종호 (2018). 인공지능 시대의 윤리와 법적 과제. 과학기술법연구, 24(3), 155-205.
- 김진홍 (2014). 공공기관의 아웃소싱 보안관계 수준 측정지표에 관한 연구. 국내박사학위논문 숭실대학교, 서울.
- 김효은 (2018). 인공도덕성 검사의 가능성. 인간환경미래, 20, 129-156.
- 김효은 (2020). 공학적 방법을 결합한 인공지능 윤리 학습. 윤리연구, 219(1), 133-153.
- 남정아 (2019). 미국의 최근 개인정보보호법제 동향에 대한 고찰. 유럽헌법연구 논문지, 31, 153-154.
- 대한무역투자진흥공사 (2021). 독일 정부의 자율주행 레벨 4 상정안 분석 및 시사

점. 뮌헨무역관.

도로교통공단 교통과학연구원 (2021). 자율주행자동차 관련 도로교통법 개정안 연구.

류정희 (2022). AI에 관한 국가의 규제와 법적 수용방안 연구. 숙명여자대학교 박사 학위논문.

목광수 (2019). 도덕의 구조 - 인공지능 시대 도덕 논의의 출발점. 철학사상, 73, 163-195.

박도현 (2022). 인간 편향성과 인공지능의 교차. 서울대학교 법학, 63(1), 139-175.

박미정 (2019). 인공지능과 데이터 윤리에 관한 소고: 인공지능에 활용되는 헬스 데이터를 중심으로. 한국의료윤리학회, 22(3), 255-273.

박소영 (2019). 인간과 인공지능의 공존 가능성에 대한 탐색: 책임의 윤리와 문학적 상상력. 윤리연구, 1(124), 17- 35.

방정미 (2021). 인공지능 알고리즘 규제거버넌스의 전환. 한국공법학회, 49-3,

박주희 (2021). 완전 자율주행차 상용화를 위한 국제규범과 국내법·제도의 조화. 과학기술정책연구원, 2020 STEPI Fellowship.

박충식 (2018). 윤리적인 인공지능 로봇: 구성적 정보 철학 관점에서. 과학철학, 21(3), 39-65.

박혜성, 김법연, 권현영 (2021). 인공지능 통제를 위한 규제의 동향과 시사점. 정보법학 논문지, 25, 2.

박형빈 (2021). 기계윤리 및 신경윤리학 관점에서 본 인공도덕행위자(AMA) 도덕성 기준과 초등도덕교육의 과제. 한국초등교육, 31(특별호 2021), 77-92.

백수원 (2021). 헌법상 투명성원칙에 기반한 인공지능 규제의 방향. 성균관법학, 33(2), 589-622.

백창화, 최재호, 임성욱 (2018). 인공지능 서비스 특징 및 품질측정항목의 고찰과 제안. 품질경영학회지, 46(3).

- 백창화 (2019). 인공지능서비스의 품질평가방법 개발. 대진대학교 박사학위논문.
- 백창화, 최재호, 임성욱 (2018). 인공지능 서비스 특징 및 품질 측정항목의 고찰과 제안. 품질경영학지 논문.
- 변순용, 송선영 (2012). 로봇윤리의 이론적 기초를 위한 근본 과제 연구. 윤리연구, 88(1).
- 변순용 (2020). 데이터 윤리에 인공지능 편향성 문제에 대한 연구. 윤리연구 논문지, 128(1), 143-158.
- 변순용 (2019). AI 로봇의 도덕성 유형에 근거한 윤리 인증 프로그램(ECP) 연구. 윤리연구. 1(126), 73-90.
- 서울시교육청 (2021). 인공지능 공공성 확보를 위한 현장 가이드라인.
- 선지원 (2019). 인공지능 알고리즘 규율에 대한 소고 - 독일의 경험을 중심으로. 경제규제와 법, 12(1), 26-43.
- 성태제 (2019). 현대 기초통계학: 이해와 적용. 학지사. 서울.
- 소순주, 안성진 (2021). 인공지능 윤리원칙 분류 모델에 관한 고찰. 컴퓨터교육학회 논문지, 25(2), 111-114.
- 소순주, 안성진 (2021). 인공지능 윤리원칙 분류 모형 및 구성요소에 관한 연구. 컴퓨터교육학회논문지, 24(6), 119-132.
- 소순주, 안성진 (2022). 인공지능 윤리원칙 기반의 인격권 및 재산보호를 위한 인공지능 윤리 측정지표에 관한 연구. 인터넷정보학회논문지, 23(3), 111-123.
- 신영진 (2021). 우리나라의 인공지능(AI)서비스를 위한 개인정보보호 개선방안. 융합정보논문지, 11(3), 20-33.
- 송지준 (2010). 논문작성에 필요한 SPSS/AMOS 통계분석 방법. 21세기사. 서울.
- 신예진 (2020). 2022 신뢰할 수 있는 인공지능 개발안내서. TTA ICT Standard Weekly, 1091.
- 안정용 (2021). 인공지능 윤리: 지각된 인공지능 자유의지가 인공지능의 윤리적 책

- 임에 미치는 영향을 중심으로. 고려대학교 박사학위논문.
- 양종모 (2017). 인공지능 알고리즘의 편향성, 불투명성이 법적 의사결정에 미치는 영향 및 규율 방안. 법조, 66(3), 60-105.
- 양종모 (2020). 인공지능 챗봇 알고리즘에 대한 몇 가지 법적 고찰. 홍익법학, 21(1), 449-482.
- 양종모 (2016). 인공지능의 위험의 특성과 법적 규제방안. 홍익법학, 17(4), 537-565.
- 양희태 (2018). 인공지능의 안전성 이슈와 정책 대응 방안. 한국통신학회논문지, 43(10), 1724-1732.
- 이광수, 안성진 (2013). 고등교육기관 통합정보시스템 구축 시 고려해야 할 환경요인과 세부 측정항목에 관한 연구. 인터넷정보학회논문지, 14(3), 57-65.
- 이기훈 (2018). 인공지능 발달에 따른 윤리학의 필요성 연구. 윤리연구, 120(1), 293-317.
- 이수경 (2021). AI 시대 인공지능 제조물에 대한 손해배상 책임에 관한 연구. 부산대학교 박사학위논문.
- 이상용 (2020). 알고리즘 규제를 위한 지도 - 원리, 구조, 내용 -. 경제규제와 법, 13(2), 129-159.
- 이승재 (2020). AMA의 도덕적 지위의 문제. 철학논총, 102(4), 527-545.
- 이연희, 변순용 (2020). 킬러로봇에 대한 윤리적 고찰. 한국초등교육, 31(특별호 2020), 217-225.
- 이성재, 정승민 (2021). 인공지능 윤리에 관한 알고리즘의 다양성 보존의 실증연구. 통계연구, 26(4), 22-44.
- 이성철, 안성진 (2012). 정보윤리/정보보호-보안교육 : 인터넷 포털 기업의 사회적 책임 강화를 위한 정보윤리강령 비교 연구. 컴퓨터교육학회 학술발표대회논문집, 16(1), 118-121.

- 이제영, 김단비, 양희태 (2019). 인공지능 기술 전망과 혁신정책 방향(2차년도) - 안전하고 윤리적인 인공지능 R&D 및 활용을 위한 제도 개선 방안을 중심으로 -. 정책연구, 2019, 1-226.
- 이청호 외 (2021). 가정용 헬스케어 AI 로봇의 개발자용 윤리체크리스트 개발에 대한 연구. 윤리연구, 132, 264-279.
- 이희욱 (2020). 인공지능의 의사결정에 대응한 자기결정권의 보장에 관한 연구. 한양대학교 박사학위논문.
- 임경숙 (2019). 인공지능에 관한 법적 규율방안. 한양대학교 박사학위논문.
- 이한슬, 천현득 (2021). 인공지능 윤리에서 해명가능성 원리. 인문학연구, 35, 37-63.
- 일본 내각부 (2019). 인간중심의 AI 사회 원칙안 (Social Principles of Human-Centric AI).
- 임미가 (2021). 인공지능 윤리 연구에 관한 체계적 문헌고찰. 윤리연구, 135(1), 47-66.
- 장철호, 차윤호 (2021). 개인정보보호 활동 결정요인 연구: 개인정보 처리자를 중심으로. 정보화정책, 28(1), 64-76.
- 전자신문 (2021). AI윤리, 누구의 몫인가. <https://www.etnews.com/20211223000199>.
- 정보통신기획평가원 (2019). 인공지능의 윤리적 문제와 해결방안 모색.
- 정보통신기술진흥센터 (2018). 4차 산업혁명 기술수준평가 및 수준향상방안.
- 정원섭 (2020). 인공지능 알고리즘의 편향성과 공정성. 인간·환경·미래, 25, 55-73.
- 정진규, 변순용, 김영걸, 김종욱 (2019). 홈헬스케어 AI Robot의 윤리인증의 필요성과 그 준거에 대한 연구. 윤리연구, 127(1), 147-168.
- 정보통신정책연구원 (2018). 4차 산업혁명시대 산업별 인공지능 윤리의 이슈 분석 및 정책적 대응방안연구.
- 조수영 (2018). 개인정보보호법과 EU의 GDPR에서의 프라이버시 보호에 관한 연구. 법학논고, 0(61), 117-148.

- 지현아 (2020). 로봇윤리(Roboethics)의 도덕교육적 적용 방안 연구. 서울대학교 박사학위논문.
- 최경진 외 (2021). AI 윤리 관련 법제화 방안 연구. 세종:한국법제연구원.
- 최미란 (2021). 인공지능 표준화 현황. 한국전자통신연구원.
- 최용성, 천명주 (2017). 인공적 도덕 행위자에 관한 도덕철학·심리학적 성찰. 윤리교육연구, 0(46), 93-129.
- 한국로봇산업협회(2020). 2019년 기준 로봇산업 실태조사 결과보고서.
- 한국인공지능윤리협회 (2021). 인공지능 윤리 헌장 (The AI Ethics Charter).
- 한국정보통신기술협회 (2022). GS 시험 인증(1등급) 안내서.
- 한국전자통신연구원 (2021). 인공지능 표준화 현황.
- 한국지능정보사회진흥원 (2018). 지능정보사회 윤리 가이드라인.
- 한국지능정보사회진흥원 (2019). 인공지능 윤리 가이드라인(일본과 EU 사례를 중심으로).
- 한국지능정보사회진흥원 (2021). 인공지능 학습용 데이터셋 구축 안내서.
- 한국지능정보사회진흥원 (2021). 주목받는 인공지능(AI) 9대 핵심 기술 분석 및 주요 시사점.
- 한국표준협회 (2022). 인공지능 인증 시험 기준.
- 한상기 (2016). 인공지능 기술의 사회적 이슈와 윤리 문제. 한국멀티미디어학회지, 20(3), 41-52.
- 한성훈 (2020). 자율주행차의 기술단계에 따른 형사책임에 관한 연구. 형사법연구, 32, 3.
- 행정안전부 디지털정부국 공공지능정책과 (2021). 공공분야 인공지능 도입을 위한 실무자 안내서(안).
- 허준, 안성진 (2020). 정보보호 정책에 대한 편향적 사고가 보안준수 행동에 미치는 영향. 컴퓨터교육학회논문지, 23(1), 63-75.

- Adamson, G., Havens, J. C., & Chatila, R. (2019). Designing a value-driven future for ethical autonomous and intelligent systems. *Proceedings of the IEEE*, 107(3), 518 - 525.
- AI HLEG. (2019). *Ethics Guidelines for Trustworthy AI*. Brussels Belgium. European Commission.
- Andrzej Rapaczynski. (2016). Driverless Cars and the Much Delayed Tort Law Revolution. *Columbia Law and Economics Working Paper*, 540.
- Ayre C., Scally AJ. (2014). Critical Values for Lawshe's Content Validity Ratio: Revisiting the Original Methods of Calculation. *sage journals*, 47(1).
- Berkman Klein center. (2020). *Principled Artificial Intelligence: Mapping Consensus in Ethical and Right-based Approaches to Principles for AI*. Research Publication. 2020-1.
- BDV. (2019). *Data Protection in the era of Artificial Intelligence*.
- Binns, R. (2018). Algorithmic accountability and public reason. *Philosophy & Technology*, 31(4), 543-556.
- Cabinet Office. (2019). *Social Principles of Human-Centric AI*. Tokyo Japan. <https://ai.bsa.org/wp-content/uploads/2019/09/humancentricai.pdf>.
- Churchill Jr, G. A. (1979). A paradigm for developing better measures of marketing constructs. *Journal of Marketing Research*, 16(1), 64-73.
- CIPL. (2020). *Artificial Intelligence and Data Protection: Delivering Sustainable AI Accountability in Practice\_Hard Issues and Practical Solutions*. pp.6-20.
- Cowls, J., & Floridi, L. (2018). *Prolegomena to a White Paper on an Ethical Framework for a Good AI Society*. SSRN Electronic Journal.
- Erik, B, Daniel. R, & Chad. S. (2017). *Artificial intelligence and the modern*

- productivity paradox: A Clash of expectations and statistics. NBER Working Paper 24001(1).
- European Commission. (2020). The Assessment List for Trustworthy Artificial Intelligence (ALTAI) for Self Assessment.
- Factsheet: Artificial Intelligence for Europe. (2018). <https://digital-strategy.ec.europa.eu/en/library/factsheet-artificial-intelligence-europe>.
- Falk, R., & Well. (1997). Many Faces of the Correlation Coefficient. *A Journal of Statistics Education*, Vol.5, No.3.
- FLI. (2017). AI Principles. <https://futureoflife.org/open-letter/ai-principles>.
- FTC. (2020). Using Artificial Intelligence and Algorithms, FTC Bureau of Consumer Protection.
- Goodman, Bryce & Flaxman, Seth. (2016). European Union regulations on algorithmic decision-making and a ‘right to explanation’. ICML Workshop on Human Interpretability in Machine Learning.
- Google. Developer Policy Center. (2021). <https://play.google.com/intl/ko/about/developer-content-policy/>.
- Greg Adamson, R. Chatila, John C. Havens. (2019). Designing a Value-Driven Future for Ethical Autonomous and Intelligent Systems. *PROCEEDINGS OF THE IEEE*. 107(3).
- Guo, X., Shen, Z., Zhang, Y., & Wu, T. (2019). Review on the application of artificial intelligence in smart homes, *Smart Cities*, 2(3).
- EU Commission. (2019). High-level expert group on artificial intelligence (AI HLEG), Ethics Guidelines for Trustworthy AI.
- Hope Reese. (2016). Why Microsoft’s ‘Tay’ AI bot went wrong. *Tech Republic*.
- IBM. (2021). Trusted AI. <https://research.ibm.com/teams/trusted-ai>.

- IEEE. 2022). <https://ethicsinaction.ieee.org/p7000>.
- IssacAsimov. (1945). Runaround.
- Joshua A. Kroll. (2017). Accountable AI gorithm, University of Pennsylvania Law eview, 165:633, 633-704.
- K. Lerman, and T. Hogg. (2014). Leveraging position bias to improve peer recommendation. PloS one, 9(6).
- Lepri, B., Oliver, N., Letouzé, E., Pentland, A., & Vinck, P. (2018). Fair, transparent, and accountable algorithmic decision making processes: The premise, the proposed solutions, and the open challenges. Philosophy & Technology, 31(4), 611 - 627.
- Leslie, D. (2019). Understanding artificial intelligence ethics and safety: A guide for the responsible design and implementation of AI systems in the public sector. The Alan Turing Institute.
- Likert, R. (1932). A technique for the measurement of attitudes. Archives of Psychology, 22, 5 - 55.
- Michael Butterworth. (2018), The ICO and artificial intelligence: The role of fairness in the GDPR framework, Computer Law & Security Review, 34(2), 257-268.
- Ruma Falk &Arnold D. Well. (1997). Many Faces of the Correlation Coefficient. Journal of Statistics Education, 5(3).
- Russell, S. (2015). Artificial Intelligence: A Modern Approach. Pearson.
- Samuel D. Adkisson. (2018). System-Level Standards: Driverless Cars and the Future of Regulatory Design. University of Hawai'i Law Review, 40:1.
- Shahriari, K., & Shahriari, M. (2017). IEEE standard review –Ethically aligned design: A vision for prioritizing human wellbeing with artificial intelligence-

- nce and autonomous systems. In 2017 IHTC, IEEE, 197-201.
- Steven F. (2019). How Artificial Intelligence Is Reshaping Repression, *Journal of Democracy*, 30(1).
- Sunstein, C. R. (1995). Problems with Rules. *California Law Review*, 83(4), 953-1026.
- Sung, T. (2019). Understanding and application of modern basic statistics. Hakjisa.
- UNESCO. (2021). Recommendation on the Ethics of Artificial Intelligence(41 C/73). SHS, General Conference, 41st.

## 부 록

### <부록 1> 인공지능 윤리 측정지표 개발을 위한 전문가 델파이 설문지

안녕하십니까?

바쁘신 가운데 귀중한 시간을 내어 설문조사에 응해주셔서 대단히 감사합니다.

4차 산업혁명에서 핵심적으로 부상하고 있는 인공지능(AI) 기술과 인공지능 윤리(Artificial Intelligence Ethics) 문제가 급속하게 이슈화되고 있습니다. 저는 2021년 11월에 AI 기술과 사회 전반에서 활용할 “인공지능 윤리원칙 분류 모형 및 구성요소에 관한 연구”를 논문지(컴퓨터교육학회 논문지(24권 6호))에 게재하였으며, 2022년 6월에는 “인공지능 윤리원칙 기반의 인격권 및 재산 보호를 위한 인공지능 윤리 측정지표에 관한 연구” 논문을 논문지(인터넷정보학회 논문지 23권 3호)에 게재하였습니다.

본 설문조사는 2022년 6월에 연구한 “인공지능 윤리원칙 기반의 인격권 및 재산보호를 위한 인공지능 윤리 측정지표에 관한 연구”결과에 추가하여 보다 많은 인공지능 윤리 측정지표 항목을 개발하고자 인공지능 윤리관련 전문가들에게 의견을 수렴하는 설문조사입니다. 설문에 제시된 “인공지능 윤리 측정지표 항목”에 대한 타당 정도를 선택하여 주시면 됩니다.

본 조사는 비공개를 원칙으로 하오니 질문 내용에 성의 있게 응답해 주시면 연구에 귀중한 자료로 활용하겠습니다. 그리고 본 설문지에 응답하신 내용은 본 연구 목적 이외에는 사용되지 않으며 어떠한 피해나 불이익을 받을 일이 없음을 약속드립니다.


각 질문 항목에 대하여 귀하의 의견과 가장 가까운 번호에 “V” 나 “O” 표시를 해주시면 감사하겠습니다.

2022년 7월 10 일

연구자 : 성균관대학교 컴퓨터교육과 박사과정 소 순 주

※ 설문 전 참고할 사항입니다.

“인공지능 윤리원칙 분류 모형 및 구성요소”(2021.11, 컴퓨터교육학회 논문지(24권 6호))



[ 인공지능 윤리원칙 정의 ]

| 윤리원칙                     | 정의                                                                                                                                                   |
|--------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| 투명성<br>(Transparency)    | 인공지능에 의하여 어떤 행위가 왜 발생했는지 혹은 어떤 행위가 왜 발생하지 않았는지를 명확하게 검증이 가능한 원칙                                                                                      |
| 책임성<br>(Accountability)  | 인공지능 기술 및 서비스에 대한 정보 공유, 사고 등의 책임(Responsibility) 분배를 명확하게 규정하고, 배상의 정도를 정확하게 측정하여 문제 발생 시 원인을 객관적, 상세화에 의하여 그 결과를 누구에게 물어야 하는가에 대한 행위 주체별 책임에 대한 원칙 |
| 공정성<br>(Fairness)        | 인공지능이 데이터를 처리하는 과정에서부터 인공지능 기능을 이용하는 단계에 이르기까지 특정 개인이나 집단에 차별, 편향되지 않도록 공정하게 보장되어야 하는 원칙                                                             |
| 통제성<br>(Controllability) | 인공지능기술 및 서비스에 대한 인간의 제어 가능성 및 오작동에 대한 대비책을 미리 마련하고, 이용자의 이용 선택권은 최대한 보장하며, 인공지능 모니터링에 의하여 사전에 위험을 방지할 수 있는 원칙                                        |
| 안전성<br>(Safety)          | 인공지능 시스템의 판단, 예측 결과로 인해 시스템이 오작동, 위험 발생, 부작용 등이 발생하여 이용자와 환경에 악영향이 미치지 않도록 인공지능 작동 수명 전반에 걸쳐 안전하게 유지, 예방할 수 있는 원칙                                    |

다음과 같이 제시된 측정지표는 인공지능 제품이나 서비스를 제공할 때 인공지능 윤리원칙을 바탕으로 윤리측정지표로 사용하고자 하는 내용을 5점 척도로 한 질문입니다. 귀하의 의견과 가장 가까운 번호에 “V” 나 “O” 표시를 해 주시기 바랍니다.

1. 윤리원칙의 구성요소 중 설명가능성(Explainability)에 속하는 측정지표의 질문입니다.

※ 설명가능성(Explainability) : AI의 판단·예측에 대한 근거와 결과 과정을 이해관계자가 쉽게 이해할 수 있도록 단어나 문장, 그림, 데이터 등으로 표현하여 설명할 수 있게 하는 구성요소입니다.

| 측정지표 항목            | 측정지표에 대한 내용                                                                                    | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------------|------------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 안전 인증자를 위한 투명성     | 안전 인증을 평가, 보증하는 안전 인증자에게 AI의 의사결정 프로세스, 작동 기능에 대하여 검증할 수 있도록 안전 관련 소스코드와 필요한 자료를 설명, 제공하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 대중 및 이해관계자를 위한 투명성 | 공적인 AI는 사회에 미치는 영향이 중대하기 때문에 사회 전체가 해당 AI의 작동 방식, 기술, 기능을 이해할 수 있도록 대중 및 이해관계자에게 충분한 설명되어야 한다. | ①         | ②      | ③    | ④   | ⑤      |

2. 윤리원칙의 구성요소 중 추적가능성(Traceability)에 속하는 측정지표의 질문입니다.

※ 추적가능성(Traceability) : AI에 문제가 발생 시 필요한 각종 데이터에 신속하게 접근하여 문제 발생 원인을 추적할 수 있도록 하는 구성요소입니다.

| 측정지표 항목  | 측정지표에 대한 내용                                                                   | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|----------|-------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 상시 운영 감시 | AI 운영에 대한 상시 모니터링 감시로 AI가 문제 발생 시 이해관계자에게 언제든지 관련 자료를 제공해야 한다.                | ①         | ②      | ③    | ④   | ⑤      |
| 정기 운영 감사 | AI 운영에 대한 정기적인 감사 정책을 수립하여 감사를 실시하고, AI가 문제 발생 시 이해관계자에게 언제든지 관련 자료를 제공해야 한다. | ①         | ②      | ③    | ④   | ⑤      |

3. 윤리원칙의 구성요소 중에서 검증가능성(Verifiability)에 속하는 측정지표의 질문입니다.

※ 검증가능성(Verifiability) : AI의 기술과 기능, 역할이 구별되어 있기 때문에 안전성을 보장하기 위하여 일정한 기준의 시험과 검증이 가능해야 하는 구성요소입니다.

| 측정지표 항목      | 측정지표에 대한 내용                                                                | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------|----------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 안전성 시험기준 적용  | AI는 안전성 확보를 위하여 안전성 시험기준을 마련하고, 시험기준에 충족하도록 제작, 운영될 수 있게 해야 한다.            | ①         | ②      | ③    | ④   | ⑤      |
| 알고리즘의 투명성 확보 | AI가 어떠한 처리 과정을 거쳐 프로파일링을 생성하였는지 검증하는 과정이 투명하게 설명될 수 있어야 한다.                | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터의 신뢰성 | AI가 학습용으로 획득한 데이터 출처를 명확하게 제시하고, 이해관계자가 요구 시 해당 데이터를 제공하여 검증할 수 있도록 해야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터의 충분성 | AI 개발 시 의도한 기능을 정확하게 수행하기 위하여 충분한 학습용 데이터 수량과 기준을 마련하여 적용해야 한다.            | ①         | ②      | ③    | ④   | ⑤      |
| 시험, 인증 결과 제시 | AI에 적용된 기술요소를 이해관계자가 공개 요구 시 공인기관의 시험, 인증 결과를 제시할 수 있어야 한다.                | ①         | ②      | ③    | ④   | ⑤      |

4. 윤리원칙의 구성요소 중에서 준법성(Compliance)에 속하는 측정지표의 질문입니다.

※ 준법성(Compliance) : AI 이해관계자와 사용자는 사고 발생 시 책임을 명확하게 하기 위하여 제반 법규와 윤리 가이드라인을 준수해야 하는 구성요소입니다.

| 측정지표 항목      | 측정지표에 대한 내용                                                                   | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------|-------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 법적 근거 확보와 제시 | AI는 설계, 개발, 유통, 운영 전 과정에서 AI 관련 법규, 윤리, 기준에 위배되지 않는다는 근거를 명확하게 제시 할 수 있어야 한다. | ①         | ②      | ③    | ④   | ⑤      |

|                      |                                                                                             |   |   |   |   |   |
|----------------------|---------------------------------------------------------------------------------------------|---|---|---|---|---|
| 사용<br>설명서와<br>기능 일치성 | AI는 이용자에게 제공되는 AI 기능과 사용 설명서 내용이 일치 한다는 것을 증명할 수 있어야 한다.                                    | ① | ② | ③ | ④ | ⑤ |
| 사용범위<br>법적기준<br>문서화  | AI는 사용 범위, 이용자 보호, 위험 방지, 작동 방법, 이용자 책임 범위 등을 법적 기준에 맞도록 명확하게 문서화하여 이용자에게 제공해야 한다.          | ① | ② | ③ | ④ | ⑤ |
| 이용자 안전<br>우선 보호      | AI는 이용자가 AI 사용에 미숙하거나, AI 사용 시 위험상황이 발생할 경우 이용자의 안전을 최우선으로 보호해야 한다.                         | ① | ② | ③ | ④ | ⑤ |
| 신고자에<br>대한 법적<br>보호  | AI에 대한 이슈, 윤리 문제 등의 발견, 잠재적 위험이 예측될 경우 이를 신고하거나 개선을 요구하는 이용자에 법적인 안전이 보호되어야 한다.             | ① | ② | ③ | ④ | ⑤ |
| 이용자<br>요구사항<br>대응    | AI 이용자가 본인에게 부정적인 영향이 미칠 수 있다는 것을 인지하고 기능 변경 요청이나 이의 제기 시 AI 제공자는 이용자에게 적절한 대응 방안을 제시해야 한다. | ① | ② | ③ | ④ | ⑤ |

5. 윤리원칙의 구성요소 중에서 책임식별성(Responsibility Identification)에 속하는 측정지표의 질문입니다.

※ 책임식별성(Responsibility Identification) : AI는 법적, 윤리적 기준으로 이해관계자가 책임을 질 수 있도록 모든 과정을 기록, 보관하여 문제 발생 시 그 행위 주체가 누구인지 명확하게 책임을 식별할 수 있어야 하는 구성요소입니다.

| 측정지표<br>항목            | 측정지표에 대한 내용                                                                                                | 전혀<br>그렇지<br>않다 | 그렇<br>지않<br>다 | 보통<br>이다 | 그렇<br>다 | 매우<br>그렇<br>다 |
|-----------------------|------------------------------------------------------------------------------------------------------------|-----------------|---------------|----------|---------|---------------|
| 개발자<br>책임식별           | AI 개발자는 설계를 기반으로 소프트웨어를 개발하여야 하며, 소스코드 개발 및 관리, 추가, 변경, 오류 제거 등 개발자의 역할과 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다. | ①               | ②             | ③        | ④       | ⑤             |
| 학습 데이터<br>이해관계자<br>식별 | AI 학습에 사용된 데이터 분류 기준, 데이터 적용 기준 등의 의사결정에 참여한 이해관계자가 누구였는지 식별할 수 있도록 관리 되어야 한다.                             | ①               | ②             | ③        | ④       | ⑤             |

6. 윤리원칙의 구성요소 중에서 알고리즘 차별성(algorithmic differentiations)에 속하는 측정지표의 질문입니다.

※ 알고리즘 차별성(algorithmic differentiations) : AI 알고리즘을 인위적 또는 의도적으로 조작하여 알고리즘 처리결과가 편향되게 나타남으로써 공정성과 투명성, 정확성을 훼손하게 되는 구성요소입니다.

| 측정지표 항목            | 측정지표에 대한 내용                                                                               | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------------|-------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 알고리즘의 의사결정 프로세스 제공 | AI의 알고리즘이 의사결정에 포함되는 분류, 우선순위 결정, 필터링, 적용 데이터 항목 등에 대한 처리 프로세스를 이해관계자가 요구 시 제공할 수 있어야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 차별적 불이익 방지         | AI의 알고리즘은 이용자가 특정 부류나 계층 또는 개인에게 손해, 차별, 불이익이 발생하지 않도록 개발되어야 한다.                          | ①         | ②      | ③    | ④   | ⑤      |

7. 윤리원칙의 구성요소 중에서 데이터 편향성(Data bias))에 속하는 측정지표의 질문입니다.

※ 데이터 편향성(Data bias) : AI 학습용 데이터를 수집, 가공, 반영하는 과정에서 인위적 또는 의도적으로 개입하거나 조작하여 AI 처리결과가 편향되게 나타남으로써 공정성과 신뢰성을 훼손하게 되는 구성요소입니다.

| 측정지표 항목           | 측정지표에 대한 내용                                                                     | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|-------------------|---------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 데이터 분류 기준 정의 및 적용 | AI 학습용 데이터 분류는 관련 산업의 표준분류 체계를 적용하며, 각 분류별로 균일한 수량을 적용할 수 있도록 기준을 마련하여 적용해야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 데이터 균일성 확보        | AI 학습용 데이터는 분류, 탐지, 인식, 이해, 예측 등 카테고리별 인스턴스 수량의 균일성과 적정 비율을 확보하여 적용해야 한다.       | ①         | ②      | ③    | ④   | ⑤      |
| 기존 사회의 편향성 방지     | AI 학습용 데이터는 편향성을 방지하기 위하여 기존 사회가 가지는 사회적 데이터를 그대로 사용하지 않고 시대적 상황을 반영하여 생성해야 한다. | ①         | ②      | ③    | ④   | ⑤      |

8. 윤리원칙의 구성요소 중에서 접근성(Accessibility)에 속하는 측정지표의 질문입니다.

※ 접근성(Accessibility) : AI는 누구나 공평하게 이용, 통제할 수 있어야 하며, 개인이나 소수집단, 취약계층이 차별받지 않도록 공평하게 분배되어 교육, 재화, 서비스, 기술에 대한 접근 기회를 동등하게 제공할 수 있어야 하는 구성요소입니다.

| 측정지표 항목      | 측정지표에 대한 내용                                                                          | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------|--------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 접근성 보장       | AI는 성별, 연령, 장애 여부를 막론하고 소외 계층 없이 누구나 이용할 수 있도록 사용자 인터페이스 기술을 적용하여 접근성을 보장해야 한다.      | ①         | ②      | ③    | ④   | ⑤      |
| 보편적 사용자 지원   | AI는 이용자 특성에 따라 제작된 것 외에는 인종, 지역, 성별, 연령, 계층 등 차별 없이 모든 시민이 보편적으로 사용할 수 있도록 제작되어야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 사용자 접근 제한 방지 | AI는 특정 계층이나 폐쇄된 영역에서만 혜택을 받을 수 있도록 인위적 조작, 통제로 사용자 접근을 제한해서는 안 된다.                   | ①         | ②      | ③    | ④   | ⑤      |
| 이용자의 쉬운 접근성  | AI는 이용자가 AI 기능을 쉽게 동작 시킬 수 있도록 접근성과 이용 가이드를 제공해야 한다.                                 | ①         | ②      | ③    | ④   | ⑤      |

9. 윤리원칙의 구성요소 중에서 공공성(Publicness)에 속하는 측정지표의 질문입니다.

※ 공공성(Publicness) : AI 기술은 가능한 많은 사람에게 도움을 주어야 하며, AI에 의하여 창출된 경제적 이익과 혜택은 모든 인류와 광범위하게 공유되어야 하고, AI로 인한 위험과 부작용 등의 피해가 발생하지 않도록 하는 구성요소입니다.

| 측정지표 항목     | 측정지표에 대한 내용                                                                                               | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|-------------|-----------------------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 공공데이터 제공    | AI는 운영 시 일반 시민으로부터 수집한 데이터는 이해관계자가 공개 요구 시 투명하게 공개해야 한다.                                                  | ①         | ②      | ③    | ④   | ⑤      |
| 공공데이터 수집 공지 | 모든 시민을 대상으로 데이터를 수집, 분석, 활용하는 AI는 수집되는 장소, 시간, 데이터 항목에 대하여 적법성, 관리 책임, 개인 정보 관리 및 보호 정책, 안전성에 대해 공지해야 한다. | ①         | ②      | ③    | ④   | ⑤      |

|                 |                                                                                         |   |   |   |   |   |
|-----------------|-----------------------------------------------------------------------------------------|---|---|---|---|---|
| 데이터 활용 제한       | AI가 수집한 데이터는 원래 사용하고자 하는 목적 이외에는 사용하지 않도록 관리되어야 한다.                                     | ① | ② | ③ | ④ | ⑤ |
| 개인정보 수집 제한      | AI는 어떠한 경우에도 개인에게 동의를 받지 않은 개인 정보를 수집해서는 안 된다.                                          | ① | ② | ③ | ④ | ⑤ |
| 사회환경에 미치는 영향 배제 | 일반 시민이 사용하는 AI는 사회적, 정치적, 역사적, 문화적 환경에 미치는 영향이 없어야 하며, 인간의 인격권을 훼손하지 않도록 해야 한다.         | ① | ② | ③ | ④ | ⑤ |
| 인간의 생명 위협 방지    | AI는 어떠한 경우에도 인간이 생명의 위협을 받거나 사망에 이르게 할 수 있도록 하는 알고리즘을 적용해서는 안 된다.                       | ① | ② | ③ | ④ | ⑤ |
| 이해관계자의 의견 반영    | AI는 다양한 이해관계자 의견과 영향도를 반영하여 개발하고, 운영에서 발생된 이슈나 문제점을 이용자로부터 적극적으로 수렴하여 신속하게 개선, 배포해야 한다. | ① | ② | ③ | ④ | ⑤ |
| 친환경 에너지 활용      | AI를 운영하는 에너지는 친환경 에너지를 활용하여 탄소 배출을 최소화할 수 있도록 해야 한다.                                    | ① | ② | ③ | ④ | ⑤ |
| 폐기 제품 관리        | 사용이 끝난 AI 제품은 지구 환경에 오염되지 않도록 회수 프로세스, 폐기 방법을 이용자에게 공지하여야 한다.                           | ① | ② | ③ | ④ | ⑤ |
| 모든 인류에게 공정한 제공  | AI는 모든 인류, 국가, 체제, 계층에 사회적, 문화적, 정치적 영향이 미치지 않도록 공정하게 제공되어야 한다.                         | ① | ② | ③ | ④ | ⑤ |

10. 윤리원칙의 구성요소 중에서 제어 가능성(Machine controllability)에 속하는 측정지표의 질문입니다.

※ 제어 가능성(Machine controllability) : AI 이용자가 AI 오작동으로 인하여 위험 상황 발생, 법규 위반, 사회적 규범 저해 등 이상 징후를 발생 시 그 작동을 즉각적으로 제어 또는 정지시킬 수 있어야 있어야 하는 구성요소입니다.

| 측정지표 항목           | 측정지표에 대한 내용                                                              | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|-------------------|--------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 강제적 통제권 이양 배제     | AI가 기능을 수행(자율 시스템)하는 중 이용자(인간)에게 강제로 통제권을 넘길 수 없도록 한다.                   | ①         | ②      | ③    | ④   | ⑤      |
| 위험 발생 시 쉬운 접근성 제공 | AI는 이용자가 AI 기능사용 중 위험 상황 발생 시 쉽게 AI를 제어할 수 있도록 사전에 이용 가이드나 방법을 제공하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |

11. 윤리원칙의 구성요소 중에서 이용자주도성(User Initiative)에 속하는 측정지표의 질문입니다.

※ 이용자주도성(User initiative) : AI 이용자가 AI 서비스 범위 내에서 그 기능을 자율적으로 조작하여 편의성 향상, 위험 회피, 법규 준수, 사회적 규범 준수 등이 가능하게 하는 구성요소입니다.

| 측정지표 항목        | 측정지표에 대한 내용                                                      | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|----------------|------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 이용자 위험회피       | AI를 이용하는 중 위험한 상황이 발생하면 즉시 위험상황을 회피할 수 있도록 하는 제어기능을 제공한다.        | ①         | ②      | ③    | ④   | ⑤      |
| 자율적 조작         | AI는 AI 이용자에게 자율적으로 AI 작동 기능을 조작할 수 있도록 하는 기능을 제공한다.              | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 데이터 선택적 제공 | AI 이용자가 본인의 데이터를 AI에게 제공해야 할 경우 이용자는 제공할 데이터를 선택적으로 지정할 수 있게 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 데이터 삭제     | AI는 AI 이용자로부터 수집, 저장한 이용자 데이터를 이용자 본인이 직접 삭제할 수 있도록 하는 기능을 제공한다. | ①         | ②      | ③    | ④   | ⑤      |
| 작동상태 제공        | AI는 이용자가 AI의 작동상태를 상시 확인할 수 있도록 작동상태를 숫자, 문자, 이미지 등으로 표현하여 제공한다. | ①         | ②      | ③    | ④   | ⑤      |

12. 윤리원칙의 구성요소 중에서 모니터링(Monitoring)에 속하는 측정지표의 질문입니다.

※ 모니터링(Monitoring) : AI의 위험 요소를 사전에 예측하기 위하여 학습용 입력데이터의 적절성, 법규적용의 적절성, 서비스 이상 징후, 오작동에 의한 결과, 정상 작동 여부 등을 상시 감시하여 위험, 부작용 등을 예방할 수 있도록 하는 구성요소입니다.

| 측정지표 항목      | 측정지표에 대한 내용                                                  | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------|--------------------------------------------------------------|-----------|--------|------|-----|--------|
| 위험 예측 상태 제공  | AI는 작동 중에 이용자가 위험한 상황이 예측될 경우 즉시 위험 예측 정보나 메시지를 이용자에게 제공한다.  | ①         | ②      | ③    | ④   | ⑤      |
| 운영상태 상시 모니터링 | AI를 제공하는 기관(사업자)은 AI 운영 상태, 현황을 상시 모니터링할 수 있는 체계를 구축하여 수행한다. | ①         | ②      | ③    | ④   | ⑤      |

13. 윤리원칙의 구성요소 중에서 견고성(Robust)에 속하는 측정지표의 질문입니다.

※ 견고성(Robust) : AI는 외부의 간섭 및 극한적인 운영환경에서도 이용자가 의도한 수준의 AI 성능과 기능을 유지할 수 있도록 하는 구성요소입니다.

| 측정지표 항목            | 측정지표에 대한 내용                                                          | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------------|----------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 예측 결과의 동일성         | AI는 동일한 조건으로 기능을 재현 시 동일한 결과를 제공할 수 있도록 보장되어야 한다.                    | ①         | ②      | ③    | ④   | ⑤      |
| 품질기준 보장            | AI는 이용자에게 제공하기로 계획된 품질기준을 보장하며, 지속적으로 목표한 품질이 유지될 수 있도록 해야 한다.       | ①         | ②      | ③    | ④   | ⑤      |
| 학습 데이터의 정확성        | AI 학습용 데이터는 정확하고 일관성 있게 가공하여 AI 모델 성능이 품질 검증 기준의 일정 목표 수준에 부합하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 기능의 지속적 업그레이드 및 배포 | AI는 최신 데이터 적용과 기술을 적용하여 지속적인 업그레이드와 배포가 이루어질 수 있도록 해야 한다.            | ①         | ②      | ③    | ④   | ⑤      |
| 기능 프로세스의 정확한 정의    | AI 제공자는 이용자가 기능의 정확도를 인지할 수 있도록 AI의 의사결정 프로세스를 명확하게 정의하여 제공해야 한다.    | ①         | ②      | ③    | ④   | ⑤      |

14. 윤리원칙의 구성요소 중에서 보안성(Security)에 속하는 측정지표의 질문입니다.

※ 보안성(Security) : AI 시스템은 이용자로부터 비인가된 정보를 수집할 수 없어야 하며, 해킹 등 외부 공격으로부터 보호해야 하고, 기밀성, 무결성, 가용성을 확보할 수 있도록 보안 검증이나 타당성이 확인되어야 하는 구성요소입니다.

| 측정지표 항목       | 측정지표에 대한 내용                                                         | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|---------------|---------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 비인가자 연결 방지    | AI는 이용자 승인 없이 타인이나 다른 기기에 스스로 또는 고의로 연결(접속) 하지 않도록 해야 한다.           | ①         | ②      | ③    | ④   | ⑤      |
| 알고리즘 시큐어 코딩   | AI는 알고리즘 개발 시 시큐어코딩에 의하여 네트워크, 해킹, 백도어 등으로부터 안전을 보장받을 수 있도록 하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 이용 종료 시 정보 삭제 | AI 이용자가 AI를 폐기하거나 영구적으로 이용을 중단할 때는 이용자 전체 정보를 삭제할 수 있도록 하여야 한다.     | ①         | ②      | ③    | ④   | ⑤      |

15. 윤리원칙의 구성요소 중에서 프라이버시 보호(Privacy protection)에 속하는 측정지표의 질문입니다.

※ 프라이버시보호(Privacy protection) : AI는 이용자와 제3자의 사생활 안전과 개인정보보호 및 통신 비밀 등이 포함된 프라이버시 침해가 되지 않도록 해야 하며, 프라이버시 침해 영향평가를 받아 AI 이용 전 과정에서 개인의 프라이버시를 보호할 수 있게 하는 구성요소입니다.

| 측정지표 항목       | 측정지표에 대한 내용                                                | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|---------------|------------------------------------------------------------|-----------|--------|------|-----|--------|
| 미동의 데이터 수집 방지 | AI는 사용자의 동의 없이 어떠한 데이터도 임의로 수집할 수 없도록 방지 대책을 수립, 적용하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 데이터 주권 보장     | AI와 이용자 간의 상호작용에 의하여 생성된 모든 데이터는 이용자에게 귀속 시킬 수 있도록 하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |

- 끝까지 성의 있게 답변해 주셔서 대단히 감사합니다. -

## <부록 2 > 인공지능 윤리원칙에 기반한 인공지능 윤리 측정지표 개발과 신뢰성에 관한 설문지

안녕하십니까?

바쁘신 가운데 귀중한 시간을 내어 설문조사에 응해주셔서 대단히 감사합니다.

최근 급성장하고 있는 인공지능(AI) 기술과 인공지능 윤리(Artificial Intelligence Ethics) 문제가 급속하게 이슈화되고 있습니다. 저는 2021년 11월에 AI 기술과 사회 전반에서 활용할 “인공지능 윤리원칙 분류 모형 및 구성요소에 관한 연구”를 논문지(컴퓨터교육학회 논문지(24권 6호))에 게재 하였으며, 2022년 6월에는 “인공지능 윤리원칙 기반의 인격권 및 재산보호를 위한 인공지능 윤리 측정지표에 관한 연구” 논문을 논문지(인터넷정보학회 논문지 23권 3호)에 게재하였습니다.

본 설문조사는 신뢰 가능한 AI 제품이나 서비스가 실현 될 수 있도록 “인공지능 윤리원칙과 구성요소”를 기반으로 “인공지능 윤리 측정지표”에 관한 후속 연구를 진행하고 있습니다. 설문에 제시된 “인공지능 윤리 측정지표 항목”에 대하여 귀하의 의견을 선택하여 주시면 되겠습니다.

귀하께서 평소 AI와 AI 윤리에 대하여 생각하시는 견해를 사실대로 작성하여 주시면 감사하겠습니다.

본 조사는 비공개를 원칙으로 하오니 질문 내용에 성의 있게 응답해 주시면 연구에 귀중한 자료로 활용하겠습니다. 그리고 본 설문지에 응답하신 내용은 본 연구 목적 이외에는 사용되지 않으며 어떠한 피해나 불이익을 받을 일이 없음을 약속드립니다.

각 질문 항목에 대하여 귀하의 의견과 가장 가까운 번호에 “V” 나 “O” 표시를 해 주시면 감사하겠습니다.

2022년 8월 12 일

연구자 : 성균관대학교 컴퓨터교육과 박사과정 소 순 주

1. 인공지능 윤리의 통제성(Controllability)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 통제성(Controllability) : 인공지능기술 및 서비스에 대한 인간의 제어 가능성 및 오작동에 대한 대비책을 미리 마련하고, 이용자의 이용 선택권은 최대한 보장하며, 인공지능 모니터링에 의하여 사전에 위험을 방지할 수 있는 원칙을 의미합니다.

| 측정지표 항목           | 측정지표에 대한 내용                                                               | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|-------------------|---------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 이용자 위험회피          | AI를 이용하는 중 위험한 상황이 발생하면 즉시 위험상황을 회피할 수 있도록 하는 제어기능을 제공한다.                 | ①         | ②      | ③    | ④   | ⑤      |
| 자율적 조작            | AI는 AI 이용자에게 자율적으로 AI 작동 기능을 조작할 수 있도록 하는 기능을 제공한다.                       | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 데이터 선택적 제공    | AI 이용자가 본인의 데이터를 AI에게 제공해야 할 경우 이용자는 제공할 데이터를 선택적으로 지정할 수 있게 한다.          | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 데이터 삭제        | AI는 AI 이용자로부터 수집, 저장한 이용자 데이터를 이용자 본인이 직접 삭제할 수 있도록 하는 기능을 제공한다.          | ①         | ②      | ③    | ④   | ⑤      |
| 작동상태 제공           | AI는 이용자가 AI의 작동상태를 상시 확인할 수 있도록 작동상태를 숫자, 문자, 이미지 등으로 표현하여 제공한다.          | ①         | ②      | ③    | ④   | ⑤      |
| 위험예측 상태 제공        | AI는 작동 중에 이용자가 위험한 상황이 예측될 경우 즉시 위험 예측 정보나 메시지를 이용자에게 제공한다.               | ①         | ②      | ③    | ④   | ⑤      |
| 운영상태 상시 모니터링      | AI를 제공하는 기관(사업자)은 AI 운영 상태, 현황을 상시 모니터링할 수 있는 체계를 구축하여 수행한다.              | ①         | ②      | ③    | ④   | ⑤      |
| 정책적 통제권 이양        | AI 이용자나 운영자가 AI를 통제할 수 없는 경우 국가 (공적 기관)가 통제하도록 정책적으로 통제권을 이양한다.           | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 제어장치 제공       | AI 이용자가 직접 AI 사용, 정지 및 본인 의도에 따라 AI를 제어할 수 있는 장치나 서비스를 제공한다.              | ①         | ②      | ③    | ④   | ⑤      |
| 생명 위험시 자동 종료      | AI가 기능을 수행하는 중 인간에게 생명의 위험이 예측될 경우 즉시 자동으로 그 기능을 종료하거나 차단한다.              | ①         | ②      | ③    | ④   | ⑤      |
| 운영자 통제 및 제어       | AI 운영주체는 AI가 오작동하거나 위험 상황 발생, 이상 징후 포착 등 비정상인 경우 즉시 운영자가 통제, 제어한다.        | ①         | ②      | ③    | ④   | ⑤      |
| 위험 발생 시 쉬운 접근성 제공 | AI는 이용자가 AI 기능 사용 중 위험 상황 발생 시 쉽게 AI를 제어할 수 있도록 사전에 이용 가이드나 방법을 제공하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |

2. 인공지능 윤리의 안전성(Safety)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 안전성(Safety) : 인공지능 시스템의 판단, 예측 결과로 인해 시스템이 오작동, 위험 발생, 부작용 등이 발생하여 이용자와 환경에 악영향이 미치지 않도록 인공지능 작동 수명 전반에 걸쳐 안전하게 유지, 예방할 수 있는 원칙을 의미합니다.

| 측정지표 항목            | 측정지표에 대한 내용                                                                | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------------|----------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 인간의 생명 보호 우선       | 모든 AI는 인간의 생명 보호를 최우선 순위에 두고 제작, 운영 되어야 한다.                                | ①         | ②      | ③    | ④   | ⑤      |
| 알고리즘의 오류 관리        | AI 작동 중 예측하지 못한 오류로 AI 기능을 수행하지 못하거나, 이용자 피해 사례가 존재하는지 관리되어야 한다.           | ①         | ②      | ③    | ④   | ⑤      |
| 외부공격에 대한 견고성       | AI는 외부로부터 물리적, 기술적 해킹이나 공격을 받을 경우 이를 차단, 방지하여 AI 기능이 지속적으로 유지될 수 있어야 한다.   | ①         | ②      | ③    | ④   | ⑤      |
| 예측 결과의 동일성         | AI는 동일한 조건으로 기능을 재현 시 동일한 결과를 제공할 수 있도록 보장되어야 한다.                          | ①         | ②      | ③    | ④   | ⑤      |
| 학습 데이터의 정확성        | AI 학습용 데이터는 정확하고 일관성 있게 가공하여 AI 모델 성능이 품질 검증 기준의 일정 목표 수준에 부합하여야 한다.       | ①         | ②      | ③    | ④   | ⑤      |
| 기능의 지속적 업그레이드 및 배포 | AI는 최신 데이터 적용과 기술을 적용하여 지속적인 업그레이드와 배포가 이루어질 수 있도록 해야 한다.                  | ①         | ②      | ③    | ④   | ⑤      |
| 기능 프로세스의 정확한 정의    | AI 제공자는 이용자가 기능의 정확도를 인지할 수 있도록 AI의 의사결정 프로세스를 명확하게 정의하여 제공해야 한다.          | ①         | ②      | ③    | ④   | ⑤      |
| 안전성 시험기준 적용        | AI는 안전성 확보를 위하여 안전성 시험기준을 마련하고, 시험기준에 충족하도록 제작, 운영될 수 있게 해야 한다.            | ①         | ②      | ③    | ④   | ⑤      |
| 알고리즘의 투명성 확보       | AI가 어떠한 처리 과정을 거쳐 프로파일링을 생성하였는지 검증하는 과정이 투명하게 설명될 수 있어야 한다.                | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터의 신뢰성       | AI가 학습용으로 획득한 데이터 출처를 명확하게 제시하고, 이해관계자가 요구 시 해당 데이터를 제공하여 검증할 수 있도록 해야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터의 충분성       | AI 개발 시 의도한 기능을 정확하게 수행하기 위하여 충분한 학습용 데이터 수량과 기준을 마련하여 적용해야 한다.            | ①         | ②      | ③    | ④   | ⑤      |
| 시험, 인증 결과 제시       | AI에 적용된 기술요소를 이해관계자가 공개 요구 시 공인기관의 시험, 인증 결과를 제시할 수 있어야 한다.                | ①         | ②      | ③    | ④   | ⑤      |

3. 인공지능 윤리의 투명성(Transparency)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 투명성(Transparency) : 인공지능에 의하여 어떤 행위가 왜 발생했는지 혹은 어떤 행위가 왜 발생하지 않았는지를 명확하게 검증이 가능한 원칙을 의미합니다.

| 측정지표 항목              | 측정지표에 대한 내용                                                                                    | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|----------------------|------------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 문제 분석을 위한 데이터 제공     | AI 제공자는 AI의 오작동으로 인하여 사고나 문제 발생 시 그 원인을 찾을 수 있도록 AI가 의사 결정에 적용한 데이터를 제공해야 한다.                  | ①         | ②      | ③    | ④   | ⑤      |
| 제작 과정의 기록 보관         | AI를 제작(설계, 개발), 판매, 운용하는 과정에서 생성, 도출된 기록을 보관하여 문제 발생 시 그 원인을 찾을 수 있도록 제공해야 한다.                 | ①         | ②      | ③    | ④   | ⑤      |
| 사고 발생 이력 보관          | AI 운영 시 발생한 각종 문제점과 사고 내역을 기록, 보관하고, 향후 유사 사례 발생 시 그 원인을 찾을 수 있도록 제공해야 한다.                     | ①         | ②      | ③    | ④   | ⑤      |
| 최종 이용자를 위한 투명성       | AI의 기능과 의사결정 프로세스를 최종 이용자가 쉽게 이해할 수 있도록 간단하게 제공하여 AI에 대한 신뢰성을 높일 수 있도록 해야 한다.                  | ①         | ②      | ③    | ④   | ⑤      |
| 사고 조사자를 위한 투명성       | AI로 인하여 사고발생 시 사고 조사자에게 사고 발생 상황과 세부내용, AI가 의사결정에 사용한 데이터(로그, 정보), 처리 프로세스 등을 제공해야 한다.         | ①         | ②      | ③    | ④   | ⑤      |
| 변호사 및 전문가 증인을 위한 투명성 | AI의 사고 대응을 위해 선임된 변호사나 전문가에게 사고와 관련된 다양한 AI 관련 자료를 제공하여 법원, 보험사 등에 사고 발생 원인을 규명할 수 있도록 해야 한다.  | ①         | ②      | ③    | ④   | ⑤      |
| 이용 범위 고지 투명성         | AI의 기능과 사용범위, 기능의 한계, 예상되는 위험, 이용자가 AI에 제공하는 데이터 범위 등에 대하여 이용자에게 고지해야 한다.                      | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 데이터 수집 투명성       | AI에 사용하는 학습용 데이터의 수집 방법, 항목, 출처, 기준 등에 대한 프로세스와 정책을 이해관계자에게 설명해야 한다.                           | ①         | ②      | ③    | ④   | ⑤      |
| 안전 인증자를 위한 투명성       | 안전 인증을 평가, 보증하는 안전 인증자에게 AI의 의사결정 프로세스, 작동 기능에 대하여 검증할 수 있도록 안전 관련 소스코드와 필요한 자료를 설명, 제공하여야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 대중 및 이해관계자를 위한 투명성   | 공적인 AI는 사회에 미치는 영향이 중대하기 때문에 사회 전체가 해당 AI의 작동 방식, 기술, 기능을 이해할 수 있도록 대중 및 이해관계자에게 충분한 설명되어야 한다. | ①         | ②      | ③    | ④   | ⑤      |

4. 인공지능 윤리의 공정성(Fairness)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 공정성(Fairness) : 인공지능이 데이터를 처리하는 과정에서부터 인공지능 기능을 이용하는 단계에 이르기까지 특정 개인이나 집단에 차별, 편향되지 않도록 공정하게 보장되어야 하는 원칙을 의미합니다.

| 측정지표 항목            | 측정지표에 대한 내용                                                                                | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|--------------------|--------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 의도적 차별 요소 제한       | AI 개발 시 알고리즘 설계나 개발 단계에서 의도적으로 차별적인 요소를 삽입하지 않아야 한다.                                       | ①         | ②      | ③    | ④   | ⑤      |
| 개인 편향적 차별 제한       | AI는 불가피한 사고 예측 상황에서 개인적인 요소 (성별, 나이, 관계, 신체적 정신적 체질)에 따른 편향적 차별이 이루어져서는 안 된다.              | ①         | ②      | ③    | ④   | ⑤      |
| 불공정한 알고리즘 방지       | AI 알고리즘이 인위적으로 특정 인종, 집단, 계층, 소수자 등을 제외할 수 있도록 불공정하게 개발되어 공정성이 훼손되어서는 안 된다.                | ①         | ②      | ③    | ④   | ⑤      |
| 인간의 생명 위협 방지       | AI로 인하여 인간이 생명의 위협을 받거나 사망에 이르게 할 수 있는 알고리즘을 방지할 수 있도록 해야 한다.                              | ①         | ②      | ③    | ④   | ⑤      |
| 알고리즘의 의사결정 프로세스 제공 | AI의 알고리즘이 의사결정에 포함되는 분류, 우선순위 결정, 필터링, 적용 데이터 항목 등에 대한 처리 프로세스를 이해 관계자가 요구 시 제공할 수 있어야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 차별적 불이익 방지         | AI의 알고리즘은 이용자가 특정 부류나 계층 또는 개인에게 손해, 차별, 불이익이 발생하지 않도록 개발되어야 한다.                           | ①         | ②      | ③    | ④   | ⑤      |
| 편향적 특성 제거          | AI의 학습용 데이터는 지역, 사회 및 인종, 성별, 연령 등이 활용 의도와 무관할 경우 편향적인 특성을 제거해야 한다.                        | ①         | ②      | ③    | ④   | ⑤      |
| 데이터의 사실성           | AI의 학습용 데이터를 인위적인 환경과 조건 하에 획득해야 하는 경우 반드시 실제 환경과 상황, 특성을 반영해야 한다.                         | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터의 수량        | AI의 학습용 데이터는 분류 체계별 균일성과 비율을 고려하여 적절한 수량을 반영할 수 있도록 해야 한다.                                 | ①         | ②      | ③    | ④   | ⑤      |
| 데이터의 유효성검사         | 학습용 데이터를 이용하여 AI 모델을 훈련시켰을 때는 목표 수준의 성능을 확인하는 데이터 유효성 검사를 실시해야 한다.                         | ①         | ②      | ③    | ④   | ⑤      |
| 학습용 데이터 품질관리       | AI는 학습용 데이터의 정확성과 적합성, 안전성, 품질 확보를 위하여 데이터 품질 관리 정책을 수립하고 품질 관리 활동에 의한 양질의 데이터를 적용해야 한다.   | ①         | ②      | ③    | ④   | ⑤      |

|                   |                                                                                                           |   |   |   |   |   |
|-------------------|-----------------------------------------------------------------------------------------------------------|---|---|---|---|---|
| 데이터 편향 방지 알고리즘 적용 | AI의 학습용 데이터를 수집할 때는 데이터 편향성을 방지하기 위한 기준, 정책을 수립하여 알고리즘에 적용해야 한다.                                          | ① | ② | ③ | ④ | ⑤ |
| 데이터 분류 기준 정의 및 적용 | AI 학습용 데이터 분류는 관련 산업의 표준분류 체계를 적용하며, 각 분류별로 균일한 수량을 적용할 수 있도록 기준을 마련하여 적용해야 한다.                           | ① | ② | ③ | ④ | ⑤ |
| 데이터 균일성 확보        | AI 학습용 데이터는 분류, 탐지, 인식, 이해, 예측 등 카테고리별 인스턴스 수량의 균일성과 적정 비율을 확보하여 적용해야 한다.                                 | ① | ② | ③ | ④ | ⑤ |
| 접근성 보장            | AI는 성별, 연령, 장애 여부를 막론하고 소외 계층 없이 누구나 이용할 수 있도록 사용자 인터페이스 기술을 적용하여 접근성을 보장해야 한다.                           | ① | ② | ③ | ④ | ⑤ |
| 보편적 사용자 지원        | AI는 이용자 특성에 따라 제작된 것 외에는 인종, 지역, 성별, 연령, 계층 등 차별 없이 모든 시민이 보편적으로 사용할 수 있도록 제작되어야 한다.                      | ① | ② | ③ | ④ | ⑤ |
| 사용자 접근 제한 방지      | AI는 특정 계층이나 폐쇄된 영역에서만 혜택을 받을 수 있도록 인위적 조작, 통제로 사용자 접근을 제한해서는 안 된다.                                        | ① | ② | ③ | ④ | ⑤ |
| 이용자의 쉬운 접근성       | AI는 이용자가 AI 기능을 쉽게 동작시킬 수 있도록 접근성과 이용 가이드를 제공해야 한다.                                                       | ① | ② | ③ | ④ | ⑤ |
| 공공데이터 수집 공지       | 모든 시민을 대상으로 데이터를 수집, 분석, 활용하는 AI는 수집되는 장소, 시간, 데이터 항목에 대하여 적법성, 관리 책임, 개인 정보 관리 및 보호 정책, 안전성에 대해 공지해야 한다. | ① | ② | ③ | ④ | ⑤ |
| 데이터 활용 제한         | AI가 수집한 데이터는 원래 사용하고자 하는 목적 이외에는 사용하지 않도록 관리되어야 한다.                                                       | ① | ② | ③ | ④ | ⑤ |
| 개인정보 수집 제한        | AI는 어떠한 경우에도 개인에게 동의를 받지 않은 개인정보를 수집해서는 안 된다.                                                             | ① | ② | ③ | ④ | ⑤ |
| 사회환경에 미치는 영향 배제   | 일반 시민이 사용하는 AI는 사회적, 정치적, 역사적, 문화적 환경에 미치는 영향이 없어야 하며, 인간의 인격권을 훼손하지 않도록 해야 한다.                           | ① | ② | ③ | ④ | ⑤ |
| 인간의 생명 위협 방지      | AI는 어떠한 경우에도 인간이 생명의 위협을 받거나 사망에 이르게 할 수 있도록 하는 알고리즘을 적용해서는 안 된다.                                         | ① | ② | ③ | ④ | ⑤ |
| 이해관계자의 의견 반영      | AI는 다양한 이해관계자 의견과 영향도를 반영하여 개발하고, 운영에서 발생된 이슈나 문제점을 이용자로부터 적극적으로 수렴하여 신속하게 개선, 배포해야 한다.                   | ① | ② | ③ | ④ | ⑤ |

5. 인공지능 윤리의 보안성(Security)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 보안성(Security) : AI 시스템은 이용자로부터 비인가된 정보를 수집할 수 없어야 하며, 해킹 등 외부 공격으로부터 보호해야 하고, 기밀성, 무결성, 가용성을 확보할 수 있도록 보안 검증이나 타당성이 확인되어야 하는 요소를 의미합니다.

| 측정지표<br>항목       | 측정지표에 대한 내용                                                                  | 전혀<br>그렇지<br>않다 | 그렇<br>지않<br>다 | 보통<br>이다 | 그렇<br>다 | 매우<br>그렇<br>다 |
|------------------|------------------------------------------------------------------------------|-----------------|---------------|----------|---------|---------------|
| 보안성 인증           | AI는 기술적, 정책적 범규에 따라 기밀성, 무결성, 가용성을 확보할 수 있도록 전문기관의 보안성 인증이나 검증을 받아야 한다.      | ①               | ②             | ③        | ④       | ⑤             |
| 사용자 인증           | 사용자 인증이 필요한 AI는 사용자 인증 정책에 따라 반드시 사용자 인증을 받은 후 사용하도록 해야 한다.                  | ①               | ②             | ③        | ④       | ⑤             |
| 상호작용 데이터<br>보안   | AI와 이용자 간의 상호작용으로 수집, 축적된 데이터는 이용자 동의 없이 AI 운영자나 제3자에게 제공하면 안 된다.            | ①               | ②             | ③        | ④       | ⑤             |
| 비인가자 연결<br>방지    | AI는 이용자 승인 없이 타인이나 다른 기기에 스스로 또는 고의로 연결(접속) 하지 않도록 해야 한다.                    | ①               | ②             | ③        | ④       | ⑤             |
| 알고리즘 시큐어<br>코딩   | AI는 알고리즘 개발 시 시큐어코딩에 의하여 네트워크, 해킹, 백도어 등으로부터 안전을 보장받을 수 있도록 하여야 한다.          | ①               | ②             | ③        | ④       | ⑤             |
| 이용 종료 시<br>정보 삭제 | AI 이용자가 AI를 폐기하거나 영구적으로 이용을 중단할 때는 이용자 전체 정보를 삭제할 수 있도록 하여야 한다.              | ①               | ②             | ③        | ④       | ⑤             |
| 개인 정보보호<br>영향 평가 | AI는 이용자의 개인 정보보호 조치가 필요한 경우 개인 정보 보호 영향 평가를 받아야 한다.                          | ①               | ②             | ③        | ④       | ⑤             |
| 개인정보<br>수집고지     | AI는 이용자로부터 수집하는 개인 정보 항목, 보관 기간, 사용목적 및 적용 범위, 폐기 등을 명확하게 고지해야 한다.           | ①               | ②             | ③        | ④       | ⑤             |
| 개인정보 가명화         | AI가 수집하는 개인 정보는 개인 정보보호 관련 법규에 따라 가명화, 암호화 등으로 보호가 될 수 있도록 하여야 한다.           | ①               | ②             | ③        | ④       | ⑤             |
| 개인 민감정보<br>수집차단  | AI는 이용자나 이해관계자로부터 승인되지 않는 개인 민감 정보 수집을 차단할 수 있는 기능이 포함되어야 한다.                | ①               | ②             | ③        | ④       | ⑤             |
| 개인정보 활용          | AI가 수집한 개인 정보 활용은 이용자 동의를 득해야 하며, 목적에 부합하지 않은 추가적인 처리나 활용을 하지 않아야 한다(GDPR5조) | ①               | ②             | ③        | ④       | ⑤             |
| 미동의 데이터<br>수집 방지 | AI는 이용자의 동의 없이 어떠한 데이터도 임의로 수집할 수 없도록 방지 대책을 수립, 적용하여야 한다.                   | ①               | ②             | ③        | ④       | ⑤             |
| 데이터 주권<br>보장     | AI와 이용자 간의 상호작용에 의하여 생성된 모든 데이터는 이용자에게 귀속 시킬 수 있도록 하여야 한다.                   | ①               | ②             | ③        | ④       | ⑤             |

6. 인공지능 윤리의 사회적영향(Social Impact)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 사회적영향(Social Impact) : 인공지능은 사회 전반에 걸쳐 다양하게 사용되며, 국가, 조직, 체제, 인종, 계층 및 사회, 정치, 문화, 기술, 환경 등에 부정적인 영향이 미치지 않도록 사용되어야 함을 의미합니다.

| 측정지표 항목         | 측정지표에 대한 내용                                                                         | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|-----------------|-------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 친환경 에너지 활용      | AI를 운영하는 에너지는 친환경 에너지를 활용하여 탄소 배출을 최소화할 수 있도록 해야 한다.                                | ①         | ②      | ③    | ④   | ⑤      |
| 폐기 제품 관리        | 사용이 끝난 AI 제품은 지구 환경에 오염되지 않도록 회수 프로세스, 폐기 방법을 이용자에게 공지하여야 한다.                       | ①         | ②      | ③    | ④   | ⑤      |
| 법·제도 준수         | 개발된 AI는 설계 단계에서부터 관련 법규를 준수하고, 관련 법규에 위배되지 않았다는 근거를 제시할 수 있어야 한다.                   | ①         | ②      | ③    | ④   | ⑤      |
| 개인정보 제공 동의 획득   | AI가 개인 정보 데이터를 수집하는 경우 반드시 수집에 대한 동의와 활용, 제3자 제공 등에 대한 동의를 획득해야 한다.                 | ①         | ②      | ③    | ④   | ⑤      |
| 데이터 사용 사전 허가 획득 | AI에 사용되는 데이터가 공적, 보안, 지적재산권, 안전 등에 해당하는 경우 이해관계자에게 관련 법·제도상의 규정에 따라 사전 허가를 획득해야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 법적 근거 확보와 제시    | AI는 설계, 개발, 유통, 운영 전 과정에서 AI 관련 법규, 윤리, 기준에 위배되지 않는다는 근거를 명확하게 제시 할 수 있어야 한다.       | ①         | ②      | ③    | ④   | ⑤      |
| 사용 설명서와 기능 일치성  | AI는 이용자에게 제공되는 AI 기능과 사용 설명서 내용이 일치 한다는 것을 증명할 수 있어야 한다.                            | ①         | ②      | ③    | ④   | ⑤      |
| 사용범위 법적기준 문서화   | AI는 사용 범위, 이용자 보호, 위험 방지, 작동 방법, 이용자 책임 범위 등을 법적 기준에 맞도록 명확하게 문서화하여 이용자에게 제공해야 한다.  | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 안전 우선 보호    | AI는 이용자가 AI 사용에 미숙하거나, AI 사용 시 위험상황이 발생할 경우 이용자의 안전을 최우선으로 보호해야 한다.                 | ①         | ②      | ③    | ④   | ⑤      |
| 모든 인류에게 공정한 제공  | AI는 모든 인류, 국가, 체제, 계층에 사회적, 문화적, 정치적 영향이 미치지 않도록 공정하게 제공되어야 한다.                     | ①         | ②      | ③    | ④   | ⑤      |

7. 인공지능 윤리의 책무성(Accountability)과 관련된 윤리 측정지표 항목에 대한 질문입니다.

※ 책무성(Accountability) : 인공지능 기술 및 서비스에 대한 정보공유, 사고 등의 책임(Responsibility) 분배를 명확하게 규정하고, 배상의 정도를 정확하게 측정하여 문제 발생 시 원인을 객관적, 상세화에 의하여 그 결과를 누구에게 물어야 하는가에 대한 행위 주체별 책임에 대한 원칙을 의미합니다.

| 측정지표 항목       | 측정지표에 대한 내용                                                                                                                     | 전혀 그렇지 않다 | 그렇지 않다 | 보통이다 | 그렇다 | 매우 그렇다 |
|---------------|---------------------------------------------------------------------------------------------------------------------------------|-----------|--------|------|-----|--------|
| 상시 운영 감시      | AI 운영에 대한 상시 모니터링 감시로 AI가 문제 발생 시 이해관계자에게 언제라도 관련 자료를 제공해야 한다.                                                                  | ①         | ②      | ③    | ④   | ⑤      |
| 정기 운영 감사      | AI 운영에 대한 정기적인 감사 정책을 수립하여 감사를 실시하고, AI가 문제 발생 시 이해관계자에게 언제라도 관련 자료를 제공해야 한다.                                                   | ①         | ②      | ③    | ④   | ⑤      |
| 신고자에 대한 법적 보호 | AI에 대한 이슈, 윤리 문제 등의 발견, 잠재적 위험이 예측될 경우 이를 신고하거나 개선을 요구하는 이용자에 법적인 안전이 보호되어야 한다.                                                 | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 요구사항 대응   | AI 이용자가 본인에게 부정적인 영향이 미칠 수 있다는 것을 인지하고 기능 변경 요청이나 이의 제기 시 AI 제공자는 이용자에게 적절한 대응 방안을 제시해야 한다.                                     | ①         | ②      | ③    | ④   | ⑤      |
| 설계자 책임식별      | AI 설계자는 관련 법규를 반영하여 기획, 설계해야 하며, 이용자 안전 보호를 최우선 시 하도록 설계자의 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다.                                    | ①         | ②      | ③    | ④   | ⑤      |
| 제작자 책임 식별     | AI 제작자는 AI에 관련된 법규, 인증기준, 생명 윤리, 정보통신 윤리, 공학 윤리 등을 준수해야 하며, 제작자 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다.                               | ①         | ②      | ③    | ④   | ⑤      |
| 운영자 책임식별      | AI를 운영하는 주체는 상시 지속적으로 AI 운영 모니터링, 관리, 위험관리 등을 수행해야 하며, 운영자 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다.                                    | ①         | ②      | ③    | ④   | ⑤      |
| 이용자 책임식별      | AI 이용자는 본인의 안전 유지, 타인의 이익이나 공익 침해 금지, 최신 상태의 소프트웨어 유지 등 이용자 의무 준수 사항을 숙지하도록 하며, AI 이용에 따른 이용자 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다. | ①         | ②      | ③    | ④   | ⑤      |
| 개발자 책임식별      | AI 개발자는 설계를 기반으로 소프트웨어를 개발하여야 하며, 소스코드 개발 및 관리, 추가, 변경, 오류 제거 등 개발자의 역할과 책임 범위를 명확하게 규정하여 식별할 수 있도록 해야 한다.                      | ①         | ②      | ③    | ④   | ⑤      |

8. 다음은 설문 응답자의 일반현황에 관련된 질문입니다. 각 문항에 대해 귀하의 의견과 가장 가까운 번호에 “V” 나 “O” 표시를 해주시기 바랍니다.

| 번호 | 질문항목                  | 응답                                                                                                                                                                                                                              |
|----|-----------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | 직업<br>(인공지능<br>이해관계자) | ① AI 윤리            ② 법률가            ③ 사회학자            ④ AI 교육자<br>⑤ AI 설계자(컨설턴트 포함)    ⑥ AI 개발자<br>⑦ AI 제작자(기업, 단체)        ⑧ AI 운영 또는 도입자<br>⑨ AI 윤리 교육자                ⑩ 윤리 교육자<br>⑪ SW 종사자                      ⑫ 일반 사용자 및 기타 |
| 2  | 성별                    | ① 남    ② 여                                                                                                                                                                                                                      |
| 3  | 연령                    | ① 20세 미만    ② 20~29세    ③ 30~39세    ④ 40~49세    ⑤ 50세 이상                                                                                                                                                                        |
| 4  | 직업 경력연수               | ① 2년 이하    ② 3~5년    ③ 6~10년    ④ 11~15년    ⑤ 16년 이상                                                                                                                                                                            |
| 5  | AI 윤리 중요도             | ① 매우 중요하다    ② 중요하다    ③ 보통이다<br>④ 중요하지 않다    ⑤ 전혀 중요하지 않다                                                                                                                                                                      |
| 6  | AI 윤리 관심도             | ① 매우 높다    ② 높다    ③ 보통이다<br>④ 관심 없다    ⑤ 전혀 관심 없다                                                                                                                                                                              |

- 끝까지 성의있게 답변해 주셔서 대단히 감사합니다 -

## ABSTRACT

# A Study on the Development and Trustworthiness of Artificial Intelligence Ethical Principles Classification Model and Ethics Measurement Indicators

Soonju So

Department of Disciplinary Education

Sungkyunkwan University

Artificial intelligence is establishing itself as the most central technology among core technologies such as big data, cloud, metaverse, and IOT in the 4th industrial revolution. Artificial intelligence provides many conveniences and useful values to humans while forming mutual relationships with humans and mutual relationships between artificial intelligence. As 5G, metaverse, self-driving cars, and robots develop, artificial intelligence is getting closer to humans and being used beneficially. However, artificial intelligence does not always provide only positive functions to humans. Artificial intelligence can endanger human life, undermine personal rights, and deal a serious blow to property and information security. There is an urgent need for standards and methods for applying artificial intelligence ethics to prevent adverse effects of artificial intelligence in advance and to preemptively respond to problems when

they occur.

In this paper, based on AI ethics principles and components, trustworthiness general-purpose AI ethics measurement indicators were developed and verified so that they can be immediately used in the AI industry. In order to develop a reliable ethical measurement indicators, 50 artificial intelligence ethics measurement indicators were expanded and developed based on the research results of artificial intelligence ethical principles and components researched previously by the researcher and 40 items of artificial intelligence ethics measurement indicators. We analyzed various documents such as guidelines, charters, guidelines, regulations, policies, laws and systems related to artificial intelligence ethics at home and abroad to define ethics measurement indicators, and conducted FGI 3 times with 30 experts related to artificial intelligence ethics to identify 55 ethics Measurement indicators were derived and defined. 50 ethical metrics were expanded and developed through a Delphi survey of experts on 55 metrics derived from FGI and validity analysis of survey data. 50 ethical measurement indicators developed by extension and 40 ethical measurement indicators developed by researchers are integrated. Refer to the Trustworthy Artificial Intelligence Evaluation List (ALTAI) published by the European Union for the development of ethical measurement indicators to ensure reliability. 7 reliability variables were defined and a questionnaire was designed. A survey was conducted to verify the reliability of the integrated 90 ethical measurement indicators, and a sample of 164 people participated in the survey. For the statistical analysis of the questionnaire, the SPSS tool was used. As a result of the ethical measurement indicators analysis, the validity test results for 90 items were very high. As a result of factor analysis, suitability was verified, and

validity was secured by loading 86 variables in exploratory factor analysis. In the reliability analysis results, all variables were verified with high reliability coefficients. According to the results of the correlation analysis, 86 out of 90 ethics measurement indicators were completed as artificial intelligence ethics measurement indicators(EMI-AI) with reliability. Subsequently, as a result of an expert Delphi survey to verify the relationship between the 86 items of EMI-AI and the 69 evaluation lists of ALTAI, 61 items of the evaluation list of ALTAI were found to have common similarities with the measurement indicators items of EMI-AI. analyzed. In addition, 18 items that existed only in EMI-AI were analyzed, and 8 items in the evaluation list that existed only in ALTAI were analyzed.

The 86 items of ethical measurement indicators finally confirmed in this paper are reliable artificial intelligence ethical measurement indicators, and they have been developed universally so that they can be applied to all industries related to artificial intelligence, so they can be used not only in Korea but also abroad. It will be possible. In addition, since it is an ethical measurement indicators developed based on the artificial intelligence ethical principle classification model and components, continuous development and expansion of the measurement indicators will be possible. The significance of this thesis is that it has laid the foundation for quickly developing ethics evaluation lists, certification/inspection lists, and detailed ethics-related guidelines using artificial intelligence ethics measurement indicators.

Keyword : Artificial Intelligence Ethical Principles, Artificial Intelligence Ethical Measurement Indicators, Ethical Measurement Indicators and Trustworthiness, AI

Ethical Measurement Indicators, EMI-AI