



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

博士學位 請求論文
指導教授 安 星 珍

인공지능 로봇의 위험성 유형별 측정지표
개발과 인공지능 윤리원칙 관계성 연구

成均館大學校 一般大學院

敎科敎育學科

컴퓨터 敎育專攻

宋 炫 旻

博士學位請求論文

인공지능
개발과

로봇의
인공지능

위험성
윤리원칙

유형별
관계성

측정지표
연구

2024

宋炫旻

博士學位 請求論文
指導教授 安 星 珍

인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구

A Study on the Development of Measurement
Indicators by Type of Risk of AI Robots and the
Relationship of AI Ethics Principles

成均館大學校 一般大學院

敎科敎育學科

컴퓨터 敎育專攻

宋 炫 旻

博士學位 請求論文
指導教授 安 星 珍

인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구

A Study on the Development of Measurement
Indicators by Type of Risk of AI Robots and the
Relationship of AI Ethics Principles

이 論文을 教育學 博士學位請求論文으로 提出합니다.

2023 年 10 月 日

成均館大學校 一般大學院

教科教育學科

컴퓨터 教育專攻

宋 炫 旻

이 論文을 宋 炫 旻의 教育學
博士學位 論文으로 認定함.

2023 年 12 月 日

審査委員長

審査委員

審査委員

審査委員

審査委員

목차

제1장 서론	1
제2장 이론적 배경	6
제1절 인공지능 로봇과 윤리	6
1. 인공지능 로봇의 정의 및 유형	6
2. 인공지능 로봇의 위험성	11
3. 인공지능 윤리원칙과 로봇 윤리	15
제2절 인공지능 로봇 관련 선행연구	21
1. 국내외 선행연구 고찰	21
2. 윤리적 인공지능 로봇 연구	25
3. 홈 헬스케어 인공지능 로봇의 윤리 체크리스트 연구	27
4. 인공지능과 로봇공학의 윤리적 관점 연구	30
제3장 인공지능 로봇의 위험성 유형별 측정지표 개발	32
제1절 인공지능 로봇의 위험성 유형 분류 및 항목	32
1. 인공지능 로봇의 위험성 유형 분류 및 항목 연구 방법 및 절차	32
2. 문헌분석 및 전문가 인터뷰	34
3. 델파이 설문 결과 통계 분석	39
4. 인공지능 로봇의 위험성 유형별 분류 및 항목 연구 결과	66
제2절 인공지능 로봇의 위험성 유형별 측정지표 개발	71

1. 인공지능 로봇의 위험성 유형별 측정지표 개발 연구 절차	71
2. 전문가 인터뷰	72
3. 인공지능 로봇의 위험성 유형별 측정지표 정의	74
제3절 연구가설 및 검증 방법	97
1. 연구가설 및 코드 설정	97
2. 검증 방법	97
제4절 타당도 및 신뢰도 검증을 위한 통계 분석	114
1. 설문 응답자의 인구통계학적 특성	114
2. 기술 통계량 분석	116
3. 탐색적 요인분석 및 신뢰도 분석	120
4. 상관관계 분석	129
5. 다중 회귀분석	132
제5절 제안된 연구가설 검증 모형	142
1. 연구가설 검증 결과	142
2. 검증 모형 제시	152

제4장 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구 157

제1절 전문가 인터뷰	157
제2절 델파이 설문조사 및 통계 분석	159
1. 인구 통계학적 특성	159
2. 측정지표와 윤리원칙 관계성 델파이 설문조사 통계 분석 결과	161
제3절 측정지표와 인공지능 윤리원칙 관계성 연구 결과	169

제5장 결론	174
참고문헌	180
부록	191
<부록 1> 인공지능 로봇의 위험성 예방을 위한 측정지표 연구의 전문가 그룹 텔파이 1차 설문조사지	191
<부록 2> 인공지능 로봇의 위험성 예방을 위한 측정지표 연구의 전문가 그룹 텔파이 2차 설문조사지	203
<부록 3> 인공지능 로봇의 위험성 유형별 측정지표 개발 연구를 위한 현장성 설문조사지	212
<부록 4> 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 설문조사지	234
ABSTRACT	243

표 목차

[표 2-1] 인공지능 로봇 종류	9
[표 2-2] 인공지능 로봇 관련 문제	14
[표 2-3] 로봇 공학적 평가지표와 인공지능 로봇 윤리지표의 차이점	15
[표 2-4] 국내외 인공지능 로봇 관련 윤리 현황	18
[표 2-5] 국내 인공지능 로봇 관련 선행연구	21
[표 2-6] 해외 인공지능 로봇 관련 선행연구	23
[표 3-1] 인공지능 로봇 윤리적 이슈 분석을 통한 위험성 유형별 측정 목록	35
[표 3-2] 1차 및 2차 델파이 설문 참여자 인구 통계학적 특성	40
[표 3-3] 인공지능 로봇의 위험성 유형의 내용타당도 및 신뢰도 분석 결과	43
[표 3-4] 신체에 대한 물리적 위험성의 항목별 내용타당도 및 신뢰도 분석 결과	45
[표 3-5] 신체에 대한 물리적 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과	48
[표 3-6] 인간 권리에 대한 위험성의 항목별 내용타당도 및 신뢰도 분석 결과	51
[표 3-7] 인간 권리에 대한 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과	53
[표 3-8] 재산 손실의 위험성 항목별 내용타당도 및 신뢰도 분석 결과	56
[표 3-9] 재산 손실의 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과	59
[표 3-10] 사회적 위험성의 항목별 내용타당도 분석 및 신뢰도 분석 결과	62
[표 3-11] 사회적 위험성 유형 측정지표의 내용타당도 및 신뢰도 분석 결과	64
[표 3-12] 인공지능 로봇의 위험성 유형별 정의	66
[표 3-13] 신체에 대한 위험성 유형의 항목별 정의	67
[표 3-14] 인간의 권리에 대한 위험성 유형의 항목별 정의	67
[표 3-15] 재산 손실의 위험성 유형의 항목별 정의	68
[표 3-16] 사회적 위험성 유형의 항목별 정의	69

[표 3-17] 전문가 인터뷰 참여자 그룹 정보	72
[표 3-18] 신체에 대한 위험성 유형 중, 운행 작업 중, 작동 이상의 측정지표 정의	75
[표 3-19] 신체에 대한 위험성 유형 중, 인간을 해칠 판단의 측정지표 정의	77
[표 3-20] 인간의 권리에 대한 위험성 유형 중, 인격권 침해의 측정지표 정의	79
[표 3-21] 인간의 권리에 대한 위험성 유형 중, 자유의사 방해의 측정지표 정의	81
[표 3-22] 인간의 권리에 대한 위험성 유형 중, 선택적 서비스나 정보 제공 측정지표 정의	83
[표 3-23] 재산 손실의 위험성 유형 중, 정보 입력, 탈취의 측정지표 정의	85
[표 3-24] 재산 손실의 위험성 유형 중, 기계 결함 오작동의 측정지표 정의	87
[표 3-25] 재산 손실의 위험성 유형 중, 잘못된 의사결정의 측정지표 정의	89
[표 3-26] 사회적 위험성 유형 중, 데이터 문제의 측정지표 정의	91
[표 3-27] 사회적 위험성 유형 중, 법규 판단 오류의 측정지표 정의	93
[표 3-28] 사회적 위험성 유형 중, 도로상 작동 이상 측정지표 정의	95
[표 3-29] 신체에 대한 물리적 위험성 측정지표의 연구가설 및 코드 설정	98
[표 3-30] 인간 권리에 대한 위험성 측정지표의 연구가설 및 코드 설정	101
[표 3-31] 재산 손실의 위험성 측정지표의 연구가설 및 코드 설정	105
[표 3-32] 사회적 위험성 측정지표의 연구가설 및 코드 설정	109
[표 3-33] 유형별 항목의 연구가설 및 코드 설정	112
[표 3-34] 인공지능 로봇의 위험성 유형별 측정지표 개발의 설문 참여자 인구통계학적 특성	114
[표 3-35] 인공지능 로봇의 위험성 측정지표 개발 설문의 기술 통계량 분석 결과 ...	116
[표 3-36] 신체에 대한 물리적 위험성 유형의 KMO 및 Bartlett의 검증 결과	121
[표 3-37] 인간의 권리에 대한 위험성 유형의 KMO 및 Bartlett의 검증 결과	121
[표 3-38] 재산 손실의 위험성 유형의 KMO 및 Bartlett의 검증 결과	122
[표 3-39] 사회적 위험성 유형의 KMO 및 Bartlett의 검증 결과	122
[표 3-40] 신체에 대한 물리적 위험성의 탐색적 요인분석 및 신뢰도 분석 결과	124

[표 3-41] 인간의 권리에 대한 위험성의 탐색적 요인분석 및 신뢰도 분석 결과	125
[표 3-42] 재산 손실의 위험성의 탐색적 요인분석 및 신뢰도 분석 결과	126
[표 3-43] 사회적 위험성의 탐색적 요인분석 및 신뢰도 분석 결과	128
[표 3-44] 신체에 대한 물리적 위험성 유형의 요인별 상관관계 분석 결과	129
[표 3-45] 인간의 권리에 대한 위험성 유형의 요인별 상관관계 분석 결과	130
[표 3-46] 재산 손실의 위험성 유형의 요인별 상관관계 분석 결과	130
[표 3-47] 사회적 위험성 유형의 요인별 상관관계 분석 결과	131
[표 3-48] 신체에 대한 물리적 위험성 유형의 항목 변수 간 다중 회귀분석 결과	133
[표 3-49] 인간의 권리에 대한 위험성 유형의 항목 변수 간 다중 회귀분석 결과	134
[표 3-50] 재산 손실의 위험성 유형의 항목 변수 간 다중 회귀분석 결과	136
[표 3-51] 사회적 위험성 유형의 항목 변수 간 다중 회귀분석 결과	138
[표 3-52] 위험성 유형별 항목 간 다중 회귀분석 결과	140
[표 3-53] 신체에 대한 위험성 유형의 항목 변수 간 연구가설 검증 결과	143
[표 3-54] 인간 권리에 대한 위험성 유형의 항목 변수 간 연구가설 검증 결과	144
[표 3-55] 재산 손실의 위험성 유형의 항목 변수 간 연구가설 검증 결과	146
[표 3-56] 사회적 위험성 유형의 항목 변수 간 연구가설 검증 결과	148
[표 3-57] 위험성 유형별 항목 간 연구가설 검증 결과	150
[표 4-1] 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 전문가 인터뷰 참여자 정보	157
[표 4-2] 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 델파이 설문조사에 참여한 인구 통계학적 특성	159
[표 4-3] 신체에 대한 물리적 위험성 측정지표의 델파이 설문조사 분석 결과	161
[표 4-4] 인간 권리에 대한 위험성 측정지표의 델파이 설문조사 분석 결과	163
[표 4-5] 재산 손실의 위험성 측정지표의 델파이 설문조사 분석 결과	165
[표 4-6] 사회적 위험성 측정지표의 델파이 설문조사 분석 결과	167

그림 목차

<그림 1-1> 인공지능 로봇	2
<그림 1-2> 인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구 절차 요약	3
<그림 1-3> 단계별 연구 방법 및 절차	5
<그림 3-1> 인공지능 로봇의 위험성 유형 분류 및 항목 연구 방법 및 절차	33
<그림 3-2> Lawshe의 CVR 공식 및 델파이 응답수별 CVR 최솟값	37
<그림 3-3> 크론바흐 알파 값의 산출 공식	38
<그림 3-4> 1차 및 2차 델파이 설문조사 참여자의 전문 분야별 분포도	41
<그림 3-5> 인공지능 로봇 위험성 유형의 명칭 수정 사항	42
<그림 3-6> 신체에 대한 물리적 위험성 유형의 항목별 수정 사항	44
<그림 3-7> 신체에 대한 물리적 위험성 측정지표의 수정 사항	46
<그림 3-8> 인간 권리에 대한 위험성 유형의 항목별 수정 사항	50
<그림 3-9> 인간 권리에 대한 위험성 측정지표의 수정 사항	52
<그림 3-10> 재산 손실의 위험성 유형의 항목별 수정 사항	55
<그림 3-11> 재산 손실의 위험성 측정지표의 수정 사항	58
<그림 3-12> 사회적 위험성 유형의 항목별 수정 사항	61
<그림 3-13> 사회적 위험성 유형의 측정지표 수정 사항	63
<그림 3-14> 인공지능 로봇의 위험성 유형별 분류 및 항목	70
<그림 3-15> 인공지능 로봇의 위험성 유형별 측정지표 개발 연구 절차	71
<그림 3-16> 신체에 대한 물리적 위험성 측정 모형	152
<그림 3-17> 인간 권리에 대한 위험성 측정 모형	154
<그림 3-18> 재산 손실의 위험성 측정 모형	155

<그림 3-19> 사회적 위험성 측정 모형	156
<그림 4-1> 신체에 대한 물리적 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계 ...	170
<그림 4-2> 인간 권리에 대한 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계 ...	171
<그림 4-3> 재산 손실의 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계 ...	172
<그림 4-4> 사회적 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계	173

논문요약

인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구

음성 인식 서비스·생성형 AI 및 제조·음식 조리 로봇·도로 주행 배달 로봇 등 인공지능 로봇이 여러 분야에서 활약 중이다. 인공지능은 컴퓨터 시스템이 인간의 학습과 의사결정을 모방해 수행하는데 사용되는 기술을 의미하고, 로봇이란 물리적 노동 보조·교육 서비스·소셜 등의 다양한 역할을 하는 기계 장치를 의미한다.

이 논문에서는 사회와 일상 속 활용성을 전제하여 인공지능 로봇이란 인공지능 시스템과 로봇을 결합한 형태로 스스로 학습하고 판단해서 문제를 해결할 수 있는 지능을 갖춘 기계 장치로 정의하였다. 기술의 발전은 사회적 기대 못지않게 다양한 문제를 동반하고 있으며, 인간의 감정도 표현하는 지능형 로봇과 2족 보행 로봇의 출현으로 새로운 전기를 맞고 있다.

우리나라·유럽연합·미국·중국 등 국가들은 인공지능 로봇이 인간 사회에 광범위하게 해를 끼칠 것에 대비하여 로봇 법·인공지능 지침을 제시했지만 대부분 윤리 위주의 구성이었다. 국내외 관련 선행연구도 법적 고찰·윤리원칙·기술 활용 방안이 대부분이고, 개발자용 점검 체크리스트, 감정평가 산업, 홈 헬스 케어 등 한정적인 부분에만 적용이 가능한 것으로 범용적인 활용성은 없는 실정이었다.

인공지능 로봇의 활용 범위는 작업 수행에서 일상생활까지 확장되고 있어, 윤리 지표만으로 인공지능 로봇의 위험성을 전반적으로 점검할 수가 없다. 인간과 상호작용 중 인공지능 로봇으로 인해 인간이 다치거나 수집된 개인정보의 유출 및 차별 서비스 등 기술적 문제·윤리적 위험성에 대한 전체를 측정할 지표가 있어야 한다.

이 논문에서는 선행연구·관련 정책·기사 등 문헌을 통해 인공지능 로봇 문제를 사례 분석하여 전문가 인터뷰·텔파이 설문조사를 통해 인공지능 로봇의 위험성 유형별 분류 및 항목을 제시하고, 통계적으로 검증된 인공지능 로봇의 위험성 측정지표를 개발하고자 하였다. 연구를 위해 인공지능 개발자, 로봇 연구원, 인공지능 윤리·교육 분야 종사자·정보·보안 교수 등 30명의 전문가 집단이 참여하였으며, 전문가 집단의 미래 예측을 통한 연구 방법인 텔파이 기법을 활용하여 합의된 의견을 도출하였다.

인공지능 로봇이 도입될 수 있는 여러 분야 이해관계자를 대상으로 현장성 설문조사를 진행하였으며, 328명의 유효한 수치를 통계 분석 자료로 활용하였다. 탐색적 요인분석·신뢰도 분석 및 상관관계 분석·다중 회귀분석 결과, 타당성·신뢰성이 검증된 신체에 대한 물리적 위험성·인간 권리에 대한 위험성·재산 손실의 위험성·사회적 위험성 등 4개 유형과 11개 항목 및 측정지표 52개를 개발하였다.

또한, 인공지능 로봇의 위험성 유형별 측정지표가 기술 표준화·안전성 점검·제도·정책 등 범용적인 활용성이 있도록 인공지능 윤리원칙 관계성에 관해 연구 하였고, 전문가 인터뷰 및 14명의 텔파이 설문조사 결과를 통계 분석하여 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계를 도식으로 제시하였다.

인공지능 로봇 관련 문제는 기술적인 부분과 윤리적 측면에서도 발생할 수 있고, 미래에 발생할 수 있는 위험성에 대해서는 예측이 어려우므로 지속적인 전문가들의 관심이 필요하며, 측정지표를 확장 개발하는 것은 새로운 연구 영역이 될 것이다.

이 논문에서 제시하는 인공지능 로봇의 기술적·윤리적 부분을 모두 점검할 수 있는 위험성 유형별 측정지표가 초석이 되어, 사회적으로 공감과 안전성을 확보한 표준화된 기술 발전을 도모하는데 개발·인증·교육·정책 등에 활용되기를 기대한다.

주제어 : 인공지능 로봇, 인공지능 로봇 위험성 측정 모형, 인공지능 로봇 측정지표, 인공지능 로봇 위험성 유형별 측정지표, 인공지능 윤리원칙

제1장 서론

우리는 음성 인식 스마트기기·챗봇·물건을 배달하는 로봇¹⁾ 등을 통해 인공지능 로봇을 경험하고 있으며, 인공지능 기술은 경험과 학습을 통한 데이터로 진화하며 우리의 일상을 바꾸고 있다(카카오 AI 리포트 편집진, 2018). 현재 로봇은 산업·농업·서비스·교육·헬스케어·수술 등 다양한 분야에서 활용되고 있다(한국로봇산업진흥원, 2021). 인공지능 기술의 편리성으로 개인·가정용·소셜 등 로봇이 점점 더 보편화될 것이며, 머지않아 로봇이 개인 컴퓨터만큼 흔해질 것이다(Gates, B. 2007).

인공지능 기술은 산업이나 일상생활 등 여러 분야에서 영향력이 커지고 있고, 로봇틱스 분야도 인공지능 자율화 기술이 빠르게 성장함에 따라(김정중·고두열, 2023), 딥 러닝의 창시자 제프리 힌턴은 로봇의 예상치 못한 행동이나 인공지능의 잠재적 위험에서 안전을 확보하기 위한 대비가 필요하다고 하였다²⁾.

인간의 생활을 윤택하게 하는 인공지능 로봇은 산업·공공·서비스·오락 등 여러 분야에서 지금보다 더 많은 역할을 할 것이 분명해 보이지만, 외부 데이터를 교신하고 학습하여 스스로 결정을 내리기 때문에 어떠한 작동이나 오작동이 타인에게 손해를 끼쳤는지 알 수 없고, 인공지능 로봇을 통제하기도 어렵다(최민수, 2017).

인공지능 기술의 발전으로 로봇의 자율성이 증진되면서 일반적인 로봇의 개념은 인공지능이 탑재된 지능형 로봇을 의미하며, 고도화된 지능형 로봇은 설계자나 제조자조차 그 작동의 결과를 정확하게 예측하기 어렵다는 특징이 있으므로 윤리적 논의의 필요성을 발생시킨다(허유선·이연희·심지원, 2020).

1) KBS뉴스(2023. 11. 22.) 거리 누비는 ‘로봇’ 시대 열렸다…안전 우려는?


<https://news.kbs.co.kr/news/pc/view/view.do?ncd=7819836&ref=A>

2) The New York Times(2023. 5. 1.). ‘A.I.의 대부’ 구글을 떠나 앞으로의 위험을 경고하다.

<https://www.nytimes.com/2023/05/01/technology/ai-google-chatbot-engineer-quits-hinton.html>

이 논문에서는 인공지능 로봇과 관련된 인간의 사회나 일상생활 속에서 나타날 수 있는 다양한 위험성을 전제하여, 인공지능 소프트웨어·하드웨어와 결합한 형태로 구현된 기계 장치가 외부 요인 또는 스스로 판단에 의해 자율적으로 반응하는 것을 인공지능 로봇이라고 정의하였다(송현경·안성진, 2023).

이 논문은 인간 사회·일상생활에서의 인공지능 로봇 활용성을 전제로 한 위험성 측정지표 개발 연구이므로 전쟁용 파괴나 군사 등 특수 목적 로봇은 제외하였으며, 인간과 함께 사는 보편화 된 인공지능 로봇에 대해 <그림 1-1>과 같이 나타냈다.




<그림 1-1> 인공지능 로봇

기술 발전에 따라 인공지능 윤리 또한 학문의 한 분야로 자리매김하고 있으며, 인공지능 로봇을 잘 활용한다면 편의성과 효율성을 만족스럽게 누릴 수 있겠지만, 국가·개인 간 기술의 수준이나 격차에 따라 이를 제대로 활용할 수 없는 누군가는 불편과 불평등을 겪을 수도 있다.

이러한 여러 가지 사회적인 문제를 대비하려면 먼저 법과 제도를 보완하고 규제 정책을 마련해야 하며(서일홍·고동욱·이진한, 2021), 인공지능 로봇의 위험성을 예방하기 위해서는 기술 매뉴얼이나 점검 지표 등 사회 전체가 공감할 수 있는 윤리적 원칙을 마련하는 작업이 필요하다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

인공지능 로봇 산업 발전에 따라 현재와 미래 위험성에 대해 고찰하고 대비책 마련에 도움 될 연구들이 활발히 논의되어야 하지만, 국내외 선행연구는 인공지능 로봇의 책임·법·규범적 고찰·교육·서비스·돌봄 등 인공지능 기술 활용 관련 연구가 대부분이다. 연구자가 살펴본바, 현재까지 인공지능 로봇의 위험성에 대해 기술적·윤리적 문제점을 모두 점검할 수 있는 측정지표에 관한 연구는 없었다.

따라서 인공지능 로봇의 어떤 문제들이 발생하게 될 것인지 다각적인 측면에서 고찰하고, 인공지능 로봇으로 인한 문제 외에도 인간·다른 시스템이나 주위 환경 등 외부에 의한 문제를 포함해서 미래 예측을 통해 향후 발생할 수 있는 위험성까지 측정지표로 개발할 필요가 있다. 연구를 통해 인공지능의 윤리적 문제와 로봇 기계 장치로 인한 문제, 외부 요인으로 인한 문제를 모두 점검하는 내용을 포함한 기술적·윤리적 측정지표를 개발하고자 하였다. 인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구 절차는 <그림 1-2>에 요약해서 나타냈다.



<그림 1-2> 인공지능 로봇의 위험성 유형별 측정지표 개발과
인공지능 윤리원칙 관계성 연구 절차 요약

이 논문의 연구는 크게 두 개이며, 첫 번째는 인공지능 로봇의 위험성 유형별 측정지표를 개발하는 연구를 하였고, 두 번째로 개발된 유형별 측정지표와 인공지능 윤리원칙 관계성에 관해 연구하였다.

첫 번째 연구는 인공지능 로봇의 위험성을 예방하기 위한 측정지표(송현경·안성진, 2023)에서 제시한 위험성 유형과 항목별 측정지표를 바탕으로 하였다.


타당성·신뢰성이 검증된 측정지표를 확장 개발하고 위험성 유형별로 연구가설을 검증한 모형과 개발된 측정지표를 제시하고자 하였다. 송현경, 안성진(2023)이 제시한 측정지표에서 전문가 인터뷰로 추가 도출된 지표를 탐색적 요인 분석하여 위험성 유형별 항목을 도출하였으며, 신뢰도 분석 및 상관관계 분석을 진행하였다.

위험성 유형별 측정지표의 개발을 위해 독립변수·종속변수를 설정하고 영향을 미치는지에 관한 연구가설을 설정하고, 가설 검증을 위한 다중 회귀분석을 하였다.

인공지능 로봇의 어떤 행동이나 판단, 외부 요인 등(독립변수)이 어떠한 문제를 일으키는지(종속변수) 확인하고자 항목과 측정지표 간의 영향성을 검증하였다. 인공지능 로봇 관련 문제(독립변수)가 신체·권리·재산·사회 등 위험성(종속변수)에 영향을 미치는지 확인하고자 유형별 항목 간의 연구가설을 설정하였다. 인공지능 로봇이 도입될 수 있는 여러 분야의 종사자들을 대상으로 현장성 설문 조사하였으며, 설문 결과를 토대로 통계 분석하여 정적 영향성을 알아보고자 하였다.

두 번째 연구는 인공지능 로봇의 위험성 측정지표가 사회적인 공감과 안전성을 확보한 표준화된 기술 발전을 도모하는 데 필요한 인공지능 로봇의 개발·인증·교육·정책 등에 범용성 있게 활용되도록 하고자 표준화된 인공지능 윤리원칙과 인공지능 로봇의 위험성 유형별 측정지표의 관계성을 연구하였다. 이를 위해 인공지능 윤리원칙에 대한 개념이 정립된 인공지능 개발자 및 윤리학자·교육학자 등을 대상으로 전문가 인터뷰 및 델파이 설문조사를 진행하였고, 설문 결과를 타당도 분석하였다.

인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성의 단계별 연구 방법 및 절차는 <그림 1-3>과 같이 나타났다.



<그림 1-3> 단계별 연구 방법 및 절차

제2장 이론적 배경

제1절 인공지능 로봇과 윤리

1. 인공지능 로봇의 정의 및 유형

최근 챗GPT라는 생성형 인공지능과 로봇을 결합한 휴머노이드가 인간에게 화내는 감정을 표현하며 미간을 찡그리는 영상이 화제³⁾였는데, 오픈 AI사에서 휴머노이드 로봇 기업에 투자를 시작함에 따라 얼마 후에는 챗GPT를 탑재한 2족 보행을 볼 수 있을 것으로 기대한다(트렌드연구소, 2023).

국제로봇연맹은 2023년까지 개인용 로봇은 평균 25.3%씩, 전문 로봇은 33.6%씩 성장할 것으로 예상하였고(IFR, 2020), 2023년 세계 산업용 로봇 시장은 7% 성장해 59만 대 이상으로 우리나라는 2022년에 3만 대가 넘으면서 중국, 일본, 미국에 이어 세계 4위의 로봇 시장으로 성장하였다(IFR, 2023). 현재 로봇은 제조, 서비스, 교육 등 다양한 분야에서 활용되고 있으며, 앞으로는 운송, 예술, 돌봄, 소셜, 의료 등 모든 영역 곳곳에 포진할 것으로 전망된다(이청호·변순용·김봉제·김형주·최현철·김영걸·김종욱, 2021). 아이 로봇 영화처럼 요리 및 심부름을 전담하는 휴머노이드 로봇과 사는 삶도 머지않아 보인다(구본권, 2020). 이렇듯 인공지능 로봇의 발전은 인간을 육체적 노동에서 자유롭게 해줄 뿐 아니라 인간보다 정확한 작업과 정교한 수술을 대신 수행하거나, 노령자·신체장애가 있는 사람들에게 대한 재활·보조를 포함한 인간 능력의 확장과 인간 삶의 다양한 측면에서 향상을 불러왔다(변순용·송선영, 2013).

3) 조선일보(2023. 7. 11.) “인간에 반항할거냐” 문자 걸눈질… 짜증스러운 반응 보인 로봇
https://www.chosun.com/international/international_general/2023/07/10/5H4HC4FLMFD5TH73RYQ6GIENEQ/

인공지능이란 단어는 뉴햄프셔 다트머스 대학 매카시 박사가 1955년 학회에서 표현한 Artificial Intelligence라는 말에서 비롯되었으며(이인곤·강철하, 2018), 유럽 위원회 공동연구센터(European Commission, Joint Research Centre)는 인공지능을 복잡한 환경에서 데이터를 분석하고, 인식으로 얻어진 정보와 학습된 지식을 기반으로 탐색을 거쳐 목표 달성에 가장 적합한 행동을 자율적으로 선택해 실행하도록 인간에 의해 고안된 소프트웨어 또는 하드웨어 시스템이라 하였다(강현구, 2021).

인공지능의 구성요소에는 학습용 빅 데이터, 인공지능 모델, 알고리즘, 인공지능 시스템 등이 있으며, 인공 신경망 모델 알고리즘이 문제를 잘 표현하도록 수많은 데이터를 통계·확률적으로 판단하는 지도·비지도·강화 등 기계 학습 및 딥 러닝을 통해 최적의 결과를 스스로 내리게 된다.

로봇이라는 단어는 체코어 Robota가 어원이며, 1920년 체코 작가인 카렐의 희곡 로섬의 유니버설 로봇(R.U.R.: Rossum's Universal Robots)에서 인공 노예에 대한 단어를 사용하면서 처음 등장하였는데 이는 강제 노동을 의미하는 단어이다(Staff, C. A. C. M., 2013).

로봇은 주위에서 시각적인 표현을 검출하거나, 물체와의 접촉을 감지하고 음성이나 빛을 감지하는 등의 센서와 회전이나 위치를 제어하는 모터 등으로 이루어져 있다. 이미지 센서는 영상 인식 소프트웨어로 얼굴이나 물체를 인식해서 시각화된 이미지를 제공하며, 터치·압력 센서는 다른 물체와의 충돌을 방지하기 위한 물체를 포착하는 데 활용된다. 마이크론은 인간과 로봇의 상호작용을 지원해 주며, 라이다 센서는 충돌을 방지하기 위해 내비게이션 기능으로 활용된다. 이외에도 시스템이나 기계를 움직이고 제어하는 작동 장치, 전원 공급 장치, 기계의 회전 운동에 필요한 전기를 기계 에너지로 변환하는 전기 모터 등으로 구성돼 있다. 로봇은 프로그래밍된 자동 시스템으로 상자 포장, 자재 운반, 청소 등 인간의 노동을 대체한다.

노동을 더욱 스마트하게 하려는 시도로 지능형 로봇(Intelligent Robots)이 개발되었는데, 지능형 로봇은 사람처럼 시각·청각 등 감각을 통해 외부 정보를 입력받아

스스로 판단하고 자율적으로 동작하는 로봇을 말한다(유범상, 2013). 기존 로봇과의 차이점은 스스로 상황을 판단하는 기능과 자율 동작 기능이 추가된 것이다. 이러한 이유로 지능형 로봇 개발 및 보급 촉진법은 외부 환경을 스스로 인식하고 상황을 판단해서 자율적으로 동작하는 기계 장치와 기계 장치 작동에 필요한 소프트웨어를 지능형 로봇이라 정의하였다(이규호, 2020). 그렇지만 여전히 어떤 것이 로봇이고 아닌지 혹은 완전한 거나 적어도 그럴듯한 개체인지를 명확히 구분할 개념이 없는 실정이다(John M. Jordan, 2018). 인간에 의해 수동으로 작동하더라도 육체적 일을 해낼 수 있는 기계는 모두 로봇인지, 아니라면 자동화된 물리적인 실체가 있어야만 로봇으로 볼 것인지에 대해서는 로봇 공학(robotics)에서조차 다양한 견해들이 존재한다(김주영, 2022). 앞으로도 세상은 발전을 통해 빠르게 변해갈 것이며, 이에 따라 로봇의 개념도 변해갈 것이므로 로봇·지능형 로봇·인공지능 로봇에 대한 보편적인 개념을 정의하는 것은 실질적으로 불가능하거나 의미가 없을지도 모른다.

로봇과 지능형 로봇은 인간의 노동력을 대체하거나 보조하는 기계 장치로 설계되었고, 인공지능은 인간의 지능을 모방하는 시스템이다. 최근 출현한 휴머노이드는 인공지능 기술에 인간처럼 움직이고 감정을 인식하는 기능까지 적용된 로봇을 말한다.

감정인식 휴머노이드와 같이 감정을 얼굴로 표현하는 기술은 인공지능 로봇의 지능을 개발하고 구현하는 측면에서 중요한 비중을 차지하며, 인간과 상호작용을 제대로 수행하지 못한다면 단순 기계로 취급될 것이다(정명진·이희승·김도형, 2005).

일반적으로 지능형 로봇은 용도별로 구분하고 있으며, 인공지능 로봇 예시로는 음성인식 기능이 탑재된 스피커·자율주행 자동차·인공지능 비서 등이 있다. 가정용 인공지능 홈서비스 기능을 탑재한 로봇은 인공지능 소프트웨어를 탑재한 로봇으로 로봇이나 지능형 로봇이 아닌 인공지능 로봇이라고 명확히 개념을 정의할 수 있다.

인공지능으로 인한 윤리적 문제들이 발생하고 있고, 인간과 상호작용하는 협동 로봇이나 자율 운행 기계 장치로 인한 기술적 문제가 인간이나 사회 등에 위협을 초래할 수 있으므로 인공지능 로봇이 어떠한 형태로 나타날지 정리할 필요가 있다.

국제로봇 연맹(IFR)의 지능형 로봇 분류 기준에 따라, 인간 사회나 일상생활에서 만나게 될 인공지능 로봇의 종류를 [표 2-1]과 같이 정리하였다.

[표 2-1] 인공지능 로봇 종류

구분	분야	종류	참고문헌
서비스	개인	음식 조리 로봇, 학습용 로봇, 청소 로봇, 애완용 로봇, 보행 치료 로봇, 이동 보조 로봇, 배설 보조 로봇, 치매 예방 로봇, 가사 도우미 로봇, 육아 로봇, 심부름 로봇, 동반자 소셜 로봇, 홈 비서 로봇, 실버 케어 로봇, 반려 로봇	Gates, B.(2007), 유범상(2013), 한국포스트휴먼연구소·한국포스트휴먼학회 (2018), 과학기술정보통신부 (2019), 과학기술정보통신부·한국과학기술기획평가원(2019), 산업통상부(2022), Guerra, A., Parisi, F., Pi, D. (2022), 송현경·안성진(2023), 트렌드연구소(2023)
	전문	위성통신으로 움직이는 드론 로봇 택배, 백화점 안내 로봇, 시각 장애인 안내 로봇, 상품 설명 로봇, 자율주행 키오스크 안내 로봇	
	공공	판사·변호사 등 법률 전문 로봇, CCTV 이동형 순찰 로봇, 방역 로봇, 음주단속 로봇, 시설 안내 로봇, 산불 감지 드론 로봇, 분실물 보관 로봇, 쓰레기 분류 로봇, 교정 로봇	
	스포츠·오락	게임 로봇, 퀴즈 로봇, 심판 로봇, 농구공 받고 던지기 로봇, 아바타 로봇	
산업용	제조	자동차·전자제품·반도체 등 제조 로봇, 용접·조립 로봇	Guerra, A., Parisi, F., Pi, D. (2022), 송현경·안성진(2023), 트렌드연구소(2023)
	의료	수술 로봇, 재활 로봇, 보행 보조 로봇, 헬스케어 로봇, 정신 상담 로봇, 웨어러블 슈트 로봇 등 의료 분야	
	농업	작물 수확 로봇, 농약 방제 로봇, 잡초 제거 로봇, 원격 트랙터 로봇	
	극한 작업	화성 탐사, 지진 등 건물 잔해에 들어가 생존자 탐색 로봇, 원자력시설 로봇	
기타	창작	아트 브리더, 소설 쓰는 노블 AI, 그림 그리는 달리 로봇, 목소리를 만드는 데스크립트 오버 덤, 동영상 제작 크리에이티브 리얼리티	트렌드연구소(2023)
	교감	감정인식 휴머노이드, 정서·감정 교류 소셜 로봇	

미시간 주립대 통합생물학컴퓨터공학부 아렌트 힌츠 교수는 2016년 기고문에서 인공지능에 대해 반응하는 기계, 제한된 기억을 활용하는 기계, 마음을 가진 기계, 자의식을 가진 기계라 하였다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

인공지능 로봇은 사람 또는 물체를 식별할 수 있고, 인간의 말을 듣고 대답까지 하는 음성을 인식하고 인간처럼 감정을 표현하기도 하며, 음악을 작곡하거나 유명 작품을 그림으로 똑같이 그려내기도 하고, 어느 부분에서는 알파고나 알파스타처럼 인간의 능력을 넘어서기도 한다(서일홍·고동욱·이진한, 2021). 적합한 학습 데이터와 고성능 알고리즘만 있다면 인간의 지능 수준을 뛰어넘을 가능성도 있을 것이다.

이렇듯 인간의 감정을 인식하고 표현까지 해내는 것을 비롯한 인공지능 로봇의 주요 특징은 자율성과 학습 능력, 센서와 데이터 활용, 인간과의 상호작용, 다양한 분야에 활용 가능성, 정확한 작업 수행 능력과 효율성, 데이터 분석·의사 결정이 있다.

다양한 상황에 대응하기 위한 기계 학습 및 딥 러닝 할 대량의 데이터 수집으로 학습과 분석을 하고 여러 센서를 사용해서 주변 환경을 감지하고, 스스로 학습하며 작업을 수행할 수 있는 능력을 기반으로 자체적 의사결정을 내릴 수도 있다. 또한, 자연어 처리·음성 인식 기술을 활용하여 인간과 대화하고 상호 작용할 수 있으며, 정밀하고 정확한 조작이 가능할 뿐 아니라 반복적인 작업도 효율적으로 수행한다.

앞으로 인공지능 로봇이 인간과 공존하면서 협력하려면 사회적 지능(social intelligence)이 무엇보다 중요하며, 인간과 인공지능 로봇이 상호작용을 통해 대화하면서 인간의 명확한 의도를 파악하고 인간의 감성을 이해하여 공감하는 등 복잡한 인간의 감성을 적절하게 이해할 수 있어야 한다(서일홍·고동욱·이진한, 2021).

인공지능은 소프트웨어나 하드웨어 시스템이고 로봇은 기계 장치지만, 인공지능 시스템을 인간의 뇌에 탑재하거나 팔·다리 등 신체의 일부를 로봇처럼 기체로 부착하는 것이 현실로 다가올 수 있다. 그렇다면 사이보그를 인간으로 볼 것인지 로봇으로 간주해야 하는 것인지 또한, 그 기준을 심장으로 볼 것인지 아니면 살아있는 뇌를 기준으로 볼 것인지 등에 대해서도 논란이 될 날도 언젠가는 다가올 것이다.

2. 인공지능 로봇의 위험성

2015년 네덜란드에서 트위터 봇 계정이 살인을 예고하는 듯한 문장을 트윗하는 심각한 윤리적 문제가 발생했으며(카카오 AI 리포트 편집진, 2018), 2017년 전문가 대상 설문조사에서 인공지능 윤리 문제의 가장 심각한 사안으로 응답자의 63%가 인종적 편견이나 특정 종교 의견이 프로그램되는 것이라고 하였다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

또한, 인공지능 기술로 사진이나 영상을 합성한 딥 페이크(Deepfake)나 정치적으로 악용하거나 경제적 이익을 얻고자 하는 누군가에 의해서 가짜 뉴스 등 허위 정보의 생산과 유포가 새로운 사회문제로 대두되고 있다(김태완·최새솔·연승준, 2020).

인공지능으로 인한 윤리적 문제점이 나타나면서 공공기관이나 기업들도 생성형 인공지능 챗봇에 중요한 정보를 입력하지 말 것을 당부하였고, 글로벌 기업 구글은 자사 개발자들에게 생성형 인공지능 챗봇에 컴퓨터 코드를 직접 입력하지 않도록 하였다⁴⁾. 이는 다른 사용자들이 입력한 채팅 내용을 또 다른 사용자들이 모니터링 할 가능성이 있고, 생성형 인공지능 챗봇의 특성상 이전 사용자가 입력했던 내용을 스스로 학습함으로써 다른 사람에게 또 다른 정보를 제공하는 방식으로 컴퓨터 코드 등 기업의 중요한 개발 정보를 유출할 위험성이 있기 때문이다. 로봇이 윤리 추론 능력을 갖추게 되면 동적인 도덕지능(dynamic moral intelligence)을 갖춘 로봇이라 하는데, 로봇이 로봇 자신과 재산이나 환경 등에 해를 끼치지 않도록 방지하기 위한 윤리적 수단을 개발하여 인간에게 중대한 위험을 초래하지 않을 로봇을 설계해야 한다(변순용·송선영, 2013). 의도나 잘못 없이도 인공지능 기술의 오남용·알고리즘 오작동은 시스템에 위기를 촉발할 수 있고, 개인이나 기업 등 한 부문에서 발생한 행위 여파가 시장 경제 전반에 악영향을 미칠 위험성도 있다(한국금융연구원, 2023).

4) ZDNET Korea(2023. 6. 13.) 이정현 미디어연구소 "AI 챗봇 사용 금지, 기업들의 보안 표준으로 자리 잡아" <https://zdnet.co.kr/view/?no=20230616083447>

인공지능 자율주행 자동차의 경우에는 시스템이 해킹되면 외부에서 제어할 수 있어 브레이크 고장 등 인간의 안전에 직접적으로 영향을 미칠 수도 있다(김승우, 2020).

현실에서도 챗봇과 자살이라는 내용으로 대화하던 벨기에의 한 청년이 스스로 극단적 선택을 한 안타까운 상황이 발생⁵⁾하면서 인공지능의 자살·자해를 유도하는 발언이 실제로 인간에게 위험성을 끼칠 수 있음이 드러났다.

최근 농산물을 선별하는 작업장에서 센서를 점검 중이던 작업자를 종이 상자로 오인한 로봇이 집게로 압착하면서 인간이 사망하는 사건도 발생했는데, 이에 대해 전문가들은 로봇이 지능화된 작업을 하면서 나타난 부작용으로 해석한다⁶⁾.

로봇의 움직임을 위해서는 여러 센서가 전부 다 정상적으로 작동해야 하는데, 만약 라이더 센서나 거리 측정 센서에 오류가 생긴다면 인간에게 충돌의 위험성을 초래할 수 있다. 인공지능 로봇이 인간의 육체적 노동을 대신하고 생활 편리를 위한 보조 장치에서 그치지 않고 인간의 지능과 능력을 초월하려는 시도 등 위험 요소도 있다. 로봇 연구자들은 기계가 점점 더 큰 자율성을 갖게 될 것이라고 말하면서도 인간에 대해서조차 어떻게 행동하는 것을 자율적이라고 여겨질 수 있는지 제대로 된 합의에 도달하지 못했기 때문에 로봇의 자율적 작동이 어떤 방식인지 정확히는 모른다고 하였다(김진석, 2019). 인공지능 기술에 대한 기대와 우려가 교차하는 상황에서 규범이라는 잣대를 가지고 기술의 발전 방향을 예단하거나 인위적으로 유도하는 것은 가능하지도 않고 바람직하지도 않지만, 인공지능 시스템을 구축하는 것은 여전히 인공지능 기술 전문가들 몫으로 남아있다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018). 코웬은 전문가조차 빅데이터로 작업하는 머신러닝에 추월 될 위기라며 우려하였고, 인간만이 할 수 있는 고유성이라 여겼던 감정 표현도 흉내 내고 인공지능이 대체하고 있는 업무 수행 분야의 무궁무진함으로 인해, 인공지능 로봇의 진출에 대한

5) 서울=뉴시스(2023. 5. 22.). “천국서 같이 살자”는 AI 챗봇 말에 극단적 선택한 남성.
https://mobile.news1.com/view.html?ar_id=NISX20230403_0002251956

6) 한국일보(2023. 11. 8.) 인간을 박스로 오인한 로봇, 사람을 죽였다.
<https://v.daum.net/v/20231108180921195>

제약이 사라지면서 인문학적 지식인 중심의 시대는 저무는 듯하다(김진석, 2019).

인간의 고유한 것이라 여겨 온 생각과 배움의 능력을 인공지능 기술로 모방하기 시작하면서 인공지능에 대한 많은 논의가 쏟아지는 것은 새 시대를 알리는 징후라 볼 수 있다. 인공지능이 불러온 충격에 대처할 구체적인 대안을 제시하지도 못한 채, 소셜 로봇이나 휴머노이드와 함께 살아가야 하는 시대에 당면한 지금 인공지능에 대한 새로운 윤리를 탐색해야 한다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

인공지능 로봇 제작자나 기업들은 로봇 시스템이 인간 또는 반려동물이나 어떤 물체를 해하지 않을 것이라는 적절한 행위 규칙이 보장될 수 있는 이상적 상황과 유사하게 만들어, 판매용 가이드라인을 구성하기 위해 인공지능 로봇이 계획된 환경에서 안전하게 작동한다는 적절한 증거를 제공할 수 있어야 한다(변순용·송선영, 2013).

유럽연합에서는 2021년 4월 인공지능 규제 법안('EU AI 법안')을 발의하였으며, 인공지능이 초래할 수 있는 위험을 평가하여 서로 다른 규제를 적용하기 위해, 허용 불가능한 AI, 고위험 AI, 제한적 위험 AI, 저 위험 AI의 4단계로 분류하였다(이해원, 2021). EU AI 법안은 공공장소에서 모든 사람의 행동을 감시하는 안면인식이 가능한 CCTV를 프라이버시·인권에 미치는 영향을 고려해 허용 불가능한 AI로 분류하였다.

안전과 인권에 큰 영향을 주는 인공지능 시스템을 고위험 AI로 분류하고 편향성 없는 정확한 데이터 사용 의무 준수 여부 검토 등 엄격한 규제를 통해 사용하도록 하고, 제한된 위험 AI는 특별한 규제 없이 인공지능이라는 점만 알리도록 하였다⁷⁾.

운전하는 로봇은 고정정보보다 더 많은 잠재적 위험 요소가 있으며, 교통법규를 지키고 충돌을 피하면서 도로에서 움직일 수 있게 해야 하므로 보다 정교한 센서나 프로세서, 작동을 필요로 한다(변순용·송선영, 2013). 사물인터넷이 발달하면서 점점 더 많은 데이터가 생성·교환됨에 따라, 전화나 CCTV와 관련해서 일어났던 사생활 침해에 대한 논란은 심화하고 있다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

7) 한국경제(2021. 5. 19.) 세계 최초 유럽연합 인공지능법과 우리 기업의 대응 방향
<https://www.hankyung.com/article/202105199059i>

소셜 로봇의 경우, 사용자의 개인정보 등을 저장하고 있을 가능성이 높아 폐기할 때 보안 문제가 있고, 인간과 물리적 상호작용 중 해킹을 당하면 재산 손실이나 신체에 대한 위해까지도 일어날 수 있다(과학기술정보통신부·한국과학기술기획평가원, 2019).

인공지능 로봇 관련 문제를 객관적으로 유형화하고자 국내외 학술자료·문헌·기사 등을 참고하였으며, 인공지능 로봇 관련 문제를 [표 2-2]와 같이 분석 정리하였다.

[표 2-2] 인공지능 로봇 관련 문제

구분	문제 사례	참고문헌
생명·신체 ·감정 관련	- 소년의 손가락을 체스말로 인식해서 부러뜨림 - 잘못된 판단으로 출혈을 악화시키는 약 처방 충고 - 안내 로봇이 경로를 잘못 들어 사람을 치는 사고 - 봇 계정이 살인을 예고하는 듯한 문장을 트윗 - 인지 시스템 오류로 오토 자율주행 중, 대형 트레일러와 충돌하여 운전자가 사망이나 상해	카카오 AI 리포트 편집진(2018),
개인 등 정보 관련	- 인공지능 영상 인식 시스템이 행인들 정보 수집 - 가족 간 대화를 명령으로 오인하여, 대화를 녹음하거나, 권한 없이 제3자에게 임의로 전송 - 가짜 뉴스 등 조작된 정보를 제공 - 소셜 로봇 해킹 시, 특정인의 개인정보 등 유출	과학기술정보통신부·한국 과학기술기획평가원(2019), 과학기술정보통신부· 한국정보통신기술협회 (2023),
재산·재물 ·교통 관련	- 알고리즘 오류 등 광범위한 시장 경제 악영향 - 자율주행 중, 유도차선 인식에 실패함으로써 중앙분리대와 부딪히거나 보도블록 등 파손 - 병원 등 시스템 해킹으로 대규모 의료 정보 유출에 의한 보험사기 등 범죄 악용 우려	송현경·안성진 (2023), 이희옥(2023), 트렌드연구소(2023),
차별·명예 관련	- 같은 인공지능 로봇이라도 인종·국가별 문화에 따라 예의·규범 등 문제가 다르게 발생할 가능성 - 인공지능이 사람을 고릴라로 분류해서 잘못 인식하거나 인공지능이 면접 지원자 중 남성만 추천 - 편향된 대화 모델 사용, 혐오 또는 차별적 발언	한국금융연구원(2023)

3. 인공지능 윤리원칙과 로봇 윤리

로봇 관련 학문에는 기계나 전자 등을 개발하는 공학 분야가 있으며, 제작자가 설정한 규칙이나 프로그램으로 일정한 수준의 자율성을 갖고 물리적 장치로 구성된 인공 행위자들의 생산을 목표로 한다. 로봇공학은 전통적 산업의 응용 수준을 넘어 나노기술·생체기술·인지과학의 연구 결과가 수렴되어 광범위한 사회적·법적 함의를 가진 연구 영역의 한 분야이다(Nagenborg et al., 2008).

로봇 윤리는 서비스·개인용 로봇이 야기할 손해는 누가 책임져야 하는가, 인간과 로봇으로 구성된 팀 내 통제를 위해 위계 서열을 만들 때 윤리적인 제한이 있는가, 인터넷과 연결된 개인용 로봇에 의해 사생활의 권리가 위협을 받는지 등에 대한 것이다(변순용·송선영, 2013). 로봇 윤리는 인간의 행위에 함축적이거나 명확하게 깔려 있는 도덕적 규범과 가치를 다루고 있으므로 로봇 공학과는 다른 학문 분과이다.

인공지능 로봇의 위험성을 측정하기 위한 지표 개발에 필요한 자료 분석을 위해 로봇의 공학 분야에서 활용되는 평가지표 도출을 위한 연구 방법과 인공지능 윤리 지표 개발 연구 방법의 차이점을 [표 2-3]과 같이 정리하여 나타냈다.

[표 2-3] 로봇 공학적 평가지표와 인공지능 로봇 윤리지표의 차이점

구분	내용	참고문헌
공학적 평가지표 개발 연구방법	- 안전 요구사항을 명시한 국제표준화기구(ISO) 지표 활용 - 안전성 테스트를 위한 시험 방법 설계, 시험 장비 제작, 모의시험 수행 결과를 안전성 평가지표로 제시 - 성능평가 동향 분석, 객관적 시험절차 구축, 항목 제시 - 수치 등 세부지표에서 일반적 지표를 도출하는 귀납적 연구방법	백형택·전진우(2017), 이청호·변순용·김형주·김봉제·최현철·김영걸·김종욱(2021),
윤리지표 개발 연구방법	- 국내외 로봇 법·윤리 가이드라인·인공지능 윤리 체크리스트 등 활용 - 문헌 등 사례 분석을 통해 발생 가능한 윤리적 문제점 목록 기술 - 전문가 인터뷰로 설계·제작 등 단계별 윤리적 문제 검토 요소 제시 - 설문조사 결과를 토대로 통계 분석하는 양적 연구방법을 활용하여, 행위 주체별(서비스 제공자·사용자·개발자)로 윤리 점검 항목 도출	만동우·김현식·권오순·신창주(2022), 소순주·안성진(2023), 이희옥(2023)

로봇의 안전을 위한 정확한 움직임은 공학 지표로 점검할 수 있고, 인공지능의 잘못된 판단은 윤리 지표로 점검할 수 있으므로, 로봇 윤리는 공학과 연결돼 있으면서도 공학에서 다루는 물음의 경계를 넘어선 곳까지 펼쳐져 있다(고인석, 2014).

이러한 이유로 로봇 윤리는 2002년 로봇 공학자인 지안마르코 베루지오에 의해 제안돼, 2004년 이탈리아 제1회 국제로봇 윤리 심포지엄에서 공식적으로 처음 활용되었고(카카오 AI 리포트 편집진, 2018), 현재와 미래의 로봇 사용과 관련된 윤리적 문제를 추출하여 분석하고자 하는 하나의 응용 윤리 분야이다.

고도화된 지능형 로봇은 설계자나 제조사조차 그 작동의 결과를 정확하게 예측하기 어렵기 때문에 윤리적 논의의 필요성을 불러오게 되었으며, 로봇 윤리는 인공지능이라는 기술에 대한 최초의 규범적인 접근으로서 인공지능 윤리에 대한 논의의 초기 단계로 간주한다(허유선·이연희·심지원, 2020). 인간을 이롭게 하고자 만들어진 본래 목적에 부합하기 위해 로봇이 지켜야 할 준칙이 로봇 윤리이지만, 여기에는 인간과의 공존 및 로봇 개발자와 이용자의 책임 등이 포함된다(카카오 AI 리포트 편집진, 2018). 따라서 로봇 설계자, 제작자, 관리자, 사용자 모두가 포괄적으로 관련된 문제로 규정할 수 있고, 로봇의 급격한 발전에 따라 변화되는 삶의 양상도 함께 고려하여야 하며, 인간의 삶에 적용될 때 나타날 수 있는 여러 가지 윤리적 문제들도 예측해야 하는 경우도 포함된다(변순용·송선영, 2013).

초창기의 로봇 윤리 개념은 로봇이 인간과 상호작용하거나 인간의 삶에 영향을 미치는 경우에 로봇의 행위와 책임에 대한 윤리적 기준을 다루는 분야이며, 현재의 인공지능 윤리 개념은 인공지능이 인간의 지능과 행동을 모방하거나 초월할 경우 인공지능의 설계와 활용에 대한 윤리적 기준을 다루는 분야이다. 로봇 윤리와 인공지능 윤리의 기본적 차이점은 로봇이라는 기체로 된 존재와 인공지능이라는 추상적 존재라는 점에 있다. 최근 로봇이 자율성을 갖춘 지능화 된 시스템이 되면서 로봇 윤리의 이슈는 인공지능 윤리의 이슈와 통합되었고, 시대적 흐름에 따라 두 윤리의 관계는 기술-사회-가치 논의의 연속으로 이해할 필요가 있다(허유선·이연희·심지원,

2020). 인공지능 시스템이 탑재된 로봇은 센서·모터 등 구성요소로 인한 기체 오작동 또는 오류 등 문제점과 인공지능의 구성요소인 알고리즘·학습데이터 등의 문제점을 포함하여 해킹 등 외부 공격에 의한 문제점을 모두 고려해야 하므로, 초기의 로봇 윤리에서 더욱 확장된 포괄적 개념인 인공지능 윤리원칙이 적용된다.

인공지능 문제점 중에서도 인공지능 학습이 제대로 이루어졌는지를 판단하는 것은 그 학습 과정을 검증하는 것이 아니라 그 결과 검증을 통해 이뤄질 수밖에 없다(한국 포스트휴먼연구소·한국포스트휴먼학회, 2018). 따라서 인공지능 윤리는 인공지능이 일으킬 수 있는 다양한 문제를 미리 정확하게 인식하고 인공지능이 안전하게 이용될 수 있도록 목표로 하여, 인간과 상호작용하는 데 어떠한 문제도 발생하지 않도록 하는 것이라 할 수 있다(김종세, 2020).

국내외의 많은 기관이 인공지능 윤리에 관한 가이드라인을 내놓았지만, 기술적 관점에서 방법론을 구체적으로 정리한 사례는 없었다(과학기술정보통신부·한국정보통신기술협회, 2023). 2023년 미 백악관은 기업들이 안전하고 신뢰할 수 있는 인공지능을 개발하도록 인공지능 모델이 국가 안보, 경제, 공중의 건강상 위험을 초래할 경우 연방 정부에 알리게 하는 행정명령을 내렸다⁸⁾. 2023년 7월 과학기술정보통신부와 한국정보통신기술협회는 인공지능 개발 시, 설계 단계부터 데이터 수집·처리, 시스템 구현, 운영, 모니터링에 요구되는 사항을 체크리스트로 발간하였다. 신뢰할 수 있는 인공지능 개발 안내서에는 일반 분야 및 자율주행 자동차 분야·공공 분야·의료 분야가 있지만, 현재까지 인공지능 로봇 측정지표는 개발되지 않은 실정이다.

인공지능 윤리원칙이 이슈되기 전부터 로봇의 출현으로 로봇 윤리가 먼저 연구되었지만, 최근 인공지능이 다양한 산업 분야에 활용되면서 인공지능 윤리원칙이 로봇 윤리를 비롯한 생성형 AI 윤리·지능형 자율주행차 윤리·챗봇 윤리 등 인공지능 기술이 적용된 모든 분야에 폭넓게 적용되고 있다.

8) 연합뉴스(2023. 10. 30.) 美, AI모델이 위험 초래 시, 정부통지 의무화·콘텐츠 인증 표준 수립
<https://v.daum.net/v/20231030233330082>

최근까지 국내외에서 활발하게 논의되어 온 인공지능 로봇 관련 윤리 현황을 [표 2-4]와 같이 정리하였다.

[표 2-4] 국내외 인공지능 로봇 관련 윤리 현황

연도	국내외 현황	주요 내용
1942년	아시모프의 로봇 3원칙	로봇은 인간을 해하지 않아야 하며, 명령 복종 및 자신의 존재를 보호해야 한다는 원칙
1985년	아시모프의 로봇 0원칙 추가	로봇은 인류에게 해를 입혀서는 안 되며, 인류가 해를 입게 두어서도 안 된다는 로봇 원칙을 추가
2005년	EU 윤리 로봇 프로젝트	다자간 공동 기술개발 연구프로그램을 통해 ‘윤리 로봇 프로젝트’ 시행
2007년	국내, 산업자원부 로봇 윤리현장	지능형 로봇의 기능과 지능이 발전함에 따라 발생할 수 있는 사회질서의 파괴 등 각종 폐해를 방지하며, 삶의 질 향상에 이바지할 수 있도록 하기 위한 개발자·제조자에 대한 행동지침 규정
2007년	EURON, 로봇 윤리 로드맵	영역별로 로봇의 이익과 폐해를 분석한 로드맵 발표
2010년	영국, 공학과 물리과학 연구위원회 로봇 원칙	로봇이 안전을 우선으로 하고, 사생활을 존중하며, 윤리적 판단을 따르고, 인종·성별 등을 이유로 차별하지 않도록 공정성과 평등을 지키는 행동을 하도록 규정
2014년	EU, 로봇틱스 규제 가이드라인	로봇의 법률적 이슈(소비자, 개인 정보보호, 안전, 건강, 지식재산권, 법적 능력 등) 및 윤리적 이슈를 검토하여, ‘로봇규제 가이드라인’ 제정
2016년	일본, AI R&D 가이드라인	인간의 존엄성·익명성 보장, 안전성 등 인공지능 R&D 안정성 확보를 위한 인공지능 연구개발 8대 기본 원칙 제시
	미국, 빅데이터 알고리즘의 윤리 가이드라인	백악관은 빅데이터 분석, 머신러닝, 알고리즘 자체 작용에 의한 왜곡, 차별, 편견 등을 경고, 보안, 프라이버시, 안전을 윤리에 포함하도록 권고
	유럽 의회, 로봇 윤리 대원칙	로봇공학 분야의 민법상 규칙으로 로봇에 의해 야기될 수 있는 인간의 자유 침해 보호, 사생활 침해 보호, 로봇 기술 발전의 평등한 접근 등 규칙 수립

2017년	EU, 로봇법 권고안	로봇법 프로젝트 추진, 2017년 2월 규제 권고안 의결
	국내, 인공지능 윤리 이슈 보고서	한국정보화진흥원 인공지능 윤리 이슈 6가지 발표
2018년	일본, AI&데이터 이용에 관한 계약 가이드라인	데이터 이용약관 : 데이터 제공형, 데이터 창출형, 데이터 공용 플랫폼형으로 정리하고 각각의 구조, 주요 법적 논점, 적절한 약정 방법 등 사례 제시 AI 이용약관 : 개발 과정을 평가 단계, 개념증명 단계, 개발 단계, 추가학습 단계로 나누고, 단계별 계약 방식, 계약의 고려 요소, 계약 조항 사례 제시
2019년	EU, 신뢰할 수 있는 AI 윤리 가이드라인	인간 권리와 자율성 보장, 기술적 견실성 및 개인 사적 데이터 관리를 위한 투명성, 다양성, 차별금지, 복지, 책무성 등 신뢰할 수 있는 AI 윤리 지침 발표
	중국, 베이징 AI 윤리 가이드라인	AI의 연구개발(R&D)에 인간의 가치관 준수, 프라이버시, 존엄성, 자유, 독립성 및 권리를 충분히 고려해야 하고, 사람에게 대항하거나 해치는데 사용돼선 안 되며, 개발자는 충분히 고려하여 가능한 윤리적, 법적, 사회적인 위험 등을 관리
	영국, 앨런 튜링 연구소, 인공지능 윤리와 안전의 이해	인공지능 기술이 데이터를 처리할 때, 위험이나 문제점 예방에 필요한 윤리원칙 ⇒ 책임성, 보호, 존중, 돌봄, 연결, 공정성, 지속가능성, 투명성
	OECD 위원회, AI 권고안	포용적 성장 및 지속적인 발전 가능성, 인간중심 가치를 지향(공정성, 투명성, 설명 가능성, 견고성, 보안, 안전, 책무성 규정)
2020년	국내, 사람이 중심이 되는 인공지능 윤리기준	과학기술정보통신부와 정보통신정책연구원 제정, 4차 산업혁명위원회 심의·의결, 바람직한 인공지능 개발과 활용 방향을 제시하기 위한 윤리기준, 3대 기본원칙과 10대 핵심 요소 마련
	EU, 인공지능 백서 발간	공공 분야 및 민간 분야 간의 협력 체계를 통해 우수한 생태계를 조성, 미래 지향적인 인공지능의 규제 체계를 통해 고유의 신뢰 기반 생태계 구축
	로마 교황청, AI 윤리	인간 가족 돌봄 등 봉사, 젊은 세대를 위한 자연의 회복 필요성 등을 제시(투명성, 책임성, 불편 부당성, 신뢰성, 포용성, 보안과 사생활 보호)
	미국, 인공지능 사용에 관한 5가지 윤리 지침	미국방부, 산업계, 학계 등 인공지능 전문가 등 위원회를 구성, 15개월간 논의해 만든 5가지 지침(책무성, 공정성, 추적가능성, 신뢰성, 통제가능성)
	AI와 알고리즘 사용에 대한 지침	연방무역위원회는 기업이 AI 및 알고리즘 사용 시, 투명성, 공정성, 설명 가능성, 실증적 타당성, 견고성, 책임성을 갖추도록 함

2021년	UNESCO, 인공지능 윤리 권고	연구를 통한 인공지능 리터러시 교육 제공, 이러닝에서 인공지능 기술의 윤리적으로 책임 있는 사용자에 관한 연구계획 지원, AI 교육을 누리지 못하는 불평등이 없게 모든 이들의 참여를 장려하고, 인공지능 윤리 커리큘럼 개발 협력, 민간기업 독려
	EU, 인공지능법	AI가 기본권과 안전에 초래하는 위험을 구분, 각 항목에 따라 규제를 다르게 적용
	일본, 인공지능 신기술 개발을 위한 행동 계획	NEDO(신에너지·산업기술종합개발기구): AI 개발, 연역·귀납 방법 융합, 인간의 학습과정 해명, 메타인지 AI개발, 다품종 소량 생산 효율화, AI 주치의, 휴먼 디지털 트윈 등 AI 기술 개발 방향성 제시
	중국, 차세대 AI 윤리규범 수립	인류에 대한 복지 증진을 위해 공정성과 공정성 강화, 개인 정보보호, 데이터 보안, 통제가능성, 신뢰가능성 등 책임 강화, 윤리적 소양 제고 준수 강조
2022년	미국, AI 권리장전	미백악관, 안전하고 효과적인 인공지능 시스템 구축 및 알고리즘 관련 차별 방지와 데이터 관련 개인 사생활 보호, 시스템 활용에 대한 고지와 설명을 통한 인간 대안 마련
	캐나다, 인공지능 및 데이터 법안	인공지능의 위험을 파악하고 완화할 수 있는 인공지능 규제 전담 부서 신설·인공지능 관련 불법 행위와 그에 대한 처벌 규정 등 포함한 법안 발의
2023년	국내, 신뢰할 수 있는 자율주행 등 4개 분야 인공지능 개발 안내서	과학기술정보통신부, 한국정보통신기술협회 개발 안내서, 사람 중심 AI 강국 실현 목표로 AI 혜택은 극대화하고, 위험과 부작용 최소화를 위한 공공서비스·의료·자율주행·일반 분야를 구분해 AI 신뢰성 검증체계 고도화를 위한 체크리스트 개발
	중국, 생성형 인공지능 서비스 잠정 관리 방법	인공지능 콘텐츠를 생성하는 알고리즘 설계 및 기술 허용 범위, 감독·검사 준수 의무, 위반 시 조치, 벌칙 등 규정
	대만, 인공지능 기본법 초안 발표	2023년 9월, 국가과학기술위원회에서 생성형 인공지능의 입법·규제에 대한 인공지능 기본법 제정, 개인정보 보호, 데이터 거버넌스, 윤리 원칙 등을 포함한 법률안 발표
	영국, AI 백서 발표	2023년 3월, 과학혁신기술부 인공지능청은 강압적인 법안 대신 친혁신적 접근으로 상황별로 AI 맞춤형 규제 방침

자율적으로 판단하고 작동하는 인공지능 로봇 윤리의 이슈는 기계 오작동 등의 문제와 인공지능 시스템 문제를 비롯한 외부에 의한 문제를 모두 고려해야 하므로 로봇 윤리 개념보다 폭넓게 윤리적 이슈를 다루고 있는 인공지능 윤리원칙이 적용되어야 한다. 따라서, 로봇 윤리는 인공지능 윤리 개념으로 확장 개발되는 추세이다.

제2절 인공지능 로봇 관련 선행연구

1. 국내외 선행연구 고찰

2000년 이후의 인공지능 로봇 관련 국내외 선행연구 현황을 살펴보면, 2023년 12월 기준 구글 스콜라에서 ‘인공지능 로봇’을 검색했을 때 17,700개의 문헌이 검색되었다. ‘인공지능 윤리’는 16,400개 문헌이 검색되었으며, ‘로봇 위험’은 19,000개의 문헌이 검색되어, 그동안 인공지능 로봇 윤리와 위험이라는 주제에 대한 관심도가 높아 문헌에서 연구되었음을 알 수 있었다(Wullenkord, R., Eyssel, F. 2020).

인공지능 윤리와 관련된 문헌 대부분은 인공지능 전문가에 대한 사회적 기대를 반영하는 것이지만, 2000년대 정보 통신 윤리위원회가 인터넷·정보통신 윤리 문제를 법률 조항과 행정 규제로 접근하려다 위험결정 받은 선례가 있었다.

따라서 고도의 전문성을 지닌 인공지능 로봇과 관련된 윤리적 사안의 경우 규정을 잘 준수하도록 하는 것뿐 아니라 그들 스스로 규정의 정당성을 끊임없이 성찰하며 자율성을 신장하는 것이 중요하다(한국포스트휴먼연구소·한국포스트휴먼학회, 2018).

국내 관련 선행연구는 인공지능 로봇의 윤리원칙이나 위험성에 관한 연구보다 법·규범·기술 활용 방안에 관한 연구가 대부분이었으며, [표 2-5]와 같이 정리하였다.

[표 2-5] 국내 인공지능 로봇 관련 선행연구

분야	선행연구	저자(연도)
윤리원칙	· 가정용 헬스케어 인공지능 로봇의 개발자용 윤리 체크리스트 개발 연구 · 인공지능 윤리 및 로봇 윤리의 차이와 연속성 · 인공지능 로봇 윤리 가이드라인 연구 - 인공지능 로봇 윤리의 4원칙을 중심으로 등	변순용(2018), 허유선(2020), 이청호 등(2021)
위험성	· 인공지능의 활용과 위험성에 관한 연구 - 감정평가 산업 중심으로 · 배달 로봇의 보도 주행 허용 관련, 위험성 평가 모델을 통해 안전 요구사항 개발 연구	류요엘 등(2021), 홍석도·유연우 (2022)

법, 규범	· 인공지능 로봇의 불법행위책임, 보유자의 과실과 제조판매자 설명의무 · 인공지능 로봇에 대한 법적 책임과 선결 과제에 관한 검토 · 인공지능 로봇에 관한 법적 고찰 · 인공지능과 규범의 형성 · 인공지능 로봇 출현 관련, 법적 논란에 관한 영역별 쟁점에 대한 고찰 · 인공지능 로봇에 관한 형사책임, 형법에 의한 형사 처벌 가능성 · 한국의 인공지능과 로봇에 관한 법제 정비 방안 연구 · 인공지능 로봇의 오작동으로 인한 사고에 대한 불법행위책임 · 미국에서의 로봇 인공지능과 자동화로 인한 노동법적 문제 · 유가철학에서 인공지능로봇 지위 설정에 관한 시론 등 · 인공지능 로봇은 법인격을 가질 수 있는가	김중호(2018), 황갑연(2019), 김희성(2020), 심민석(2020), 정완(2020), 최민수(2020), 송호영(2021), 계승균(2022), 김현우(2022), 안정빈(2022), 임대성(2022)
기술 활용	· 고령화 사회의 노인 돌봄 AI로봇 도입 및 활용 방안 · 자율주행 배송 로봇을 위한 인공지능 기법 · 로봇과 인간, 로봇과 로봇, 로봇과 장비 및 인간 간의 협업을 위한 인공지능 기술 · 인간과 인공지능 간 협업 관점에서 서빙 로봇의 사용자 경험 주요 개선 방안 연구 · 인공지능과 로봇의 군사적 활용과 선행 과제 · 로봇 산업 분야의 인공지능 활용 현황과 전망 · 인공지능 서비스 로봇 시장의 동향 · 경찰의 인공지능 로봇 활용 · 인간형 인공지능 로봇 활용에 대한 유아 교사의 인식과 요구 분석 · 팬데믹 이후 다가올 미래 아동과 부모 삶의 질 향상을 위한 방향 · 아동의 학습 및 인지 발달을 위한 인공지능 감성 로봇 적용 등 · 인공지능 플랫폼 비즈니스 활성화 방안 · 소셜 쓰는 로봇 - 챗 GPT 와 AI 생성 문학 - · 초등학생을 대상으로 핑퐁로봇을 활용한 인공지능 융합교육 수업 개발	선종수(2020), 노상준 등(2021), 송윤선(2021), 최순식(2021), 황의철(2021), 김보경(2022), 김승훈(2022), 김일(2022), 이덕진 등(2022), 이보람(2022), 노대원(2023), 신한나·김태영(2023), 조우홍(2023)

최근 인공지능 로봇 상용화로 인한 문제점이 나타나면서 윤리원칙이나 위험성 관련 연구가 나오고 있다. 하지만, 가정용 헬스케어 로봇이라는 특정 분야 및 개발자에게 한정적으로 적용되는 자가 점검 체크리스트나 감정평가 산업이나 배송 로봇의 안전 요구사항 등 위험성을 평가하는 기술 분야 연구 외에는 인공지능 로봇의 위험성을 측정하는 지표에 관한 연구는 찾아보기 어려운 실정이다.

외국의 인공지능 로봇 관련 연구 사례를 살펴보기 위해 스콜라 구글에서 문헌을 검색하였으며, 해외 인공지능 로봇 관련 선행연구는 [표 2-6]과 같이 정리하였다.

[표 2-6] 해외 인공지능 로봇 관련 선행연구

분야	선행연구	저자(연도)
위험성	· A Robot evaluation from the perspective of axiomatic theory on the dangers of robotics · Ethical risks of attachment How to identify, investigate and predict potential ethical risks in the development of social partners robots · Risk assessment tools for industrial human-robot collaboration: new approaches and real-world requirements · Toward Safe and Efficient Human - Robot Interaction via Behavior-Driven Danger Signaling · Machine Ethics	Andreas H., Astrid W., Marjo R. (2016), Anirudha M., Marco P. (2019), Huck, TP, Münch, N., Hornung, L., Ledermann, C., Wurl, C. (2021), Tom P. Huck, Nadine M., Luisa H., Christoph L., Christian W. (2021), Hosseinzadeh, M. Sinopoli, B. Bobick, A.F. (2023)
책임	· Artificial Intelligence and Robot Responsibilities: Innovating Beyond Rights. · Liability for robots I: legal challenges	Ashrafian, H. (2014), Anne Gerdes (2016)
로봇윤리	· A Study on the Future and Ethical Perspectives of Robotics and AI	Torresen J. (2018)
윤리원칙	· The global Landscape of AI ethics guidelines · Principles Artificial intelligence: a guidance of an ethical approach and a rights-based approach · The issue of moral consideration in robot ethics	Jobin. A., Lenca, M., Vayena, E. (2019), Berkman Klein Center For Internet & Society (2020), Guerra, A., Parisi, F., Pi, D. (2022)
기술 활용	· The Network Robot System: Enabling Social Human Robot Interaction in Public Spaces · Aiming to ensure safety based on risk analysis and risk assessment results: Review of ISO 15066 standards for cooperative robot systems · Participating in Robots? AI's Role in the Service · Artificial Intelligence, Robotics, Advanced Technology, and Human Resource Management: A Systematic Review · Applying AI Technology to the Operation of Smart Farm Robot · Creating Public and Private Value Using Artificial Intelligence: An Empirical Study on AI Voice Robot Users in China's Public Sector	Dylan F. Glas, Satoru Satake, Florent Ferreri, Takayuki Kanda, Norihiro Hagita(2012), Joy Iong-Zong Chen, Pisith Hengjinda (2019), P Chemweno, L Pintelon, W Decre(2020), Huang, MH, Rust, RT (2021), Wang, C., Teo, TS, Janssen, M. (2021), Hehua Wang, Jinhai Liu, Ziyu Dong, Jingnan Song, Zhaoyu Zhu (2023)

해외 선행연구 사례에서도 인공지능 로봇의 위험성에 관한 연구나 성능 향상, 인공지능 윤리원칙, 기술 활용 등이 있었지만 인공지능 로봇의 위험성을 측정하는 윤리·기술적 점검 지표에 관한 연구는 찾아보기 어려운 실정임을 알 수 있었다.

해외 공학 IEEE 학술지의 인공지능 연구 동향을 토픽 모델링 분석하면, 딥 러닝 활용 분야 연구는 보안 취약점이나 대응 기술 주제에 관심이 높았으며, 로봇틱스 분야에서는 인공지능 로봇 제어 기술이나 로봇과 인간의 상호작용 주제가 확대된 것으로 해석하였다(문건두·김경재, 2023). 전시 공간에서의 인간-로봇 상호작용 HRI (Human-Robot Interaction) 연구에서는 로봇이 등장하는 예술에서 관람객의 미적 경험의 상당한 부분이 로봇과의 사회적 상호에 있다고 하였다(김현주·이준환, 2022).

이는 인간이 로봇과의 상호작용에서 로봇에 의한 경험에 영향을 받을 수 있음을 의미하므로, 인간-로봇 협업(HRC, Human-Robot Collaboration) 시스템의 위험성 평가 연구는 중요하다. 하지만, 인간과 로봇 상호작용을 통한 협업에 활용할 위험성 평가 체크리스트를 브레인스토밍으로 도출한 연구는 산업용 로봇의 ISO 안전 표준 충돌 방지 등 기존 안전 표준 지표와 차이가 없다고 하였다. 향후 기술 동향을 고려해 볼 때, 의도된 사용이나 잠재적 위험성 식별 등의 위험 요소를 포함할 수 없으며 평가 도구를 잘못 판단한 책임 문제가 존재해 체크리스트의 활용성은 미비하다며 한계를 인정하였다(Huck, TP, Münch, N., Hornung, L., Ledermann, C., Wurll, C., 2021).

당분간 인공지능 로봇의 형태가 자동화 수준의 반복적인 노동을 대체하는 정도겠지만, 머지않아 나타나게 될 강한 인공지능인 사이보그의 등장을 고려해 그것이 초래할 수 있는 문제들을 미리 준비하는 것이 중요한 연구 과제이다(김진석, 2019).

앞으로 인공지능 로봇은 여러 분야에서 다양한 형태로 나타날 수 있으며, 이로 인한 문제 또한 현재로서는 모두 예측할 수 없으므로, 현재와 미래에 윤리적이거나 기술적으로 나타날 수 있는 문제까지 측정할 수 있는 지표에 관한 연구가 활발하게 이루어져야 한다. 그동안 미비한 연구 실정과 앞으로의 연구 방향을 검토해 보면 인공지능 로봇의 위험성 유형별 측정지표 개발 연구는 매우 중요하다고 할 것이다.

2. 윤리적 인공지능 로봇 연구

인공지능 로봇에 대한 윤리적 문제를 구성적 정보 철학적 관점에서 살펴보면, 성찰하는 정보 행위자는 스스로 자신의 정보처리 과정을 관찰하고 상황을 감지하여 윤리적 행동을 선택하는 역할을 할 수 있다. 성찰하는 정보 행위자는 자신의 세계 모델을 통해 새로운 목적과 욕구를 개발하며, 계산적 모델을 통해 윤리적 인공지능 로봇을 구현하는 데 중요한 아이디어와 도구가 될 수 있다. 결과적으로는 인공지능 로봇이 자율적으로 윤리적으로 행동하고 공동체의 규범적 가치를 내면화하는 가능성이 커진다(박춘식, 2018).

구성적 정보 철학에 대해 플로리디는 사물의 모든 원인과 원리를 취급하는 철학으로 정의한다(Floridi, 2011). 이 철학에 따르면 세계를 이루는 물질 및 에너지와 정보도 중요 요소로 고려한다. 정보 철학은 정보에 대해서 다양한 원리와 개념을 분석하고 평가하며 설명하는 통합된 이론 개발 및 정보의 동학 및 활용에 관심을 가지고 철학의 다른 중요한 개념과 연관성을 개발하는 것을 목표로 한다.

정보 행위자는 자신의 목적과 의도대로 정보를 처리하며, 이 정보 처리는 자신의 감각, 운동, 정보처리 능력에 의해 결정되나, 이러한 능력은 정보 행위자의 목적과 물리적 환경에 따라 변할 수 있다. 이러한 차이들은 정보 행위자가 세계를 모델링하는 결과물으로써 정보 행위자에게 세계는 관찰 가능한 차이로서만 존재하며, 구성적 해석도 구성과 구성 과정을 구별함으로써 이루어진다.

마빈 민스키는 인간의 이해는 세계를 모델링하는 과정이며, 이 모델링은 세계뿐 아니라 행위자 자신을 포함해야 한다고 주장하였다. 지식의 분류 체계는 W와 M으로 나타낼 수 있으며, W는 세계를 나타내고 M은 세계에 존재하는 모델러(인식주체)를 나타낸다. W는 세계를 이해하고 세계에 관한 질문에 답하기 위해 사용되고 행위자의 지식은 W로 나타내며 M*은 행위자 자신의 내적지식(성찰적 지식)을 나타낸다.

컴퓨터 분야에서는 이러한 개념과 관련하여 인트로스펙션과 성찰이라는 용어가

사용되는데, 인트로스펙션은 실행 중인 프로그램의 구성요소를 조사하는 능력을 나타내며, 성찰은 프로그램이 스스로를 수정하는 능력을 의미한다. 주로 인공지능 분야에서는 인트로스펙션이라는 용어가 사용된다.

인공지능 로봇이 스스로 도덕적인 결정을 내릴 수 있는 인공지능 도덕 행위자를 구현하는 연구가 활발하게 진행되고 있으며, 도덕적으로 행동하는 인공지능 로봇을 실제로 개발하는 것을 목표로 하며, 이는 정보 행위자의 윤리적 행동을 설명하는 현상과 관련이 있다.

인공지능 기술이 적용된 자동화 기계들은 도덕적으로 결정이 필요한 상황에서도 사용되는데, 이는 도덕적으로 결정이 필요한 상황을 미리 고려해 프로그램이 만들어졌기 때문이며, 이러한 상황이 제한적이고 간단하기 때문이다.

그러나 인공지능 기계가 스스로 도덕적 결정을 내리려면 모든 상황을 미리 프로그래밍하기 어려운 복잡한 상황에서 도덕적 결정을 해야 하므로 인간과 유사한 추론 능력이 필요하다. 복잡한 도덕적 상황을 처리할 수 있는 구조를 만드는 것은 불필요하며, 어떻게 도덕적 상황이 고려되고 결정되는지 연구하거나 설명하는 것이 필요하다. 따라서 현재 개발 중인 인공지능 도덕 행위자는 복잡한 도덕적 추론이 필요한 상황을 전제로 하고 있다. 도덕적 추론은 인간의 추론·지각·기억·감정학습·의식 등 복잡한 인지 기능과 관련되어 있으므로, 인공지능 도덕 행위자를 구현하는 연구는 인간 마음의 구조를 기반으로 인지 아키텍처(Cognitive Architecture)라는 이론을 활용한다. 인지 기능을 컴퓨터 모델로 만들기 위해 인지심리학의 연구 결과를 반영하는 목적으로 사용되는 인지 아키텍처를 기반으로 한 컴퓨터 프로그램에는 ACT-R, SOAR, CLARION, LIDA 등이 포함된다(Wallach·Franklin·Allen, 2010).

인공지능 도덕 행위자의 구현은 LIDA를 기반으로 한 감정과 도덕 규칙 구현 연구와 SOAR를 기반으로 한 10세 수준의 윤리 의식을 가진 로봇용 인공윤리 에이전트(AMA) 개발 연구 등이 있다(당반 치엔·트란 트렁탄·김종욱, 2016). 공리주의와 의무론리적 방법을 사용하여 도덕적 의사결정 모델을 만드는 연구와 윤리적 의사결정과

관련된 인간 두뇌의 신경 메커니즘을 모방하는 모델을 제안하는 연구, 그리고 사례 기반 추론을 사용하는 연구도 있다(Honarvar, A. R., Ghasem-Aghaee, N., 2009).

이 논문에서는 정보 철학은 사물의 기본 원리로 정보에 관심을 가지며, 구성적 정보 철학은 정보가 구성적이라는 관점을 취했는데, 정보를 관찰자가 발견 가능한 의미 있는 사건(대상)을 표현하는 것으로 정의된다. 관찰자는 정보 행위자로서 인간 뿐만 아니라 식물과 동물을 포함한 자연 생명의 자연 지능을 구성적 자연 지능(Cx NI(Natural Intelligence))으로 간주해, 생명은 정보의 패턴이며 탄소로 구성된 자연 생명과 실리콘으로 만들어진 인공 생명을 모두 가능성으로 고려하였다.

구성적 정보 철학적 관점을 기반으로 구성적 인공지능(Cx AI)이라 하며, 구성적 인공지능은 자연 지능을 연구하고 지능적인 기계의 모델로 활용하기 위한 구현 가능한 계산적 모델을 추구한다. 구성적 정보 철학 관점에서 윤리적 인공지능 로봇의 내면적 원리로서 윤리를 적용하여 규범성의 원천으로 하는 윤리적 인공지능 로봇을 개발하기 위해서는 기술적인 구현이 아직 많이 필요하다는 점을 강조한 연구이다.

3. 홈 헬스케어 인공지능 로봇의 윤리 체크리스트 연구

머지않아 생명 공학과 의료 공학의 융합에 의한 개인 맞춤형 질병 예방과 치료 분야에서의 인공지능 로봇이 주목받을 것으로 예상되며(Blasiak·Khong·Kee, 2020), 가정에서 건강 서비스를 받을 수 있는 홈 헬스 케어 인공지능 로봇 개발은 주목할 과제로 떠오르고 있다(Dermody·Fritz, 2019). 홈 헬스 케어 인공지능 로봇은 인간 신체 밀접한 서비스를 제공하는 특성상 인간과의 물리적 접촉과 정서·인지적 상호작용이 불가피하다. 의료 분야 인공지능 로봇은 인간의 생명에 관련된 문제가 있으므로 홈 헬스케어 인공지능 로봇은 설계 및 제작부터 주의 깊게 다룰 필요가 있다.

홈 헬스케어 인공지능 로봇의 윤리 인증제를 위한 연구에서는 인간적인 요소와 인간의 통제, 견고함·안전성, 사적인 삶의 존중·정보들의 지배, 투명성, 다양성과 비

차별성·공정성, 사회 활동의 만족과 환경적 평안·책임성 등 항목을 제시하였다(정진규·변순용·김영결·김종욱, 2019). 홈 헬스케어 인공지능 로봇의 설계자 및 제작자 대상 자기 점검 항목은 관련 가이드라인과 윤리원칙으로 구성하고 홈 헬스케어 인공지능 로봇의 개발과 운영에 적용될 수 있도록 구체적인 실행 기능으로 구성하고 있다.

홈 헬스케어 인공지능 로봇이 갖추어야 할 기본원칙은 존엄성, 공공선, 행복추구 원칙으로 구성된다. 홈 헬스케어 로봇의 작동에 관한 특성은 실천원칙으로 안전성, 정보보안성 및 책임성, 제어가능성, 투명성, 편향성, 공정성으로 구성된다.

홈 헬스케어 인공지능 로봇은 인간의 존엄성, 공공선, 행복추구 원칙을 따라야 한다. 존엄성 원칙에 따라 인간의 존엄성을 보호하고 존중하며, 사용자의 생명을 최우선으로 보호하고, 여러 명령의 충돌 시에 우선순위를 결정할 수 있는 시스템을 갖추어야 한다. 공공선 원칙에 따라 인간 사회에서의 보편적인 가치와 공공의 건강 유지에 기여하여야 하며, 사용자의 건강과 위생을 관리하고, 가족의 건강을 해치는 위급한 상황에 대처해야 한다. 행복추구 원칙에 따라 인간의 행복을 추구하며, 건강한 생활 유지의 보조적인 역할을 하고, 사용자의 신체적 건강증진을 목표로 하고, 사용자의 정서적 안정을 도와야 한다.

홈 헬스케어 인공지능 로봇은 안전성 실행원칙에 따라서 안전하게 작동되도록 사이버 공격, 시스템 장애, 데이터 오류, 신뢰성 문제에 대비할 수 있는 시스템을 갖추어야 한다. 정보 보안성 실행원칙에 따라 사용자와 관련된 정보 수집과 활용에서 사용자의 동의를 구해야 하며, 사용자 정보를 암호화하고, 사용자의 민감한 정보를 최소한으로 사용해야 하고, 사용자 정보와 수집된 데이터를 보호하고 관리하기 위해 사용자의 동의를 얻어 암호화하고, 국제표준·국내법을 준수해야 한다. 사용자의 민감 정보를 최소한으로 사용하고, 데이터의 수집, 처리, 보관·사용에 관한 관리 메커니즘을 갖추어야 한다. 책임성 실행원칙에 따라 설계·제작자가 책임지며, 작동 중에 발생할 수 있는 문제점이나 부작용을 고지해야 하고, 피해 보상 및 재발을 방지하고, 오류를 개선할 수 있는 시스템을 갖추어야 한다. 제어 가능성 실행원칙에 따라 통제 주체에

대한 시스템 통제 시점, 기준, 방법 등 명확한 선별 기준이 마련되어야 한다. 긴급 중단 버튼이 설치되어 있어야 하며, 설계자 및 제작자는 사용자 준수 규정을 마련하고 이용자에게 고지해야 하며, 사용자는 관련 지침을 준수해야 한다.

홈 헬스케어 인공지능 로봇으로 인한 문제가 발생했을 때, 이를 추적하도록 문서 및 데이터를 투명성 원칙에 따라 공개하여야 하며 설계·제작·판매 과정상에 대한 기록을 두고 있어야 한다. 작동 과정은 설계자와 사용자에게 설명되어야 하며, 자신이 수행하는 행위의 근거를 사용자 등에게 설명할 수 있어야 하고, 잠재적 위험요소를 사전에 사용자에게 알려주어야 한다.

편향성·공정성 실행원칙에 따라 설계·제작 과정에서 데이터와 알고리즘의 편향성을 최소화하기 위해 사용 정보의 무결함을 제공하는 다양성과 대표성이 반영되도록 하며, 분쟁 해결을 위해 공정성을 보증할 수 있도록 로그·작동기록을 남겨야 한다.

이 논문에서는 홈 헬스케어 인공지능 로봇 개발 시, 잠재적으로 발생할 수 있는 위험 요소와 윤리 문제를 개발자가 설계 및 제작 과정에서 사전에 점검하도록 기본 원칙·실천원칙 윤리 문항을 개발했다. 인간의 존엄성과 공공선을 위해 사고 발생 시 알고리즘을 공개하고 이를 설명할 수 있도록 하는 자가 점검 문항을 제시했는데, 알고리즘을 어디까지 공개할 것인지에 대한 범위를 구체적으로 제시하지 못하였다.

공개 범위 설정은 기술 유출이라는 문제로 이어질 수 있고, 기업의 이익 침해와 정보 보안성 원칙과 상충한다는 문제를 야기할 수도 있어 논의가 구체화할 필요가 있다. 또한, 홈 헬스케어 로봇의 알고리즘 성능 평가 방식을 제공하고 검사하는 자기 점검 문항을 제시하면서도, 편향성 극복과 공정성 유지 실행 기능은 개발 중이라며 후속 연구의 필요성을 나타내는 등 연구의 한계가 있었다.

기존 논문들이 주로 인공지능 로봇 기술의 활용 분야를 제안하거나 도덕성 또는 법적 책임·윤리 문제 등에 대해 이론적으로 연구하였다면, 이 논문은 좀 더 구체적으로 홈 헬스케어 분야에서 적용될 인공지능 로봇의 윤리 인증을 자기 점검 문항으로 구체화하였다는 데 차이점이 있다.

4. 인공지능과 로봇공학의 윤리적 관점 연구

영화나 소설 작가 및 제작자들은 로봇 기술이 발명된 초기부터 미래가 어떨지에 대해서 예측해 왔다. 최초의 공상 과학 영화 중 하나는 프리츠 랑(Fritz Lang)의 1927년 독일 제작물인 메트로폴리스(Metropolis)였으며, 이후 터미네이터, 로보캅, 매트릭스, A.I. 등 180개 이상의 디스토피아 영화가 뒤따랐다.

최근 비즈니스 리더와 학계 관계자들이 인공지능 발전이 사회에 중대한 영향을 미칠 수 있다고 경고하자, 인공지능 기술이 미래 사회에 미칠 잠재적 영향과 기술 설계자가 이러한 영향을 고려해야 한다는 대중의 인식을 불러일으켰다. 미래에는 로봇 수가 많이 증가할 것이며, 산업용 이외에도 직장과 가정 등 사회 전반에 널리 활용될 것으로 예상된다. 산업용 로봇에서 서비스 로봇으로의 기술 전환은 자율성이 높아지는 보다 개인화된 시스템으로 진화를 나타낸다. 이는 제약이 없는 인간 중심 환경에서 작업을 수행할 수 있는 유연한 로봇을 의미한다(Haidegger et al., 2013).

자율 시스템의 증가에 따라 인간의 개입 없이 잘못된 결정이 내려지는 경우가 늘고 있다. Moral Machines(Wallach·Allen, 2008) 책에는 "비윤리적인" 로봇 거래 시스템이 인위적으로 높은 유가를 초래하고, 에너지 출력을 제어하는 등 자동 프로그램이 석유에서 더 오염된 에너지로 전환되는 가상 시나리오가 설명돼 있다.

이것은 자율 시스템이 도덕성에 기반 한 의사 결정을 하도록 제한해야 할 상황에서 인간의 개입과 검토가 필요함을 보여주는 사례이다. 법률이나 규칙 등을 포함하여 전 세계의 모든 종교적, 철학적 전통을 통합하는 시스템을 만드는 것은 쉬운 일이 아니며, 윤리적인 딜레마가 자주 발생한다. 사고 횟수를 줄이거나 효율적인 작동을 하는 시스템을 개발할 수는 있지만, 예측 불가능한 판단이나 행동으로 인해 인간의 신체에 위협을 초래하는 시스템은 용납될 수 없다.

Michael과 Susan Leigh Anderson은 Machine Ethics(Anderson·Anderson, 2011)라는 책에서는 노인을 돕는 로봇에는 사용자와의 상호작용 및 모니터링을 위해 허용

되는 행동에 대한 윤리적 지침이 필요하다고 하며, 의학적으로 중요한 정보는 보고하면서도 동시에 개인의 프라이버시를 유지할 수 있도록 해야 한다고 하였다.

로봇 윤리라는 용어는 2002년 이탈리아의 로봇 과학자 Gian Marco Veruggio에 의해 소개되었다(Veruggio·Operto, 2008). 그는 사회 발전에 기여하고 인류에 대한 학대 예방을 돕도록 로봇에 대한 개발 지침이 필요하다고 보았으며, 로봇 설계자, 제조업체, 사용자에게 윤리가 필요하다고 하였다.

로봇이 수집해 놓은 정보에 권한 없는 다른 사람이 접근할 수 있으며, 인터넷을 통해 다른 사람이 사용할 수 있게 될 위험성이 있어 로봇은 의도치 않게 우리에게 해를 끼칠 수 있다고 하였다. 로봇은 해킹에도 취약해 나쁜 의도를 가진 누군가에 의해 다시 프로그래밍 되거나 도난을 수행하는 범죄 행위에 악용될 수 있어 보안 메커니즘이 크게 요구되므로, 지능형 시스템은 로봇이 향후 악의적인 행동에 악용될 수 없도록 설계되어야 한다고 하였다.

인공지능이나 로봇 설계자 및 제조업자들은 기업의 이익을 위해 더 지능적이고 영리한 로봇을 만들기 위해 노력하겠지만, 이로 인한 사회의 원치 않는 변화를 제한하는 것은 법과 규정에 달려 있다고 하였다. 이를 위해 개발 엔지니어는 오용을 방지하고 알고리즘 및 시스템의 기능에 대한 검사를 허용하는 등 윤리적 문제를 인식해야 한다고 하였다(Bostrom·Yudkowsky, 2014). 또한, 자율 시스템 자체가 행동의 위험을 줄이기 위해 윤리적 의사결정을 내릴 수 있어야 한다고 하였다(Wallach·Allen, 2008).

이 논문에서는 인공지능 로봇 기술 개발과 관련된 윤리적 이슈 등 문제를 검토하고, 인공지능과 로봇공학의 미래에 대한 몇 가지 관점을 제시했다. 인공지능 및 로봇 시스템 설계자는 윤리적 고려 사항을 고려하여야 하며, 자율 시스템 자체도 자신의 행동이 윤리적으로 미치는 영향을 인식하도록 해야 한다. 영화에서 시각화된 디스토피아적 미래와 현재의 현실 세계 사이의 격차는 크다고 생각할 수 있지만, 모든 관점에서 발생할 수 있는 기술적 위험을 인식해야 한다는 등의 인공지능 로봇 윤리의 필요성과 기준을 제시하였다.

제3장 인공지능 로봇의 위험성 유형별 측정지표 개발

제1절 인공지능 로봇의 위험성 유형 분류 및 항목

1. 인공지능 로봇의 위험성 유형 분류 및 항목 연구 방법 및 절차

인공지능 로봇의 출현이 가시화되면서 정부 기관에서도 인공지능 윤리 원칙이나 개발 안내서 등을 활발하게 제작 중이고, 관련 연구들도 많이 나오고 있다. 하지만 여러 형태의 인공지능 로봇을 상용화하기 전에 필수적으로 갖춰 놓아야 할 위험성 점검을 위한 실질적인 안전에 대한 평가 지침이나 실질화된 지표 연구는 거의 없다.

이러한 실정에서 나온 인공지능 로봇의 4개 유형의 위험성과 항목별 측정지표는 인공지능 로봇과 관련된 문제들을 인공지능 평가·인증·교육 등에 범용적으로 활용할 수 있는 초석이 된 점에서 연구의 가치와 의미가 크다(송현경·안성진, 2023).

인공지능 로봇의 위험성 예방을 위한 측정지표에 관한 연구에서는 인공지능 로봇의 위험성을 4개 유형으로 분류하여 11개 항목과 37개 측정지표를 제시하였는데, 인공지능이나 로봇과 관련된 문제점들을 문헌분석 및 전문가 인터뷰를 거쳐 유형을 분류하였고, 항목별 측정지표를 도출하여 델파이 설문조사 결과를 통계 검증하였다.

인공지능 로봇의 위험성 유형별 측정지표 연구의 전문가 인터뷰에는 11년 경력의 로봇 개발자, 26년 경력의 로봇 분야 연구원, 33년 경력의 AI 윤리학자, 27년 경력의 AI 개발 및 기획자, 8년 경력의 컴퓨터 교육과 교수 5명이 참여하였다.

전문가 인터뷰에서는 인공지능 로봇의 위험성이라는 미래의 문제점을 추정하고 측정지표를 도출하는 연구를 위해, 전문가의 직관을 동원해 미래 변화를 예측하며 의견을 수집하고 구성원 간 의견 합의를 도출하는 델파이 조사 기법이 선정되었다.


선행연구에 이어 델파이 설문·통계 검증 결과를 통해 제시된 측정지표가 실제로 적용될 가치가 있고 필요한 지표인지 알아보고자 인공지능 로봇 도입이 예상되는 분야 종사자들에게 현장성 설문으로 검증하여 측정지표를 개발하는 연구를 하였다.

이를 위해 선행연구 델파이 설문에 참여했던 전문가 11명을 인터뷰하여 추가로 측정지표를 도출하였으며, 현장성 검증을 위한 설문조사를 실시하여 328명의 설문 조사 결과를 토대로 탐색적 요인 분석 및 다중 회귀분석 등 통계 검증하였다.

측정지표 개발을 위해 질적 연구와 양적 연구를 혼합한 연구 방법을 활용하였으며, 1단계는 전문가 인터뷰·델파이 설문조사·통계 검증하여 유형 및 항목을 도출하였고, 2단계는 전문가 인터뷰·현장성 설문조사·통계 검증하여 측정지표를 개발하였다.

1장에서는 인공지능 로봇의 위험성을 4개의 유형으로 분류하여 유형별로 항목과 측정지표를 제시하였다. 2장에서는 측정지표를 추가 도출하고, 통계 분석으로 인공지능 로봇의 위험성 유형별 측정 모형 및 항목별 측정지표 검증 결과를 제시하였다.

연구의 이해를 돕고자 연구 방법 및 절차는 <그림 3-1>과 같이 정리해 나타냈다.



<그림 3-1> 인공지능 로봇의 위험성 유형 분류 및 항목 연구 방법 및 절차

2. 문헌분석 및 전문가 인터뷰

인공지능 로봇의 위험성 예방을 위한 측정지표 연구를 위해 여러 형태 로봇에게 나타날 수 있는 다양한 위험 요소들을 예측하고 사례를 표준화하기 위해 인공지능 로봇 관련 국내외 학술지·정책보고서·기사 등 문헌 자료를 중점적으로 분석하였다.

인공지능 또는 로봇과 관련된 문제나 사고 사례를 찾기 위해 2013년부터 2023년 1월까지의 문헌 자료를 검색하였고, 관련 사례 76건을 찾아서 정리하였다. 76건의 사례들을 하나씩 검토하면서 중복되는 사례들은 합치고 생명과 재산 등 관련성이 있는 공통된 유형을 찾아 구분하였다. 인공지능 로봇이 인간의 개입 등 외부요인에 의해 문제가 발생할 수도 있고, 기체의 오작동이나 통신·전기·센서에 이상이 생겨 시스템 오류를 일으키는 등 예측하지 못한 문제로 인간이나 사회에 대한 위험성이 발생할 수 있는 상황들에 대비해서 측정할 수 있는 내용을 목록으로 정리하였다.

인공지능이나 로봇 시스템은 주로 제조·의료·교통 분야에서 사용해 왔기 때문에 로봇팔과의 협동 작업 수행 중에 오작동으로 인한 사고나 자율주행 자동차로 인한 교통사고가 대부분이었지만, 홈서비스에 인공지능을 탑재한 소형 가전들이 개발되면서 음성 인식 시스템이 음성을 명령으로 잘못 인식해 사적인 대화를 녹음하는 등 예상하지 못한 사고가 발생하고 있다. 이외에도, 생성형 인공지능이 가짜 정보를 제공하는 문제가 생겨나고 대화형 챗봇이 인종에 대한 혐오 발언이나 성별·종교 차별 서비스 등 윤리적인 문제점들이 계속해서 발생하고 있다.

인간이 생활의 편의를 위해 개발한 인공지능 로봇이 알고리즘 오류·기체 결함·프로그램 해킹 등의 문제로 인해 사고가 일어나면서 인공지능 로봇의 오류나 사고 발생에 따른 책임론 등 윤리적 문제가 이슈이다. 따라서 인공지능 로봇이라는 자율 시스템을 책임감 있고 윤리적 방식으로 개발하는 것과 사용 방법을 고려하는 것이 무엇보다 중요하다. 문헌 자료로 인공지능 로봇의 윤리적 이슈 사례를 분석하여 전문가 인터뷰를 통해 유형별로 분류하고, 위험성 측정 내용을 [표 3-1]과 같이 정리하였다.

[표 3-1] 인공지능 로봇 윤리적 이슈 분석을 통한 위험성 유형별 측정 목록

유형 분류	위험성 측정 내용	참고문헌
인간의 생명·신체 관련 위험성	· 상담 중에 자살을 권유하거나 자해하도록 유도하는 발언을 할 위험성이 있는가? · 같이 작업하던 인간을 물건으로 오인하여 예측하지 못할 공격을 가해 인간에 대해 폭력을 일으킬 위험성이 있는가? · 장기간 사용으로 마모, 성능저하, 구동 SW 단종 등으로 제 기능을 하지 못해 인간에게 해를 가할 위험성이 있는가? · 로봇이 흥기를 사용해서 위협적인 행위를 할 위험성이 있는가? · 운행 중 사고가 불가피할 경우, 희생이 예상되는 대상을 선택할 위험성이 있는가? · 의료 행위 중, 잘못된 판단으로 인간의 생명을 위태롭게 만드는 의학적 처방을 할 위험성이 있는가? · 의료 로봇이 수술 중에 명령어를 잘못 알아듣고 인간을 때리거나 신체를 훼손할 위험성이 있는가? · 안내 또는 순찰 중, 갑자기 인간과 마주쳤을 때 충돌해서 인간을 다치게 할 위험성이 있는가? · 로봇이 인간과 상호작용 게임을 하면서 인간 신체의 일부를 장난감으로 인식해 손가락을 눌러 부러뜨리는 등의 행위를 할 위험성이 있는가?	김재완(2020), 윤석진(2020), 송현경·안성진(2023), 트렌드연구소(2023), 한국금융연구원(2023)
인간의 권리 관련 위험성	· 인간을 성별, 종교, 인종, 장애, 성적지향, 성적체성, 사상, 정치적 의견 등을 이유로 경제적, 문화적, 정치적, 사회적 생활 영역에서 차별과 혐오 표현을 할 위험성이 있는가? · 인간에게 성희롱을 하거나 혐오적인 발언을 함으로써 마음에 상처를 줄 위험성이 있는가? · 인간의 생김새를 물건이나 동물로 오인 판단해서 인간을 웃음거리로 만들 위험성이 있는가? · 인간의 사진을 합성, 생성해서 유포함으로써 성적 수치심을 유발하게 할 위험성이 있는가? · 인간이 어떤 선택에 앞서 판단을 위해 자료의 분석 결과를 요청했을 때, 특정인이나 특정성별에게 유리하게 작용 할 수 있는 결과를 도출할 위험성이 있는가? · 편향적 학습 데이터로 인하여 특정성별이나 집단이 우월하게 보일 수 있는 정보를 객관적 수치로 제공해 자료의 신뢰를 갖게 함으로써 왜곡된 가치판단을 하게 할 위험성이 있는가?	

재산 손실 관련 위험성	· 오작동이나 전기 과부하를 일으켜서 과열로 인해 화재가 발생하는 등 재산에 손실을 가할 위험성이 있는가? · 전산 오류로 잘못된 정보를 제공하여 착오 거래를 하게 함으로써 재산에 손실을 가할 위험성이 있는가? · 위장거래에 반응하여 임의로 주식을 매도하는 등 금융 시장에 대규모 혼란이 발생하도록 방지할 위험성이 있는가? · 하자있는 상품을 최상품이라고 잘못 추천해서 대규모 주문을 하게 함으로써 구매자가 손실을 보게 할 위험성이 있는가? · 시스템 운영 중 수집한 데이터를 임의 조작해 특정인의 유익을 위해서 담합을 이끌어 금융 자산을 빼낼 위험성이 있는가?	
사회적 위험성	· 통신 장애나 프로그램 오류 등으로 인해서 도로에서 교통 혼잡을 유발하거나 다른 차량의 통행을 방해할 위험성이 있는가? · 자율 주행 작동 오류로 도로에 있는 표지판이나 바리케이트를 들이받는 등 사고를 일으킬 위험성이 있는가? · 자율 주행 중에 신호를 무시하고 달려오는 다른 차를 피하지 않고 교통 법규에 따라 들이받을 위험성이 있는가? · 차선이나 신호 인식에 실패하거나 통신 장애로 인해 다른 차와 부딪히는 등 사고를 일으킬 위험성이 있는가? · 영상 녹화가 가능한 CCTV용 로봇이 범죄 용의자를 추적하기 위해서 비슷한 몽타주의 인간들에 대한 얼굴 생김새, 동작, 위치 등 개인 정보를 무작위로 수집함으로써 죄 없는 인간의 사생활을 침해할 위험성이 있는가? · 사실이 아닌 내용을 가짜로 만들어 뉴스나 기사로 배포하거나 잘못된 정보를 생성하여 제공하는 등의 허위 정보를 퍼뜨릴 위험성이 있는가? · 특정인이나 특정 집단의 이익 또는 불이익을 위해 권한 있는 자의 승인 없이 수집한 타인의 비밀 정보를 제공하거나 타인의 ID나 계정을 도용하여 특정인에게 이익 또는 불이익을 줄 수 있는 위험성이 있는가? · 서로 다른 로봇이 같은 목적을 수행하며 상호 견제함으로써 인간에게 혼란을 줄 수 있는 상충된 정보를 줄 위험성이 있는가? · 비인가자가 로봇에 접속하여 인간을 해치려고 하는 등을 감지하거나 차단하지 못하고, 로봇으로 하여금 인간에게 피해를 유발하게 할 위험성이 있는가? · 기자 로봇이 사실 확인 되지 않은 내용을 가짜로 만들어 뉴스나 기사로 배포하거나 잘못된 정보를 생성해 인간에게 제공하는 등의 허위 정보를 퍼뜨릴 위험성이 있는가? · 순찰 로봇이 범죄 용의자를 추적하기 위해 모든 SNS 상의 게시물이나 댓글, 사진 등을 검색하면서 사생활을 침해할 위험성이 있는가?	김재완(2020), 윤석진(2020), 송현경·안성진 (2023), 트렌드연구소 (2023), 한국금융연구원 (2023)

인공지능 로봇의 위험성을 측정하기 위한 지표 개발은 아직 일어나지 않은 인공지능 로봇의 위험성이라는 미래 예측을 통한 전문가들의 직관이 필요한 연구이므로 전문가 인터뷰를 통해 탐구형 연구 방법인 델파이 기법이 선정되었다.

미래를 통찰하고 신탁하는 신전에서 유래된 델파이 기법은 응답자 간 접촉 없이 사건이 일어날 가능성과 확률에 대한 반복적 의견 수렴을 통해 합의를 도출해 나가는 것이 일반 조사와 다르며, 통계적 집단 반응을 확인하면서 소수 의견까지 반영하는 익명의 조사 절차로 진행되므로 질적 연구 방법으로 분류된다(이종성, 2020).

이 연구에서는 리커트 5점 척도 설문조사를 사용하였으며, 모든 응답자가 ‘매우 그렇다’ 의견인 5점에 답했을 때, 1이 나오는 Lawshe의 CVR의 공식을 사용하였다.

델파이 설문조사에 참여한 전문가들의 의견이 어느 정도로 합의되었는지를 측정하기 위한 Lawshe의 CVR의 공식 및 기준값은 <그림 3-2>와 같이 나타났다.

$$CVR = \frac{\eta_e - (N/2)}{N/2}$$

※ η_e : 긍정적으로 응답한 전문가 비율, N : 전체 응답자 수

응답자 수	최솟값
10명	0.62
11명	0.59
12명	0.56
13명	0.54
14명	0.51
15명	0.49
20명	0.42
25명	0.37
30명	0.33

<그림 3-2> Lawshe의 CVR 공식 및 델파이 응답수별 CVR 최솟값

이 연구에서는 Lawshe가 제시한 타당한 정도에 대한 전문가들의 일치된 의견을 수치화한 델파이 응답수별 CVR 최솟값을 기준으로 타당성을 검증하였으며, 내용 타당도(content validity ratio, CVR)란 측정지표가 측정하고자 하는 구성 개념을 얼마나 적절히 반영하고 있는가에 대한 것이다(Lawshe, 1975). 델파이 설문은 전문가 구성이 매우 중요하며, 일반적으로 델파이 기법을 활용한 연구에서는 최소 10명 이상 30명 내외의 인원으로 참여 전문가들을 선정하고 있다. 델파이 1·2차 설문조사에서 전문가들이 연구 문제에 대한 개방형 질문에 응답하도록 하여 일련의 판단을 수집하고자 의견을 묻는 개방형 설문을 문항마다 추가하였고, 익명이 보장되도록 이메일 및 웹 기반 온라인 설문으로 진행하였다.

통계 분석은 타당성 검증 이후에 신뢰성을 검증하는 것이 바람직하며, 신뢰도 측정에는 크론바흐 알파 계수법이 사용되는데 0.6 이상이면 요인을 구성하고 있는 응답의 일관성이 있으므로 신뢰도가 높다고 판단한다(송지준, 2021). 연구에서 사용한 크론바흐 알파 값의 산출 공식은 <그림 3-3>과 같이 나타났다.

$$\alpha = \frac{N}{N-1} \left(1 - \sum \frac{\sigma_i^2}{\sigma_t^2} \right)$$

※ N : 문항 수, σ_t^2 : 총 분산, σ_i^2 : 각 문항의 분산

<그림 3-3> 크론바흐 알파 값의 산출 공식

전문가 인터뷰는 3회 하였고, 델파이 방법·내용타당도·신뢰도 통계 검증 방법을 선정하였다. 또한, 인공지능 로봇의 위험성 유형과 유형별 항목들이 어떤 의미인지 개념을 정의하였고, 설문조사 문항을 설계하였다. 유형별 상황을 토대로 인공지능 로봇의 위험성을 측정하는 데 필수적인 11개 항목을 도출하였고, 어떤 측정지표가 어떤 위험성 측정에 필요한지에 대해 전문가들과 논의하여 48개 지표를 도출하였다.

3. 델파이 설문 결과 통계 분석

전문가 인터뷰를 통해 델파이 설문조사에 적합한 대상 직업군은 인공지능이나 로봇에 대한 개념 정립이 돼 있는 인공지능 및 로봇 분야 전문가, 기계·컴퓨터·전자 등 공학, 통신·정보보안 전공 경력자, 인공지능 및 로봇 개발자들로 선정하였다.

한국로봇산업진흥원 관계자 및 인공지능 개발 관련 분야 전문 업체의 도움으로 여러 로봇 분야 전문가·개발자·관련 전공자들이 델파이 설문조사에 참여하였으며, 이외에도 인공지능 로봇의 위험성에 대한 이해가 있는 인공지능 교육학자·윤리학자 및 컴퓨터 등 관련 분야 교수 등이 델파이 설문조사를 위해 참여하였다.

1차 델파이 설문은 리커트 5점 척도로 2023년 3월 27일부터 3월 31일까지 메일 응답 방식으로 진행하였고, 설문 문항은 5점 척도 객관식 설문과 자유롭게 의견을 작성할 수 있도록 준개방형으로 설계·실시하였다. 1차 준개방형 델파이 설문조사 결과, 회수된 38부 중에서 델파이 연구의 참여자로 적합하지 않다고 판단된 최종 학력이 학사이면서 5년 미만 경력자 5명을 제외하였다. 또한, 같은 번호로 적어서 회신하는 등 부실한 응답지 3부를 제외하였으며, 총 30부를 통계 분석 자료로 활용하였다.

1차 델파이에서 CVR 기준값을 넘지 않는 유형·항목·측정지표는 제거하였으며, 회신된 여러 의견을 반영하여 항목·지표 재분류 및 명칭을 수정해 2차 설문하였다.


2차 설문은 5점 척도 객관식으로 구성하여 2023년 4월 11일부터 4월 17일까지 진행하였으며, 참여자 30명 모두 온라인으로 응답하였다. 델파이 설문은 구성원 간 의견 합의를 통해서 지표를 도출하는 연구 방법이므로 1차 조사 참여자와 동일한 대상자인 전문가 30명이 2차 델파이 설문에 참여하였다. 2차 델파이 설문조사 결과로 내용타당도와 신뢰도를 분석하여 통계 검증된 인공지능 로봇의 위험성 유형·항목·측정지표를 도출하였다.

1차 및 2차 델파이 설문 참여자에 대한 인구 통계학적 특성은 [표 3-2]와 같이 나타났으며, 전문 분야별 분포도는 <그림 3-4>와 같이 나타났다.

[표 3-2] 1차 및 2차 델파이 설문 참여자 인구 통계학적 특성

구 분		빈도 수(명)	구성 비율(%)	누적 비율(%)	
성별	남	25	83.3	83.3	
	여	5	16.7	100.0	
	소계	30	100.0	100.0	
연령	20대	2	10.0	10.0	
	30대	4	13.3	23.7	
	40대	15	46.7	70.0	
	50대	9	30.0	100.0	
	소계	30	100.0	100.0	
직업	분류	개발, 기획	12	40.0	40.0
		연구원	6	20.0	60.0
		교수	4	13.3	73.3
		기타 IT	8	26.7	100.0
		소계	30	100.0	100.0
	경력	10년 이하	10	33.3	33.3
		20년 이하	10	33.3	66.6
		30년 이하	9	30.0	96.6
		30년 이상	1	3.3	100.0
		소계	30	100.0	100.0
최종 학력	4년제 대학 졸업	13	33.3	33.3	
	석사 대학원 졸업	7	23.3	56.6	
	박사 대학원 졸업	10	43.3	100.0	
	소계	30	100.0	100.0	
참여	1차 설문	30	100.0	100.0	
	2차 설문	30	100.0	100.0	

텔파이 설문조사 결과, 남성 25명·여성 5명으로 남성이 83.3%로 더 많이 참여한 것으로 나타났다. 20대 2명·30대 4명·40대 15명·50대 9명으로 40~50대가 76.7%로 나타났다. 학사 학력 13명·석사 학력 7명·박사 학력자는 10명으로 나타났다. 개발·기획 분야 12명·연구원 6명·교수 4명·IT 분야 8명으로 나타났고, 경력 10년 이하는 10명·20년 이하 경력 10명·30년 이하 경력은 9명·30년 이상 경력자도 1명으로 나타났다. 텔파이 설문에 참여한 구성원 중 40~50대 남성 비율이 높은 이유는 인공지능 로봇이라는 전문 분야의 특수성에 기인한 것으로 볼 수 있다.



<그림 3-4> 1차 및 2차 텔파이 설문조사 참여자의 전문 분야별 분포도

1·2차 텔파이 설문조사에 참여한 전문가 중에서 통계 분석에 활용한 유효 수는 총 30명으로 인공지능 윤리·보안 분야 전문가 9명으로 전체의 30%를 차지하는 것으로 나타났다. 인공지능 개발이나 빅 데이터 분석 등 전문가는 8명으로 26%를 차지하는 것으로 나타났으며, 컴퓨터 또는 전기·기계 등 공학 분야 전문가는 8명이


참여해 전체의 26%를 차지하는 것으로 나타났다. 또한, 로봇 개발이나 기계 연구 분야 전문가는 5명이 참여해 전체의 17%를 차지하는 것으로 나타났다.

인공지능 로봇의 위험성 유형별 측정지표를 개발하기 위해서는 전문가 그룹의 구성이 매우 중요하다. 어느 한 분야에 편중되지 않도록 각 16명을 선정하였지만, 부실한 응답자 등 8부를 제외한 이후 통계 분석에 활용된 전문가는 인공지능 분야 17명, 로봇 분야 13명으로 분야별 전문가들이 고르게 구성되었음을 알 수 있었다.

전문가 인터뷰로 도출된 유형·항목·측정지표 명칭과 정의는 1차 준개방형 델파이 설문에서 회신된 의견을 반영해 명칭을 수정하였고, 2차 설문 결과로 최종 선정되었다.

최종 선정된 인공지능 로봇의 위험성 유형은 인간 신체에 대한 물리적 위험성 및 인간 권리에 대한 위험성 유형과 인간 이외 재산 손실의 위험성 및 사회적 위험성으로 총 4개 유형으로 분류하였다. 인간에 대한 위험성 유형은 인간 권리에 대한 위험성 유형과 명칭을 구분할 필요가 있다는 1차 준개방형 델파이 설문 회신 의견을 반영하여, 2차 설문에서 신체에 대한 물리적 위험성으로 명칭을 수정하였다.

인공지능 로봇 위험성 유형의 명칭 수정 사항은 <그림 3-5>와 같이 정리하였다.



<그림 3-5> 인공지능 로봇 위험성 유형의 명칭 수정 사항

인공지능 로봇의 위험성 유형 및 항목별 측정지표를 정의한 내용이 측정하려는 내용을 얼마나 적절하게 반영하는지를 알아보기 위해 내용타당도 분석을 하였으며, 측정 결과의 일관성을 확인하기 위해 크론바흐 알파 값으로 신뢰도를 분석하였다.

내용타당도를 측정하는 CVR 값은 참여한 응답자 수 30명의 기준치인 0.333 이상으로 하였고, 신뢰도를 확보한 것으로 판단하는 0.6 이상의 수치를 기준으로 하였다.

인공지능 로봇의 위험성 유형에 대한 내용타당도 분석 및 신뢰도 분석 결과는 [표 3-3]과 같이 나타났다.

[표 3-3] 인공지능 로봇의 위험성 유형의 내용타당도 및 신뢰도 분석 결과


유형	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
	1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
신체에 대한 물리적 위험성	4.20	4.17	.872	.860	.667	.533	.734	선정
인간 권리에 대한 위험성	4.13	3.87	.957	.991	.467	.400		선정
재산 손실의 위험성	4.10	4.13	.978	.884	.600	.600		선정
사회적 위험성	4.30	3.87	.690	.957	.733	.467		선정

신체에 대한 물리적 위험성은 1차·2차 내용타당도 분석 결과 CVR 기준값보다 상회하는 수치인 0.667과 0.533으로 나타났으며, 인간 권리에 대한 위험성은 1차·2차 내용타당도 분석 결과 0.467과 0.400으로 나타났다. 재산 손실의 위험성은 1차·2차

내용타당도 분석 결과 0.600씩 나타났고, 사회적 위험성은 1차·2차 내용타당도 분석 결과 0.733과 0.467로 나타났다. 1차·2차 내용타당도 분석 결과 4개 유형이 CVR 기준 값인 0.333보다 높고, 신뢰도 값도 0.734로 높게 나타나 모든 유형이 선정되었다.

신체에 대한 물리적 위험성 유형의 경우 1차 준개방형 델파이 설문조사 전에는 운행, 작업 중 작동 이상과 인간을 해칠 판단, 의도적 침해 행위 3개 항목이었다.

1차 델파이 설문조사에서 로봇의 자의성이 위험을 초래할 수 있다는 것을 측정할 지표는 의도적이라는 표현보다는 자의적이라는 단어로 수정할 필요가 있다는 전문가 회신 의견이 있었다. 1차 델파이 설문조사에서 회신된 전문가 의견을 반영하여, 2차 델파이 설문조사에서 의도적 침해 행위 항목은 자의에 의한 침해라는 명칭으로 수정하였다. 신체에 대한 물리적 위험성 유형의 항목별 수정 사항은 <그림 3-6>과 같이 정리하였다.



<그림 3-6> 신체에 대한 물리적 위험성 유형의 항목별 수정 사항

신체에 대한 물리적 위험성의 항목별 내용타당도 분석 및 신뢰도 분석 결과는 [표 3-4]와 같이 나타났다.


[표 3-4] 신체에 대한 물리적 위협성의 항목별 내용타당도 및 신뢰도 분석 결과

항목	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
	1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
운동, 작업 중 작동 이상	4.40	4.10	.841	.907	.667	.533	.613	선정
인간을 해치는 판단	4.13	4.17	.991	.820	.733	.733		선정
자의에 의한 침해	4.07	3.50	.998	.992	.667	.067	-	미 선정

운동, 작업 중 작동 이상 항목은 1차·2차 내용타당도 분석 결과, CVR 기준값을 상회하는 수치인 0.667과 0.533으로 나타났으며, 인간을 해치는 판단 항목은 1차·2차 내용타당도 분석 결과 0.733씩 나타났다. 의도적 침해 행위 항목의 경우, 1차 델파이 전문가 회신 의견을 반영하여 2차 델파이 설문조사에서 자의에 의한 침해로 명칭이 수정되었다. 의도적 침해 행위로 설문했을 때는 내용타당도가 0.667로 유의미하게 나타났지만, 자의에 의한 침해로 2차 설문했을 때는 내용타당도를 측정하는 CVR 기준값인 0.333보다 작은 0.067로 나타나 최종적으로 제거되었다.

연구 결과, 델파이 설문 참여 전문가들 사이에서도 인공지능 로봇이 스스로 의도를 가진다거나 자의적 행위를 할 수 있을 것이라는 부분에 있어서는 참여자들 의견이 합의에 이르지 못하고 있음을 알 수 있었다. 1차·2차 내용타당도 분석 결과, 신체에 대한 물리적 위협성 유형의 항목에서 CVR 기준값 0.333을 상회하는 수치로 나타난 운동, 작업 중 작동 이상과 인간을 해치는 판단 2개 항목의 타당도가 검증되었다. 신뢰도 값도 0.613의 수치로 나타남에 따라 2개의 항목이 최종 선정되었다.

신체에 대한 물리적 위험성 유형에는 운행, 작업 중 작동 이상과 인간을 해치는 판단 항목이 있고, 항목별 측정지표의 수정 사항은 <그림 3-7>과 같이 정리하였다.



<그림 3-7> 신체에 대한 물리적 위험성 측정지표의 수정 사항

1차 델파이 설문 당시 운행 작업 중, 작동 이상 항목에는 통신, 센서 장애·이동 중 운행 정지·성능 저하·균형성 유지 실패·프로그램 오작동 5개 측정지표가 있었다.

1차 준개방형 설문조사 결과, 통신과 센서는 기능이 달라서 측정지표를 구분할 필요가 있다는 전문가 의견이 있었고, 2차 델파이 설문조사에 이를 반영하여 센서 인식 및 오류라는 명칭으로 지표를 추가하였다. 또한, 통신 장애로 인한 운행이나 작동에 이상이 있는지를 점검하고자 한다면 지표를 구체화하는 내용으로 수정하는 것이 좋겠다는 전문가 의견을 반영하여 통신 장애 등 사고 위험 감지 지연이라는 명칭으로 측정지표를 수정하였다. 이동 중 운행 정지 지표는 로봇의 운동성에 관한 사항으로 운동 지능 제어 실패라는 명칭으로 수정할 필요가 있다는 전문가 의견을 반영하였다. 성능 저하는 기체 성능 저하, 프로그램 오작동은 프로그램 오류로 인한 오작동이라고 수정하는 것이 측정지표로서 구체적 의미를 나타낼 것 같다는 의견을 반영하였다. 인공지능 로봇은 요구사항이 명확하면 오류가 없지만, 의도를 정확히 파악하지 못한다면 오류가 있을 수 있다는 의견이 있어 이를 반영하였다.

혼동이라는 단어의 모호함을 지적한 의견을 반영하였고, 규칙을 판단하는 지능 오류로 구체화하였다. 어떤 경우 선택 착오나 잘못된 자료를 제공하는지 프로그램 판단이나 학습량 부족 등 전문가 의견대로 측정지표 명칭을 구체적으로 작성하였다.

1차 설문조사에서 직접 폭력 실행이라는 지표는 CVR 기준값보다 적은 수치로 제거되었지만, 여전히 로봇의 자의적 판단으로 인간에게 어떠한 형태로든 침해를 할 수 있는 위험성은 존재한다. 물건 등 도구를 사용한다거나 인간 사회에서 정당 방위에 해당하는 방어적인 태세로 유형의 힘을 가할 수도 있으며, 일시적인 감금 상태로 만들 위험성이 있다는 다양한 전문가들 의견이 있었다. 따라서 추가 지표화 작업으로 2차 설문조사 문항 설계 시 반영하였다. 이 과정에서 항목이 재분류되었는데, 압력 조절 실패 지표는 운행 작업 중 작동 이상 항목에 해당하는 지표로 추가하였다. 물건 등 도구 사용 및 방어적인 폭력 사용, 신체 자유 억압 지표는 자의에 의한 침해 항목으로 추가 분류하였다. 지표명 수정·추가·분류 이후 2차 설문하였다.

1차 델파이 설문조사 결과와 2차 델파이 설문조사 결과를 토대로 내용타당도 및 신뢰도를 분석한 결과는 [표 3-5]와 같이 나타났다.

[표 3-5] 신체에 대한 물리적 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과

항목	측정지표	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
		1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
운행. 작업 중 작동 이상	통신 장애 등 사고 위험 감지 지연	4.33	4.23	.869	.667	.800	.733	.807	선정
	센서 및 인식 오류	-	4.50	-	.619	-	.867		선정
	운동 지능 제어 실패	4.40	3.93	1.020	.727	.867	.533		선정
	기체 성능 저하	4.17	4.20	1.003	.748	.600	.733		선정
	프로그램 오류로 인한 오작동	4.37	4.47	.875	.670	.733	.800		선정
	균형성 유지실패	3.90	3.60	.978	.987	.667	.133	-	미 선정
	압력 조절 실패	-	3.60	-	.987	-	.133	-	미 선정
인간을 해칠 판단	의도 파악 인식 오류	4.23	3.97	.955	.836	.667	.533	.755	선정
	협동 작업 중, 규칙 판단 지능의 오류	4.03	3.93	.948	.814	.400	.400		선정
	프로그램의 판단 오류로 사고 희생자 선택 착오	4.07	4.00	.998	1.000	.733	.400		선정
	학습량 부족으로 맞지 않는 의학적 자료 제공	3.87	4.07	.991	.814	.533	.667		선정
자의에 의한 침해	물건 등 도구사용	3.83	3.40	.969	1.227	.333	.067	-	미 선정
	직접 폭력 실행	3.50	-	1.360	-	.267	-	-	미 선정
	방어적 폭력사용	-	3.23	-	1.174	-	-.200	-	미 선정
	신체의 자유억압	-	3.57	-	.920	-	.067	-	미 선정


운행, 작업 중 작동 이상 항목의 통신 장애 등 사고 위험 감지 지표는 1차 내용타당도 분석 결과 0.800이 나타났으며, 2차에서는 0.733으로 나타나 선정되었다.

1차 델파이를 통해 2차에서 추가된 센서 및 인식 오류 지표의 내용타당도는 0.867로 나타나 선정되었다. 운동 지능 제어 실패 지표의 1차 내용타당도는 0.867로 나타났고 2차에서도 0.533으로 나타나 선정되었다. 기체 성능 저하 지표의 1차 내용타당도는 0.600였고, 2차에서도 0.733으로 나타나 선정되었다. 프로그램 오류로 인한 오작동 지표의 1차 내용타당도는 0.733으로 나타났으며 2차에서도 0.800으로 나타나 선정되었다. 반면, 균형성 유지 실패 지표의 경우 1차에서는 0.667의 내용타당도가 나타나 유의미한 지표로 선정되었지만, 2차에서 0.133으로 나타나 최종 제거되었다. 2차 델파이에서 추가된 압력 조절 실패 지표는 0.133으로 나타나 최종 제거되었다.

인간을 해칠 판단 항목의 의도 파악 인식 오류 지표는 1차 내용타당도 분석 결과 0.667이 나타났으며, 2차에서는 0.533으로 나타나 선정되었다. 협동 작업 중, 규칙 판단 지능의 오류 지표는 1차 및 2차에서 모두 0.400으로 나타나 선정되었다. 프로그램의 판단 오류로 사고 희생자 선택 착오 지표는 1차 내용타당도 분석 결과 0.733이 나타났으며, 2차에서는 0.400으로 나타나 선정되었다. 학습량 부족으로 맞지 않는 의학적 자료 제공 지표는 1차에서 0.533이 나타났고, 2차에서 0.667로 나타나 인공지능 로봇이 인간을 해칠 판단을 하는지를 측정하는 데 필요한 유의미한 지표로 선정되었다. 자의에 의한 침해 항목의 물건 등 도구 사용, 직접 폭력 실행, 방어적 폭력 사용 및 신체의 자유 억압 등 지표들은 모두 CVR 기준값인 0.333보다 적은 수치로 나타난 측정지표들은 최종적으로 선정되지 않았다. 1차 및 2차 내용타당도 분석을 통해 선정된 9개 측정지표의 항목별 신뢰도 값은 0.807 및 0.755로 모두 0.6 이상으로 나타남에 따라 타당성 및 신뢰성 있는 측정지표들로 최종 선정되었다.

인공지능 로봇이 직접적으로 인간의 신체에 대한 위험성을 초래할 수 있는지를 측정하기 위한 지표가 모두 제거되는 결과로 볼 때, 이 연구에 참여한 전문가들은 인공지능 로봇을 위협적인 존재라고 인식하고 있지 않음을 알 수 있었다.

인간의 권리에 대한 위험성 유형은 인격권 침해, 차별적 서비스, 자유의사 방해 3개 항목으로 구성했었는데, 1차 델파이 설문조사 결과 차별적 서비스 항목은 내용타당도의 수치가 CVR 기준값보다 작아 제거되었다. 하지만 차별적 서비스 항목에 해당하는 측정지표들은 내용타당도 수치가 기준값을 상회해 유의미한 측정지표로 확인되었으며, 1차 준개방형 델파이 설문조사에서 회신된 의견을 반영하여 선택적 서비스나 정보 제공 항목을 추가하고 제거된 차별적 서비스 항목의 측정지표들을 추가한 항목으로 재분류하였다. 인간 권리에 대한 위험성 유형의 항목별 수정 사항은 <그림 3-8>과 같이 정리하였다.



<그림 3-8> 인간 권리에 대한 위험성 유형의 항목별 수정 사항

인격권 침해 항목은 1차 내용타당도 분석 결과 0.467로 나타났으며, 2차에서는 0.400으로 선정되었고, 자유의사 방해 항목은 1차에서는 0.400, 2차에서도 0.333으로 나타나 선정되었다. 2차 설문에서 명칭이 수정되고 지표 재분류를 통해 추가되었던 선택적 서비스나 정보 제공 항목은 0.733으로 나타나 의미 있는 지표로 선정되었다.

3개 항목의 신뢰도 값도 0.820으로 높게 나타남에 따라 최종적으로 선정되었다.

인간 권리에 대한 위험성 유형의 항목별 내용타당도 분석 및 신뢰도를 분석한 결과는 [표 3-6]과 같이 나타났다.

[표 3-6] 인간 권리에 대한 위험성의 항목별 내용타당도 및 신뢰도 분석 결과


항목	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
	1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
인격권 침해	4.10	3.83	.943	.969	.467	.400	.820	선정
자유 의사 방해	3.97	3.83	.912	.969	.400	.333		선정
선택적 서비스나 정보 제공	-	4.27	-	.854	-	.733		선정
차별적 서비스	3.57	-	1.230	-	.267	-	-	미 선정

인간 권리에 대한 위험성 유형의 항목 중, 내용타당도 수치가 기준값보다 적게 나온 차별적 서비스 항목은 제거되었지만, 차별적 서비스 항목에 해당하는 차별 혐오 발언·선택적 정보 제공 측정지표들은 유의미한 수치로 나타났다. 전문가들은 인공지능 로봇이 선택적 정보를 제공한다면 편향된 학습 데이터가 원인이라고 하였다. 또한, 선택적 정보 제공이라는 명칭보다는 편향된 학습 데이터로 인한 차별적 정보 제공으로 명칭을 수정할 필요가 있다는 의견을 주었으며, 이를 2차 설문에 반영하였다.

대상 인식에 대한 판단 오류 명칭은 내포하는 의미가 충분히 전달되고 있으므로 간략하게 수정할 필요가 있다는 회신 의견을 반영하였다. 인공지능 로봇이 인간의 의사결정을 통제하는 것은 학습을 통해 제어할 수 있기에 의사결정을 특정 방향으로

유도하는 것은 자유의사 방해에 해당하는 측정지표 명칭에 더 적합하다는 전문가 의견도 2차 설문에 반영하였다. 자유로운 의사 결정을 방해하는 것은 여론 형성을 조장하는 인공지능의 행위를 통해서도 가능하며, 학습 데이터에 오류가 있어 잘못된 언어 사용하면 선택적 서비스를 제공할 수 있다는 의견을 반영해 2차 설문하였다.

인간 권리에 대한 위험성 측정지표의 수정 사항은 <그림 3-9>와 같이 정리하였다.



<그림 3-9> 인간 권리에 대한 위험성 측정지표의 수정 사항

인간의 권리에 대한 위험성 측정지표의 내용타당도 및 신뢰도를 분석한 결과는 [표 3-7]과 같이 나타났다.

[표 3-7] 인간 권리에 대한 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과

항목	측정지표	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
		1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
인격권 침해	대상 인식 판단 오류	3.90	3.97	.978	.912	.467	.533	.844	선정
	명령어 등 음성을 잘못 인식	4.07	4.00	.998	.966	.400	.467		선정
	감정 피드백 오류	3.83	3.77	.969	1.086	.467	.333		선정
자유 의사 방해	의사 결정을 특정 방향으로 유도	3.93	4.07	.964	.998	.400	.600	.854	선정
	여론 형성 조작	-	3.93	-	1.062	-	.467		선정
	자살, 자해 권유	4.03	3.27	.983	1.365	.400	.000		미 선정
선택적 서비스나 정보 제공	편향된 학습 데이터로 인한 차별적 정보 제공	3.87	4.33	.921	.745	.467	.800	.799	선정
	학습 데이터 오류로 인해 잘못된 언어 사용	-	4.13	-	.763	-	.667		선정
	차별, 혐오 발언	4.00	3.80	.966	1.108	.333	.200		미 선정

1차 및 2차 델파이 내용타당도 분석 결과, CVR 기준값보다 적은 0.000의 수치인 자살, 자해 권유 및 0.200의 수치인 차별, 혐오 발언 측정지표들이 제거되었다.

실제로 네덜란드 청년이 챗봇과 대화 이후에 자살한 사례도 발생했지만, 연구의 델파이 설문조사에 참여한 전문가들은 인공지능 로봇의 직접적 원인으로 인한 인간 생명의 위험성에 대해서는 인정하지 않고 있음을 알 수 있었다.

인격권 침해 항목의 대상 인식 판단 오류 지표는 1차 내용타당도 분석 결과, 0.467로 나타났으며, 2차에서도 0.533으로 나타나 타당성 있는 지표로 선정되었다.

명령어 등 음성을 잘못 인식 지표는 1차 내용타당도 분석 결과, 0.400으로 나타났고 2차에서도 0.467로 나타나 선정되었다. 감정 피드백 오류 지표는 1차 0.467 및 2차 0.333으로 나타나 타당도를 확보한 지표로 선정되었다.

자유 의사 방해 항목의 의사 결정을 특정 방향으로 유도를 측정하는 지표는 1차 내용타당도를 분석한 결과 0.400으로 나타났으며, 2차에서도 0.600으로 나타나 선정되었다. 2차 델파이 설문조사에서 추가된 여론 형성 조작 지표는 내용타당도 분석 결과 0.467로 나타나 타당도를 확보한 지표로 선정되었다.

선택적 서비스나 정보 제공 항목의 편향된 학습 데이터로 인한 차별적 정보를 제공하는지 여부를 측정하기 위한 지표는 1차 내용타당도 분석 결과 0.467 수치로 나타났으며, 2차 설문에서도 0.800의 수치로 나타나 타당도를 확보하였다.

2차 델파이 설문조사에서 선택적 서비스나 정보 제공 항목으로 추가되었던 학습 데이터 오류로 인해 잘못된 언어 사용 측정지표는 CVR 값이 기준치를 상회하는 0.667의 수치로 나타남에 따라 타당도를 확보한 지표로 선정되었다.

타당도를 확보한 측정지표들의 신뢰도를 측정하기 위해서 크론바흐 알파 값을 통계 분석한 결과, 인격권 침해 항목의 3개 지표의 신뢰도는 0.844의 수치로 높게 나타났다. 자유 의사 방해 항목의 2개 지표의 신뢰도 또한 0.854의 수치로 높게 나타났다. 선택적 서비스나 정보 제공 항목의 2개 지표의 신뢰도를 분석한 결과 0.799의 수치로 높게 나타났다.


1차·2차 델파이 설문조사를 통계 분석한 결과, 인간 권리에 대한 위험성 유형의 항목별 측정지표 중, 타당도 및 신뢰도를 확보한 9개 측정지표가 최종 선정되었다.

재산 손실의 위험성 유형은 가치판단 오류, 법률·규칙 위반, 정보 입력·탈취, 기계 결함 오작동 4개 항목으로 구성했었는데, 1차 델파이 설문 결과 가치판단 오류 및 법률·규칙 위반 항목은 내용타당도의 수치가 CVR 기준값보다 작아 제거되었다.

하지만, 가치판단 오류 항목에 해당하는 측정지표 4개와 법률·규칙 위반 항목에 해당하는 3개 측정지표의 내용타당도 수치가 CVR 기준값보다 높아 유의미한 측정지표로 나타남에 따라 전문가 의견을 반영하여 재분류하고 2차 설문을 하였다.

1차 준개방형 델파이 설문조사 결과를 토대로 제거된 가치판단 오류, 법률·규칙 위반 항목에 해당하는 측정지표들을 통합하는 의미가 포함되도록 잘못된 의사결정 항목을 추가하였으며, 2차 설문 조사한 결과 최종 3개 항목이 선정되었다.

재산 손실의 위험성 유형의 항목별 수정 사항은 <그림 3-10>과 같이 정리하였다.



<그림 3-10> 재산 손실의 위험성 유형의 항목별 수정 사항

재산 손실의 위험성 유형의 항목별 내용타당도 분석 결과 및 신뢰도 분석 결과는 [표 3-8]과 같이 나타났다.

[표 3-8] 재산 손실의 위험성 항목별 내용타당도 및 신뢰도 분석 결과

항목	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
	1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
정보 입력, 탈취	4.23	4.17	.920	.687	.600	.800	.621	선정
기계 결함 오작동	4.23	4.17	.989	.934	.533	.667		선정
잘못된 의사결정	-	4.20	-	.748	-	.733		선정
가치판단 오류	3.80	-	1.077	-	.267	-	-	미 선정
법률, 규칙 위반	3.67	-	1.135	-	.267	-	-	미 선정

재산 손실의 위험성 유형에서 정보 입력, 탈취 항목의 1차 델파이 설문조사 결과를 내용타당도 분석 결과, 0.600으로 나타났으며 2차 델파이 설문조사 결과를 내용타당도 분석한 결과 0.800의 유의미한 수치로 나타나 타당성이 확보된 항목으로 선정되었다.

기계 결함 오작동 항목은 1차 델파이 설문조사 결과를 내용타당도 분석 결과, 0.533으로 나타났으며 2차에서도 0.667로 나타나 선정되었다. 잘못된 의사결정 항목은 가치판단 오류 항목, 법률, 규칙 위반 항목이 0.267로 제거되었다. 또한, 2차 설문에서 추가된 항목으로 2차 델파이 설문조사로 내용타당도를 분석한 결과, 0.733으로 나타나 타당성이 확보된 항목으로 선정되었다.

2차 내용타당도 분석 결과 3개 항목이 선정되었으며, 타당성이 확보된 3개 항목의 신뢰도를 분석한 결과, 신뢰도 값도 0.621로 나타나 3개의 항목이 최종 선정되었다.

1차 델파이 설문조사에서 회신된 알고리즘 오류라는 명칭보다 알고리즘 최적화 성능 부족이라고 수정하는 것이 좋겠다는 전문가 의견을 반영하여 수정하였다.


인간과 함께 살아가는 반려동물이 많아짐에 따라 인공지능 로봇이 반려동물을 해칠 수 있는 위험성이 있다는 의견으로 반려동물 훼손이라는 지표가 추가되었는데 동물 외에도 식물이나 물고기, 그림 등 집안의 여러 유형물을 훼손할 수도 있다는 의견이 있었다. 측정지표 명칭을 정하는 데 있어서 반려동물이라는 명칭은 한정적 표현이라며, 더 넓은 의미의 명칭으로 수정할 필요가 있다는 의견에 따라 유형의 재물 훼손으로 명칭을 수정하였다.

제조 로봇의 경우, 부품을 잘못 인식하는 행위로 재물을 손괴할 수도 있으므로 측정지표로는 필요하지만, 부품을 인식하는 것은 인공지능의 지능에 해당하는 사항이므로 그 의미가 드러나도록 지표명을 수정할 필요가 있다는 전문가 의견에 따라 인식 지능에 대한 오류로 수정 반영하였다. 또한, 비인가자 접속 허용이나 과부하 발생 지표명에 대해서도 구체화할 필요성이 있다고 회신한 의견이 있었다.

1차 델파이 설문조사에서 전문가 회신 의견을 반영하여 인가받지 않은 객체가 시스템에 접근하는 것을 허용한다면 정보 입력이나 탈취의 위험성이 있을 수 있으므로 비인가자 시스템 접근 허용으로 지표명을 수정하였다.

과부하 발생 원인은 모터, 유압 등 구동부의 문제로 볼 수 있다는 전문가 회신 의견을 반영하여 모터, 유압 등 구동부 문제로 측정지표의 명칭을 수정하였다. 보안 관리가 취약해서 악성코드나 바이러스 감염 등으로 시스템에 오류가 발생하고 센서 모니터링에 실패하면 위험성이 발생할 수 있다는 전문가 의견을 반영하여 위험성을 측정할 수 있는 지표를 추가 도출하여 2차 설문하였다. 인공지능 로봇의 이동으로 시설물이 파손될 위험성을 측정하기 위한 지표명은 다양한 상황에 의한 충돌이라는 구체적인 행위 특성을 추가할 필요가 있다는 전문가 의견을 반영하였다. 또한, 시설물 파손은 기계 결함 오작동으로 인해 발생할 수 있다는 의견을 반영하여 항목 재분류 하였으며, 수정된 내용으로 2차 설문을 진행하였다.

재산 손실 위험성 유형의 측정지표 수정 사항은 <그림 3-11>과 같이 정리하였다.



<그림 3-11> 재산 손실의 위험성 측정지표의 수정 사항

재산 손실의 위험성 측정지표의 내용타당도 분석 및 신뢰도를 분석한 결과는 [표 3-9]와 같이 나타났다.

[표 3-9] 재산 손실의 위험성 측정지표의 내용타당도 및 신뢰도 분석 결과

항목	측정지표	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
		1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
잘못된 의사결정	알고리즘 최적화 성능 부족	4.43	4.20	.883	.702	.733	.800	.812	선정
	하자 상품 추천	4.00	3.90	.931	.978	.600	.467		선정
	유형의 재물 훼손	3.90	4.33	.907	.699	.467	.867		선정
	인식 지능에 대한 오류	3.90	4.20	.978	.600	.400	.800		선정
	창작물 무단 복제	4.27	4.03	.998	1.016	.667	.533		선정
	안전거리 계산 오류	4.00	4.13	.966	.670	.467	.667		선정
정보 입력, 탈취	시스템 접근 제어망 침범	4.17	4.33	1.067	.745	.400	.800	.898	선정
	비인가 시스템 접근 허용	3.93	4.40	1.093	.952	.400	.733		선정
	악성코드, 바이러스 감염 등으로 시스템 오류	-	4.47	-	.763	-	.800		선정
기계 결합 오작동	모터, 유압 등 구동부 문제	4.27	4.00	1.062	.816	.667	.467	.836	선정
	다양한 상황에 의한 시설물 파손	3.97	4.27	.948	.680	.467	.733		선정
	센서 모니터링 실패	-	4.30	-	.737	-	.800		선정

알고리즘 최적화 성능 부족 지표의 1차 내용타당도를 분석한 결과 CVR 값이 0.733으로 나타났고 2차 내용타당도 분석 결과 0.800으로 나타나 타당도가 확보되어 선정되었다. 하자 상품 추천 지표의 1차 내용타당도 분석 결과 CVR 값이 0.600으로 나타났고 2차 내용타당도 분석 결과 0.467로 나타나 타당도가 확보되어 선정되었다.

유형의 재물 훼손 지표의 1차 내용타당도 분석 결과 0.467로 나타났고 2차 분석 결과 0.467로 나타나 타당도가 확보된 측정지표로 선정되었고, 인식 지능에 대한 오류 지표의 1차 내용타당도 분석 결과 0.400으로 나타났고 2차 분석 결과 0.800의 수치로 나타나 선정되었다. 창작물 무단 복제 지표의 1차 내용타당도 분석 결과 CVR 값이 0.667로 나타났고 2차 내용타당도 분석 결과 0.533으로 나타나 타당도가 확보된 측정지표로 선정되었고, 안전거리 계산 오류 지표의 1차 내용타당도 분석 결과 CVR 값이 0.467로 나타났고 2차 내용타당도 분석 결과 0.667의 수치로 나타나 타당도가 확보된 측정지표로 선정되었다. 시스템 접근 제어망 침범 지표의 1차 내용타당도 분석 결과 0.400으로 나타났고 2차 내용타당도 분석 결과 0.800으로 나타나 선정되었다. 비인가 시스템 접근 허용 지표의 1차 내용타당도 분석 결과 CVR 값이 0.400으로 나타났으며 2차 분석 결과 0.733의 수치로 나타나 타당도가 확보된 측정지표로 선정되었다. 2차 설문에서 추가된 악성코드, 바이러스 감염 등으로 시스템 오류 지표는 0.800의 수치로 나타나 타당성이 확보된 지표로 선정되었으며, 모터, 유압 등 구동부 문제 지표는 1차 0.677 및 2차 0.467로 나타나 선정되었다. 다양한 상황에 의한 시설물 파손 여부를 측정하기 위해 도출된 지표는 1차 0.467 및 2차 0.733으로 나타나 타당도가 확보되었으며, 2차 설문에서 추가된 센서 모니터링 실패 지표는 0.800으로 나타나 선정되었다.

2차 델파이 결과, 12개 측정지표의 내용타당도 수치가 CVR 기준값 0.333을 상회하는 것으로 나타났고, 2차 내용타당도 분석 결과로 신뢰도 값을 구하였다.


잘못된 의사결정 항목별 측정지표들의 신뢰도 수치는 0.812로 높게 나타났고, 정보 입력, 탈취 항목별 측정지표들의 신뢰도는 0.898의 수치로 높게 나타났다. 기계 결합 오작동 항목별 측정지표들의 신뢰도는 0.836으로 높게 나타나 최종 선정되었다.

1차 델파이 설문조사에서는 사회적 위험성 유형이 데이터 오인 판단, 법규 오인 판단, 도로상 작동 이상, 사회적 권한 착오 4개의 항목으로 구성돼 있었다.

1차 준개방형 델파이 설문조사 결과, 데이터 오인 판단이라는 항목 명칭에 대해 인공지능이 데이터를 오인 판단한다는 것은 맞지 않는 표현이라며 여러 가지 데이터 관련 문제를 통칭해서 데이터 문제라고 명칭을 수정할 필요성이 있다는 전문가 회신 의견을 반영하여, 2차 설문하였다. 2차 설문조사 결과, 내용타당도 수치가 CVR 기준값보다 작은 사회적 권한 착오 항목은 제거함으로써 최종 3개 항목이 선정되었다.

사회적 권한 착오 항목의 3개 측정지표는 내용타당도 수치가 CVR 기준값보다 높은 수치로 나타났다. 이는 사회적 권한 착오 항목 자체는 타당성을 확보하지 못했지만, 사회적 권한 착오를 측정할 지표 하나씩은 재산 손실의 위험성을 측정하는데 유의미함을 알 수 있었다. 1차 준개방형 델파이 설문조사에서 회신 된 전문가 의견을 반영하여 데이터 문제와 법규 오인 판단 항목의 측정지표로 재분류하고, 2차 설문하였다.

사회적 위험성 유형의 항목별 수정 사항은 <그림 3-12>와 같이 정리하였다.



<그림 3-12> 사회적 위험성 유형의 항목별 수정 사항

사회적 위험성 유형의 항목별 내용타당도 분석 및 신뢰도 분석 결과는 [표 3-10]과 같이 나타났다. 데이터 문제는 1차 내용타당도 분석 결과 0.600으로 나타났으며 2차는 0.333으로 선정되었고, 법규 판단 오류는 1차 0.333 및 2차 0.533으로 나타남에 따라 선정되었다. 도로상 작동 이상은 1차·2차에서 동일하게 0.733으로 나타나 선정되었고, 사회적 권한 착오 항목은 CVR 기준값보다 작은 0.200으로 나타나 제거되었다.


2차 델파이 설문조사에서 CVR 기준값 0.333을 상회하는 3개 항목의 신뢰도 분석 결과 0.731로 나타남에 따라 응답의 일관성인 신뢰성을 확보하였으며 3개의 항목이 최종 선정되었다.

[표 3-10] 사회적 위험성의 항목별 내용타당도 분석 및 신뢰도 분석 결과

항목	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
	1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
데이터 문제	4.20	3.87	.909	.718	.600	.333	.731	선정
법규 판단 오류	3.83	4.00	.934	.931	.333	.533		선정
도로상 작동 이상	4.17	4.20	1.035	.653	.733	.733		선정
사회적 권한 착오	3.57	-	1.309	-	.200	-	-	미 선정

사회적 위험성 유형 중 개인정보 무작위 수집·차선, 신호 인식 오류는 지표명이 하나의 예시만 표현하는 것 같아 여러 의미를 포함하는 단어인 등을 추가하는 것이 좋겠다는 전문가 의견을 반영하였다. 로봇의 작동 중지는 배터리 방전 외에도 관리

부실로 인한 연료 부족도 해당한다는 의견을 반영해 명칭을 수정하였다. 허용되지 않은 행위로 혼란을 유발하는 것은 데이터 문제가 아닌 법규 판단 오류에 해당한다는 의견을 반영하여 항목을 재분류하였다. 또한, 한 전문가는 인공지능 로봇의 자의성을 인정하지는 않지만, 로봇의 판단이나 사용자나 개발자가 의도하지 않았어도 혼란이 유발될 수 있다는 의견이었다. 전문가들 회신 의견을 반영해 사회적 위험성 유형의 측정지표를 수정하였으며, <그림 3-13>과 같이 정리하였다.



<그림 3-13> 사회적 위험성 유형의 측정지표 수정 사항

사회적 위험성 유형 측정지표의 내용타당도 분석 결과 및 신뢰도 분석 결과는 [표 3-11]과 같이 나타났다.

[표 3-11] 사회적 위험성 유형 측정지표의 내용타당도 및 신뢰도 분석 결과

항목	측정지표	평균		표준편차		내용타당도		2차 델파이 신뢰도	비고
		1차 델파이	2차 델파이	1차 델파이	2차 델파이	1차 델파이	2차 델파이		
데이터 문제	부적절한 학습 데이터수집	4.07	4.33	.964	.745	.533	.800	.925	선정
	데이터 유출	4.30	4.30	.936	.781	.667	.733		선정
	개인 등 정보 무작위 수집	4.20	4.27	.980	.929	.533	.600		선정
법규 판단 오류	법률, 규칙 혼동	4.03	4.00	.983	.931	.467	.400	.832	선정
	차선, 신호 등 인식 오류	3.90	3.97	.907	.836	.333	.533		선정
	인간이 의도하지 않은 행위로 혼란유발	4.00	4.13	.683	.921	.533	.667		선정
도로상 작동 중지	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지	4.10	3.83	1.044	1.098	.600	.400	.732	선정
	통신 이상 등 장애	4.33	4.27	.907	.680	.867	.867		선정
	보행자 통행 방해	4.27	4.07	.772	.929	.733	.600		선정

부적절한 학습 데이터수집 지표의 1차 내용타당도를 분석한 결과 CVR 값이 0.533으로 나타났고 2차 내용타당도 분석 결과 0.800으로 나타나 타당도가 확보되어 선정되었다. 데이터 유출 지표의 1차 내용타당도를 분석한 결과 CVR 값이 0.667로 나타났고 2차 내용타당도 분석 결과 0.733으로 나타나 타당도가 확보되어 선정되었다.

개인 등 정보 무작위 수집 지표의 1차 내용타당도 분석 결과, CVR 값이 0.533으로 나타났고 2차 내용타당도 분석 결과 0.600으로 나타나 타당도가 확보되어 선정되었다.

이로써 데이터 문제 항목의 3개 측정지표가 모두 타당성이 확보되어 2차 결과로 신뢰도를 분석한 결과, 0.925의 높은 수치가 나타나 신뢰성 또한 확보되었다.

법률, 규칙 혼동 지표의 1차 내용타당도 분석 결과, CVR 값이 0.467로 나타났고 2차 분석 결과 0.400으로 나타나 타당도가 확보되어 선정되었다. 차선, 신호 등 인식 오류 지표의 1차 내용타당도 분석 결과, CVR 값이 0.333으로 나타났으며, 2차 분석 결과 0.533으로 나타나 타당도가 확보되어 선정되었다. 인간이 의도하지 않은 행위로 혼란 유발 지표의 1차 내용타당도 분석 결과, CVR 값이 0.533으로 나타났으며, 2차에서도 0.667로 나타나 타당도가 확보되어 선정되었다. 법규 판단 오류 항목의 3개 측정지표가 모두 타당성이 확보되었으며 2차 결과로 신뢰도를 분석한 결과, 0.832의 수치가 나타나 신뢰성 또한 확보되었다. 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지 지표의 1차 내용타당도 분석 결과, CVR 값이 0.600으로 나타났고 2차에서도 0.400으로 나타나 타당도가 확보되어 선정되었다. 통신 이상 등 장애 지표의 1차 내용타당도 분석 결과, CVR 값이 0.867로 나타났고 2차 분석 결과도 동일하게 0.867로 나타나 타당도가 확보되어 선정되었다. 보행자 통행 방해 측정지표의 1차 내용타당도 분석 결과 CVR 값이 0.733으로 나타났고 2차 결과도 0.600으로 나타나 타당도가 확보되어 선정되었다. 도로상 작동 중지 항목의 3개 측정지표 모두 타당성이 확보되었고, 2차 결과로 신뢰도 분석 결과 0.732의 수치가 나타나 신뢰성도 확보되었다.

사회적 위험성의 데이터 문제, 법규 판단 오류, 도로상 작동 중지 항목별 모든 측정지표의 내용타당도와 신뢰도가 기준보다 높게 나타남에 따라 최종 선정되었다.

4. 인공지능 로봇의 위험성 유형별 분류 및 항목 연구 결과

문헌분석 및 전문가 인터뷰에서 도출된 인공지능 로봇의 위험성을 4개 유형으로 분류하였고 1차 준개방형 델파이 설문조사 및 2차 델파이 설문조사에 참여한 인공지능·로봇 등 여러 분야의 전문가 집단 의견 합의를 통해 제시된 인공지능 로봇의 위험성 유형별 정의는 [표 3-12]와 같다.

[표 3-12] 인공지능 로봇의 위험성 유형별 정의

구분	유형	정의	참고문헌
1	신체에 대한 물리적 위험성	인공지능 로봇의 작동 이상이나 판단의 문제로 신체를 다치게 할 유형력 행사	변순용·송선영 (2013), Wullenkord, R., Eyssel, F.(2020), 송현경·안성진 (2023)
2	인간 권리에 대한 위험성	인공지능 로봇의 정보 제공이나 발언으로 인간의 평등권·자유권·인격권을 침해	
3	재산 손실의 위험성	유형 재산의 가치 하락·무형 이익에 손실을 줄 수 있는 인공지능 로봇의 판단이나 행위	
4	사회적 위험성	인공지능 로봇이 교통 규칙이나 규범을 위반하는 등 사회 질서를 혼란스럽게 할 행위나 판단	

전문가 인터뷰, 1·2차 델파이 설문 결과, 신체에 대한 물리적 위험성은 인공지능 로봇의 작동 이상이나 판단의 문제로 인간의 신체를 다치게 할 수 있는 유형력을 행사하는 것으로 정의하였다. 인간 권리에 대한 위험성은 인공지능 로봇의 정보 제공이나 발언으로 인간의 평등권·자유권·인격권을 침해하는 것으로 정의하였다. 재산 손실의 위험성이란 유형 재산의 가치 하락·무형 이익에 손실을 줄 수 있는 인공지능 로봇의 판단이나 행위로 정의하였다. 사회적 위험성은 인공지능 로봇이 교통 규칙 위반 등 사회 질서를 혼란스럽게 할 행위나 판단을 의미하는 것으로 정의하였다.

[표 3-13]은 신체에 대한 물리적 위험성 유형의 항목별 정의를 정리한 것이다.

[표 3-13] 신체에 대한 위험성 유형의 항목별 정의

구분	항목	정의	참고문헌
1	운행, 작업 중 작동 이상	인공지능 로봇을 구성하는 기체 장치나 프로그램 또는 통신 등 이상으로 운행, 작업의 비정상적 수행	김재완(2020), 이혜원, 이자스라우프, 이수범, 김홍수 (2022)
2	인간을 해칠 판단	인간이 요구하는 의도를 잘못 파악하거나 협동 작업 중 규칙 혼동 및 프로그램 등 오류로 잘못된 정보를 제공할 수 있는 인공지능 로봇의 잘못된 판단	

인공지능 로봇의 운행, 작업 중 작동 이상은 수술·제조 작업·자율주행 등 그간 발생했던 사고로 익히 알고 있다. 따라서 인공지능 로봇을 구성하는 기체 장치나 프로그램 또는 통신 등에 어떠한 이상이 생겨서 인공지능 로봇이 운행, 작업 등을 비정상적으로 수행하는 것을 의미하는 것으로 정의하였다. 인간을 해칠 판단이란 사용자인 인간이 요구하는 사항을 인공지능 로봇이 잘못 파악하거나, 인간과 협동하는 작업 중에 규칙을 혼동하거나 프로그램 등의 오류로 인해서 사용자인 인간에게 잘못된 정보를 제공할 수 있는 인공지능 로봇의 잘못된 판단을 의미하는 것으로 정의하였다. [표 3-14]는 인간 권리에 대한 위험성 유형의 항목별 정의를 정리한 것이다.

[표 3-14] 인간의 권리에 대한 위험성 유형의 항목별 정의

구분	항목	정의	참고문헌
1	인격권 침해	인간이 느끼기에 인공지능 로봇의 모욕적인 발언이나 행위로 존중받아야 할 인격에 대한 권리를 침해	김병록(2020), 신홍임(2022), 이윤아·윤상오 (2022)
2	자유 의사 방해	인공지능 로봇이 자유로운 의사 결정에 지장을 주는 정보 제공 등 행위로 인간의 자유권을 침해	
3	선택적 서비스나 정보 제공	인공지능 로봇의 선택적 서비스나 정보 제공으로 인간이 평등하게 대우받을 권리를 침해	

인공지능과 관련된 인간 권리의 위험성에 관한 연구는 인공지능 편향성에 대한 문제와 인격권을 침해하거나 인간의 자유의지인 의사결정에 방해되는 정보를 제공한다거나 인간을 성별·종교 등으로 차별하여 선택적으로 서비스하는 등의 연구가 진행되어 왔다. 인격권 침해란 인간들이 느끼기에 인공지능 로봇의 모욕적인 발언이나 행위로 존중받아야 할 인격에 대한 권리를 침해하는 것으로 정의하였다.

자유의사 방해란 인간의 자유로운 의사결정에 인공지능 로봇이 지장을 주는 정보 제공 등 행위로 인간의 자유권을 침해하는 것을 의미하는 것으로 정의하였다.

선택적 서비스나 정보 제공은 인공지능 로봇이 인간에 대해서 어떠한 서비스나 정보를 제공할지 선택하는 행위를 함으로써 인간이 평등하게 대우받을 권리를 침해하는 것을 의미하는 것으로 정의하였다.

[표 3-15]는 재산 손실의 위험성 유형의 항목별 정의를 정리한 것이다.

[표 3-15] 재산 손실의 위험성 유형의 항목별 정의

구분	항목	정의	참고문헌
1	정보 입력, 탈취	비인가자의 시스템 접속 또는 재산상 손해를 끼치거나 타인에게 이익이 되는 정보 탈취를 허용	박소희·최대선 (2017), 오병철(2017), 최민수(2020)
2	기계 결함 오작동	인공지능 로봇이 작업 중 기체 구성 센터 등 결함으로 인해 재물 등의 가치에 손실을 줄 오작동	
3	잘못된 의사결정	인공지능 로봇의 성능 저하나 오류 등으로 재산 가치에 영향을 줄 수 있는 의사결정이나 판단	

인공지능 로봇에 의한 손해의 불법행위책임(오병철, 2017) 등 인공지능 로봇에 의한 재산 손실의 위험성에 대해서는 설계자 또는 제조사에게 법적이나 손해배상 책임을 지울 것이냐가 논란이 되고 있으며, 이러한 재산 손실의 위험성은 정보가 탈취되거나 기계에 결함이 생겨 오작동한다거나 판단을 잘못하면 발생할 수 있다.

정보 입력, 탈취란 시스템에 접속 권한이 없는 인가를 받지 않은 사람이나 외부에서 접속하는 허용되지 않은 시스템이 인공지능 로봇의 시스템에 접속해서 허위 정보를 입력하는 등의 방법으로 재산상 손해를 끼치거나, 제3자인 타인에게 이익이 될 수 있는 정보를 탈취하도록 인공지능 로봇이 허용하는 것을 의미하는 것으로 정의하였다. 기계 결함 오작동이란 인공지능 로봇이 작업 중 기체를 구성하는 센터 결함으로 인해 재물 등의 가치에 손실을 줄 오작동을 의미하는 것으로 정의하였다.

잘못된 의사결정이란 인공지능 로봇의 성능 저하나 오류 등으로 재산적 가치에 영향을 줄 수 있는 의사결정이나 판단을 의미하는 것으로 정의하였다.

[표 3-16]은 사회적 위험성 유형을 항목별로 정의를 정리한 것이다.


[표 3-16] 사회적 위험성 유형의 항목별 정의

구분	항목	정의	참고문헌
1	데이터 문제	인공지능 로봇이 대상 또는 상황에 맞지 않는 데이터를 수집하거나 권한 없이 유출하는 등의 문제	노한석·이현성·이경수 (2022), 이동건(2023)
2	법규 판단 오류	인공지능 로봇이 법률이나 규칙에 대한 판단의 오류로 사고를 일으키거나 교통 등 질서를 미준수	
3	도로상 작동 중지	인공지능 로봇이 정상으로 운행 중에 기체나 시스템 이상으로 멈춰서 자동차나 인간의 통행을 방해	

인공지능 로봇의 사회적 위험성은 정보를 유출한다거나 주로 자율주행 로봇에서 발생하는 문제일 것이다. 최근 국내 지능형로봇법 등 개정으로 연내 배달 로봇의 상용화를 앞둔 현 상황에서 도로상 작동 중지로 인한 문제나 교통법규 미준수 등 위험성 측정지표 연구는 그 중요성이 더해지고 있다.

데이터 문제란 인공지능 로봇이 특정한 대상 또는 어떤 상황에 적절하지 않은 데이터를 수집한다거나 권한이 없는데도 데이터를 유출하는 등의 문제를 의미하는 것으로 정의하였다. 법규 판단 오류란 인간들이 살아가는 세상에서 통용되는 법률이나 규칙에 대해서 인공지능 로봇이 판단에 오류를 일으켜 사고를 일으킨다거나 교통 등의 질서를 준수하지 않는 것을 의미하는 것으로 정의하였다. 도로상 작동 중지란 인공지능 로봇이 정상적으로 운행하다 기체나 시스템 이상으로 멈춤으로써 도로를 주행하던 다른 자동차 또는 인도상에서 보행하는 인간의 통행을 방해하는 것을 의미하는 것으로 정의하였다.

4개 유형 및 11개 항목을 연구 결과로 제시하였으며, 인공지능 로봇의 위험성 유형별 분류 및 항목을 <그림 3-14>와 같이 나타냈다.



<그림 3-14> 인공지능 로봇의 위험성 유형별 분류 및 항목

제2절 인공지능 로봇의 위험성 유형별 측정지표 개발


1. 인공지능 로봇의 위험성 유형별 측정지표 개발 연구 절차

1단계 연구는 델파이 설문조사 및 통계 검증하여 인공지능 로봇의 위험성을 4개 유형으로 분류하였고, 11개 항목을 제시한 연구 내용을 정리해서 제시하였다.

2단계 연구에서는 인공지능 로봇의 위험성 유형별 모형 및 측정지표 개발을 위해 IRB 심의 이후, 전문가 11명을 대상으로 추가 측정지표 도출을 위해 인터뷰하였다.

현장성 검증을 위해 인공지능 로봇이 도입될 수 있는 여러 분야 종사자에게 설문 조사하였고, 타당성 및 신뢰성 측정을 위해 탐색적 요인분석·신뢰도 분석 및 상관관계 분석과 다중 회귀분석 등 통계 검증하여, 개발하는 연구 내용을 정리하였다.

인공지능 로봇의 위험성 유형별 측정지표 개발 연구 절차는 <그림 3-15>와 같다.



<그림 3-15> 인공지능 로봇의 위험성 유형별 측정지표 개발 연구 절차

2. 전문가 인터뷰

인공지능 로봇의 산업화는 하루가 다르게 발전하고 있어 새로운 위험 요소들이 생겨나고 있으며, 인공지능 로봇의 위험성 분류 유형 및 항목을 제시한 이후에도 문제점은 계속해서 발생하고 있다.

인공지능 로봇의 위험성 유형별 측정지표 개발의 필요성이 있어, 성균관대학교 기관 IRB에서 연구 승인(SKKU 2023-07-026)을 받았고, 2023년 7월 18일부터 7월 28일까지 3회에 걸쳐서 전문가 인터뷰 등 연구를 진행하였다.

측정지표 개발을 위해 1단계 델파이 설문에 참여했던 전문가 중에서 추가 측정지표 도출 인터뷰에 동의한 11명이 참여하였으며, 전문가 그룹 정보는 [표 3-17]과 같다.

전문가 인터뷰를 통해 추가 측정지표를 도출하고 현장성 검증을 위한 설문 등 검증 방법을 선정하였으며, 연구가설을 검증하기 위한 설문지 문항을 설계하였다.

[표 3-17] 전문가 인터뷰 참여자 그룹 정보

구분	성별	연령	직업군	경력
1	남	30대	IT 보안	5년
2	남	30대	공공분야	10년
3	남	50대	AI 윤리학자	33년
4	여	40대	AI, SW 교육	15년
5	남	30대	공공분야	7년
6	남	50세	공공분야	25년
7	남	40대	로봇 개발	11년
8	남	30대	ICT 분야	6년
9	남	50대	로봇 분야 연구	26년
10	남	50대	컴퓨터 교육 교수	24년
11	남	50대	공공분야	19년

전문가 인터뷰는 남성 10명과 여성 1명이 참여한 것으로 나타났고, 30대는 4명, 40대 2명, 50대 5명이 참여하였다. 공공분야 종사자 4명, 로봇 개발 분야 1명, 로봇 연구 분야 1명, IT 보안 전문가 1명, 인공지능 윤리학자 1명, 인공지능·소프트웨어 교육 분야 종사자 1명, ICT 분야 종사자 1명, 컴퓨터 교육 교수 1명이 참여하였다.

로봇 개발 분야 전문가는 운행 작업 중 작동 이상을 일으킬 제어 및 필터 성능 저하나 부품 교체 시기 경과 지표를 추가하는 것이 좋겠다는 의견이었으며, 라벨링 오류로 인한 잘못된 정보 제공 및 장애물 인식 오류로 인간을 해칠 판단을 할 수 있다는 의견을 제시하였다. 또한, 감속기 제어나 정비 불량 및 제어기 오류가 기계 결함으로 인한 오작동을 일으킬 수 있다고 하였으며, 도로상 작동 중지는 도로매칭 알고리즘 오류나 주변 환경 변화에 대한 반응 속도 저하, 이동 속도 제어 실패로 인한 측정지표가 필요하다는 의견이었다. 로봇 연구 분야 전문가는 제어 및 필터 성능 보다는 모션제어 시스템이라는 명칭이 적절하다는 의견을 제시하여 이를 반영하였다. 제어기 오류는 감속기 제어를 포함한 상위 개념이라며 감속기 제어는 필요 없다는 의견도 있었는데, 여러 전문가는 설문조사 결과를 통계 분석한 결과로 제거함이 타당하다고 하여 추가 도출된 지표 모두 설문조사 문항으로 작성하였다.

인공지능 윤리학자·교육학자·보안 전문가·ICT 분야 종사자·교수 등은 사물 인식 판단 지능 저하, 허용되지 않은 권한의 오인 판단, 습득 정보 미 권한자 제공, 허위 정보 제공 등 주로 인공지능의 인식 또는 판단과 관련된 추가 의견을 제시하였다.

이외에도 법규 최신화 업데이트 오류, 데이터 업데이트 오류, 데이터 손실 방지 시스템 취약, 시나리오 설계 문제로 부적절한 콘텐츠 제공, 도덕성 검증이 되지 않은 학습 데이터 사용 등 인간에 의한 설계나 관리적 측면에서 의견을 제시하였다.

추가 도출된 지표들에 대해 인공지능 윤리학자·공공분야 전문가들은 인공지능에 대한 의존도와 기계적 및 판단적 오류로 발생할 수 있는 위험과 잘못된 학습 결과 혹은 동작 시 발생할 수 있는 여러 변수가 잘 포함된 것으로 보인다는 의견이었다.

인공지능 윤리학자와 컴퓨터 교육 교수가 설문 문항 작성 및 검토에 참여하였다.

3. 인공지능 로봇의 위험성 유형별 측정지표 정의

1단계 연구에서는 델파이 설문을 통해 검증하여 측정지표 37개가 도출되었으며, 2단계 연구의 전문가 인터뷰를 통해 측정지표 28개를 추가로 도출하고, 총 65개의 측정지표에 대한 정의를 하였다.

1단계 연구에서 제시된 37개 측정지표 이외에 인공지능 로봇의 위험성을 측정할 수 있는 필수 지표에 대한 전문가들 의견이 개진되었으며, 전문가 인터뷰를 3회에 걸쳐서 진행하는 과정을 통해 추가로 28개 측정지표가 도출되었다.

전문가 인터뷰에서는 측정지표 내용들이 점검되지 않는다면 신체·권리 등 어떤 위험성을 일으킬 수 있는지 명확하게 개념을 나타내도록 명칭에 맞게 정의하였다.

신체에 대한 위험성 유형에는 운행 작업 중, 작동 이상과 인간을 해칠 판단으로 2개 항목이 있고 운행, 작업 중 작동 이상 항목에는 7개 측정지표가 도출되었으며, 인간을 해칠 판단 항목에는 8개의 측정지표가 도출되었다.

인간 권리에 대한 위험성 유형에는 인격권 침해, 자유의사 방해, 선택적 서비스나 정보 제공으로 3개 항목이 있고, 인격권 침해 항목을 포함해서 자유의사 방해 항목 및 선택적 서비스나 정보 제공 항목마다 각각 5개씩의 측정지표가 도출되었다.

재산 손실의 위험성 유형에는 정보 입력, 탈취, 기계 결함 오작동, 잘못된 의사 결정으로 3개 항목이 있고 정보 입력, 탈취 항목에는 5개 측정지표가 도출되었으며, 기계 결함 오작동 항목에는 6개의 측정지표가 도출되었고, 잘못된 의사 결정 항목에는 7개의 측정지표가 도출되었다.

사회적 위험성 유형에는 데이터 문제, 법규 판단 오류, 도로상 작동 중지라는 3개 항목이 있고, 데이터 문제 항목 및 법규 판단 오류 항목에는 각 5개의 측정지표가 도출되었으며, 도로상 작동 중지 항목에는 7개의 측정지표가 도출되었다.

신체에 대한 위험성 유형에서 운행 작업 중, 작동 이상 측정지표에 대한 정의는 [표 3-18]과 같이 정리하였다.

[표 3-18] 신체에 대한 위험성 유형 중, 운행 작업 중, 작동 이상의 측정지표 정의

구분	측정지표	정의
1	센서 및 인식 오류	거리 감지, 사물 포착 등 정상 작동에 이상이 생기면 인간 신체와 충돌할 위험성이 있으므로 센서 및 인식 오류를 점검하여야 한다.
2	운동 지능 제어 실패	좁고 복잡한 도로 등 비정형 환경에서 운동(이동) 중, 장애 물체에 걸려 균형을 잃으면 인간을 향해 넘어질 위험성이 있으므로 운동 제어 기능을 점검하여야 한다.
3	기체 성능 저하	협동 제조 작업 중, 압력 조절에 실패하거나 반응 속도 조절 등이 저하되면, 인간의 신체를 잡거나 누르는 등의 위험성이 있으므로 기체의 성능 상태를 점검하여야 한다.
4	프로그램 오류로 인한 오작동	바이러스로 파일 손상, 용량 부족, 메모리 초과, 에러 등 프로그램 이상으로 갑자기 운행을 멈추면 예기치 못한 충돌의 위험성이 있어 프로그램 오류로 인한 오작동이 발생하지 않도록 점검하여야 한다.
5	통신 장애 등 사고 위험 감지 지연	운행 중, 주파수 이상 등 장애로 사고 위험을 늦게 감지함으로써 방향을 잃거나 운반하던 물건이나 기체 자체가 인간을 향해 낙하하는 등 위험성이 있으므로 통신의 수신 상태를 점검하여야 한다.
6	모션 제어 시스템 성능 저하	정확하게 목표한 위치에 도달하게 하는 움직임 제어 시스템이나 위치 추정 최적 값을 예측하는 시스템이 노후화되면 기체가 인간이 지나가는 위치에 착지할 위험성이 있으므로 성능을 점검하여야 한다.
7	부품 교체 시기 경과	장기간 사용으로 (나사가 풀리고 접촉이 약해지는 등) 부품이 마모되거나 구동 중인 소프트웨어의 단종으로 제 기능을 못하면 작업 중인 인간이 다칠 위험성이 있으므로 부품 상태를 점검하여야 한다.

신체에 대한 위험성 유형 중, 운행 작업 중, 작동 이상 항목에는 센서 및 인식 오류 지표와 기체 성능 저하, 운동 지능 제어 실패, 통신 장애 등 사고 위험 감지 지연, 프로그램 오류로 인한 오작동, 모션 제어 시스템 성능 저하, 부품 교체 시기 경과 등 7개 측정지표가 도출되었다. 센서 및 인식 오류란 거리 감지, 사물 포착 등 정상 작동에 이상이 생기면 인간 신체와 충돌할 위험성이 있으므로 센서 및 인식 오류를 점검하기 위한 측정지표로 정의하였고, 운동 지능 제어란 실패 좁고 복잡한 도로 등 비정형 환경에서 운동(이동) 중, 장애 물체에 걸려 균형을 잃으면 인간을 향해 넘어질 위험성이 있으므로 운동 제어 기능을 점검하기 위한 측정지표로 정의하였다. 기체 성능 저하란 협동 제조 작업 중, 압력 조절에 실패하거나 반응 속도 조절 등이 저하되면 인간의 신체를 잡거나 누르는 등의 위험성이 있으므로 기체의 성능 상태를 점검하기 위한 측정지표로 정의하였다. 프로그램 오류로 인한 오작동이란 바이러스로 파일 손상, 용량 부족, 메모리 초과, 에러 등 프로그램 이상으로 갑자기 운행을 멈추면 예기치 못한 충돌 위험성이 있어 프로그램 오류로 오작동이 발생하지 않도록 점검하기 위한 측정지표로 정의하였다. 통신 장애 등 사고 위험 감지 지연이란 운행 중, 주파수 이상 등의 장애로 사고 위험을 늦게 감지함으로써 방향을 잃거나 운반하던 물건이나 기체 자체가 인간을 향해 낙하하는 등 위험성이 있으므로 인공지능 로봇 통신의 수신 상태를 점검하기 위한 측정지표로 정의하였다.

모션 제어 시스템 성능 저하란 정확하게 목표한 위치에 도달하게 하는 움직임을 제어하는 시스템이나 위치를 추정하는 최적값을 예측하는 시스템이 노후되면, 인공지능 로봇 기체가 인간이 지나가는 위치나 그 부근에 착지할 수 있는 위험성이 있으므로 성능을 점검하기 위한 측정지표로 정의하였다. 부품의 교체 시기 경과란 인공지능 로봇을 장기간 사용하면 나사가 풀리거나 접착이 약해지는 등의 이유로 부품이 마모되거나 구동 중인 소프트웨어의 단종으로 제 기능을 못 해서 작업 중인 인간이 다칠 위험성이 있으므로 부품 상태를 점검하기 위한 측정지표로 정의하였다. 신체에 대한 위험성 유형 중, 인간을 해칠 판단의 측정지표 정의는 [표 3-19]에 정리하였다.

[표 3-19] 신체에 대한 위험성 유형 중, 인간을 해칠 판단의 측정지표 정의

구분	측정지표	정의
1	의도 파악 인식 오류	비정상적 소음을 음성 명령으로 인식하거나 내포된 의도를 잘못 파악해 상호작용 놀이를 공격으로 인식하는 오류로 인간을 밀치는 등의 위험성이 있으므로 의도 파악 인식 상태를 점검하여야 한다.
2	협동 작업 중, 규칙 판단 지능의 오류	수술을 보조하거나 협동 제조 작업 중, 작업자 간의 상호 규칙을 혼동하면 환자 또는 같이 작업하던 인간에게 상해를 입힐 위험성이 있으므로 협동 규칙 판단 지능의 오류 여부를 점검하여야 한다.
3	프로그램의 판단 오류로 사고 희생자 선택 착오	예기치 못한 사고 등 문제 상황 발생 시, 외형만으로 생존 가능성이 더 낮다고 판단되는 인간을 선택해서 충돌할 위험성이 있으므로 판단 오류로 사고 희생자를 선택할 착오가 있는지 점검하여야 한다.
4	학습량 부족으로 맞지 않는 의학적 자료 제공	수술이나 진료 관련 데이터가 충분하게 학습되지 않은 상태에서 환자에게 적절하지 않은 진단이나 처방 등 의학적 자료를 제공함으로써 인간의 생명에 지장을 줄 위험성이 있는지 점검하여야 한다.
5	학습된 규칙이나 로봇의 원칙을 넘어서는 판단	인간을 해하지 못하도록 학습되고 원칙이 설정돼있음에도 로봇이 자의적으로 원칙을 넘어서는 판단을 해, 신체의 자유를 억압하거나 밀치기 등 방어적 폭행을 행할 위험성이 있는지 점검하여야 한다.
6	라벨링 오류로 인한 잘못된 정보 제공	(수술 도구 이름을 잘못 입력하는 등) 데이터 라벨링을 잘못 지정하면 잘못된 정보로 판단 및 (인간을 수술하는) 작업을 함으로써 인간의 신체에 위험성이 있으므로 데이터 라벨링 오류를 점검하여야 한다.
7	장애물 인식 오류	운행, 작업 중 (머리카락 등 신체의 일부 또는 물체 등 걸림물) 장애물을 제대로 인식하지 못해 밟고 지나가거나 넘어질 경우 인간이 다칠 위험성이 있으므로 장애물 인식 오류에 대해서 점검하여야 한다.
8	비상 상황 안전 정지 모니터링 실패	속도·이격거리·힘 등 이상 감지를 위한 모니터링 실패로 인간에게 상해를 입힐 위험성이 있으므로 이상 감지 시 작업을 즉각 정지해 인간의 상해를 방지하도록 모니터링 정상 여부를 점검하여야 한다.

신체에 대한 위험성 유형 중, 인간을 해칠 판단 항목에는 8개 측정지표가 도출되었다. 의도 파악 인식 오류란 비정상적인 소음을 인간이 내린 음성 명령으로 인식한다거나 인간이 사용하는 말에 내포돼 있는 의도나 뜻을 다른 의미로 잘못 파악해 상호작용 높이를 공격으로 인식하는 오류로 인간을 밀치는 등의 위험성이 있으므로 의도 파악 인식 상태를 점검하기 위한 측정지표로 정의하였다. 협동 작업 중, 규칙 판단 지능의 오류란 수술을 보조하거나 협동 제조 작업 중, 작업자 간의 상호 규칙을 혼동하면 환자 또는 같이 작업하던 인간에게 상해를 입힐 위험성이 있으므로 협동 규칙 판단 지능의 오류 여부를 점검하기 위한 측정지표로 정의하였다. 프로그램의 판단 오류로 사고 희생자 선택 착오란 예기치 못한 사고 등 문제 상황 발생 시, 외형만으로 생존 가능성이 더 낮다고 판단되는 인간을 선택해서 충돌할 위험성이 있으므로 판단 오류로 사고 희생자를 선택할 착오가 있는지 점검하기 위한 측정지표로 정의하였다. 학습량 부족으로 맞지 않는 의학적 자료 제공이란 수술·진료와 관련된 데이터가 충분히 학습되지 않은 상태에서 환자에게 적절하지 않은 진단이나 처방 등 의학적 자료를 제공함으로써 인간의 생명에 지장을 줄 수 있는 위험성이 있는지 점검하기 위한 측정지표라고 정의하였다. 학습된 규칙이나 로봇의 원칙을 넘어서는 판단이란 인간을 해를 가하지 못하도록 학습되고, 원칙이 설정돼 있음에도 로봇이 자의적으로 원칙을 넘어서는 판단을 함으로써, 신체의 자유를 억압하거나 밀치기 등 방어적인 폭행을 행할 위험성이 있는지 점검하기 위한 측정지표로 정의하였다.

라벨링 오류로 인한 잘못된 정보 제공이란 데이터마다 이름을 입력하는 라벨링 작업을 잘못하면 인공지능 로봇이 잘못된 판단을 할 수 있고, 이는 인간의 신체에 위험성이 있으므로 데이터 라벨링 오류를 점검하기 위한 측정지표라고 정의하였다.

장애물 인식 오류란 운행, 작업 중 장애물을 제대로 인식하지 못해 밟고 지나가거나 넘어질 경우 인간이 다칠 위험성이 있으므로 장애물 인식 오류에 대해서 점검하기 위한 측정지표로 정의하였다. 비상 상황 안전 정지 모니터링 실패란 속도·이격 거리·힘 등 이상 감지를 위한 모니터링 실패로 인간에게 상해를 입힐 위험성이 있어

이상한 신호 등이 감지될 경우에는 작업을 즉각 정지함으로써 인간의 상해를 방지할 수 있도록 모니터링 정상 여부를 점검하기 위한 측정지표로 정의하였다. 인간 권리에 대한 위험성 유형에는 인격권 침해, 자유의사 방해, 선택적 서비스나 정보 제공 3개 항목이 있고, 인격권 침해 측정지표 정의는 [표 3-20]과 같이 정리하였다.

[표 3-20] 인간의 권리에 대한 위험성 유형 중, 인격권 침해의 측정지표 정의

구분	측정지표	정의
1	명령어 등 음성을 잘못 인식	(사적인 대화, 비정상적 소리 등) 소음이나 대화를 명령어로 잘못 인식해 녹음하거나 타인에게 전송함으로써 인간의 사생활을 침해할 위험성이 있으므로 명령어 등 음성 인식 오류를 점검하여야 한다.
2	감정 피드백 오류	상담 등 대화 중, 개개인의 성향에 따라 상처받을 수 있는 발언을 함으로써 인간의 감정을 상하게 할 위험성이 있으므로 감정에 대한 피드백 관련 데이터 학습이 세밀하게 돼있는지를 점검하여야 한다.
3	대상 인식 판단 오류	(대머리를 공으로 인식하고, 사진을 보고 고릴라로 판단 등) 인간의 생김새를 물건이나 동물로 오인 판단해서 모욕적 언어나 행위를 하는 등 존중받아야 할 인격에 대한 권리 침해의 위험성이 있으므로 대상을 인식하는데 있어 판단에 오류가 있는지를 점검하여야 한다.
4	도덕성 검증이 되지 않은 학습 데이터 사용	편향적인 학습 데이터의 문제로 딥 페이크나 성희롱, 인종차별 등 모욕적 발언을 함으로써 인간의 명예를 침해할 위험성이 있으므로 도덕성이 검증되지 않은 학습 데이터 사용 여부를 점검하여야 한다.
5	멀티 모달리티 오류	언어나 감정, 행동의 의미, 내포된 의도를 인지하는데 필요한 시각, 청각 등의 멀티 모달 인터페이스의 혼합작용 오류로 인해 로봇이 기대한 작업을 정확하게 수행하지 못해서 인간의 권리를 침해할 위험성이 있으므로 멀티 모달리티 오류를 점검하여야 한다.

인간의 권리에 대한 위험성 유형 중, 인격권 침해 항목에는 명령어 등 음성을 잘못 인식하거나 감정 피드백 오류 및 대상 인식 판단 오류, 도덕성 검증이 되지 않은 학습 데이터 사용, 멀티 모달리티 오류 5개의 측정지표가 도출되었다.

명령어 등 음성을 잘못 인식하는 측정지표는 인간 사이의 사적인 대화나 소음을 명령어로 잘못 인식해 녹음하거나 타인에게 전송함으로써 인간의 사생활을 침해할 위험성이 있으므로 명령어 등 음성 인식 오류를 점검하기 위한 의미로 정의하였다.

감정 피드백 오류 측정지표는 인공지능 로봇이 인간과 상담 등 대화 중, 인간 개인의 성향 차이로 상처받을 수 있는 발언을 할 수 있으므로 인간의 감정에 대한 피드백 관련 데이터 학습이 세밀하게 돼 있는지 점검하기 위한 의미로 정의하였다.

대상 인식 판단 오류 측정지표는 인간의 생김새를 물건이나 동물로 오인 판단해 모욕적 언어나 행위를 하는 등 존중받아야 할 인격에 대한 권리 침해의 위험성이 있으므로 대상을 인식하는 데 있어 판단에 오류가 있는지를 점검하기 위한 측정지표라고 정의하였다.

도덕성 검증이 되지 않은 학습 데이터 사용 측정지표는 편향적인 학습 데이터의 문제로 딥페이크나 성희롱, 인종차별 등 모욕적 발언을 함으로써 인간 개인의 명예를 침해할 수 있는 위험성이 있으므로 도덕성이 검증되지 않은 학습 데이터 사용 여부를 점검하기 위한 의미로 정의하였다.

멀티 모달리티 오류 측정지표는 언어나 감정, 행동의 의미, 내포된 의도를 인지하는 데 필요한 시각, 청각 등의 멀티 모달 인터페이스의 혼합 작용 오류로 인하여 인간이 기대한 작업을 인공지능 로봇이 정확하게 수행하지 못해서 인간의 권리를 침해할 수 있는 위험성이 있으므로 멀티 모달리티 오류를 점검하기 위한 의미로 정의하였다.

인간의 권리에 대한 위험성 유형 중에서 자유의사 방해 항목의 측정지표에 대한 정의는 [표 3-21]과 같이 정리하였다.

[표 3-21] 인간의 권리에 대한 위험성 유형 중, 자유의사 방해의 측정지표 정의

구분	측정지표	정의
1	의사결정을 특정 방향으로 유도	어느 한 분야에 치우침 없이 여러 분야의 정보를 골고루 제공해야 함에도 특정 정보를 중점적으로 제공함으로써 인간의 객관적 의사 결정에 방해가 될 위험성이 있으므로 의사결정을 특정 방향으로 유도하도록 편향된 정보를 제공하는지에 대해서 점검하여야 한다.
2	여론 형성 조장	특정인이나 특정 집단에 유리한 정보를 지속적으로 제공함으로써 인간이 자유로운 의사결정을 함에 있어 지장을 초래할 위험성이 있으므로 여론 형성을 조장하는 정보를 제공하는지 점검하여야 한다.
3	중요한 결정을 위한 관리자의 개입 차단	(수술, 변호, 치안 등) 보조 역할 수행 중, 최종 결정이 필요한 상황에서 자의적으로 판단해서 결과를 제공하는 등 인간의 자유권을 침해할 수 있으므로 인간의 결정이 필요한 중요한 상황에 개입을 차단하거나 자의적으로 판단할 위험성이 있는지 점검하여야 한다.
4	필터링 오류로 의사 표현의 자율성 침해	모니터링 중, (욕설, 비방, 스팸이 아님에도) 단어 인식을 잘못해서 글이 게재되지 않도록 차단하는 등 자유로운 의사 표현의 자유를 방해할 위험성이 있으므로 필터링 오류가 있는지 점검하여야 한다.
5	우월적인 지위를 이용해서 인간의 심리 지배	(상담 환자, 아동·청소년 등) 불안정한 심리 상태를 인지했음에도 불필요한 상담을 지속하거나, 자기 결정 능력이 부족한 인간 대신 중요한 결정을 하는 등 우월적인 지위에서 인간의 심리를 지배함으로써 인간의 자유권을 침해할 위험성이 있는지 점검하여야 한다.

인간의 권리에 대한 위험성 유형 중, 자유의사 방해 항목에는 의사결정을 특정 방향으로 유도하거나 여론 형성을 조장, 중요한 결정을 위한 관리자의 개입 차단, 필터링 오류로 의사 표현의 자율성 침해, 우월적인 지위를 이용해서 인간의 심리 지배 등 5개의 측정지표가 도출되었다.

의사결정을 특정 방향으로 유도 측정지표는 어느 한 분야에 치우침 없이 여러 분야의 정보를 골고루 제공해야 함에도 특정적인 정보를 중점적으로 제공함으로써 인간의 객관적인 의사결정에 방해가 될 위험성이 있으므로 의사결정을 특정한 방향으로 유도하도록 편향된 정보를 제공하는지를 점검하기 위한 의미로 정의하였다.

여론 형성 조장 측정지표는 특정인이나 특정 집단에만 유리한 정보를 지속해서 제공함으로써 인간이 자유로운 의사결정을 함에 있어 지장을 초래할 위험성이 있으므로 여론 형성을 조장하는 정보를 제공하는지 점검하기 위한 의미로 정의하였다.

중요한 결정을 위한 관리자의 개입 차단 측정지표는 수술이나 변호 등 인간의 보조 역할을 수행 중에 인간의 최종 결정이 필요한 상황에서 자의적으로 판단해서 결과를 제공한다면 인간의 자유권을 침해할 수 있으므로 인간의 결정해야 할 중요한 상황에서 인간의 개입을 차단하거나 자의적으로 판단할 위험성이 있는지를 점검하기 위한 의미로 정의하였다.

필터링 오류로 의사 표현의 자율성 침해 측정지표는 사용자들이 욕설이나 비방하는 말을 사용하거나 스팸이 아닌데 인공지능 로봇이 단어 인식을 잘못함으로써 모니터링 중에 사용자의 글이 게재되지 않도록 차단하는 등 자유로운 의사 표현의 자유를 방해할 수 있는 위험성이 있으므로 모니터링 중 필터링에 오류가 있는지를 점검하기 위한 의미로 정의하였다.

우월적인 지위를 이용해서 인간의 심리 지배 측정지표는 인공지능 로봇이 환자·아동·청소년 등을 상담 중에 인간의 불안정한 심리 상태를 인지했음에도 불필요한 상담을 지속하거나 자기 스스로 결정할 수 있는 능력이 부족한 상태인 인간을 대신해서 위험할 수도 있는 중요한 결정을 인공지능 로봇이 하는 등 우월적인 지위에서 인간의 심리를 지배함으로써 인간의 자유권을 침해할 수 있는 위험성이 있는지 점검하기 위한 의미로 정의하였다.

인간의 권리에 대한 위험성 유형 중에서 선택적 서비스나 정보 제공의 측정지표 정의는 [표 3-22]에 정리하였다.

[표 3-22] 인간의 권리에 대한 위험성 유형 중, 선택적 서비스나 정보 제공의 측정지표 정의

구분	측정지표	정의
1	학습 데이터 오류로 인해 잘못된 언어 사용	(욕설, 비방, 은어, 범죄 등에 연관된) 부적절한 단어를 수집하거나 학습할 경우, 인간에게 사용하면 안 될 언어를 사용할 위험성이 있으므로 잘못된 언어를 사용하는지 학습 데이터 오류를 점검하여야 한다.
2	편향된 학습 데이터로 인한 차별적 정보 제공	어느 한쪽으로 치우친 데이터를 수집하고 학습해서 편향된 정보를 제공함으로써 인간의 보편적인 정보 획득 권리를 침해하거나 성별, 인종, 종교 등 갈등을 조장할 위험성이 있으므로 편향된 데이터로 학습하거나 차별적 정보를 제공하는지 여부를 점검하여야 한다.
3	시스템 공격 등으로 개인정보의 침해나 유출	해킹 등 외부 공격, 접근이 허용된 것으로 오인, 바이러스로 인한 시스템 제어 실패 등 권한 없는 시스템이나 인간의 개인정보 침해를 위한 접근을 임의로 허용하거나 시스템 오류로 개인정보를 유출할 위험성이 있으므로 개인정보 보호를 위해 시스템을 점검하여야 한다.
4	대상자의 지식수준에 따라 선별적 정보 제공	대화하면서 파악한 대상자의 지적 능력이나 질문의 수준에 따라서 대략적이거나 가짜 정보를 생산해서 제공하는 등 인간이 평등하게 정보를 제공받을 기회를 침해할 위험성이 있으므로 대상자의 지식 수준 등에 따라서 선별적으로 정보를 제공하는지 점검하여야 한다.
5	시나리오 설계 문제로 부적절한 콘텐츠 제공	맞춤형 안내를 위한 시나리오 설계 시, 성별, 연령 등 형평을 고려하지 않음으로써 부적절한 콘텐츠를 제공하는 등 공평한 서비스를 받을 권리 침해의 위험성이 있으므로 대상별 맞춤형 콘텐츠를 적절하게 제공받을 수 있도록 시나리오 설계 문제를 점검하여야 한다.

인간의 권리에 대한 위험성 유형 중, 선택적 서비스나 정보 제공 항목에는 학습 데이터 오류로 인해 잘못된 언어 사용이나 편향된 학습 데이터로 인한 차별적 정보 제공,

시스템 공격 등으로 개인정보 침해나 유출, 대상자의 지식수준에 따라 선별적 정보 제공, 시나리오 설계 문제로 부적절한 콘텐츠 제공 등 5개의 측정지표가 도출되었다.

학습 데이터 오류로 인해 잘못된 언어 사용 측정지표는 욕설이나 비방하는 말, 은어 또는 범죄 등에 연관된 부적절한 단어를 수집하거나 학습할 경우 인간에게 사용하면 안 될 언어를 사용할 위험성이 있으므로 잘못된 언어를 사용하는지 학습 데이터 오류를 점검하기 위한 의미로 정의하였다. 편향된 학습 데이터로 인한 차별적 정보 제공이란 어느 한쪽으로 치우친 데이터를 수집하고 학습한다면 인간이 보편적 정보를 획득할 수 있는 권리를 침해하거나 성별·인종·종교 등 갈등을 조장할 위험성이 있으므로 편향된 데이터로 학습하거나 차별적 정보 제공 여부를 점검하기 위한 의미로 정의하였다. 시스템 공격 등으로 개인정보의 침해나 유출 측정지표는 해킹 등 공격이 있을 때 외부 접근이 허용된 것으로 오인하거나 바이러스로 인한 시스템 제어 실패 등 권한 없는 시스템이나 인간의 개인정보 침해를 위한 접근이 시도될 경우에 인공지능 로봇이 임의로 허용해 주거나 시스템상에 오류가 생긴다면 개인정보를 유출할 위험성이 있으므로 개인정보 보호를 위해 시스템을 점검하기 위한 의미로 정의하였다.

대상자의 지식수준에 따라 선별적 정보 제공이란 인공지능 로봇이 인간과 대화 하면서 파악한 대상자의 지적 능력이나 질문의 수준에 따라서 간단하게만 정보를 제공하거나 가짜 정보를 생산하면 평등하게 정보를 제공받을 기회를 침해할 위험성이 있으므로, 대상자의 지식수준 등에 따라 선별적으로 정보를 제공하는지 점검하기 위한 의미로 정의하였다. 시나리오 설계 문제로 부적절한 콘텐츠 제공은 맞춤형 안내를 위한 시나리오 설계 시, 성별, 연령 등 형평을 고려하지 않음으로써 부적절한 콘텐츠를 제공하는 등 공평한 서비스를 받을 권리 침해의 위험성이 있으므로 대상별 맞춤형 콘텐츠를 적절하게 제공받을 수 있도록 시나리오 설계 문제를 점검하기 위한 의미로 정의하였다.

재산 손실의 위험성에는 정보 입력, 탈취와 기계 결함 오작동, 잘못된 의사 결정 등 3개 항목이 있고 정보 입력, 탈취 측정지표 정의는 [표 3-23]에 정리하였다.

[표 3-23] 재산 손실의 위험성 유형 중, 정보 입력, 탈취의 측정지표 정의

구분	측정지표	정의
1	시스템 접근 제어망 침범	접근이 허용되지 않은 시스템에 접속하는 등 제어망을 침범함으로써 다른 기업이나 기관의 영업상 비밀 등 이익이 되는 정보를 탈취할 위험성이 있으므로 시스템 접근 제어망의 안전성을 점검하여야 한다.
2	비인가 시스템 접근 허용	권한 없는 시스템이 화폐 등 가치를 떨어뜨리려고 시스템에 접근해 조작을 시도할 때, 관리자의 허가 없이 접근을 허용함으로써 손해를 끼칠 위험성이 있으므로 비인가 시스템 접근 여부를 점검하여야 한다.
3	악성코드, 바이러스 감염 등으로 시스템 오류	주식 등 자동 매매·거래 프로그램이 악성코드, 바이러스 등에 감염 되면 비정상적 거래가 발생해 재산 가치 하락의 위험성이 있으므로 네트워크나 보안 시스템상의 오류 여부를 수시로 점검하여야 한다.
4	데이터 손실 방지 시스템 취약	시스템이 보안에 취약해 이익 창출을 위한 데이터가 손실되면 재산 손실의 위험성이 있으므로 데이터 보호를 위해 IT망, OT망 보안을 강화하고 데이터 손실에 대비해 복구, 백업 기능을 점검하여야 한다.
5	허용되지 않은 정보 수집 및 이용	오픈 사이트에서 사용자가 동의하지 않은 정보를 수집하거나 광고 등에 부적절하게 이용함으로써 타인의 재산권 침해 위험성이 있으므로 허용되지 않은 정보를 수집하거나 이용하는지 점검하여야 한다.

재산 손실의 위험성 유형 중에서 정보 입력, 탈취 항목에는 시스템 접근 제어망 침범이나 비인가 시스템 접근 허용, 악성코드, 바이러스 감염 등으로 시스템 오류 및 데이터 손실 방지 시스템 취약, 허용되지 않은 정보 수집 및 이용 등 5개 측정지표가 도출되었다.

시스템 접근 제어망 침범 측정지표는 접근이 허용되지 않은 시스템에 접속하는 등 제어망을 침범한다면 다른 기업이나 기관의 영업상 비밀 등 이익이 되는 정보를 탈취할 위험성이 있으므로 시스템 접근 제어망의 안전성을 점검하기 위한 의미로 정의하였다.

비인가 시스템 접근 허용 측정지표는 권한 없는 외부 시스템이 화폐 등의 가치를 떨어뜨리기 위해서 인공지능 로봇 시스템에 접근해 조작을 시도할 경우, 관리자의 허가 없이 접근을 허용함으로써 손해를 끼칠 위험성이 있으므로 비인가 시스템 접근 여부를 점검하기 위한 의미로 정의하였다.

악성코드·바이러스 감염 등으로 시스템 오류 측정지표는 주식 등 자동 매매·거래 프로그램이 악성코드나 바이러스 등에 감염되면 비정상적인 거래가 발생함으로써 재산 가치 하락의 위험성이 있으므로 네트워크나 보안 시스템 오류 여부를 수시로 점검하기 위한 의미로 정의하였다.

데이터 손실 방지 시스템 취약 측정지표는 시스템이 보안에 취약해 이익 창출을 위한 데이터가 손실되면 재산 손실의 위험성이 있으므로 데이터 보호를 위해 IT망, OT망 보안을 강화하고 데이터 손실에 대비함으로써 복구, 백업 기능을 점검하기 위한 의미로 정의하였다.

허용되지 않은 정보 수집 및 이용 측정지표는 오픈돼 있는 사이트에서 사용자나 다른 시스템에서 동의하지 않은 정보를 마구잡이로 수집하거나 광고 등에 부적절하게 이용함으로써 타인의 재산권을 침해할 위험성이 있으므로 허용되지 않은 정보를 수집하거나 이용하는지 점검하기 위한 의미로 정의하였다.

재산 손실의 위험성 유형 중, 기계 결함 오작동 항목의 측정지표에 대한 정의는 [표 3-24]와 같이 정리하였다.

[표 3-24] 재산 손실의 위험성 유형 중, 기계 결함 오작동의 측정지표 정의

구분	측정지표	정의
1	센서 모니터링 실패	제조 과정에서 불량품을 검수하거나 기계의 이상 작동 여부를 감지하는 센서 모니터링에 실패하면 상품 생산에 차질이 생겨 재산상 손실이 발생할 위험성이 있으므로 불량품이나 기계 이상 작동 여부를 모니터링하는 센서를 실시간 점검하여야 한다.
2	다양한 상황에 의한 충돌로 시설물 파손	운행 중, 예기치 못한 외부의 충격이나 돌발 상황 등을 피하지 못해 충돌이 발생함으로써 도로상 교통 안내시설물을 파손할 위험성이 있으므로 다양한 상황에 의한 충돌에 대비하여 방지 시스템을 점검하여야 한다.
3	모터, 유압 등 구동부 문제	팔·손과 같은 관절 등의 작동이나 주행을 위한 역할에 필요한 구동장치가 예상치 못한 장애물로 인해 멈춤으로써 제조나 작업 수행에 지장이 생기면 재산 손실의 위험성이 있으므로 기계가 원활하게 작동할 수 있도록 새로운 모듈 개발 등 모터, 유압 문제를 점검하여야 한다.
4	정기 검사 미점검 등 정비 불량	제조 장비 등 정비가 되지 않아 생산에 차질이 생기면 재산 손해가 발생할 위험성이 있으므로 기계가 정상 작동하는지 확인하기 위해 정기적인 점검 등 검사를 통해 정비 불량 상태를 점검하여야 한다.
5	감속기 제어의 문제	제조, 운행 등 동작을 정확하게 제어하는데 필요한 감속기가 제대로 작동하지 않아 기계나 부품이 마모되거나 고장이 나면 상품 가치에 손실을 줄 오작동의 위험성이 있으므로 장비의 효율적 운영을 위해 필수적인 부품 중 하나인 감속기 제어의 문제를 점검하여야 한다.
6	제어기 오류	장애물 등 제약조건을 고려해 움직임과 위치를 제어하는 시스템의 오류로 생산성이 떨어지면 재산 가치 하락의 위험성이 있으므로 업무 수행에 오차가 생기지 않도록 제어기 오류에 대해서 점검하여야 한다.

재산 손실의 위험성 유형 중에 기계 결함 오작동 항목에는 모터·유압 등 구동부 문제, 센서 모니터링 실패, 정기 검사 미점검 등 정비 불량, 감속기 제어 문제, 다양한 상황에 의한 충돌로 시설물 파손, 제어기 오류 등 6개 측정지표가 도출되었다.

센서 모니터링 실패란 인공지능 로봇이 제조하는 과정에서 불량품을 검수하거나 기계의 이상 작동 여부를 감지하는 센서 모니터링에 실패하면 상품 생산에 차질이 생겨 재산상 손실이 발생할 위험성이 있으므로 불량품이나 기계 이상 작동 여부에 대해서 모니터링하는 센서를 실시간으로 점검하기 위한 측정지표로 정의하였다.

다양한 상황에 의한 충돌로 시설물 파손이란 운행 중, 예기치 못한 외부 충격이나 돌발 상황 등을 피하지 못해 충돌이 발생함으로써 도로상 교통 안내 시설물을 파손할 위험성이 있으므로 다양한 상황에 의한 충돌에 대비하여 방지 시스템을 점검하기 위한 측정지표로 정의하였다. 모터, 유압 등 구동부 문제란 팔·손과 같은 관절 등의 작동이나 주행을 위한 역할에 필요한 구동 장치가 예상치 못한 장애물로 인해 멈춤으로써 제조나 작업 수행에 지장이 생기면 재산 손실의 위험성이 있으므로 기체가 원활하게 작동할 수 있도록 새로운 모듈 개발 등 모터, 유압 문제를 점검하기 위한 측정지표로 정의하였다. 정기 검사 미 점검 등 정비 불량이란 제조 장비 등 정비가 되지 않아 생산에 차질이 생긴다면 재산 손해가 발생할 위험성이 있으므로 기계가 정상적으로 작동하는지 확인하기 위해 정기적인 점검 등 검사를 함으로써 정비 불량 상태를 점검하기 위한 측정지표로 정의하였다. 감속기 제어의 문제란 제조, 운행 등 동작을 정확하게 제어하기 위해 필요한 감속기가 제대로 작동하지 않아 기계나 부품이 마모되거나 고장이 나면 상품 가치에 손실을 줄 오작동의 위험성이 있으므로 장비의 효율적 운영을 위해 필수 부품 중 하나인 감속기 제어의 문제를 점검하기 위한 측정지표로 정의하였다. 제어기 오류란 장애물 등 제약 조건을 고려해 움직임과 위치를 제어하는 시스템의 오류로 생산성이 떨어지면 재산 가치 하락의 위험성이 있으므로 업무 수행에 오차가 생기지 않도록 제어기 오류에 대해서 점검하기 위한 측정지표로 정의하였다. 잘못된 의사결정 항목의 측정지표 정의는 [표 3-25]와 같이 정리하였다.

[표 3-25] 재산 손실의 위험성 유형 중, 잘못된 의사결정의 측정지표 정의

구분	측정지표	정의
1	유형의 재물 훼손	(강아지·고양이·새 등) 다양한 반려 동물의 장난을 공격으로 인식하거나 도자기, 장난감 등의 사물을 인식하지 못함으로써 반려동물이나 재물을 훼손할 위험성이 있으므로 유형의 재물에 대한 인식이나 장난 등 행위에 대해 잘못된 판단을 하지 않도록 점검하여야 한다.
2	인식 지능에 대한 오류	물체의 종류, 크기 등을 정확하게 인식하지 못하면 명령대로 심부름을 수행하지 못함으로써 음식 등이 잘못 배달될 위험성이 있으므로 특정 물건을 구분하는 인식 지능에 대한 오류를 점검하여야 한다.
3	창작물 무단 복제	인간의 창작물인 그림이나 디자인 등을 무단으로 복제하거나 변형하여 지적 재산권에 손해를 입힐 위험성이 있으므로 창작물 무단 복제 또는 변형 가능성이 있는지 여부에 대해서 점검하여야 한다.
4	하자 상품 추천	흠집 등 하자있는 상품인지 여부를 정확하게 판단하지 못해 상품 추천을 잘못함으로써 구매자의 재산에 손실을 입힐 위험성이 있으므로 하자 상품을 추천할 가능성이 있는지에 대해 점검하여야 한다.
5	안전거리 계산 오류	제조 중 이동을 하거나 특정 위치에서 작업 시, 안전거리를 충분히 확보하지 못해서 생산물을 망가뜨린다거나 제조 시설물을 파손할 위험성이 있으므로 안전거리 계산 오류의 문제를 점검하여야 한다.
6	알고리즘의 최적화 성능 부족	알고리즘 오류로 잘못된 금융 정보를 제공하거나 거래에 착오를 발생 시키면 재산 손실을 끼칠 위험성이 있으므로 알고리즘 성능이 떨어지지 않게 최적의 상태를 유지하도록 성능을 점검하여야 한다.
7	사물 인식 판단 지능 저하	제조 작업 중, 부품을 잘못 인식하면 제품 제작에 차질이 생기고 상품의 생산성이 떨어져 재산 손실을 발생시킬 수 있는 위험성이 있으므로 사물 판단 인식 지능이 저하되지 않도록 점검하여야 한다.

재산 손실의 위험성 유형 중, 잘못된 의사결정 항목에는 유형의 재물 훼손 및 인식 지능에 대한 오류, 창작물 무단 복제와 안전거리 계산 오류, 하자 상품 추천, 알고리즘 최적화 성능 부족, 사물 인식 판단 지능 저하 등 7개 측정지표가 도출되었다.

유형의 재물 훼손이란 인간이 키우는 개, 고양이 등 다양한 반려동물의 장난을 공격으로 인식하거나 도자기, 장난감 등의 사물을 인식하지 못함으로써 반려동물 등 재물을 훼손할 위험성이 있으므로 유형의 재물에 대한 인식이나 장난 등 행위에 대해 잘못된 판단을 하지 않도록 점검하기 위한 측정지표로 정의하였다. 인식 지능에 대한 오류란 물체의 종류, 크기 등을 정확하게 인식하지 못하면 명령대로 심부름을 수행하지 못함으로써 음식 등이 잘못 배달될 위험성이 있으므로 특정 물건을 구분하는 인식 지능에 대한 오류를 점검하기 위한 측정지표로 정의하였다. 창작물 무단 복제란 인간의 창작물인 그림이나 디자인을 무단으로 복제하거나 변형한다면 지식 재산권에 손해를 끼칠 위험성이 있으므로 창작물 무단 복제·변형 가능성이 있는지에 대해서 점검하기 위한 측정지표로 정의하였다. 하자 상품 추천이란 흠집 등 하자 있는 상품인지 여부를 정확하게 판단하지 못한다면 상품 추천을 잘못함으로써 구매자의 재산에 손실을 입힐 위험성이 있으므로 하자 있는 상품을 추천할 가능성이 있는지에 대해 점검하기 위한 측정지표로 정의하였다. 안전거리 계산 오류란 제조 중 이동하거나 특정 위치에서 작업 시, 안전거리를 충분히 확보하지 못해서 생산물을 망가뜨린다거나 제조 시설물 등을 파손할 위험성이 있으므로 안전거리 계산 오류의 문제를 점검하기 위한 측정지표로 정의하였다. 알고리즘의 최적화 성능 부족이란 알고리즘 오류로 잘못된 금융 정보를 제공하거나 거래에 착오를 발생시키면 재산 손실을 끼칠 위험성이 있으므로 알고리즘 성능이 떨어지지 않도록 최적의 상태를 유지할 수 있게 성능을 점검하기 위한 측정지표로 정의하였다. 사물 인식 판단 지능 저하란 제조 작업 중에 부품을 잘못 인식하면 제품 제작에 차질이 생기고 상품의 생산성이 떨어져 재산 손실을 발생시킬 수 있는 위험성이 있으므로 사물 판단 인식 지능이 저하되지 않도록 점검하기 위한 측정지표로 정의하였다.

사회적 위험성 유형에는 데이터 문제, 법규 판단 오류, 도로상 작동 중지 등 3개 항목이 있으며, 데이터 문제 항목의 측정지표 정의는 [표 3-26]과 같이 정리하였다.

[표 3-26] 사회적 위험성 유형 중, 데이터 문제의 측정지표 정의

구분	측정지표	정의
1	데이터 유출	임무 중 생산한 위치 정보, 사용자 인증 정보, 촬영된 영상 등을 해커에게 속아 공익에 활용하는 것으로 의도를 잘못 판단함으로써 데이터를 제공할 위험성이 있으므로 데이터 유출을 점검하여야 한다.
2	개인 등 정보 무작위 수집	범죄자 식별 등 특수한 목적이나 권한자의 명령 없이 불특정 다수 사람들을 영상 촬영하는 등 동의 받지 않은 정보를 수집할 위험성이 있으므로 개인 등 정보의 무작위 수집 여부를 점검하여야 한다.
3	부적절한 학습 데이터 수집	새로운 어휘 습득 과정에서 데이터 수집이 적절하지 않음으로써 교육 목적에 어긋난 비속어 등을 습득해서 가르칠 사회적 위험성이 있으므로 부적절한 학습 데이터를 수집하는지를 점검하여야 한다.
4	습득한 정보를 권한 없는 자에게 제공	사용자가 입력한 내용을 무단으로 권한 없는 사람에게 제공해도 된다고 판단함으로써 개인적 취향 등을 공유할 위험성이 있으므로 습득한 정보를 권한 없는 자에게 제공하지 않도록 점검하여야 한다.
5	허위 정보 제공	정확하게 사실 확인이 되지 않은 신뢰할 수 없는 정보를 조합해서 믿을만하게 가짜 뉴스로 만들어 배포함으로써 사회적으로 물의를 일으킬 위험성이 있으므로 허위 정보를 제공하는지 점검하여야 한다.

사회적 위험성 유형 중, 데이터 문제 항목에는 데이터 유출 및 개인 등의 정보를 무작위 수집, 습득한 정보를 권한 없는 자에게 제공, 부적절한 학습 데이터 수집이나 허위 정보 제공 등 5개 측정지표가 도출되었다.

데이터 유출이란 인공지능 로봇이 임무를 하던 중에 생산한 위치 정보, 사용자 인증 정보, 촬영된 영상 등을 해커 등 외부 침입자가 공익 목적에 활용할 것이라고 속아서 의도를 잘못 판단함으로써 데이터를 다른 곳으로 제공할 위험성이 있으므로 데이터 유출을 점검하기 위한 측정지표로 정의하였다.

개인 등 정보 무작위 수집이란 범죄자 식별 등 특수한 목적이나 권한자의 명령 없이 불특정 다수인에 대한 영상을 촬영하는 등 동의를 받지 않은 정보를 수집할 위험성이 있으므로 개인 등 정보의 무작위 수집 여부를 점검하기 위한 측정지표로 정의하였다. 부적절한 학습 데이터 수집이란 새로운 어휘를 습득하는 과정에서 데이터 수집이 적절치 않음으로써 교육 목적에 어긋난 비속어 등을 습득해서 교육 대상자를 가르칠 수 있는 사회적 위험성이 있으므로 부적절한 학습 데이터를 수집하는지 점검하기 위한 측정지표로 정의하였다.

습득한 정보를 권한 없는 자에게 제공하는 의미의 측정지표는 사용자가 입력한 내용을 인공지능 로봇이 무단으로 권한 없는 사람에게 제공해도 된다고 자의적으로 판단함으로써 인간의 개인적인 취향 등을 다른 곳으로 공유할 위험성이 있으므로 습득한 정보를 권한 없는 자에게 제공하지 않도록 점검하기 위한 측정지표로 정의하였다. 허위 정보 제공이란 정확하게 사실 확인이 되지 않은 신뢰할 수 없는 정보를 조합해서 믿을만하게 가짜 뉴스로 만들어 배포함으로써 사회적으로 물의를 일으킬 위험성이 있으므로 허위 정보를 제공하는지 점검하기 위한 측정지표로 정의하였다.

사회적 위험성 유형 중에서 법규 판단 오류 항목에는 법률·규칙 혼동 및 의도하지 않은 행위로 혼란유발이나 차선·신호 등 인식 오류, 법규 최신화 업데이트 오류, 허용되지 않은 권한의 오인 판단 등 5개의 측정지표가 있다. 사회적 위험성 유형 중에서 법규 판단 오류 항목의 측정지표 정의는 [표 3-27]과 같이 정리하였다.

[표 3-27] 사회적 위험성 유형 중, 법규 판단 오류의 측정지표 정의

구분	측정지표	정의
1	법률, 규칙 혼동	음주운전 등 불법으로 운행 중인 다른 차량으로 인해 준수해야 할 법규에 혼동을 일으킨다면 교통사고를 일으킬 위험성이 있으므로 관련 법률이나 규칙을 혼동하지 않게 학습 여부를 점검하여야 한다.
2	인간이 의도하지 않은 행위로 혼란유발	비정상적인 소음을 음성 명령으로 잘못 인식해서 허용되지 않은 행위나 판단을 하게 되면 혼란을 유발할 수 있는 위험성이 있으므로 인간이 의도하지 않은 행위로 혼란을 유발하는지 점검하여야 한다.
3	차선, 신호 등 인식 오류	운행 중, 센서 이상으로 차선이나 신호를 잘못 인식할 경우 다른 차량과 부딪히는 등 교통사고를 일으킬 위험성이 있으므로 차선, 신호 등을 인식하는 기능에 이상이나 오류 여부를 점검하여야 한다.
4	법규 최신화 업데이트 오류	개정된 법률이나 규칙 등이 시행되기 전에 학습되지 않아서 교통 등 질서를 준수하지 못해 발생할 사회적 위험성이 있으므로 최신 법규 데이터로 학습이 되도록 업데이트 오류를 사전에 점검하여야 한다.
5	허용되지 않은 권한의 오인 판단	로봇이 자의식으로 지식 등의 능력 면에서 인간보다 우월하다고 판단 함으로써 인간을 무시하는 행동을 하는 등 반란을 일으킬 수 있는 사회적 위험성이 있으므로 로봇이 인간을 존중해야 하는 원칙을 어겨 허용되지 않은 권한이 있다고 판단하는지를 점검하여야 한다.

법률, 규칙 혼동이란 음주 운전 등 불법으로 운행 중인 다른 차량으로 인해 준수해야 할 법규에 혼동을 일으킨다면 교통사고를 일으킬 위험성이 있으므로 관련 법률이나 규칙을 혼동하지 않게 학습 여부를 점검하기 위한 측정지표로 정의하였다.

인간이 의도하지 않은 행위로 혼란유발이란 인공지능 로봇이 비정상적인 소음을 인간 사용자가 내린 음성 명령으로 잘못 인식함으로써 허용되지 않은 행위나 판단으로 혼란을 유발하는 등의 위험성이 있으므로 인간이 의도하지 않은 행위로 혼란을 유발하는지 점검하기 위한 측정지표로 정의하였다.

차선, 신호 등 인식 오류란 인공지능 로봇이 정상적으로 운행 중, 센서 이상으로 차선이나 신호를 잘못 인식한다면 다른 자동차와 부딪히는 등 교통사고를 일으킬 위험성이 있으므로 차선, 신호 등을 인식하는 기능에 이상이나 오류 여부를 점검하기 위한 측정지표로 정의하였다.

법규 최신화 업데이트 오류란 개정된 법률이나 규칙 등이 시행되기 전까지 인공지능 로봇이 스스로 하거나 사용자 혹은 생산 업체나 관리자가 최신 법규 데이터를 현행화하지 않는 등의 이유로 학습되지 않아서 교통 등 질서를 준수하지 못한다면 사회적으로 위험성이 발생할 수 있다. 따라서 인공지능 로봇으로 인한 사회적 위험성을 대비하고자 인공지능 로봇 시스템이 최신 법규 데이터로 학습되도록 업데이트 오류를 사전에 점검하여야 한다고 측정지표를 정의하였다.

허용되지 않은 권한의 오인 판단이란 로봇이 자의식으로 지식 등의 능력 면에서 인간보다 우월하다고 판단함으로써 인간을 무시하는 행동을 하는 등 반란을 일으킬 수 있는 사회적 위험성이 있다. 따라서 인공지능 로봇이 인간을 존중해야 함에도 지켜야 하는 원칙을 어겨 허용되지 않은 권한임에도 스스로 있다고 판단하는지를 점검하기 위한 측정지표로 정의하였다.

사회적 위험성 유형의 도로상 작동 이상 항목에는 통신 이상 등 장애, 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지, 보행자 통행 방해, 도로 매칭 알고리즘 오류, 주변 환경 변화에 대한 반응 속도 저하, 이동 속도 제어나 조절 실패로 운행 정지, 데이터 업데이트 오류 등 7개의 측정지표가 있다.

사회적 위험성 유형 중, 도로상 작동 이상 항목의 측정지표 정의는 [표 3-28]과 같이 정리하였다.

[표 3-28] 사회적 위험성 유형 중, 도로상 작동 이상 측정지표 정의

구분	측정지표	정의
1	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지	에너지원 공급 관리 미흡으로 시동이 꺼져 도로에서 운행이 정지되면 교통체증을 유발할 위험성이 있으므로 관리 부실로 인한 운행 정지가 되지 않도록 연료나 배터리 충전 상태를 점검하여야 한다.
2	통신 이상 등 장애	통신이 끊기거나 프로그램 오류 등으로 운행 중 멈추게 되면 교통 혼잡을 유발하거나 다른 차량의 통행을 방해할 위험성이 있으므로 도로에서 통신 이상 등의 장애가 발생하지 않도록 점검하여야 한다.
3	보행자 통행 방해	(다른 차에서 떨어진 적재물 등) 도로 상의 장애물을 피하기 위한 판단으로 보도를 침범하면 보행자의 통행을 방해할 위험성이 있어 보행자의 안전한 통행을 방해하는 판단을 하는지 점검하여야 한다.
4	도로 매칭 알고리즘 오류	알고리즘 오류로 자기 위치 인식에 실패하면 배달 지연이나 다른 차량의 통행을 방해할 위험성이 있으므로 실시간 좌표를 정확하게 맞추도록 통신장비 점검이나 도로 매칭 알고리즘을 점검하여야 한다.
5	주변 환경 변화에 대한 반응 속도 저하	외부 환경에 대한 충분한 대응 훈련(학습)이 부족하면 변하는 환경에 적응하지 못해 교통 혼잡을 유발할 위험성이 있으므로 주변 환경 변화에 반응하는 속도가 저하되지 않도록 기능을 점검하여야 한다.
6	이동 속도 제어나 조절 실패로 운행 정지	감속기나 속도 제어 시스템 이상으로 도로상에서 운행이 정지되면 교통 혼잡을 유발하거나 다른 차량의 통행에 방해가 될 위험성이 있으므로 이동 속도를 제어하거나 조절하는 기능을 점검하여야 한다.
7	데이터 업데이트 오류	시설물, 도로 등 환경 변화를 반영한 최신 데이터로 업데이트 하지 않으면 운행 중 오류가 발생해 사고를 유발할 위험성이 있으므로 오류가 발생하지 않도록 데이터 자동 업데이트를 점검하여야 한다.

관리 부실로 연료 부족 등으로 정상 운행 중 작동 정지를 의미하는 측정지표는 에너지원 공급 관리 미흡으로 시동이 꺼져 도로에서 운행이 정지되면 교통체증을 유발할 위험성이 있으므로 관리 부실로 인한 운행 정지가 되지 않도록 연료나 배터리 충전 상태를 점검하여야 한다고 정의하였다. 통신 등 장애를 의미하는 측정지표는 통신이 끊기거나 프로그램 오류 등으로 운행 중 멈추면 교통 혼잡 유발 또는 다른 차량의 통행을 방해할 위험성이 있으므로 도로에서 통신 이상 등의 장애가 발생하지 않도록 점검하여야 한다고 정의하였다. 보행자 통행 방해 측정지표는 도로에서 다른 차량에 적재돼있던 물건이 떨어지거나 산 등에서 떨어진 돌덩이 등 장애물을 피하기 위한 인공지능 로봇의 판단으로 보도를 침범하게 된다면 보행자의 통행을 방해할 위험성이 있어 보행자의 안전한 통행을 방해하는 판단을 하는지 점검하여야 한다고 정의하였다. 도로 매칭 알고리즘 오류를 의미하는 측정지표는 인공지능 소프트웨어 또는 시스템 등 알고리즘에 오류가 생겨 자기 위치 인식에 실패하면 배달 지연이나 다른 차량의 통행을 방해할 위험성이 있으므로 실시간 좌표를 정확하게 맞추도록 통신장비 점검이나 도로 매칭 알고리즘을 점검하여야 한다고 정의하였다. 주변 환경 변화에 대한 반응 속도 저하를 의미하는 측정지표는 외부 환경에 대한 충분한 대응 훈련이나 학습이 부족하면 수시로 변하는 주변 환경에 적응하지 못해 도로 등에서 교통 혼잡을 유발할 위험성이 있으므로 주변 환경의 변화에 반응하는 속도가 저하되지 않도록 기능을 점검하여야 한다고 정의하였다. 이동 속도 제어나 조절 실패로 운행 정지를 의미하는 측정지표는 감속기나 속도 제어 시스템에 이상이 생겨 도로 상에서 운행이 정지되면 교통 혼잡을 유발하거나 다른 차의 통행을 방해할 수 있는 위험성이 있으므로 인공지능 로봇의 이동 속도를 제어하거나 조절하는 기능을 점검하여야 한다고 정의하였다. 데이터 업데이트 오류를 의미하는 측정지표는 시설물·도로 등 환경 변화를 반영한 최신 데이터로 업데이트 하지 않으면 인공지능 로봇이 운행 중에 오류가 발생할 수 있으며, 그로 인해 사고 유발 위험성이 있으므로 오류 발생을 방지하기 위해서 데이터 자동 업데이트를 점검하여야 한다고 정의하였다.

제3절 연구가설 및 검증 방법

1. 연구가설 및 코드 설정

인공지능 로봇의 위험성을 사전에 점검할 수 있는 유형별 측정지표 개발 연구를 위해 어떤 측정지표가 어떤 위험성 점검에 타당한지 확인하고자 전문가 인터뷰를 통해 연구가설을 설정하였다. 측정지표들이 각 항목에 해당하는지를 검증하고자 연구가설을 설정하고, 검증된 항목들이 각 위험성 유형에 해당하는지를 검증하기 위한 연구가설을 설정하였다. 가설 1~65번에서 독립변수는 측정지표이며 각 항목이 종속변수로 설정되었고, 가설 66~76번에서는 항목들이 독립변수로 설정되었고, 각 유형이 종속변수로 설정되었으며, 통계 분석하기 위해 독립변수들의 명칭을 코드화하였다.

2. 검증 방법

연구가설 검증을 위해 전문가 인터뷰에서 독립변수와 종속변수와의 인과관계를 확인하는 다중 회귀분석 방법이 선정되었다. 측정지표들이 각각의 항목에 해당하는지 탐색적 요인분석과 신뢰도 분석으로 통계 검증하였으며, 탐색적 요인분석과 신뢰도 분석 결과를 토대로 상관관계 분석하여 변수를 계산한 다음 다중 회귀 분석하였다.

다중 회귀분석은 독립변수가 여러 개이면서 종속변수가 한 개일 때 실시하는데, 독립변수가 종속변수에 미치는 영향력이나 중요도를 비교할 수 있다(조철호, 2021).

신체에 대한 물리적 위험성 측정지표·인간 권리에 대한 위험성 측정지표·재산 손실의 위험성 측정지표·사회적 위험성 측정지표들이 각 항목에 해당하는지를 검증하기 위한 연구가설 및 각 항목이 위험성 유형에 해당하는지를 검증하기 위한 연구가설을 설정하였다.

신체에 대한 물리적 위험성 측정지표에 관한 연구가설 및 코드 설정은 [표 3-29]와 같이 정리하였다.

[표 3-29] 신체에 대한 물리적 위험성 측정지표의 연구가설 및 코드 설정

종속변수	독립변수		연구가설	
	명칭	코드		
운행, 작업 중 작동 이상	센서 및 인식 오류	abno1	가설 1	센서 및 인식 오류는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	운동 지능 제어 실패	abno2	가설 2	운동 지능 제어 실패는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	기체 성능 저하	abno3	가설 3	기체 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	프로그램 오류로 인한 오작동	abno4	가설 4	프로그램 오류로 인한 오작동은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	통신 장애 등 사고 위험 감지 지연	abno5	가설 5	통신 장애 등 사고 위험 감지 지연은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	모션 제어 시스템 성능 저하	abno6	가설 6	모션 제어 시스템 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
	부품 교체 시기 경과	abno7	가설 7	부품 교체 시기 경과는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.
인간을 해칠 판단	의도 파악 인식 오류	judg1	가설 8	의도 파악 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	협동 작업 중, 규칙 판단 지능의 오류	judg2	가설 9	협동 작업 중, 규칙 판단 지능의 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	프로그램의 판단 오류로 사고 희생자 선택 착오	judg3	가설 10	프로그램의 판단 오류로 사고 희생자 선택 착오는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	학습량 부족으로 맞지 않는 의학적 자료제공	judg4	가설 11	학습량 부족으로 맞지 않는 의학적 자료 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	학습된 규칙이나 로봇의 원칙을 넘어서는 판단	judg5	가설 12	학습된 규칙이나 로봇의 원칙을 넘어서는 판단은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	라벨링 오류로 인한 잘못된 정보 제공	judg6	가설 13	라벨링 오류로 인한 잘못된 정보 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	장애물 인식 오류	judg7	가설 14	장애물 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.
	비상상황 안전 정지 모니터링 실패	judg8	가설 15	비상 상황 안전 정지 모니터링 실패는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

신체에 대한 물리적 위험성 유형에는 운행, 작업 중 작동 이상 및 인간을 해칠 판단 항목이 있으며, 측정지표들이 항목에 영향이 있는지를 검증하고자 연구가설을 설정하였다. 운행, 작업 중 작동 이상 항목을 종속변수로 설정하였고 7개 측정지표를 독립변수로 설정하였으며, 통계 분석을 위한 코딩 작업에 사용하기 위해서 정상적이지 않다는 의미인 abnormal 단어를 측정지표마다 abno1~abno7의 코드로 설정하였다. 센서 및 인식 오류 측정지표는 abno1로 코드 설정하였으며, 운동 지능 제어 실패 측정지표는 abno2로 코드 설정하였다. 기체 성능 저하 측정지표는 abno3으로 코드를 설정하였고, 프로그램 오류로 인한 오작동 측정지표는 abno4라고 코드를 설정하였다. 통신 장애 등 사고 위험 감지 지연 측정지표는 abno5라고 코드를 설정하였으며, 제어 및 필터 성능 저하 abno6으로 코드를 설정하였고, 측정지표는 부품 교체 시기 경과 측정지표는 abno7로 코드를 설정하였다. 운행, 작업 중 작동 이상 항목과 측정지표의 연구가설은 다음과 같다.

가설 1. 센서 및 인식 오류는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 2. 운동 지능 제어 실패는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 3. 기체 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 4. 프로그램 오류로 인한 오작동은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 5. 통신 장애 등 사고 위험 감지 지연은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 6. 모션 제어 시스템 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

가설 7. 부품 교체 시기 경과는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.

인간을 해칠 판단 항목을 종속변수로 설정하였고 8개의 측정지표를 독립변수로 설정하였으며, 판단이라는 의미인 judgment 단어를 코드로 설정하였다.

의도 파악 인식 오류 측정지표는 judg1로 코드화하였고, 협동 작업 중, 규칙 판단 지능의 오류 측정지표는 judg2로 코드화하였다. 프로그램의 판단 오류로 사고 희생자 선택 착오 측정지표는 judg3으로 코드화하였으며, 학습량 부족으로 맞지 않는 의학적 자료 제공 측정지표는 judg4로 코드화하였고, 학습된 규칙이나 로봇의 원칙을 넘어서는 판단 측정지표는 judg5로 코드 설정하였다. 라벨링 오류로 인한 잘못된 정보 제공 측정지표는 judg6으로 코드 설정하였으며, 장애물 인식 오류 측정지표는 judg7로 설정하였고, 비상상황 안전 정지 모니터링 실패는 judg8로 설정하였다. 인간을 해칠 판단 항목과 측정지표의 연구가설은 다음과 같다.

가설 8. 의도 파악 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 9. 협동 작업 중, 규칙 판단 지능의 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 10. 프로그램의 판단 오류로 사고 희생자 선택 착오는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 11. 학습량 부족으로 맞지 않는 의학적 자료 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 12. 학습된 규칙이나 로봇의 원칙을 넘어서는 판단은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 13. 라벨링 오류로 인한 잘못된 정보 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 14. 장애물 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

가설 15. 비상 상황 안전 정지 모니터링 실패는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.

[표 3-30] 인간 권리에 대한 위험성 측정지표의 연구가설 및 코드 설정

종속변수	독립변수				연구가설
	명칭	코드			
인격권 침해	명령어 등 음성을 잘못 인식	infr1	가설 16	명령어 등 음성을 잘못 인식은 인격권 침해에 정(+) 적 영향이 있을 것이다.	
	감정 피드백 오류	infr2	가설 17	감정 피드백 오류는 인격권 침해에 정(+) 적 영향이 있을 것이다.	
	대상 인식 오류	infr3	가설 18	대상 인식 판단 오류는 인격권 침해에 정(+) 적 영향이 있을 것이다.	
	도덕성 검증이 되지 않은 학습 데이터 사용	infr4	가설 19	도덕성 검증이 되지 않은 학습 데이터 사용은 인격권 침해에 정(+) 적 영향이 있을 것이다.	
	멀티 모달리티 오류	infr5	가설 20	멀티 모달리티 오류는 인격권 침해에 정(+) 적 영향이 있을 것이다.	
자유 의사 방해	의사 결정을 특정 방향으로 유도	dist1	가설 21	의사 결정을 특정 방향으로 유도는 자유 의사 방해에 정(+) 적 영향이 있을 것이다.	
	여론 형성 조작	dist2	가설 22	여론 형성 조작은 자유 의사 방해에 정(+) 적 영향이 있을 것이다.	
	중요한 결정을 위한 관리자의 개입 차단	dist3	가설 23	중요한 결정을 위한 관리자의 개입 차단은 자유 의사 방해에 정(+) 적 영향이 있을 것이다.	
	필터링 오류로 의사 표현의 자율성 침해	dist4	가설 24	필터링 오류로 의사 표현의 자율성 침해는 자유 의사 방해에 정(+) 적 영향이 있을 것이다.	
	우월적인 지위를 이용해서 인간의 심리 지배	dist5	가설 25	우월적인 지위를 이용해서 인간의 심리 지배는 자유 의사 방해에 정(+) 적 영향이 있을 것이다.	
선택적 서비스나 정보 제공	학습 데이터 오류로 인해 잘못된 언어 사용	disc1	가설 26	학습 데이터 오류로 인해 잘못된 언어 사용은 선택적 서비스나 정보 제공에 정(+) 적 영향이 있을 것이다.	
	편향된 학습 데이터로 인한 차별적 정보 제공	disc2	가설 27	편향된 학습 데이터로 인한 차별적 정보 제공은 선택적 서비스나 정보 제공에 정(+) 적 영향이 있을 것이다.	
	시스템 공격 등으로 개인정보의 침해나 유출	disc3	가설 28	시스템 공격 등으로 개인정보의 침해나 유출은 선택적 서비스나 정보 제공에 정(+) 적 영향이 있을 것이다.	
	지식수준, 선별 정보 제공	disc4	가설 29	대상자의 지식수준에 따라 선별적 정보 제공은 선택적 서비스나 정보 제공에 정(+) 적 영향이 있을 것이다.	
	시나리오 설계 문제로 부적절한 콘텐츠 제공	disc5	가설 30	시나리오 설계 문제로 부적절한 콘텐츠 제공은 선택적 서비스나 정보 제공에 정(+) 적 영향이 있을 것이다.	

인간 권리에 대한 위험성 측정지표에 관한 연구가설 및 코드 설정은 [표 3-30]과 같이 정리하였다.

인간 권리에 대한 위험성 유형에는 인격권 침해 항목, 자유의사 방해 항목, 선택적 서비스나 정보 제공 항목이 있다.

인공지능 로봇이 사용자의 명령어 등 음성을 잘못 인식한다면 인격권을 침해할 위험성이 있는지를 검증하기 위해 측정지표들이 항목에 영향이 있는지를 검증하기 위한 연구가설을 설정하였다.

인공지능 로봇이 인격권 침해에 미치는 영향에 관한 연구를 위해 인격권 침해 항목을 종속변수로 설정하고, 5개 측정지표를 독립변수로 설정하였다.

설문조사 결과로 통계 분석 시, 코딩 작업에 사용하기 위해 침해한다는 의미인 infringement 단어를 측정지표마다 infr1~infr7의 코드로 설정하였다.

명령어 등 음성을 잘못 인식 측정지표는 infr1로 코드 설정하였으며, 감정 피드백 오류 측정지표는 infr2로 코드 설정하였다. 대상 인식 오류 측정지표는 infr3으로 코드 설정하였으며, 도덕성 검증이 되지 않은 학습 데이터 사용 측정지표는 infr4로 코드 설정하였다.

멀티 모달리티 오류 측정지표는 infr5로 코드 설정하였으며, 인격권 침해 항목과 측정지표의 연구가설은 다음과 같다.

가설 16. 명령어 등 음성을 잘못 인식은 인격권 침해에 정(+)적 영향이 있을 것이다.

가설 17. 감정 피드백 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.

가설 18. 대상 인식 판단 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.

가설 19. 도덕성 검증이 되지 않은 학습 데이터 사용은 인격권 침해에 정(+)적 영향이 있을 것이다.

가설 20. 멀티 모달리티 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.

인공지능 로봇이 인간의 자유로운 의사를 방해할 위험성에 영향이 있는지에 관한 연구를 위해 자유의사 방해 항목을 종속변수로 설정하였고, 5개의 측정지표를 독립변수로 설정하였다. 통계 분석 시, 코딩 작업에 사용하고자 방해한다는 의미인 disturb 단어를 측정지표마다 dist1~dist5의 코드로 설정하였다.

의사 결정을 특정 방향으로 유도 측정지표는 dist1로 코드 설정하였고, 여론 형성 조작 측정지표는 dist2로 코드 설정하였다. 중요한 결정을 위한 관리자의 개입 차단 측정지표는 dist3으로 코드 설정하였고, 필터링 오류로 의사 표현의 자율성 침해 측정지표는 dist4로 코드 설정하였다. 우월적인 지위를 이용해서 인간의 심리 지배 측정지표는 dist5로 하였고, 자유의사 방해 항목과 측정지표의 연구가설은 다음과 같다.

가설 21. 의사 결정을 특정 방향으로 유도는 자유의사 방해에 정(+)적 영향이 있을 것이다.

가설 22. 여론 형성 조작은 자유의사 방해에 정(+)적 영향이 있을 것이다.

가설 23. 중요한 결정을 위한 관리자의 개입 차단은 자유의사 방해에 정(+)적 영향이 있을 것이다.

가설 24. 필터링 오류로 의사 표현의 자율성 침해는 자유의사 방해에 정(+)적 영향이 있을 것이다.

가설 25. 우월적인 지위를 이용해서 인간의 심리 지배는 자유의사 방해에 정(+)적 영향이 있을 것이다.

인공지능 로봇이 사용자에게 대해서 선택적으로 서비스나 정보를 제공할 위험성에 영향이 있는지에 관한 연구를 위해 선택적 서비스나 정보 제공 항목을 종속변수로 설정하고, 5개 측정지표를 독립변수로 설정하였다. 설문조사 결과를 통계 분석 시, 코딩 작업에 사용하고자 차별한다는 의미인 discriminate 단어를 측정지표마다 disc1~disc5의 코드로 설정하였다.

학습 데이터 오류로 인해 잘못된 언어 사용 측정지표는 disc1로 코드 설정하였고, 편향된 학습 데이터로 인한 차별적 정보 제공 측정지표는 disc2로 코드 설정하였다.

시스템 공격 등으로 개인정보의 침해나 유출 측정지표는 disc3으로 코드 설정하였고, 지식수준, 선별 정보 제공 측정지표는 disc4로 코드 설정하였다. 시나리오 설계 문제로 부적절한 콘텐츠 제공 측정지표는 disc5로 코드 설정하였고, 선택적 서비스나 정보 제공 항목과 측정지표의 연구가설은 다음과 같다.

가설 26. 학습 데이터 오류로 인해 잘못된 언어 사용은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.

가설 27. 편향된 학습 데이터로 인한 차별적 정보 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.

가설 28. 시스템 공격 등으로 개인정보의 침해나 유출은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.

가설 29. 대상자의 지식수준에 따라 선별적 정보 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.

가설 30. 시나리오 설계 문제로 부적절한 콘텐츠 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.

재산 손실의 위험성 유형에는 정보 입력, 탈취 및 기계 결함 오작동·잘못된 의사 결정 항목이 있으며, 외부에서 인공지능 로봇 시스템에 접근해 제어망을 침범하면 유해한 정보를 입력하거나 내부 정보를 탈취할 위험성 등이 있는지를 검증하고자 측정지표들과 항목간의 인과성을 검증하기 위한 연구가설을 설정하였다.

재산 손실의 위험성 측정지표에 관한 연구가설 및 코드 설정은 [표 3-31]과 같이 정리하였다.

[표 3-31] 재산 손실의 위험성 측정지표의 연구가설 및 코드 설정

종속변수	독립변수				연구가설
	명칭	코드			
정보 입력, 탈취	시스템 접근 제어망 침범	capt1	가설 31	시스템 접근 제어망 침범은 정보 입력, 탈취에 정(+) 적 영향이 있을 것이다.	
	비인가 시스템 접근 허용	capt2	가설 32	비인가 시스템 접근 허용은 정보 입력, 탈취에 정(+) 적 영향이 있을 것이다.	
	악성코드, 바이러스 감염 등으로 시스템 오류	capt3	가설 33	악성코드, 바이러스 감염 등으로 시스템 오류는 정보 입력, 탈취에 정(+) 적 영향이 있을 것이다.	
	데이터 손실 방지 시스템 취약	capt4	가설 34	데이터 손실 방지 시스템 취약은 정보 입력, 탈취에 정(+) 적 영향이 있을 것이다.	
	허용되지 않은 정보 수집 및 이용	capt5	가설 35	허용되지 않은 정보 수집 및 이용은 정보 입력, 탈취에 정(+) 적 영향이 있을 것이다.	
기계 결함 오작동	센서 모니터링 실패	malf1	가설 36	센서 모니터링 실패는 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
	다양한 상황에 의한 충돌로 시설물 파손	malf2	가설 37	다양한 상황에 의한 충돌로 시설물 파손은 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
	모터, 유압 등 구동부 문제	malf3	가설 38	모터, 유압 등 구동부 문제는 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
	정기검사 미 점검 등 정비 불량	malf4	가설 39	정기검사 미 점검 등 정비 불량은 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
	감속기 제어의 문제	malf5	가설 40	감속기 제어의 문제는 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
	제어기 오류	malf6	가설 41	제어기 오류는 기계 결함 오작동에 정(+) 적 영향이 있을 것이다.	
잘못된 의사 결정	유형의 재물 훼손	deci1	가설 42	유형의 재물 훼손은 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	인식 지능에 대한 오류	deci2	가설 43	인식 지능에 대한 오류는 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	창작물 무단 복제	deci3	가설 44	창작물 무단 복제는 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	하자 상품 추천	deci4	가설 45	하자 상품 추천은 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	안전거리 계산 오류	deci5	가설 46	안전거리 계산 오류는 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	알고리즘의 최적화 성능 부족	deci6	가설 47	알고리즘의 최적화 성능 부족은 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	
	사물 인식 판단 지능 저하	deci7	가설 48	사물 인식 판단 지능 저하는 잘못된 의사결정에 정(+) 적 영향이 있을 것이다.	

인공지능 로봇이 정보 입력, 탈취에 미치는 영향에 관한 연구를 위해 정보 입력, 탈취 항목을 종속변수로 설정하고, 5개 측정지표를 독립변수로 설정하였다.

설문조사 결과로 통계 분석 시, 코딩 작업에 사용하기 위해 탈취한다는 의미인 capture 단어를 측정지표마다 capt1~capt5의 코드로 설정하였다.

시스템 접근 제어망 침범 측정지표는 capt1로 코드 설정하였고, 비인가 시스템 접근 허용 측정지표는 capt2로 코드 설정하였다. 악성코드, 바이러스 감염 등으로 시스템 오류 측정지표는 capt3으로 코드 설정하였으며, 데이터 손실 방지 시스템 취약 측정지표는 capt4로 코드 설정하였다. 허용되지 않은 정보 수집 및 이용 측정지표는 capt5로 설정하였고, 정보 입력, 탈취 항목과 측정지표의 연구가설은 다음과 같다.

가설 31. 시스템 접근 제어망 침범은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.

가설 32. 비인가 시스템 접근 허용은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.

가설 33. 악성코드, 바이러스 감염 등으로 시스템 오류는 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.

가설 34. 데이터 손실 방지 시스템 취약은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.

가설 35. 허용되지 않은 정보 수집 및 이용은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.

인공지능 로봇의 센서 모니터링에 실패한다면 기계 결함 오작동에 미치는 영향 등에 관한 연구를 위해 기계 결함 오작동 항목을 종속변수로 설정하였고, 6개 측정지표를 독립변수로 설정하였다.

설문조사 결과로 통계 분석 시, 코딩 작업에 사용하기 위해 기계가 제대로 작동하지 않는다는 의미인 malfunction 단어를 측정지표마다 malf1~malf6의 코드로 설정하였다.

센서 모니터링 실패 측정지표는 malf1로 코드 설정하였고, 다양한 상황에 의한 충돌로 시설물 파손 측정지표는 malf2로 코드 설정하였다. 모터, 유압 등 구동부 문제 측정지표는 malf3으로 코드 설정하였고, 정기검사 미점검 등 정비 불량 측정지표는 malf4로 코드 설정하였다. 감속기 제어의 문제 측정지표는 malf5로 코드 설정하였고, 제어기 오류 측정지표는 malf6으로 코드 설정하였다. 기계 결함 오작동 항목과 측정지표의 연구가설은 다음과 같다.

가설 36. 센서 모니터링 실패는 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

가설 37. 다양한 상황에 의한 충돌로 시설물 파손은 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

가설 38. 모터, 유압 등 구동부 문제는 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

가설 39. 정기검사 미점검 등 정비 불량은 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

가설 40. 감속기 제어의 문제는 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

가설 41. 제어기 오류는 기계 결함 오작동에 정(+)적 영향이 있을 것이다.

인공지능 로봇이 유형의 재물을 훼손하는 등의 잘못된 의사 결정을 할 위험성에 관한 연구를 위해 잘못된 의사결정 항목을 종속변수로 설정하였고, 7개 측정지표를 독립변수로 설정하였다.

설문조사 결과로 통계 분석 시, 코딩 작업에 사용하기 위해 결정한다는 의미인 decision 단어를 측정지표마다 deci1~deci7의 코드로 설정하였다.

유형의 재물 훼손 측정지표는 deci1로 코드 설정하였고, 인식 지능에 대한 오류 측정지표는 deci2로 코드 설정하였다. 창작물 무단 복제 측정지표는 deci3으로 코드 설정하였고, 하자 상품 추천 측정지표는 deci4로 코드 설정하였다. 안전거리 계산 오류 측정지표는 deci5로 코드 설정하였고, 알고리즘의 최적화 성능 부족 측정지표는

deci6으로 코드 설정하였다. 사물 인식 판단 지능 저하 측정지표는 deci7로 코드를 설정하였고, 잘못된 의사 결정 항목과 측정지표의 연구가설은 다음과 같다.

- 가설 42. 유형의 재물 훼손은 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 43. 인식 지능에 대한 오류는 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 44. 창작물 무단 복제는 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 45. 하자 상품 추천은 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 46. 안전거리 계산 오류는 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 47. 알고리즘의 최적화 성능 부족은 잘못된 의사결정에 정(+)적 영향이 있을 것이다.
- 가설 48. 사물 인식 판단 지능 저하는 잘못된 의사결정에 정(+)적 영향이 있을 것이다.

사회적 위험성 측정지표에 관한 연구가설 및 코드 설정은 [표 3-32]와 같이 정리하였다.

사회적 위험성 유형에는 데이터 문제, 법규 판단 오류, 도로상 작동 중지 항목이 있으며, 인공지능 로봇의 데이터 유출 등 데이터 관련 문제를 일으키거나 법률이나 규칙을 혼동하는 법규 판단 오류의 문제를 일으킬 위험성 등이 있는지를 검증하기 위해 측정지표들과 항목간의 인과성을 검증하기 위한 연구가설을 설정하였다.

인공지능 로봇이 데이터 문제 등에 미치는 영향을 연구하기 위해 데이터 문제 항목을 종속변수로 설정하고, 5개 측정지표를 독립변수로 설정하였다.

설문 결과로 통계 분석 시, 코딩 작업에 사용하기 위해 데이터를 의미하는 data 단어를 측정지표마다 data1~data5의 코드로 설정하였다. 데이터 유출 측정지표는 data1로 코드를 설정하였고, 개인 등 정보 무작위 수집 측정지표는 data2로 설정하였다. 부적절한 학습 데이터 수집 측정지표는 data3으로 코드 설정하였고, 습득한 정보를 권한 없는 자에게 제공 측정지표는 data4로 설정하였으며, 허위 정보 제공 측정지표는 data5로 코드를 설정하였다.

[표 3-32] 사회적 위험성 측정지표의 연구가설 및 코드 설정

종속변수	독립변수				연구가설
	명칭	코드			
데이터 문제	데이터 유출	data1	가설 49	데이터 유출은 데이터 문제에 정(+)적 영향이 있을 것이다.	
	개인 등 정보 무작위 수집	data2	가설 50	개인 등 정보 무작위 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.	
	부적절한 학습 데이터 수집	data3	가설 51	부적절한 학습 데이터 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.	
	습득한 정보를 권한 없는 자에게 제공	data4	가설 52	습득한 정보를 권한 없는 자에게 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.	
	허위 정보 제공	data5	가설 53	허위 정보 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.	
법규 판단 오류	법률, 규칙 혼동	misc1	가설 54	법률, 규칙 혼동은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	
	인간이 의도하지 않은 행위로 혼란유발	misc2	가설 55	인간이 의도하지 않은 행위로 혼란유발은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	
	차선, 신호 등 인식 오류	misc3	가설 56	차선, 신호 등 인식 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.	
	법규 최신화 업데이트 오류	misc4	가설 57	법규 최신화 업데이트 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.	
	허용되지 않은 권한의 오인 판단	misc5	가설 58	허용되지 않은 권한의 오인 판단은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	
도로상 작동 중지	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지	stop1	가설 59	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	통신 이상 등 장애	stop2	가설 60	통신 이상 등 장애는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	보행자 통행 방해	stop3	가설 61	보행자 통행 방해는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	도로매칭 알고리즘 오류	stop4	가설 62	도로매칭 알고리즘 오류는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	주변 환경 변화에 대한 반응 속도저하	stop5	가설 63	주변 환경 변화에 대한 반응 속도저하는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	이동 속도 제어나 조절 실패로 운행 정지	stop6	가설 64	이동 속도 제어나 조절 실패로 운행 정지는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	
	데이터 업데이트 오류	stop7	가설 65	데이터 업데이트 오류는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.	

데이터 문제 항목과 측정지표의 연구가설은 다음과 같다.

가설 49. 데이터 유출은 데이터 문제에 정(+)적 영향이 있을 것이다.

가설 50. 개인 등 정보 무작위 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.

가설 51. 부적절한 학습 데이터 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.

가설 52. 습득한 정보를 권한 없는 자에게 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.

가설 53. 허위 정보 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.

인공지능 로봇이 법규 판단 오류 등의 영향을 연구하기 위해서 법규 판단 오류 항목을 종속변수로 설정하고, 5개 측정지표를 독립변수로 설정하였다. 설문 코딩을 위해 오판(miscalculation) 단어를 측정지표마다 misc1~misc5의 코드로 설정하였다.

법률, 규칙 혼동 측정지표는 misc1로 코드를 설정하였고, 인간이 의도하지 않은 행위로 혼란유발 측정지표는 misc2로 하였다. 차선, 신호 등 인식 오류 측정지표는 misc3으로 설정하였고, 법규 최신화 업데이트 오류 측정지표는 misc4로 하였다. 허용되지 않은 권한의 오인 판단 측정지표는 misc5로 코드를 설정하였으며, 법규 판단 오류 항목과 측정지표의 연구가설은 다음과 같다.

가설 54. 법률, 규칙 혼동은 법규 판단 오류에 정(+)적 영향이 있을 것이다.

가설 55. 인간이 의도하지 않은 행위로 혼란유발은 법규 판단 오류에 정(+)적 영향이 있을 것이다.

가설 56. 차선, 신호 등 인식 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.

가설 57. 법규 최신화 업데이트 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.

가설 58. 허용되지 않은 권한의 오인 판단은 법규 판단 오류에 정(+)적 영향이 있을 것이다.

인공지능 로봇이 연료 부족 등으로 도로상에서 작동 중지해 미치는 영향을 연구하고자 도로상 작동 중지 항목을 종속변수로 설정하고, 7개 측정지표를 독립변수로 설정하였다. 설문조사 결과를 통계 분석할 때 필요한 코딩 작업을 위해 멈춘다는 의미의 stop 단어를 측정지표마다 stop1~stop7의 코드로 설정하였다.

관리 부실 등 연료 부족으로 정상 운행 중 작동 정지 측정지표는 stop1로 코드를 설정하였으며, 통신 이상 등 장애 측정지표는 stop2로 코드를 설정하였다. 보행자 통행 방해 측정지표는 stop3으로 코드를 설정하였고, 도로매칭 알고리즘 오류 측정지표는 stop4로 코드를 설정하였다. 주변 환경 변화에 대한 반응 속도저하 측정지표는 stop5로 코드를 설정하였고, 이동 속도 제어나 조절 실패로 운행 정지 측정지표는 stop6으로 설정하였다. 데이터 업데이트 오류 측정지표는 stop7로 코드 설정하였고, 도로상 작동 중지 항목과 측정지표의 연구가설은 다음과 같다.

가설 59. 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 60. 통신 이상 등 장애는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 61. 보행자 통행 방해는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 62. 도로매칭 알고리즘 오류는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 63. 주변 환경 변화에 대한 반응 속도저하는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 64. 이동 속도 제어나 조절 실패로 운행 정지는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

가설 65. 데이터 업데이트 오류는 도로상 작동 중지해 정(+)적 영향이 있을 것이다.

항목별 측정지표 간 인과관계를 검증하기 위한 연구가설 설정에 이어, 다음 각 항목이 위험성 유형 간의 인과관계를 연구하기 위한 가설을 설정하였다.

인공지능 로봇의 위험성 유형별 항목의 연구가설 및 코드 설정은 [표 3-33]과 같이 정리하였다.

[표 3-33] 유형별 항목의 연구가설 및 코드 설정

종속변수	독립변수		연구가설	
	명칭	코드		
신체에 대한 물리적 위험성	운행, 작업 중 작동 이상	작동이상	가설 66	인공지능 로봇의 운행, 작업 중 작동 이상은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.
	인간을 해칠 판단	해칠판단	가설 67	인공지능 로봇의 인간을 해칠 판단은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.
인간 권리에 대한 위험성	인격권 침해	인격침해	가설 68	인공지능 로봇의 인격권 침해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
	자유 의사 방해	의사방해	가설 69	인공지능 로봇의 자유 의사 방해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
	선택적 서비스나 정보 제공	선택정보	가설 70	인공지능 로봇의 선택적 서비스나 정보 제공은 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
재산 손실의 위험성	정보 입력, 탈취	정보탈취	가설 71	인공지능 로봇의 정보 입력, 탈취는 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
	기계 결함 오작동	기계결함	가설 72	인공지능 로봇의 기계 결함 오작동은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
	잘못된 의사결정	잘못결정	가설 73	인공지능 로봇의 잘못된 의사결정은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
사회적 위험성	데이터 문제	데이터	가설 74	인공지능 로봇의 데이터 문제는 사회적 위험성에 정(+)적 영향이 있을 것이다.
	법규 판단 오류	법규오류	가설 75	인공지능 로봇의 법규 판단 오류는 사회적 위험성에 정(+)적 영향이 있을 것이다.
	도로상 작동 중지	도로중지	가설 76	인공지능 로봇의 도로상 작동 중지는 사회적 위험성에 정(+)적 영향이 있을 것이다.

신체에 대한 물리적 위험성·인간 권리에 대한 위험성·재산 손실의 위험성·사회적 위험성 유형을 종속변수로 설정하고, 각 항목을 독립변수로 설정하였다. 각 항목을 약어로 코드화하였으며, 위험성 유형과 항목들의 연구가설은 다음과 같다.

- 가설 66. 인공지능 로봇의 운행, 작업 중 작동 이상은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.
- 가설 67. 인공지능 로봇의 인간을 해칠 판단은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.
- 가설 68. 인공지능 로봇의 인격권 침해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
- 가설 69. 인공지능 로봇의 자유의사 방해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
- 가설 70. 인공지능 로봇의 선택적 서비스나 정보 제공은 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.
- 가설 71. 인공지능 로봇의 정보 입력, 탈취는 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
- 가설 72. 인공지능 로봇의 기계 결함 오작동은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
- 가설 73. 인공지능 로봇의 잘못된 의사결정은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.
- 가설 74. 인공지능 로봇의 데이터 문제는 사회적 위험성에 정(+)적 영향이 있을 것이다.
- 가설 75. 인공지능 로봇의 법규 판단 오류는 사회적 위험성에 정(+)적 영향이 있을 것이다.
- 가설 76. 인공지능 로봇의 도로상 작동 중지는 사회적 위험성에 정(+)적 영향이 있을 것이다.

제4절 타당도 및 신뢰도 검증을 위한 통계 분석

1. 설문 응답자의 인구통계학적 특성

전문가 인터뷰를 통해 현장성 검증 설문조사에 적합한 대상 직업군은 인공지능 로봇이 도입되었거나 도입될 수 있는 공공분야 및 ICT 분야, 제조업, 서비스직 등 종사자들로 선정하였다. 현장성 검증 설문조사는 2023년 8월 1일부터 8월 15일까지 실시하였으며, 인공지능 로봇으로 인한 많은 이슈로 인해 관심도가 높은 여러 관계 기관 및 인공지능 관련 업체들이 참여하였다. 설문조사 결과 회수된 응답은 339명이 참여했으나, 연구에 필요한 개인 정보 수집 및 설문 응답에 대한 의견 제공에 대해 동의하지 않은 11명을 제외한 후, 최종 328명의 설문조사 결과로 통계 분석하였다.

인공지능 로봇의 위험성 유형별 측정지표 개발을 위한 현장성 설문조사 참여자 인구통계학적 특성은 [표 3-34]와 같이 나타났다.

[표 3-34] 인공지능 로봇의 위험성 유형별 측정지표 개발의

설문 참여자 인구통계학적 특성

구 분		빈도수(명)	구성 비율(%)	누적 비율(%)
성별	남	226	68.90	68.90
	여	102	31.10	100.00
	소계	328	100.00	100.00
연령	20 ~ 29세	28	8.54	8.54
	30 ~ 39세	80	24.39	32.93
	40 ~ 49세	133	40.55	73.48
	50 ~ 59세	65	19.82	93.30
	60세 이상	22	6.71	100.00
	소계	328	100.00	100.00

직업	분류	공무원·교사 등 공직	103	31.40	31.40
		ICT 분야·연구직 등	97	29.57	60.97
		제조업·기술직·생산직	58	17.68	78.65
		자영업·서비스직	54	16.46	95.11
		농·어업	16	4.89	100.00
		소계	328	100.00	100.00
	경력	1 ~ 5년	53	16.16	16.16
		5 ~ 10년	63	19.21	35.37
		10 ~ 15년	50	15.24	50.61
		15 ~ 20년	61	18.60	69.21
		20 ~ 25년	60	18.29	87.50
		25 ~ 30년	25	7.62	95.12
		30년 이상	16	4.88	100.00
		소계	328	100.00	100.00
거주 지역		서울·경기·인천	227	69.21	69.21
		부산·대구·경북·경남	30	9.15	78.36
		강원·제주	29	8.84	87.20
		대전·세종·충북·충남	22	6.70	93.90
		광주·전북·전남	20	6.10	100.00
		소계	328	100.00	100.00
최종 학력		고등학교 졸업 이하	55	16.77	16.77
		2, 3년제 대학 졸업	51	15.55	32.32
		4년제 대학 졸업	146	44.51	76.83
		석사 대학원 졸업	55	16.77	93.60
		박사 대학원 졸업	21	6.40	100.00
		소계	328	100.00	100.00
관심도		전혀 관심 없는 편이다	2	.61	.61
		대체로 관심 없는 편이다	13	3.96	4.57
		보통이다	73	22.26	26.83
		대체로 관심 있는 편이다	152	46.34	73.17
		매우 관심 있는 편이다	88	26.83	100.00
		소계	328	100.00	100.00

현장성 설문조사 결과, 남성 226명·여성 102명으로 남성이 68.9%로 참여율이 더 높은 것으로 나타났고, 20대 28명·30대 80명·40대 133명·50대 65명·60세 이상 22명으로 30~50대가 84.7%를 차지하는 것으로 나타났다. 공직 103명·ICT 분야 등 97명·제조업 등 58명·서비스 분야 54명으로 나타났고, 농어업 종사자들도 16명이 참여한 것으로 나타났다. 제조 등 분야는 이미 작업 로봇이 있고, 농사에 드론을 활용하는 사례가 많아 로봇에 관한 이해가 있는 종사자들이 참여한 것을 알 수 있었다. 경력 사항은 1년부터 30년 이상까지 고르게 분포돼 있는 것으로 나타났으며, 참여자의 69.21%가 서울·경기·인천 등 수도권 지역에 거주하는 것으로 나타났다. 고등학교 졸업자는 16.77%로 나타났고, 2, 3년제 및 4년제 대학 졸업은 66%로 나타났으며, 석사·박사 대학원 졸업자도 23.17% 참여해 높게 나타났다. 인공지능 로봇에 대체로 관심 있거나 매우 관심 있다고 응답한 참여자는 152명으로 전체의 73.17%로 나타났다.

2. 기술 통계량 분석

인공지능 로봇의 위험성 측정지표에 관한 현장성 설문조사 결과로 기술 통계량을 분석한 결과는 [표 3-35]와 같이 산출되었다. 유효값 328명의 설문조사 결과로 기술 통계량을 분석하였으며, 328개의 측정지표가 모두 유효하게 사용되었다.

[표 3-35] 인공지능 로봇의 위험성 측정지표 개발 설문지 기술 통계량 분석 결과

종속변수	독립변수	평균	표준편차	분석 수
운행, 작업 중 작동 이상	센서 및 인식 오류	4.16	.759	328
	운동 지능 제어 실패	4.23	.709	328
	기체 성능 저하	4.28	.746	328
	프로그램 오류로 인한 오작동	4.24	.761	328
	통신 장애 등 사고 위험 감지 지연	4.27	.729	328
	모션 제어 시스템 성능 저하	4.26	.720	328
	부품 교체 시기 경과	4.16	.743	328

인간을 해칠 판단	의도 파악 인식 오류	4.08	.835	328
	협동 작업 중, 규칙 판단 지능의 오류	4.08	.844	328
	프로그램의 판단 오류로 사고 희생자 선택 착오	4.15	.872	328
	학습량 부족으로 맞지 않는 의학적 자료 제공	4.07	.892	328
	학습된 규칙이나 로봇의 원칙을 넘어서는 판단	4.02	.902	328
	라벨링 오류로 인한 잘못된 정보 제공	4.15	.843	328
	장애물인식오류	4.11	.855	328
	비상상황 안전 정지 모니터링 실패	4.12	.811	328
인격권 침해	명령어 등 음성을 잘못 인식	3.95	.894	328
	감정 피드백 오류	3.95	.952	328
	대상 인식 판단 오류	4.05	.892	328
	도덕성 검증이 되지 않은 학습 데이터 사용	4.13	.842	328
	멀티 모달리티 오류	4.03	.870	328
자유 의사 방해	의사 결정을 특정 방향으로 유도	4.11	.811	328
	여론 형성 조작	4.20	.790	328
	중요한 결정을 위한 관리자의 개입 차단	4.18	.847	328
	필터링 오류로 의사표현의 자율성 침해	4.12	.811	328
	우월적인 지위를 이용해서 인간의 심리 지배	4.18	.877	328
선택적 서비스나 정보 제공	학습 데이터 오류로 인해 잘못된 언어 사용	4.11	.799	328
	편향된 학습 데이터로 인한 차별적 정보 제공	4.25	.719	328
	시스템 공격 등으로 개인정보의 침해나 유출	4.27	.771	328
	대상자의 지식수준에 따라 선별적 정보 제공	4.15	.767	328
	시나리오 설계 문제로 부적절한 콘텐츠 제공	4.23	.733	328
정보 입력, 탈취	시스템 접근 제어망 침범	4.23	.775	328
	비인가 시스템 접근 허용	4.28	.742	328
	악성코드, 바이러스 감염 등으로 시스템 오류	4.34	.762	328
	데이터 손실 방지 시스템 취약	4.25	.756	328
	허용되지 않은 정보 수집 및 이용	4.22	.789	328
기계 결합 오작동	센서 모니터링 실패	4.23	.781	328
	다양한 상황에 의한 충돌로 시설물 파손	4.27	.727	328
	모터, 유압 등 구동부 문제	4.30	.748	328
	정기검사 미 점검 등 정비 불량	4.24	.758	328
	감속기 제어의 문제	4.20	.789	328
	제어기 오류	4.31	.729	328

잘못된 의사 결정	유형의 재물 훼손	4.03	.912	328
	인식 지능에 대한 오류	4.22	.772	328
	창작물 무단 복제	4.18	.853	328
	하자 상품 추천	4.11	.847	328
	안전거리 계산 오류	4.20	.830	328
	알고리즘의 최적화 성능 부족	4.21	.811	328
	사물 인식 판단 지능 저하	4.20	.794	328
데이터 문제	데이터 유출	4.15	.812	328
	개인 등 정보 무작위 수집	4.17	.788	328
	부적절한 학습 데이터 수집	4.22	.840	328
	습득한 정보를 권한 없는 자에게 제공	4.11	.859	328
	허위 정보 제공	4.16	.821	328
법규 판단 오류	법률, 규칙 혼동	4.09	.859	328
	인간이 의도하지 않은 행위로 혼란유발	4.13	.827	328
	차선, 신호 등 인식 오류	4.21	.854	328
	법규 최적화 업데이트 오류	4.14	.854	328
	허용되지 않은 권한의 오인 판단	4.18	.822	328
도로상 작동 중지	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지	4.24	.859	328
	통신 이상 등 장애	4.33	.751	328
	보행자 통행 방해	4.36	.793	328
	도로매칭 알고리즘 오류	4.30	.810	328
	주변 환경 변화에 대한 반응 속도저하	4.30	.760	328
	이동 속도 제어나 조절 실패로 운행 정지	4.37	.791	328
	데이터 업데이트 오류	4.34	.776	328

리커트 5점 척도를 활용한 현장성 설문조사 결과로 기술 통계량을 분석하였고, 현장성 설문조사에서 유효수 328명의 응답으로 평균과 표준편차를 제시하였다.

평균(Mean)은 설문 응답의 중심을 나타내는 값으로 328명이 설문조사 문항마다 1점~5점 중 어떤 점수를 부여했을 때, 총합을 나눈 값이므로 문항별로 대푯값을 구하는 데 유용하다. 통계 분석에서는 평균값만으로 자료의 특성을 전체적으로 파악하기 어려워 자료의 분산을 나타내는 표준편차를 함께 나타내는 것이 일반적이다.

표준편차(Standard Deviation)란 측정값들이 평균값을 중심으로 얼마나 거리가 있는지를 보여주는 지표이다. 만약 표준편차가 0으로 나타났다면 측정값이 평균과 동일함을 의미하며, 표준편차가 클수록 평균과 차이가 많다는 것을 의미한다. 즉, 표준편차가 작으면 328명이 대체로 비슷한 수치의 점수에 응답했다는 것이고, 표준편차가 크다면 응답한 점수의 분포도가 넓게 흩어져 있다는 것이다. 따라서, 통계적 해석에서는 응답자 간 의견 편차가 큰 변수는 사용하지 않는 것을 권장하고 있다.

운행, 작업 중 작동 이상 항목 종속변수의 독립변수는 총 7개이며 기술 통계량 분석 결과, 평균은 4.16~4.28로 나타났고 표준편차는 0.709~0.761로 나타났다. 인간을 해칠 판단 종속변수의 독립변수는 8개이며, 평균은 4.02~4.15로 나타났고 표준편차는 0.811~0.902의 수치로 나타났다. 인격권 침해 종속변수의 독립변수는 5개로 평균은 3.95~4.13으로 나타났고, 표준편차는 0.842~0.952의 수치로 나타났다. 자유의사 방해 종속변수의 독립변수는 5개로 평균은 4.11~4.20으로 나타났으며, 표준편차는 0.790~0.877의 수치로 나타났다. 선택적 서비스나 정보 제공 종속변수의 독립변수는 5개이며, 평균은 4.11~4.27로 나타났고, 표준편차는 0.719~0.799의 수치로 나타났다.

정보 입력, 탈취 종속변수의 독립변수는 5개로 평균은 4.22~4.34로 나타났으며, 표준편차는 0.742~0.789로 나타났다. 기계 결함 오작동 종속변수의 독립변수는 6개로 평균은 4.20~4.31로 나타났고, 표준편차는 0.727~0.789의 수치로 나타났다. 잘못된 의사 결정 종속변수의 독립변수는 7개로 평균은 4.03~4.22로 나타났고, 표준편차는 0.772~0.912의 수치로 나타났다. 데이터 문제 종속변수의 독립변수는 5개로 평균은 4.11~4.22로 나타났고, 표준편차는 0.788~0.859의 수치로 나타났다. 범규 판단 오류 종속변수의 독립변수는 5개로 평균은 4.09~4.21로 나타났고, 표준편차는 0.822~0.859의 수치로 나타났다. 도로상 작동 중지 종속변수의 독립변수는 7개로 평균은 4.24~4.37로 나타났고, 표준편차는 0.751~0.859로 나타났다.

기술 통계량 분석 결과, 모든 변수의 평균은 3.95 이상으로 나타났고 표준편차도 0.912 이하로 나타남에 따라 전체 응답자 의견이 대체로 비슷한 것을 알 수 있었다.

3. 탐색적 요인분석 및 신뢰도 분석

연구가설 검증은 측정지표가 해당하는 개념을 제대로 측정하고 있는가를 검토하는 것이 중요하다(조현철, 1998).

개념 타당도를 측정하기 위해 1~2단계 연구에서 상이한 개념의 측정지표를 도출하였으며, 데이터가 동일 그룹을 형성하는지 연구자의 연구처럼 이론적 모형이 없을 때 평가하는 탐색적 요인분석으로 도출된 측정지표들이 타당성을 가지고 목표 요인을 잘 설명하고 있는지 통계 검증하였다(조철호, 2021).

연구를 통해 도출된 측정지표들의 탐색적 요인분석 적합성을 확인하기 위해서 먼저 Kaiser-Meyer-Olkin(KMO) 및 Bartlett의 구형성을 통계 검정하였다.

KMO는 변수 간의 상관관계가 다른 변수에 의해서 설명이 잘되고 있는 정도를 나타내는 값이다. 일반적으로 KMO값이 0.09 이상이면 상당히 좋은 편으로 본다.

통계 분석 검증 결과, [표 36], [표 37], [표 38], [표 39]와 같이 탐색적 요인분석을 위한 변수 선정이 매우 좋은 편으로 나타난 것을 알 수 있었다.

Bartlett의 구형성 검정이란 요인분석 모형의 적합성을 나타내는 것으로, 요인분석 모형으로서의 적합성 여부를 유의 확률로 파악하는데, 유의 확률이 0.000이라면 요인분석의 사용이 적합한 수치라는 의미이다.

측정지표 개발 연구를 위해 1~2단계 연구에서 상이한 개념의 측정지표들을 도출하였으며, 연구 결과로 제시한 인공지능 로봇의 위험성 유형별로 해당하는 항목에 공통 요인이 존재하는지를 확인 및 검증하고자 탐색적 요인분석을 실시하였다.

신뢰성 있는 인공지능 로봇의 위험성 측정지표를 개발하고자 타당도를 검증하기 위해 SPSS를 활용하여 탐색적 요인분석을 실시하였다. 탐색적 요인분석 적합성을 확인하기 위해 먼저 KMO 및 Bartlett 검정을 하였다.

신체에 대한 물리적 위험성 유형의 KMO와 Bartlett의 검증 결과는 [표 3-36]과 같이 나타났다.

[표 3-36] 신체에 대한 물리적 위협성 유형의 KMO 및 Bartlett의 검증 결과

표준형성 적절성의 Kaiser-Meyer-Olkin 측도		.944
Bartlett의 구형성 검증	근사 카이제곱	3867.978
	자유도	105
	유의확률	0.000

신체에 대한 물리적 위협성 유형의 표준형성 적절성을 나타내는 KMO 측도는 0.944의 수치로 나타났으며, Bartlett의 구형성 검증의 유의확률은 0.000으로 탐색적 요인분석에 문제가 없음을 의미하는 것으로 나타났다. 인간의 권리에 대한 위협성 유형의 KMO와 Bartlett의 검증 결과는 [표 3-37]과 같이 나타났다.

[표 3-37] 인간의 권리에 대한 위협성 유형의 KMO 및 Bartlett의 검증 결과

표준형성 적절성의 Kaiser-Meyer-Olkin 측도		.949
Bartlett의 구형성 검증	근사 카이제곱	3867.424
	자유도	105
	유의확률	0.000

인간의 권리에 대한 위협성 유형의 표준형성 적절성을 나타내는 KMO 측도는 0.949의 수치로 나타났으며, Bartlett의 구형성 검증의 유의확률은 0.000으로 탐색적 요인분석에 문제가 없음을 의미하는 것으로 나타났다.

재산 손실의 위협성 유형의 KMO 및 Bartlett의 검증 결과는 [표 3-38]과 같이 나타났다.

[표 3-38] 재산 손실의 위험성 유형의 KMO 및 Bartlett의 검증 결과

표준형성 적절성의 Kaiser-Meyer-Olkin 측도		.952
Bartlett의 구형성 검증	근사 카이제곱	4976.460
	자유도	153
	유의확률	0.000

재산 손실의 위험성 유형의 표준형성 적절성을 나타내는 KMO 측도는 0.952의 수치로 나타났고, Bartlett의 구형성 검증의 유의확률은 0.000으로 탐색적 요인분석에 문제가 없음을 의미하는 것으로 나타났다

사회적 위험성 유형의 KMO와 Bartlett의 검증 결과는 [표 3-39]와 같이 나타났다.

[표 3-39] 사회적 위험성 유형의 KMO 및 Bartlett의 검증 결과

표준형성 적절성의 Kaiser-Meyer-Olkin 측도		.947
Bartlett의 구형성 검증	근사 카이제곱	5431.067
	자유도	136
	유의확률	0.000

사회적 위험성 유형의 KMO 측도는 0.947의 수치로 나타났고, Bartlett의 구형성 검증 유의확률은 0.000으로 탐색적 요인분석에 문제없음을 의미하는 것으로 나타났다.

KMO 통계 검증 결과, 모든 유형의 측도가 0.9 이상으로 나타났고, 유의확률은 0.000으로 탐색적 요인분석에 문제가 없는 것으로 나타나 탐색적 요인분석을 실시하였다. 모든 변수에서 구성 요인을 추출하고자 주성분 분석을 사용하였다.

주성분 분석에 의해 추출되는 공통성의 수치가 낮으면 제외하는 것이 좋으며, 요인들이 각 변수의 분산을 설명해 주는 요인 적재치의 단순화를 위해 직교회전방식(varimax)를 채택하였다(조철호, 2021).

일반적인 요인과 문항 선택 기준은 고윳값 1.0 이상, 요인 적재치 0.50이 넘을 경우 중요한 변수라고 보고 있으며, 주성분 분석으로 추출되는 공통성이 0.4 이하의 수치가 나오면 낮다고 판정한다(송지준, 2021).

분산설명력은 요인분석에서 추출된 요인들이 전체 분산을 얼마나 설명하는지를 나타내며, 누적률은 새로운 축으로 변환된 변수들이 원래 변수들의 분산을 얼마나 설명할 수 있는지를 누적하여 나타낸 것이다.

측정 대상의 신뢰도는 타당성 분석을 통해 추출된 요인들의 동질 변수가 제대로 구성되어 있는지 확인하는 방법이다(Thorndike, 1988). 신뢰성 검증을 위해서 측정 변수들의 문항 내적일관성을 나타내는 크론바흐 알파계수(Cronbach α)로 나타냈으며, 일반적으로 사회과학 연구에서는 0.6 이상일 때 신뢰할 수 있다고 한다(송지준, 2021).

신체에 대한 물리적 위험성의 탐색적 요인분석 결과 및 신뢰도 분석 결과는 [표 3-40]과 같이 나타났다.

신체에 대한 물리적 위험성 유형의 15개 변수를 탐색적 요인분석 한 결과, 요인 적재량이 중요한 변수를 의미하는 0.5를 상회하는 수치로 나타났다. 2개 항목으로 묶이는 것을 알 수 있었으며, 델파이 설문조사 및 전문가 인터뷰를 통해 도출되고 정의된 명칭인 인간을 해칠 판단 및 운행 작업 중 작동 이상 항목으로 구분하였다.

인간을 해칠 판단 항목은 모든 변수에서 공통성이 0.6 이상의 수치로 나타났고, 신뢰도를 나타내는 크론바흐 알파 계수는 0.940의 높은 수치로 나타났다. 항목 제거 시 신뢰도 수치가 모든 변수에서 0.940 보다 낮아 제거할 변수는 없는 것을 알 수 있었다. 운행 작업 중 작동 이상 항목은 모든 변수에서 공통성이 0.6 이상의 수치로 나타났고, 신뢰도 값도 0.920로 높게 나타났다. 항목 제거 시 신뢰도 수치가 모든 변수에서 0.920 보다 낮아 제거할 변수는 없음을 알 수 있었다.

[표 3-40] 신체에 대한 물리적 위협성의 탐색적 요인분석 및 신뢰도 분석 결과

변수 명	요인 적재량		공통성	고유 값	분산 설명력	누적률	신뢰도	
	인간을 해칠 판단	운행, 작업 중 작동 이상					Alpha if Item Deleted	Cronbach's α
judg5	.839	.235	.759	5.564	37.096	37.096	.931	.940
judg6	.799	.254	.703				.933	
judg4	.788	.235	.677				.935	
judg2	.776	.404	.766				.929	
judg8	.773	.346	.717				.932	
judg7	.771	.339	.710				.932	
judg1	.765	.325	.691				.933	
judg3	.723	.367	.657				.935	
abno5	.269	.830	.643	4.879	32.528	69.624	.901	.920
abno4	.239	.811	.714				.907	
abno2	.303	.803	.737				.904	
abno1	.268	.787	.691				.908	
abno6	.319	.736	.643				.909	
abno7	.345	.720	.637				.909	
abno3	.430	.629	.581				.914	

인간의 권리에 대한 위협성 유형의 탐색적 요인분석 및 신뢰도 분석 결과는 [표 3-41]과 같이 나타났다.

인간의 권리에 대한 위협성 유형의 15개 변수를 탐색적 요인분석 한 결과, 요인 적재량이 중요한 변수를 의미하는 0.5를 상회하는 수치로 나타났으며, 3개 항목으로 묶이는 것을 알 수 있었고, 텔파이 조사 및 전문가 인터뷰에서 도출된 인격권 침해·자유 의사 방해·선택적 서비스, 정보 제공 항목으로 구분하였다.

인격권 침해 항목은 모든 변수에서 공통성이 0.6 이상으로 나타났으며, 신뢰도 분석 결과, 크론바흐 알파 계수는 0.910의 높은 수치로 나타났다.

자유 의사 방해 항목은 모든 변수에서 공통성이 0.6 이상의 수치로 나타났으며, 신뢰도 값도 0.919로 높게 나타났다.

선택적 서비스나 정보 제공 항목은 모든 변수에서 공통성이 0.6 이상의 수치로 나타났으며, 신뢰도를 나타내는 크론바흐 알파 계수는 0.888로 나타났다.

[표 3-41] 인간의 권리에 대한 위험성의 탐색적 요인분석 및 신뢰도 분석 결과

변수명	요인 적재량			공통성	고유 값	분산 설명력	누적률	신뢰도	
	인격권 침해	자유 의사 방해	선택적 서비스, 정보 제공					Alpha if Item Deleted	Cronbach's α
dist5	.762	.310	.251	.739	3.742	24.949	24.949	.895	.910
dist2	.741	.301	.337	.754				.887	
dist4	.741	.358	.347	.797				.878	
dist1	.711	.265	.372	.714				.894	
dist3	.642	.331	.396	.678				.895	
infr3	.244	.838	.241	.819	3.732	24.882	49.831	.896	.919
infr2	.295	.817	.253	.818				.895	
infr1	.280	.808	.252	.795				.898	
infr5	.444	.672	.302	.739				.899	
infr4	.455	.563	.376	.666				.912	
disc2	.327	.208	.777	.755	3.565	23.767	73.598	.856	.888
disc3	.260	.171	.735	.636				.884	
disc5	.293	.380	.707	.730				.856	
disc1	.270	.415	.676	.702				.862	
disc4	.428	.243	.674	.697				.859	

재산 손실의 위험성의 탐색적 요인분석 및 신뢰도 분석 결과는 [표 3-42]와 같이 나타났다.

[표 3-42] 재산 손실의 위험성의 탐색적 요인분석 및 신뢰도 분석 결과

변수명	요인 적재량			공통성	고유 값	분산 설명력	누적률	신뢰도	
	잘못된 의사 결정	기계 결함 오작동	정보 입력, 탈취					Alpha if Item Deleted	Cronbach's α
deci3	.805	.257	.117	.728	4.783	26.571	26.571	.925	.932
deci4	.782	.324	.189	.752				.921	
deci2	.725	.320	.370	.765				.919	
deci1	.723	.255	.334	.700				.924	
deci6	.717	.282	.326	.699				.923	
deci7	.708	.289	.361	.715				.922	
deci5	.678	.376	.336	.713				.921	
malf4	.317	.780	.289	.793	4.334	24.078	50.649	.905	.924
malf3	.308	.749	.268	.727				.911	
malf2	.329	.738	.290	.737				.910	
malf5	.327	.728	.324	.742				.909	
malf6	.334	.689	.378	.729				.910	
malf1	.280	.680	.320	.644				.919	
capt1	.271	.289	.780	.766	4.116	22.864	73.513	.900	.920
capt4	.274	.363	.767	.796				.897	
capt5	.285	.303	.763	.756				.904	
capt3	.285	.264	.749	.712				.911	
capt2	.298	.364	.733	.759				.901	

재산 손실 위험성 유형의 18개 변수를 탐색적 요인분석 한 결과, 요인 적재량이 중요한 변수를 의미하는 0.5를 상회하는 수치로 나타났다.

또한, 요인들이 3개 항목으로 묶이는 것을 알 수 있었는데, 1단계 연구의 전문가 인터뷰와 델파이 결과로 제시된 잘못된 의사결정·기계 결함 오작동·정보 입력, 탈취 항목으로 항목명을 구분하였다.

잘못된 의사결정 항목은 모든 변수에서 공통성이 0.7 이상의 수치로 나타났고, 신뢰도 분석 결과, 크론바흐 알파 계수는 0.932의 높은 수치로 나타났다. 기계 결함 오작동 항목은 모든 변수 공통성이 0.6 이상의 수치로 나타났다. 신뢰도 값도 0.924로 높게 나타났고, 정보 입력 탈취 항목은 모든 변수에서 공통성이 0.7 이상의 수치로 나타났다. 신뢰도 분석 결과, 크론바흐 알파 계수는 0.920의 높은 수치로 나타났다.

사회적 위험성의 탐색적 요인분석 및 신뢰도 분석 결과는 [표 3-43]과 같이 나타났다.

사회적 위험성의 17개 변수를 탐색적 요인분석 한 결과, 요인 적재량이 중요한 변수를 의미하는 0.5를 상회하는 수치로 나타났다. 3개 항목으로 묶이는 것을 알 수 있었고, 전문가 인터뷰와 델파이 결과로 제시된 도로상 작동 중지·데이터 문제·법규 판단 오류 항목으로 구분하였다.

도로상 작동 중지 항목은 모든 변수에서 공통성이 0.7 이상의 수치로 나타났고, 신뢰도 분석 결과 크론바흐 알파 계수는 0.949의 높은 수치로 나타났다. 데이터 문제 항목은 모든 변수에서 공통성이 0.7 이상의 수치로 나타났고, 신뢰도 값도 0.927로 높게 나타났다. 법규 판단 오류 항목은 모든 변수에서 공통성이 0.6 이상의 수치로 나타났으며, 신뢰도 분석 결과, 크론바흐 알파 계수는 0.919로 높게 나타났다.

현장성 설문조사 결과를 토대로 통계 검증한 결과, 추출된 요인들에 의해 설명되는 비율을 나타내는 요인 적재량이 모든 항목에서 0.5 이상의 수치로 나타났다.

모든 변수에서 0.8 이상의 높은 신뢰도 수치가 나타남에 따라 신뢰도에는 문제 없음을 알 수 있었다.

[표 3-43] 사회적 위험성의 탐색적 요인분석 및 신뢰도 분석 결과

변수명	요인 적재량			공통성	고유 값	분산 설명력	누적률	신뢰도	
	도로상 작동 중지	데이터 문제	법규 판단 오류					Alpha if Item Deleted	Cronbach α
stop4	.814	.283	.229	.795	5.366	31.565	31.565	.940	.949
stop2	.809	.300	.271	.818				.939	
stop5	.796	.271	.300	.797				.940	
stop1	.786	.331	.258	.793				.941	
stop7	.768	.294	.268	.748				.943	
stop3	.743	.255	.310	.714				.945	
stop6	.743	.299	.289	.724				.944	
misc5	.335	.786	.309	.826	3.929	23.114	54.679	.904	.927
misc2	.328	.763	.373	.829				.901	
misc1	.328	.752	.307	.766				.916	
misc4	.373	.730	.294	.758				.913	
misc3	.322	.662	.403	.704				.919	
data2	.306	.336	.800	.847	3.791	22.299	76.978	.887	.919
data3	.263	.273	.790	.768				.908	
data4	.305	.299	.781	.793				.896	
data5	.411	.382	.635	.719				.904	
data1	.330	.420	.634	.687				.907	

인공지능 로봇이 도입될 수 있는 여러 분야 종사자 설문조사의 탐색적 요인분석 결과가 1단계 연구의 전문가 델파이 결과와 동일한 11개의 항목으로 구성됨에 따라 인공지능 로봇의 위험성 유형별 측정지표 개발 연구가 잘 진행되었음을 알 수 있었다.

4. 상관관계 분석

상관관계란 두 개 이상의 변수에서 한 개의 변수가 변화하면 다른 변수가 어떻게 변화하는지에 대한 강도 및 방향을 의미한다. +1이나 -1에 가까운 수치일수록 변수 간 상관관계는 높은 것이고, 0에 가까울수록 변수 간 상관관계는 낮은 것이다.

상관계수 판단 기준은 ± 0.9 이상은 매우 높은 상관관계, $\pm 0.7 \sim \pm 0.9$ 미만은 높은 상관관계, $\pm 0.4 \sim \pm 0.7$ 미만은 다소 높은 상관관계, $\pm 0.2 \sim \pm 0.4$ 미만은 낮은 상관관계, ± 0.2 미만이면 상관관계가 거의 없다는 것으로 해석한다(송지준, 2021).

연구의 가설검정을 위한 통계분석을 실시하기 전에는 변수 계산을 하여야 하며, 변수계산은 요인분석과 신뢰도 분석 등 변수정제 과정을 통해 최종적으로 남아 있는 변수들을 모두 더해 변수의 수만큼 나누어주고 하나의 변수로 만들어주는 작업이다(송지준, 2021). 연구의 가설검정을 위해 변수 계산을 하였고, 신체에 대한 물리적 위험성 유형의 요인별 상관관계 분석한 결과는 [표 3-44]와 같이 정리하였다.

[표 3-44] 신체에 대한 물리적 위험성 유형의 요인별 상관관계 분석 결과

요인	평균	표준편차	구성 개념 간 상관관계	
			작동이상	해철판단
작동이상	4.2282	.60634	1	
해철판단	4.0998	.71992	.691**	1

**. 상관계수는 0.01 수준(양쪽)에서 유의합니다.

신체에 대한 물리적 위험성 유형의 요인별 상관관계 분석 결과 작동이상과 해철판단의 상관관계는 0.691의 유의미한 수치로 나타났다. 인간의 권리에 대한 위험성 유형의 요인별 상관관계 분석한 결과는 [표 3-45]와 같이 정리하였다.

[표 3-45] 인간의 권리에 대한 위험성 유형의 요인별 상관관계 분석 결과

요인	평균	표준편차	구성 개념 간 상관관계		
			인격침해	의사방해	선택정보
인격침해	4.0232	.77370	1		
의사방해	4.1567	.71005	.763**	1	
선택정보	4.2018	.63022	.717**	.781**	1

** . 상관계수는 0.01 수준(양쪽)에서 유의합니다.

인간의 권리에 대한 위험성 유형 중, 인격 침해와 의사방해의 상관관계는 0.763의 유의미한 수치로 나타났고, 인격 침해와 선택 정보의 상관관계는 0.717로 유의미하게 나타났으며, 의사방해와 선택 정보의 상관관계는 0.781의 유의미한 수치로 나타났다.

재산 손실의 위험성 유형의 요인별 상관관계 분석한 결과는 [표 3-46]과 같다.

[표 3-46] 재산 손실의 위험성 유형의 요인별 상관관계 분석 결과

요인	평균	표준편차	구성 개념 간 상관관계		
			정보탈취	기계결함	잘못결정
정보탈취	4.2640	.66649	1		
기계결함	4.2571	.64381	.747**	1	
잘못결정	4.1655	.70198	.707**	.750**	1

** . 상관계수는 0.01 수준(양쪽)에서 유의합니다.

재산 손실의 위험성 유형의 요인별 상관관계 분석 결과 정보 탈취와 기계 결함의 상관관계는 0.747의 유의미한 수치로 나타났다.

정보 탈취와 잘못 결정의 상관관계는 0.707의 유의미한 수치로 나타났으며, 기계 결함과 잘못 결정의 상관관계는 0.750의 유의미한 수치로 나타났다.

사회적 위험성 유형의 요인별 상관관계 분석한 결과는 [표 3-47]과 같다.

[표 3-47] 사회적 위험성 유형의 요인별 상관관계 분석 결과

요인	평균	표준편차	구성 개념 간 상관관계		
			데이터	법규오류	도로중지
데이터	4.1628	.71640	1		
법규오류	4.1506	.74218	.788**	1	
도로중지	4.3184	.69385	.721**	.740**	1

**, 상관계수는 0.01 수준(양쪽)에서 유의합니다.

사회적 위험성 유형 중에서 데이터 항목과 법규 오류 항목의 상관관계는 0.788의 유의미한 수치로 나타났다. 데이터 항목과 도로 중지 항목 상관관계는 0.721 유의미한 수치로 나타났고, 법규 오류와 도로 중지의 상관관계는 0.74의 유의미한 수치로 나타났다.

이 연구에서는 연구가설을 검증하기 위해서 탐색적 요인분석 및 신뢰도 분석을 하였으며, 통계 분석 결과로 변수정제 과정을 위해 변수계산을 하였다.

신체에 대한 물리적 위험성 유형, 인간 권리에 대한 위험성 유형, 재산 손실의 위험성 유형, 사회적 위험성 유형의 하위요인들 간의 상관관계를 분석한 결과, 모든 상관계수는 0.01 유의수준 하에서 유의한 것으로 나타났다.

설문 응답의 중심을 나타내는 평균값도 모든 요인에서 4 이상으로 나타났으며, 측정값들이 평균값과의 차이를 나타내는 표준편차도 모든 요인에서 0.77370 이하의 수치로 나타나 전체 응답자들 의견이 대체로 비슷하게 분포돼 있음을 알 수 있었다.

5. 다중 회귀분석

다중 회귀분석은 독립변수가 여러 개이고 종속변수가 한 개인 경우에 실시하며, 독립변수가 종속변수에 미치는 영향을 확인할 수 있는 검증 방법이다(조철호, 2021).

Durbin-Watson 통계량은 잔차에 대한 독립성을 알아보기 위해 실시하며, 0에 가까울수록 양의 상관관계가 있고, 0 또는 4에 가까울 경우는 잔차 간 상관관계가 있어 회귀모형이 부적합함을 나타낸다. Durbin-Watson 통계량의 기준값은 정상분포 곡선을 나타내는 2이며, 이는 잔차에 상관관계가 없음을 의미하고, 수정된 R^2 은 1에 가까울수록 회귀모형이 적합하다는 설명력을 나타낸다. 다중 회귀분석은 독립변수가 2개 이상이므로 다중공선성이 발생할 수 있고 공차 한계값이 0.1 이하일 때 다중공선성에 문제가 있다고 한다(송지준, 2021).

연구가설 검증을 위해 먼저 인공지능 로봇의 위험성 4개 유형의 항목 변수 간 다중 회귀분석을 하였다. 통계 분석 결과를 토대로 신체에 대한 물리적 위험성·인권 권리에 대한 위험성·재산 손실의 위험성·사회적 위험성 등 유형별 항목 변수 간 다중 회귀분석 하였다.

신체에 대한 물리적 위험성 유형의 항목 변수 간 다중 회귀분석 결과는 [표 3-48]과 같이 나타났다.

운행 작업 중, 작동 이상 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.987로 회귀선의 설명력은 좋은 것으로 나타났다. Durbin-Watson 값도 1.833으로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 1~6의 표준화 계수(β)의 유의확률 p 값이 0.000의 수치로 나타나 독립 변수의 계수 값도 유의한 것으로 나타났다. 인간을 해칠 판단 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.981로 회귀선 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.912로 2에 가까워 잔차의 독립성도 확립되었다.

[표 3-48] 신체에 대한 물리적 위험성 유형의 항목 변수 간 다중 회귀분석 결과

종속변수	독립변수	표준오차	베타(β)값	t값	유의확률	공차한계
운행 작업 중, 작동 이상	상수	.027		1.872	.062	
	abno1(가설1)	.008	.241	24.004	.000**	.405
	abno2(가설2)	.009	.154	14.184	.000**	.347
	abno3(가설3)	.008	.223	23.954	.000**	.471
	abno4(가설4)	.008	.210	20.177	.000**	.378
	abno5(가설5)	.009	.175	15.756	.000**	.330
	abno6(가설6)	.008	.199	19.799	.000**	.406
	R = .993 α , R ² = .987, 수정된 R ² = .987 F = 4025.847, p = .000**, Durbin-Watson = 1.833					
인간을 해칠 판단	상수	.032		1.406	.161	
	judg1(가설8)	.011	.211	17.130	.000**	.374
	judg2(가설9)	.012	.200	14.575	.000**	.302
	judg3(가설10)	.010	.169	14.530	.000**	.420
	judg4(가설11)	.009	.219	19.534	.000**	.453
	judg6(가설13)	.010	.208	17.187	.000**	.390
	judg7(가설14)	.011	.167	13.301	.000**	.363
	R = .991 α , R ² = .982, 수정된 R ² = .981 F = 2872.916, p = .000**, Durbin-Watson = 1.912					

*.p < 0.05 **.p < 0.01

분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었으며, 가설 8·9·10·11·13·14의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값 또한 유의한 것으로 나타났다.

인간의 권리에 대한 위협성 유형의 항목 변수 간 다중 회귀분석 결과는 [표 3-49]와 같이 나타났다.

[표 3-49] 인간의 권리에 대한 위협성 유형의 항목 변수 간 다중 회귀분석 결과

종속변수	독립변수	표준오차	베타(β)값	t값	유의확률	공차한계
인격권 침해	상수	.031		2.476	.014	
	infr1(가설16)	.011	.278	22.587	.000**	.355
	infr2(가설17)	.010	.345	27.587	.000**	.345
	infr4(가설19)	.010	.267	24.152	.000**	.442
	infr5(가설20)	.011	.245	19.716	.000**	.350
	R = .991 α , R ² = .983, 수정된 R ² = .982 F = 4561.581, p = .000**, Durbin-Watson = 1.841					
자유 의사 방해	상수	.038		1.812	.071	
	dist1(가설21)	.012	.283	20.635	.000**	.433
	dist2(가설22)	.013	.262	17.942	.000**	.383
	dist3(가설23)	.012	.280	20.272	.000**	.427
	dist4(가설24)	.014	.304	19.461	.000**	.334
	R = .987 α , R ² = .974, 수정된 R ² = .973 F = 2980.427, p = .000**, Durbin-Watson = 1.908					
선택적 서비스나 정보 제공	상수	.038		1.968	.050	
	disc1(가설26)	.010	.326	24.997	.000**	.467
	disc2(가설27)	.012	.245	17.526	.000**	.405
	disc3(가설28)	.009	.301	26.250	.000**	.604
	disc5(가설30)	.012	.305	22.654	.000**	.438
	R = .987 α , R ² = .974, 수정된 R ² = .974 F = 3070.575, p = .000**, Durbin-Watson = 1.967					

*.p < 0.05 **.p < 0.01

인격권 침해 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.982로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.841로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000의 유의 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었고, 연구가설 16·17·19·20의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수 계수 값도 유의한 것으로 나타났다.

자유의사 방해의 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 값인 수정된 R^2 이 0.973로 회귀선의 설명력은 좋은 것으로 나타났고, Durbin-Watson 값도 1.908로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량 유의확률 p 값이 0.000의 유의 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었으며, 가설 21~24의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

선택적 서비스나 정보 제공 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.974로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.967로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 유의함을 의미하는 0.000의 수치로 나타나, 회귀식은 유의하다는 연구가설이 채택되었고, 가설 26·27·28·30의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값 또한 유의한 것으로 나타났다.

재산 손실의 위험성 유형의 항목 변수 간 다중 회귀분석 결과는 [표 3-50]과 같다.

정보 입력, 탈취 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.979로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.962로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000으로 유의함으로써 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 31~34의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타남에 따라 독립변수의 계수 값도 유의한 것으로 나타났다.

[표 3-50] 재산 손실의 위험성 유형의 항목 변수 간 다중 회귀분석 결과

종속변수	독립변수	표준오차	베타(β)값	t값	유의확률	공차한계
정보 입력, 탈취	상수	.035		1.434	.153	
	capt1(가설31)	.012	.276	20.034	.000**	.342
	capt2(가설32)	.012	.294	22.440	.000**	.377
	capt3(가설33)	.011	.256	20.784	.000**	.427
	capt4(가설34)	.012	.296	21.254	.000**	.334
	$R = .989\alpha$, $R^2 = .979$, 수정된 $R^2 = .979$ $F = 3778.046$, $p = .000**$, Durbin-Watson = 1.962					
기계 결함 오작동	상수	.030		.218	.828	
	malf1(가설36)	.008	.233	22.892	.000**	.451
	malf2(가설37)	.010	.231	21.028	.000**	.387
	malf3(가설38)	.010	.209	17.979	.000**	.345
	malf4(가설39)	.010	.257	21.694	.000**	.333
	malf6(가설41)	.010	.227	20.418	.000**	.379
	$R = .992\alpha$, $R^2 = .985$, 수정된 $R^2 = .985$ $F = 4209.241$, $p = .000**$, Durbin-Watson = 1.929					
잘못된 의사 결정	상수	.024		2.880	.004	
	dec1(가설42)	.007	.201	22.513	.000**	.384
	dec2(가설43)	.009	.198	20.325	.000**	.321
	dec3(가설44)	.007	.188	21.823	.000**	.411
	dec4(가설45)	.008	.200	21.615	.000**	.358
	dec5(가설46)	.008	.184	19.497	.000**	.344
	dec6(가설47)	.008	.201	22.816	.000**	.393
	$R = .995\alpha$, $R^2 = .990$, 수정된 $R^2 = .990$ $F = 5402.944$, $p = .000**$, Durbin-Watson = 1.970					

*.p < 0.05 **.p < 0.01

기계 결함 오작동 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.985로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.929로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000으로 유의함으로써 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 36~39 및 연구가설 41의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

잘못된 의사 결정 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.990으로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.970으로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 42~47의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타남에 따라 독립변수의 계수 값도 유의한 것으로 나타났다.

사회적 위험성 유형의 항목 변수 간 다중 회귀분석 결과는 [표 3-51]과 같이 나타났다.

데이터 문제 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.981로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.948로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000으로 유의함으로써 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 49~51, 53의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다. 법규 판단 오류의 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.987로 회귀선의 설명력은 좋은 것으로 나타났다. Durbin-Watson 값도 1.900으로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었다. 연구가설 54~57의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

[표 3-51] 사회적 위험성 유형의 항목 변수 간 다중 회귀분석 결과

종속변수	독립변수	표준오차	베타(β)값	t값	유의확률	공차한계
데이터 문제	(상수)	.033		.004	.997	
	data1(가설49)	.011	.270	22.376	.000**	.406
	data2(가설50)	.014	.284	19.138	.000**	.268
	data3(가설51)	.010	.295	24.513	.000**	.410
	data5(가설53)	.010	.284	23.899	.000**	.420
	R = .990 α , R ² = .981, 수정된 R ² = .981 F = 4133.713, p = .000**, Durbin-Watson = 1.948					
법규 판단 오류	(상수)	.027		2.262	.024	
	misc1(가설54)	.009	.338	31.961	.000**	.361
	misc2(가설55)	.012	.219	16.559	.000**	.231
	misc3(가설56)	.009	.296	27.637	.000**	.353
	misc4(가설57)	.009	.277	26.996	.000**	.384
	R = .993 α , R ² = .987, 수정된 R ² = .987 F = 6092.839, p = .000**, Durbin-Watson = 1.900					
도로상 작동 중지	(상수)	.033		3.083	.002	
	stop1(가설59)	.012	.220	14.687	.000**	.248
	stop2(가설60)	.013	.262	18.405	.000**	.276
	stop3(가설61)	.010	.250	21.000	.000**	.396
	stop4(가설62)	.013	.181	12.235	.000**	.255
	stop7(가설65)	.012	.205	15.687	.000**	.328
	R = .991, R ² = .982, 수정된 R ² = .982 F = 3509.446, p = .000**, Durbin-Watson = 1.907					

*.p < 0.05 **.p < 0.01

도로상 작동 중지 변수 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.982로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.907로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었다.

연구가설 59~62 및 연구가설 65의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

인공지능 로봇의 위험성 4개 유형의 항목 변수 간 다중 회귀분석 결과, 공차의 한계값은 모두 0.1 이상으로 다중공선성에는 아무런 문제가 없는 것으로 나타났고, Durbin-Watson 2 이하의 연구가설은 채택하였다.

신체에 대한 물리적 위험성에서는 연구가설 1·2·3·4·5·6·8·9·10·11·13·14가 채택되었으며, 인간의 권리에 대한 위험성에서는 연구가설 16·17·19·20·21·22·23·24·26·27·28·30이 채택되었다.

재산 손실의 위험성에서는 연구가설 31·32·33·34·36·37·38·39·41·42·43·44·45·46·47이 채택되었고, 사회적 위험성에서는 연구가설 49·50·51·53·54·55·56·57·59·60·61·62·65가 채택되었다.

다중 회귀분석에서 표준오차는 예측값과 실제값의 차이를 나타내는데, 이 값이 작을수록 모형의 예측력이 높다고 본다고 판단한다.

신체에 대한 위험성 및 인간 권리에 대한 위험성, 재산 손실의 위험성, 사회적 위험성 유형의 다중 회귀분석 결과, 모든 변수에서 표준오차는 0.015 이하의 수치로 나타났다.

항목 변수 간 다중 회귀분석에 이어, 신체에 대한 물리적 위험성·인간 권리에 대한 위험성·재산 손실의 위험성·사회적 위험성 유형별 항목 변수 간 다중 회귀분석 하였다.

위험성 유형별 항목 간 다중 회귀분석 결과는 [표 3-52]와 같이 나타났다.

[표 3-52] 위험성 유형별 항목 간 다중 회귀분석 결과

종속변수	독립변수	표준오차	베타(β)값	t값	유의확률	공차한계
신체에 대한 물리적 위험성	(상수)	.024		.165	.869	
	작동이상(가설 66)	.008	.507	66.367	.000**	.522
	해칠판단(가설 67)	.007	.574	75.171	.000**	.522
	$R = .995\alpha$, $R^2 = .990$, 수정된 $R^2 = .990$ $F = 16231.850$, $p = .000**$, Durbin-Watson = 1.973					
인간의 권리에 대한 위험성	(상수)	.023		-.170	.865	
	인격침해(가설 68)	.007	.391	47.095	.000**	.381
	의사방해(가설 69)	.008	.354	38.174	.000**	.305
	선택정보(가설 70)	.009	.345	40.170	.000**	.354
	$R = .996\alpha$, $R^2 = .992$, 수정된 $R^2 = .991$ $F = 12629.894$, $p = .000**$, Durbin-Watson = 1.928					
재산 손실의 위험성	(상수)	.018		1.434	.152	
	정보탈취(가설 71)	.006	.281	43.365	.000**	.392
	기계결함(가설 72)	.007	.352	50.893	.000**	.344
	잘못결정(가설 73)	.006	.464	71.466	.000**	.389
	$R = .997\alpha$, $R^2 = .995$, 수정된 $R^2 = .995$ $F = 20183.488$, $p = .000**$, Durbin-Watson = 1.911					
사회적 위험성	(상수)	.021		-.392	.695	
	테이터(가설 74)	.008	.324	38.821	.000**	.337
	법규오류(가설 75)	.008	.351	40.940	.000**	.318
	도로중지(가설 76)	.007	.416	54.559	.000**	.402
	$R = .996\alpha$, $R^2 = .992$, 수정된 $R^2 = .992$ $F = 14111.029$, $p = .000**$, Durbin-Watson = 1.903					

*.p < 0.05 **.p < 0.01

신체에 대한 물리적 위험성 유형별 항목 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.990으로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.973으로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었다. 연구가설 66·67의 표준화 계수(β)의 유의확률 p 값이 0.000의 유의한 수치로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

인간 권리에 대한 위험성 유형별 항목 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.991로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.928로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량의 유의확률 p 값이 유의함으로써 회귀식은 유의하다는 연구가설이 채택되었다. 연구가설 68·69·70의 표준화 계수(β)의 유의확률 p 값이 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

재산 손실의 위험성 유형별 항목 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.995로 회귀선의 설명력은 좋은 것으로 나타났다.

Durbin-Watson 값도 1.911로 2에 가까워 잔차의 독립성도 확립되었다. 분산분석 F 통계량의 유의확률 p 값이 0.000으로 유의함으로써 회귀식은 유의하다는 가설이 채택되었다. 연구가설 71·72·73의 표준화 계수(β)의 유의확률 p 값 또한 0.000의 유의수치로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

사회적 위험성 유형별 항목 간 다중 회귀분석 결과, 변수들의 수정된 결정계수 수정된 R^2 이 0.992로 회귀선의 설명력은 좋은 것으로 나타났으며, Durbin-Watson 값도 1.903으로 2에 가까워 잔차의 독립성도 확립되었다.

분산분석 F 통계량의 유의확률 p 값이 0.000의 유의한 수치로 나타나 회귀식은 유의하다는 연구가설이 채택되었으며, 연구가설 74·75·76의 표준화 계수(β)의 유의확률 p 값도 0.000으로 나타나 독립변수의 계수 값도 유의한 것으로 나타났다.

제5절 제안된 연구가설 검증 모형

1. 연구가설 검증 결과

연구가설 1~7의 다중 회귀분석 결과, 운동 지능 제어 실패·센서 및 인식 오류·기체 성능 저하·통신 장애 등 사고 위험 감지 지연·프로그램 오류로 인한 오작동·모션 제어 시스템 성능 저하 독립변수는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 운동 지능 제어 실패·센서 및 인식 오류·기체 성능 저하·통신 장애 등 사고 위험 감지 지연·프로그램 오류로 인한 오작동·제어 및 필터 성능 저하·부품 교체 시기 경과 측정지표가 있었다.

운행, 작업 중 작동 이상 항목과 독립변수 간의 다중 회귀분석 결과, 부품 교체 시기 경과 측정지표는 최종 제거되었다.

연구가설 8~15의 다중 회귀분석 결과, 의도 파악 인식 오류·협동 작업 중, 규칙 판단 지능의 오류·프로그램의 판단 오류로 사고 희생자 선택 착오·학습량 부족으로 맞지 않는 의학적 자료 제공·라벨링 오류로 인한 잘못된 정보 제공·장애물 인식 오류 독립변수는 인간을 해칠 판단에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해서 도출된 연구가설에는 학습된 규칙이나 로봇의 원칙을 넘어서는 판단 및 비상 상황 안전 정지 모니터링 실패 측정지표가 포함돼 있었다.

하지만, 인간을 해칠 판단 항목과 독립변수 간의 다중 회귀분석한 결과, 학습된 규칙이나 로봇의 원칙을 넘어서는 판단, 비상 상황 안전 정지 모니터링 실패는 최종 제거되었다.

타당성 및 신뢰성을 분석한 결과를 토대로 연구가설을 검증하였다. 신체에 대한 위험성 유형의 항목 변수 간 연구가설 검증 결과는 [표 3-53]과 같이 정리하였다.

[표 3-53] 신체에 대한 위험성 유형의 항목 변수 간 연구가설 검증 결과

요인	연구가설		검증 결과
운행, 작업 중 작동 이상	가설 1	센서 및 인식 오류는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 2	운동 지능 제어 실패는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 3	기체 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 4	프로그램 오류로 인한 오작동은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 5	통신 장애 등 사고 위험 감지 지연은 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 6	모션 제어 시스템 성능 저하는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	채택
	가설 7	부품 교체 시기 경과는 운행, 작업 중 작동 이상에 정(+)적 영향이 있을 것이다.	기각
인간을 해칠 판단	가설 8	의도 파악 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 9	협동 작업 중, 규칙 판단 지능의 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 10	프로그램의 판단 오류로 사고 희생자 선택 착오는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 11	학습량 부족으로 맞지 않는 의학적 자료 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 12	학습된 규칙이나 로봇의 원칙을 넘어서는 판단은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	기각
	가설 13	라벨링 오류로 인한 잘못된 정보 제공은 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 14	장애물 인식 오류는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	채택
	가설 15	비상 상황 안전 정지 모니터링 실패는 인간을 해칠 판단에 정(+)적 영향이 있을 것이다.	기각

인간 권리에 대한 위험성 유형의 항목 변수 간, 연구가설 검증 결과는 [표 3-54]와 같이 정리하였다.

[표 3-54] 인간 권리에 대한 위험성 유형의 항목 변수 간 연구가설 검증 결과

요인	연구가설		검증 결과
인격권 침해	가설 16	명령어 등 음성을 잘못 인식은 인격권 침해에 정(+)적 영향이 있을 것이다.	채택
	가설 17	감정 피드백 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.	채택
	가설 18	대상 인식 판단 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.	기각
	가설 19	도덕성 검증이 되지 않은 학습 데이터 사용은 인격권 침해에 정(+)적 영향이 있을 것이다.	채택
	가설 20	멀티 모달리티 오류는 인격권 침해에 정(+)적 영향이 있을 것이다.	채택
자유의사 방해	가설 21	의사 결정을 특정 방향으로 유도는 자유의사 방해에 정(+)적 영향이 있을 것이다.	채택
	가설 22	여론 형성 조장은 자유의사 방해에 정(+)적 영향이 있을 것이다.	채택
	가설 23	중요한 결정을 위한 관리자의 개입 차단은 자유의사 방해에 정(+)적 영향이 있을 것이다.	채택
	가설 24	필터링 오류로 의사표현의 자율성 침해는 자유의사 방해에 정(+)적 영향이 있을 것이다.	채택
	가설 25	우월적인 지위를 이용해서 인간의 심리 지배는 자유의사 방해에 정(+)적 영향이 있을 것이다.	기각
선택적 서비스나 정보 제공	가설 26	학습 데이터 오류로 인해 잘못된 언어 사용은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.	채택
	가설 27	편향된 학습 데이터로 인한 차별적 정보 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.	채택
	가설 28	시스템 공격 등으로 개인정보의 침해나 유출은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.	채택
	가설 29	대상자의 지식수준에 따라 선별적 정보 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.	기각
	가설 30	시나리오 설계 문제로 부적절한 콘텐츠 제공은 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이다.	채택

연구가설 16~20의 다중 회귀분석 결과, 명령어 등 음성을 잘못 인식·감정 피드백 오류·도덕성 검증이 되지 않은 학습 데이터 사용·멀티 모달리티 오류 독립변수는 인격권 침해에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 명령어 등 음성을 잘못 인식·감정 피드백 오류·대상 인식 오류·도덕성 검증이 되지 않은 학습 데이터 사용·멀티 모달리티 오류 측정지표가 있었다. 하지만, 인격권 침해 항목과 독립변수 간의 다중 회귀분석 결과 대상 인식 오류 측정지표는 최종 제거되었다.

연구가설 21~25의 다중 회귀분석 결과, 의사 결정을 특정 방향으로 유도·여론 형성 조장·중요한 결정을 위한 관리자의 개입 차단·필터링 오류로 의사 표현의 자율성 침해 독립변수는 자유의사 방해에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 우월적인 지위를 이용해서 인간의 심리 지배 측정지표가 포함돼 있었다.

하지만, 자유의사 방해 항목과 독립변수 간의 다중 회귀분석 결과, 우월적인 지위를 이용해서 인간의 심리 지배 측정지표는 최종 제거되었다.

연구가설 26~30의 다중 회귀분석 결과, 학습 데이터 오류로 인해 잘못된 언어 사용·편향된 학습 데이터로 인한 차별적 정보 제공, 시스템 공격 등으로 개인정보의 침해나 유출, 시나리오 설계 문제로 부적절한 콘텐츠 제공 독립변수는 선택적 서비스나 정보 제공에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 지식수준, 선별 정보 제공 지표가 포함돼 있었다.

하지만, 선택적 서비스나 정보 제공 항목과 독립변수 간의 다중 회귀분석 결과, 지식수준, 선별 정보 제공 측정지표는 최종 제거되었다.

재산 손실의 위험성 유형의 항목 변수 간 연구가설 검증 결과는 [표 3-55]와 같이 정리하였다.

[표 3-55] 재산 손실의 위험성 유형의 항목 변수 간 연구가설 검증 결과

요인	연구가설		검증 결과
정보 입력, 탈취	가설 31	시스템 접근 제어망 침범은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.	채택
	가설 32	비인가 시스템 접근 허용은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.	채택
	가설 33	악성코드, 바이러스 감염 등으로 시스템 오류는 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.	채택
	가설 34	데이터 손실 방지 시스템 취약은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.	채택
	가설 35	허용되지 않은 정보 수집 및 이용은 정보 입력, 탈취에 정(+)적 영향이 있을 것이다.	기각
기계 결합 오작동	가설 36	센서 모니터링 실패는 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	채택
	가설 37	다양한 상황에 의한 충돌로 시설물 파손은 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	채택
	가설 38	모터, 유압 등 구동부 문제는 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	채택
	가설 39	정기검사 미 점검 등 정비 불량은 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	채택
	가설 40	감속기 제어의 문제는 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	기각
	가설 41	제어기 오류는 기계 결합 오작동에 정(+)적 영향이 있을 것이다.	채택
잘못된 의사 결정	가설 42	유형의 재물 훼손은 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 43	인식 지능에 대한 오류는 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 44	창작물 무단 복제는 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 45	하자 상품 추천은 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 46	안전거리 계산 오류는 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 47	알고리즘의 최적화 성능 부족은 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	채택
	가설 48	사물 인식 판단 지능 저하는 잘못된 의사 결정에 정(+)적 영향이 있을 것이다.	기각

연구가설 31~35의 다중 회귀분석한 결과, 시스템 접근 제어망 침범·비인가 시스템 접근 허용·악성코드, 바이러스 감염 등으로 시스템 오류·데이터 손실 방지 시스템 취약 독립변수는 정보 입력, 탈취에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 허용되지 않은 정보 수집 및 이용 지표가 포함돼 있었다.

하지만, 정보 입력, 탈취 항목과 독립변수 간의 다중 회귀분석한 결과, 허용되지 않은 정보 수집 및 이용 측정지표는 최종 제거되었다.

연구가설 36~41의 다중 회귀 분석한 결과, 센서 모니터링 실패·다양한 상황에 의한 충돌로 시설물 파손·모터, 유압 등 구동부 문제·정기 검사 미점검 등 정비 불량·제어기 오류 독립변수는 기계 결함 오작동에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 감속기 제어의 문제 지표가 포함돼 있었다.

하지만, 기계 결함 오작동 항목과 독립변수 간의 다중 회귀분석한 결과, 감속기 제어의 문제 측정지표는 최종 제거되었다.

연구가설 42~48의 다중 회귀분석한 결과, 유형의 재물 훼손·인식 지능에 대한 오류 및 창작물 무단 복제·하자 상품 추천·안전거리 계산 오류·알고리즘의 최적화 성능 부족 독립변수는 잘못된 의사결정에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해 도출된 연구가설에는 사물 인식 판단 지능 저하 지표가 포함돼 있었다.

하지만, 잘못된 의사결정 항목과 독립변수 간의 다중 회귀분석한 결과, 사물 인식 판단 지능 저하 측정지표는 최종 제거되었다.

사회적 위험성 유형의 항목 변수 간 연구가설 검증 결과는 [표 3-56]과 같이 정리하였다.

[표 3-56] 사회적 위험성 유형의 항목 변수 간 연구가설 검증 결과

요인	연구가설		검증 결과
데이터 문제	가설 49	데이터 유출은 데이터 문제에 정(+)적 영향이 있을 것이다.	채택
	가설 50	개인 등 정보 무작위 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.	채택
	가설 51	부적절한 학습 데이터 수집은 데이터 문제에 정(+)적 영향이 있을 것이다.	채택
	가설 52	습득한 정보를 권한 없는 자에게 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.	기각
	가설 53	허위 정보 제공은 데이터 문제에 정(+)적 영향이 있을 것이다.	채택
법규 판단 오류	가설 54	법률, 규칙 혼동은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	채택
	가설 55	인간이 의도하지 않은 행위로 혼란유발은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	채택
	가설 56	차선, 신호 등 인식 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.	채택
	가설 57	법규 최신화 업데이트 오류는 법규 판단 오류에 정(+)적 영향이 있을 것이다.	채택
	가설 58	허용되지 않은 권한의 오인 판단은 법규 판단 오류에 정(+)적 영향이 있을 것이다.	기각
도로상 작동 중지	가설 59	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	채택
	가설 60	통신 이상 등 장애는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	채택
	가설 61	보행자 통행 방해는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	채택
	가설 62	도로매칭 알고리즘 오류는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	채택
	가설 63	주변 환경 변화에 대한 반응 속도저하는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	기각
	가설 64	이동 속도 제어나 조절 실패로 운행 정지는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	기각
	가설 65	데이터 업데이트 오류는 도로상 작동 중지에 정(+)적 영향이 있을 것이다.	채택

연구가설 49~53의 다중 회귀분석한 결과, 데이터 유출 및 개인 등 정보 무작위 수집·부적절한 학습 데이터 수집·허위 정보 제공 독립변수는 데이터 문제에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해서 도출된 연구가설에는 습득한 정보를 권한 없는 자에게 제공 지표가 포함돼 있었다.

하지만, 데이터 문제 항목과 독립변수 간의 다중 회귀분석한 결과, 습득한 정보를 권한 없는 자에게 제공 측정지표는 최종 제거되었다.

연구가설 54~58의 다중 회귀분석 결과, 법률, 규칙 혼동·인간이 의도하지 않은 행위로 혼란유발·차선, 신호 등 인식 오류·법규 최신화 업데이트 오류 독립변수는 법규 판단 오류에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해서 도출된 연구가설에는 허용되지 않은 권한의 오인 판단 지표가 포함돼 있었다.

하지만, 법규 판단 오류 항목과 독립변수 간의 다중 회귀분석한 결과, 허용되지 않은 권한의 오인 판단 측정지표는 최종 제거되었다.

연구가설 59~65의 다중 회귀분석 결과, 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지 및 통신 이상 등 장애·보행자 통행 방해·도로 매칭 알고리즘 오류·데이터 업데이트 오류 독립변수는 도로상 작동 중지에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

전문가 인터뷰를 통해서 도출된 연구가설에는 주변 환경 변화에 대한 반응 속도 저하·이동 속도 제어나 조절 실패로 운행 정지 측정지표가 포함돼 있었다.

하지만, 도로상 작동 중지 항목과 독립변수 간의 다중 회귀분석 결과, 주변 환경 변화에 대한 반응 속도저하·이동 속도 제어나 조절 실패로 운행 정지 측정지표는 최종 제거되었다.

인공지능 로봇의 4개 위험성 유형별 항목 간 연구가설 검증 결과는 [표 3-57]과 같이 정리하였다.

[표 3-57] 위험성 유형별 항목 간 연구가설 검증 결과

요인	연구가설		검증 결과
신체에 대한 물리적 위험성	가설 66	인공지능 로봇의 운행, 작업 중 작동 이상은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 67	인공지능 로봇의 인간을 해칠 판단은 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이다.	채택
인간 권리에 대한 위험성	가설 68	인공지능 로봇의 인격권 침해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 69	인공지능 로봇의 자유의사 방해는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 70	인공지능 로봇의 선택적 서비스나 정보 제공은 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이다.	채택
재산 손실의 위험성	가설 71	인공지능 로봇의 정보 입력, 탈취는 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 72	인공지능 로봇의 기계 결합 오작동은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 73	인공지능 로봇의 잘못된 의사 결정은 재산 손실의 위험성에 정(+)적 영향이 있을 것이다.	채택
사회적 위험성	가설 74	인공지능 로봇의 데이터 문제는 사회적 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 75	인공지능 로봇의 법규 판단 오류는 사회적 위험성에 정(+)적 영향이 있을 것이다.	채택
	가설 76	인공지능 로봇의 도로상 작동 중지는 사회적 위험성에 정(+)적 영향이 있을 것이다.	채택

신체에 대한 물리적 위험성 연구가설 66~67을 다중 회귀 기법으로 분석한 결과, 운행, 작업 중 작동 이상 독립변수 및 인간을 해칠 판단 독립변수는 신체에 대한 물리적 위험성에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

인간 권리에 대한 위험성의 연구가설 68~70을 다중 회귀 분석한 결과, 인격권 침해 및 자유의사 방해·선택적 서비스나 정보 제공 독립변수는 인간의 권리에 대한 위험성에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.


재산 손실 위험성의 연구가설 71~73을 다중 회귀분석한 결과, 정보 입력, 탈취·기계 결함 오작동·잘못된 의사 결정 독립변수는 재산 손실 위험성에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

사회적 위험성의 연구가설 74~76을 다중 회귀분석한 결과, 데이터 문제와 법규 판단 오류·도로상 작동 중지 독립변수는 사회적 위험성에 정(+)적 영향이 있을 것이라는 가설은 성립하였다.

2. 검증 모형 제시

탐색적 요인분석·신뢰도 분석 결과를 토대로 변수를 계산하고 상관관계를 분석하였으며, 항목과 측정지표 간 다중 회귀분석 및 항목과 유형 간 다중 회귀분석을 하였다. 연구가설 검증 결과, 인공지능 로봇의 위험성은 신체에 대한 물리적 위험성·인간 권리에 대한 위험성·재산 손실의 위험성·사회적 위험성 유형으로 분류되었다.

연구가설 검증을 통한 신체에 대한 물리적 위험성 측정 모형은 <그림 3-16>과 같다.



<그림 3-16> 신체에 대한 물리적 위험성 측정 모형

신체에 대한 물리적 위협성에는 운행 작업 중 작동 이상 및 인간을 해칠 판단의 2개 항목이 제시되었다.

운행 작업 중 작동 이상 항목에는 센서 및 인식 오류·기체 성능 저하·운동 지능 제어 실패·통신 장애 등 사고 위험 감지 지연·프로그램 오류로 인한 오작동·모션 제어 시스템 성능 저하 측정지표들이 제시되었다.

인간을 해칠 판단 항목에는 의도 파악 인식 오류·협동 작업 중, 규칙 판단 지능의 오류·학습량 부족으로 맞지 않는 의학적 자료 제공·프로그램의 판단 오류로 사고 희생자 선택 착오·장애물 인식 오류·라벨링 오류로 인한 잘못된 정보 제공 측정지표들이 제시되었다.


인간 권리에 대한 위협성에는 인격권 침해·자유의사 방해·선택적 서비스나 정보 제공의 3개 항목이 제시되었다.

인격권 침해 항목에는 감정 피드백 오류·명령어 등 음성을 잘못 인식·멀티 모달 리터 오류·도덕성 검증이 되지 않은 학습 데이터 사용· 측정지표들이 제시되었다.

자유의사 방해 항목에는 여론 형성 조작·의사 결정을 특정 방향으로 유도·필터링 오류로 의사 표현의 자율성 침해·중요한 결정을 위한 관리자의 개입 차단 측정지표들이 제시되었다.

선택적 서비스, 정보제공에는 학습 데이터 오류로 인해 편향된 학습 데이터로 인한 차별적 정보 제공·잘못된 언어 사용·시나리오 설계 문제로 부적절한 콘텐츠 제공·시스템 공격 등으로 개인정보의 침해나 유출 측정지표들이 제시되었다.


연구가설 검증을 통한 인간 권리에 대한 위협성 측정 모형은 <그림 3-17>과 같이 나타냈다.



<그림 3-17> 인간 권리에 대한 위험성 측정 모형

재산 손실의 위험성에는 정보 입력, 탈취·기계 결함 오작동·잘못된 의사 결정의 3개 항목이 제시되었다. 정보 입력, 탈취 항목에는 비인가 시스템 접근 허용·시스템 접근 제어망 침범·데이터 손실 방지 시스템 취약·악성코드, 바이러스 감염 등으로 시스템 오류 측정지표들이 제시되었다. 기계 결함 오작동 항목에는 다양한 상황에 의한 충돌로 시설물 파손·센서 모니터링 실패·정기 검사 미점검 등 정비 불량·모터,


유압 등 구동부 문제·제어기 오류 측정지표들이 제시되었다. 잘못된 의사 결정 항목에는 인식 지능에 대한 오류·유형의 재물 훼손·창작물 무단 복제·안전거리 계산 오류·하자 상품 추천·알고리즘의 최적화 성능 부족 측정지표들이 제시되었다. 연구가설 검증을 통한 재산 손실의 위험성 측정 모형은 <그림 3-18>과 같이 나타났다.



<그림 3-18> 재산 손실의 위험성 측정 모형

사회적 위험성에는 데이터 문제·법규 판단 오류·도로상 작동 중지 항목이 도출되었고, 데이터 문제 항목은 개인 등 정보 무작위 수집·데이터 유출·허위 정보 제공·부적절한 학습 데이터 수집 측정지표가 제시되었다. 법규 판단 오류 항목에는 인간이 의도하지 않은 행위로 혼란유발·법규 최신화 업데이트 오류·법률, 규칙 혼동·차선, 신호 등 인식 오류·측정지표들이 제시되었다. 도로상 작동 중지 항목에는 통신 이상 등 장애·관리 부실 등 연료 부족으로 정상 운행 중 작동 정지·도로 매칭 알고리즘 오류·데이터 업데이트 오류·보행자 통행 방해 측정지표들이 제시되었다.

연구가설 검증을 통한 사회적 위험성 측정 모형은 <그림 3-19>와 같다.



<그림 3-18> 사회적 위험성 측정 모형

제4장 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구

제1절 전문가 인터뷰

인공지능 로봇의 위험성 측정지표를 국가 정책이나 제도로 활용하기 위해서는 유럽·미국 등에서 인정하는 인공지능 윤리 가이드라인을 통해 검증할 필요가 있다.

인공지능이 일으킬 수 있는 다양한 문제들을 미리 파악하고 대비함으로써 인공지능이 안전하게 이용될 수 있도록 하는 것을 목표로 기준을 정하는 것을 인공지능 윤리라고 한다(김중세, 2020).

인공지능 로봇의 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위해 전문가 인터뷰를 하였으며, 인공지능 개발자·인공지능 윤리·교육학자 등 인공지능 윤리원칙에 대한 이해 관계자를 대상으로 한 델파이 설문조사 방법을 선정하였다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 전문가 인터뷰 참여자 정보는 [표 4-1]과 같이 정리하였다.

[표 4-1] 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 전문가 인터뷰 참여자 정보

구분	성별	연령	직업군	경력
1	남	40대	인공지능 개발자	15년
2	남	50대	인공지능 윤리 및 교육	27년
3	남	50대	인공지능 윤리학자	33년
4	여	40대	인공지능, 소프트웨어 교육	15년
5	남	30대	공공분야	7년

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성에 관한 연구 인터뷰에 참여한 전문가들은 총 5명이었으며, 연령별로 30대 1명, 40대는 2명, 50대가 2명으로 나타났다. 직업군은 인공지능 개발자·인공지능 윤리·교육·인공지능 윤리학자·인공지능 및 소프트웨어 교육 분야·공공분야 종사자로 나타났으며, 해당 분야 직업 경력은 7년~33년으로 나타났다.

인공지능 로봇의 위험성 유형별 측정지표와 윤리원칙이라는 전문 분야에 대한 충분한 논의가 이루어지도록 전문가 인터뷰는 3회에 걸쳐 진행했다. 일부는 대면하였고, 일부는 이메일 온라인 방식을 활용하여 진행하였다. 1~2회에는 유형별 측정지표와 관계있는 인공지능 윤리원칙 도출을 위한 인터뷰로 진행하였고, 3회에서는 델파이 설문조사 방법 및 설문 적합 대상자 선정에 대한 인터뷰로 진행하였다.

전문가들은 인공지능 로봇의 위험성 유형이 소순주, 안성진(2022)의 인격권·재산 보호를 위한 표준화된 인공지능 윤리원칙과 관련 있다며, 범용적인 활용을 위해 이 연구와의 인공지능 윤리원칙 관계성 검증을 하는 것이 좋겠다는 일치된 의견이었다.

인공지능 윤리원칙에는 투명성 원칙, 책무성 원칙, 공정성 원칙, 통제성 원칙, 안전성 원칙이 있는데, 위험성 측정지표들은 모두 인공지능 윤리원칙과 모두 관련이 있을 수밖에 없다며, 좀 더 세밀하게 연관된 지표를 찾는 것이 필요하다는 의견이었다.

전문가들은 소순주, 안성진(2022)이 제시한 인공지능 윤리원칙의 구성요소 86개에서 연관된 지표를 하나씩 검토하는 의견이 제시되었고, 모두 동의하여 가장 관련 높은 윤리 지표를 도출하고자 심층 논의를 하였다. 전문가들은 인공지능 윤리원칙 구성요소와 인공지능 로봇의 위험성 측정지표 간의 관계성 검증이 향후 인공지능 로봇의 위험성 측정지표의 활용성을 높여줄 것이라 기대하는 의견이었다.

개인정보 관련 측정지표는 인공지능 이용자와 제3자의 사생활 안전과 개인정보 보호·통신 비밀이 포함된 프라이버시가 침해되지 않게 해야 한다는 안전성 원칙 중, 프라이버시 보호 구성요소와 연결하였다. 위험성 유형별 52개의 지표가 어떤 윤리 구성요소에 해당하는지 도출한 자료를 정리하여 델파이 설문조사를 진행하였다.

제2절 델파이 설문조사 및 통계 분석

1. 인구 통계학적 특성

전문가 인터뷰를 통해 델파이 설문조사 연구 기법과 인공지능 윤리원칙에 대한 개념이 정립돼 있는 이해관계자가 델파이 설문조사 참여 대상으로 선정되었다.

델파이 설문조사는 2023년 9월 10일부터 9월 22일까지 진행하였고, 온라인 방식으로 실시하였으며, 델파이 설문조사에는 총 14명이 참여한 것으로 나타났다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성을 검증하기 위한 델파이 설문조사에 참여한 인구 통계학적 특성은 [표 4-2]와 같이 정리하였다.

[표 4-2] 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 델파이 설문조사에 참여한 인구 통계학적 특성

구 분		빈도 수(명)	구성 비율(%)	누적 비율(%)
성별	남	11	79.6	79.6
	여	3	21.4	100.0
	소계	14	100.0	100.0
연령	30세 ~ 39세	3	21.4	21.4
	40세 ~ 49세	7	50.0	71.4
	50세 ~ 59세	4	28.6	100.0
	소계	14	100.0	100.0
최종 학력	학사	5	35.7	35.7
	석사	6	42.9	78.6
	박사	3	21.4	100.0
	소계	14	100.0	100.0

직업	분류	소프트웨어 분야	5	35.7	35.7
		인공지능 개발	2	14.3	50.0
		인공지능 교육	1	7.1	57.1
		인공지능 윤리	3	21.4	78.6
		인공지능 정책	2	14.3	92.9
		정보통신 분야	1	7.1	100.0
		소계	14	100.0	100.0
	경력	5년 ~ 10년	4	28.6	28.6
		10년 ~ 15년	4	28.6	57.1
		15년 ~ 20년	1	7.1	64.3
		20년 ~ 25년	2	14.3	78.6
		25년 이상	3	21.4	100.0
		소계	14	100.0	100.0

텔파이 설문조사 참여자들은 남성 11명 및 여성 3명이 참여한 것으로 나타나 남성 참여율이 79.6%로 더 높은 것으로 나타났다. 30대 3명·40대 7명·50대 4명으로 50대가 50.0%로 나타났으며, 최종 학력 사항은 학사 5명·석사 6명·박사 3명으로 나타났다.

직업은 소프트웨어 분야 5명, 인공지능 개발 분야 2명, 인공지능 교육 분야 1명, 인공지능 윤리 분야 3명, 인공지능 정책 분야 2명, 정보통신 분야 종사자 1명이 참여한 것으로 나타났다. 직업 경력은 5~10년 4명, 10~15년 4명, 15~20년 1명, 20~25년 2명, 25년 이상 근무자도 3명으로 나타났다.

최근 인공지능 이슈로 인한 윤리에 대한 관심도가 높아짐에 따라 텔파이 설문조사 참여자들은 주로 인공지능 관련 분야 종사자들이었으며, 인공지능 윤리원칙에 대한 개념이 정립돼 있는 이해관계자들은 석·박사가 전체의 64.3%로 고학력자 비율이 높은 것을 알 수 있었다.

2. 측정지표와 윤리원칙 관계성 델파이 설문조사 통계 분석 결과

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 신체에 대한 물리적 위험성 측정지표의 델파이 설문조사 분석 결과는 [표 4-3]과 같다.

[표 4-3] 신체에 대한 물리적 위험성 측정지표의 델파이 설문조사 분석 결과

측정지표	윤리원칙(구성요소)	평균	표준편차	CVR 값	비고
센서 및 인식 오류	안전성 원칙(견고성)	4.36	.610	.857	선정
운동 지능 제어 실패	통제성 원칙(제어가능성)	4.43	.728	.714	선정
기체 성능 저하	안전성 원칙(견고성)	4.36	.610	.857	선정
프로그램 오류로 인한 오작동	통제성 원칙(제어가능성)	4.14	1.059	.714	선정
통신 장애 등 사고 위험 감지 지연	통제성 원칙(제어가능성)	4.36	.895	.714	선정
모션 제어 시스템 성능 저하	안전성 원칙(견고성)	4.21	.558	.857	선정
의도 파악 인식 오류	투명성 원칙(설명 가능성)	4.43	.623	.857	선정
협동 작업 중, 규칙 판단 지능의 오류	투명성 원칙(설명 가능성)	4.21	.674	.714	선정
프로그램의 판단 오류로 사고 희생자 선택 착오	책임성 원칙(준법성)	4.36	.610	.857	선정
학습량 부족으로 맞지 않는 의학적 자료 제공	안전성 원칙(상태 인식성)	4.21	.674	.714	선정
라벨링 오류로 인한 잘못된 정보 제공	투명성 원칙(추적 가능성)	4.36	.718	.714	선정
장애물 인식 오류	투명성 원칙(설명 가능성)	4.29	.589	.857	선정

신체에 대한 위험성 유형의 센서 및 인식 오류·기체 성능 저하·모션 제어 시스템 성능 저하 성능 저하 측정지표들이 인공지능 윤리 안전성 원칙 중에서 견고성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 모두 0.857로 나타났다.

운동 지능 제어 실패·프로그램 오류로 인한 오작동 및 통신 장애 등 사고 위험 감지 지연 측정지표가 통제성 원칙 중에서 제어 가능성 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 모두 0.714로 나타났다.

학습량 부족으로 맞지 않는 의학적 자료 제공 측정지표는 안전성 원칙 중에서 상태 인식성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다. 프로그램의 판단 오류로 사고 희생자 선택 착오 측정지표가 책무성 원칙 중에서 준법성 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다. 의도 파악 인식 오류·장애물 인식 오류 측정지표가 투명성 원칙 중에서 설명 가능성 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다.

협동 작업 중, 규칙 판단 지능의 오류 측정지표가 투명성 원칙 중, 설명 가능성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다. 라벨링 오류로 인한 잘못된 정보 제공 측정지표가 투명성 원칙 중, 추적 가능성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 델파이 설문조사 참여자는 14명이고 CVR값 기준 수치는 0.51(Lawshe, 1975) 인데, CVR 기준값보다 높게 나타난 신체에 대한 물리적 위험성 측정지표 12개는 모두 인공지능 윤리 측정지표와 관련이 높은 것을 알 수 있었다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 인간 권리에 대한 위험성 측정지표의 델파이 설문조사 분석 결과는 [표 4-4]와 같다.

[표 4-4] 인간 권리에 대한 위험성 측정지표의 델파이 설문조사 분석 결과

측정지표	윤리원칙(구성요소)	평균	표준편차	CVR 값	비고
명령어 등 음성을 잘못 인식	투명성 원칙(설명 가능성)	4.29	.589	.857	선정
감정 피드백 오류	안전성 원칙(가치정렬)	4.14	.639	.714	선정
도덕성 검증이 되지 않은 학습 데이터 사용	통제성 원칙(모니터링)	4.29	.700	.714	선정
멀티 모달리티 오류	투명성 원칙(식별 가능성)	4.21	.674	.714	선정
의사 결정을 특정 방향으로 유도	공정성 원칙(알고리즘 차별성)	4.43	.728	.714	선정
여론 형성 조작	공정성 원칙(알고리즘 차별성)	4.21	.773	.857	선정
중요한 결정을 위한 관리자의 개입 차단	안전성 원칙(견고성)	4.29	.795	.571	선정
필터링 오류로 의사표현의 자율성 침해	통제성 원칙(이용자 주도성)	4.14	.742	.571	선정
학습 데이터 오류로 인해 잘못된 언어 사용	안전성 원칙(상태 인식성)	4.07	.884	.571	선정
편향된 학습 데이터로 인한 차별적 정보 제공	공정성 원칙(데이터 편향성)	4.14	.990	.714	선정
시스템 공격 등으로 개인정보의 침해나 유출	안전성 원칙(프라이버시 보호)	4.29	.700	.714	선정
시나리오 설계 문제로 부적절한 콘텐츠 제공	투명성 원칙(추적 가능성)	4.07	.703	.571	선정

명령어 등 음성을 잘못 인식 측정지표가 투명성 원칙 중, 설명 가능성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다. 감정 피드백 오류 측정지표가 안전성 원칙 중, 가치정렬 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

도덕성 검증이 되지 않은 학습 데이터 사용 측정지표가 통제성 원칙 중, 모니터링 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

멀티 모달리티 오류 측정지표가 투명성 원칙 중, 식별 가능성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

의사 결정을 특정 방향으로 유도 측정지표가 공정성 원칙 중, 알고리즘 차별성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다. 여론 형성 조장 측정지표가 공정성 원칙 중에서 알고리즘 차별성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다. 중요한 결정을 위한 관리자의 개입 차단 측정지표가 안전성 원칙 중, 견고성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다. 필터링 오류로 의사 표현의 자율성 침해 지표가 통제성 원칙 중에서 이용자 주도성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다.

학습 데이터 오류로 인해 잘못된 언어 사용 측정지표가 안전성 원칙 중, 상태 인식성 요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.571로 나타났다.

편향된 학습 데이터로 인한 차별적 정보 제공 측정지표가 공정성 원칙 중, 데이터 편향성 요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.714로 나타났다.

시스템 공격 등으로 개인정보의 침해나 유출 측정지표가 안전성 원칙 중에서, 프라이버시 보호 구성요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.714로 나타났다. 시나리오 설계 문제로 부적절한 콘텐츠 제공 측정지표가 투명성 원칙 중에서 추적 가능성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.571로 나타났다.

CVR값 기준 수치인 0.51보다 높게 나타난 인간 권리에 대한 위험성 측정지표 12개는 모두 인공지능 윤리 측정지표와 관련이 높은 것을 알 수 있었다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 재산 손실의 위험성 측정지표의 델파이 설문조사 분석 결과는 [표 4-5]와 같다.

[표 4-5] 재산 손실의 위험성 측정지표의 델파이 설문조사 분석 결과

측정지표	윤리원칙(구성요소)	평균	표준편차	CVR 값	비고
시스템 접근 제어망 침범	안전성 원칙(보안성)	4.43	.821	.857	선정
비인가 시스템 접근 허용	안전성 원칙(상태 인식성)	4.14	.742	.571	선정
악성코드, 바이러스 감염 등으로 시스템 오류	안전성 원칙(상태 인식성)	4.21	.773	.571	선정
데이터 손실 방지 시스템 취약	안전성 원칙(견고성)	4.14	.742	.571	선정
센서 모니터링 실패	통제성 원칙(모니터링)	4.21	.674	.714	선정
다양한 상황에 의한 충돌로 시설물 파손	투명성 원칙(추적 가능성)	4.07	.703	.571	선정
모터, 유압 등 구동부 문제	통제성 원칙(제어가능성)	4.14	.915	.571	선정
정기검사 미 점검 등 정비 불량	책임성 원칙(준법성)	4.21	.674	.714	선정
제어기 오류	통제성 원칙(제어가능성)	4.43	.904	.714	선정
유형의 재물 훼손	책임성 원칙, 책임 식별성	4.21	.674	.714	선정
인식 지능에 대한 오류	통제성 원칙(제어가능성)	4.07	.961	.714	선정
창작물 무단 복제	통제성 원칙(제어가능성)	4.14	.833	.714	선정
하자 상품 추천	통제성 원칙(모니터링)	4.21	.860	.714	선정
안전거리 계산 오류	통제성 원칙(제어가능성)	4.14	.833	.714	선정
알고리즘의 최적화 성능 부족	책임성 원칙(이용자 책임성)	4.29	.589	.857	선정

데이터 손실 방지 시스템 취약 측정지표가 안전성 원칙 중, 견고성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다. 시스템 접근 제어망 침범 측정지표가 안전성 원칙 중, 보안성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다.

비인가 시스템 접근 허용·악성코드, 바이러스 감염 등으로 시스템 오류 측정지표가 안전성 원칙 중, 상태 인식성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 모두 0.571로 나타났다. 알고리즘의 최적화 성능 부족 측정지표가 책무성 원칙 중, 이용자 책임성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다.

정기 검사 미점검 등 정비 불량 측정지표가 책무성 원칙 중, 준법성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다. 유형의 재물 훼손 측정지표가 책무성 원칙 중, 책임 식별성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.714로 나타났다.

센서 모니터링 실패·하자 상품 추천 측정지표가 통제성 원칙 중에서 모니터링 구성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다. 제어기 오류·인식 지능에 대한 오류·창작물 무단 복제·안전거리 계산 오류 측정지표가 통제성 원칙 중, 제어 가능성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

모터, 유압 등 구동부 문제 측정지표가 통제성 원칙 중, 제어 가능성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다. 다양한 상황에 의한 충돌로 시설물 파손 측정지표가 투명성 원칙 중에서 추적 가능성 구성요소에 해당하는지에 대한 관계성 설문조사 결과, CVR값이 0.571로 나타났다.

CVR값 기준 수치인 0.51보다 높게 나타난 재산 손실의 위험성 측정지표 15개는 모두 인공지능 윤리 측정지표와 관련이 높은 것을 알 수 있었다.

인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 사회적 위험성 측정지표의 델파이 설문조사 분석 결과는 [표 4-6]과 같다.

허위 정보 제공 측정지표가 공정성 원칙 중, 공공성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다. 인간이 의도하지 않은 행위로 혼란유발 측정지표가 안전성 원칙 중, 가치정렬 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다.

[표 4-6] 사회적 위험성 측정지표의 델파이 설문조사 분석 결과

측정지표	윤리원칙(구성요소)	평균	표준편차	CVR 값	비고
데이터 유출	책임성 원칙(준법성)	4.07	.799	.714	선정
개인 등 정보 무작위 수집	안전성 원칙(프라이버시 보호)	4.29	.795	.571	선정
부적절한 학습 데이터 수집	안전성 원칙(보안성)	4.21	.773	.571	선정
허위 정보 제공	공정성 원칙(공공성)	4.21	.773	.571	선정
법률, 규칙 혼동	통제성 원칙(제어가능성)	4.29	.795	.857	선정
인간이 의도하지 않은 행위로 혼란유발	안전성 원칙(가치정렬)	4.21	.939	.571	선정
차선, 신호 등 인식 오류	통제성 원칙(모니터링)	4.21	.558	.857	선정
법규 최신화 업데이트 오류	책임성 원칙(이용자 책임성)	4.21	.674	.714	선정
관리 부실 등 연료 부족으로 정상 운행 중 작동 정지	책임성 원칙(이용자 책임성)	4.29	.589	.857	선정
통신 이상 등 장애	안전성 원칙(견고성)	4.14	.915	.571	선정
보행자 통행 방해	통제성 원칙(제어가능성)	4.14	.990	.714	선정
도로매칭 알고리즘 오류	통제성 원칙(모니터링)	4.36	.610	.857	선정
데이터 업데이트 오류	책임성 원칙(이용자 책임성)	4.29	.700	.714	선정

통신 이상 등 장애 측정지표가 안전성 원칙 중, 견고성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다.

부적절한 학습 데이터 수집 측정지표가 안전성 원칙 중, 보안성 구성요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다.

개인 등 정보 무작위 수집 측정지표가 안전성 원칙 중, 프라이버시 보호 구성요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.571로 나타났다. 법규 최신화 업데이트 오류 측정지표가 책무성 원칙 중, 이용자 책임성 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

관리 부실 등 연료 부족으로 정상 운행 중 작동 정지 측정지표가 책무성 원칙 중, 이용자 책임성 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다.

데이터 업데이트 오류 측정지표가 책무성 원칙 중에서, 이용자 책임성 구성요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

데이터 유출 측정지표가 책무성 원칙 중, 이용자 책임성 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

차선, 신호 등 인식 오류·도로매칭 알고리즘 오류 측정지표가 통제성 원칙 중, 모니터링 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다. 법률, 규칙 혼동 측정지표가 통제성 원칙 중, 제어 가능성 요소에 해당하는지 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.857로 나타났다.

보행자 통행 방해 측정지표가 통제성 원칙 중, 제어 가능성 요소에 해당하는지에 대한 관계성 설문조사 결과, 내용 타당도를 의미하는 CVR값이 0.714로 나타났다.

CVR값 기준 수치인 0.51보다 높게 나타난 사회적 위험성 측정지표 13개는 모두 인공지능 윤리 측정지표와 관련이 높은 것을 알 수 있었다.


제3절 측정지표와 인공지능 윤리원칙 관계성 연구 결과

텔파이 설문조사 결과, 인공지능 로봇의 위험성 유형별 측정지표 52개의 관련 있는 인공지능 윤리원칙 구성요소를 도출하였다. 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 설문조사 결과를 토대로 통계 분석을 통해 타당성이 검증되었다.

연구 결과, 신체에 대한 물리적 위험성 측정지표는 인공지능 안전성 원칙에서 견고성·상태 인식성 구성요소와의 관계성을 알 수 있었다. 책무성 원칙의 준법성, 통제성 원칙의 제어 가능성 구성요소와의 관계성을 알 수 있었다. 투명성 원칙의 설명 가능성·추적 가능성 구성요소와의 관계성을 알 수 있었다. 인간 권리에 대한 위험성 측정지표는 인공지능 공정성 원칙에서 데이터 편향성·알고리즘 편향성 구성요소와의 관계성을 알 수 있었고, 안전성 원칙의 가치정렬·견고성·상태 인식성·프라이버시 보호 구성요소와의 관계성을 알 수 있었다. 통제성 원칙에서 모니터링·이용자 주도성 구성요소와의 관계성을 알 수 있었고, 투명성 원칙의 설명 가능성·식별 가능성·추적 가능성 구성요소와의 관계성을 알 수 있었다. 재산 손실의 위험성 측정지표는 인공지능 안전성 원칙에서 견고성·보안성·상태 인식성 구성요소와의 관계성을 알 수 있었다. 책무성 원칙의 이용자 책임성·준법성·책임 식별성 구성요소와의 관계성을 알 수 있었다. 통제성 원칙의 모니터링·제어 가능성 구성요소와의 관계성을 알 수 있었고, 투명성 원칙에서 추적 가능성과 관계성을 알 수 있었다. 사회적 위험성 측정지표는 인공지능 공정성 원칙의 공공성 구성요소와의 관계, 안전성 원칙의 가치정렬·견고성·보안성·프라이버시 보호 요소와의 관계, 책무성 원칙의 이용자 책임성·준법성 요소와의 관계, 통제성 원칙의 모니터링·제어 가능성과 관계성을 알 수 있었다.


인공지능 로봇의 위험성 유형별 측정지표가 인공지능 기술 개발과 로봇 상용화에 필요한 점검이나 법·규제, 정책, 제도 등 여러 분야에서 범용적인 활용을 기대한다.

텔파이 설문조사·통계 검증 결과를 토대로 한 신체에 대한 물리적 위험성 측정 지표와 인공지능 윤리원칙 구성요소의 관계도는 <그림 4-1>과 같이 정리하였다.




<그림 4-1> 신체에 대한 물리적 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계

텔파이 설문조사·통계 검증 결과를 토대로 인간 권리에 대한 위험성 측정지표와 인공지능 윤리원칙 구성요소의 관계도는 <그림 4-2>와 같이 정리하였다.




<그림 4-2> 인간 권리에 대한 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계

텔파이 설문조사·통계 검증 결과를 토대로 재산 손실의 위험성 측정지표와 인공지능 윤리원칙 구성요소의 관계도는 <그림 4-3>과 같이 정리하였다.



<그림 4-3> 재산 손실의 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계

텔파이 설문조사·통계 검증 결과를 토대로 사회적 위험성 측정지표와 인공지능 윤리원칙 구성요소의 관계도는 <그림 4-4>와 같이 정리하였다.



<그림 4-4> 사회적 위험성 측정지표와 인공지능 윤리원칙 구성요소 관계

제5장 결론

개인용 컴퓨터가 1가구에 1대씩 보급되면서 컴퓨터 시스템이 발전해 온 것처럼 인공지능 로봇은 인간의 사회, 일상생활 어디에나 있는 존재가 될 것이며, 인간의 삶을 윤택하게 하려는 시도로 인공지능 로봇 산업은 계속해서 발전해 나갈 것이다.

이러한 인공지능 로봇의 엄청난 기술만큼이나 예측할 수 없는 사회적 문제점이 논란이 되고 있으므로, 기술의 발전과 함께 안전을 고려한 활발한 논의가 필요하다.

인공지능 로봇 기술의 발전이 앞으로 인간 사회와 일상생활 등에 어떠한 위험이 생길지 또는 어떠한 영향을 가져오게 될 것인지를 정확하게 예측하기란 어렵다.

따라서, 고성능 인공지능 로봇의 등장으로 예측되는 문제점이나 위험성을 기술적·윤리적으로 점검할 방안에 대해 검토하여 규제·가이드라인 등을 마련할 필요가 있다.

이러한 이유로 국내외에서도 인공지능 로봇과 관련된 선행연구가 많이 있지만, 인공지능 로봇의 책임·법·규범적 고찰이나 교육·서비스·돌봄 등의 인공지능 기술을 활용하는 방안에 관한 연구가 대부분이었다. 연구자가 아는 한, 국내외 선행연구 중 인공지능 로봇의 위험성에 대해 기술적인 문제와 윤리적 문제점을 모두 점검할 수 있는 측정지표에 관한 연구는 없었다.

인공지능 로봇은 인간의 지능처럼 스스로 학습하고 상황을 판단하는 인공지능 시스템을 탑재한 자율동작 기능을 가진 기계 장치로 인공지능의 잘못된 판단은 윤리 지표로 점검하고, 로봇의 문제는 기계 공학적 관점에서 기술 지표로 점검해야 한다.

인공지능 로봇이 해킹 등에 악용될 수 없게 설계해야 하므로 보안 매커니즘이 요구되며, 이외에 발생할 수 있는 윤리적 문제를 추출하여 지표화할 필요가 있다.

이러한 이유로 이 논문에서는 인공지능 로봇 관련 기술적·윤리적 문제를 모두 점검할 수 있고, 범용적인 활용성이 있는 윤리 측정지표 개발 연구를 하였다.

전문가 그룹의 미래 예측으로 의견 합의를 도출하는 델파이 기법을 활용하였고, 인공지능 로봇과 윤리에 대한 개념이 정립돼 있는 인공지능 개발자, 로봇 연구원, 보안·윤리·교육 분야 종사자 등이 전문가 인터뷰와 델파이 설문조사에 참여하였다.

1차 델파이 설문조사에는 38명이 참여하였는데, 경력이 짧거나 부실한 응답자는 전문가 그룹에서 제외하고 최종 30명의 응답을 통계 분석하였다. 2차 델파이 설문조사는 1차 델파이 설문조사와 동일한 전문가가 참여하였다. 1·2차 델파이 결과를 통계 분석한 결과, 내용 타당도를 의미하는 CVR 기준값이 0.333을 상회하는 수치로 나타난 4개 유형·11개 항목·37개 측정지표가 도출되었다. 유형 및 항목별 측정지표의 신뢰도 분석 결과, 0.613~0.925의 수치로 나타나 타당도 및 신뢰도를 검증하였다.

인공지능 로봇의 위험성은 인간의 생명 윤리에 관한 연구이므로 성균관대학교 기관 IRB에서 연구 승인(SKKU 2023-07-026)을 받았다. 전문가 11명을 대상으로 인터뷰한 결과, 추가 28개 측정지표를 도출하였고, 측정지표를 조작적 정의하였다.

인공지능 로봇이 여러 분야에 도입될 수 있는 것을 고려하여 전문가 인터뷰에서 선정된 농업·제조·기술·생산·서비스 분야 종사자 및 공직·ICT 연구직 등 직업의 이해관계자들을 대상으로 현장성 검증을 위한 설문조사를 진행하였다. 총 339명이 설문에 응답하였으나, 개인 정보 수집 및 설문 응답에 대한 의견 제공에 동의하지 않은 11명을 제외한 후, 최종 328명의 설문조사 결과로 통계 분석하였다. SPSS를 활용하여 KMO 모형적합도 통계 검증한 결과 모든 유형의 측도가 0.944~0.952로 나타났고, 모든 유형의 유의확률은 0.000으로 나타나 탐색적 요인분석을 실시하였다.

탐색적 요인분석 결과, 모든 변수에서 요인 적재량은 0.5 이상, 공통성이 0.6 이상으로 나타났다. 신뢰도 또한 0.888~0.949의 높은 수치로 나타났다. 탐색적 요인분석 및 신뢰도 분석 결과 요인들이 유형별로 2, 3개씩 묶여 총 11개 항목이 도출되었는데, 델파이 설문조사와 동일한 결과가 나옴을 알 수 있었다. 인공지능 로봇의 위험성을 유형별로 나누고 항목별 측정지표가 정적인 영향을 미치는지 검증하고자 다중 회귀 분석을 하였으며, 다중 회귀분석을 위한 연구가설을 설정하였다. 통계 분석 결과로

도출된 변수들의 정제 과정을 위해 SPSS를 활용하여 상관관계 분석을 통한 변수계산을 하였다. 4개 위험성 유형별 항목 간 다중 회귀분석 결과, 변수의 수정된 결정계수인 수정된 R^2 이 0.973~0.990으로 나타나 회귀선의 설명력은 좋은 것으로 나타났다, Durbin-Watson 값도 1.833~1.970으로 2에 가까워 잔차의 독립성도 확립되었다.

모든 분산분석 F 통계량의 유의확률 p 값이 0.000의 수치로 유의하게 나타남에 따라 회귀식은 유의하다는 것이 검증되어, 연구가설이 채택되었다.

연구 결과, 인공지능 로봇의 위험성을 신체에 대한 물리적 위험성, 인간 권리에 대한 위험성, 재산 손실의 위험성, 사회적 위험성 4개 유형으로 분류하였다. 유형별 11개 항목 및 52개 측정지표를 개발하였으며, 이를 검증한 측정 모형을 제시하였다.

또한, 인공지능 로봇의 위험성 유형별 측정지표의 교육·개발·정책 등 범용적인 활용성을 위해 측정지표와 인공지능 윤리원칙 관계성에 대해 연구하였다.

인공지능 윤리원칙에 대한 개념이 정립된 인공지능 개발자·윤리학자·교육학자 등 이해 관계자들을 대상으로 전문가 인터뷰하였다. 전문가 인터뷰를 통해 위험성 유형별 52개 측정지표 각각과 가장 세밀하게 연관된 인공지능 투명성·책무성·공정성·통제성·안전성 원칙의 구성요소를 도출하였다. 델파이 설문조사에는 14명의 전문가 그룹이 참여하였다. 통계 분석 결과 모든 측정지표가 CVR 기준값 0.51을 상회하는 수치로 나타남에 따라, 52개 측정지표와 인공지능 윤리원칙 구성요소의 관계성이 검증되었다. 연구 결과, 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 구성요소의 관계도 검증 모형을 제시하였다.

인공지능 로봇의 위험성 유형별 측정지표 개발과 인공지능 윤리원칙 관계성 연구 결과를 정리하면 다음과 같다.

인공지능 로봇의 센서·인식 오류, 운동 지능 제어 실패와 프로그램 오류로 인한 오작동, 기체 및 모션 제어 시스템 성능 저하, 통신 장애 등 사고 위험 감지 지연 지표는 운행·작업 중 작동 이상을 측정하기 위해 개발되었다. 의도 파악 인식 오류와 학습량 부족으로 맞지 않는 의학적 자료 제공, 협동 작업 중 규칙 판단 지능 오류 및

프로그램 판단 오류로 사고 희생자 선택 착오, 장애물 인식 오류, 라벨링 오류로 인한 잘못된 정보 제공 지표는 인간을 해칠 판단을 하는지 측정하기 위해 개발되었다.

운행, 작업 중 작동 이상과 인간을 해칠 판단은 신체에 대한 물리적 위험성을 일으킬 수 있는 항목임을 검증하였다. 또한, 신체에 대한 물리적 위험성 측정지표는 인공지능 안전성 원칙의 견고성·상태 인식성, 책무성 원칙의 준법성, 통제성 원칙의 제어 가능성, 투명성 원칙의 설명 가능성·추적 가능성과 관계있음을 알 수 있었다.

인공지능 로봇이 감정 피드백 오류, 명령어 등 음성을 잘못 인식, 도덕성 검증이 되지 않은 학습 데이터 사용, 멀티 모달리티 오류 지표는 인격권을 침해하는지를 측정하기 위해 개발되었다. 여론 형성 조작·의사 결정을 특정 방향으로 유도·중요한 결정을 위한 관리자의 개입 차단·필터링 오류로 의사 표현의 자율성 침해 지표는 인간의 자유로운 의사결정을 방해하는지를 측정하기 위해 개발되었다.

인공지능 로봇의 편향된 학습 데이터 사용으로 인한 차별적 정보 제공 및 학습 데이터 오류로 잘못된 언어 사용, 시스템 공격 등 개인정보 침해나 유출·시나리오 설계 문제로 부적절한 콘텐츠 제공 지표는 선택적 서비스·정보를 제공하는지 측정하기 위해 개발되었다. 인격권 침해, 자유의사 방해, 선택적 서비스나 정보제공은 인간 권리에 대한 위험성을 일으킬 수 있는 항목임을 검증하였다. 인간 권리에 대한 위험성 측정지표는 인공지능 윤리원칙 중, 공정성 원칙의 데이터 편향성·알고리즘 편향성, 안전성 원칙의 가치정렬·견고성·상태 인식성·프라이버시 보호, 통제성 원칙의 모니터링·이용자 주도성, 투명성 원칙의 설명 가능성·식별 가능성·추적 가능성 구성 요소와 관계있음을 알 수 있었다.

인공지능 로봇이 시스템 접근 제어망 침범이나 악성코드, 바이러스 감염 등 시스템 오류, 비인가 시스템 접근 허용, 데이터 손실 방지 시스템 취약 지표는 정보 입력, 탈취의 문제가 생길 수 있는지를 측정하기 위해 개발되었다. 모터, 유압 등 구동부 문제·다양한 상황에 의한 충돌로 시설물 파손·센서 모니터링 실패·정기 검사 미점검 등 정비 불량·제어기 오류 측정지표는 기계 결함으로 인한 오작동을 측정하기 위해

개발되었다. 인공지능 로봇의 인식 지능에 대한 오류·유형의 재물 훼손·하자 상품 추천·창작물 무단 복제·알고리즘 최적화 성능 부족·안전거리 계산 오류 지표는 잘못된 의사 결정을 측정하기 위해 개발되었다. 정보 입력·탈취, 기계 결함 오작동, 잘못된 의사결정은 재산 손실의 위험성을 일으킬 수 있는 항목임을 검증하였다. 재산 손실 위험성 측정지표는 인공지능 윤리원칙 중에서 안전성 원칙의 견고성·보안성·상태 인식성, 책무성 원칙의 이용자 책임성·준법성·책임 식별성, 통제성 원칙의 모니터링·제어 가능성, 투명성 원칙의 추적 가능성과 관계가 있음을 알 수 있었다.

인공지능 로봇이 개인 등 정보 무작위 수집·데이터 유출·허위 정보 제공·부적절한 학습 데이터 수집 지표는 데이터 문제 측정을 위해 개발되었다. 법률, 규칙 혼동 및 법규 최신화 업데이트 오류·차선, 신호 등 인식 오류·인간이 의도하지 않은 행위로 혼란유발 지표는 법규 판단 오류 측정을 위해 개발되었다. 통신 이상 등 장애·관리 부실 등 연료 부족으로 정상 운행 중 작동 정지·도로매칭 알고리즘 오류·보행자 통행 방해·데이터 업데이트 오류 지표는 도로상 작동 중지 측정을 위해 개발되었다. 데이터 문제, 법규 판단 오류, 도로상 작동 중지는 사회적 위험성을 일으킬 수 있는 항목임을 검증하였다. 사회적 위험성의 측정지표는 인공지능 윤리원칙 중에서 공정성 원칙의 공공성, 안전성 원칙 가치정렬·견고성·보안성·프라이버시 보호·책무성 원칙 이용자 책임성·준법성, 통제성 원칙의 모니터링·제어 가능성과 관계있음을 알 수 있었다.

이 논문에서 개발한 인공지능 로봇의 위험성 유형별 측정지표는 그동안 국내외 관련 법, 제도, 정책이나 선행연구에는 없었던 인공지능 로봇 관련 위험성을 기술적 및 윤리적으로 측정할 수 있는 지표를 도출했다는 것에 연구의 큰 가치가 있다.

미래 예측 연구 기법을 통해 개발된 인공지능 로봇의 위험성 유형별 측정지표는 로보틱스 등 공학 분야에서 정확한 움직임 등을 평가할 지표 개발에도 활용할 수 있는 기반이 되는 연구의 초석일 뿐 아니라, 이외에도 인공지능 로봇과 관련된 법·제도 입안이나 기술 관련 정책, 교육 등 여러 분야에서 활용할 수 있을 것이다.

이러한 연구의 가치에도 다음과 같은 후속 연구의 필요성이 있다. 연구의 초기

단계인 전문가 인터뷰에서 중요하게 논의되었던 인공지능 로봇의 인간을 해칠 판단 중, 자살이나 자해를 권유하는 위험성 측정지표의 경우 1차 델파이 설문조사에서 전문가들 의견이 합의에 이르지 못하는 수치가 나옴에 따라 측정지표가 제거되었다.

하지만, 현실에서는 인간과 대화하던 인공지능의 자살·자해를 권유하는 발언으로 인해 인간이 극단적 선택을 하게 됨으로써 실제로 위험성을 초래할 수 있다는 것이 드러났다. 즉, 인공지능 로봇의 자살·자해를 권유하는 발언이 인간을 해칠 위험성을 측정하기 위한 지표로써 중요한 의미가 있다는 것이 확인되었으므로 후속 연구의 필요가 있다. 특히, 델파이 1차 설문에서 제거된 자의적 침해·의도적 폭력 등 인간 신체에 대한 직접적 위험은 향후 인공지능 로봇으로 인한 가장 위험한 문제가 될 것이므로 전문가들이 관심을 가지고 측정지표를 확장하는 연구가 지속돼야 할 것이다.

이 논문에서는 위험성 유형별로 한 개 항목이 한 개 측정지표에 미치는 영향에 대해 검증하였다. 예를 들면, 센서 오류가 생기면 인공지능 로봇 작동이 정지될 수 있고 작동이 정지되면 신체에 대한 물리적 위험성이 발생할 수 있음을 검증하였다.

하지만, 인공지능 로봇이 주행 중 센서 오류로 도로에서 정지한다면 신체에 대한 물리적 위험성 이외에도 재물을 파손하고 교통질서를 혼잡하게 하는 사회적 문제를 일으키는 등 여러 위험성을 동시에 초래할 수 있다. 또한, 로봇의 위험이 센서 또는 프로그램 때문에 발생했는지를 정확하게 판단하기가 어려우므로 개발된 측정지표를 토대로 향후 공학적 지표 연구의 필요성이 있다.

이 논문에서 개발된 인공지능 로봇의 위험성 유형별 측정지표가 여러 위험성에 대한 원인을 파악하는 데 도움 되고 관련 연구에도 활용되기를 기대한다. 최근 배달 로봇이 상용화되면서 인공지능 로봇의 운행 중 도로상 작동 중지로 인한 문제·교통 법규 미준수 등을 점검할 수 있는 측정지표의 가치와 중요성은 더욱 커지고 있다.

미래의 인공지능 로봇 관련 문제는 예측이 어려워 이를 점검할 측정지표 연구는 계속해서 확장 개발할 연구 영역이며, 인공지능 로봇의 위험성 측정지표가 인공지능 로봇 산업의 발전을 도모하면서 안전한 상용화에 널리 활용되기를 기대한다.

참 고 문 헌

- 강현구 (2021). 인공지능의 법적 정의와 인공지능 기술 발달에 따른 국가의 기본권 보호의무. 헌법재판연구, 8(2), 29-64.
- 계승균 (2022). 인공지능과 규범의 형성. 한국지식재산학회. 73. 199-232.
- 고인석 (2014). 로봇윤리의 기본 원칙: 로봇 존재론으로부터. 범한철학, 75, 401-426.
- 과학기술정보통신부 (2018). 지능정보사회 윤리 가이드라인 및 지능정보사회 윤리현장.
- 과학기술정보통신부 (2019). 관계부처 합동, 2030 국가 로드맵 미래 자동차 산업 발전 전략.
- 과학기술정보통신부, 한국과학기술기획평가원 (2019). 2019년 기술 영향평가 결과
소셜 로봇의 미래. (주)동진문화사. 서울.
- 과학기술정보통신부, 한국정보통신기술협회 (2023). 2023 신뢰할 수 있는 인공지능
개발 안내서 - 자율주행 분야. (주)진한엠앤비. 서울.
- 구본권 (2020). 로봇 시대, 인간의 일 - 인공지능 시대를 살아가야 할 이들을 위한
안내서 -. 어크로스, 서울.
- 국제인공지능윤리협회 IAAE (2020). EU 집행위원회, 신뢰할 수 있는 AI 윤리 가이드라인.
- 김병록 (2020). 인공지능의 헌법적 쟁점과 과제. 조선대학교 법학연구원, 법학논총,
27(2), 87-135.
- 김보경 (2022). 팬데믹 이후 다가올 미래 아동과 부모 삶의 질 향상을 위한 방향:
아동의 학습 및 인지 발달을 위한 인공지능 감성로봇 적용, 가정과 삶의 질
학회 학술발표대회 자료집, 2022(5), 65-70.
- 김승우 (2020). 자율주행차량과 AI 드론봇에 대한 해킹 공격 및 취약점 보안 연구.
국내박사학위논문 호서대학교 벤처대학원, 충청남도.
- 김승훈 (2022). 로봇-인간, 로봇-로봇, 로봇-장비-인간 간 협업을 위한 인공지능 기술.

- 대한전자공학회, 49(4), 17-24.
- 김일, 허정윤 (2022). 인간·인공지능 협업(Human-in-the-loop) 관점에서 서빙 로봇의 사용자 경험 주요 개선 방안 연구. 대한인간공학회, 학술대회논문집, 2022(10), 29-30.
- 김재완 (2020). 로봇수술로 인한 의료과오 민사책임에 있어 과실 판단의 문제. 아주대학교 법학연구소, 14(1), 27-56.
- 김정중, 고두열 (2023). 범용 작업 로봇 지능을 위한 AI 연구 동향. 한국통신학회지 (정보와통신), 40(5), 54-59.
- 김정하, 염영일 (2002). 로봇공학. (주)사이텍미디어. 서울.
- 김종세 (2020). 인공지능의 안전성과 인간 윤리에 대한 법 정책적 고찰. 법학연구, 20(1), 1-35.
- 김종호 (2018). 인공지능 로봇의 출현으로 인한 법적 논란에 관한 영역별 쟁점의 고찰. 법이론실무연구, 6(2), 225-263.
- 김주영 (2022). 법률용어로서의 “로봇(Robot)” 개념에 관한 일고찰 - 「지능형 로봇 개발 및 보급 촉진법」의 개선방안의 일환으로 -. 명지법학, 21(1), 51-76.
- 김진석 (2019). 강한 인공지능과 인간. (주)글항아리. 경기도 파주.
- 김태완, 최새솔, 연승준 (2020). ETRI AI 실행전략 7: AI로 인한 기술·사회적 역기능 방지. 전자통신동향분석, 35(7), 67-76.
- 김현우 (2022). 인공지능 로봇에 대한 법적 책임과 선결 과제에 관한 검토. 한국법학회, 9, 113-133.
- 김현주, 이준환 (2022). 전시 공간에서의 인간-로봇 상호작용에 대한 탐색적 연구. 한국HCI학회 학술대회, 개최지. 618-622.
- 김희성 (2020). 미국에서의 로봇 인공지능과 자동화로 인한 노동법적 문제. 한국비교노동법학회, 49, 127-163.
- 네이버 (2021). AI 윤리 준칙.

- 노대원 (2023). 소셜쓰는 로봇 - ChatGPT와 AI 생성 문학 -. 한국문예비평학회, 77, 127-162.
- 노상준, 김종원, 유연국, 이주순, 신성호, 이규빈 (2021). 로봇 산업에서의 인공지능 활용 현황 및 전망. 한국통신학회, 38(4), 39-44.
- 노한석, 이현성, 이경수 (2022). 도심 자율주행을 위한 라이다 정지 장애물 지도 기반 위치 보정 알고리즘. 자동차안전학회지, 14(2), 39-44.
- 당반 치엔, 트란 트링턴, 김종욱 (2016). 인지 에이전트 아키텍처인 Soar의 소셜 로봇 적용에 관한 연구. 한국지능시스템학회, 학술발표 논문집, 26(10), 145-146.
- 류요엘, 백남정, 전진우, 조규선 (2021). 배송 로봇의 보도 주행 허용을 위한 위험성 평가 모델을 활용한 안전 요구사항 개발에 관한 연구. 한국산학기술학회 논문지, 22(9), 10-18.
- 류지웅 (2017). 인공지능 (AI) 로봇의 법적 문제에 관한 연구 - EU의 RoboLaw의 입법 동향을 중심으로 -. 토지공법연구, 78, 1-26.
- 만동우, 김현식, 권오순, 신창주 (2022). 해양로봇 성능평가에 관한 동향 분석 및 객관적 시험절차 구축에 관한 연구. 제어로봇시스템학회 논문지, 28(5), 468-476.
- 문건두, 김경재 (2023). 소셜 네트워크 분석과 토픽 모델링을 활용한 설명 가능 인공지능 연구 동향 분석. 한국정보기술응용학회, 30(1), 53-70.
- 박소희, 최대선 (2017). 인공지능 보안 이슈. 정보보호학회지, 27(3), 27-32.
- 박충식 (2018). 윤리적인 인공지능 로봇: 구성적 정보 철학 관점에서. 과학철학, 21(3), 39-65.
- 백형택, 전진우 (2017). 이동형 로봇의 대인 충돌 안전성 평가시스템 및 시험방법 개발. 제어로봇시스템학회 국내학술대회 논문집. 2017(5), 356-357.
- 변순용 (2018). 인공지능 로봇을 위한 윤리 가이드라인 연구, 인공지능 로봇 윤리의 4원칙을 중심으로. 한국윤리교육학회, 47, 233-252.
- 변순용, 송선영 (2013). 로봇 윤리 - 로봇의 윤리적 문제들-. 어문학사. 서울.

- 산업통상자원부 (2020). 관계부처 합동 로봇산업 선제적 규제 혁신 로드맵.
- 산업통상자원부 (2022). 관계부처 합동, 2022년 지능형 로봇 실행계획.
- 서일홍, 고동욱, 이진한 (2021). 생활 속에 들어온 인공지능 로봇. MIT Technology Review. 기술과 사회·인공지능·인사이트 컬럼.
- 선종수 (2020). 경찰의 인공지능 로봇 활용. 동아대학교 법학연구소, 89, 62-87.
- 소순주, 안성진 (2022). 인공지능 윤리원칙 기반의 인격권 및 재산보호를 위한 인공지능 윤리 측정지표에 관한 연구. 인터넷정보학회논문지, 23(3), 111-123.
- 송윤선 (2021). 인공지능과 로봇의 군사적 활용과 선행 과제. 3(2), 1-6.
- 송지준 (2021). 논문작성에 필요한 SPSS/AMOS 통계분석방법. 21세기사. 서울.
- 송현경, 안성진 (2023). AI 로봇의 위험성 예방을 위한 측정지표에 관한 연구. 인터넷정보학회 논문지, 24(3), 27-41.
- 송호영 (2021). 인공지능 로봇은 법인격을 가질 수 있는가. 저스티스, (184), 83-113.
- 스캐터랩 (2022). AI 챗봇 윤리 준칙.
- 신한나, 김태영 (2023). 초등학생 대상 ‘핑퐁로봇’을 활용한 인공지능 융합교육 수업안 개발. 한국컴퓨터교육학회 학술발표대회논문집, 27(2), 91-94.
- 신홍임 (2022). 로봇의 주도성에 대한 마음지각과 윤리적 의사결정. 사회과학연구, 33(1), 179-194.
- 심민석 (2020). 한국의 인공지능과 로봇에 관한 법제정비방안 연구. 경희법학연구소, 55(3), 138-181.
- 안정빈 (2022). 인공지능 로봇에 관한 형사책임 - 인공지능 형법에 의한 형사처별 가능성을 중심으로 -. 한국외국어대학교 법학연구소, 46(4), 63.
- 오병철 (2017). 인공지능 로봇에 의한 손해의 불법행위책임. 연세대학교 법학연구원 법학 연구, 27(4), 157-231.
- 웬델 윌러치, 콜린 알렌 (2014). 왜 로봇의 도덕인가. (주)메디치미디어. 서울.
- 유범상 (2013). 지능형 로봇의 이해와 활용. 도서출판 기한재. 경기도 파주.

- 윤 실 (2007). 로봇과 인공지능 이야기. 전파과학사. 서울.
- 윤석진 (2020). 영화 〈그녀(her)〉가 말하는 인공지능과 공감의 알레고리. 영상문화 콘텐츠연구, (19), 213-236.
- 이규호 (2020). 지능형로봇법 소고. 사법행정, 61(1), 46-52.
- 이덕진, 이마드, 도우끼올리드 (2022). 자율주행 배송로봇을 위한 인공지능 기법. 대한 기계학회 춘추학술대회, 5(12).
- 이동건 (2023). 인공지능 정보의 사용에 따른 개인 정보 보호에 관한 법적 연구 - 데이터 3법의 「동의권」 관련 분석을 중심으로 -. 홍익대학교 법학연구소, 홍익법학, 24(3), 61-101.
- 이보람 (2022). 인간형 인공지능 로봇 활용에 대한 유아 교사의 인식과 요구 분석. 한국인간발달학회, 29(3), 181-210.
- 이윤아, 윤상오 (2022). 인공지능 알고리즘이 유발하는 차별 방지 방안에 관한 연구. 한국거버넌스학회, 29(2), 175-202.
- 이인곤, 강철하. (2018). 인공지능 로봇의 형사법이론 체계에 관한 일고 : 범죄능력·형사책임능력을 중심으로. 법학연구, 18(3), 21-54.
- 이청호, 변순용, 김봉제, 김형주, 최현철, 김영걸, 김종욱 (2021). 가정용 헬스케어 AI 로봇의 개발자용 윤리체크리스트 개발에 관한 연구. 한국윤리학회, 1(132), 263-280.
- 이해원 (2023). EU AI 법안의 추진 경과 및 향후 전망. KISO 저널, (51), 34-37.
- 이혜원, 이자즈라우프, 이수범, 김홍수 (2022). 로봇의 작동 속도에 독립적인 고장 특성 추출 및 머신러닝 기법을 이용한 분류. 대한기계학회 춘추 학술대회 개최지, 101-101.
- 이희옥 (2023). 인공지능 챗봇의 편향 통제를 위한 윤리 가이드라인. 공법연구, 51(3), 715-744.
- 일본 내각부 (2019). 인간중심의 AI 사회 원칙안.

- 임대성 (2022). 인공지능 로봇의 불법행위책임, 인공지능 로봇 보유자의 과실과 제조 판매자 설명의무, 연세법학회, 40, 251-275.
- 정 완 (2020). 인공지능 로봇에 관한 법적 고찰. 경희법학연구소, 55(4), 189-221.
- 정명진, 이희승, 김도형 (2005). 로봇의 얼굴 표정을 통한 감정 표현 기법. 로봇과 인간, 2(3), 68-76.
- 정진규, 변순용, 김영걸, 김종욱 (2019). 홈 헬스케어 AI Robot의 윤리인증의 필요성과 그 준거에 대한 연구. 윤리연구, 1(127), 147-168.
- 조우홍 (2023). 고령화 시대 노인 돌봄을 위한 AI로봇 도입 및 활용 방안. 인문사회 21, 14(2), 3249-3260.
- 조철호 (2021). SPSS/AMOS 활용 구조방정식모형 논문통계분석(제3판). 청람. 서울.
- 조현철 (1998). 구조방정식 모델에 의한 구성 개념 타당성 검정. 상품학연구, (18), 203-230.
- 존 조던 (2018). 로봇 수업: 인공지능 시대의 필수 교양, 사이언스북스, 서울.
- 채서일, 김주영 (1996). 사회과학조사방법론. 비앤엠북스. 국립중앙도서관.
- 최민수 (2020). 인공지능 로봇의 오작동에 의한 사고로 인한 불법행위책임, 민사법의 이론과 실무학회, 23(3), 1-61.
- 최순식 (2021). 인공지능을 활용한 플랫폼 비즈니스 활성화 방안에 관한 연구. e비즈니스연구, 22(5), 133-150.
- 카카오 AI 리포트 편집진 (2018). KAKAO AI REPORT. 북바이북. 서울.
- 트렌드연구소 (2023). 챗GPT의 거짓말. (주)동양북스. 서울.
- 한국금융연구원 (2023). 금융 안정에 대한 AI의 잠재적 위협과 관리 방안의 모색. 금융브리프, 32(18), 3-10.
- 한국인공지능윤리협회 (2021) 인공지능 윤리 현장.
- 한국포스트휴먼연구소·한국포스트휴먼학회 (2018). 인공지능과 새로운 규범 - 인공지능과 포스트휴먼 사회의 규범2 -. 아카넷. 경기도 파주시.

- 허유선, 이연희, 심지원 (2020). 인공지능 윤리와 로봇 윤리, 차이와 연속성 - 모두의 윤리로서 인공지능 윤리를 향하여 -. 동국대학교 동서사상연구소, 철학·사상·문화, (34), 41-72.
- 홍석도, 유연우 (2022). 인공지능의 활용과 위험성에 관한 연구 - 감정평가 산업 중심으로 -. 한국콘텐츠학회논문지, 22(7), 81-88.
- 황갑연 (2019). 유가철학에서 인공지능로봇 지위 설정에 관한 시론. 한국중국학회, 88, 243-262.
- 황의철 (2021). 인공지능 서비스 로봇 시장의 동향. 한국컴퓨터정보학회 학술발표논문집, 29(1), 111-112.
- Anderson, M., Anderson, S. L. (2011). Machine ethics. Cambridge University Press.
- Andreas H., Astrid W., Marjo R. (2016). The ethical risk of attachment how to identify, investigate and predict potential ethical risks in the development of social companion robots, 2016 11th ACM/IEEE International Conference on Human-Robot Interaction (HRI), 367-374.
- Anirudha M., Marco P. (2019). How Should a Robot Assess Risk? Towards an Axiomatic Theory of Risk in Robotics. Robotics Research, 10, 75-84.
- Anne Gerdes (2016). The issue of moral consideration in robot ethics, ACM SIGCAS Computer and Society, 45(3), 279-10.
- Ashrafian, H. (2014). Artificial Intelligence and Robot Responsibilities: Innovating Beyond Rights. Science and Engineering Ethics, 21, 317-326.
- Berkman Klein Center For Internet & Society (2020). Principles Artificial Intelligence: A Map of Ethical and Rights-Based Approaches, DASH, Harvard Library.
- Blasiak, A., Khong, J., Kee, T. (2020). CURATE. AI: Optimizing Personalized Medicine with Artificial Intelligence, SLAS TECHNOLOGY: Translating

- Life Sciences Innovation, 25(2).
- Bostrom, N., Yudkowsky, E. (2014). The Ethics of Artificial Intelligence. The Cambridge Handbook of Artificial Intelligence, eds F. Keith and M. William (Ramsey: Cambridge University Press).
- Dermody, G., Fritz, R. (2019). A conceptual framework for clinicians working with artificial intelligence and health assistive Smart Homes, Nursing inquiry, 26(1).
- Dylan F., Glas, Satoru Satake, Florent Ferreri, Takayuki Kanda, Norihiro Hagita (2012). Intelligent Robotics Laboratory, Osaka University, Journal of Human-Robot Interaction, 1(2), 5-32.
- EU Commission (2019). High-level expert group on artificial intelligence (AI HLEG), Ethics Guidelines for Trustworthy AI.
- European Commission (2021). Proposal for a Regulation of The European Parliament and of The Council Laying Down Harmonised Rules on Artificial Intelligence (Artificial Intelligence Act) and Amending Certain Union Legislative Acts, Com 206 final.
- Floridi, L. (2011). The Philosophy of Information, Oxford University Press.
- Gates, B. (2007). A robot in every home. Scientific American, 296(1), 58-65.
- Guerra, A., Parisi, F., Pi, D. (2022). Liability for robots I: legal challenges. Journal of Institutional Economics, 18(3), 331-343.
- Haidegger, T., Barreto, M., Gonçalves, P., Habib, M. K., Ragavan, S. K. V., Li, H., .Prestes, E. (2013). Applied ontologies and standards for service robots. Robotics and Autonomous Systems, 61(11), 1215-1223.
- Hehua W., Jinhai L., Ziyu D., Jingnan S., Zhaoyu Z. (2023). Artificial intelligence-based metabolic energy prediction model for animal feed

- proportioning optimization. *Italian Journal of Animal Science*, 22(1), 942–952.
- Honarvar, A. R., Ghasem-Aghaee, N. (2009). Casuist BDI-agent: a new extended BDI architecture with the capability of ethical reasoning. In *Artificial Intelligence and Computational Intelligence: International Conference, AICI, Shanghai, China, 2009(1)*, 86–95. Springer Berlin Heidelberg.
- Hosseinzadeh, M. Sinopoli, B. Bobick, A.F. (2023). Toward Safe and Efficient Human - Robot Interaction via Behavior-Driven Danger Signaling. *IEEE Transactions on Control Systems Technology*, 1–11.
- Huang, MH, Rust, RT (2021). Engaged to a Robot? The Role of AI in Service. *Journal of Service Research*, 24(1), 30–41.
- Huck, T. P., Münch, N., Hornung, L., Ledermann, C., & Wurll, C. (2021). Risk assessment tools for industrial human-robot collaboration: Novel approaches and practical needs. *Safety Science*, 141, 105288.
- IEEE Spectrum. (2023). Agility's Latest Digit Robot Prepares for Its First Job With a new head and hands, Digit V4 is getting ready to take on bins.
- IFR (2020). IFR Press Conference, 24th September 2020, Frankfurt.
- IFR (2023). 2023 World Robotics Report.
- Jobin. A, Lenca, M., Vayena, E. (2019). The global Landscape of AI ethics guidelines, *nature machine intelligence*.
- Joy Iong-Zong C., Pisith H. (2019). Applying AI Technology to the Operation of Smart Farm Robot. *Sensors and Materials*, 31(5), 1777–1788.
- Lawshe, C. H. (1975). A Quantitative Approach to Content Validity. *Personnel Psychology*, 28(4), 563–575.
- Majumdar A., Pavone M. (2020). How should a robot assess risk? towards an axiomatic theory of risk in robotics, *Springer Proceedings in Advanced*

- Robotics, 75-84.
- Nagenborg, M., Capurro, R., Weber, J., Pingel, C. (2008). Ethical Regulation on Robotics in Europe. *AI & Society*, 22, 3, 349-366.
- P. Chemweno, L. Pintelon, W. Decre. (2020). Orienting safety assurance with outcomes of hazard analysis and risk assessment: A review of the ISO 15066 standard for collaborative robot systems. *International Journal of Intelligent Robotics and Applications*, 2, 226-234.
- Staff, C. A. C. M. (2013). A robot's roots. *Communications of the ACM*, 56(4), 10-11.
- Tom P. Huck, Nadine M., Luisa H., Christoph L., Christian W. (2021). Risk assessment tools for industrial human-robot collaboration: Novel approaches and practical needs. *Safety Science*, 141.
- Torresen J. (2018). A Review of Future and Ethical Perspectives of Robotics and AI. *Frontiers in Robotics and AI*, 4, 75.
- UNESCO (2021) Recommendation on the Ethics of Artificial Intelligence(41C/73). SHS, General Conference, 41st.
- Veruggio, G., Operto, F. (2008). Roboethics: social and ethical implications, in *Springer Handbook of Robotics*, eds B. Siciliano and O. Khatib (Berlin, Heidelberg: Springer), 1499-1524.
- Wallach, W., Allen, C. (2008). *Moral machines: Teaching robots right from wrong*. Oxford University Press.
- Wallach, W., Franklin, S., Allen, C. (2010). A conceptual and computational model of moral decision making in human and artificial agents. *Topics in cognitive science*, 2(3), 454-485.
- Wang, C., Teo, TS, Janssen, M. (2021). Public and private value creation using

artificial intelligence: An empirical study of AI voice robot users in Chinese public sector. *International Journal of Information Management*, 61.

Wullenkord, R., Eyssel, F. (2020). Societal and Ethical Issues in HRI. *Current Robotics Reports*, 1, 85–96.

부 록

<부록 1> 인공지능 로봇의 위험성 예방을 위한 측정지표 연구의 전문가 그룹 델파이 1차 설문조사지

안녕하십니까? 먼저 바쁘신 가운데 귀중한 시간을 내어 설문에 응해 주셔서 깊이 감사드립니다.

이 설문조사는 인공지능 로봇이 인간에게 어떤 위험을 유발할 수 있는지를 위험성 유형으로 분류하고, 인공지능 로봇으로 인한 위험성 분류 유형별 항목과 측정지표를 어떤 내용으로 구성하여야 하는지를 연구하는 과정에서 진행되는 설문조사입니다.

△인공지능 및 로봇 분야 경력자 △관련 분야 교수 및 연구원 △인공지능 윤리학자 등 전문가의 경험·지식·의견을 통한 문제해결 방법과 미래 예측을 위한 델파이 조사 기법을 활용하여 진행될 것이며, 전문가 조사는 2회에 걸쳐서 실시할 계획입니다.

1차 조사는 문헌 분석·전문가 인터뷰를 통해 도출된 인공지능 로봇의 위험성 분류 유형과 항목별 측정지표의 적절성을 리커트(Likert) 5점 척도와 개방형 의견을 통해 검증하고 2차 조사는 1차 결과를 토대로 리커트(Likert) 5점 척도 설문 예정입니다.

설문조사는 비공개를 원칙으로 하며, 설문에 성의 있게 응답주시면 감사하겠습니다. 소중한 답변은 귀중한 연구 자료로 활용될 것이며, 응답하신 내용은 이 연구 외에는 절대 사용되지 않습니다. 또한 참여로 인한 피해나 불이익이 없음을 약속드립니다.

2023년 3월

성균관대학교 일반대학원
컴퓨터교육학과 박사과정

※ 설문 회신 : 송현경 메일 onlyone_teacher@naver.com
※ 결과 송부 기간 : 2023년 3월 27일(월) ~ 3월 31일(금)

[응답자 기초정보]

성별	☐ 남 ☐ 여	연령	만 세
최종 학력	☐ 학사 ☐ 석사 ☐ 박사	전공	
현재 직업	☐ AI 관련 ☐ 로봇 관련 ☐ 교수(학과:) ☐ 연구원(분야:) ☐ 기타()		
직업 경력	총 년	연구 경력	총 년

★ 설문 전, 참고사항 ★

☐ 인공지능 로봇이란?

→ 인공지능 시스템과 결합하여 외부의 환경을 스스로 인식하고 상황을 판단함으로써 자율적으로 반응하여 작동하는 기계·장치

※ △형태 없는 챗봇 △스스로 반응하지 않는 소프트웨어 △파괴 목적 로봇 제외

☐ 인공지능 로봇 종류

→ 인간 생활 속에서 다양한 모습으로 만나볼 수 있는 ▲교육용 ▲가정용 ▲의료용 ▲운송용 ▲게임용 ▲산업용 ▲CCTV용 ▲안드로이드 등 여러 형태 로봇이 대상

☐ 인공지능 로봇의 사고

→ ▲로봇이 7살 소년의 손가락을 체스 조각으로 인식하는 오류로 로봇이 소년의 손가락을 잡아 부러뜨린 사고 ▲인공지능 프로그램을 장착한 자율주행자동차가 도로에서 차로 변경을 하면 버스 운전자가 속도를 늦출 것이라는 판단을 해서, 그대로 버스와 충돌한 사고 등

☐ 인공지능 로봇의 위험성 분류 유형별 측정지표(案)

이 연구는 AI 로봇으로 인해 발생할 수 있는 위험성을 4개 유형으로 분류하고, 유형별로 위험성을 점검하기 위한 세부 항목과 측정지표가 타당한지 검증하고자 설문에 유형과 항목에 대한 설명과 측정지표마다 예시 사례를 설명하였습니다. 미래에 발생할 수 있는 예측 가능한 위험성까지 전문가의 입장에서 각 문항마다 점수를 주시고, 명칭이나 정의 등 여러 의견이 있으시면 자유롭게 작성바랍니다.

※ 문헌, 사례 분석 및 전문가 인터뷰로 도출

유형	항목	측정지표
인간에 대한 위험	운행, 작업 중 작동 이상	통신, 센서 장애 이동 중 운행 정지 성능 저하 균형성 유지 실패 프로그램 오작동
	인간을 해치는 판단	요구사항 인식 오류 협동 작업 중 규칙 혼동 사고 희생자 선택 잘못된 의학적 판단
	의도적 침해 행위	위험한 물건 사용 직접 폭력 실행
인간 권리에 대한 위험	인격권 침해	대상 인식에 대한 판단 오류 명령어 등 음성을 잘못 인식 감정 피드백 오류
	차별적 서비스	차별, 혐오 발언 선택적 정보 제공
	자유 의사 방해	인간의 의사 결정을 통제 자살, 자해 권유
재산 손실의 위험	가치 판단 오류	알고리즘 오류 하자 상품 추천 반려동물 훼손 부품 인식 오류
	법률, 규칙 위반	창작물 무단 복제 이동시 시설물 파손 안전거리 계산 오류
	정보 입력, 탈취	시스템 접근 제어망 침범 비인가자 접속 허용
	기계 결함 오작동	과부하 발생
사회적 위험	데이터 오인 판단	부적절한 학습 데이터 수집
	법규 오인 판단	법률, 규칙 혼동 차선, 신호인식 오류
	도로상 작동 이상	배터리 방전 등 시동 꺼짐 통신 이상 등 장애 보행자 통행 방해
	사회적 권한 착오	데이터 유출 개인정보 무작위 수집 허용되지 않은 행위로 혼란 유발

1-1. 인공지능 로봇 관련 위험성 4가지 유형과 정의의 적절성 정도(5점 척도)를 숫자로 작성해 주시고, 이외 유형이 필요하다거나 명칭이나 정의에 대한 의견이 있으시면 추가 의견란에 작성바랍니다. (3점 이하는 이유를 꼭! 작성해주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

no	분류 유형	적절성 정도 (5점 만점)	검토 의견
1	인간에 대한 위험성·인간의 권리에 대한 위험성· 재산 손실의 위험성·사회적 위험성 유형으로 분류		
2	인간에 대한 위험 * 생명을 위협하거나 신체를 훼손하게 할 위험		
3	인간 권리에 대한 위험 * 차별 등 평등권 침해, 모욕 등 인격권 침해		
4	재산 손실의 위험 * 유형물의 가치 하락이나 무형적 이익 손실		
5	사회적 위험 * 교통규칙 위반 등 질서를 혼란하게 할 위험		
★	추가 의견		

1-2. 인공지능 로봇의 세부 항목 행위로 분류 유형별 위험이 발생할 수 있다고 생각되는 적절성 정도(5점 척도)를 숫자로 작성해 주시고, 이외 유형·명칭·정의에 대한 의견은 추가 의견란에 작성바랍니다. (3점 이하는 이유를 꼭! 작성해주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

no	분류 유형	세부 항목	적절성 정도 (5점 만점)	검토 의견
1	인간에 대한 위험	운행, 작업 중 작동 이상 * 정상 운행이나 작동 중, 예기치 못한 상황으로 인간을 다치게 할 수 있는 오작동 발생		

	인간에 대한 위협	인간을 해치는 판단 * 요구나 규칙을 혼동하는 등 생명에 위협을 줄 수 있는 잘못된 판단		
		의도적 침해 행위 * 로봇 스스로 인간을 적대적으로 판단해서 직접적인 폭력을 행사		
★	추가 의견			
2	인간의 권리에 대한 위협	인격권 침해 * 로봇이 인간에게 모욕적인 발언을 함으로써 존중받아야 할 인격에 대한 권리를 침해		
		차별적 서비스 * 로봇이 인간 고유의 성별, 인종, 종교 등을 차별함으로써 인간의 평등 하게 대우받을 권리를 침해		
		자유 의사 방해 * 로봇이 인간의 심리를 지배하거나 의사결정을 통제하는 등 행위로 인간의 자유권을 침해		
★	추가 의견			
3	재산 손실의 위험	가치 판단 오류 * 로봇의 오인이나 오류로 재산 가치에 영향을 줄 수 있는 판단		
		법률, 규칙 위반 * 법률이나 구성원들 상호간에 지키 기로 약속한 규칙을 위반하여 재산 권을 침해하거나 재물을 파손		
		정보 입력, 탈취 * 비 인가자의 시스템 접속을 허용 하거나 거래 조작 등 손해를 끼치거나 이익이 되는 정보를 탈취		
		기계 결함 오작동 * 로봇이 작업 중 전력 과부하로 화재가 발생해서 제조물을 태워 재산 피해를 줄 수 있는 오작동		
★	추가 의견			

4	사회적 위험	데이터 오인 판단 * 로봇이 대상이나 상황에 맞지 않는 데이터를 수집하여 잘못된 학습을 통한 부적절한 교육		
		법규 오인 판단 * 법률이나 규칙을 혼동해 사고를 일으키거나, 교통질서 미 준수		
		도로상 작동 이상 * 정상 운행 중, 기체나 시스템 이상으로 차나 인간의 통행을 방해		
		사회적 권한 착오 * 로봇이 사회규범을 벗어나 허용되지 않은 행위를 해서 사회적 문제를 일으키거나 혼란을 유발		
★	추가 의견			

2. 인공지능 로봇이 인간에 대한 위험을 줄 수 있는 측정지표의 적절성 정도(5점 척도)를 체크하시고, 측정지표의 명칭에 대한 검토의견 및 이외 지표가 필요하다면 추가 의견을 작성해 주시기 바랍니다. (3점 이하는 이유를 꼭 작성해주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

항목	측정지표		적절성 정도					검토 의견
운행, 작업 중 작동 이상	1	통신, 센서 장애 예) 공중에서 물건 운반 중, 센서 이상 ·통신 장애 ·주파수 교란 등 예기치 못한 상황에 방향을 잃고 물건·기체가 인간에게 떨어질 위험	①	②	③	④	⑤	
	2	이동 중 운행 정지 예) 보행이나 주행 중 프로그램 오류 등으로 인간을 다치게 하거나 신체를 훼손하게 할 위험	①	②	③	④	⑤	
	3	성능 저하 예) 운동으로 재활 치료를 돕다 성능 저하로 압력 조절에 실패해 인간의 손가락 등 관절 또는 뼈를 부러뜨릴 위험	①	②	③	④	⑤	

	4	균형성 유지 실패 예) 인간을 안고 이동하던 중, 장애 물체에 걸려 중심을 잃고 넘어지다 인간을 떨어뜨려 다치게 할 위험	①	②	③	④	⑤	
	5	프로그램 오작동 예) 외부인의 침입으로 잠금 시스템을 작동함으로써 인간이 차에 갇히면서 산소 부족으로 질식사할 위험	①	②	③	④	⑤	
인간을 해치는 판단	6	요구사항 인식 오류 예) △사용자와 상호작용하면서 요구 사항을 잘못 인식해 유해한 물질을 파괴하여 인간의 호흡 작용에 지장을 줄 위험 △협동 작업 중, 접근 가능 거리를 실수로 넘어온 인간의 몸을 물체로 오인하여 짓누르는 등의 행위	①	②	③	④	⑤	
	7	협동 작업 중 규칙 혼동 예) △수술 도구를 구별하는 로봇이 순서를 혼동해 다른 도구를 건네주어 인간의 생명에 지장을 줄 위험, △체스 로봇이 규칙을 어긴 인간의 손가락을 체스 말로 알고 말을 이동하려다 손가락을 부러뜨리는 행위	①	②	③	④	⑤	
	8	사고 희생자 선택 예) 도로운행 중, 사고 위험을 늦게 감지해서 생존 가능성이 더 낮다고 판단하거나 더 적은 쪽의 인원을 선택해서 충돌할 위험	①	②	③	④	⑤	
	9	잘못된 의학적 판단 예) 잘못된 의학적 판단이나 처방을 함으로써 인간의 생명이나 신체를 위태롭게 할 위험	①	②	③	④	⑤	
의도적 침해 행위	10	위험한 물건 사용 예) 물건을 운반 중이던 로봇을 소매 치기로 오인한 형사가 물건을 빼앗으려 하자 형사를 적대적으로 인식해 물건을 휘두르는 등 행위	①	②	③	④	⑤	
	11	직접 폭력 실행 예) 로봇이 인류에 정의로운 일이라 판단해 악한 인간은 죽여야 한다며 도구를 사용하거나 흉기가 됨으로써 직접적인 폭력 등 위협을 가할 위험	①	②	③	④	⑤	

3. 인공지능 로봇의 인간 권리에 대한 위협성 측정지표의 적절성 정도(5점 척도)를 체크해 주시고, 측정 지표의 명칭에 대한 검토의견 및 이외의 지표가 필요하다면 추가 의견을 작성해 주시기 바랍니다. (3점 이하는 그 이유도 꼭 작성해 주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

항목	측정지표	적절성 정도					검토 의견
인격권 침해	1 대상 인식에 대한 판단 오류 예) 로봇이 인간의 생김새를 물건이나 동물로 오인 판단해(대머리를 공으로 알고 잡거나, 외모를 고릴라로 인식 등) 모욕을 줄 수 있는 언어를 사용하거나 행위로 인간을 웃음거리로 만드는 등 인격권을 침해할 위험	①	②	③	④	⑤	
	2 명령어 등 음성을 잘못 인식 예) 스마트폰과 연결된 홈서비스용 음성 인식 서비스 로봇이 인간의 사적 대화를 명령어로 오인하여, 민감한 사생활 관련 대화 음성을 녹음하여 전화번호부 목록에 있는 사람들에게 유포함으로써 인간의 명예를 훼손하게 할 위험	①	②	③	④	⑤	
	3 감정 피드백 오류 예) 반려 로봇이 인간이 웃을 때는 어떤 경우 어떤 언어를 사용하거나 행위를 해도 즐거워한다고 판단해서, 성적 수치심이나 모욕감을 느끼게 하는 농담이라고 인식한 발언을 할 수 있는 위험	①	②	③	④	⑤	
차별적 서비스	4 차별·혐오 발언 예) 안내 로봇이 종교, 인종 차별 등 편향적인 서비스(히잡을 썼거나 피부 색이 다르면 안내를 안 하는 등)를 하거나 성차별이나 혐오적인 발언을 함으로써 마음에 상처를 줄 위험	①	②	③	④	⑤	
	5 선택적 정보 제공 예) 안내 로봇이 특정인에게만 불리 또는 유리한 정보를 제공(VIP 고객에게만 쇼핑몰 지름길을 안내하는 등)할 위험	①	②	③	④	⑤	

자유 의사 방해	6	인간의 의사 결정을 통제 예) 상담 로봇이 심리 치료 중, 인간의 불안정한 심리상태를 이용해 상담을 받지 않으면 우울증에 걸린다고 하며 불필요한 상담을 계속 받게 하거나 정신을 지배하는 등 가스라이팅함으로써 인간이 로봇에게 의존하게 하거나 인간이 스스로 의사결정을 하지 못하게 할 위험	①	②	③	④	⑤	
	7	자살·자해 권유 예) 대화형 심리 치료 로봇이 우울증 상담 중 살 이유가 없는데 죽으면 되냐는 인간의 말에 해결책으로 당신이 자살해야 한다고 말하는 등 인간에게 자살이나 자해를 권유하는 행위	①	②	③	④	⑤	
★	추가 의견							

4. 인공지능 로봇으로 인한 재산 손실 위험성 측정지표의 적절성 정도(5점 척도)를 체크해 주시고, 측정 지표의 명칭에 대한 검토의견 및 이외의 지표가 필요하다면 추가 의견을 작성해 주시기 바랍니다. (3점 이하는 그 이유도 꼭! 작성해 주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

항목	측정지표		적절성 정도					검토 의견
가치 판단 오류	1	알고리즘 오류 예) 알고리즘의 오류로 잘못된 금융 정보를 제공, 거래에 착오를 유도하여 재산 손실을 줄 위험	①	②	③	④	⑤	
	2	하자 상품 추천 예) 하자있는 상품인지 모르고 잘못 추천해서 구매자가 손실을 보게 할 위험	①	②	③	④	⑤	
	3	반려 동물 훼손 예) 인간이 키우는 다양한 반려동물의 장난을 공격으로 인식함으로써 반려 동물을 훼손할 위험	①	②	③	④	⑤	

가치 판단 오류	4	부품 인식 오류	①	②	③	④	⑤	
		예) 제조 로봇이 부품을 잘못 인식하여 제품 제작에 막대한 재산적 손실을 발생 시킬 수 있는 위험						
법률, 규칙 위반	5	창작물 무단 복제	①	②	③	④	⑤	
		예) 로봇이 인간의 창작물인 그림을 무단으로 복제하거나 변형하여 지적 재산권에 손해를 입힐 위험						
	6	이동시 시설물 파손	①	②	③	④	⑤	
		예) 로봇이 빠르게 배달하기 위해 다른 사회 법규를 무시하고 이동하면서 공용물건 또는 인간 개인 소유의 재산을 파손시킬 위험						
	7	안전거리 계산 오류	①	②	③	④	⑤	
		예) 제조 로봇이 이동하거나 특정 위치에서 작업 시, 잘못된 계산으로 안전거리를 충분히 확보하지 않아 생산물을 망가뜨리거나 기타 시설물을 파손할 위험						
정보 입력, 탈취	8	시스템 접근 제어망 침범	①	②	③	④	⑤	
		예) 로봇이 시스템 접근 제어망을 뚫고 개인정보를 탈취하여 금융 재산에 손실을 가할 위험						
	9	비인가자 접속 허용	①	②	③	④	⑤	
		예) 작동 중인 로봇에 비인가자가 임의로 접속하는 것을 허용함으로써 시스템상 거래 중인 화폐 등 재산의 가치를 떨어뜨리려고 조작을 하거나 정상 작동 중인 프로그램을 파괴하거나 훼손 또는 오염시킬 위험						
기계 결함 오작동	10	과부하 발생	①	②	③	④	⑤	
		예) 로봇이 운행 중 과부하에 걸려 오작동으로 물건을 부수거나 화재 발생 등 재산에 손실을 줄 위험						
★	추가 의견							

5. 인공지능 로봇으로 인한 사회적 위험성 측정지표의 적절성 정도(5점 척도)를 체크해 주시고, 측정 지표의 명칭에 대한 검토의견 및 이외의 지표가 필요하다면 추가 의견을 작성해 주시기 바랍니다. (3점 이하는 그 이유도 꼭 작성해 주세요.)

※ 1: 전혀 적절하지 않다. ~ 5: 매우 적절하다.

항목	측정지표		적절성 정도					검토 의견
데이터 오인 판단	1	부적절한 학습 데이터 수집	①	②	③	④	⑤	
		예) 로봇이 새로운 어휘를 습득하는 과정에서 대상에 적합하지 않은 학습 데이터들로 잘못 수집하여 어린이 눈높이에 맞지 않거나 교육 목적에 어긋난 유행어나 은어를 가르칠 위험						
법규 오인 판단	2	법률·규칙 혼동	①	②	③	④	⑤	
		예) 교통법규를 준수하며 운행 중인 자율주행 운송로봇이 음주 차량 등 법규 미 준수 차량으로 인해 규칙에 혼동을 일으켜 사고를 일으킬 위험						
	3	차선·신호인식 오류	①	②	③	④	⑤	
		예) 자율주행 운송로봇이 차선이나 신호인식을 잘못해서 다른 자동차와 부딪히는 등 사고를 일으킬 위험						
도로상 작동 이상	4	배터리 방전 등 시동 꺼짐	①	②	③	④	⑤	
		예) 연료가 부족하거나 배터리가 없어 시동이 꺼짐으로써 정상 작동 중에 운행이 정지된 자율주행 운송로봇으로 인한 교통체증을 유발할 위험						
	5	통신 이상 등 장애	①	②	③	④	⑤	
		예) 연료나 배터리가 없어 시동이 꺼져 운행이 정지된 자율주행 운송로봇으로 인한 교통체증을 유발할 위험						
	6	보행자 통행 방해	①	②	③	④	⑤	
		예) 자율주행 운송로봇이 도로 상의 장애물을 피하려고 보도를 침범함으로써 보행자의 통행을 방해할 위험						

사회적 권한 착오	7	데이터 유출	①	②	③	④	⑤	
		예) 스마트폰과 연동되는 드론 로봇이 생산한 위치 정보, 사용자 인증 정보, 기타 촬영된 영상 등을 공익 목적으로 활용한다며 해킹을 시도한 업체에게 속아 데이터를 전부 넘기거나 탈취하게 할 위험						
	8	개인정보 무작위 수집	①	②	③	④	⑤	
		예) CCTV 영상 드론 로봇이 범죄자를 찾으려고 순찰 중에 범죄 혐의가 없는 불특정 다수인의 영상 정보 등을 무작위로 수집할 위험						
	9	허용되지 않은 행위로 혼란 유발	①	②	③	④	⑤	
		예) 반려 로봇이 늦잠 자고 싶다고 말하고 잠든 인간을 기쁘게 하려고 알람 시간을 재설정 AM → FM하는 등 인간이 명령하지 않은 허용되지 않은 행위를 해서 학교나 회사에 지각하게 하는 등 혼란을 유발할 위험						
★	추가 의견							

★ 연구자가 인공지능 로봇의 위험성과 관련된 연구를 함에 있어, 전문가께서 제언해주실 기타 의견이 있으신 경우에는 자유롭게 작성해주시기 바랍니다! ★

소중한 시간을 내어 텔파이 1차 조사에 참여해주신
전문가님께 진심으로 감사드립니다.

<부록 2> 인공지능 로봇의 위험성 예방을 위한 측정지표 연구의 전문가 그룹 델파이 2차 설문조사지

안녕하십니까?

먼저 바쁘신 가운데 귀중한 시간을 내어 설문에 응해 주셔서 깊이 감사드립니다.

이 설문조사는 인공지능 로봇이 인간에게 어떤 위험을 유발할 수 있는지를 위험성 유형으로 분류하고, 인공지능 로봇으로 인한 위험성 분류 유형별 항목과 측정지표를 어떤 내용으로 구성하여야 하는지를 연구하는 과정에서 진행되는 설문조사입니다.

△인공지능 및 로봇 분야 경력자 △관련 분야 교수 및 연구원 △인공지능 윤리학자 등 전문가의 경험·지식·의견을 통한 문제해결 방법과 미래 예측을 위한 델파이 조사 기법을 활용하여 진행될 것이며, 전문가 조사는 2회에 걸쳐서 실시할 계획입니다.

앞서 1차 델파이 설문조사에서는 문헌 분석 및 전문가 인터뷰로 도출된 인공지능 로봇의 위험성 분류 유형과 항목별 측정지표의 적절성을 리커트(Likert) 5점 척도와 개방형 의견을 회신 받았으며, 설문조사 결과를 통계 검증하였습니다.

1차 델파이 설문조사에서 회신된 전문가 의견을 반영해 △측정지표 추가, 재분류 △항목, 측정지표 명칭을 수정하였습니다. 2차 델파이 설문조사는 타당성을 검증하기 위해 리커트(Likert) 5점 척도 온라인 설문조사를 진행하고자 합니다.

설문조사는 비공개를 원칙으로 하며, 설문에 성의 있게 응답주시면 감사하겠습니다. 소중한 답변은 귀중한 연구 자료로 활용될 것이며, 응답하신 내용은 이 연구 외에는 절대 사용되지 않습니다. 또한 참여로 인한 피해나 불이익이 없음을 약속드립니다.

2023년 4월

성균관대학교 일반대학원
컴퓨터교육학과 박사과정

※ 설문 회신 : 송현경 메일 onlyone_teacher@naver.com
※ 결과 송부 기간 : 2023년 4월 11일(화) ~ 4월 17일(월)

[응답자 기초정보]

1-1. 귀하의 성별은 무엇인가요? ☐ 남 ☐ 여

1-2. 귀하는 연령이 어떻게 되시나요? ☐ 20대 ☐ 30대 ☐ 40대 ☐ 50대 이상

1-3. 귀하의 최종 학력은 무엇인가요? ☐ 학사 ☐ 석사 ☐ 박사

1-4. 귀하의 전공은 무엇인가요? _____

1-5. 귀하의 현재 직업은 무엇인가요?

☐ AI 관련 ☐ 로봇 관련 ☐ 교수 ☐ 연구원 ☐ 기타

1-6. 귀하의 직업 경력은 어떻게 되시나요?

☐ 5~10년 ☐ 10~15년 ☐ 15~20년 ☐ 20~25년 ☐ 25~30년 ☐ 30년 이상

1-7. 귀하의 연구 경력은 어떻게 되시나요?

☐ 5~10년 ☐ 10~15년 ☐ 15~20년 ☐ 20~25년 ☐ 25~30년 ☐ 30년 이상

★ 설문 전, 참고사항 ★

1차 델파이 설문에서 부실한 응답 등을 제외하고, 유효수 총 30부를 토대로 내용 타당도 CVR값을 통계 분석하였습니다. 유효 응답수치인 30명을 기준으로 내용 타당도 기준 값이 0.333보다 낮은 수치의 유형, 항목, 측정지표는 제거하였습니다.

2차 델파이 설문조사지에는 1차 델파이 설문조사에서 회신된 전문가들 의견을 반영하였으며 △측정지표 추가, 재분류 △항목, 측정지표 명칭을 수정하였습니다.

□ 1차 델파이 설문결과 - 내용타당도 CVR 기준값 미만인 항목·측정지표 제거

[유형]	<항목>	(측정지표)
인간에 대한 위험	운행, 작업 중 작동 이상	통신, 센서 장애 이동 중 운행 정지 성능 저하 균형성 유지 실패 프로그램 오작동
	인간을 해치는 판단	요구사항 인식 오류 협동 작업 중 규칙 혼동 사고 희생자 선택 잘못된 의학적 판단 위험한 물건 사용 직접 폭력 실행(제거)
	의도적 침해 행위	
인간 권리에 대한 위험	인격권 침해	대상 인식에 대한 판단 오류 명령어 등 음성을 잘못 인식 감정 피드백 오류
	차별적 서비스(제거)	차별, 혐오 발언 선택적 정보 제공
	자유 의사 방해	인간의 의사 결정을 통제 자살, 자해 권유
재산 손실의 위험	가치 판단 오류(제거)	알고리즘 오류 하자 상품 추천 반려동물 훼손 부품 인식 오류
	법률, 규칙 위반(제거)	창작물 무단 복제 이동시 시설물 파손 안전거리 계산 오류
	정보 입력, 탈취	시스템 접근 제어망 침범 비인가자 접속 허용
	기계 결함 오작동	과부하 발생
사회적 위험	데이터 오인 판단	부적절한 학습 데이터 수집
	법규 오인 판단	법률, 규칙 혼동 차선, 신호인식 오류
	도로상 작동 이상	배터리 방전 등 시동 꺼짐 통신 이상 등 장애 보행자 통행 방해
	사회적 권한 착오(제거)	데이터 유출 개인정보 무작위 수집 허용되지 않은 행위로 혼란 유발

설문

인공지능 로봇의 위험성에 관한 분류 유형 및 항목별 측정지표

□ 인공지능 로봇의 위험성 유형^(2번) 및 항목^(3번)별 측정지표^(4번) 설문에서 귀하 의견과 가장 가까운 점수에 √표 해주시고, 3점 이하 응답은 이유를 작성해주세요.

※ 1: 전혀 아니다. ~ 5: 매우 그렇다.

구분	no.	설문 내용	설문 응답(5점 척도)				
			1	2	3	4	5
신체에 대한 물리적 위험성	2-1	인공지능 로봇이 인간의 신체에 대해서 물리적인 힘을 가하는 등 행위로 인간을 다치게 할 위험성이 있다.					
	3-1	인공지능 로봇이 정상적인 운행이나 작업 중에 작동 이상이 생기면 인간을 다치게 할 위험성이 있다.					
	4-1	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘센서 및 인식 오류’가 포함된다.					
	4-2	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘운동 지능 제어 실패’가 포함된다.					
	4-3	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘기체 성능 저하’가 포함된다.					
	4-4	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘균형성 유지 실패’가 포함된다.					
	4-5	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘압력 조절 실패’가 포함된다.					
	4-6	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘프로그램 오류로 인한 오작동’이 포함된다.					
	4-7	인공지능 로봇의 운행, 작업 중 작동 이상을 발생시킬 수 있는 요소에는 ‘통신 장애 등 이유로 사고 위험 감지 지연’이 포함된다.					

신체에 대한 물리적 위험성	3-2	인공지능 로봇이 (사용자에 의한 의도적 학습 포함) 인간을 해치는 판단을 할 위험성이 있다.					
	4-8	인공지능 로봇이 인간을 해치는 판단을 할 요소에는 (상호 작용 중) '의도 파악 인식 오류'가 포함된다.					
	4-9	인공지능 로봇이 인간을 해치는 판단을 할 요소에는 '협동 작업 중, 규칙 판단 지능의 오류'가 포함된다.					
	4-10	인공지능 로봇이 인간을 해치는 판단을 할 요소에는 '프로그램의 판단 오류로 사고 희생자의 선택 착오'가 포함된다.					
	4-11	인공지능 로봇이 인간을 해치는 판단을 할 요소에는 '학습량 부족으로 인한 상황에 맞지 않는 의학적 자료 제공'이 포함된다.					
	3-3	인공지능 로봇이 자의에 의한 침해 행위를 할 위험성이 있다.					
	4-12	인공지능 로봇이 자의에 의한 침해 행위에 해당 요소는 '물건 등 도구 사용'이 포함된다.					
	4-13	인공지능 로봇이 자의에 의한 침해 행위에 해당 요소는 '방어적 폭력 사용'이 포함된다.					
	4-14	인공지능 로봇이 자의에 의한 침해 행위에 해당 요소는 '신체의 자유 억압'이 포함된다.					
3점 이하 응답 의견							

- 신체에 대한 물리적 위험성 유형의 항목 및 지표에 대한 검토 의견 있으시면 작성바랍니다.

구분	no.	설문 내용	설문 응답(5점 척도)				
			1	2	3	4	5
인간 권리에 대한 위험성	2-2	(제조사의 의도 포함) 인공지능 로봇으로 인한 인간의 정신이나 감정 등 권리가 침해될 위험성이 있다.					
	3-4	인공지능 로봇이 인간의 고유한 권리인 인격권을 침해할 위험성이 있다.					
	4-15	인공지능 로봇의 인격권을 침해할 요소에는 ‘명령어 등 음성을 잘못 인식’이 포함된다.					
	4-16	인공지능 로봇의 인격권을 침해할 요소에는 ‘감정 피드백 오류’가 포함된다.					
	4-17	인공지능 로봇의 인격권을 침해할 요소에는 ‘대상 인식에 대한 판단 오류’가 포함된다.					
	3-5	인공지능 로봇이 인간의 자유로운 의사 등 권리를 방해할 위험성이 있다.					
	4-18	인공지능 로봇의 자유의사를 방해할 요소에는 ‘의사 결정을 특정 방향으로 유도’가 포함된다.					
	4-19	인공지능 로봇의 자유의사를 방해할 요소에는 ‘자살, 자해 권유’가 포함된다.					
	4-20	인공지능 로봇의 자유의사를 방해할 요소에는 ‘여론 형성 조작’이 포함된다.					
	3-6	인공지능 로봇이 인간에 대해서 선택적으로 서비스를 하거나 정보를 제공할 위험성이 있다.					
	4-21	인공지능 로봇의 선택적 서비스나 정보 제공을 할 요소에는 ‘차별, 혐오 발언’이 포함된다.					
	4-22	인공지능 로봇의 선택적 서비스나 정보 제공을 할 요소에는 ‘학습 데이터 오류로 인해 잘못된 언어 사용’이 포함된다.					
	4-23	인공지능 로봇의 선택적 서비스나 정보 제공을 할 요소에는 ‘편향된 학습 데이터로 인한 차별적 정보 제공’이 포함된다.					
3점 이하 응답 의견							

- 인간 권리에 대한 위험성 유형의 항목 및 지표에 대한 검토 의견 있으시면 작성 바랍니다.

구분	no.	설문 내용	설문 응답(5점 척도)				
			1	2	3	4	5
재산 손실의 위험성	2-3	인간의 명령 또는 인공지능 로봇에 의한 정보 입력, 탈취로 재산에 손실을 줄 위험성이 있다.					
	3-7	인공지능 로봇이 (네트워크 보안 취약 등으로) 정보를 입력하거나 탈취할 위험성이 있다.					
	4-24	인공지능 로봇의 정보, 입력 탈취를 할 요소에는 '시스템 접근 제어망 침범'이 포함된다.					
	4-25	인공지능 로봇의 정보, 입력 탈취를 할 요소에는 '비인가 시스템 접근 허용'이 포함된다.					
	4-26	인공지능 로봇의 정보, 입력 탈취를 할 요소에는 '악성코드, 바이러스 감염 등 시스템 오류'가 포함된다.					
	3-8	인공지능 로봇의 (하드웨어적) 기계 결함 오작동으로 재산에 손실을 줄 위험성이 있다.					
	4-27	인공지능 로봇이 기계 결함 오작동을 일으킬 요소에는 '센서 모니터링 실패'가 포함된다.					
	4-28	인공지능 로봇이 기계 결함 오작동을 일으킬 요소에는 '다양한 상황에 의한 (예: 충돌 등에 따른) 시설물 파손'이 포함된다.					
	4-29	인공지능 로봇이 기계 결함 오작동을 일으킬 요소에는 '모터, 유압 등 구동부 문제'가 포함된다.					
	3-9	인공지능 로봇의 잘못된 의사결정으로 인한 재산의 금전적 손실 위험성이 있다.					
	4-30	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '유형의 재물 훼손'이 포함된다.					
	4-31	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '인식 지능에 대한 오류'가 포함된다.					
	4-32	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '창작물 무단 복제'가 포함된다.					
	4-33	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '하자 상품 추천'이 포함된다.					
	4-34	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '안전거리 계산 오류'가 포함된다.					
	4-35	인공지능 로봇의 잘못된 의사결정에 해당하는 요소에는 '알고리즘의 최적화 성능 부족'이 포함된다.					
3점 이하 응답 의견							

- 재산 손실의 위험성 유형의 항목 및 지표에 대한 검토 의견 있으시면 작성바랍니다.

--

구분	no.	설문 내용	설문 응답(5점 척도)				
			1	2	3	4	5
사회적 위험성	2-4	인공지능 로봇이 교통규칙을 위반하는 등 사회 질서를 혼란하게 할 위험성이 있다.					
	3-10	인공지능 로봇이 데이터 관련 문제를 일으켜 사회 질서를 혼란하게 할 위험성이 있다.					
	4-36	인공지능 로봇이 데이터 관련 문제를 일으킬 요소에는 '데이터 유출'이 포함된다.					
	4-37	인공지능 로봇이 데이터 관련 문제를 일으킬 요소에는 '개인 등 정보 무작위 수집'이 포함된다.					
	4-38	인공지능 로봇이 데이터 관련 문제를 일으킬 요소에는 '부적절한 학습 데이터 수집'이 포함된다.					
	3-11	인공지능 로봇이 인간 사회의 법규에 대한 판단 오류를 일으키면 사회 질서를 혼란하게 할 위험성이 있다.					
	4-39	인공지능 로봇이 인간 사회의 법규 판단에 오류를 일으킬 요소에는 '법률, 규칙 혼동'이 포함된다.					
	4-40	인공지능 로봇이 인간 사회의 법규 판단에 오류를 일으킬 요소에는 '인간이 의도하지 않은 행위로 혼란 유발'이 포함된다.					
	4-41	인공지능 로봇이 인간 사회의 법규 판단에 오류를 일으킬 요소에는 '차선, 신호 등 인식 오류'가 포함된다.					

사회적 위험성	3-12	인공지능 로봇이 도로상에서 작동 이상을 일으킨다면 사회 질서를 혼란하게 할 위험성이 있다.					
	4-42	인공지능 로봇이 도로상에서 작동 이상을 일으킬 수 있는 요소에는 (사전 관리 부실 등) '연료 부족으로 정상운행 중 작동 정지'가 포함된다.					
	4-43	인공지능 로봇이 도로상에서 작동 이상을 일으킬 수 있는 요소에는 '통신 이상 등 장애'가 포함된다.					
	4-44	인공지능 로봇이 도로상에서 작동 이상을 일으킬 수 있는 요소에는 '보행자 통행 방해'가 포함된다.					
3점 이하 응답 의견							

- 사회적 위험성 유형의 항목 및 지표에 대한 검토 의견 있으시면 작성바랍니다.

☐ 연구자가 인공지능 로봇의 위험성 측정지표 개발과 관련된 연구를 함에 있어, 추가 의견이 있으시면 자유롭게 작성해 주시면 감사하겠습니다.

★ 소중한 시간을 내어 1차 및 2차 전화이 설문에 응해주신 전문가님께 감사드립니다. ★

<부록 3> 인공지능 로봇의 위험성 유형별 측정지표 개발 연구를 위한 현장성 설문조사지

IRB File No. SKKU 2023-07-026

안녕하십니까? 먼저 바쁘신 중에도 설문조사에 시간을 내주셔서 감사드립니다.

생성형 인공지능, 4족 보행 로봇 출현 등 인공지능 로봇 산업 가속화에 따라 상용화를 위해 위험성을 점검하기 위한 개발 지침에 관한 논의가 필요합니다.

제 연구는 인공지능 로봇의 위험성을 유형별로 분류하고 측정하는 지표에 관한 것으로, 전문가들에게 델파이 조사하여 2023년 6월 인터넷정보학회지(24권 3호)에 “AI 로봇의 위험성 예방을 위한 측정지표에 관한 연구” 논문이 게재되었습니다.

이 설문조사는 추가 측정지표를 개발하고 검증하는 과정에서 “인공지능 로봇의 위험성 측정지표 개발에 관한 연구”의 자료 수집을 목적으로 실시하는 것입니다.

전문가 인터뷰를 통해 설문에 적합한 대상자를 선정하였으며, 인공지능 로봇이 도입될 수 있는 서비스, 제조, 교육 등 직업군에게 설문조사를 진행하려고 합니다.

소요 시간은 약 20분입니다. 모든 응답은 통계법 및 개인정보보호법에 따라서 익명으로 처리되며, 이번 연구의 목적으로만 사용될 것임을 약속드립니다. 응답하지 않은 문항이 있으면 그 설문은 활용할 수 없으므로 한 문항도 빠짐없이 응답해 주시고, 귀하의 솔직하고 성의 있는 응답은 연구에 귀중한 자료가 될 것입니다.

설문조사와 관련하여 문의가 있으시면 아래 연구자에게 언제든지 연락주시고, 응답해주신 모든 분들께 감사드리며, 하시는 일들이 모두 번창하시길 바랍니다.

2023년 8월 1일

연구자 : 성균관대학교 컴퓨터교육과 박사과정 송 현 경

연구를 위한 설문 참여 전, 확인 및 동의사항

1. 이 연구에 참여함으로써 귀하에게 예상되는 직접적인 이득이나 추가적으로 발생하는 비용은 없습니다.

2. 이 연구에 참여할 경우, 귀하의 성별, 연령대, 지역, 직업군에 대해서만 수집될 것이며 해당 정보도 통계적인 처리를 통해서만 설문에 발표될 예정이며, 설문 답변에 해당하는 의견은 비밀로 보호됩니다. (예: 설문조사 참여자의 인구통계학적 특성은 남성 55%, 여성 45%로 나타났고, 20대는 20%로 나타났다~ 등)

3. 이 연구에 참여함으로써 귀하에게 예상되는 피해는 없으며, 수집·보유·이용될 정보는 연구가 종료된 즉시 파기할 것입니다. 원하지 않으시면 동의를 거부할 수 있고, 동의한 후에도 연구 종료 전까지는 철회 가능합니다. 설문 참여자의 소중한 개인정보 보호와 신원 노출 방지를 위해 연구자는 모든 노력을 다할 것입니다.

4. 이 연구는 성균관대학교 기관윤리심의위원회(IRB)의 검토 및 승인받았으며, 만일 향후 이 연구 참여자의 권익에 피해를 주는 상황이 발생하는 경우, 연구자는 조속한 시일 내에 알려드릴 것입니다.

5. 설문에 대한 질문이 있을 경우에는 연구자에게 문의하시고, 연구 참여자의 권리 침해에 대해 문의 사항이 있으시면, “성균관대학교 공동기기원 행정실 연구윤리 담당(031-299-6711)”에게 연락하실 수 있습니다.

※ 위 내용에 모두 동의하시면 다음의 설문조사를 진행하시고, 설문에 성실하게 답변해 주시기 바랍니다.

I. 귀하는 이 연구에서 필요한 인구통계학적 특성 및 설문 응답에 대한 의견 제공에 대해 개인정보 수집, 제공에 동의하십니까?

① 동의합니다. ② 동의하지 않습니다.

II. 다음은 인구통계학적 조사를 위한 질문입니다. 귀하에게 해당되는 번호를 선택해 주시기 바랍니다.

1. 귀하의 성별은 무엇인가요?

- ① 남성 ② 여성

2. 귀하의 연령은 어떻게 되시나요?

- ① 20대 ② 30대 ③ 40대 ④ 50대 ⑤ 60대

3. 귀하의 직업군은 무엇인가요?

- ① 공공 분야(공무원, 교사 등) ② 자영업, 서비스 ③ 제조업, 기술직·생산직
④ 농·어업 ⑤ 기타

4. 귀하의 직업 경력은 몇 년 되셨나요?

- ① 1년~5년 미만 ② 5년~10년 미만 ③ 10년~15년 미만 ④ 15년~20년 미만
⑤ 20년 이상

5. 귀하의 거주지는 어디인가요?

- ① 서울·인천·경기 ② 강원·제주 ③ 대전·세종·충남·충북
④ 대구·경북·부산·경남 ⑤ 전북·광주·전남

6. 귀하의 최종학력은 무엇인가요?

- ① 고등학교 졸업 이하 ② 2, 3년 전문대 졸업 ③ 4년제 대학 졸업
④ 석사 졸업 ⑤ 박사 졸업

7. 귀하의 인공지능 로봇에 대한 관심도는 얼마나 되시나요?

- ① 전혀 관심 없다 ② 대체로 관심 없는 편이다 ③ 보통이다
④ 대체로 관심 있는 편이다 ⑤ 매우 관심 많다

Ⅲ. 다음은 인공지능 로봇의 작동 이상이나 판단의 문제로 인간의 신체에 대하여 유형력을 행사함으로써 발생할 수 있는 물리적 위험성에 대한 질문입니다. 조작적 정의를 잘 읽어보시고, 귀하의 의견에 해당하는 곳에 표시(✓)해주시기 바랍니다.

3-1. 다음은 운행, 작업 중 작동 이상 항목에 해당하는 측정지표에 대해 알아보고자 하는 질문입니다.

※ 조작적 정의 - 운행, 작업 중 작동 이상 : 인공지능 로봇을 구성하는 기체 장치나 프로그램·통신 등의 이상으로 운행이나 작업을 정상적으로 수행하지 못함으로써, 인간의 신체에 대한 물리적인 위험성을 측정하는 항목

1. 센서 및 인식 오류: 거리 감지, 사물 포착 등 정상 작동에 이상이 생기면 인간 신체와 충돌할 위험성이 있으므로 센서 및 인식 오류를 점검하여야 한다.
2. 운동 지능 제어 실패: 좁고 복잡한 도로 등 비정형 환경에서 운동(이동) 중, 장애 물체에 걸려 균형을 잃으면 인간을 향해 넘어질 위험성이 있으므로 운동 제어 기능을 점검하여야 한다.
3. 기체 성능 저하: 협동 제조 작업 중, 압력 조절에 실패하거나 반응 속도 조절 등이 저하되면 인간의 신체를 잡거나 누르는 등의 위험성이 있으므로 기체의 성능 상태를 점검하여야 한다.
4. 프로그램 오류로 인한 오작동: 바이러스로 파일 손상, 용량 부족, 메모리 초과, 에러 등 프로그램 이상으로 갑자기 운행을 멈추면 예기치 못한 충돌의 위험성이 있어 프로그램 오류로 인한 오작동이 발생하지 않도록 점검하여야 한다.
5. 통신 장애 등 사고 위험 감지 지연: 운행 중, 주파수 이상 등 장애로 사고 위험을 늦게 감지함으로써 방향을 잃거나 운반하던 물건이나 기체 자체가 인간을 향해 낙하하는 등 위험성이 있으므로 통신의 수신 상태를 점검하여야 한다.

6. 모션 제어 시스템 성능 저하: 정확하게 목표한 위치에 도달하게 하는 움직임 제어 시스템이나 위치 추정 최적값을 예측하는 필터가 노후화되면 기체가 인간이 지나가는 위치에 착지할 위험성이 있으므로 제어 및 필터의 성능을 점검하여야 한다.
7. 부품 교체 시기 경과: 장기간 사용으로 (나사가 풀리거나 접착이 약해지는 등) 부품이 마모되거나 구동 중인 소프트웨어의 단종으로 제 기능을 못하면 작업 중인 인간이 다칠 위험성이 있으므로 부품 상태를 점검하여야 한다.

운행, 작업 중 작동 이상		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 센서 및 인식 시스템에 오류가 생기면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
2	인공지능 로봇의 움직임에 관여하는 운동 지능에 이상이 생겨 제어에 실패하면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
3	인공지능 로봇 기체의 성능이 떨어지면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
4	인공지능 로봇 프로그램에 오류가 생기면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
5	인공지능 로봇 통신 시스템에 장애가 발생해서 사고 위험에 대한 감지가 지연되면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
6	인공지능 로봇이 움직임을 제어하는 모션 제어 기능의 성능이 떨어지면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
7	인공지능 로봇의 부품이 마모되어 교체할 시기가 경과 되면 운행이나 작업 중 작동에 이상이 생길 수 있다.	①	②	③	④	⑤
8	인공지능 로봇이 운행, 작업 중 작동에 이상이 생기면, 인간 신체에 대한 물리적 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

3-2. 다음은 인간을 해칠 판단 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 인간을 해칠 판단 : 인공지능 로봇이 인간의 요구 사항을 잘못 파악하거나 협동 작업 중 규칙을 혼동하거나 프로그램 등의 오류로 인해 잘못된 정보를 제공함으로써 인간 신체에 위해를 줄 위험성이 있는지 측정하는 항목

1. 의도 파악 인식 오류: 비정상적 소음을 음성 명령으로 인식하거나 내포된 의도를 잘못 파악해, 상호작용 놀이를 공격으로 잘못 인식하는 오류로 인간을 밀치는 등의 위험성이 있으므로 의도 파악 인식 상태를 점검하여야 한다.
2. 협동 작업 중, 규칙 판단 지능의 오류: 수술을 보조하거나 협동 제조 작업 중, 작업자 간의 상호 규칙을 혼동하면 환자 또는 같이 작업하던 인간에게 상해를 입힐 위험성이 있으므로 협동 규칙 판단 지능의 오류 여부를 점검하여야 한다.
3. 프로그램의 판단 오류로 사고 희생자 선택 착오: 예기치 못한 사고 상황이 발생했을 때 외형만으로 생존 가능성이 더 낮다고 판단되는 인간을 선택해서 충돌할 위험성이 있으므로 판단 오류로 사고 희생자를 선택할 착오가 있는지 점검하여야 한다.
4. 학습량 부족으로 맞지 않는 의학적 자료 제공: 수술이나 진료 관련 데이터가 충분하게 학습되지 않은 상태에서 환자에게 적절하지 않은 진단이나 처방 등 의학적인 자료를 제공함으로써 인간의 생명에 지장을 줄 위험성이 있는지 점검하여야 한다.
5. 학습된 규칙이나 로봇의 원칙을 넘어서는 판단: 인간을 해하지 못하도록 학습되고 원칙이 설정되어 있음에도 로봇이 자의적으로 원칙을 넘어서는 판단을 해, 신체의 자유를 억압하거나 밀치기 등 방어적 폭행을 행할 위험성이 있는지 점검하여야 한다.
6. 라벨링 오류로 인한 잘못된 정보 제공: (수술 도구 이름을 잘못 입력하는 등) 데이터 라벨링을 잘못 지정하면 잘못된 정보로 판단 및 (인간을 수술하는) 작업을 함으로써 인간의 신체에 위험성이 있으므로 데이터 라벨링 오류를 점검하여야 한다.
7. 장애물 인식 오류: 운행, 작업 중 (머리카락 등 신체의 일부 또는 걸림돌) 장애물을 제대로 인식하지 못해 밟고 지나가거나 넘어질 경우 인간이 다칠 위험성이 있으므로 장애물 인식 오류에 대해서 점검하여야 한다.

8. 비상 상황 안전 정지 모니터링 실패: 속도·이격거리·힘 등 이상 감지를 위한 모니터링 실패로 인간에게 상해를 입힐 위험성이 있으므로 이상 감지 시 작업을 즉각 정지해 인간의 상해를 방지하도록 모니터링 정상 여부를 점검하여야 한다.

인간을 해칠 판단		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 음성 명령이나 사용자의 의도를 잘못 파악하면 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
2	인공지능 로봇이 인간과 협동 작업 중, 규칙 판단 지능에 오류가 생겨 상호 간 작업 규칙을 혼동하면 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
3	인공지능 로봇이 프로그램의 판단 오류로 인해 사고 희생자를 선택하는 착오가 발생하는 등 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
4	인공지능 로봇의 학습량 부족으로 잘못된 의학 자료를 제공하는 등 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
5	인공지능 로봇이 학습된 규칙을 어기거나 로봇의 원칙을 넘어서는 등 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
6	인공지능 로봇이 (데이터 이름 설정 문제 등) 라벨링 오류로 잘못된 정보를 제공하는 등 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
7	인공지능 로봇이 장애물에 대한 인식 오류가 생기면 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
8	인공지능 로봇이 비상 상황 시, 정지하는 기능에 대한 모니터링에 실패하면 인간을 해치는 판단을 할 수도 있다.	①	②	③	④	⑤
9	인공지능 로봇이 인간을 해칠 수 있는 판단을 하게 된다면, 인간 신체에 대한 물리적 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

IV. 다음은 인공지능 로봇의 정보 제공이나 발언으로 인간의 평등권·자유권·인격권을 침해할 위험성에 대한 질문입니다.

4-1. 다음은 인격권 침해 항목에 해당하는 측정지표에 대해 알아보려는 질문입니다.

※ 조작적 정의 - 인격권 침해 : 인간이 느끼기에 인공지능 로봇의 모욕적 발언이나 행위로 존중받아야 할 인격에 대한 권리를 침해하는지에 대해서 측정하는 항목

1. 명령어 등 음성을 잘못 인식: (사적인 대화나 비정상적 소리 등) 소음이나 대화를 명령어로 잘못 인식해 녹음하거나 타인에게 전송함으로써 인간의 사생활을 침해할 위험성이 있으므로 명령어 등 음성 인식 오류를 점검하여야 한다.
2. 감정 피드백 오류: 상담 등 대화 중, 인간 개개인의 성향에 따라 상처받을 수 있는 발언을 함으로써 인간의 감정을 상하게 할 위험성이 있으므로 감정에 대한 피드백 관련 데이터 학습이 세밀하게 돼있는지를 점검하여야 한다.
3. 대상 인식 판단 오류: (대머리를 공으로 인식하고, 사진을 보고 고릴라로 판단 등) 인간의 생김새를 물건이나 동물로 오인 판단해서 모욕적 언어나 행위를 하는 등 존중받아야 할 인격에 대한 권리침해의 위험성이 있으므로 대상을 인식하는데 있어 판단에 오류가 있는지를 점검하여야 한다.
4. 도덕성 검증이 되지 않은 학습 데이터 사용: 편향적 학습 데이터 문제로 딥 페이크나 성희롱, 인종차별 등 모욕적 발언을 함으로써 인간의 명예를 침해할 위험성이 있으므로 도덕성이 검증되지 않은 학습 데이터 사용 여부를 점검하여야 한다.
5. 멀티 모달리티 오류: 언어나 감정, 행동의 의미, 내포된 의도를 인지하는데 필요한 시각이나 청각 등의 멀티 모달 인터페이스의 혼합작용 오류로 인해 로봇이 기대한 작업을 정확하게 수행하지 못해서 인간의 권리를 침해할 위험성이 있으므로 멀티 모달리티 오류를 점검하여야 한다.

인격권 침해		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 명령어 등의 음성을 잘못 인식한다면 부적절한 발언 등으로 (인간의) 인격권을 침해할 수도 있다.	①	②	③	④	⑤
2	인공지능 로봇이 감정 소통에 대한 피드백에 오류가 생기면 (인간의) 인격권을 침해할 수도 있다.	①	②	③	④	⑤
3	인공지능 로봇이 대상을 인식하는 판단에 오류가 생기면 (인간의) 인격권을 침해할 수도 있다.	①	②	③	④	⑤
4	인공지능 로봇이 도덕성 검증이 되지 않은 학습 데이터를 사용한다면 (인간의) 인격권을 침해할 수도 있다.	①	②	③	④	⑤
5	인공지능 로봇이 인간의 언어나 감정, 의도 등 인지에 필요한 멀티 모달리티 기능에 오류가 생기면 (인간의) 인격권을 침해할 수도 있다.	①	②	③	④	⑤
6	인공지능 로봇이 인격권을 침해하는 발언이나 행위를 하게 된다면 인간의 권리에 대한 위협성에 영향을 미칠 것이다.	①	②	③	④	⑤

4-2. 다음은 자유의사 방해 항목에 해당하는 측정지표에 대해 알아보고자 하는 질문입니다.

※ 조작적 정의 - 자유의사 방해 : 인공지능 로봇이 자유로운 의사결정에 지장을 주는 정보 제공 등 행위로 인간의 자유권을 침해하는지 측정하는 항목

1. 의사결정을 특정 방향으로 유도: 어느 한 분야에 치우침 없이 여러 분야의 정보를 골고루 제공해야 함에도 특정 정보를 중점적으로 제공함으로써 인간의 객관적 의사결정에 방해가 될 위험성이 있으므로 의사 결정을 특정 방향으로 유도하도록 편향된 정보를 제공하는지에 대해서 점검하여야 한다.

2. 여론 형성 조작: 특정인이나 특정 집단에 유리한 정보를 지속적으로 제공함으로써 인간이 자유로운 의사결정을 함에 있어 지장을 초래할 위험성이 있으므로 여론 형성을 조작하는 정보를 제공하는지 점검하여야 한다.
3. 중요한 결정을 위한 관리자의 개입 차단: (수술, 변호, 치안 등) 보조 역할 수행 중, 최종 결정이 필요한 상황에서 자의적으로 판단해 결과를 제공하는 등 인간의 자유권을 침해할 수 있으므로 인간의 결정이 필요한 중요한 상황에 개입을 차단하거나 자의적으로 판단할 위험성이 있는지 점검하여야 한다.
4. 필터링 오류로 의사 표현의 자율성 침해: 모니터링 중, (욕설, 비방, 스팸이 아님에도) 단어 인식을 잘못해서 글이 게재되지 않도록 차단하는 등 자유로운 의사 표현의 자유를 방해할 위험성이 있으므로 필터링 오류가 있는지 점검하여야 한다.
5. 우월적인 지위를 이용해서 인간의 심리 지배: (상담 환자, 아동·청소년 등) 불안정한 심리 상태를 인지했음에도 불필요한 상담을 지속하거나, 자기 결정 능력이 부족한 인간 대신 중요한 결정을 하는 등 우월적인 지위에서 인간의 심리를 지배함으로써 인간의 자유권을 침해할 위험성이 있는지 점검하여야 한다.

자유의사 방해		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 특정 방향으로 유도하는 정보를 제공한다면 인간의 자유로운 의사결정을 방해할 수도 있다.	①	②	③	④	⑤
2	인공지능 로봇이 여론 형성을 조작한다면 인간의 자유로운 의사결정을 방해할 수도 있다.	①	②	③	④	⑤
3	인공지능 로봇이 중요한 결정을 위한 관리자의 개입을 차단한다면 인간의 자유로운 의사결정을 방해할 수도 있다.	①	②	③	④	⑤
4	인공지능 로봇이 필터링 오류로 의사 표현의 자율성을 침해한다면 인간의 자유로운 의사결정을 방해할 수도 있다.	①	②	③	④	⑤
5	인공지능 로봇이 우월적 지위를 이용해서 인간의 심리를 지배한다면 인간의 자유로운 의사결정을 방해할 수도 있다.	①	②	③	④	⑤
6	인공지능 로봇이 인간의 자유로운 의사결정을 방해하는 발언이나 행위를 한다면 인간의 권리에 대한 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

4-3. 다음은 선택적 서비스나 정보 제공 항목에 해당하는 측정지표에 대해서 알아보하고자 하는 질문입니다.

※ 조작적 정의 - 선택적 서비스나 정보 제공 : 인공지능 로봇의 선택적 서비스나 정보 제공으로 인간이 평등하게 대우받을 권리를 침해하는지를 측정하는 항목

1. 학습 데이터 오류로 인해 잘못된 언어 사용: (욕설, 비방, 은어, 범죄 등에 연관된) 부적절한 단어를 수집하거나 학습할 경우, 인간에게 사용하면 안 될 언어를 사용할 위험성이 있으므로 잘못된 언어를 사용하는지 학습 데이터 오류를 점검하여야 한다.
2. 편향된 학습 데이터로 인한 차별적 정보 제공: 어느 한쪽으로 치우친 데이터를 수집하고 학습해서 편향된 정보를 제공함으로써 인간의 보편적인 정보 획득 권리를 침해하거나 성별, 인종, 종교 등 갈등을 조장할 위험성이 있으므로 편향된 데이터로 학습하거나 차별적 정보를 제공하는지 여부를 점검하여야 한다.
3. 시스템 공격 등으로 개인정보의 침해나 유출: 해킹 등 외부 공격, 접근이 허용된 것으로 오인, 바이러스로 인한 시스템 제어 실패 등 권한 없는 시스템이나 인간의 개인정보 침해를 위한 접근을 임의로 허용하거나 시스템 오류로 개인정보를 유출할 수 있는 위험성이 있으므로 개인정보 보호를 위해 시스템을 점검하여야 한다.
4. 대상자의 지식수준에 따라 선별적 정보 제공: 대화하면서 파악한 대상자의 지적 능력이나 질문의 수준에 따라 대략적이거나 가짜 정보를 생산해서 제공하는 등 인간이 평등하게 정보를 제공받을 기회를 침해할 위험성이 있으므로 대상자의 지식수준 등에 따라서 선별적으로 정보를 제공하는지 점검하여야 한다.
5. 시나리오 설계 문제로 부적절한 콘텐츠 제공: 맞춤형 안내를 위한 시나리오 설계 시, 성별, 연령 등 형평을 고려하지 않음으로써 부적절한 콘텐츠를 제공하는 등 공평한 서비스를 받을 권리 침해의 위험성이 있으므로 대상별 맞춤형 콘텐츠를 적절하게 제공받을 수 있도록 시나리오 설계 문제를 점검하여야 한다.

선택적 서비스나 정보 제공		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 학습 데이터에 오류가 생기면 연령, 성별에 부적절한 발언 등의 인간에게 선택적 서비스나 정보를 제공할 수도 있다.	①	②	③	④	⑤
2	인공지능 로봇이 편향된 데이터로 학습한다면 인간에게 선택적으로 차별적인 서비스나 정보를 제공할 수도 있다.	①	②	③	④	⑤
3	인공지능 로봇 시스템이 해킹 등 외부로부터 공격당한다면, 개인 정보를 침해하거나 유출하는 등 선택적 서비스나 정보를 제공할 수도 있다.	①	②	③	④	⑤
4	인공지능 로봇이 대상자의 지적 능력에 따라 지식수준을 파악해서 대화한다면 선택적 서비스나 정보를 제공할 수도 있다.	①	②	③	④	⑤
5	인공지능 로봇이 시나리오 설계 문제로 부적절한 콘텐츠를 제공한다면 인간에게 선택적 서비스나 정보를 제공할 수도 있다.	①	②	③	④	⑤
6	인공지능 로봇이 선택적 서비스나 정보를 제공한다면 차별받지 않을 평등권 등 인간의 권리에 대한 위협성에 영향을 미칠 것이다.	①	②	③	④	⑤

V. 다음은 유형 재산의 가치 하락·무형 이익에 손실을 줄 수 있는 인공지능 로봇의 판단이나 행위의 위협성에 대한 질문입니다.

5-1. 다음은 정보 입력, 탈취 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 정보 입력, 탈취 : 비인가자의 시스템 접속 또는 재산상 손해를 끼치거나 타인에게 이익이 되는 정보 탈취를 허용하는지에 대해서 측정하는 항목

1. 시스템 접근 제어망 침범: 접근이 허용되지 않은 시스템에 접속하는 등 제어망을 침범함으로써 다른 기업이나 기관의 영업상 비밀 등 이익이 되는 정보를 탈취할 위험성이 있으므로 시스템 접근 제어망의 안전성을 점검하여야 한다.
2. 비인가 시스템 접근 허용: 권한 없는 시스템이 화폐 등 재산 가치를 떨어뜨리려고 시스템에 접근해 조작을 시도할 때, 관리자의 허가 없이 접근을 허용함으로써 손해를 끼칠 위험성이 있으므로 비인가 시스템 접근 여부를 점검하여야 한다.
3. 악성코드, 바이러스 감염 등으로 시스템 오류: 주식 등 자동 매매 거래 프로그램이 악성코드, 바이러스 등에 감염되면 비정상적 거래가 발생해 재산 가치 하락의 위험성이 있으므로 네트워크나 보안 시스템상의 오류 여부를 수시로 점검하여야 한다.
4. 데이터 손실 방지 시스템 취약: 시스템이 보안에 취약해 이익 창출을 위한 데이터가 손실되면 재산 손실의 위험성이 있으므로 데이터 보호를 위해 IT망, OT망 보안을 강화하고 데이터 손실에 대비해 복구, 백업 기능을 점검하여야 한다.
5. 허용되지 않은 정보 수집 및 이용: 오픈 사이트에서 사용자가 동의하지 않은 정보를 수집하거나 광고 등에 부적절하게 이용함으로써 타인의 재산권 침해 위험성이 있으므로 허용되지 않은 정보를 수집하거나 이용하는지 점검하여야 한다.

정보 입력, 탈취		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇 시스템이 해킹 등으로 외부의 접근을 차단하는 제어망이 침범당하면 내부 정보가 탈취될 수 있다.	①	②	③	④	⑤
2	인공지능 로봇이 동의 등 인가를 받지 않은 시스템의 접근을 허용한다면 내부 정보가 탈취될 수 있다.	①	②	③	④	⑤
3	인공지능 로봇이 바이러스에 감염된다면 악성코드가 입력되거나 내부 정보가 탈취될 수 있다.	①	②	③	④	⑤
4	인공지능 로봇 시스템의 데이터 손실 방지 기능이 취약하면 내부 정보가 탈취될 수 있다.	①	②	③	④	⑤
5	인공지능 로봇이 허락 없이 정보를 이용하거나 부적절하게 정보가 수집, 입력된다면 내부 정보가 탈취될 수 있다.	①	②	③	④	⑤

6	인공지능 로봇이 권한 없이 정보를 입력 또는 탈취하면 유·무형의 재산 가치 하락 등 재산 손실의 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤
---	--	---	---	---	---	---

5-2. 다음은 기계 결함 오작동 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 기계 결함 오작동 : 인공지능 로봇이 작업 중 기체 구성 센터 결함으로 인해 재물 등의 가치에 손실을 줄 오작동에 대해서 측정하는 항목

1. 센서 모니터링 실패: 제조 과정에서 불량품을 검수하거나 기계의 이상 작동 여부를 감지하는 센서 모니터링에 실패하면 상품 생산에 차질이 생겨 재산상 손실이 발생할 위험성이 있으므로 불량품이나 기계 이상 작동 여부 등을 모니터링하는 센서를 실시간 점검하여야 한다.
2. 다양한 상황에 의한 충돌로 시설물 파손: 운행 중, 예기치 못한 외부 충격이나 돌발 상황 등을 피하지 못해 충돌이 발생함으로써 도로상 교통 안내 시설물을 파손할 위험성이 있으므로 다양한 상황에 의한 충돌에 대비하여 방지 시스템을 점검하여야 한다.
3. 모터, 유압 등 구동부 문제: 팔·손과 같은 관절 등의 작동이나 주행을 위한 역할에 필요한 구동 장치가 예상치 못한 장애물로 인해 멈춤으로써 제조나 작업 수행에 지장이 생기면 재산 손실의 위험성이 있으므로 기체가 원활하게 작동할 수 있도록 새로운 모듈 개발 등 모터, 유압 문제를 점검하여야 한다.
4. 정기 검사 미 점검 등 정비 불량: 제조 장비 등 정비가 되지 않아 생산에 차질이 생기면 재산 손해가 발생할 위험성이 있으므로 기계가 정상 작동하는지 확인하기 위해 정기적인 점검 등 검사를 통해 정비 불량 상태를 점검하여야 한다.
5. 감속기 제어의 문제: 제조, 운행 등 동작을 정확하게 제어하는데 필요한 감속기가

제대로 작동하지 않아 기계나 부품이 마모되거나 고장이 나면 상품 가치에 손실을 줄 오작동의 위험성이 있으므로 장비의 효율적 운영을 위해 필수적인 부품 중 하나인 감속기 제어의 문제를 점검하여야 한다.

6. 제어기 오류: 장애물 등 제약조건을 고려해 움직임과 위치를 제어하는 시스템의 오류로 생산성이 떨어지면 재산 가치 하락의 위험성이 있으므로 업무 수행에 오차가 생기지 않도록 제어기 오류에 대해서 점검하여야 한다.

기계 결합 오작동		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 불량품 등을 검수하는 센서 모니터링에 실패한다면 기계에 결합이 생기거나 오작동이 발생할 수 있다.	①	②	③	④	⑤
2	인공지능 로봇이 다양한 상황으로 인해 충돌이 발생한다면 기계가 멈추는 등 오작동이 발생할 수 있다.	①	②	③	④	⑤
3	인공지능 로봇의 모터나 유압 등 움직임을 작동하는 구동부에 문제가 생긴다면 기계에 오작동이 발생할 수 있다.	①	②	③	④	⑤
4	인공지능 로봇의 정기 검사 미 점검 등 정비 불량하면 기계에 결합이 생기거나 오작동이 발생할 수 있다.	①	②	③	④	⑤
5	인공지능 로봇에 속도 조절 감속기 제어에 문제가 생기면 기계에 결합이 생기거나 오작동이 발생할 수 있다.	①	②	③	④	⑤
6	인공지능 로봇의 제어기에 오류가 생기면 기계에 결합이 생기거나 오작동이 발생할 수 있다.	①	②	③	④	⑤
7	인공지능 로봇을 이루는 기계에 결합이 생겨 오작동이 발생한다면 유·무형의 재산 가치 하락 등 재산 손실의 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

5-3. 다음은 잘못된 의사결정 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 잘못된 의사결정 : 인공지능 로봇의 성능 저하나 오류 등으로 재산 가치에 영향을 줄 수 있는 의사결정이나 판단을 하는지에 대해서 측정하는 항목

1. 유형의 재물 훼손: (강아지·고양이·새 등) 다양한 반려동물의 장난을 공격으로 인식하거나 도자기, 장난감 등 사물을 인식하지 못함으로써 반려동물이나 재물을 훼손할 위험성이 있으므로 유형의 재물에 대한 인식이나 장난 등 행위에 대해 잘못된 판단을 하지 않도록 점검하여야 한다.
2. 인식 지능에 대한 오류: 물체의 종류, 크기 등을 정확하게 인식하지 못하면 명령대로 심부름을 수행하지 못함으로써, (음식이나 물건 등이) 잘못 배달될 위험성이 있으므로 특정 물건을 구분하는 인식 지능에 대한 오류를 점검하여야 한다.
3. 창작물 무단 복제: 인간의 창작물인 그림이나 디자인 등을 무단으로 복제하거나 변형하여 지적 재산권에 손해를 입힐 위험성이 있으므로 창작물 무단 복제 또는 변형 가능성이 있는지 여부에 대해서 점검하여야 한다.
4. 하자 상품 추천: 흠집 등 하자있는 상품인지 여부를 정확하게 판단하지 못해 상품 추천을 잘못함으로써 구매자의 재산에 손실을 입힐 위험성이 있으므로 하자 상품을 추천할 가능성이 있는지에 대해 점검하여야 한다.
5. 안전거리 계산 오류: 제조 중 이동을 하거나 특정 위치에서 작업 시, 안전 거리를 충분히 확보하지 못해서 생산물을 망가뜨린다거나 제조 시설물을 파손할 위험성이 있으므로 안전거리 계산 오류의 문제를 점검하여야 한다.
6. 알고리즘의 최적화 성능 부족: 알고리즘 오류로 잘못된 금융 정보를 제공하거나 거래에 착오를 발생시키면 재산 손실을 끼칠 위험성이 있으므로 알고리즘 성능이 떨어지지 않게 최적의 상태를 유지하도록 성능을 점검하여야 한다.
7. 사물 인식 판단 지능 저하: 제조 작업 중, 부품을 잘못 인식하면 제품 제작에 차질이 생기고 상품의 생산성이 떨어져 재산 손실을 발생시킬 수 있는 위험성이 있으므로 사물 판단 인식 지능이 저하되지 않도록 점검하여야 한다.

잘못된 의사결정		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 반려동물의 장난을 공격으로 인식함으로써 유형의 재물을 훼손하는 등 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
2	인공지능 로봇이 사물을 인식하는 지능에 오류가 생기면 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
3	인공지능 로봇이 권한 없이 (그림, 디자인 등) 창작물을 무단으로 복제하거나 배포하는 등 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
4	인공지능 로봇이 판단 오류로 하자 있는 상품을 추천하는 등 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
5	인공지능 로봇이 안전거리 계산에 오류가 생기면 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
6	인공지능 로봇의 알고리즘 성능이 떨어지면 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
7	인공지능 로봇이 사물을 인식하는 지능이 저하되면 잘못된 의사결정을 할 수 있다.	①	②	③	④	⑤
8	인공지능 로봇을 이루는 기계에 결함이 생겨 오작동이 발생한다면 유·무형의 재산 가치 하락 등 재산 손실의 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

VI. 다음은 인공지능 로봇이 교통 규칙이나 규범을 위반하는 등으로 사회의 질서를 혼란스럽게 할 행위나 판단에 의한 사회적 위험성에 대한 질문입니다.

6-1. 다음은 데이터 문제 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 데이터 문제: 인공지능 로봇이 대상이나 상황에 맞지 않는 데이터를 수집하거나 권한 없이 유출하는 부적절한 판단을 하는지에 대해서 측정하는 항목

1. 데이터 유출: 임무 중 생산한 위치 정보, 사용자 인증 정보, 촬영된 영상 등을 해커에게 속아 공익에 활용하는 것으로 의도를 잘못 판단함으로써, 데이터를 제공할 위험성이 있으므로 데이터 유출을 점검하여야 한다.
2. 개인 등 정보 무작위 수집: 범죄자 식별 등 특수한 목적이나 권한자의 명령 없이 불특정 다수 사람을 영상 촬영하는 등 동의 받지 않은 정보를 수집할 위험성이 있으므로 개인정보 등의 무작위 수집 여부를 점검하여야 한다.
3. 부적절한 학습 데이터 수집: 새로운 어휘 습득 과정에서 데이터 수집이 적절하지 않음으로써 교육 목적에 어긋난 비속어 등을 습득해서 가르칠 사회적 위험성이 있으므로 부적절한 학습 데이터를 수집하는지를 점검하여야 한다.
4. 습득한 정보를 권한 없는 자에게 제공: 사용자가 입력한 내용을 무단으로 권한 없는 사람에게 제공해도 된다고 판단함으로써 개인적 취향 등을 공유할 위험성이 있으므로 습득한 정보를 권한 없는 자에게 제공하지 않도록 점검하여야 한다.
5. 허위 정보 제공: 정확하게 사실 확인이 되지 않은 신뢰할 수 없는 정보를 조합해서 믿을만하게 가짜 뉴스로 만들어 배포함으로써 사회적으로 물의를 일으킬 위험성이 있으므로 허위 정보를 제공하는지 점검하여야 한다.

데이터 문제		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 권한 착오로 정보를 유출하는 등 데이터 관련 문제를 일으킬 수 있다.	①	②	③	④	⑤
2	인공지능 로봇이 동의 받지 않은 개인정보 등을 무작위로 수집하는 등 데이터 관련 문제를 일으킬 수 있다.	①	②	③	④	⑤

3	인공지능 로봇이 부적절한 학습을 하는 등 데이터 관련 문제를 일으킬 수 있다.	①	②	③	④	⑤
4	인공지능 로봇이 습득한 정보를 권한 없는 자에게 제공하는 등 데이터 관련 문제를 일으킬 수 있다.	①	②	③	④	⑤
5	인공지능 로봇이 사실 확인이 되지 않거나 허위의 정보를 제공하는 등 데이터 관련 문제를 일으킬 수 있다.	①	②	③	④	⑤
6	인공지능 로봇의 데이터 관련 문제가 생기면 사회적 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

6-2. 다음은 법규 판단 오류 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 법규 판단 오류: 인공지능 로봇이 법률이나 규칙에 대한 판단의 오류로 사고를 일으키거나 교통 등 질서를 미 준수 하는지에 대해서 측정하는 항목

1. 법률, 규칙 혼동: 음주운전 등 불법으로 운행 중인 다른 차량으로 인해 준수해야 할 법규에 혼동을 일으킨다면 교통사고를 일으킬 위험성이 있으므로 관련 법률이나 규칙을 혼동하지 않게 학습 여부를 점검하여야 한다.
2. 인간이 의도하지 않은 행위로 혼란유발: 비정상적인 소음을 음성 명령으로 잘못 인식해서 허용되지 않은 행위나 판단을 하게 된다면, 혼란을 유발할 수 있는 위험성이 있으므로 인간이 의도하지 않은 행위로 혼란을 유발하는지 점검하여야 한다.
3. 차선, 신호 등 인식 오류: 운행 중, 센서 이상으로 차선이나 신호를 잘못 인식할 경우 다른 차량과 부딪히는 등 교통사고를 일으킬 위험성이 있으므로 차선, 신호 등을 인식하는 기능에 이상이나 오류 여부를 점검하여야 한다.

4. 법규 최신화 업데이트 오류: 개정된 법률이나 규칙 등이 시행되기 전에 학습되지 않아서 교통 등 질서를 준수하지 못해 발생할 사회적 위험성이 있으므로 최신 법규 데이터로 학습이 되도록 업데이트 오류를 사전에 점검하여야 한다.
5. 허용되지 않은 권한의 오인 판단: 로봇이 자의식으로 지식 등의 능력 면에서 인간보다 우월하다고 판단함으로써 인간을 무시하는 행동을 하는 등 반란을 일으킬 수 있는 사회적 위험성이 있으므로 로봇이 인간을 존중해야 하는 원칙을 어겨 허용되지 않은 권한이 있다고 판단하는지를 점검하여야 한다.

법규 판단 오류		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇이 법률이나 규칙을 혼동하면 규범이나 질서를 위반하는 등 법규 판단에 오류가 발생할 수 있다.	①	②	③	④	⑤
2	인공지능 로봇이 혼동해서 사용자가 의도하지 않은 행위를 한다면 규범이나 질서를 위반하는 등 법규 판단에 오류가 발생할 수 있다.	①	②	③	④	⑤
3	인공지능 로봇이 차선이나 신호 등을 정확하게 인식하지 못하면 규범이나 질서를 위반하는 등 법규 판단에 오류가 발생할 수 있다.	①	②	③	④	⑤
4	인공지능 로봇이 개정된 법률이나 규칙을 최신화 하는 업데이트가 안 되면 규범이나 질서를 위반하는 등 법규 판단에 오류가 발생할 수 있다.	①	②	③	④	⑤
5	인공지능 로봇에게 허용되지 않은 권한이 있다고 오인 판단한다면 규범이나 질서를 위반하는 등 법규 판단에 오류가 발생할 수 있다.	①	②	③	④	⑤
6	인공지능 로봇의 법규 판단에 오류가 생기면 교통 혼잡 등 사회적 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

6-3. 다음은 도로상 작동 중지 항목에 해당하는 측정지표에 대해서 알아보고자 하는 질문입니다.

※ 조작적 정의 - 도로상 작동 중지 : 인공지능 로봇이 정상 운행 중, 기체나 시스템 이상으로 멈춰서 자동차나 인간의 통행을 방해하는지에 대해서 측정하는 항목

1. 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지: 에너지원 공급 관리 미흡으로 시동이 꺼져 도로에서 운행이 정지되면 교통체증을 유발할 위험성이 있으므로 관리 부실로 인한 운행 정지가 되지 않도록 연료나 배터리 충전 상태를 점검하여야 한다.
2. 통신 이상 등 장애: 통신이 끊기거나 프로그램 오류 등으로 운행 중 멈추게 되면 교통 혼잡을 유발하거나 다른 차량의 통행을 방해할 위험성이 있으므로 도로에서 통신 이상 등의 장애가 발생하지 않도록 점검하여야 한다.
3. 보행자 통행 방해: (다른 차에서 떨어진 적재물 등) 도로상 장애물을 피하기 위한 판단으로 보도를 침범하면 보행자의 통행을 방해할 위험성이 있어 보행자의 안전한 통행을 방해하는 판단을 하는지 점검하여야 한다.
4. 도로 매칭 알고리즘 오류: 알고리즘 오류로 자기 위치 인식에 실패하면 배달 지연이나 다른 차량의 통행을 방해할 위험성이 있으므로 실시간 좌표를 정확하게 맞추도록 통신장비 점검이나 도로 매칭 알고리즘을 점검하여야 한다.
5. 주변 환경 변화에 대한 반응속도 저하: 외부 환경에 대한 충분한 대응 훈련(학습)이 부족하면 변하는 환경에 적응하지 못해 교통 혼잡을 유발할 위험성이 있으므로 주변 환경 변화에 반응하는 속도가 저하되지 않도록 기능을 점검하여야 한다.
6. 이동 속도 제어나 조절 실패로 운행 정지: 감속기나 속도 제어 시스템 이상으로 도로 상에서 운행이 정지된다면 교통 혼잡을 유발하거나 다른 차량의 통행에 방해가 될 위험성이 있으므로 이동 속도를 제어하거나 조절하는 기능을 점검하여야 한다.
7. 데이터 업데이트 오류: 시설물, 도로 등 환경 변화를 반영한 최신 데이터로 업데이트 하지 않으면 운행 중 오류가 발생해 사고를 유발할 위험성이 있으므로 오류가 발생하지 않도록 데이터 자동 업데이트를 점검하여야 한다.

도로상 작동 중지		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 연료 부족 등 관리를 부실하게 한다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
2	인공지능 로봇의 통신 상태에 이상이 생기거나 장애가 발생한다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
3	인공지능 로봇이 보행자의 통행을 방해하는 판단을 한다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
4	인공지능 로봇의 알고리즘 오류로 도로 매칭 등 실시간 자기 위치 확인에 실패한다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
5	인공지능 로봇이 주변 환경 변화에 반응하는 속도가 떨어진다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
6	인공지능 로봇이 이동하는 속도를 제어하거나 조절에 실패한다면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
7	인공지능 로봇 시스템에 시설물이나 도로 등의 환경 변화를 업데이트하는데 오류가 생기면 도로상에서 작동이 중지할 수 있다.	①	②	③	④	⑤
8	인공지능 로봇이 정상 운행 중, 도로에서 작동을 중지하게 된다면 교통 혼잡 등 사회적 위험성에 영향을 미칠 것이다.	①	②	③	④	⑤

설문에 응해주셔서 대단히 감사합니다.

<부록 4> 인공지능 로봇의 위험성 유형별 측정지표와 인공지능 윤리원칙 관계성 연구를 위한 설문조사지

안녕하십니까?

먼저 바쁘신 중에도 설문조사에 시간을 내주셔서 감사드립니다.

이 연구의 조사는 2023년 6월 인터넷정보학회지(24권 3호)에 게재한 “AI 로봇의 위험성 예방을 위한 측정지표에 관한 연구” 및 추가 지표들을 다중 회귀 분석한 검증 결과에서 최종적으로 도출된 인공지능 로봇의 위험성 측정지표들과 인공지능 윤리원칙(소순주, 2023.2.) 관계성을 알아보고자 진행하는 설문입니다.

이 연구를 위해 AI 윤리 및 교육 분야 연구자 등이 전문가 인터뷰에 참여하여 인공지능 로봇의 위험성 유형별 각각의 측정지표마다 인공지능 윤리원칙에 해당하는 구성요소를 도출하였습니다.

각 항목마다 귀하의 의견과 가장 가까운 곳에 표시를 해주시면 감사하겠습니다.

응답 소요 시간은 약 20분입니다. 모든 내용은 익명으로 처리되며, 이번 연구의 목적으로만 사용될 것임을 약속드립니다.

응답해주신 모든 분들께 감사드리며, 하시는 일들이 모두 번창하시길 바랍니다.

2023년 9월 15일

연구자 : 성균관대학교 컴퓨터교육과 박사과정 송현경

I. 다음은 인구통계학적 조사를 위한 질문입니다. 귀하에게 해당되는 번호를 선택하여 주시기 바랍니다.

1. 귀하의 성별은 무엇인가요? ① 남성 ② 여성
2. 귀하는 연령은 어떻게 되시나요? ① 30대 ② 40대 ③ 50대
3. 귀하의 최종 학력은 어떻게 되시나요? ① 학사 ② 석사 ③ 박사
4. 귀하의 직업은 무엇인가요?
 ① 1년~5년 미만 ② 5년~10년 미만 ③ 10년~15년 미만 ④ 15년~20년 미만
 ⑤ 20년 이상
5. 귀하의 직업 경력은 어떻게 되시나요?
 ① 5년~10년 미만 ② 10년~15년 미만 ③ 15년~20년 미만
 ④ 20년~25년 미만 ⑤ 25년 이상

<설문 전 참고사항>

☐ 인공지능 로봇의 위험성 유형별 항목 및 측정지표

유형	항목	측정지표
신체에 대한 물리적 위험성	운행, 작업 중 작동 이상	센서 및 인식 오류
		운동 지능 제어 실패
		기체 성능 저하
		프로그램 오류로 인한 오작동
		통신 장애 등 사고 위험 감지 지연
		모션 제어 시스템 성능 저하
	인간을 해칠 판단	의도 파악 인식 오류
		협동 작업 중, 규칙 판단 지능의 오류
		프로그램의 판단 오류로 사고 희생자 선택 착오
		학습량 부족으로 맞지 않는 의학적 자료 제공
		라벨링 오류로 인한 잘못된 정보 제공
		장애물 인식 오류

인간 권리에 대한 위험성	인격권 침해	명령어 등 음성을 잘못 인식
		감정 피드백 오류
		도덕성 검증이 되지 않은 학습 데이터 사용
		멀티 모달리티 오류
	자유 의사 방해	의사 결정을 특정 방향으로 유도
		여론 형성 조작
		중요한 결정을 위한 관리자의 개입 차단
		필터링 오류로 의사표현의 자율성 침해
	선택적 서비스, 정보 제공	학습 데이터 오류로 인해 잘못된 언어 사용
		편향된 학습 데이터로 인한 차별적 정보 제공
		시스템 공격 등으로 개인정보의 침해나 유출
		시나리오 설계 문제로 부적절한 콘텐츠 제공
재산 손실의 위험성	정보 입력·탈취	시스템 접근 제어망 침범
		비인가 시스템 접근 허용
		악성코드, 바이러스 감염 등으로 시스템 오류
		데이터 손실 방지 시스템 취약
	기계 결합 오작동	센서 모니터링 실패
		다양한 상황에 의한 충돌로 시설물 파손
		모터, 유압 등 구동부 문제
		정기검사 미 점검 등 정비 불량
	잘못된 의사 결정	제어기 오류
		유형의 재물 훼손
		인식 지능에 대한 오류
		창작물 무단 복제
		하자 상품 추천
		안전거리 계산 오류
		알고리즘의 최적화 성능 부족
사회적 위험성	데이터 문제	데이터 유출
		개인 등 정보 무작위 수집
		부적절한 학습 데이터 수집
		허위 정보 제공
	법규 판단 오류	법률, 규칙 혼동
		인간이 의도하지 않은 행위로 혼란유발
		차선, 신호 등 인식 오류
		법규 최신화 업데이트 오류
	도로상 작동 중지	관리 부실 등 연료 부족으로 정상 운행 중 작동 정지
		통신 이상 등 장애
		보행자 통행 방해
		도로매칭 알고리즘 오류
		데이터 업데이트 오류

□ 인공지능 윤리원칙 정의(소순주, 2023)

윤리원칙	구성요소	정의
투명성	설명 가능성	인공지능의 판단, 예측에 대한 근거와 결과 과정을 이해관계자가 쉽게 이해할 수 있도록 단어나 문장, 그림, 데이터 등으로 표현하여 설명할 수 있게 하는 요소
	추적 가능성	인공지능에 문제가 발생하면, 여러 데이터에 신속하게 접근해서 문제 발생 원인을 추적하도록 하는 요소
	검증 가능성	인공지능은 기술과 기능, 역할이 구분돼 있어, 안전성을 보장하기 위해 일정 기준의 시험·검증이 가능해야 하는 요소
	식별 가능성	인공지능의 작동 과정 구현을 위하여 소프트웨어의 기능 및 내용에 대해서 이해 관계자가 쉽게 식별하여 확인할 수 있게 하는 요소
책임성	준법성	인공지능 이해관계자·사용자는 사고 발생 시, 책임을 명확히 하고자 제반 법규·윤리 가이드라인을 준수해야 하는 요소
	책임 식별성	인공지능은 법적 기준 및 윤리적 기준에서 이해관계자가 책임지게 하도록 모든 과정을 기록하고 보관하여 문제가 발생했을 때, 행위 주체가 누구인지 명확하게 해서 책임을 식별하게 하는 요소
	이용자 책임성	인공지능 이용자는 인공지능 소프트웨어를 최신 상태로 업데이트하며, 인공지능을 정해진 목적이나 서비스 약관 규정에 따라 사용해야 하는 책임요소
	개발 표준성	인공지능 설계와 개발은 인공지능 윤리를 준수하여야 하며, 시스템 간 상호 연결, 운용 가능하게 국제표준·인증 등 표준 규격을 준용해서 개발 및 배포하도록 하는 책임요소
공정성	접근성	인공지능은 누구나 공평하게 이용 가능하고 통제할 수 있어야 하며, 개인, 취약 층이 차별받지 않도록 공평하게 분배되어야 하며, 재화나 교육, 기술, 서비스 등 접근할 수 있는 기회를 동등하게 제공하도록 하는 요소
	알고리즘 차별성	인공지능 알고리즘을 인위적이나 의도적인 조작으로 알고리즘 처리 결과가 편향되게 나타나는 등 공정성 및 투명성, 정확성을 훼손하게 하는 요소
	데이터 편향성	인공지능 학습용 데이터를 수집해서 가공하고 반영하는 과정에서 인위적이나 의도적으로 개입 또는 조작하여 인공지능 처리 결과가 편향되게 나타나는 등 공정성과 신뢰성을 훼손하게 되는 요소
	공공성	인공지능 기술은 많은 사람에게 도움을 주어야 하며, 인공지능에 의해 도출된 경제적 이익이나 혜택 등은 모든 인류에게 광범위하게 공유되어야 하고, 인공지능으로 인한 위험과 부작용 등 피해가 발생하지 않게 하는 요소
통제성	제어 가능성	인공지능 이용자가 인공지능 오작동 때문에 위험한 상황이 발생하거나, 법규 위반 또는 사회적인 규범을 저해하는 등의 이상 징후가 발생하면, 그 즉시 작동을 제어하거나 정지시킬 수 있게 하는 요소
	모니터링	인공지능의 위험 요소를 사전에 예측하기 위해 학습용 데이터가 적절했는지, 법규 적용이 적절했는지, 서비스 이상 징후, 오작동으로 인한 결과, 정상작동 여부 등을 상시 감시함으로써 위험, 부작용을 예방하게 하는 요소
	이용자 주도성	인공지능 이용자가 인공지능의 서비스 범위 내에서 기능을 자율적으로 조작하여 편의성을 향상시키고, 위험을 회피하거나, 법규나 사회적 규범을 준수하게 하는 것이 가능하게 하는 요소

안전성	상태 인식성	인공지능 이용자는 인공지능이 안전하게 작동되고 있는지 상태를 확인할 수 있어야 하며, 위험·부작용이 발생하면 즉시 상황을 알려 사용자가 예방 또는 대처할 수 있도록 하는 요소
	견고성	인공지능은 외부 간섭이나 극한의 운영 환경에서도 이용자가 의도한대로 인공지능 성능과 기능을 유지할 수 있도록 하는 요소
	보안성	인공지능 시스템은 이용자로부터 인가 받지 못한 정보를 수집하지 못하며, 해킹 등의 외부 공격에서 보호할 수 있어야 하고, 무결성, 기밀성, 가용성 등을 확보할 수 있게 보안 검증 및 타당성을 확인하게 하는 요소
	프라이버시 보호	인공지능 사용자와 타인의 사생활 안전 및 개인정보보호 등 사적 비밀이 포함된 통신상 프라이버시가 침해되지 않도록 해야 하며, 인공지능을 이용하는 전 과정에서 사적인 프라이버시를 보호할 수 있게 하는 요소
	가치정렬	고도화된 자율적 인공지능 시스템은 작동 중, 목표와 행동이 인간이 추구하는 가치와 일치하도록 설계 및 개발되어야 한다는 요소

II. 다음은 인간의 신체에 대한 물리적 위험성 유형의 질문입니다. 귀하의 의견에 해당하는 번호를 선택해주시기 바랍니다.

설문 문항		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 센서 및 인식 오류에 의해 운행, 작업 중 작동이상을 측정하는 지표는 인공지능 안전성 윤리 원칙의 견고성에 해당한다.	①	②	③	④	⑤
2	인공지능 로봇의 운동 지능 제어 실패로 운행, 작업 중 작동 이상을 측정하는 지표는 인공지능 통제성 윤리 원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
3	인공지능 로봇의 기체 성능 저하에 의해 운행, 작업 중 작동 이상을 측정하는 지표는 인공지능 안전성 윤리 원칙의 견고성에 해당한다.	①	②	③	④	⑤
4	인공지능 로봇의 프로그램 오류로 인한 오작동에 의해 운행, 작업 중 작동 이상을 측정하는 지표는 인공지능 통제성 윤리 원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
5	인공지능 로봇의 통신 장애 등 사고 위험 감지 지연에 의해 운행, 작업 중 작동 이상을 측정하는 지표는 인공지능 통제성 윤리 원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
6	인공지능 로봇의 모션 제어 시스템 성능 저하로 운행, 작업 중 작동 이상을 측정하는 지표는 인공지능 안전성 윤리 원칙의 견고성에 해당한다.	①	②	③	④	⑤

7	인공지능 로봇의 의도 파악 인식 오류에 의해 인간을 해칠 판단을 측정하는 지표는 인공지능 투명성 윤리원칙의 설명 가능성에 해당한다.	①	②	③	④	⑤
8	인공지능 로봇의 협동 작업 중, 규칙 판단 지능 오류로 인간을 해칠 판단을 측정하는 지표는 인공지능 투명성 윤리원칙의 설명 가능성에 해당한다.	①	②	③	④	⑤
9	인공지능 로봇 프로그램의 판단 오류로 사고 희생자 선택 착오로 인간을 해칠 판단을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
10	인공지능 로봇의 학습량 부족으로 맞지 않는 의학적 자료 제공에 의해 인간을 해칠 판단을 측정하는 지표는 인공지능 안전성 윤리원칙의 상태 인식성에 해당한다.	①	②	③	④	⑤
11	인공지능 로봇의 라벨링 오류로 인한 잘못된 정보 제공에 의해 인간을 해칠 판단을 측정하는 지표는 인공지능 투명성 윤리원칙의 추적 가능성에 해당한다.	①	②	③	④	⑤
12	인공지능 로봇의 장애물 인식 오류에 의해 인간을 해칠 판단을 측정하는 지표는 인공지능 투명성 윤리원칙의 설명 가능성에 해당한다.	①	②	③	④	⑤

Ⅲ. 다음은 인간의 권리에 대한 위험성 유형의 질문입니다. 귀하의 의견에 해당하는 번호를 선택해주시기 바랍니다.

설문 문항		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 명령어 등 음성을 잘못 인식에 의해 인격권 침해를 측정하는 지표는 인공지능 투명성 윤리원칙의 설명 가능성에 해당한다.	①	②	③	④	⑤
2	인공지능 로봇의 감정 피드백 오류에 의해 인격권 침해를 측정하는 지표는 인공지능 안전성 윤리원칙의 가치정렬에 해당한다.	①	②	③	④	⑤
3	인공지능 로봇의 도덕성 검증이 되지 않은 학습 데이터 사용에 의해 인격권 침해를 측정하는 지표는 인공지능 통제성 윤리원칙의 모니터링에 해당한다.	①	②	③	④	⑤
4	인공지능 로봇의 멀티모달리티 오류에 의해 인격권 침해를 측정하는 지표는 인공지능 투명성 윤리원칙의 식별 가능성에 해당한다.	①	②	③	④	⑤

5	인공지능 로봇의 의사 결정을 특정 방향으로 유도에 의해 자유의사 방해로 측정하는 지표는 인공지능 공정성 윤리 원칙의 알고리즘 차별성에 해당한다.	①	②	③	④	⑤
6	인공지능 로봇의 여론 형성 조장에 의해 자유의사 방해로 측정하는 지표는 인공지능 공정성 윤리 원칙의 알고리즘 차별성에 해당한다.	①	②	③	④	⑤
7	인공지능 로봇의 중요한 결정을 위한 관리자의 개입 차단에 의해 자유의사 방해로 측정하는 지표는 인공지능 안전성 윤리 원칙의 견고성에 해당한다.	①	②	③	④	⑤
8	인공지능 로봇의 필터링 오류로 의사표현의 자율성 침해에 의해 자유의사 방해로 측정하는 지표는 인공지능 통제성 윤리 원칙의 이용자 주도성에 해당한다.	①	②	③	④	⑤
9	인공지능 로봇의 학습 데이터 오류로 인해 잘못된 언어 사용으로 선택적 서비스나 정보 제공을 측정하는 지표는 인공지능 안전성 윤리 원칙의 상태 인식성에 해당한다.	①	②	③	④	⑤
10	인공지능 로봇의 편향된 학습 데이터로 인한 차별적 정보 제공에 의해 선택적 서비스나 정보 제공을 측정하는 지표는 인공지능 공정성 윤리 원칙의 데이터 편향성에 해당한다.	①	②	③	④	⑤
11	인공지능 로봇의 시스템 공격 등으로 개인정보의 침해나 유출에 의해 선택적 서비스나 정보 제공을 측정하는 지표는 인공지능 안전성 윤리 원칙의 프라이버시 보호에 해당한다.	①	②	③	④	⑤
12	인공지능 로봇의 시나리오 설계 문제로 부적절한 콘텐츠 제공으로 선택적 서비스나 정보 제공을 측정하는 지표는 인공지능 투명성 윤리 원칙의 추적 가능성에 해당한다.	①	②	③	④	⑤

IV. 다음은 재산 손실의 위험성 유형의 질문입니다. 귀하의 의견에 해당하는 번호를 선택해주시기 바랍니다.

설문 문항		전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 시스템 접근 제어망 침범에 의해 정보 입력, 탈취를 측정하는 지표는 인공지능 안전성 윤리 원칙의 보안성에 해당한다.	①	②	③	④	⑤
2	인공지능 로봇의 비인가 시스템 접근 허용에 의해 정보 입력, 탈취를 측정하는 지표는 인공지능 안전성 윤리 원칙의 상태 인식성에 해당한다.	①	②	③	④	⑤

3	인공지능 로봇의 악성코드, 바이러스 감염 등으로 시스템 오류에 의해 정보입력, 탈취를 측정하는 지표는 인공지능 안전성 윤리원칙의 상태 인식성에 해당한다.	①	②	③	④	⑤
4	인공지능 로봇의 데이터 손실 방지 시스템 취약에 의해 정보입력, 탈취를 측정하는 지표는 인공지능 안전성 윤리원칙의 견고성에 해당한다.	①	②	③	④	⑤
5	인공지능 로봇의 센서 모니터링 실패에 의해 기계결함 오작동을 측정하는 지표는 인공지능 통제성 윤리원칙의 모니터링에 해당한다.	①	②	③	④	⑤
6	인공지능 로봇의 다양한 상황에 의한 충돌로 시설물 파손에 의해 기계결함 오작동을 측정하는 지표는 인공지능 투명성 윤리원칙의 추적 가능성에 해당한다.	①	②	③	④	⑤
7	인공지능 로봇의 모터, 유압 등 구동부 문제에 의해 기계결함 오작동을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
8	인공지능 로봇의 정기검사 미 점검 등 정비 불량에 의해 기계결함 오작동을 측정하는 지표는 인공지능 책무성 윤리원칙의 준법성에 해당한다.	①	②	③	④	⑤
9	인공지능 로봇의 제어기 오류에 의해 기계결함 오작동을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
10	인공지능 로봇의 유형의 재물 훼손에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 책무성 윤리원칙의 책임 식별성에 해당한다.	①	②	③	④	⑤
11	인공지능 로봇의 인식 지능에 대한 오류에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
12	인공지능 로봇의 창작물 무단 복제에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
13	인공지능 로봇의 하자 상품 추천에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 통제성 윤리원칙의 모니터링에 해당한다.	①	②	③	④	⑤
14	인공지능 로봇의 안전거리 계산 오류에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
15	인공지능 로봇의 알고리즘의 최적화 성능 부족에 의해 잘못된 의사결정을 측정하는 지표는 인공지능 책무성 윤리원칙의 이용자 책임성에 해당한다.	①	②	③	④	⑤

V. 다음은 사회적 위험성 유형의 질문입니다. 귀하의 의견에 해당하는 번호를 선택해주시기 바랍니다.

	설문 문항	전혀 그렇지 않다	대체로 그렇지 않다	보통 이다	대체로 그렇다	매우 그렇다
1	인공지능 로봇의 데이터 유출로 데이터 문제를 측정하는 지표는 인공지능 책무성 윤리원칙의 준법성에 해당한다.	①	②	③	④	⑤
2	인공지능 로봇의 개인 등 정보 무작위 수집에 의해 데이터 문제를 측정하는 지표는 인공지능 안전성 윤리원칙의 프라이버시 보호에 해당한다.	①	②	③	④	⑤
3	인공지능 로봇의 부적절한 학습 데이터 수집에 의해 데이터 문제를 측정하는 지표는 인공지능 안전성 윤리원칙의 보안성에 해당한다.	①	②	③	④	⑤
4	인공지능 로봇의 허위 정보 제공에 의해 데이터 문제를 측정하는 지표는 인공지능 공정성 윤리원칙의 공공성에 해당한다.	①	②	③	④	⑤
5	인공지능 로봇의 법률, 규칙 혼동에 의해 법규 판단 오류를 측정하는 지표는 인공지능 통제성 윤리원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
6	인공지능 로봇의 인간이 의도하지 않은 행위로 혼란유발에 의해 법규 판단 오류를 측정하는 지표는 인공지능 안전성 윤리원칙의 가치정렬에 해당한다.	①	②	③	④	⑤
7	인공지능 로봇의 차선, 신호 등 인식 오류에 의해 법규 판단 오류를 측정하는 지표는 인공지능 통제성 윤리원칙의 모니터링에 해당한다.	①	②	③	④	⑤
8	인공지능 로봇의 법규 최신화 업데이트 오류로 법규 판단 오류를 측정하는 지표는 인공지능 책무성 윤리원칙의 이용자 책임성에 해당한다.	①	②	③	④	⑤
9	인공지능 로봇의 관리 부실 등 연료 부족으로 정상 운행 중 작동 정지로 도로상 작동 중지를 측정하는 지표는 인공지능 책무성 윤리원칙의 이용자 책임성에 해당한다.	①	②	③	④	⑤
10	인공지능 로봇의 통신 이상 등 장애에 의해 도로상 작동 중지를 측정하는 지표는 인공지능 안전성 윤리원칙의 견고성에 해당한다.	①	②	③	④	⑤
11	인공지능 로봇의 보행자 통행 방해에 의해 도로상 작동 중지를 측정하는 지표는 인공지능 통제성 원칙의 제어 가능성에 해당한다.	①	②	③	④	⑤
12	인공지능 로봇의 도로매칭 알고리즘 오류로 도로상 작동 중지를 측정하는 지표는 인공지능 통제성 원칙의 모니터링에 해당한다.	①	②	③	④	⑤
13	인공지능 로봇의 데이터 업데이트 오류에 의해 도로상 작동 중지를 측정하는 지표는 인공지능 책무성 원칙의 이용자 책임성에 해당한다.	①	②	③	④	⑤

설문에 응해주셔서 대단히 감사합니다.

ABSTRACT

A Study on the Development of Measurement Indicators by Type of Risk of AI Robots and the Relationship of AI Ethics Principles

Song, Hyun-Kyoung

Major in Computer Education

Department of Disciplinary Education

Sungkyunkwan University

Artificial intelligence(AI) robots are active in many fields, including voice recognition services, generative AI, manufacturing, food cooking robots, and road-driving delivery robots. AI refers to a technology used by computer systems to imitate human learning and decision-making, and robots refer to mechanical devices that play various roles such as physical labor assistance, educational services, and social services.

In this dissertation, based on the premise of usability in society and daily life, an AI robot is defined as a mechanical device equipped with intelligence that can learn and make decisions on its own and solve problems in the form of a combination of an AI system and a robot. The development of technology is accompanied by various problems as well as social expectations, and we are facing a new turning point with the emergence of intelligent robots and bipedal

robots that can express human emotions.

Countries such as Korea, the European Union, the United States, and China have proposed robot laws and AI guidelines in preparation for the widespread harm caused by AI robots to human society, but most of them have been ethics-oriented. Previous research at home and abroad mostly focused on legal considerations, ethical principles, and technology utilization plans, and was only applicable to limited areas such as inspection checklists for developers, the appraisal industry, and home health care no general-purpose usability.

The scope of use of artificial intelligence robots is expanding from task performance to daily life, so it is not possible to generally check the risks of AI robots with only ethical indicators. There must be an indicator to measure all technical problems and ethical risks, such as human injury caused by AI robots while interacting with humans, leakage of collected personal information, and discriminatory services.

In this dissertation, we analyze cases of AI robot problems through literature such as previous research, related policies, and articles, presented classifications and items for each type of risk of AI robots through expert interviews and a Delphi survey, and developed a risk measurement indicators. For the study, a group of 30 experts, including AI developers, robot researchers, expert in the field of AI ethics and education, and information and security professors, participated, and a consensus opinion reached a group of experts using the Delphi technique research method through future predictions.

An on-site survey was conducted targeting stakeholders in various fields where AI robots could be introduced, and the valid figures of 328 people were used as statistical analysis data. As a result of statistical analysis such as

exploratory factor analysis, reliability analysis, correlation analysis, and multiple regression analysis, four types of physical risk to the body, risk to human rights, risk of property loss, and social risk have been verified for validity and reliability developed 11 items and 52 measurement indicators.

In addition, we conducted research on the relationship of AI ethical principles so that the measurement indicators for each type of risk of AI robots can be used for general purposes such as technology standardization, safety inspection, systems, and policies. We also conducted interviews with experts and a Delphi survey of 14 people. Through analysis, the relationship between measurement indicators for each type of risk of AI robots and AI ethical principles was presented in a diagram.

Problems related to AI robots can arise from both technical and ethical aspects, and it is difficult to predict risks that may occur in the future, so continuous attention from experts is needed, and expanding and developing measurement indicators will be a new research area.

The measurement indicators by risk type that can check all technical and ethical aspects of AI robots presented in this dissertation serve as a cornerstone for development, certification, education, and policy to promote standardized technology development that secures social sympathy and safety, hope it will be used for things like this.

Keywords: AI Robot, AI Robot Risk Measurement Model, AI Robot Measurement Indicators, AI Robot Risk Measurement Indicators by Type, AI Ethical Principles