

AI 산출물에 의한 저작권 침해에 관한 연구*

A Study on Copyright Infringement by AI-Generated Works

전웅준(Eung Jun Jeon)**

목 차

- I. 서론
- II. 생성형 AI의 특성에서 바라본 저작권 침해 문제
 - 1. 생성형 AI의 기술적 특징
 - 2. 생성형 AI의 초과모방성 현상
 - 3. AI 생명주기에 따른 단계별 침해 국면
 - 4. 법적 관점에서 바라본 생성형 AI 모델의 일반적 특성
 - 5. 암기 현상 또는 압축된 사본 형태의 학습데이터 저장 가능성
- III. AI 산출물에 의한 저작권 침해 관련 세부 판단 기준
 - 1. 기본적인 견해
 - 2. 의거성
 - 3. 실질적 유사성
- IV. 저작권 침해 책임의 귀속 주체
 - 1. 직접 침해자 v. 간접침해자
 - 2. AI 개발자(서비스제공자) v. AI 이용자
 - 3. 저작권법상 OSP 책임
- V. 법률 개정의 필요성 여부
 - 1. 기본적인 견해
 - 2. 의거성 관련 입증책임 전환
 - 3. 저작권법상 OSP 책임 관련
 - 4. AI 모델에 대한 금지 및 폐기 청구 관련
- VI. 결론

*  크리에이티브 커먼즈 저작자표시-비영리-변경금지 4.0 국제 라이선스
위 조건을 따르는 경우에 한해서 저작물을 복제, 배포, 전송할 수 있습니다.

** 법무법인 린 변호사.

요 약

본 연구는 AI 산출물에 의한 기존 저작권 침해의 문제를 고찰하기 위해 우선 생성형 AI의 기술적 특성에 관하여 ‘생성형 AI의 확률적 모방성’과 ‘초과 모방성 현상’이라는 개념을 제시하였다. ‘생성형 AI의 확률적 모방성’은 AI 모델이 학습데이터의 분포를 파악하여 이를 확률적으로 모방하는 특성을 법적 관점에서 해석한 것이며 ‘초과 모방성 현상’은 생성형 AI가 일반적인 모방성을 넘어 의도적으로 저작권 침해물을 생성하는 현상을 개념화한 것이다. 이와 같은 관점하에 본 연구는 크게 다음의 세 가지 사항을 검토하였다.

첫째, AI의 확률적 모방성은 ‘학습데이터의 분포를 따르는’ 기술적 특성에서 비롯되는데, 이러한 모방성은 기술발전에 의해 다양한 형태로 나타날 수 있다. 이와 같은 AI 산출물에 대한 저작권 침해 여부를 판단하기 위해서는 생성형 AI의 산출 과정에 대한 과학적·기술적 검토가 요구된다. 그러나 AI 모델 내부 구조가 블랙박스과 같이 작동함에 따라 침해 과정을 직접적으로 입증하기가 어렵다는 점이 특히 의거성의 입증에 어렵게 하고 있다. 이러한 의거성 입증의 어려움을 해결하기 위해 학습데이터에 피침해 저작물이 존재하고 AI 산출물이 피침해 저작물과 매우 유사한 경우, 증거거리 설에 기초하여 의거성에 대한 입증책임을 전환하는 방안을 고려할 수 있다고 보았다.

둘째, AI 이용자와 AI 개발자의 책임 귀속 문제는 침해행위의 구조적 특성과 밀접하게 연결된다. 이용자가 침해 유발적인 프롬프트를 입력하여 특정 저작물과 유사한 결과물을 얻은 경우, 이는 이용자의 직접 침해로 볼 가능성이 높다. 반면, 기술적으로 특정 저작물의 모방을 유도하는 AI 모델(e.g. 과적합된 모델)을 의도적으로 제공한 개발자는 직접 혹은 공동 침해 책임을 부담할 수 있다. 따라서 개별 사안 단위로 AI 이용자 또는 AI 개발자의 침해 주체성 여부를 검토하는 법적·정책적 관점이 필요하다. 같은 맥락에서 AI 모델 자체가 침해행위로 조성된 물건으로서 금지 및 폐기 청구의 대상이 되는지도 검토할 수 있다. 기본적으로 AI 모델은 파라미터의 형태로 존재하기 때문에 학습데이터의 복제물로 볼 수 없지만, 의도적으로 특정 저작물을 모방하도록 설계된 AI 모델의 경우에는 규범적 관점에서 금지 및 폐기 청구의 대상이 될 가능성이 있다.

셋째, AI 산출물의 저작권 침해를 방지하고 책임 소재를 명확히 하기 위해서는 입증책임 전환, 필터링 및 모니터링 기술, OSP(온라인서비스제공자)에 대한 통지·삭제 절차 등 추가적인 규제 장치의 도입이 검토될 수 있다. 그러나 이러한 방안이 과도하게 적용될 경우 기술 발전이 위축되고 표현의 자유에 대한 제약으로 이어질 수 있으므로 새로운 입법적 제안은 기존 법리와 제도를 존중하는 전제에서 신중히 고려되어야 한다고 생각된다.

주 제 어

생성형 인공지능, 저작권 침해, 모방성, 과적합, 암기, 역류

I. 서론

최근 인공지능(AI) 기술의 급속한 발전은 콘텐츠 생성 영역에서 혁신적인 변화를 이끌어왔다. 특히, 생성형 AI(Generative AI)의 등장으로 텍스트, 이미지, 오디오, 비디오 등의 콘텐츠를 자동으로 생성하는 기술이 보편화되고 있다. 그러나 이러한 발전은 기존 저작권 체계에 대한 새로운 도전과 법적 문제를 야기하고 있으며, 특히 AI 산출물에 대한 저작권 보호 여부 및 AI에 의해 생성된 콘텐츠가 기존 저작권을 침해하는지에 대한 논쟁이 활발하게 진행되고 있다. 생성형 AI는 확률적 모방성을 기반으로 학습 데이터를 분석하고 이를 토대로 새로운 콘텐츠를 생성하는 특징을 갖고 있다. 나아가 최근에는 생성형 AI의 일반적인 모방성을 넘어 의도적으로 특정 저작물의 유형을 베낄 수 있는 AI 모델도 등장하고 있다. 이러한 특성으로 인해 AI가 생성한 산출물이 기존 저작물과 유사한 경우 해당 산출물이 저작권 침해에 해당하는지, 그리고 AI 이용자와 개발자 중 누구에게 법적 책임이 귀속되는지가 핵심적인 논의 대상이 된다. 특히, AI 이용자가 입력하는 프롬프트(prompt)의 역할과 AI 시스템의 자율성이 결합되면서 기존 저작권법의 깊은 이해와 창의적인 해석이 요구되고 있다. 본 연구는 생성형 AI의 기술적 특성 및 원리를 바탕으로 AI 산출물이 기존 저작권을 침해할 가능성을 분석하고 이에 대한 법적 책임 구조를 명확히 하고자 한다. 이를 위해 AI 저작권 침해 판단 기준, AI 개발자와 이용자의 법적 책임, AI 시스템의 자율성이 미치는 영향 등을 종합적으로 검토하고, 저작권 보호와 기술 혁신 간의 균형을 맞출 수 있는 법적·정책적 고려를 시도한다.

II. 생성형 AI의 특성에서 바라본 저작권 침해 문제

1. 생성형 AI의 기술적 특징

(1) 생성형 AI의 확률적 모방성

생성형 인공지능(Generative AI)은 이용자가 입력한 특정한 요구(프롬프트, prompt)에 따라 AI가 다양한 수준의 자율성을 가지고 텍스트, 이미지, 오디오, 비디오 등의 콘텐츠를 생성하는 인공지능 기술을 말한다.¹⁾ 이러한 개념 정의의 중요 요건으로는 AI의 목적이 콘텐츠를 표현하고 생성하는 것에 있다는 점, 콘텐츠를

생성할 때 AI에게 상당한 정도의 자율성이 있다는 점, 콘텐츠 생성은 이용자의 프롬프트에 의해 지시·유도된다는 점이라고 생각된다.

콘텐츠 생성이 이용자의 프롬프트 입력에 의하지만 AI에게 구체적인 표현 생성에 관하여 상당한 자율성이 있다는 점은 AI 산출물의 저작물 적격성(copyrightability), AI 산출물에 의한 침해의 근본적 가능성 및 책임주체성 논의에 미묘한 영향을 준다. 프롬프트는 현재 기술 수준에서 이용자에게 AI 산출물에 대한 충분한 통제력을 제공한다고 보기 어렵다.²⁾ 동일한 프롬프트를 입력하여도 다양한 산출물이 출력되며 프롬프트에 명시적으로 기재한 요소가 산출물에 포함되지 않거나 명시되지 않은 요소가 추가될 수 있다.³⁾ 이러한 특성을 고려하면 AI 산출물이라는 성과 내지 가치를 프롬프트를 입력한 이용자에게 전적으로 귀속하기에는 이론상 무리가 있다. 나아가 AI의 자율성을 중시하는 관점에서는 AI 산출물에 의한 타인 저작권 침해에 대하여 과연 이용자에게 책임을 물을 수 있는지 근본적인 의문을 품을 수 있다. 이와 같은 창작적 통제력 정도에 관하여 일부 견해는 매우 상세하거나 반복적인 프롬프트에 의해 (저작권을 부여할 수 있는 정도로) AI 산출물을 통제할 수 있다고 보고 있으나, 상세한 프롬프트도 여전히 무한한 숫자의 다양한 산출물을 생성할 수 있으므로 AI 모델의 산출물을 충분히 통제한다고 보기 어렵고 반복적

- 1) 2023. 5.11. EU 의회의 Internal Market Committee와 Civil Liberties Committee가 발표한 ‘EU 인공지능 법안’ 수정안은 생성형 인공지능을 “AI systems specifically intended to generate, with varying levels of autonomy, content such as complex text, images, audio, or video”라고 조문 내에서 정의한 바 있다(Art. 28b 4). 위 EU 의회안은 일부 수정되어 2023. 6. 14. 의회에서 가결되었다. 수정안 제28조b 제4항에 대응하는 최종안 제53조 제1항 (b)는 생성형 AI 보다 더 넓은 관점인 범용 AI(general-purpose AI) 측면에서 학습콘텐츠에 관한 상세 요약 공개 등을 규율하기 때문에 위 생성형 AI의 정의를 삭제하였다.
- 2) USCO, Copyright and Artificial Intelligence Part 2: Copyrightability, January 2025, 18면. “The Office concludes that, given current generally available technology, prompts alone do not provide sufficient human control to make users of an AI system the authors of the output.”
- 3) 생성형 AI 모델 특히 확률적 언어모델(ChatGPT 등)은 출력의 무작위성 정도를 통제하는 하이퍼파라미터인 temperature 변수를 가지고 있다. temperature가 높을 수록(예를 들어 1이상) AI 모델은 확률적으로 다양한 토큰을 출력값으로 선택하므로 창의적이고 예측하기 어려운 결과가 산출될 수 있다. 반면 temperature가 0에 가깝게 낮으면 AI 모델은 확률이 가장 큰 토큰만을 선택하려고 하기 때문에 출력값이 거의 결정론적(deterministic)으로 나타나게 된다. 이러한 경우에는 프롬프트를 반복 실행하면 거의 동일한 산출물이 출력된다. Stable Diffusion에서는 CFG Scale 변수가 같은 기능을 수행한다. ChatGPT의 경우 temperature 변수의 설정은 일반적인 ChatGPT UI에서는 지원되지 않고 개발자 모드인 OpenAI Playground 또는 OpenAI API에서 가능하다.

프롬프트는 단순히 “주사위를 다시 굴리는 것”과 같아 실질적으로 통제력의 수준을 변화시킨다고 볼 수 없다고 생각된다.⁴⁾

생성형 AI에게 유보된 상당한 자율성은 기술적으로 보면 AI 산출물이 확률 내지 확률분포에 따른다는 의미이다. 통계학의 용어를 빌면, 생성형 모델은 주어진 원본 데이터를 학습하여 원본 데이터와 통계적으로 구별되지 않거나(GAN), 원본 데이터의 확률분포를 모델링하여(Diffusion, VAE), 유사한(가짜) 데이터를 생성하는 인공지능 모델이며 따라서 원본 데이터의 분포를 파악하여 학습하는 것이 가장 중요하게 다루어진다. 이와 같은 학습데이터의 분포를 모방하려는 기술적 특성으로 인하여 생성형 인공지능의 산출물은 타인의 저작물과 유사할 수 있으며 이로 인해 AI의 산출 단계(OUTPUT 단계)에서 저작권 침해의 문제가 발생하게 된다.

(2) 판별형 AI와 대비

생성형 AI와 대비되는 개념으로서 판별형 AI(Discriminative AI)가 있다. ChatGPT, Stable Diffusion 과 같은 생성형 인공지능은 콘텐츠를 생성하는 표현력에 집중한다는 점에서 데이터를 분류하거나 범주화하도록 설계된 판별형 인공지능과 구분된다.⁵⁾ 판별형 AI는 주어진 데이터를 분류하거나 특정 범주(클래스)로 나누는데 특화된 인공지능이다. 입력 데이터에서 특징을 분석해, 그 특징이 주어진 분류 기준에 얼마나 부합하는지를 평가함으로써 결과를 산출한다. 수학적 개념으로는, 조건부 확률 $P(Y/X)$ 를 학습하여 입력한 X 가 클래스 Y 에 속할 가능성을 계산한다고 설명된다.⁶⁾ 예컨대 이미지가 고양이인지 개인지 분류하거나, 이메일이 스팸인지 정상인지 판별하는 것이 대표적인 판별형 AI의 예시이다. 의료 분야에서는 환자의 사진이나 검사 결과를 분석해 암세포가 있는지 없는지 판단하는 식으로 활용되며, 금융 영역에서는 거래 내역의 이상 패턴을 찾아 사기 여부를 탐지하는 역할을 수행한다. 이러한 판별형 AI는 군집화, 회귀, 분류 등의 여러 기법을 활용하여 입력된 데이터가 특정 기준에 부합하는지 판별하고, 그 결과를 정량적으로 제시한다.

4) USCO, Copyright and Artificial Intelligence Part 2: Copyrightability, January 2025, 20면

5) Background: What is a Generative Model? <https://developers.google.com/machine-learning/gan/generative?hl=en> (최종 방문 2025. 4.20.).

6) 반면, 생성형 AI 모델은 학습데이터를 기초로 하여 데이터 자체의 확률분포 $P(X)$ 를 학습하는데 중점을 둔다. <https://news.skhyun.co.kr/post/all-around-ai-6>(고려대학교 인공지능학과 김동현 교수, 최종방문 2025. 2.15.).

이러한 판별형 AI는 AI 산출물에 의한 저작권 침해 관점에 국한하여 보면, 저작권 침해 이슈가 거의 없다고 볼 수 있다.

위 두가지의 형태의 AI는 서로 상반된 기능을 수행하는 것처럼 보이지만, 실제로는 긴밀히 협력하여 개발·이용될 수 있다. 예를 들어 대표적인 생성형 AI인 GAN(Generative Adversarial Networks) 자체도 생성자(Generative)가 가짜 데이터를 생성하고 판별자(Discriminator)가 이것이 진짜인지 가짜인지 판별하면서 양측이 경쟁적으로 학습한다. 그 결과, 생성자는 점점 진짜와 구분하기 어려운 높은 수준의 콘텐츠를 만들게 되고, 판별자는 더욱 미묘한 차이를 파악해 낼 수 있는 정교함을 갖추게 되어, 진짜와 구별되지 않는 가짜를 만들 수 있는 지점에서 양자는 경쟁을 멈추고 평형을 이루게 된다.

(3) 검색방식 모델과의 차이

종래 DB검색 방식을 채택한 모델(Retrieval Based Model)와 비교하여 보면, 검색 기반 모델은 DB에 저장된 저작물이 선택(검색)되어 그대로 공개되는 것이지만, 생성형 모델에서는 어떤 콘텐츠가 AI 알고리즘에 의해 새롭게 생성되어 공개되는 것이기 때문에 위 양 모델에서 발생하는 문제의 본질은 상당히 다르다. 생성형 인공지능은 표현물 생성 과정에서 상당한 수준의 자율성을 갖기 때문에 학습된 원본데이터와 생성된 표현물 사이의 동일성(실질적 유사성) 정도가 문제되는 것이다. 생성형 인공지능은 확률 내지 확률분포함수에 따라 산출물을 생성하므로 원칙적으로 프롬프트 입력시마다 매번 다른 내용의 산출물을 생성하게 된다(이른바 ‘암기’ 현상은 예외에 속한다고 본다). 이와 같이 AI 이용자가 AI 산출물 생성에 대해 결정론적인 통제를 할 수 없다는 점은 표현력이 높은 AI 산출물에 대해 AI 이용자의 저작권 귀속을 부인하게 되는 하나의 근거가 된다.

의거성의 관점에서, 생성형 AI는 이용자의 프롬프트의 지시나 유도를 받지만 AI 스스로가 상당한 자율성을 가지고 블랙박스적인 경로에 따라 산출물을 생성하는 것이기 때문에, 가사 학습데이터에 포함된 저작물이 산출물에서 동일하게 생성되었다고 하여 이러한 현상을 의도적인 침해로 단정하거나 AI가 해당 학습데이터만을 참고하여 복제물을 생성하였다고 인정하기는 어렵다. 다만 의도적으로 AI 개발자가 모방지향적인 AI모델을 개발하거나 AI 이용자가 침해유발적인 프롬프트를 입력하는 경우는 다르게 보아야 한다. 이에 대해서는 후술한다.

2. 생성형 AI의 초과모방성 현상

전술한 바와 같이 생성형 AI는 기본적으로 확률적인 모방성을 내재하고 있다. 이러한 잠재적 모방성 경향으로 인하여 AI 산출물이 기존 저작물의 복제물 내지 2차 저작물 여부 여부가 다투어질 수 있다. 특정 작가의 작품이 학습데이터로 제공된 상태에서 (산출 경로는 불분명하지만) AI가 위 작품과 유사한 산출물을 생성할 가능성이 이론상 존재한다. 또한 일부 연구에서는 생성형 AI의 암기(memorization) 현상이 지적되고 있다.⁷⁾ 예를 들어 GitHub Copilot 모델은 일반적인 상황에서는 암기된 코드를 거의 출력하지 않지만 학습데이터와 매우 유사한 긴 코드 발췌물(excerpts)이 프롬프트로 제공되었을 때는 원본 학습데이터가 그대로 출력되는 암기 현상이 나타날 수 있다고 보고되었다.⁸⁾ 이와 같은 암기현상은 AI 모델의 크기가 크고 학습데이터에 중복된 데이터가 많으며 프롬프트의 컨텍스트 토큰이 많은 경우에 더 자주 발생한다고 한다.⁹⁾

그러나 AI 산출물에 의한 저작권 침해 현상에서 더욱 심각하게 보아야 할 경우는 의도적으로 저작권 침해물을 생성하려는 행위라고 생각된다. AI 모델의 잠재적 모방성에 기초하여 원본 학습데이터와 동일한 산출물이 생성될 확률은 정상적인 확률분포에 따른다면 유의미하게 크다고 보기 어렵고 AI 모델의 암기현상은 이용자에 의한 일종의 해킹 내지 AI 모델의 버그에 가깝기 때문이다. 본 연구는 생성형 AI가 일반적, 잠재적인 모방성 경향을 넘어서 의도적인 저작권 침해물을 만드는 현상을 ‘초과모방성 현상’이라고 부르려고 한다. 현재 연구 성과 및 외국 소송의 진행 상황을 참고하면, 생성형 AI의 기본적인 모방성을 초과하여 의도적으로 저작권 침해를 유발하는 행위로는 다음과 같은 유형이 지적되고 있다. 다만 이러한 연구결과는 AI 기술의 발전에 따라 충분히 유동적일 것으로 예상된다.

첫 번째로는 AI 개발자가 과적합(overfitting)된 AI 모델을 만드는 경우이다. 학습 완료된 AI 모델에 소규모 데이터셋을 이용한 추가 학습(미세 조정 등)을 하여, 해당 학습데이터셋에 강한 영향을 받는 과적합된 AI 산출물이 의도적으로 생성되도록 하는 유형이다.¹⁰⁾ 최근 사례로는 고인이 된 유명 코미디언인 조지 칼린(George

7) Gowthami Somepalli et al., Diffusion Art or Digital Forgery? Investigating Data Replication in Diffusion Models, 2022; Nicholas Carlini et al., Extracting Training Data from Diffusion Models, 2023.

8) Nicholas Carlini et al., Quantifying Memorization Across Neural Language Models, 2023, 6면

9) Nicholas Carlini et al., 앞의 글, 1면; Antonia Karamolegkou et al., Copyright Violations and Large Language Models, 2023, 2면.

Carlin)의 목소리와 코미디 스타일을 모방하여 마치 고인이 살아서 연기하는 것처럼 보이는 “George Carlin: I’m Glad I’m Dead”이라는 AI 영상을 만든 행위가 위 유형에 속한다.¹¹⁾ 이러한 유형에서는 AI 개발자가 공동 또는 단독으로 침해 주체로 인정될 수 있다.

두 번째 유형으로는, AI 이용자가 기존 작가의 이름을 지정하거나 기존 저작물의 창작적 표현과 공통된 산출물을 생성하도록 지시하는 침해유발적 프롬프트를 입력하는 경우이다. 여기에는 NYT v. OpenAI 사건에서 보듯이 생성형 AI의 암기 현상에 기대어 특정 신문기사 단어의 절반에 가까운 대량의 프롬프트를 입력하여 나머지 신문기사의 내용을 의도적으로 출력하는 행위도 포함된다.¹²⁾ 이러한 유형에서 침해주체는 프롬프트를 입력하는 AI 이용자라고 할 것이다.

참고로 이러한 초과모방성 현상은 저작물 적격성(copyrightability)의 관점에서 보면 AI 산출물에 대한 이용자 내지 개발자의 창작적 통제력(creative control)의 증가와 논리적으로 연관이 있다. USCO(미국 저작권청)는 현재 기술 수준에 의하면 프롬프트 자체는 매우 구체적으로 기술되었다고 하더라도 아이디어를 전달해 주는 지시(instruction)에 불과하여 AI 산출물을 인간의 저작물로 평가되기에 충분한 인간의 통제력을 제공하지 못한다고 보고 있지만,¹³⁾ 다른 한편으로는 향후 기술이 발전하여 프롬프트가 AI 산출물의 표현적 요소(expressive element)에 대해 향상된 통제력을 제공할 가능성도 인정하고 있다(반대로 AI 기술 발전이 자동화 및 최적화 기술이 이용자의 통제력을 더 감소시키는 방향으로 진행될 수도 있다고 지적한다).¹⁴⁾

3. AI 생명주기에 따른 단계별 침해 국면

AI에 관한 법적 문제는 AI의 생명주기(life cycle)에 따라 고찰하는 것이 유용하다. AI 모델 개발 및 이용은 크게 보면 AI 학습 단계(INPUT 단계), AI 출력 단계(OUTPUT 단계), AI 서비스 단계로 구분할 수 있다.

우선, 인공지능 학습 단계(INPUT 단계)에서 발생하는 저작물의 복제·전송의 문

10) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 20면.

11) Main Sequence, Ltd. et al v. Dudesy, LLC et al., US District Court for the Central District of California (2:24-cv-00711).

12) The New York Times Company v. Microsoft Corporation et al., 1:23-cv-11195, (S.D.N.Y.) 원고 증거 J.

13) USCO, Copyright and Artificial Intelligence Part 2: Copyrightability, January 2025, 18면.

14) 앞의 글, 21면.

제는 생성형 인공지능이 최우선적으로 해결해야 하는 과제이다. 여기에는 공정이용 판단, TDM 예외 입법, 저작권자에 대한 보상 등의 첨예한 이슈가 포함된다.

AI 출력 단계(OUTPUT 단계)에서는 본 연구에서 논하는 AI 산출물의 저작권 침해 문제가 거론된다. 국내외 논의를 보면, AI 출력 단계에서 발생하는 저작권 침해는 기존의 법리에 따라 처리할 수 있는 것으로 파악된다. AI 출력단계에서의 저작권 침해는 AI 학습단계에서의 저작권 침해와 별개로 사고할 수 있으므로 AI 학습 단계에서 TDM 예외, 공정이용이 성립하더라도 AI 출력단계에서 AI 이용자에 의한 저작권 침해는 인정될 수 있다.¹⁵⁾ 그러나 AI 학습·개발 단계에서 공정이용 등이 인정된 경우에는 AI 개발자에게 AI 출력단계의 저작권 침해 책임을 묻는 상황을 예상하기는 어렵다고 보인다. AI 출력단계에서 AI 개발자에 의한 저작권 침해가 문제되는 상황이라면 대체로 AI 학습단계에서의 공정이용은 부정되어야 할 것으로 생각된다.

AI 서비스 단계에서 발생하는 법적 문제는 가짜 뉴스, 명예훼손, 차별적 행위, 가스라이팅 등을 들 수 있다. 이러한 문제는 저작권법과는 구분되는, AI 규제 영역이라고 할 수 있다.

4. 법적 관점에서 바라본 생성형 AI 모델의 일반적 특성

법적 관점에서 중요하게 고려되어야 하는 AI 모델의 특성은 다음과 같다.¹⁶⁾

첫 번째, 이론적으로 학습완료된 AI 시스템에는 학습데이터가 남아 있지 않다는 점이다. 수학적 및 전산학적 관점에서, AI 모델은 알고리즘, 통계적 구조, 파라미터의 값으로 구성되어 있으므로 학습데이터가 저장되어 있지 않으며, AI 모델이 소프트웨어

15) 박성호, 2023 전국 저작권법 학자대회 토론집, 54면; 김경숙, 인공지능 생성물과 저작권 문제, IT와 법연구 제27집, 2023, 61면

16) 여기서 AI 모델은 알고리즘의 구조 및 학습에 의해 결정된 파라미터(가중치)를 지칭하는 것으로 정의한다. 이는 Open Source Initiative(OSI)의 ‘The Open Source AI Definition - 1.0’ 정의를 따른 것이다(<https://opensource.org/ai/open-source-ai-definition>, 2025. 1.16. 최종방문). AI 시스템은 AI 모델을 실제로 구동하기 위해 프로그램 코드로 작성한 응용시스템 및 관련 하드웨어라고 보면 될 것인데, EU AI Act는 AI 시스템의 개념에 관하여 “다양한 수준의 자율성을 가지고 작동하도록 설계된 기계 기반 시스템으로서, 배포 후 적응성을 나타낼 수 있으며, 명시적 또는 암묵적 목표를 위해, 입력된 데이터를 기반으로 물리적·가상 환경에 영향을 미칠 수 있는 예측, 콘텐츠, 추천 또는 결정과 같은 산출물(output)을 생성하는 방법을 추론하는 시스템을 의미한다.”고 정의하여 OECD AI Recommendation을 따르고 있다(<https://legalinstruments.oecd.org/en/instruments/OECD-LEGAL-0449>, 2025.4.20. 최종방문)..

어와 하드웨어와 결합된 AI 시스템에도 마찬가지로 학습데이터가 저장되어 있지 않다. 이는 생성형 AI 모델이 종래 검색기반 모델과 근본적으로 구별되는 특성이다. 따라서 원칙적으로 생성형 AI는 저장형 내지 검색형 OSP와 구분되며 침해소송의 증거조사 단계에서도 AI 시스템만을 조사하여서는 침해된 학습데이터를 찾을 수 없다.

다만, 최근에는 생성형 AI에 RAG(Retrieval-Augmented Generation) 기술이 접목되고 있는데, RAG는 먼저 외부 데이터베이스에서 관련 정보를 검색한 후(Retrieval) 검색된 정보를 원래 프롬프트에 추가하여(Augmentation) 증강된 프롬프트를 바탕으로 응답을 생성(Generation)한다.¹⁷⁾ RAG 기술을 채택한 생성형 AI는 부분적으로 저장형 내지 검색형 OSP의 성격을 띠다고 할 수 있다. 일반적인 학습완료 언어모델(Pre-trained language model)은 사실적 지식을 모두 수치화하여 AI 모델의 파라미터에 저장하는 방식을 취하는 것이지만 세상의 모든 지식을 정확하게 접근하고 조작하는 것에 한계가 있을 수밖에 없으며 AI 산출물에 대한 출처 제공에 제약이 있고 학습하지 않은 지식에 대한 추가 업데이트 문제를 해결하기 위해 큰 비용이 소요된다는 단점이 있다. RAG와 같은 AI 기술 동향을 보면 AI 시스템 외부에 별도의 데이터베이스나 메모리를 추가하여 지식집약적 업무(knowledge-intensive tasks) 처리, 출처 제공, 데이터의 현행화 문제를 해결하려는 경향이 발견된다. 이와 같이 수치화된 AI 모델의 외부에 별도의 메모리를 추가하여 콘텐츠를 처리하려는 시도는 해당 메모리가 저장하고 있는 데이터의 성격에 따라 저작권 침해의 가능성을 높일 수 있다. 향후 AI 기술은 다양하게 변형될 수 있으므로 이러한 변화·발전의 가능성을 열어 놓고 AI 시스템의 구조를 이해할 필요가 있다.

두 번째, AI 모델의 블랙박스적인 성격으로 인하여 AI 출력값과 입력값 간의 경로파악이 어렵다. AI 산출물이 외견상 기존 저작물에 대한 침해물이라고 보이는 경우 해당 산출물이 어느 학습데이터에 의존하여 어떠한 방법으로 생성되었는지 입증되어야 하는데, 현재 기술 수준으로는 이러한 경로파악에 관한 완벽한 입증은 불가능하다. 이는 저작권 침해 판단에서 의거성 입증의 곤란성으로 이어지게 된다. 세 번째, 생성형 AI는 프롬프트에 의해 작동되므로 AI 개발자와 AI 이용자가 분리된다. 이는 생성형 AI에 의해 어떠한 법적 문제가 발생하였을 때 책임의 귀속주체를 판별하는 것에 어려움을 준다.

17) Patrick Lewis et al., 'Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks', 2020. 2020년에 등장한 RAG 기술은 기존 Naive RAG에서 Advanced RAG, Modular RAG으로 계속 진화중이다.

5. 암기 현상 또는 압축된 사본 형태의 학습데이터 저장 가능성

근래에 들어 생성형 AI 모델이 학습데이터를 암기(memorization)하였다거나 생성형 AI 모델이 학습데이터를 압축된 사본(compressed copy) 형태로 저장하는 것으로 볼 수 있다는 연구결과가 나타나고 있다.¹⁸⁾ 종래 연구에서도 이른바 비표현적 이용(nonexpressive use)와 양립할 수 없다고 보이는 ‘학습데이터의 암기 내지 재구성(reconstituting) 현상’이 대규모 확률 모델에서 발생할 수 있다는 견해가 유력하였다.¹⁹⁾ 다만 종래의 견해는 AI 모델이 학습데이터의 특징과 연관관계를 학습한다는 점에 착안하여 ‘일반적으로’ AI 산출물은 학습데이터의 저작권을 침해하지 않지만, 일정한 예외적인 상황, 예컨대 text to image 모델에서 중복된 학습데이터가 많은 경우, 학습이미지가 독특한 텍스트 설명(text description)과 결합된 경우, 학습데이터 대비 AI 모델의 크기가 큰 경우 등에서 암기현상이 발생할 수 있다고 보는 정도였다. 최근의 연구경향은 이러한 내용을 심화하여 AI 모델이 학습데이터를 저장하는 것으로 볼 수 있는지, AI 모델의 암기 현상이 AI 모델의 본질적·잠재적인 현상인지에 관하여 논하고 있다.²⁰⁾ 이에 대해서 AI 모델의 기술적 원리에 천착하는 견해는 AI 모델의 저장장치 성격을 부인하면서, AI 모델은 학습데이터를 수치벡터로 변환하여 학습하고 학습데이터의 추상화된 통계적 패턴만을 파라미터에 저장하므로 학습데이터 자체를 저장한다고 볼 수 없고, 암기 현상은 우연적 현상이거나 악의적 해킹의 결과라고 본다.²¹⁾ 반면 현재 AI 모델이 보여주는 암기 내지 역류

18) A. Feder Cooper, James Grimmelmnn, “The Files are in the Computer: On Copyright, Memorization, and Generative AI”, Chicago-Kent Law Review(Forthcoming), 2024, Available at arXiv: <https://arxiv.org/abs/2404.12590> (2025.4.20. 최종방문); Giorgio Franceschelli, Claudia Cevenini, Mirco Musolesi, “Training Foundation Models as Data Compression: On Information, Model Weights and Copyright Law”, 2024, Available at arXiv: <https://arxiv.org/abs/2407.13493> (2025.4.20. 최종방문).

19) Matthew Sag, “Copyright Safety for Generative AI”, 61 Hous. L. Rev. 295, 2023.

20) 위 Copper, Grimmelmnn의 논문(2024)은 암기(memorization)의 개념을 추출(extraction, 사용자가 의도적으로 원본과 동일한 산출물을 생성하도록 유도), 반복 생성(regurgitation, 사용자의 의도와 무관하게 원본과 거의 동일한 산출물을 생성하는 경우), 재구성(reconstruction, 일반적인 생성 방식이 아니라 어떠한 방식으로든 원본과 거의 동일한 산출물을 생성할 수 있는 경우)과 개념상 구분하고, 모든 학습이 데이터를 암기하는 것은 아니지만 AI 모델이 데이터를 암기하였다면 이는 저작권법상 복제에 해당할 수 있으며, 암기는 AI 모델 자체에 잠재(latent)된 특성이므로 반드시 적대적 사용자가 추출을 시도할 때에만 발생하는 것이 아니라고 주장한다.

21) 예컨대, NYT v. OpenAI 사건에서 OpenAI의 주장.

(regurgitation) 현상을 심각하게 보는 견해는 AI 모델이 단순히 통계적 패턴만을 저장한다고 볼 수 없고 규범적 관점에서 학습데이터를 압축화한 사본 형태로 저장하는 것으로 보아야 한다고 주장한다.²²⁾

이러한 견해의 차이는 침해 주체를 결정하는 것에도 연결되는데, 암기현상을 AI 모델의 비본질적 현상으로 보면 AI 모델은 중립적 도구이므로 AI 산출물에 의한 저작권 침해 문제는 침해유발적인 프롬프트를 입력하는 이용자의 책임을 이해하는 것이 자연스럽다. 그러나 암기 현상을 AI 모델의 내재적 현상으로 보게 되면 AI 산출물에 의한 저작권 침해 현상에서 AI 개발자의 책임을 완전히 부인하기 어렵다.

AI 모델의 저장장치 성격 내지 암기 현상의 내재적 경향에 관한 논의는 이제 막 시작되었으므로 앞으로 AI 모델의 본질에 대한 과학·기술적 연구 및 법률적 고찰을 통해 저작권 보호와 기술 혁신 간의 적절한 타협을 이룰 수 있는 정책적 결론을 도출하여야 할 것으로 생각된다.

III. AI 산출물에 의한 저작권 침해 관련 세부 판단 기준

1. 기본적인 견해

국내외의 대체적인 견해를 살펴보면, AI 산출물에 대한 저작권 침해 판단 기준은 어문저작물, 미술저작물, 음악저작물, 영상저작물 등의 일반적인 저작물에 대한 침해 판단 기준과 다르지 않다고 보고 있다.²³⁾ 이는 AI 산출물이 주로 텍스트, 이미지, 음악, 영상이므로 이에 대한 대비 판단 기준이 기존 저작권 침해 판단의 경우와 다를 필요가 없기 때문으로 생각된다. 2023년 문체부의 ‘생성형 AI 저작권 안내서’도 같은 취지로 기술되어 있으며 다만 “AI 산출물에 대해서는 어떤 경우에 의거성 요건을 충족했다고 볼 것인지, 그에 대한 증명은 어떻게 할 것인지 등과 관련한 논의가 지속되고 있으므로 향후 해외 동향과 관련 판례 등을 주시할 필요가 있다고” 부기하고 있다.²⁴⁾

22) 예컨대, Andersen v Stability AI 사건에서 원고 Andersen의 주장.

23) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 32면; 국내 학자들도 AI 산출물에 의한 저작권 침해에 대해 종래 법리인 의거성 및 실질적 유사성을 논하고 있다(‘한국저작권위원회, 앞의 2023 전국 저작권법 학자대회 토론집’ 참고).

24) 문체부, 생성형 AI 안내서, 2023, 65면.

사실, AI 산출물에 의한 저작권 침해의 판단기준을 논하기 위해서는 그 전에 AI 산출물에 의해 과연 타인 저작권이 침해될 수 있는지 자체를 검토할 필요가 있다. 특히 AI 모델에 대한 창작적 통제력(creative control) 부재를 이유로 AI 산출물의 저작물 적격성(copyrightability)를 부정하고 관련 프롬프트를 입력한 이용자에게 저작권 부여를 거절하는 견해를 취한다면 침해유발적 프롬프트를 입력한 이용자에게도 유사한 논리로 침해책임을 부정해야 한다는 논리가 이론상 불가능하지는 않다고 보인다. 다만, 적어도 AI 모델의 잠재적 모방성 수준을 넘은 ‘초과모방성’ 현상에 대해서는 AI 개발자 내지 AI 이용자의 침해책임을 부인하기 어렵다고 생각된다. 반대로 AI 산출물에 대한 저작권 부여를 긍정하는 견해를 취한다면 AI 산출물에 의한 타인 저작권 침해 가능성을 더욱 적극적으로 고찰하여야 할 것이다.

2. 의거성

(1) 기본적인 견해

저작권 침해가 인정되기 위해서는 피침해 저작물의 저작물성, 의거성(의거관계), 실질적 유사성, 침해자의 고의 또는 과실이 인정되어야 한다. 복잡한 구조의 인공지능 모델의 알고리즘, 예컨대 여러 개의 은닉층이 설정되고 파라미터가 많은 심층학습 모델이 채택하고 있는 알고리즘은 대체로 인간이 이해하기 어렵다는 점(인공지능 알고리즘의 블랙박스적인 성격)에서 의거성 판단 기준이 문제된다. 현재 기술수준으로는 (특히 심층학습) 인공지능의 출력값이 어느 입력값, 노드, 가중치에 의해 산출되었는지 정확한 경로 파악이 어렵고, 학습데이터에 원저작물이 포함되었다는 점을 입증할 수 있더라도 AI 산출물이 그 중 어느 원저작물에 의거하여 작성되었는지 특정하기 어려우므로 기술적 관점에서 의거성 입증에 곤란함이 있다. 저작권법적 관점에서는 이른바 ‘비표현적 이용’ 이론에 근거하여, 기계학습은 데이터들의 패턴, 특징을 추출하여 인식하는 것이고 특정 데이터의 표현에 의존하는 것이 아니라는 점을 들어 학습데이터에 원저작물이 있었다고 하더라도 법리적 이유로 의거성 부존재를 주장할 수 있는 여지가 있다.²⁵⁾

의거관계는 침해자가 저작권이 있는 저작물에 ‘의거’하여 그것을 ‘이용’하는 것

25) 전웅준, ‘ChatGPT 등 생성형 인공지능 모델이 제기하는 저작권 관련 쟁점’, 데이터와 지식재산(강원대학교 IP 사업단·지속가능한 혁신과 법 센터·한국디지털재산법학회 2023년 7월 27일 공동 학술대회 자료집), 39면.

을 의미한다.²⁶⁾ 즉 의거의 의미는 타인의 저작물을 보거나 접하여 그것을 토대로 저작물을 작성하거나 제공·제시하는 등 이용하는 것을 말한다.²⁷⁾ 미국 저작권법 이론에서 복제(copying) 또는 현실적인 복제(actual copying)라고 부르는 용어가 한국과 일본에서는 의거로 번역되었다. 통설, 판례는 직접 증거에 의해 의거관계가 입증되기 어렵더라도 피침해 저작물에 대한 접근가능성과 양 저작물의 유사성 등의 간접사실이 인정되면 의거관계가 추정된다고 본다.²⁸⁾ 이러한 간접사실에는 양 저작물 사이에 의거하지 않았다면 나올 수 없는 현저한 유사성(striking similarity)도 포함된다. 통설, 판례는 미국법의 access라는 용어를 ‘접근’이라는 용어로 번역하여 사용하고 있지만, 원래 이는 침해자가 저작권자의 저작물에 가까이 접근하였다는 것으로는 부족하고 실제로 감상할 수 있는 상태에 있었다는 것을 의미한다. 즉 침해자가 저작권자의 작품을 보거나 복제할 수 있는 합리적인 기회, 가능성이 있는 경우를 말하므로 이에 미치지 못하는 가능성이나 의심만으로는 의거관계가 추정될 수 없다.²⁹⁾

저작권법이 침해요건으로 ‘의거성’ 내지 ‘의거관계’를 요구하는 것은 저작권이 모방금지권을 속성으로 하고 있기 때문이다. 즉 문화적 다양성 추구, 표현의 자유를 위해, 후행 저작물이 객관적으로 선행 저작물과 유사하더라도 그에 대한 침해자의 경험, 인식없이 독립적으로 창작된 경우라면 저작권의 효력이 미치지 않도록 설계된 것이다(독립 창작의 항변 가능). 이와 같은 관점에서 국내의 대체적인 견해는 의거성 요건을 침해자의 주관적 요건으로 이해하고 있다. 국내 학설은, 의거(이용)는 타인의 저작물을 베꼈다는 행위자의 주관, 즉 타인의 저작물의 표현내용을 인식하고 그것을 이용한다는 심리상태에 관계되는 요건으로 설명하거나³⁰⁾ 이를 ① 기존 저작물에 대한 표현내용을 인식하고 ② 그것을 이용한다는 의사를 가지고 ③ 실제로 그것을 이용하는 행위로 구분하고 ③번 요소는 주관적인 요소라고 보기 어려우나 ①, ② 요소가 주관적 요소에 해당하므로 전체적으로 주관적 요건으로 보고 있다.³¹⁾

이에 대해 일본의 학설은 의거를 고의·과실과 엄격히 분리하고 무의식적 복제

26) 오승중, 저작권법(제5판), 박영사, 2020, 1249면; 이해완, 저작권법(제3판), 박영사, 2015, 1009면.

27) 박성호, 저작권법(제3판), 박영사, 2023, 655면.

28) 대법원 2014. 7.24. 선고 2013다8984판결(선덕여왕 사건).

29) 오승중, [판례평석] 저작권침해에 있어서의 의거성 판단과 일반 불법행위 성립 여부-서울고등법원 2012. 12.20. 선고 2012나17150판결, 대한변협신문, 2013. 8. 12.

30) 박성호, 앞의 책, 655면.

31) 오승중, 앞의 책, 1250면.

의 경우에도 의거가 성립한다는 것을 설명하기 위해 의거의 의미를 객관적으로 파악하는 경향이 강하다.³²⁾ 이러한 견해에 따라 일본 문화청의 AI 저작권 보고서는 AI 이용자가 기존 저작물을 인식하지 못하였으나 AI 학습데이터에 해당 저작물이 포함되는 경우, 객관적으로 해당 저작물에 대한 접근이 있었다고 인정되므로 해당 생성형 AI를 이용하여 해당 저작물과 유사한 산출물이 생성된 경우 의거성이 추인되고 AI 이용자에 의한 저작권 침해가 성립될 수 있다고 설명하고 있다.³³⁾ 이와 같은 견해의 대립을 고려하면 향후 의거성의 의미에 대한 심도있는 논의가 필요하다고 생각된다. 국내에서도 의거 개념은 표현의 인식과 이용이라는 주관적 측면과 저작권에 대한 객관적으로 위법한 침해 상태(고의·과실과 다름)를 의미한다는 객관적 측면을 모두 포함하므로 의거의 객관적 측면을 강조하는 것은 부득이하다고 설명하거나³⁴⁾ 의거(모방) 역시 접근 등 객관적 사실에 의해 판단되고 있다는 점에서 의거를 주관적 요건으로, 실질적 유사성을 객관적 요건으로 나누는 것에 의문을 품는 견해가 있다.³⁵⁾

(2) 침해 주체에 대한 선결적인 판단 필요

의거성의 의미를 침해자의 선행 저작물에 대한 주관적인 인식과 경험에 기초한 것으로 보면 의거성을 판단하기 위해서는 먼저 침해자가 누구인지가 특정되어야 한다. 본 연구주제인 AI 산출물에 의한 저작권 침해의 경우 침해자로 등장할 수 있는 행위주체가 AI 개발자와 AI 이용자로 이분화되어 있다. 그러므로 저작권 침해의 의거성 판단을 위해서는 문제된 상황에서 침해자를 AI 개발자와 AI 이용자 중에서 누구로 볼 것인지 즉 침해 주체에 대한 판단이 선행되어야 한다.

(3) 학습데이터 포함 여부 및 침해자 인식에 따른 의거성 판단

기계학습 방법론에 따르면 AI 개발자가 사용한 학습데이터에 저작권자의 피침

32) 박성호, 서울중앙지법 지식재산권 실무연구회·한국지적재산권변호사협회 공동주최 연구회 발제문 및 토론문, 2024. 9.9. 일본 문헌에서는 의거를 설명하면서 주관적 요건이라는 용어를 사용하지 않는다고 한다.

33) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 34면.

34) 박성호, 위 토론문.

35) 임원선, 저작권 침해 유형과 침해 판단 기준에 대한 검토, 계간 저작권(통권 131호), 2020, 139면.

해 작품이 포함되었는지에 따라 근본적으로 침해 인정 여부가 달라진다. 우선 AI 개발자가 사용한 학습데이터에 저작권자의 작품이 전혀 없는 경우 AI 개발자 또는 AI 이용자의 행위에는 의거관계가 인정되지 않아 저작권 침해가 성립할 수 없다는 점에 거의 이론이 없다. 기계학습 방법론에 따르면 이러한 경우에도 AI 산출물이 기존 저작물과 유사할 수 있는 가능성이 있으나 이는 저작권법상 의거성이 없으므로 우연의 일치에 불과하다고 보아야 할 것이다.

AI 개발자가 사용한 학습데이터에 저작권자의 작품이 있는 경우에는 기본적으로 선행 저작물에 대한 침해자의 인식에 따라 의거성 판단이 결정되고 그외 학습데이터로 제공된 저작권자의 작품 규모, 채택된 인공지능 알고리즘이 의거성 판단에 영향을 미칠 것으로 생각된다. 학습데이터에 피침해 저작물이 중복되지 않고 양적으로 미미하게 포함된 경우라면 AI 이용자가 침해유발적인 프롬프트를 입력하였더라도 실제로 피침해 저작물과 의거관계가 인정되는 AI 산출물이 생성된다고 단정하기 어렵다. 개별 인공지능 알고리즘의 특성에 따른 의거성 판단의 문제는 후술하기로 한다.

피침해 저작물에 대한 침해자의 인식에 따라 의거성 판단이 달라질 수 있다는 점에 대해 일본 문화청 AI 저작권 보고서는 다음과 같이 정리하고 있다.³⁶⁾

학습데이터에 피침해 저작물이 포함된 상황에서 AI 이용자가 피침해 저작물을 인식하고 (침해유발적인) 프롬프트를 입력하여 해당 저작물의 창작적 표현을 가진 것을 생성한 경우 의거성이 인정되어 AI 이용자의 저작권 침해가 성립한다. 이러한 사례로는 이미지 자체를 프롬프트로 입력하는 경우(Image to Image 방식) 또는 피침해 저작물의 제목 등 특정 고유명사를 입력하는 경우를 예시하고 있다. 이와 같은 위 보고서의 결론에는 국내에서도 이견이 없을 것으로 생각된다.

그러나 AI 이용자가 피침해 저작물을 인식하지 못하였으나 AI 학습용 데이터에 해당 저작물이 포함된 경우 한국의 다수설적 견해와 위 일본 보고서의 견해는 상당한 차이를 보일 것으로 생각된다. 위 일본 보고서는 AI 이용자가 피침해 저작물(그 표현 내용)을 인식하지 못했으나 해당 생성형 AI의 개발·학습단계에서 해당 저작물이 학습된 경우 객관적으로 해당 저작물에 대한 접근이 인정되므로, 해당 생성형 AI를 이용하여 해당 저작물과 유사한 산출물이 생성되었다면 의거성이 추인되고 AI 이용자에 의한 저작권 침해가 성립될 수 있다고 보고 있다.³⁷⁾ 다만, 프

36) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 33면.

롬프트 입력 단계 및 출력 단계에서 적절한 필터링 조치를 하였다면 의거성을 부인할 수 있다고 한다. 이에 대해 국내 학설과 같이 의거성을 주관적인 요소로 파악하는 견해에서는 침해자인 이용자가 피침해 저작물의 존재를 알지 못한 경우 알지 못한 데 과실이 있다고 하더라도 의거관계가 성립하지 않는다고 보고 있다.³⁷⁾

이러한 견해의 차이는 침해에 대한 조치에서 큰 차이를 보이게 된다. 위 일본 보고서도 AI 이용자가 침해행위에 관계된 저작물을 인식하지 못한 경우 일반적으로 저작권 침해에 대한 고의·과실이 인정되지 않으므로 저작권 침해가 인정되더라도 허용되는 구체조치는 금지명령에 그치고 형사처벌이나 손해배상명령은 부인된다고 한다. 그러나 의거성 요건을 주관적으로 보는 견해에 따르면 의거성 자체가 부정되므로 금지청구도 허용될 수 없다. 위 일본 보고서 견해의 실제적 의의는 AI 산출물이 기존 저작물과 유사한 경우 AI 이용자의 인식과 무관하게 금지(삭제)청구의 대상이 되게 함으로써 저작권자 보호에 더 충실하다는 점에 있다고 생각된다.

(4) 개별 AI 알고리즘의 특수성에 따른 의거성 판단

생성형 AI는 하나의 단일한 알고리즘을 채택한 것이 아니기 때문에 이미지 생성 모델, LLM 유형마다 AI 알고리즘이 상이하다고 할 수 있다. 본 연구에서 개별 AI 알고리즘의 특수성에 따른 의거성 판단 논의는 AI 모델의 개발 내용을 분석하는 것이므로 침해 주체로서 AI 개발자의 역할을 주로 염두에 둔 것이다.

예컨대 GAN(Generative Adversarial Networks)은 모델 자체가 진짜와 거의 같은 가짜 데이터를 만드는 알고리즘을 채택하고 있으므로(저작권법적으로는 striking similarity), 만약 AI 개발자가 특정 저작권자의 작품들을 다량으로 수집하여 이들을 GAN의 학습데이터로 사용하였다면, GAN의 원리 및 제공된 학습데이터의 성격에 비추어 보아 AI 모델이 특정 저작권자의 작품에 의거하여 특정 저작권자의 작품과 유사한 이미지를 생성하였다고 추정할 수 있다고 생각된다.³⁸⁾ 다만 침해 주체를 누구로 보는가가 문제인데, 생성형 AI는 기본적으로 AI 이용자의 프롬프트 입력에 의해 작동되는 것이므로 이러한 사안에서는 AI 개발자와 AI 이용자가 공동으로 저

37) 박성호, 위 토론문, 2면은 이러한 견해를 수긍할 수 있다고 보고 있다.

38) 임철근, 서울중앙지법 지식재산권 실무연구회·한국지적재산권변호사협회 공동주최 연구회 토론문, 2024. 9.9.; 김형지, 서울중앙지법 지식재산권 실무연구회·한국지적재산권변호사협회 공동주최 연구회 토론문, 2024. 9.9.

39) 전웅준, ‘인공지능 관련 저작권 침해에 관한 시론’, 경영법률 제31권 제4호, 2021, 276면.

작권 침해 책임을 부담해야 할 것으로 보인다.

영상처리에 주로 사용되는 CNN(convolutional neural network)의 경우라면, 인공지능이 인식하는 특징(feature)은 형식적, 수식적인 관계에서 도출되는 것이고 의미적(semantic) 것과는 전혀 관계가 없으므로, 인공지능이 학습데이터로 제공된 그림에서 그 어떤 미감(표현)을 향수하였다고 보기 어렵다(비표현적 이용). 만약 학습데이터로서 여러 화가의 작품들이 랜덤하게 인공지능에게 제공되었다면, 원칙적으로 이들 그림 전부를 학습한 AI 모델은 특정 화가의 작품에 의거하여 새로운 그림을 생성하였다고 단정할 수 없다고 생각된다. 그러나 학습데이터가 주로 또는 전부 특정 작가의 작품들이었고 AI 알고리즘이 LoRA(Low Rank Adaptation)와 같이 특정 도메인의 데이터셋에 강하게 영향받도록 설계된 경우에는 AI 모델의 산출물은 해당 작가의 작품에 의거한다고 볼 수 있을 것이다.⁴⁰⁾

LLM, 인공지능망에 의한 자연어 처리에서 채택되고 있는 단어 임베딩 기술, Seq2Seq 기술 등은 단어 내지 문장의 특징들을 수치벡터로 압축치환하여 단어 내지 문장 간의 (통계적) 상관관계, 관계적 유사성, 의미적 연관성을 파악하는 정도에 이르렀으므로 어떤 관점에서 보면 인공지능이 문장의 맥락을 파악하는 것으로도 볼 수 있다(‘맥락’을 어떻게 정의하고 이해하는가에도 의존하는 문제이다). 자연어 처리 연구자들은 현재 NLP 기술이 ‘문맥’, ‘맥락’을 이해하는 수준에 도달하였다고 말하고 있어, 특정 영역의 인공지능 기술(NLP, NMT 등)은 어느 정도 의미론적 이해(=추론 능력)에 접근하였다고 보는 듯하다.⁴¹⁾ 그러나 이 경우에도 인공지능이

40) LoRA(Low-Rank Adaptation)는 대규모 사전 학습 AI 모델(LLM, 이미지 생성 모델 등)을 효율적으로 미세조정(fine-tuning)하는 기법이다. 이 방식은 기존 모델의 거대한 원본 가중치는 대부분 고정시킨 채, 모델의 특정 부분(주로 어텐션 레이어)에 매우 작은 크기의 ‘저랭크(low-rank)’ 행렬 두 개를 추가한다. 미세조정 시에는 이 작은 행렬들의 가중치만 학습시키므로, 전체 모델을 학습하는 것보다 훨씬 적은 계산 자원과 메모리으로도 빠르고 효과적으로 모델을 특정 작업이나 스타일에 맞게 조정할 수 있다. low-rank 행렬의 가중치를 학습할 때 특정 도메인의 데이터셋에 강하게 영향받도록 설계하는 것이 LoRA의 핵심 아이디어이다.

41) 인공지능 연구개발자들은 현재 NMT 기술의 수준이 ‘문맥, 맥락’을 이해하는 정도라고 말하고 있다. 이러한 판단은 ‘문맥, 맥락’을 어떻게 정의하는가에 달려 있으며, 본 연구의 경우 인공지능 산출물의 창작성, 의거성 여부 판단과 관련되어 있다. 뉴욕대 조경현 교수는 “신경망 기계번역은 딥 러닝을 적용해 문장의 맥락을 파악해 번역하는 방식”이라고 인터뷰한 바 있으며(조선일보, ‘넥타이도 못 매는 이 남자. AI 혁명 최전선에 서다’ 2021.7.3.자), 네이버 파파고 프로젝트의 김준석 리더는 “문장 벡터 속에는 문장 전체의 모든 정보, 즉, 단어의 의미, 단어의 순서, 문장의 구조, 단어들 간의 의존 관계 등 번역을 위해 필요한 모든 정보들이 녹아들어 간다. 그래서 문맥을 이해하는 자연스러운 번역 결과를 만들어 낼 수 있게 된다”라고 기술하고 있다(김준석, ‘일상생활 속으로 들

원본 저작물 표현(학습데이터)의 개념적 의미(semantic)나 개성을 이해하고 복제하였는지는 기술적으로 불분명하므로 ‘비표현적 이용’가능성이 존재한다고 생각된다. 인공지능 알고리즘이 문장 내지 단어의 전후 관계를 파악하고 단어들의 유사성 정도를 구분한다고 하더라도 이는 원칙적으로 구문론적(syntactic)인 이해에 그치고 아직 의미론적(semantic)인 이해에 도달하였다고 보기 어렵다.⁴²⁾ 그러므로 원칙적으로는 인공지능이 생성한 문장들이 원본 저작물과 유사하더라도 의거관계를 쉽게 인정해서는 안된다고 생각된다. 다만 이러한 견해는 침해 주체를 AI 개발자로 보아야 하는 상황을 염두에 둔 것이다. 전술한 바와 같이 AI 이용자가 침해유발적 프롬프트를 입력하여 원본 저작물과 유사한 AI 산출물을 생성하는 경우는 이에 해당하지 아니하며, 나아가 AI 개발자가 의도적으로 과적합(overfitting)된 AI 모델을 개발하는 경우도 위 결론에 포함되지 아니한다.

3. 실질적 유사성

실질적 유사성은 저작권 침해의 객관적 요건으로 이해되고 있다. AI 산출물에서 실질적 유사성은 암기 현상에 의하여 원저작물과 유사한 AI 산출물이 생성되는 경우와 의도적인 프롬프트에 의해 원저작물과 스타일, 화풍이 유사한 AI 산출물이 생성되는 경우에 주로 문제된다. 암기 현상의 경우 실질적 유사성 판단은 어렵지 아니하기 때문에(거의 동일함), 여기서 문제되는 것은 실질적 유사성이 아니라 고의적인 의도적인 침해인지, 의거성 여부일 것이다. 암기 현상은 향후 생성형 AI 기술이 극복해야 할 지점이고, 현재 연구된 내용에 따르면 암기 현상에 대응할 수 있는 조치로서 AI 개발시 중복된 학습데이터 제거, 모델규모의 최소화, 비정상적인 프롬프트 차단, 출력단계의 필터링 조치 등이 제안되고 있으므로, 앞으로도 암기 현상에 따른 실질적 유사성 여부는 크게 문제되지 않을 것으로 생각된다.

실제적으로 실질적 유사성 여부가 문제되는 경우는 확률분포를 추종하는 생성형 AI의 잠재적 모방성에 따라 원저작물의 스타일, 화풍, 작풍 등이 유사한 AI 산출물이 생성되는 경우라고 할 것이다. 저작권의 보호대상은 구체적으로 외부에 표현한 창작적인 표현이므로 아이디어, 스타일, 화풍, 작풍 등은 원칙적으로 실질적 유사

어은 기계 번역’, 국립국어원, 새국어생활 27권 4호, 66면, 2017).

42) 다만 LLM에서 의미론적 이해, 추론(reasoning) 능력은 다른 유형의 AI 모델에 비해 높다고 볼 수 있다. 단순한 확률에 의한 결과가 아니라 추론 능력에 의하여 산출물을 생성하였다는 점은 의거성 인정에 긍정적인 역할을 하는 요소이다.

성의 판단대상이 아니다.⁴³⁾ 작가의 전반적인 스타일(문체, 그림 기법)은 원칙적으로 저작권이 직접적으로 보호하지는 아니하므로 특정 작가의 화풍을 모방하라는 프롬프트(in the style of)에 의해 스타일이 모방되었다고 하더라도 이를 단정적으로 저작권 침해라고 보기는 어렵다.⁴⁴⁾ 그러나 아이디어와 창작적 표현은 구체적인 사안마다 개별적으로 판단되어야 한다. 예를 들어, 고호의 독특한 붓터치, 강렬한 색채와 같이 스타일의 구체적이고 독창적인 표현은 저작권의 보호대상이 될 수 있으므로, 저작권으로 보호되지 않는 ‘일반적 스타일과 저작권으로 보호받는 ‘독창적 스타일’의 경계가 아주 분명하다고 볼 수는 없다.

이러한 실질적 유사성에 대한 법리가 AI 산출물에 의한 저작권 침해에서도 그대로 적용될 수 있다는 점에 대해 국내외적으로 큰 이견은 없는 것으로 보인다.⁴⁵⁾ 미국에서 진행되고 있는 AI소송에서도 전통적인 실질적 유사성 법리가 강조된 결정이 발견된다. Andersen v. Stability AI 사건에서 담당판사 Orrick은, 원고들의 ‘AI 산출물은 파생저작물’이라는 주장에 대해 제3자가 저작권을 가지는 학습콘텐츠와 실질적으로 유사한지에 대한 입증이 부족하다고 판시하였다.⁴⁶⁾ Orrick 판사는 생성형 AI의 ‘모든’ 출력 이미지가 입력데이터의 파생저작물일 수 밖에 없다는 원고들의 주장을 받아들이지 아니하였다. 그 이유는 ‘모든’ 학습데이터가 실제로 저작권의 보호를 받고 있거나 ‘모든’ 산출물이 저작권이 있는 학습데이터에 의존(rely upon)하였다는 주장이 설득력이 없기 때문이다. 만약 위와 같은 조건이 모든 충족된 상황에서도 원고들은 원저작물과 특정 출력 이미지 사이에 보호받는 표현의 실질적 유사성을 여전히 입증하여야 한다고 Orrick 판사는 지적하였다. 원고들은 소장에서 “산출물이 학습데이터의 특정 이미지와 근접하게 일치(close match)할 가능성은 낮다”고 진술한 바 있는데, 피고들은 이러한 원고의 진술을 원용하여 복제(copying) 내지 실질적 유사성을 부정하고 있는 상황이다.

43) 박유선, ‘생성형 인공지능(AI)의 스타일 모방의 저작권 침해에 관한 연구’, 산업재산권 제76호, 한국지식재산학회, 2023, 440면.

44) 스타일의 모방에 따른 저작권침해 문제는 대체로 AI 산출단계의 문제가 아니라 AI 학습단계의 문제에 해당한다.

45) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 33면; 신재호, 2023 전국 저작권법 학자대회 토론집, 62면; 이철남, 2023 전국 저작권법 학자대회 토론집, 78면; 차상욱, 2023 전국 저작권법 학자대회 토론집, 97면; 최진원, 2023 전국 저작권법 학자대회 토론집, 103면; 미국 AI 소송에서도 AI 산출물에 대한 실질적 유사성에 대한 주장은 종래의 법리에 따르는 것으로 보인다.

46) Andersen v. Stability AI Ltd., No. 3:23-cv-00201, 2023 WL 7132064, at 12 (N.D. Cal. Oct. 30, 2023).

관련하여, 검토 방향이 상이하기는 하지만, 인공지능 산출물을 ‘약한 저작권 보호(thin copyright protection)’이론에 의해 보호하자는 전제에서 법적으로 보호받는 인공지능 산출물에 대한 침해 판단기준은 실질적 유사성에서 현저한 유사성(striking similarity)으로 정책적으로 상향할 필요가 있다는 견해가 있다.⁴⁷⁾ 이러한 정책적 견해에 따르면 일부 영역의 저작물(즉 표현력이 높은 인공지능 산출물)에 대한 침해판단의 기준은 종래의 실질적 유사성 법리와는 다르게 된다.

IV. 저작권 침해 책임의 귀속 주체

1. 직접 침해자 v. 간접침해자

저작권법 제123조 제1항은 “저작권 그 밖에 이 법에 따라 보호되는 권리를 가진 자는 그 권리를 침해하는 자에 대하여 침해의 정지를 청구할 수 있으며, 그 권리를 침해할 우려가 있는 자에 대하여 침해의 예방 또는 손해배상의 담보를 청구할 수 있다.”고 규정한다. 이러한 문언 형식에 따르면 ‘권리를 침해하는 자’가 저작권 침해 책임의 귀속 주체라고 할 수 있다. 학설은 ‘권리를 침해하는 자’를 직접 침해자로 이해하고 원칙적으로 OSP 등의 간접 침해자(방조행위자)는 금지청구의 상대방에서 제외하나⁴⁸⁾ 판례는 침해행위의 방조하는 간접 침해자도 금지청구의 상대방으로 보고 있다.⁴⁹⁾ 다만 판례가 간접 침해자를 바로 침해 주체로 이해하는지 아니면 간접 침해자를 직접 침해자와 동등하게 평가할 수 있는 상황에 한하여 침해 주체로 이해하는지는 다소 불분명하다.

따라서 이러한 국내 실무에 따르면 침해 주체는 저작권 침해의 직접 침해자와 간접 침해자를 모두 포함하여 직접 침해와 간접 침해를 구분할 실익이 감소하나, 학설에 의하면 침해 주체 여부를 판단하기 위해서는 저작권 침해의 직접 침해행위를 명확히 특정하여야 한다. 생성형 AI와 같이 AI 개발자(서비스제공자)와 AI 이용

47) 손승우, ‘인공지능 창작물의 저작권 보호’, 정보법학 제20권 제3호, 2016, 106면.

48) 박성호, 저작권법, 박영사, 2014, 722~727면.

49) 대법원 2007. 1. 25. 선고 2005다11626 판결 [가처분이의] “소리바다 서비스 이용자들의 복제권 침해행위를 방조하는 채무자들 역시 그 침해정지청구의 상대방이 될 수 있다고 할 것”이라고 판시하여 방조행위자를 금지청구의 상대방으로 인정한 원심인 서울고등법원 2005. 1. 12. 선고 2003나21140 판결을 그대로 유지하였다.

자가 분리되는 상황이라면 직접 프롬프트를 입력하여 어떠한 산출물(저작권 침해 관점에서는 침해물)을 생성하는 AI 이용자가 직접 침해자가 된다고 보아야 하고, AI 개발자(서비스제공자)에 대해서는 간접 침해자(방조행위자 내지 공동불법행위자)에 해당하는지 여부 나아가 일정한 경우 직접 침해자에 해당하는지 여부가 다 투여지게 된다.

2. AI 개발자(서비스제공자) v. AI 이용자

(1) 외국의 동향

일본 문화청 AI 저작권 보고서는 물리적인 행위주체인 AI 이용자가 저작권 침해 행위의 주체로서 저작권 침해책임을 부담하는 것이 원칙이지만 일본 학설의 법리인 규범적 책임론에 따라 일정한 경우 물리적인 행위 주체 이외의 자가 규범적인 행위 주체로서 저작권 책임을 지는 경우가 있다고 설명한다.⁵⁰⁾ 그리고 AI 개발자(서비스 제공자)가 규범적인 행위주체가 인정되는 사례에 관하여 ① 특정한 생성형 AI를 이용하였을 때 침해물이 고빈도로 생성되는 경우 AI 사업자(개발자, 서비스제공자)가 침해 주체로 평가될 가능성이 높고 ② AI 사업자가 생성형 AI를 개발·제공 시에 해당 생성형 AI가 기존 저작물의 유사물을 생성할 개연성이 높음을 인식하고 있음에도 불구하고 해당 유사물의 생성을 방지하는 조치를 취하지 않은 경우 AI 사업자가 침해 주체로 평가될 가능성이 높다고 설명하고 있다. 위 일본 문화청 AI 저작권 보고서의 전체 취지를 볼 때 ①번 사안은 LoRA 기법과 같이 기초 모델을 추가학습할 때 해당 학습데이터셋에 강하게 영향받는 산출물을 생성하도록 미세조정하는 사례를 염두에 두었다고 해석되고 ②번 사안은 AI 사업자가 기존 저작물의 유사물이 생성되지 않도록 해야 할 의무를 부담하는 특정한 상황에서 그러한 의무를 이행하지 않는 경우에 해당한다고 생각된다(부작위에 의한 침해).

위 일본 문화청 AI 저작권 보고서는 직접 침해자, 간접 침해자라는 용어를 사용하지 않고 규범적 행위주체로 평가되는 자가 금지명령을 부담한다고 보고 있는데, ①번 사안은 AI 사업자가 적극적으로 특정한 AI 모델을 의도하여 침해적인 산출물을 생성하도록 한 것이므로 직접 침해자 성격이 강하고 ②번 사안은 AI 사업자가 저작권 침해 방지 조치를 소홀히 한 경우이므로 방조적 성격 즉 간접 침해의 성격

50) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 36면.

을 띤다. 미국에서 진행되는 AI 소송에서는 대체로 AI 사업자가 피고로 특정되면서 AI 학습단계에서는 학습데이터 무단 복제에 따른 직접 침해자로, AI 산출단계에서는 AI 이용자의 직접 침해행위에 가공하는 간접 침해자(기여 침해, 대위침해, 유도침해)로 주장되고 있다.⁵¹⁾

(2) 침해 주체(직접 침해자)에 대한 판단

국내 실무는 간접 침해자에게도 금지명령을 부과할 수 있으므로 직접 침해자와 간접 침해를 구별할 실익이 그리 크지 않다. 그러나 방조 행위자인 간접 침해자는 금지명령의 내용, 폐기청구의 가부, 손해배상액의 산정 등에서 직접 침해자와 구별될 수 있으므로, 일단 직접 침해를 침해 주체로 보고 생성형 AI에서 직접 침해를 판단하는 것이 바람직하다고 생각된다.

대체적인 국내외 견해는 AI 산출단계에서 직접 침해자는 (침해유발적인) 프롬프트를 입력한 AI 이용자로 보고 있다. 일본 문화청 AI 저작권 보고서가 원칙적으로 AI 이용자를 저작권 침해의 행위주체로 보고 있음을 전술한 바와 같고, 국내에서도 AI 이용자가 직접 침해에 대한 책임을 부담한다는 견해가 주장되고 있다.⁵²⁾ AI 이용자를 직접 침해자로 볼 수 있는 행위 유형으로서는 ① AI 이용자가 특정 저작물을 인식하고 이를 모방하라는 침해유발적인 프롬프트를 입력하는 경우 ② 대규모 AI 모델이 가질 수 있는 암기(memorization) 현상을 의도적으로 유발하는 프롬프트를 입력하는 경우를 들 수 있다. AI 개발자(서비스제공자)의 입장을 살펴 보면,

51) 예컨대, *The New York Times Company v. Microsoft Corporation et al.*, 1:23-cv-11195, (S.D.N.Y.) 소장 63면은 피고들의 기여 책임(contributory copyright infringement)를 주장하고, *Andersen v. Stability AI Ltd.*, 3:23-cv-00201, (N.D. Cal.) 2차 소장(2024. 10.31.자) 57면은 유도 침해(inducement of copyright infringement)를 주장한다.

52) 김경숙, 2023 전국 저작권법 학자대회 자료집, 20면(“원저작물과 실질적으로 유사하여 2차적 저작물작성권 또는 복제권을 침해하는 생성물이라면 이 생성물을 생성하고 공중이 이용할 수 있도록 한 이용자가 직접침해에 대한 책임을 지고”); 박성호, 2023 전국 저작권법 학자대회 자료집, 54면(“인공지능 이용자가 그 행위주체이므로 인공지능 개발자가 아닌 그 이용자가 인공지능 생성물의 저작권 침해 책임의 주체가 되어야 한다”); 신재호, 2023 전국 저작권법 학자대회 자료집, 62면(“오히려 혜택을 보는 생성형 AI 이용자에게 자신이 생성한 산출물에 대한 저작권 침해의 위험을 부담토록 하는 것이 공평해 보입니다”); 정태호, 2023 전국 저작권법 학자대회 자료집, 90면(“AI는 생성물의 창작성을 위한 도구처럼 보일 수 있고 이 경우에는 그 이용자가 저작권 침해를 실제적으로 유도한 사람이라고 볼 수도 있으므로, 이러한 이용자에 대한 침해 책임을 어떻게 다룰 것인지에 대해서도 향후 연구가 필요할 것으로 생각함”);

일반적인 파운데이션 모델의 경우 AI 개발자는 AI 산출물 생성에 의한 직접 침해자로 보기 어렵다고 생각된다. 침해의 직접적 행위자는 침해 유발적인 프롬프트를 입력한 AI 이용자이고 AI 개발자는 피침해저작물 생성에 대한 인식도 없기 때문이다.

미국 소송에서도 AI 개발자는 AI 산출단계에서 AI 이용자의 직접 침해를 용이하게 하여 주는 간접 침해자로 이론구성되어 있다.⁵³⁾ 또한 AI 개발자가 저작권 침해물 생성을 방지하는 필터링 등 기술적 조치를 취한 경우에도 AI 개발자에게 직접 침해 책임을 묻기 어렵다고 생각된다. 침해 구조가 부작위범과 같기 때문에 방조 책임 등의 간접 침해를 묻는 것이 자연스럽기 때문이다. 그러나 일본 문화청 AI 저작권 보고서가 지적하듯이 AI 개발자가 미세 조정 과정에서 특정 저작자의 저작물 위주로 AI 추가학습을 하여 의도적인 과적합(overfitting) 현상을 발생시키는 AI 모델을 만든 경우에는 적극적인 작위 행위로 인한 직접 침해자성이 긍정된다고 판단된다. 이러한 사례는 전술한 미국 법원의 조지 칼린 사건에서 발견된 바 있다.⁵⁴⁾

3. 저작권법상 OSP 책임

생성형 AI가 저작권 침해물을 생성하는 경우 AI 서비스제공자에게 일종의 OSP 내지 ISP 책임을 부담시켜 저작권 침해물 생성을 방지하는 기술적 조치를 취하도록 요구할 것인지 검토할 필요가 있다. 저작권법은 ‘온라인서비스제공자’의 정의는 제2조에서, ‘온라인서비스제공자의 책임’은 제102조의 책임제한 규정 및 제103조의 notice and takedown 규정으로 이원화하고 있으므로, 이들 규정의 적용 가부를 살펴보기로 한다.

먼저 생성형 AI 서비스제공자는 저작권법 제2조 제30호의 ‘온라인서비스제공자’에는 해당할 것으로 본다. 위 조항은 온라인서비스제공자를 가. 이용자가 선택한 저작물등을 그 내용의 수정 없이 이용자가 지정한 지점 사이에서 정보통신망을 통

53) 예컨대, The New York Times Company v. Microsoft Corporation et al., 1:23-cv-11195, (S.D.N.Y.) 소장 63면은 피고들의 기여 책임(contributory copyright infringement)을 주장한다(“In the alternative, to the extent an end-user may be liable as a direct infringer based on output of the GPT-based products, Defendants materially contributed to and directly assisted with the direct infringement perpetrated by end-users of the GPT-based products by way of: (i) jointly-developing LLM models capable of distributing unlicensed copies of Times Works to end-users; (ii) building and training the GPT LLMs using Times Works”).

54) Main Sequence, Ltd. et al v. Dudesy, LLC et al., US District Court for the Central District of California (2:24-cv-00711).

하여 전달하기 위하여 송신하거나 경로를 지정하거나 연결을 제공하는 자, 나. 이용자들이 정보통신망에 접속하거나 정보통신망을 통하여 저작물등을 복제·전송할 수 있도록 서비스를 제공하거나 그를 위한 설비를 제공 또는 운영하는 자로 구분하고 있는데, 위 가.호는 인터넷접속서비스(단순도관)제공자를, 나.호는 인터넷 접속서비스제공자를 포함한 캐싱, 호스팅, 정보검색서비스제공자를 포괄한 것으로 해석된다고 한다.⁵⁵⁾ 현재 생성형 AI 서비스제공자는 이용자의 프롬프트에 따라 저작물을 자체 클라우드에서 생성하고(다만 PC기반 서비스는 제외) 이를 이용자에게 복제·전송하는 역할을 수행하고 있으므로, 개념상 나.호 온라인서비스제공자에 해당하는 것으로 해석할 수 있다고 생각된다. 주류적 견해는 생성형 AI 서비스제공자가 저작권법상 온라인서비스제공자에 해당하지 않는 것으로 보고 있으나,⁵⁶⁾ 현행 저작권법 제2조 제30호의 온라인서비스제공자의 정의는 제102조의 개별 온라인서비스제공자의 개념과 일치한다고 보기 어렵기 때문에 비록 전통적 의미의 중개자에는 해당하지는 아니하나 문리해석상 생성형 AI 서비스제공자는 저작권법 제2조 제30호의 온라인서비스제공자의 범위에 속할 수 있다고 판단된다. 나아가 일부 생성형 AI 서비스는 이용자가 생성한 콘텐츠를 게시하거나 공유하는 서비스를 제공하고 있는데,⁵⁷⁾ 이러한 유형의 서비스는 생성형 AI 서비스에서 쉽게 결합할 수 있거나 서비스 구성상 필수적으로 채택해야 할 요소로 볼 수 있으므로, 정의 조항 자체에서 생성형 AI 서비스제공자를 배제할 필요는 없다고 보인다.

제102조를 살펴보면, 생성형 AI(챗봇, 이미지 생성 툴)가 제1항 제3호의 저장서비스 또는 검색서비스에 해당하는지 문제된다. 이는 생성형 AI 서비스제공자가 AI 학습에 사용된 콘텐츠를 학습완료 후에도 자신의 지배범위인 AI 시스템에서 저장·관리하는 것으로 볼 수 있는지에 관한 문제이다. 전술한 바와 같이 기술적 관점에서 볼 때 생성형 AI는 학습데이터를 학습완료된 모델 내부에서 저장하는 것이 아

55) 이규홍, 온주 저작권법 제2조 제30호. 현행 OSP 정의는 제102조의 4가지 유형과 정확히 일치하지 않아 개선을 요한다.

56) 유계환, 김윤명, ‘주요국의 AI 규제 동향 및 시사점’, IP Focus 제2024-06, 한국지식재산연구원, 2024, 21면은 “현행법상 AI 서비스 제공자가 저작권법상 OSP에 해당할 가능성은 높지 않음. AI 서비스를 제공하는 자신의 지배영역인 게시판 등에 이용자가 생성한 콘텐츠 등의 정보를 게시할 수 있는 서비스를 제공하는 방식은 아니므로 OSP로 보기 어려움. 다만 정보검색과 연계된 서비스 방식이라는 점에서는 OSP로 볼 여지가 있으며, 이 경우 저작권법상 규정된 OSP의 일 유형으로 보아 AI서비스제공자가 이용자의 이용행위에 대한 면책이 주장가능 할 것임”이라고 설명하고 있다.

57) 예컨대, 미드저니(Midjourney)의 explore page(<https://www.midjourney.com/explore?tab=top>). (2025. 3.31. 접속).

니라 개별 프롬프트에 대응하여 각기 다른 생성물을 출력하고 있는 것이므로 저장 서비스에 해당한다고 보기 어렵고, RAG 기술이 결합되지 않는 한 생성형 AI를 검색서비스로 보기도 어렵다.

다만, 저장서비스 여부에 관하여는 암기(memorization) 현상 등을 들어 실질적으로 AI 모델이 알고리즘적 내지 수학적으로 원본 학습데이터의 일부를 저장하는 것으로 볼 수 있다는 견해가 힘을 얻고 있다. 예컨대, Sarah Andersen v. Stability AI 사건에서 원고는 Stable Diffusion 모델이 학습데이터로 사용된 저작물의 사본을 압축된 형태로 저장하고 있고(Compressed Copy 주장), Stable Diffusion 모델이 학습 이미지를 수학적 내지 알고리즘적인 표현 형태로 포함하면서 이를 통해 학습 이미지의 일부 또는 전부를 재구성할 수 있다는 주장을 하고 있다(algorithmic or mathematical representation 주장). 이에 대해 법원은 위 주장을 바로 기각하지 않고 원고에게 해당 주장을 명확히 하고 이를 뒷받침하는 구체적인 증거를 제시하도록 명령하였다.⁵⁸⁾ 기계학습의 원리로 보면 AI 모델은 통계적 처리를 거친 파라미터 숫자만을 포함하고 있을 뿐이므로 위와 같은 원고의 주장은 수학적으로는 타당하지 않다고 할 수 있다. 그러나 암기현상, 과적합현상 등 모방성이 현저한 AI 산출물이 생성되는 현실을 볼 때 규범적으로는 AI 모델이 압축된 사본 형태로 저작물을 저장하고 있고 이를 수학적 내지 통계적으로 재구성하여 원본 학습이미지를 재현할 수 있다는 주장도 소송과정에서 충분히 심리될 필요가 있다고 생각된다.

또한 제103조는 OSP에 대한 notice and takedown 절차를 규정하고 있는데, 특정 산출물이 저작권 침해물임을 들어 특정 산출물이 더 이상 생성되지 않도록 출력단계에서 필터링을 하여 달라는 요구는 기술적으로 가능할 것으로 생각된다(출력 필터링).⁵⁹⁾ 그러나 이미 학습이 완료된 AI 모델에 대해 학습데이터 일부를 제거하라는 요청은 특정 학습데이터를 삭제한다고 해서 AI 모델이 해당 데이터를 ‘잊는’ 것이 아니기 때문에 큰 실효성이 없고 AI 모델의 관련 파라미터를 수동적으로 조정하여 저작권 침해물이 생성되지 않도록 요구하는 것은 현재 기술로는 거의 불가능한 것으로 보이므로 제103조의 취지와 부합하지 않는다. 최근 AI 모델에 대한 재훈련이 없어도 유해한 생성물을 삭제하여 주는 기술로서 머신 언러닝(machine unlearning) 연구가 활발히 진행되고 있으나 현재 기술 수준으로는 전체적인 성능을 유지하면서 학습데이터에서 특정 데이터를 삭제한 것과 동일한 결과를 얻기 위

58) Sarah Andersen et al. v. Stability AI Ltd. et al., No. 23-cv-00201-WHO (N.D. Cal. Aug. 12, 2024).

59) 개인정보 보호위원회, 인공지능 개발·서비스를 위한 공개된 개인정보 처리 안내서, 2024, 21면.

해 모델 파라미터를 사후적으로 조정하는 것은 매우 어렵다고 알려져 있다.⁶⁰⁾ 학습데이터에서 특정 저작물을 제외하여 달라는 요구의 궁극적인 모습은 해당 저작물을 제거한 후 남은 전체 학습데이터로 AI 모델을 다시 학습하는 것이다.⁶¹⁾ 그러나 이 방법은 학습 비용이 크고 시간도 많이 소요되며 특정 저작물을 제거하여 달라는 요청이 빈번할수록 AI 개발에 큰 부담이 되기 때문에 현실적이지 못하다. 이러한 단점을 보완하기 위해 최초 학습단계에서부터 SISA(Sharding, Isolation, Slicing, Aggregation) 기법을 채택하여, 특정 데이터의 제거 요청이 왔을 때 전체 데이터를 재학습하는 것이 아니라 해당 데이터가 포함된 조각(shard)만 부분적으로 재학습할 수 있도록 AI 모델을 개발하는 방법도 제안되었다.⁶²⁾ 위 분야에 관한 연구는 이제 시작 단계에 있어서 아직 머신 언리닝에 관한 현실적인 솔루션은 없는 것으로 보인다.

V. 법률 개정의 필요성 여부

1. 기본적인 견해

전술한 내용을 종합하면, AI 산출단계의 저작권 침해 문제에 관하여 입법적으로 추가할 사항은 특별히 없는 것으로 판단된다. 다만 AI 모델의 원리상 의거성 입증 이 어려우므로 학습데이터에 피침해 저작물이 존재하고 AI 산출물이 피침해 저작물과 매우 유사한 경우 입증책임을 전환하여 침해자 격인 AI 이용자 또는 AI 개발자에게 의거성 부존재에 대한 입증책임을 부담시키는 것이 타당하다는 견해가 유력하게 주장되고 있다. 또한 정책적으로 AI 개발자(서비스제공자)에게 저작권 침해물 생성을 방지하도록 조치해야 하는 경우 저작권법의 OSP 책임 규정을 적용할 필요가 있는데 문언해석상 이의 적용이 어렵다고 한다면 입법적으로 AI 개발자(서비스제공자)에 대한 책임(제한) 규정을 도입하는 것을 검토할 수 있다. 마지막으로 AI 학습단계 내지 AI 산출단계에서 저작권 침해가 확인되는 경우 AI 모델 자체가 침해행위로 조성된 물건으로 평가되어 금지 및 폐기명령의 대상이 되는지, 학습데

60) 개인정보 보호위원회, 앞의 글, 22면.

61) 이를 Naive Retraining이라고 한다.

62) Jie Xu et al., "Machine Unlearning: Solutions and Challenges", IEEE Transactions on Emerging Topics in Computational Intelligence 2024, 4면.

이터에서 피침해 저작물의 opt-out을 허용하여야 하는지, 침해 예방 조치로서 필터링 의무는 어떻게 구현되어야 하는지 등을 검토할 필요가 있다고 생각된다.

2. 의거성 관련 입증책임 전환

생성형 AI의 산출단계에서 저작권 침해가 문제되는 대표적인 유형은 AI 이용자가 피침해 저작물을 인식하였고 학습데이터에도 피침해 저작물이 존재하는 경우이다. 이 경우 원고 저작권자는 피고 AI 이용자의 의거 사실 및 피침해 저작물의 학습데이터 포함 사실을 입증하여야 한다. 그러나 의거 사실은 피고 AI 이용자의 지배영역에 있는 사안이고 피침해 저작물의 학습데이터 포함 사실은 AI 개발자의 지배영역에 있는 사안이므로, 현실적으로 원고 저작권자가 이를 입증하는 것은 매우 어렵다. AI 저작권 소송의 경우 법률요건분류설에 따라 일률적으로 원고 저작권자에게 입증책임을 부담시키는 것보다는, 이와 같은 특수한 사정을 고려하여 AI 산출물이 피침해 저작물과 유사하다면 의거성의 입증책임을 전환하여 AI 이용자에게 의거사실의 부존재를 입증하여야 한다는 견해가 유력하다.⁶³⁾ 이에 대한 소송법적 근거로는 위험영역설을 발전시킨 이론인 증거거리설을 생각해 볼 수 있다. 이 설의 핵심은 증거와의 거리, 증명의 난이도, 금반언, 사실존재의 개연성, 나아가 실체법의 입법취지 등 실질적 요소를 고려하여 증명책임을 분배하자는 것이다. 위 견해는 주장책임과 증명책임을 소거를 분리하는 것을 전제로 하고 있으므로,⁶⁴⁾ 이 경우에도 의거성에 대한 주장책임은 원고 저작권자가 부담해야 할 것이다. 만약 이와 같은 소송법상의 해석론이 지지를 받지 못한다고 하면 입법적으로 의거성 관련 입증책임을 전환하는 것을 고려할 수 있다. 한편, 증명책임을 전환은 실체법상 책임요건의 완화를 뜻한다는 점에서 특별한 정당화를 요구하므로,⁶⁵⁾ 증명책임을 전환에 대한 논의를 본격화하는 것보다는 조금 더 기술 발전의 추이를 지켜보는 것이 바람직하다는 견해도 존재한다.⁶⁶⁾

63) 박성호, “AI 생성물의 저작권 침해 책임과 이시다 미노리[石田穰]의 ‘증거거리설’”, 법률신문, 2023; 박성호, 위 발제문, 11면.

64) 박성호, 위 발제문, 9면.

65) 이동진, 위험영역설과 증거법적 보증책임, 저스티스, 2013, 186면.

66) 김형지, 위 토론문, 6면.

3. 저작권법상 OSP 책임 관련

생성형 AI 서비스가 대중화되면 그에 따른 AI 서비스제공자의 법적 책임도 비례화될 필요가 있다. 전술한 바와 같이, 생성형 AI 서비스는 기술적 관점에서만 보면 저장서비스 내지 검색서비스에 해당하지 아니하여(단 RAG 결합 모델은 제외) 저작권법상 OSP 책임(제한) 규정을 적용하기 어렵다. 이를 대비하여 저작권법상 OSP 책임 규정과 유사하게, 입법적으로 AI 서비스제공자의 책임제한 및 notice and takedown 절차에 의한 저작권 침해 방지 조치를 규정하는 것으로 고려할 수 있다.

이를 구체적으로 살펴보면, 제102조 책임제한과 관련하여 RAG 모델은 외부 DB에서 검색을 하여 산출물을 생성하는 구조를 취하고 있으므로 저장형(외부 DB에 저작물이 저장된 것으로 볼 수 있는 경우) 또는 검색형 서비스로 보아 제102조 제1항 제3호의 요건을 적용할 수 있는 가능성이 있다고 생각된다. 반면 RAG를 채택하지 않은 일반적인 생성형 AI 서비스는 호스팅 내지 정보검색서비스라고 보기 어렵기 때문에 제102조 제1항 제3호를 직접 적용하기는 어렵다. 그러나 전술한 바와 같이, 규범적 관점에서 AI 모델은 압축된 사본 형태로 저작물을 저장하고 있는 것이고 이를 수학적 내지 통계적으로 재구성하여 원본 저작물을 재현하는 것이라는 주장이 있는 상황임을 고려한다면, 생성형 AI 서비스를 호스팅서비스와 유사한 성격으로 보아 제102조 제1항 제3호와 유사하게 책임면제 요건을 정책적으로 규정할 수 있을 것으로 생각된다. 나아가 제103조의 notice & takedown 절차도 유사하게 응용할 수 있을 것으로 보인다. 기술발전의 추이를 살펴보아야 하겠지만, 후술하는 생성형 AI 서비스제공자의 필터링 조치(프롬프트 필터링, 출력 필터링)를 제102조 및 제103조의 요건의 ‘저작물의 복제·전송의 중단’에 대응시킬 수 있을 것이다.

4. AI 모델에 대한 금지 및 폐기 청구 관련

본 연구의 주제는 아니나 AI 학습단계에서 저작권 침해가 인정되는 경우 학습완료된 AI 모델이 침해행위로 조성된 물건으로 평가되어 금지 및 폐기 청구의 대상이 되는지 검토할 필요가 있다. 저작권법 제123조 제1항은 저작권자는 저작권 침해자에 대해 침해의 정지를 청구할 수 있다고 규정하며 제2항은 ‘침해행위에 의하여 만들어진 물건’의 폐기나 그 밖의 필요한 조치를 청구할 수 있다고 규정하고 있다. 위 규정에 근거하여 폐기청구의 대상이 되기 위해서는 AI 모델 내지 AI 시스템이 ‘저작권 침해행위에 의하여 만들어진 물건’에 해당하여야 한다. 이에 대해 살펴

보면, 기술적 원리로 볼 때 수치벡터를 학습하여 파라미터로 구현된 AI 모델은 원형적인 모습에서는 학습데이터를 저장하지 않으며 학습데이터의 단순 변형물로 보기도 어렵기 때문에 일반적으로 AI 모델 자체는 학습데이터의 복제물(2차적저작물)이라고 보기는 어려울 것으로 생각된다. 즉 수치벡터를 이용하여 학습을 하고 학습이 끝나면 모든 정보를 AI 모델의 파라미터 형태로 저장하는 AI 학습 알고리즘을 고려한다면 일반적으로 AI 모델 자체는 ‘표현’의 복제라는 관점에서 학습데이터의 복제물(2차적저작물)이라고 할 수 없기 때문에 금지 및 폐기 청구의 대상이 되기는 어렵다고 판단된다.⁶⁷⁾

한편, 추가학습을 통해 의도적으로 특정 저작물을 침해하기 위한 만들어진 AI 모델과 같이(전술한 바와 같이 이 경우에는 AI 개발자가 침해자가 된다), AI 모델이 학습데이터인 저작물과 유사한 산출물을 높은 확률로 생성하는 경우에는 학습데이터인 저작물의 핵심적 특징이 AI 모델에 구현되었다고 볼 수 있기 때문에 규범적 관점에서 AI 모델이 학습데이터 저작물의 복제물로 평가될 가능성이 있다. 이러한 경우에는 AI 모델 자체도 금지 및 폐기 청구의 대상이 될 수 있다고 생각된다.⁶⁸⁾ 위 Sarah Andersen v. Stability AI 사건에서 제기된, AI 모델이 압축된 사본 형태로 저작물을 저장하고 있고 이를 수학적 내지 통계적으로 재구성하여 원본 학습이미지를 재현할 수 있다는 주장도 같은 맥락에 해당한다. AI 모델은 향후 다양한 형태로 발전할 수 있으므로, 여러 가능성을 열어 놓고 AI 모델의 침해적 요소에 대해 탄력적으로 사고할 필요가 있다.

침해가 인정되는 경우 학습데이터에서 피침해 저작물을 제거하는 opt-out 청구를

-
- 67) 일본 문화청 AI 저작권 보고서는 “AI 학습을 통해 만들어진 학습된 모델은 학습에 이용된 저작물의 복제물이라고는 할 수 없는 경우가 많다고 생각되고, 「침해 행위를 조성한 것」 또는 「침해 행위로 작성된 것」에 해당하지는 않는다고 판단된다. 또한, 일반적으로 AI 학습을 통해 만들어진 학습된 모델은 학습 데이터인 저작물과 유사하지 않은 것을 생성할 수 있다고 여겨지므로, 「오로지 침해 행위에 제공된 기계 혹은 기구」에도 해당하지 않는다고 판단된다. 따라서 AI 학습을 통해 만들어진 학습된 모델에 대한 폐기 청구는 일반적으로 인정되지 않을 것으로 보인다.”라고 설명한다. 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 30면.
- 68) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 30면, “해당 학습된 모델이 학습데이터인 저작물과 유사성이 있는 생성물을 높은 확률로 생성하는 상태에 있는 경우 등은 학습데이터인 저작물의 본질적 특징이 해당 학습된 모델에 간존하고 있다고 할 수 있고, 법적으로 해당 학습된 모델이 학습데이터인 저작물의 복제물이라고 평가될 수도 있다. 이러한 경우 「침해 행위를 조성한 것」 또는 「침해 행위로 작성된 것」으로서 해당 학습된 모델의 폐기 청구가 인정될 수도 있다”라고 설명한다.

허용할 것인지 문제되는데, 이러한 조치는 저작권법상 장래 침해 행위 예방에 필요한 조치로 인정될 수 있다고 생각된다.⁶⁹⁾ 관련하여, EU AI Act는 범용 인공지능 모델의 경우 AI 공급자(provider)에게 학습콘텐츠에 관한 상세 요약서를 작성·공개하도록 요구하고 있다(제53조 제1항 제d호). 위 조항은 EU DSM 저작권 지침(Directive 2019/790) 제4조 제3항에서 규정한, 저작권자의 TDM에 관한 권리 유보(opt-out)를 용이하게 실현시켜 줄 수 있는 도구로 해석되는바,⁷⁰⁾ EU 법체계는 저작권 침해물 산출 여부와 관계없이 폭넓게 저작권자의 opt-out 청구를 수용한다고 볼 수 있다.

침해 예방 조치의 적절한 예로서는 피침해 저작물과 유사한 산출물이 생성되지 않도록 적절한 필터링 조치를 취하는 것을 들 수 있다. 필터링 조치는 프롬프트 입력단계에서 특정 프롬프트를 필터링 하는 조치(프롬프트 필터)와 AI 산출물 출력단계에서 유사 저작물 필터링을 하는 조치(출력 필터) 등이 제시된다.⁷¹⁾

이와 같은 침해 구제 조치는 원칙적으로 법원의 재량사항이므로 입법적으로 규정하는 것보다는 가이드라인과 같은 해석 매뉴얼로서 융통성이 있게 제시되는 것이 바람직하다고 생각된다. 나아가 이러한 조치가 기술 혁신의 저해요소가 되거나 이용자의 표현의 자유를 침해하지 않도록 유념할 필요가 있다.

69) 일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024, 30면, 35면, 각 “저작권 침해 대상이 된 해당 저작물이 장래에 AI 학습에 이용됨에 따라 복제 등의 침해 행위가 새롭게 발생할 개연성이 높다고 할 수 있는 경우는 해당 AI 학습에 이용되는 학습용 데이터셋에서 해당 저작물을 제거하는 것이 장래 침해 행위 예방에 필요한 조치 청구로 인정될 수 있다고 생각된다”, “AI 개발사업자가 규범적 행위주체로서 저작권 침해 책임을 부담하는 경우, 해당 AI 개발사업자에 대해서는 저작권 침해 예방에 필요한 조치로서, 침해물을 생성한 생성형 AI 개발에 이용된 데이터셋이 이후에도 AI 개발에 이용될 개연성이 높은 경우 해당 데이터셋에서 해당 침해행위에 관계된 저작물등의 폐기를 청구하는 것이 가능하다고 생각된다”라고 설명한다.

70) João Pedro Quintais, ‘Generative AI, Copyright and the AI Act’, Kluwer Copyright Blog(<https://copyrightblog.kluweriplaw.com/2023/05/09/generative-ai-copyright-and-the-ai-act/>) 2023(2025.1.16. 최종 접속), “This is the provision that most clearly aims at enabling opt-out under Article 4 CDSM Directive.” 이라고 설명한다.

71) 개인정보 보호위원회, 인공지능 개발·서비스를 위한 공개된 개인정보 처리 안내서, 2024, 21면

VI. 결론

본 연구는 AI 산출물에 의한 기존 저작권 침해의 문제를 고찰하기 위해 우선 생성형 AI의 기술적 특성에 관하여 ‘생성형 AI의 확률적 모방성’과 ‘초과 모방성 현상’이라는 개념을 제시하였다. ‘생성형 AI의 확률적 모방성’은 AI 모델이 학습데이터의 분포를 파악하여 이를 확률적으로 모방하는 특성을 법적 관점에서 해석한 것이며 ‘초과 모방성 현상’은 생성형 AI가 일반적인 모방성을 넘어 의도적으로 저작권 침해물을 생성하는 현상을 개념화한 것이다. 이와 같은 관점하에 본 연구는 크게 다음의 세 가지 사항을 검토하였다.

첫째, AI의 확률적 모방성은 ‘학습데이터의 분포를 따르는’ 기술적 특성에서 비롯되는데, 이러한 모방성은 기술발전에 의해 다양한 형태로 나타날 수 있다. 이와 같은 AI 산출물에 대한 저작권 침해 여부를 판단하기 위해서는 생성형 AI의 산출 과정에 대한 과학적·기술적 검토가 요구된다. 그러나 AI 모델 내부 구조가 블랙박스과 같이 작동함에 따라 침해 과정을 직접적으로 입증하기가 어렵다는 점이 특히 의거성의 입증에 어렵게 하고 있다. 이러한 의거성 입증의 어려움을 해결하기 위해 학습데이터에 피침해 저작물이 존재하고 AI 산출물이 피침해 저작물과 매우 유사한 경우, 증거거리설에 기초하여 의거성에 대한 입증책임을 전환하는 방안을 고려할 수 있다고 보았다.

둘째, AI 이용자와 AI 개발자의 책임 귀속 문제는 침해행위의 구조적 특성과 밀접하게 연결된다. 이용자가 침해 유발적인 프롬프트를 입력하여 특정 저작물과 유사한 결과물을 얻은 경우, 이는 이용자의 직접 침해로 볼 가능성이 높다. 반면, 기술적으로 특정 저작물의 모방을 유도하는 AI 모델(e.g. 과적합된 모델)을 의도적으로 제공한 개발자는 직접 혹은 공동 침해 책임을 부담할 수 있다. 따라서 개별 사안 단위로 AI 이용자 또는 AI 개발자의 침해 주체성 여부를 검토하는 법적·정책적 관점이 필요하다. 같은 맥락에서 AI 모델 자체가 침해행위로 조성된 물건으로서 금지 및 폐기 청구의 대상이 되는지도 검토할 수 있다. 기본적으로 AI 모델은 파라미터의 형태로 존재하기 때문에 학습데이터의 복제물로 볼 수 없지만, 의도적으로 특정 저작물을 모방하도록 설계된 AI 모델의 경우에는 규범적 관점에서 금지 및 폐기 청구의 대상이 될 가능성이 있다.

셋째, AI 산출물의 저작권 침해를 방지하고 책임 소재를 명확히 하기 위해서는 입증책임 전환, 필터링 및 모니터링 기술, OSP(온라인서비스제공자)에 대한 통지·삭

제 절차 등 추가적인 규제 장치의 도입이 검토될 수 있다. 그러나 이러한 방안이 과도하게 적용될 경우 기술 발전이 위축되고 표현의 자유에 대한 제약으로 이어질 수 있으므로 새로운 입법적 제안은 기존 법리와 제도를 존중하는 전제에서 신중히 고려되어야 한다고 생각된다.

* 논문최초투고일: 2025년 03월 31일; 논문심사(수정)일: 2025년 04월 14일; 논문게재확정일: 2025년 04월 20일

참고문헌

단행본

박성호, 저작권법(제3판), 박영사, 2023.

오승중, 저작권법(제5판), 박영사, 2020.

이해완, 저작권법(제3판), 박영사, 2015.

국내문헌

개인정보보호위원회, 인공지능개발·서비스를 위한 공개된 개인정보처리 안내서, 2024.

김경숙, 인공지능생성물과 저작권 문제, IT와법연구제27집, 2023.

박성호, “AI 생성물의 저작권 침해 책임과 이시다미노리[石田穰]의 ‘증거거리설’”, 법률신문, 2023.

박유선, ‘생성형 인공지능(AI)의 스타일 모방의 저작권 침해에 관한 연구’, 산업재산권 제76호, 한국지식재산학회, 2023.

서울중앙지법 지식재산권실무연구회·한국지적재산권변호사협회 공동주최 연구회 발제문 및 토론문, 2024. 9.9.

손승우, ‘인공지능 창작물의 저작권 보호’, 정보법학 제20권제3호, 2016.

유계환, 김윤명, ‘주요국의 AI 규제동향 및 시사점’, IP Focus 제2024-06, 한국지식재산연구원, 2024.

이규홍, 온주 저작권법 제2조 제30호.

이동진, ‘위험영역설과 증거법적 보증책임’, 저스티스, 2013.

임원선, ‘저작권침해유형과 침해판단기준에 대한 검토’, 계간저작권(통권131호), 2020.

전웅준, ‘인공지능관련 저작권침해에 관한 시론’, 경영법률 제31권 제4호, 2021.

_____, ‘ChatGPT 등 생성형 인공지능 모델이 제기하는 저작권 관련 쟁점’, 데이터와 지식재산(강원대학교IP 사업단·지속가능한혁신과법센터·한국디지털재산법학회 2023년 7월27일 공동학술대회자료집).

한국저작권위원회, 2023 전국 저작권 법학자 대회 토론집.

문체부, 생성형AI 안내서, 2023.

외국문헌

일본 문화청 문화심의회 저작권분과회 법제도소위원회, AI と著作権に関する考え方について, 2024.

A. Feder Cooper, James Grimmelmman, “The Files are in the Computer: On Copyright, Memorization, and Generative AI”. Chicago-Kent Law Review(Forthcoming), 2024.

Antonia Karamolegkou et al., Copyright Violations and Large Language Models, 2023.

Giorgio Franceschelli, Claudia Cevenini, Mirco Musolesi, “Training Foundation Models as Data Compression: On Information, Model Weights and Copyright Law”, 2024.

Gowthami Somepalli et al., Diffusion Art or Digital Forgery? Investigating Data Replication in Diffusion Models, 2022.

Jie Xu et al., “Machine Unlearning: Solutions and Challenges”, IEEE Transactions on Emerging Topics in Computational Intelligence 2024.

João Pedro Quintais, ‘Generative AI, Copyright and the AI Act’, Kluwer Copyright Blog

Matthew Sag, “Copyright Safety for Generative AI”, 61 Hous. L. Rev. 295, 2023.

Nicholas Carlini et al., Extracting Training Data from Diffusion Models, 2023.

Nicholas Carlini et al., Quantifying Memorization Across Neural Language Models, 2023.

Patrick Lewis et al., ‘Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks’, 2020.

USCO, Copyright and Artificial Intelligence Part 2: Copyrightability, January 2025.

Abstract

This study introduces the concepts of “probabilistic mimicry of generative AI” and “excessive mimicry” to examine copyright infringement in AI-generated outputs. “Probabilistic mimicry” refers to the legal interpretation of how AI models probabilistically imitate their training data distribution, while “excessive mimicry” describes situations where generative AI intentionally produces infringing works beyond normal imitation.

From this perspective, the study examines three key issues:

First, AI’s probabilistic mimicry stems from its technical feature of following training data distribution, which may manifest differently as technology evolves. Determining copyright infringement in AI outputs requires scientific analysis of the generation process. However, AI models function as black boxes, making it difficult to prove infringement directly or establish substantial similarity. To address this, the study suggests that when an infringed work exists in the training data and the AI output closely resembles it, the burden of proving substantial similarity might shift based on “probative proximity.”

Second, attributing responsibility between AI users and developers relates directly to infringement characteristics. Users who input prompts resulting in outputs similar to copyrighted works likely bear direct liability. Conversely, developers who intentionally create models that induce mimicry of specific works (e.g., overfitted models) may face direct or joint liability. This requires case-by-case legal and policy analysis. Additionally, it’s worth considering whether AI models themselves—though not direct reproductions of training data—could face injunctions or destruction if designed to imitate specific copyrighted works.

Third, preventing AI copyright infringement may require additional measures like burden of proof adjustments, filtering technologies, and notice-and-takedown procedures for online service providers. However, excessive regulation could impede technological progress and limit expression. Therefore, new legislative proposals should carefully balance these concerns while respecting existing legal frameworks.

Keywords: Generative AI, copyright infringement, mimicry, overfitting, memorization, regurgitation